

머신러닝 첫걸음

역사와 로드맵 · 문제 정식화와 세 갈래 분류 · 파이프라인과 사전지식 리뷰

Machine Learning 1 · 1주차

한국과학영재학교 (KSA)

Chapter 1

이번 주차 개요

이 챕터를 마치면:

- 1943~2025 연표 위에서 1969년과 2012년을 가로지른 두 “AI 겨울”의 원인을 각 한 문장으로 설명.
- 문제를 입력 x · 출력 y · 가설 h 로 **정식화**하고, “라벨이 있는가? 보상이 있는가?” 두 질문만으로 **세 갈래** 분류.
- 회귀 vs 분류를 “같은 모델, 다른 출력”(항등 링크 vs 시그모이드)으로 설명하고, “손실함수 J 를 정의하고 최소화한다”는 뼈대를 이름으로 부름.
- 수집 → 정제 → EDA → 모델링 → 평가 파이프라인을 끝까지 돌리고, 결측치·중복·이상치와 데이터 누수를 잡는 순서를 지킴.

세 차시 한 줄

1.1 역사·로드맵 **1.2** 문제 정의와 세 갈래 **1.3** 데이터 파이프라인 + 세 가지 수학

1.1 아주 짧은 역사와 이번 학기 로드맵

이 두 과목이 다루는 질문

2012년 ImageNet 대회에서 **AlexNet** 이 등장하기 전까지, “이 사진에 고양이가 있는가”를 알려주는 방법은 **사람이 직접 특징을 설계**하는 것이었다 — 가장자리 검출기, 색 히스토그램, 특정 모양의 필터를 손으로 조합해 “고양이스러움”을 수치로 정의하려 했다.

AlexNet은 그런 손설계 없이, 수백만 장의 사진과 정답 라벨만 보고 **스스로 무엇을 봐야 하는지 학습**해서 기존 방법들을 압도적인 차이로 이겼다.


**정답이 있는 데이터로부터, 규칙을 사람이 짜는 대신
기계가 데이터에서 직접 찾아내게 하려면 어떻게 해야 하는가?**

아주 짧은 역사 — 퍼셉트론에서 LLM까지

- 이번 학기에 배울 아이디어들이 **언제, 어떤 순서로** 등장했는지 알면 “왜 지금 이 순서로 배우는가”가 더 잘 보인다.
- 흥미로운 점: 역사가 직선으로 발전한 게 아니라 **침체기(“AI 겨울”)**를 두 번이나 거쳤다는 것.

연도	사건
1943	맥컬록-피터즈 신경원 모형 — “수학적으로 학습 가능한 뉴런”의 시작
1950s	퍼셉트론(단층 신경망) 등장
1969	민스키·페퍼트(1969)의 XOR 한계 증명 → 첫 AI 겨울 (Ch. 9)
1986	역전파(Rumelhart·Hinton·Williams, 1986) 재발견 → 다층 학습 가능
1998	LeCun의 CNN(LeNet), 손글씨 숫자 인식 성공 (Ch. 10)
2012	AlexNet, ImageNet 압승 — 딥러닝 시대의 시작
2013	word2vec · VAE — 표현학습 · 생성모델의 현대적 형태 (Ch. 14, 15)
2017	Transformer(“Attention Is All You Need”) (Ch. 12)
2022	ChatGPT — 사전학습 + RLHF로 조정된 대규모 언어모델의 대중화
2025	GPT-4o · Gemini · Claude 등 멀티모달 LLM이 스마트폰 · 워크스테이션에 내장

연표를 “연도 축” 위에 그리면



1969년 XOR 증명과 1986년 역전파 사이의 17년이 가장 넓은 간격으로 보인다.

- 1943→1969의 **26년**, 1969→1986의 **17년** 같은 긴 침체기가 역사의 상당 부분을 차지.
- **2012년 이후에만** 5년·5년·3년 간격이 반복된다.
- 표만 보면 안 와닿는 “직선이 아니다”가 숫자로 보인다.
- 실습: 연표의 간격을 직접 계산하고, 2012년 이전 vs 이후의 **평균 간격**을 비교.

1969 — 첫 겨울의 시작

- 민스키·페퍼트가 단층 퍼셉트론은 **XOR**(배타적 논리합, “둘 중 정확히 하나만 참일 때만 참”)조차 표현할 수 없음을 **수학적으로 증명**.
- “아직 알고리즘이 부족하다”가 아니라, “이 구조로는 **원리적으로 불가능하다**”는 훨씬 강한 주장.
- 결과: 연구비가 끊기고 연구자 수가 급감 — “**첫 AI 겨울**”이 10년 넘게 이어짐.

흥미로운 점

답(층을 여러 개 쌓으면 XOR도 표현 가능)은 이미 알려진 수학 안에 있었지만, “그 여러 층을 어떻게 학습시킬 것인가”라는 **계산적 문제**가 안 풀려서 겨울이 그토록 길어졌다.

1986 — 역전파가 거울을 끝내다

- 러멜하트·힌튼·윌리엄스(1986)가 역전파를 (재)발견.
- 여러 층을 가진 신경망도 **경사하강법으로 실제로 학습**시킬 수 있다는 것이 드러나.
- 정확히 1969년의 한계(XOR)를 **실제로 풀어내는** 방법이었다.

앞에서 다시 만난다

Ch. 9에서 이 알고리즘을 손으로 유도해본다. 그 유도에 등장하는 **연쇄법칙**은 1.3절에서 손으로 직접 계산해볼 바로 그 도구와 **정확히 같은** 것이다.

2012 — 딥러닝 시대의 개막

- AlexNet은 1986년의 역전파, 1998년의 CNN(LeNet)과 근본적으로 **다른 새 수학을 쓴 게 아니었다.**
- 결정적 차이: **GPU로 병렬 연산**하게 되면서 계산량이 감당 가능해졌고, 인터넷 덕분에 ImageNet 같은 **대규모 라벨링된 데이터셋**이 존재했다.

교훈

“좋은 아이디어가 있어도 데이터와 계산 자원이 받쳐주지 않으면 묻힐 수 있다.”

- 1969년의 증명 하나가 연구를 십수 년간 위축시켰다: **이론적 한계를 정확히 아는 것이** 때로는 “무작정 더 시도해보다” 강력하다 — 동시에 역전파는 바로 그 한계를 정확히 풀어낸 해법이였다.

반복되는 패턴 — 돌파구의 정체

다수의 “돌파구”는 새 수학이 아니다

이미 있던 아이디어(경사하강법, 연쇄법칙, 확률론)를 더 큰 데이터 · 더 많은 계산 자원 위에서 다시 조합한 것이다.

- 1969 XOR 증명 → 17년 → 1986 역전파(바로 XOR의 해법).
- 1998 LeNet → 2012 AlexNet(같은 수학, GPU + ImageNet).
- **이번 학기 목표:** 그 재사용되는 기본 아이디어 자체를 손으로 짚어보는 것.

“왜 2012년이었을까” — 첫 번째 축: 계산

- AlexNet은 2012년 최신 GPU 두 장(NVIDIA GTX 280)으로 **약 5~11일** 걸리던 학습.
- 같은 모델을 당시 CPU 클러스터로 돌리면 **월 단위로** 늘어나는 것이 일반적 추정.
- “학습이 불가능했다”가 아니라 “**학기가 끝나기 전에 끝나지 않았다**” — 연구의 속도 경쟁에서는 사실상 같은 것.

연상해야 할 도구: 무어의 법칙

집적회로의 성능이 대략 2년마다 배가. 고정된 “한 학기 안에 끝나야 하는” 학습 시간 예산이 그대로라면, 1998년에는 LeNet 크기의 모델을 돌리는 데 거의 다 썼겠지만, 2012년에는 같은 예산 안에 **충과 폭이 훨씬 큰 모델**을 돌려볼 수 있었다.

신경망 연구에서 “구조”와 “계산”은 한 쪽만 커져서는 안 되는 한 쌍 (Ch. 9 역전파의 연산 비용을 손으로 셀 때 다시 등장).

“왜 2012년이었을까” — 두 번째 축: 데이터

- ImageNet: 약 **140만 장**의 이미지에 **1000개 클래스** 라벨을 붙인 데이터셋 (2009년 공개).
- 중요한 점: 라벨 대부분이 **일반인이 직접 매긴 것** — 인터넷과 클라우드소싱(아마존 메카니컬 터크) 플랫폼이 없었다면, 100만 장 넘는 사진마다 “고양이”·“셔터”를 붙이는 비용이 **연구비를 압도했을** 것이다.

“140만 장”과 “2장 GPU”의 동시 출현

AlexNet의 승리는 두 축이 **동시에** 갖춰진 2012년에만 가능했던 것 — 어느 하나만 있었어도 그 해의 결과물은 달라졌다.

이번 학기 내내 등장하는 모든 모델이 이 “두 축” 위에 선다.

세 번째 교훈: 라벨의 형태가 모델의 형태를 결정한다

- 2012년의 패러다임 전환은 “**사진 + 범주 라벨**”이라는 **지도학습**의 가장 전형적인 형태 위에서 일어났다.
- 정답이 없는 데이터만 있을 때(비지도학습, Ch. 14~15), 보상 신호만 있을 때(강화학습, ML2)에는 같은 GPU·데이터 속도 중요하지만,

“어떤 신호로 학습하는가”에 따라 최적의 모델 가족 자체가 달라진다.

- 1.2절에서 “**데이터의 형태가 문제를 결정한다**”고 할 때 뜻하는 바가 정확히 이것.
- 부수 효과: “우리 데이터가 작으니 신경망은 아직 이르다” 같은 실무 판단이 왜 흔한지도 자연스럽게 이해된다.

이번 학기 로드맵 — 8주 × 2 블록

Block A (Ch. 2-7): 고전 ML — 신경망 없이도 강력; 지금도 정형(tabular) 데이터에서 자주 이긴다.

- 2 회귀: 선형·로지스틱, 경사하강법, PR-AUC
- 3 생성 관점 분류: 나이브베이즈와 GDA
- 4 거리 기반·클러스터링: kNN, k-means, GMM/EM
- 5 SVM과 커널: 마진, 소프트 마진, 커널 트릭
- 6 정규화와 모델 선택: L1/L2, 교차검증
- 7 트리: 결정트리, 랜덤 포레스트, GBDT+SHAP
- 8 Block A 캡스톤 + 중간고사 대비

Block B (Ch. 9-16): 신경망 → 생성모델

- 9 신경망 기초: 퍼셉트론 한계, 역전파, 정규화
- 10 CNN: 합성곱, 풀링, 탐지·분할·전이학습
- 11 시퀀스 모델: RNN, BPTT, LSTM/GRU
- 12 어텐션과 트랜스포머: QKV, Multi-Head
- 13 그래프 표현학습: Random Walk, Node2Vec, P
- 14 표현학습: PCA, word2vec, 임베딩 활용(RAG)
- 15 잠재변수 생성모델: EM/GMM, VAE, GAN, Diffus
- 16 Block B 캡스톤 + ML1 총정리

매 장 시작 전에 이 표를 펼쳐 “지금 어디서 무엇을 배우고, 어디로 이어지는지”를 확인하는 습관. (부록 Ch. 17: LLM)

ML1과 ML2의 관계

- 강화학습과 로봇 시뮬레이션은 이번 학기(ML1)에서는 전혀 다루지 않는다.
- ML1과 ML2는 서로 독립된 과목으로 설계. ML2가 이 주제를 처음부터 끝까지 전담.
- ML1을 먼저 듣지 않아도 ML2를 바로 들을 수 있다 — ML2 1주차에 필요한 신경망 기초를 압축해서 다시 짚어주기 때문.

Block B의 내용 한 줄

역전파의 원리를 손으로 유도(Ch. 9)한 뒤 CNN(Ch. 10)까지 기본기를 다지고, 시퀀스 모델→Transformer→LLM 계보(Ch. 11~13)를 훑은 뒤, 비지도학습(PCA·임베딩)과 VAE·GAN·Diffusion까지 생성모델로 마무리(Ch. 14~15).

이번 학기 쓸 도구들 (수학 + 코드)

도구	이 학기에서 쓰이는 곳	언제 처음 등장
numpy	모든 실습의 기본. $w^T x$, 행렬곱, 경사하강법 반복	Ch. 2
matplotlib	손실 곡선, 결정경계, t-SNE/PCA 시각화	Ch. 2
pandas	EDA, 결측치 처리, 그룹별 통계	Ch. 6 (1.3절 예습)
scikit-learn	분류·회귀·클러스터링 모델의 표준 인터페이스	Ch. 2
PyTorch	신경망·CNN·시퀀스 모델·VAE/GAN	Ch. 9
Hugging Face	LLM 프롬프팅, 사전학습 모델 활용	Ch. 17
gymnasium	(ML2에서) 강화학습 환경 — ML1에서는 등장하지 않음	—

이 목록을 “이번 학기에 **새로 배워야 할 것**”이 아니라, “이 학기 내내 **반복해서 손이 갈 것**”으로 읽는다 — 완벽히 외우는 것보다, **필요할 때 10초 만에 꺼내 쓸 수 있는 것**이 목표.

실습 노트북의 역할

- 각 절마다 붙는 실습 노트북(Colab 배지)은 “개념을 손으로 확인”에 집중.
- 이번 절의 노트북: 연표의 “격차”를 직접 계산, 2012년 이전의 AI 겨울을 시각화, 도구 목록의 라이브러리가 실제로 import 되는지 확인.

미리 강조

“어떤 모델을 쓰느냐”보다 “도구가 손에 익었느냐”가 이 학기 전반부의 진짜 성패를 가른다.

자주 하는 실수: “최신 모델”부터 잡기

- 가장 흔한 실패 패턴: Transformer(Ch. 12) · LLM(Ch. 17)이 “산업에서 쓰는 것”이라는 이유로 **Block A**를 건너뛰고 **Ch. 12**로 직행.
- 실제 경험: 작은 네트워크의 손실이 안 떨어지는데 (a) 데이터 스케일? (b) 학습률? (c) 구조 자체의 문제인지 구분 못 하고 “일단 층을 늘려보자”로 끝남.
- 한 달 뒤엔 **원인 모를 손실 곡선**만 남는다.

디버깅이 불가능해지는 이유

Ch. 6의 “train/val/test 분리”와 Ch. 2의 “손실함수를 손으로 한 번 계산” 같은 **기초 도구가 없기** 때문이다.

실수의 본질 — 그리고 로드맵이란

- 본질: “최신 = 어렵다 = 배우면 실력이 된다”는 착각.
- 실제로 최신 모델 논문의 한 줄 한 줄은 전부 Block A·B 기초 (경사하강법, 시그모이드, 교차 엔트로피, 어텐션)의 **변형**.
- 기초가 없으면 논문을 “읽는” 게 아니라 “**눈으로 훑어보는**” 것에 그침.
- 반대로 Block A를 충실히 마치면 Transformer 논문을 읽을 때 “이 단락은 어텐션의 QKV를 다루는데, 12.1절의 QKV랑 같다”로 **바로 위치를 잡을 수 있다**.

로드맵은 “배울 것의 목록”이 아니라 “어디서 어떤 기초가 다시 쓰이는지”를 보여주는 지도.

실습: 나만의 학기 타임라인 만들기 (10분)

연표만 보는 것으로는 “나”의 계획이 안 된다 — 아래 3개를 노트로 직접 짜기 (이 3개가 학기 내내 되돌아볼 “나만의 로드맵”):

- 1 **연표 다시 쓰기:** 1943~2025 연표를 보지 않고 “이 사건이 왜 결정적이었는가”를 각 한 문장으로 다시 쓰기 (막히면 1.2절 “왜?” 설명을 다시 보는 것이 정상).
- 2 **교차점 찾기:** (a) 팀 프로젝트 발표가 있는 주간, (b) 새로 등장하는 수학 도구가 가장 많은 장, (c) 1.3절의 세 가지 수학(내적·연쇄법칙·베이즈)이 **전부 한 번에** 등장하는 장을 각각 하나씩 찾기.
- 3 **도구 점검:** 지금 import 해볼 수 있는 것 (numpy·matplotlib·pandas) vs 아직 설치/설명이 필요한 것 (PyTorch, Hugging Face) 나눠보기.

힌트: (2)의 답

(b) = **Chapter 9** — 역전파는 연쇄법칙을 수직 층에 반복 적용. (c) = **Chapter 3** — 나이브베이즈는 조건부 확률 + 베이즈 정리 + 가우시안 밀도의 내적 형태. 맞췄다면, 1.3절의 수학이 “개별 장의 도구”가 아니라 “학기 전체를 관통하는 도구”라는 감각이 잡힌 것.

확인 문제: 연표와 로드맵 (a)(b)

이 절의 내용만으로 답해볼 것 (답은 바로 아래).

- (a) “2012년 AlexNet 승리의 원인은 앞서 나온 CNN(LeNet, 1998)이 수학적으로 더 좋았기 때문.” — **이 주장에 반대하려면 어떤 근거 두 가지를 꺼내야 하는가?**
- (b) “첫 AI 겨울이 10년 넘게 길었던 이유는, 답이 이미 알려진 수학 안에 있었기 때문이다.” — **인과가 잘못되었다면 어떻게 고쳐야 하는가?**

답

(a) (1) AlexNet은 LeNet과 근본적으로 다른 새 수학을 쓰지 않았고, (2) 결정적 차이는 **GPU 병렬 연산 + 대규모 라벨링 데이터셋의 동시 출현** — “수학의 우위”가 아니라 “계산+데이터” 축이 2012년에야 갖춰진 것이 핵심 근거.

(b) **인과가 반전.** “답이 알려진 수학 안에 있었다”는 사실은 겨울이 더 **길어진** 이유. 진짜 이유는 “여러 층을 학습시킬 계산적 문제(역전파)가 1986년 재발견까지 17년간 안 풀려 있었다”.

확인 문제 (c) + 자주 묻는 질문 1

- (c) “정형 데이터에서 지금도 신경망보다 자주 이긴다”는 말은 어느 블록에 해당하는가? 한 문장으로 설명.
- 답: **Block A(Ch. 2-7)** — 회귀·나이브베이지스·kNN·SVM·정규화·트리 모델이 정형 데이터에서 아직까지도 신경망을 이기는 경우가 흔하다는 것이 Block A를 학기 초반에 배치한 이유.

Q. ML1과 ML2를 둘 다 들어야 하나요?

- 아니다 — 두 과목은 완전히 독립 설계.
- ML1: 데이터사이언스 → 고전 ML → 딥러닝 → 생성모델. ML2: 강화학습·로봇 시뮬레이션만 전담.
- 어느 쪽을 먼저 들어도, 혹은 하나만 들어도 상관없다.

자주 묻는 질문 2: Block A를 건너뛰면?

Q. Block A(고전 ML)를 안 배우고 Block B(신경망)로 바로 넘어가면 안 되나요?

- 이론적으로는 되지만, 권장하지 않는다.
- Ch. 6 정규화, Ch. 7 트리 앙상블의 “**편향-분산 트레이드오프**”와 “train/val/test 분리”는 신경망에도 **그대로 적용** — Ch. 9의 드롭아웃·배치정규화는 정확히 같은 원리.
- 지금도 정형 데이터에서는 고전 ML이 신경망을 이기는 경우가 흔해서 **실무에서 바로 쓸모가** 있다.

Q. 수학이 약한데 따라갈 수 있나요?

- 1.3절의 세 가지 수학(내적, 연쇄법칙, 베이즈 정리)이 **사실상 전부**. 그 이상의 새 수학 도구는 거의 등장하지 않고,
- 대신 그 세 가지를 **점점 더 복잡한 상황에 반복 적용**하는 것이 이번 학기의 실제 난이도. 낯선 표기가 나올 때마다 1.3절을 참고하는 습관이면 충분.

자주 묻는 질문 3: 순서와 깊이

Q. ML2를 먼저 듣고 ML1을 나중에 들어도 되나요?

- **된다** — 상호 선행 과목 관계가 아니라 완전 독립 설계. ML2는 1주차에 신경망 기초를 압축해서 다시 짚어줌.
- 다만 ML1의 “정형 데이터에서 왜 아직도 고전 ML이 강한가” 실무 감각은 ML2(로봇·강화학습 중심)에서는 다루지 않음 — 산업 현장에서 둘 다 쓸 예정이라면 **순서와 무관하게 두 과목 다 권함**.

Q. 모든 장을 같은 깊이로 배워야 하나요?

- **아니다** — 목표는 16개 장을 동일하게 깊게 이해하는 것이 아니라, 매 장에서 “ **h 는 무엇이고, J 는 무엇이며, 어떻게 최소화하는가**”라는 세 가지 질문에 답할 수 있는 정도.
- 특정 장(예: Ch. 12)이 흥미로우면 더 깊게 파도 좋지만, 그때도 Ch. 9의 역전파가 먼저 잡혀 있어야 “깊이 파는 것”과 “그저 보는 것”을 스스로 구분할 수 있다.

Python이 약한데? + 이번 차시 마무리

Q. Python이 약한데 코드를 따라갈 수 있나요?

- 기본 문법(변수, for 루프, 함수, 리스트)만 있으면 충분.
- 이 책은 의도적으로 개념 코드를 **순수 Python**(리스트 + for 루프)으로 짰 경우가 많음 — “벡터 연산 뒤에 숨은 for 루프를 직접 눈으로 보기”가 우선.
- scikit-learn·PyTorch의 호출 이름을 외우는 것이 목표가 아니라, “**이 함수가 안에서 뭘 하는가**”를 알고 쓰는 것이 목표.

1.1 마무리

어떤 모델을 쓸지보다 먼저 물어야 할 질문은 항상 같다: **이 문제는 무엇을 데이터로 갖고 있고, 무엇을 맞히고 싶은가.**

1.2 머신러닝 문제 정식화와 세 갈래 분류

문제를 푸는 게 아니라, 먼저 “정의”부터

“어떤 알고리즘을 쓸까”부터 고민하는 것이 흔한 착각 — 실전에서는 **순서가 반대**. 알고리즘보다 먼저 문제 자체를 세 가지로 정의한다:

- ① **입력** x — 무엇을 **특징(feature)**으로? (예: 집의 평수, 방 개수, 지어진 연도)
- ② **출력** y — 무엇을 맞히나? **연속값(회귀)**인가 **범주(분류)**인가?
- ③ **가설** h — 입력 $\rightarrow$ 출력 함수를 어떤 **형태**로? (직선? 트리? 신경망?)

집값 예측: x =평수·방·위치, y =거래가 (**연속값**), h =**선형 함수**부터. 세 가지가 안 정해지면 학습 목표 자체가 불분명.

스팸 필터: x =제목의 ‘무료’·발신자·느낌표 수 (**특징의 벡터**), y =스팸(1)/정상(0)(**범주**). x, y 의 **형태(연속 vs 범주)**가 다르니 **손실함수도 달라야** 한다.

x 를 잘못 고르면(예: 스팸 필터에 “도착 요일”만 특징으로) 아무리 좋은 알고리즘을 써도 h 가 배울 **신호 자체가 없다**. “어떤 알고리즘이 가장 정확한가”보다 “이 특징들이 애초에 **정답과 관련이 있는가**”가 **항상 먼저 물어야 할 질문**.

학습(training)의 표기: m 과 (i)

학습의 정의

주어진 데이터 $(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})$ 에 대해 $h(x^{(i)})$ 가 $y^{(i)}$ 에 최대한 가깝도록 h 의 파라미터를 조정하는 과정.

- 위 첨자 (i) = “ i 번째 데이터 샘플” (이 학기 내내 반복되는 표기). $x^{(3)}$ = 세 번째 집의 특징 벡터.
- m = 학습 데이터의 **전체 개수**(샘플 수).
- 예: 집 200채면 $m = 200$, $x^{(37)}$ = 37번째 집의 (평수, 방 개수, 연식), $y^{(37)}$ = 그 집의 실제 거래가.

학습은 “학습 데이터를 외우는 것”이 아니라, **본 적 없는 201번째 집에도 일반화되는 규칙을 찾는 것** — 일반화 능력의 엄밀한 검증은 Ch. 6.

“정의를 먼저”의 역사: 세 시대

“먼저 문제를 정의하라”가 추상적 교훈이 아니라 실제 역사에서 어떤 결과를 만들었는지 세 시대로:

- **1959 사무엘의 체커스 (Samuel, 1959):** “머신러닝”이라는 말을 현대적 의미로 만든 논문. 기계를 “플레이하게” 하는 게 아니라, “**이 판국이 얼마나 좋은가**(평가함수, y)를 **학습**하는 문제”로 **재정의** — 판국 수가 사람이 규칙을 전부 쓸 수 없을 만큼 많으므로 기계가 self-play에서 배우게. (이 재정의가 40년 뒤 **AlphaGo** 계보의 출발점.)
- **1970s 전문가 시스템 (MYCIN, 1976) — 역의 길:** 의사들이 “X 증상이면 Y를 의심하라”는 **규칙을 수백 개 직접** 써넣은 감염 진단. 좁은 영역에서 전문의에 필적했으나, 규칙 **유지보수가 사람에게**, 새 영역마다 수천 개를 다시 사람이 — 교훈: “정의(=모든 규칙을 사람이 쓰는 것)가 사람에 의존할수록, 상한도 사람의 역량에 갇히고 유지비도 비싸진다.”
- **1998 LeNet과 우편 자동화 (Ch. 10):** “입력: 손글씨 숫자 이미지, 출력: 어느 숫자인가”. 사람이 형상(입력/출력)과 특징을 설계하고, “**특징을 어떻게 쓸 것인가**”는 기계가 데이터에서 **학습** — USPS 우편 분류에서 “사람은 문제만 정의하고 **기계가 세부 규칙을 배운다**” 경로가 **확장성에 이긴 첫 대규모 증거**.

세 시대가 주는 메시지

“정의를 먼저 하라”는 **매핑($x \rightarrow y$)의 어느 부분을 사람이 쓰고, 어느 부분을 기계가 배우게 할 것인가를 정한다**는 뜻. “평가함수를 쓴다” → “**학습한다**”(1959), “**인식 규칙을 쓴다**” → “**특징을 학습한다**”(1998)

“정의를 바꾸는” 순간 불가능했던 문제가 가능해졌다.

실습: 세 문제를 스스로 정식화해보기

각 시나리오에 대해 x (입력 특징), y (출력), h 의 대략적 형태(직선? 규칙 기반? “이번 학기에 배울 것”)를 노트에 적어보기.

시나리오	힌트 (x / y / 갈래)
1. 신용카드 이상거래 탐지 매 결제가 사기인지를 즉시 판단	x =결제 금액·시간·가맹점 종류, y =사기/정상(범주) → 분류
2. 뉴스 기사 주제 자동 분류 정치/경제/스포츠/문화 태그	x =기사 텍스트(나중에 단어 빈도·임베딩으로), y =4개 범주 중 하나 → 분류(다중 클래스)
3. 공장 설비 잔여수명 예측 진동·온도·가동시간 센서	x =센서 측정값들, y =남은 일수(숫자) → 회귀

세 문제 모두 “정답 라벨이 있고 y 가 범주냐 숫자냐”라는 같은 질문 하나로 갈린다 — 이번 학기 내내 새 문제를 만날 때마다 가장 먼저 꺼내 쓸 도구.

“정답”은 언제나 사람이 정한다: 라벨의 책임 I

$y^{(37)}$ 이 “그 집의 실제 거래가”라고 썼는데, “실제”를 오래 바라보자 —

- $y^{(37)}$ 은 “세상에서 정말 그 집의 가치”가 아니라, **그 거래가 기록된 숫자**. 특수 사유(가족 간 거래, 급매)로 비정상적으로 싸게 거래됐다면 “가치”는 달라진다.
- 즉 라벨은 “세상의 진실”이 아니라 “**그 시점, 그 상황에서 사람이 기록한 값**”.

실무 결과 1: 라벨의 정의는 팀 전체가 합의해야 한다

“이탈 = 30일 이상 미접속”으로 정한 팀과 “이탈 = 구독 해지”로 정한 팀이 같은 데이터셋에 라벨을 매기면, **같은 고객에게 두 라벨이 동시에 붙을 수 있다**. 정의가 일관성이 없으면 아무리 좋은 h 도 그 모순을 학습할 수 없다.

라벨의 책임 II — 품질 확인과 세 갈래의 기준

실무 결과 2: 라벨 품질은 EDA 단계에서 먼저 확인

라벨 분포가 **99:1**로 극단적으로 불균형하면 “정확도 99%”는 사실상 **무의미**하다(전체를 “비정상”으로 예측해도 99%). 해결은 라벨 재정의 · 재가중치 · 다른 평가지표(PR-AUC, Ch. 2.3) — 출발점은 모두 “**이 라벨이 정확히 무엇을 측정하는가**”를 처음에 명확히 했는가.

- 이 개념이 바로 다음 세 갈래 분류와 직결된다: **라벨이 있는가 없는가가 지도/비지도/강화를 가르는 기준**이기 때문이다.

세 갈래 분류: 무엇을 데이터로 갖고 있는가

머신러닝 문제는 세 갈래로 나뉜다 — 알고리즘의 이름이 아니라, **어떤 형태의 데이터를 갖고 있고 어떤 신호로 학습하는가**로 갈린다.

	데이터 형태	목표	이번 학기 예시
지도학습	(x, y) 쌍	새 x 에 대한 y 예측	회귀·분류, kNN, SVM, 트리, 신경망
비지도학습	x 만	데이터의 숨은 구조 발견	k-means, PCA, EM/GMM
강화학습	상태·행동·보상	누적 보상을 최대화하는 정책	ML1에서는 안 다룬 (ML2 전담)

강조: 기준은 “얼마나 어려운 문제인가”가 아니라 **“손에 쥔 데이터에 무엇이 적혀 있는가”**.

지도학습 내부: 판별적 vs 생성적

지도학습 안에서도 다시 두 갈래가 갈린다:

판별적 (discriminative)

- $P(y | x)$ — “ x 가 주어졌을 때 y 의 확률”을 곧바로 학습.
- 예: 회귀 · 로지스틱회귀 · SVM · 신경망.

생성적 (generative)

- $P(x | y)$ — “각 클래스가 데이터를 어떻게 만들어내는지”를 먼저 학습.
- 그 다음 **베이즈 정리**로 뒤집어 $P(y | x)$ 를 얻는다. 예: Ch. 3의 나이브베이즈 · GDA.

같은 문제를 **정반대 방향**에서 접근하는 두 철학의 차이는 Chapter 3에서 자세히 다룬다.

비지도학습과 강화학습

비지도학습 — 정답 없이 **구조만** 주어짐

- “이 고객들을 비슷한 성향끼리 묶어라”(군집화).
- “1000개 특징을 정보 손실 최소로 10개로 줄여라” (차원 축소).
- Chapter 14~15에서 다룸.

강화학습 — 정답이 아니라 **보상만** 주어짐

- 에이전트가 **시행착오**로 좋은 행동을 스스로 찾음.
- 체스·바둑: “이 수가 정답이다”라고 알려주는 사람은 없지만, “이겼다/졌다”는 신호는 있다.

ML1에서는 다루지 않는다

ML1과 ML2는 서로 독립된 과목이고, ML2가 **강화학습과 로봇 시뮬레이션을 처음부터 끝까지 전문으로** 다룬다. (ML2를 듣기 위해 ML1을 먼저 들을 필요는 없다.)

두 질문을 실제 시나리오에

시나리오	Q1: y 가?	Q2: 보상이?	갈래
지난 분기 매출로 다음 분기 매출 예측 고객 구매 기록만으로 “비슷한 취향” 그룹 발견	있음(매출 숫자) 없음	— 없음	지도·회귀 비지도
드론이 충돌 없이 목표지에 도착하도록 경로 학습	없음	있음(도착/ 충돌 신호)	강화
X-ray 사진으로 폐렴 유무 판별	있음(의사 진단)	—	지도·분류

왜 두 단계인가

y 가 있으면 강화학습의 구조(상태·행동·보상)가 존재할 여지가 **아예 없다** $\Rightarrow$ 질문 1이 먼저. 2를 먼저 던지면 y 가 있는 데이터에서 보상을 **억지로** 만들 위험 — “매출이 올랐으니 보상 +1”의 순간, **보상 설계(reward shaping)**의 가장 흔한 함정(행동 $\rightarrow$ 결과 인과가 모호).

세 갈래를 대표하는 유명한 시스템

- **지도 — ImageNet/AlexNet**: 100만 장이 넘는 사진 각각에 사람이 미리 “고양이”·“자동차” 같은 **정답 라벨**을 붙여줬다. 라벨이 없었으면 이 방식 자체가 불가능.
- **비지도 — 넷플릭스/스포티파이 군집화**: “당신과 비슷한 취향의 사람이 좋아하는 콘텐츠”를 추천할 때, “이 사람은 그룹 3에 속한다”는 **정답 라벨은 어디에도 없다**. 시청·청취 기록만으로 비슷한 패턴을 알고리즘이 스스로 묶어냄.
- **강화 — AlphaGo**: 바둑의 “정답 수”를 사람이 알려준 적 없다(최선의 수를 사람도 모른다). 대신 “**이겼다(+1)** / **졌다(-1)**”라는 보상만으로 스스로 수백만 판을 두며 정책 개선 — ML2에서 처음부터 다름.

같은 데이터, 다른 갈래: “라벨 관점”이 문제를 바꾼다

한 이커머스: 각 고객의 (연령, 지역, 월 구매 횟수, 평균 구매액, 최근 90일 방문 빈도) + “지난 30일 구독 해지 여부(1/0)” 라벨.

- 1 **그냥 있는 그대로** — y = 해지 여부 예측 → **지도학습·분류**(이탈 예측 모델, Ch. 2~7의 도구 중 하나).
- 2 **라벨만 버리면** — 특징만으로 “비슷한 구매 성향을 묶어라” → **비지도학습·군집화**. 군집이 나중에 “이 군집의 이탈 확률이 높다”는 통찰로 이어질 수도 — **라벨을 버린 비지도가 라벨을 쓴 지도보다 넓은 시야를 줄 수 있음**.
- 3 **한 걸음 더** — 매 주 쿠폰(10%/20%/무료배송)을 직접 결정하고, 다음 주 매출(보상)을 관찰하며 **시행착오**로 개선 → **강화학습**. “이 고객에게 이 쿠폰이 정답”이라는 라벨은 어디에도 없고, **보상(매출 변화)만**.

같은 원본 데이터셋에서, 무엇을 라벨로 볼 것인가에 따라 세 갈래 모두가 만들어진다.

ML1의 챕터가 지도(Ch. 2~13) + 비지도 (Ch. 14~15) 두 갈래에 머무는 이유: 강화학습은 “정답이 아예 없고 보상만 있다” — 데이터의 형태 자체가 **근본적으로 달라** 별도 과목(ML2)을 통째로 할애할 만큼 다르다.

회귀 vs 분류: 같은 모델, 다른 출력

지도학습은 다시 출력이 **연속값**이나 **범주**로 나뉜다:

- **회귀(regression)**: 숫자를 예측 (집값, 기온).
- **분류(classification)**: 범주를 예측 (스팸/정상, 개/고양이/새).

같은 선형 모델 $w^T x + b$ 라도, **출력을 그대로 쓰면 회귀**, **시그모이드를 씌워 0~1 확률로 해석하면 분류** (둘 다 Ch. 2). 앞으로 몇 장 동안 반복되는 패턴:

모델 구조는 비슷한데, 출력을 해석하는 방식과 손실함수(loss function)만 문제에 맞게 바뀐다.

- 예: 학습된 $w = [0.5, -2.0]$, $b = 1.0$, 새 데이터 $x = [3, 0.5]$.

$$w^T x + b = 0.5 \times 3 + (-2.0) \times 0.5 + 1.0 = 1.5 - 1.0 + 1.0 = 1.5$$

같은 1.5, 두 가지 읽기 — 시그모이드

- **회귀**로 쓰면: 결과 1.5 를 그대로 예측값으로 읽음 (예: “이 집은 1.5억 원”).
- **분류**로 쓰면: 정확히 같은 1.5 를 시그모이드 $\sigma(z) = 1/(1 + e^{-z})$ 에 통과시켜 $\sigma(1.5) \approx 0.82$ → “이 이메일이 스팸일 확률 82%”로 읽음.

가중치 w , 편향 b , 입력 x 는 완전히 동일한데, 오직 “출력을 어떻게 해석할 것인가”만 바뀌었다.

시그모이드가 왜 필요한가

z 는 $(-\infty, +\infty)$ 의 아무 값이나 나온다. “확률”로 읽으려면 0과 1 사이가 필요하고, z 가 커질수록 1에, 작을수록 0에 **부드럽게(미분 가능하게)** 가까워져야 한다 — 그래야 Ch.2 경사하강법에서 미분이 잘 되기 때문. 시그모이드는 이 두 성질을 동시에 만족하는 **가장 간단한** 함수.

링크 함수 + 실습: 같은 계산, 두 가지 해석

“출력 해석을 확률로 바꾸는” 단계 = **링크 함수**: 회귀 = **항등 함수**(z 를 그대로), 이진 분류 = **시그모이드**. Ch.2에서 이 차이로 손실함수가 어떻게 달라지는지 직접 유도(MSE vs 교차 엔트로피).

```
import math

def sigmoid(z):
    return 1 / (1 + math.exp(-z))

w = [0.5, -2.0]
b = 1.0
x = [3, 0.5]

z = sum(wi * xi for wi, xi in zip(w, x)) + b
print("z =", z) # 1.5
print("회귀로 읽으면:", z) # 1.5 그대로( 예측값)
print("분류로 읽으면:", sigmoid(z)) # 약 0.818 양성( 클래스일확률 )
```

z 를 만드는 코드는 **한 줄로 똑같고**, sigmoid() 를 씌우느냐 마느냐 **한 줄 차이**가 회귀/분류. Ch.2: 이 z 를 만드는 w, b 자체를 **데이터로 학습**(경사하강법). Colab: 2D 점군을 회귀선 vs 분류 경계로 나란히, classify_dataset() 작성.

공통 뼈대: 손실함수 J 를 정의하고 최소화한다

지금부터 배우는 거의 모든 알고리즘은 다음 두 단계 틀을 따른다:

- ① 모델이 얼마나 틀렸는지를 숫자 하나로 요약하는 **손실함수** $J(w)$ 를 정의.
 - ② $J(w)$ 를 **최소화**하는 w 를 찾는다 (대개 **경사하강법**, Ch. 2).
- 회귀의 손실(평균제곱오차)과 분류의 손실(교차 엔트로피)은 **형태가 다르지만**, “틀린 정도를 수치화하고 그걸 줄인다”는 **구조 자체는 동일**.
 - Ch. 2 선형·로지스틱회귀, Ch. 5 SVM(힌지 손실), Ch. 9 신경망 (역전파로 손실 최소화)까지 $-h$ 의 형태와 J 의 모양은 알고리즘마다 다르고, **절차 자체는 똑같이 반복**.

매 챕터에 습관적으로 던질 세 질문: “ h 는 무엇이고, J 는 무엇이며, 어떻게 최소화하는가.”

세 갈래를 가르는 “데이터의 형상” — 표로 보면 된다

- **지도**: 2개 블록 — 왼쪽 x 블록(특징 열), 오른쪽 y 블록(라벨 1열). 행 m 개, 열 $(p + 1)$ 개.
핵심 질문: “라벨 열이 있는가?”
- **비지도**: 1개 블록 — x 블록만 있고 라벨 **열이 없다**. 행 m 개, 열 p 개. 목표: “구조를 찾자”.
- **강화**: 형상 자체가 다름 — 각 행이 (s_t, a_t, r_t, s_{t+1}) 4개 필드(상태, 행동, **보상**, 다음 상태)를 가진 **경험 튜플** 목록. 라벨 열 대신 **보상 열**이 있다.

“라벨 열”과 “보상 열”의 차이

라벨 = “이 입력 x 에 대한 **정답**”. 보상 = “이 행동을 취한 **결과**가 좋았는가”를 숫자로 알려줄 뿐, “정답 행동은 무엇이었는가”를 **아주 느리고 부분적으로만** 알려준다. 이것이 세 갈래의 가장 근본적인 차이 (ML2에서 본격 다룸).

자주 하는 실수: 정의를 건너뛰고 알고리즘부터

- 사례: 스타트업이 “이탈 예측 모델 만들자”는 목표만 갖고 “그럼 신경망을 쓸까, XGBoost를 쓸까?”부터 논의.
- 몇 주 뒤 모델은 완성됐지만 **성능이 엉망** — “이탈”의 정의(30일 미접속? 구독 해지? 환불 요청?)조차 **팀마다 다르게** 이해하고, y (라벨) 자체가 일관성 없이 매겨져 있었음.

알고리즘 선택에 쓴 시간보다, y 를 정의하는 데 쓴 시간이 훨씬 적었던 것이 진짜 원인.

- “어떤 모델이 가장 정확할까”는 **프로젝트 중반 이후**의 질문. 초반에 가장 먼저 답해야 할 질문은 “ x 는 무엇이고, y 는 정확히 무엇이며, 그 정의에 **모두가 동의하는가**”.
- Ch. 8, 16 팀 프로젝트: 데이터를 내려받자마자 모델링에 뛰어들지 말고, 이 세 가지 질문에 **팀 전체가 명시적으로** 답을 적어두기.

실수 두 번째: “라벨 없으니 비지도겠지”

“라벨이 없다”는 **현상**이 “비지도학습이 맞는 문제”라는 **결론**으로 바로 이어지지 않는다.

- “**라벨이 비싸서 못 만들었다**” vs “**라벨이 원리적으로 없다**”: X-ray 폐렴 판별에서 “폐렴/정상” 라벨은 의사가 매겨야 해 비싸고 느리다. 비지도로 푸는 것은 “라벨을 만들지 않겠다”는 선택이지 “원리적으로 없다”가 아님 → 대개는 “**라벨을 일부라도** 만들 수 있는가”를 먼저 고민 (의사 10장만 라벨 + 나머지 비지도 = **반지도학습**, Ch. 9~10에서 간접 다룸).
- “**보상이 있긴 한데 '라벨'인 줄 알았다**”: “재구매 여부”는 **라벨**(지도)로 쓸 수도, “또 샀으니 +1”이라는 **보상**(강화)으로 읽을 수도 — Q1/Q2로 다시 확인.

확인 문제: 이 시나리오에는 어떤 갈래인가 (a)~(d)

각 사례를 읽는 지도/비지도/강화, 그리고 회귀/분류까지 판단:

시나리오	답
(a) 넷플릭스가 시청 기록(장르, 시청 시간)만으로 “비슷한 취향 그룹” 자동 탐색	비지도 — “그룹 3에 속한다”는 정답 없이 구조(비슷한 패턴)만으로 탐색
(b) 은행이 과거 대출자(소득, 신용점수, 상환 여부)로 “새 신청자가 상환할지” 예측	지도·분류 — “상환함/못함” 범주 정답이 이미 붙어 있음
(c) 로봇 청소기가 배터리 아끼며 방을 최대한 깨끗이 청소하도록 스스로 수백 번 시행착오	강화 — “이 방향이 정답”을 알려주는 사람 없이 “청소 면적”·“남은 배터리” 보상으로 정책 개선 (ML2에서 본격)
(d) 부동산 플랫폼이 매물 정보로 예상 거래가를 숫자 로 예측	지도·회귀 — y (거래가)가 범주가 아니라 연속 숫자

기준이 항상 같다: “정답 라벨이 있는가”, 있다면 “숫자인가 범주인가” — 질문 두 개로 어떤 문제든 분류할 수 있다.

확인 문제 (e)(f)(g) + 1.2 마무리

- (e) 게임사가 “플레이어가 다음 주에도 접속할 것인가”를 과거 행동 로그로 예측 → **지도·분류** (“다음 주에도 접속” 라벨이 이미 붙어 있음).
- (f) 같은 게임사가 “지금 어떤 아이템을 쓰면 장기 승률에 좋은지”를 실제 플레이(시행착오)로 학습 → **강화** (“지금의 정답 행동” 라벨은 없고 “승리/패배” 보상만). (e)(f)는 **같은 게임 로그**를 갖고, 예측 대상을 보는 관점에 따라 갈래가 바뀜.
- (g) SNS가 친구 관계 **그래프만** 갖고 “비슷한 커뮤니티”를 자동 탐색 → **비지도** (“커뮤니티 5에 속한다”는 라벨 없이 연결 밀도 구조로 탐색).

Q. “지도 vs 비지도”와 “회귀 vs 분류”는 같은 기준인가? 아니다 — 수직 관계. 지도가 “라벨이 있는가?”로 먼저 갈리고, 그 안에서 “숫자인가 범주인가?”로 갈린다. 비지도/강화는 회귀/분류 구분 **그 자체가 없다**.

반지도(라벨 1% 수준)·자기지도(라벨이 데이터에서 자동 생성)는 세 갈래의 **경계** 변종 (Ch. 9~10, 14~15에서 간접 등장). “보상”이 있어도 무조건 강화가 아님 — **보상의 인과성**(행동→결과)이 성립할 때만 신호 (ML2 reward shaping).

1.2 마무리

핵심 질문

어떤 문제를 만나든, 첫 질문은 항상 같다: **손에 쥔 데이터에 무엇이 적혀 있는가 — 그리고 그것을 “라벨”으로 볼 것인가, “보상”으로 볼 것인가, 아니면 “구조”로만 볼 것인가.**

- x, y, h 로 **먼저 정의**하고, 두 질문으로 세 갈래를 가르고, 지도 안에서는 “연속/범주”로 회귀/분류를 가른다.
- 회귀 vs 분류 = **같은 모델, 다른 출력** (항등 링크 vs 시그모이드).
- 모든 알고리즘의 뼈대 = J 를 **정의하고 최소화** (h, J , 최소화 방법의 세 질문).

1.3 데이터사이언스 파이프라인과 사전지식 리뷰

모델은 파이프라인의 한 조각일 뿐

1.2절은 “모델을 어떻게 정의하는가”였지만, 실전에서 모델 학습은 전체 작업의 **작은 일부**에 불과하다. 실제 데이터 프로젝트의 순환:

- ① **수집** — 어디서 데이터를 구할 것인가. Ch. 8, 16 팀 프로젝트에서는 Kaggle, UCI ML Repository, Hugging Face Datasets 등 공개 저장소를 주로 사용. 실무에선 “이 데이터를 이 목적으로 써도 되는가”(라이선스, 개인정보) 확인도 포함 — 캐글 대회 데이터라도 **상업적 재사용이 금지**된 경우가 흔함.
- ② **정제** — 결측치 · 중복 · 이상치를 처리 (현실 데이터는 거의 항상 지저분).
- ③ **탐색적 데이터 분석(EDA)** — 모델을 만들기 전에 분포 · 상관관계 · 클래스 비율을 **눈으로** 확인. 이 단계의 발견이 어떤 모델을 고를지까지 결정 (예: 99:1 불균형 → 정확도 대신 PR-AUC, Ch. 2.3).
- ④ **모델링** — 1.2절에서 정식화한 문제에 맞는 h 를 고르고 학습. 이번 학기 대부분의 장.
- ⑤ **평가** — **학습에 쓰지 않은** 데이터로 성능 검증 (엄밀한 원리는 Ch. 6). 나쁘면 4단계(다른 모델?)로만 돌아가지 않고 **1~3단계로 되돌아가야** 할 수도 — “모델이 나쁜 것”이 아니라 “데이터가 애초에 그 신호를 담고 있지 않은 것”일 수 있기 때문.

왜 이 순서인가 — 결함은 아래로 “증폭”된다

- **모델링은 다섯 단계 중 하나일 뿐** — 처음 배우는 이들이 가장 자주 간과하는 점. 캐글 프로젝트에서 결측치 처리 + EDA에 드는 시간이 모델 코드보다 **긴 경우가 흔함**.
- 파이프라인 앞 단계의 결함은 뒤에서 아무리 좋은 모델을 써도 **수리되지 않는다**.
- **결측치 미처리**: 모델이 “결측 처리의 흔적”을 **정답인 양** 학습.
- **중복 행**: 같은 사례를 여러 번 외워 “중요도가 부풀려진” 데이터.
- **미래 정보**(예: “거래 완료 여부”를 특징으로 쓰는 집값 예측): 훈련 때는 비현실적으로 정확하고 **실전에만 무너지는**, 디버깅이 거의 불가능한 모델.

실무 경험자들의 일치된 증언

파이프라인은 위에서 아래로 흐르되, **결함은 위에서 아래로 “증폭”**되는 구조.

자주 하는 실수: EDA를 건너뛰고 바로 모델링

1.2절의 “정의 없이 알고리즘부터 고르지 말라”가 이 파이프라인에도 그대로 적용된다.

- 흔한 실패 패턴: 데이터를 내려받자마자 `df.head()` 만 한 번 찍어보고 바로 `model.fit(X, y)` 를 돌림.
- 나중에 성능이 이상해서 다시 들여다보면:
 - ▶ 가격 열에 **음수값**이 섞여 있었거나,
 - ▶ 한 지역이 전체의 **90%**를 차지해 다른 지역은 사실상 학습이 안 됐거나,
 - ▶ 특정 열이 “**미래 정보**”(예측 시점엔 알 수 없는 값)를 담고 있어 학습 때만 비현실적으로 정확했던 것.

EDA 10분의 가치

전부 `df.describe()`, `df.corr()`, 그룹별 통계 몇 줄 만 먼저 찍어봤어도 모델을 돌리기 **전에** 잡을 수 있었던 것. EDA에 쓰는 10분이, 잘못된 가정 위에 쌓은 모델을 디버깅하는 **몇 시간**을 아껴준다.

유명한 사고: Aha! 데이터셋 (Wolpert & Kibler, 1992)

머신러닝 역사에서 **데이터 품질**의 중요성을 보여주는 가장 유명한 사례:

- 1992년, SRI 국제 AI 센터의 **Wolpert와 Kibler** — “Do We Know the Data We’re Using?” (Wolpert & Kibler, 1992).
- 당시 표준 벤치마크 UCI의 “Aha!” 데이터셋을 들여다봤더니, **동일한 특징 벡터의 행이 서로 다른 정답 라벨로 2개 이상 들어 있는 경우가 100건**.
- 같은 입력에 서로 모순되는 정답이 두 개면, 아무리 완전한 모델이라도 그 쌍 중 **적어도 한 건은 틀릴 수밖에** 없다 (수학적 문제).

교훈

“어떤 알고리즘이 더 좋은가” 비교 논문들에, 알고리즘이 아니라 **데이터의 모순이 만든 “반드시 틀려야 하는”** 바닥이 이미 포함돼 있었다. 중복을 정리하자 정확도가 올랐다 — 성능이 이상할 때 **첫 의심은 “모델이 약해서”가 아니라 “데이터에 문제가 있어서”**일 수 있고, 그 확인은 `df.duplicated()` 같은 단순한 검사로 한다.

더티 데이터의 세 가지 표준 모양

“데이터가 지저분하다”는 말은 막연한 인상이 아니라, 실전에서 반복해서 나타나는 **세 가지 표준 모양**을 가리킨다 (Aha! 사례는 두 번째 모양의 극단):

- ❶ **결측치 (missing value)**: 값이 아예 비어 있는 경우 — NaN, 빈칸, 혹은 0 / -1 / -999 / 999 같은 **센티넬 값**(의도된 “측정 실패” 표시). 센티넬은 “비어 보이지 않아서” **가장 위험** — 0으로 임의 채워진 결측치를 그대로 쓰면 “0은 특별한 값”이라는 **거짓 신호**가 들어감 → describe()의 최솟값·분포로 “합리적 범위를 벗어난 값이 모여 있는가” 확인.
- ❷ **중복 (duplicate)**: 같은 행이 여러 번 — “완전 중복”부터 같은 응답자·동일 물건이 다른 시점에 기록된 “부분 중복”까지. duplicated()는 **완전 중복만** 잡아주고, 부분 중복은 “어떤 열들의 조합을 동일 사례로 볼 것인가”를 사람이 먼저 결정 (예: 부동산 = “지번+거래일” 조합).

더티 데이터 (끝): 이상치 — 도메인 지식의 영역

- 3. **이상치 (outlier)**: 범위는 합리적이지만 분포와 극단적으로 어긋난 값.
- 음수 가격, 250세 나이 = 센티넬 → **1번(결측치)**으로. “합법적이지만 극단적”인 값(수백억짜리 단독주택 한 채)은 **3번(이상치)**으로 처리할지, 드물지만 **중요한 사례** 라면 그대로 둘지는 —

판단의 성격

도메인 지식으로만 판단할 수 있는 문제. “코드 짜는 것”이 아니라 “문제를 이해하는 것”의 영역에 속한다는 점을 기억할 것.

- 세 모양 모두 **정제 단계**에서 다루고, 발견은 **EDA 단계**에서 한다 — 다음 4가지 질문으로.

EDA: 모델을 돌리기 전에 데이터와 “대화”하기

EDA의 목적은 “데이터를 보는 것” 자체가 아니라, 모델링 **전에** 다음 질문에 답을 얻어두는 것 — 이 질문들은 **모델이 아니라 데이터에** 대해 묻는 것들이다:

- ① **각 특징의 스케일이 서로 얼마나 다른가?** — 평균(수십~백) vs 연식(네 자리 연도) vs 가격(억 단위). 차이가 크면 Ch. 4.1의 **특징 정규화**를 모델에 넣기 전에 — EDA의 **첫** 질문.
- ② **어떤 특징이 목표 변수와 강하게 연관되는가?** — 아무 특징도 관련이 없으면 예측력에 한계 (1.2절의 강조와 정확히 같은 질문).
- ③ **목표 변수의 분포가 합리적인가?** — 음수값, 한쪽 꼬리가 극단적으로 긴가 (가격 데이터는 보통 **오른쪽 꼬리**가 긴 분포). 꼬리가 길면 “평균을 얼마나 잘 맞히느냐” 기준(MSE, Ch. 2)이 극단값에 지나치게 민감해질 수 있음.
- ④ **클래스 균형(분류)은 적당한가?** — 양성:음성 = 99:1이면 전부를 “음성”으로 예측하는 멍한 모델도 정확도 99% — 정확도는 **무의미**하고 PR-AUC(Ch. 2.3)를 처음부터 염두.

실 데이터로: Kaggle “House Prices”(1,460행 × 81 특징)는 describe() 만 찍어도 SalePrice 가 **오른쪽으로 심하게 치우쳐** 있고 **최댓값이 99퍼센타일보다 수 배** 크다는 것을 즉시 보여준다 — 극단값 몇 개가 훈련을 얼마나 끌어당기는지 Ch. 6의 정규화를 배우기 전에 감 잡기. describe() · corr() · isna().sum() · groupby() 는 **도구일 뿐** — EDA는 그 **도구로 질문에 답하는 과정**.

실습: pandas로 첫 EDA + 결측치와 그룹별 통계

개념 코드는 순수 Python/numpy로 손으로 짜는 경우가 많지만, 실전 데이터 탐색 단계에서는 pandas 가 사실상 표준.

```
import pandas as pd

data = {
    "size_sqm": [59, 84, 112, 46, 132, 78],
    "rooms": [2, 3, 4, 1, 4, 3],
    "year_built": [2015, 2008, 1998, 2020, 1995, 2011],
    "price_million": [320, 410, 505, 250, 560, 390],
}
df = pd.DataFrame(data)

print(df.describe())           # 각열의평균표준편차최소최대   /// 한눈에
print(df.corr(numeric_only=True)["price_million"]) # 목표와의연관
print(df.isna().sum())         # 열별결측개수
```

실제 데이터에는 결측치가 거의 항상 있다 — 결측 + 지역 정보로 가장 자주 쓰는 처리:

```
import numpy as np
df2 = pd.DataFrame({
    "size_sqm": [59, 84, 112, 46, 132, 78, np.nan],
    "district": ["A", "B", "A", "C", "B", "A", "C"],
    "price_million": [320, 410, 505, 250, 560, 390, np.nan],
})
```

dropna vs fillna: 보편 정답은 없다

dropna() — 결측 있는 행을 통째로 버림

- 결측이 **극히 일부**라면 간단하고 안전.
- 위험: 데이터가 적거나 결측이 특정 **그룹에 몰려** 있으면 그 그룹 **통째로** 지워버림 (위 예: 지역 C의 결측을 지우면 지역 C의 평균가 정보 자체가 사라짐).

fillna() — 중앙값·평균 등으로 채움

- 데이터가 적거나 결측이 특정 그룹에 몰려 있으면 **그룹 단위 통계**(지역별 중앙값)로 채우는 쪽이 안전.
- 실전 한 단계 전: “**왜 결측인가**”를 먼저 조사 — **결측 패턴 자체가 정보**인 경우 (예: “층수” 결측이 단독주택에만 몰려 있으면 “결측 여부”가 “타입”을 보여주는 특징).

데이터 나누기: 순서가 중요한 이유

EDA가 끝나면 모델링 전의 첫 번째 실제 결정: **train set / test set** 분리.

실무 원칙 (Ch. 6에서 엄밀하게)

데이터에 대한 통계를 써야 하는 모든 조작은

훈련 셋에서 fit(계산) → 테스트 셋에 apply(적용)

순서로 — 결코 “전체에서 fit → 훈련 셋에 apply” 하지 않는다.

- 예: 가격 결측 5%를 **전체 평균**으로 채운 뒤 나눠 버리면, 훈련 행이 “**테스트 행이 포함된 평균**”으로 채워진 셈 — 실전(전체 평균을 알 수 없는 상황)에서 불가능한 정보를 훈련에 살짝 새겨넣은 것.
- 이를 **데이터 누수 (data leak)**라 부름.

데이터 누수는 작을수록 위험하다

- 5% 결측의 평균이라는 **이 정도 크기의 누수는 숫자에 거의 영향을 주지 않는다** — 그래서 위험.
- 작은 누수를 습관으로 익혀두면, 나중에 “거래 완료 여부” 같은 미래 정보를 특징에 섞어넣는 **큰 누수**와 같은 버릇으로 인식되지 않고, 어느 순간 **평가 자체가 믿을 수 없게** 되었을 때 원인 찾기가 몇 배로 어려워진다.

비율보다 중요한 원칙

나누기 비율(70:30, 80:20...)은 문제 크기에 따라 달라지지만, **테스트 셋은 마지막 평가 한 번에만 쓴다**. 테스트 성적이 나빠서 “테스트를 봐서 고치고, 다시 테스트”를 반복하면, 테스트는 “새 데이터”가 아니라 사실상 **훈련 데이터**가 되어버린다 (검증 셋의 역할은 Ch. 6).

실습: 파이프라인을 처음부터 끝까지 (1/2) — 정제

120채의 집, 평수 40~140m², 진짜 가격은 $1.5 \times \text{평수} + 20 + \text{잡음}$ (백만 원). 정제가 실제로 할 일을 확인하려 두 가지 “더티함”을 의도적으로 섞어 넣음 — **3개 완전 중복 행, 센티넬 -999 가 1행.**

```
import numpy as np
import pandas as pd

# 1) 수집: 지저분한데이터셋시뮬레이션
rng = np.random.default_rng(0)
size = rng.uniform(40, 140, 120)
price = 1.5 * size + 20 + rng.normal(0, 8, 120)

for i in [5, 6, 7]:                                     # 행3 완전중복
    size = np.append(size, size[i])
    price = np.append(price, price[i])
price[11] = -999.0                                     # 행1 센서센티넬
df = pd.DataFrame({"size_sqm": size, "price_million": price})

# 2) 정제행( 수준): 중복제거—통계량이관여하지않아나누기전에안전
print("rows before cleaning:", len(df))
print("min price:", df["price_million"].min())          # 가-999 보인다!
print("duplicate rows:", df.duplicated().sum())
df = df.drop_duplicates().reset_index(drop=True)
```

실습: 파이프라인 (2/2) — 나누기·채움·모델링

```
# 3) 통계량기반정제채움 () 이전에** 데이터를나눈다
perm = rng.permutation(len(df))
cut = int(0.75 * len(df))
df_tr = df.iloc[perm[:cut]].copy()
df_te = df.iloc[perm[cut:]].copy()

# 4) 채움: 훈련행에서만중앙값계산 , 그통계량을테스트에적용
med = df_tr.loc[df_tr["price_million"] >= 0, "price_million"].median()
for d in (df_tr, df_te):
    d.loc[d["price_million"] < 0, "price_million"] = med

# 5) 모델링: 선형회귀정상방정식 (, Ch에서.\,2 유도)
def linreg(X, y):
    Xb = np.column_stack([X, np.ones_like(X)])
    w = np.linalg.solve(Xb.T @ Xb, Xb.T @ y)
    return w[0], w[1]

slope, intercept = linreg(df_tr["size_sqm"].values,
                           df_tr["price_million"].values)
```

결과: 123행 → 중복 3행 제거 → 120행, 75/25로 train 90 / test 30, train median 152.6, **learned slope=1.400, intercept=29.471** (true: 1.5, 20). 기울기 1.400 ≈ 진짜 1.5 — 0.1의 차이는 랜덤 잡음, “모델이 못 배운 것”이 아니라 **데이터 자체의 불확실성**. 절편 29.5는 진짜 20에서 더 크게 벗어남 — 표본 90개 수준에서 **절편은 기울기보다**

평가: R^2 , 그리고 “잘 외운” 모델

90행 훈련 모델로 30행 테스트를 평가:

```
def r2(y, p):  
    return 1 - ((y - p) ** 2).sum() / ((y - y.mean()) ** 2).sum()  
  
def mae(y, p):  
    return np.abs(y - p).mean()  
  
Xtr, ytr = df_tr["size_sqm"].values, df_tr["price_million"].values  
Xte, yte = df_te["size_sqm"].values, df_te["price_million"].values  
print(f"train R2={r2(ytr, slope*Xtr+intercept):.4f}")  
print(f"test R2={r2(yte, slope*Xte+intercept):.4f}")
```

train R2=0.9406 MAE=7.13 test R2=0.9561 MAE=7.58 (평균 713만 원 오차, 평균 가격의 약 2%).

- **R^2 (결정계수):** “목표 변수의 변동 중 모델이 몇 % 설명하는가”. 1.0 = 완벽, 0 = “모두 평균을 예측하는 모델”과 같은 수준.
- 주목: **train과 test의 R^2 가 거의 같다(0.94 vs 0.96)** — “일반적인 규칙”을 배운 것이지 “90행만 외운” 것이 아님을 보여주는 좋은 신호.

과대적합: 24차 다항식


그 반대 — “외운 모델”은 어떤 모습일까? 훈련 행 앞 25개에 고차 다항식을 맞춰봄:

```
Xs, ys = Xtr[:25], ytr[:25]
mu, sd = Xs.mean(), Xs.std()          # 표준화 (Ch.\,4.1 스케일문제 )
for deg in [1, 24]:
    V = np.vander((Xs - mu) / sd, N=deg + 1) # 설계행렬 [1, x, x^2, ...]
    coef, *_ = np.linalg.lstsq(V, ys, rcond=None)
    Vt = np.vander((Xte - mu) / sd, N=deg + 1)
    print(f"degree {deg}: train R2={r2(ys, V @ coef):.4f} test R2={r2(yte, Vt @ coef):.4f}")
```

degree 1: train R2=0.8820 test R2=0.9368 degree 24: train R2=1.0000 test R2=-63495.2701

과대적합(overfitting)의 교훈

과대적합: 훈련 점수는 1.0000이 되지만, 테스트는 평균만 찍는 모델보다 나빠진다



degree 1(왼쪽)은 점들의 경향에 따르는 한 줄, degree 24(오른쪽)은 25개 훈련 점(파랑)에 붙어 점과 점 사이 잡음까지 외워 테스트(빨강)에서 광범위하게 흔들린다.

- 24차 다항식은 25개 훈련 점을 **완전히** 통과 (train $R^2=1.0000$ — 매우 “완벽”해 보임).
- 그런데 테스트 R^2 는 **마이너스 6만** — “평균만 예측하는 모델”($R^2=0$)보다 **몇만 배 나쁨**.
- 25개 파라미터가 25개 점에 정확히 맞춰지는 순간, 다항식은 “점들과 점들 사이에서” 점에 붙어 있던 **잡음 자체**를 외워버림.

핵심 교훈

“훈련 점수가 높다”는 사실은 잘 배웠다는 증거가 아니라, 외웠을 가능성을 알리는 신호일 수 있으며, 모델이 좋은지 나쁜지를 결정하는 것은 언제나 보지 않은 데이터의 점수다. (엄밀한 처리는 Ch. 6.)

수학과 Python 사전지식 리뷰 — 세 영역

이번 학기는 다음 세 영역의 수학을 계속 재사용한다 — 낯선 표기가 나올 때마다 이 절로 돌아와 확인할 것:

- **선형대수**: 벡터의 **내적** $w^\top x = \sum_j w_j x_j$, **행렬-벡터 곱**, 그리고 **그래디언트**(다변수 함수를 각 변수로 편미분해서 만든 벡터, $\nabla_w J$). 고유벡터/고유값은 Ch. 14(PCA)에서 다시.
- **미적분**: **연쇄법칙 (chain rule)** — 합성함수 $f(g(x))$ 의 미분이 $f'(g(x)) g'(x)$ 라는 것. Ch. 9(역전파)의 핵심 도구가 바로 이것.
- **확률**: 조건부 확률과 **베이즈 정리**

$$P(y \mid x) = \frac{P(x \mid y) P(y)}{P(x)}$$

Ch. 3에서 본격적으로 사용.

손으로 한 번: 내적(4)과 연쇄법칙(42)

표기가 낯설다면 아주 작은 숫자로 직접 계산해보는 것이 가장 빠르다.

- **내적**: $w = [2, -1, 3]$, $x = [1, 4, 2]$ 일 때:

$$w^T x = (2)(1) + (-1)(4) + (3)(2) = 2 - 4 + 6 = 4$$

각 자리끼리 곱해서 다 더하는 것뿐 — 이 계산이 이번 학기 거의 모든 챕터의 첫 줄에 등장.

- **연쇄법칙**: $g(x) = 3x + 1$, $f(u) = u^2$, $x = 2$ 일 때 $f(g(x)) = (3x + 1)^2$ 의 미분:

$$f'(g(x)) \cdot g'(x) = 2(3x + 1) \cdot 3 = 2 \cdot 7 \cdot 3 = 42$$

직접 전개($(9x^2 + 6x + 1)$ 의 도함수 $18x + 6$, $x = 2$ 에서)해도 **똑같이 42** — 연쇄법칙은 “안쪽을 미분하고 바깥쪽을 미분해서 곱한다”는 지름길일 뿐, 다른 답을 주는 게 아니다.

두 가지를 기억하자

Ch. 9에서 이 연쇄법칙 계산을 **한 번이 아니라 수십 개의 층을 거쳐 반복**하게 된다 — 지금 이 작은 예제가 그 전체 과정의 **축소판**. 실전에서는 numpy/PyTorch로 훨씬 빠르게 같은 계산을 하지만, 처음 배울 때는 벡터 연산 뒤에 숨은 **for 루프를 직접 눈으로 보는 쪽**이 이해에 더 도움이 된다는 판단에서, 개념 코드는 순수 Python(리스트 + for 루프)으로 짰 경우가 많다.

행렬-벡터 곱: numpy로 한 줄

```
import numpy as np

X = np.array([[1.0, 2.0], [3.0, 4.0]]) # 2x2 행렬
w = np.array([0.5, -0.5])             # 길이 2 벡터
print(X @ w) # 행렬벡터- 곱: [-0.5, -0.5]
```

- $X @ w$ (행렬곱)는 앞으로 매 장에 나오는 $w^T x$ 형태의 계산을 **한 줄로 표현** — for 루프로 직접 짜는 것보다 **빠르고 읽기 쉬움**.
- 이번 학기 수학의 전량은 **내적(4) + 연쇄법칙(42)** 이 두 계산의 “여러 번, 다른 형태로 반복”에 불과하다.

확인 문제: 파이프라인 원칙을 실제 상황에서 (a)(b)

- (a) 이탈 라벨이 붙은 10,000행에서 EDA 결과 “이탈”이 2%~~뿐~~. 이 사실이 파이프라인의 어느 단계에 무엇을 바꾸는가?
- 답: **EDA의 발견이 평가 단계(지표 선택)를 바꿈** — 정확도는 “전부 비이탈”로 예측해도 98%라 이 문제에선 무의미에 가까움. **PR-AUC**(Ch. 2.3) 같은 불균형 클래스 지표를 처음부터 염두에 두고, 이후 단계(클래스 가중, 샘플링 전략)를 계획.
- (b) 1,000행에서 age 결측이 훈련부 10개, 테스트부 3개. 평균으로 채운다 — 어느 부분의 평균을 계산해야 하는가?
- 답: **훈련 부분** — “훈련에서 fit, 테스트에 apply” 원칙. 전체 평균을 쓰면 테스트 정보가 훈련에 살짝 새는 형태.

확인 문제 (c)(d)

- (c) 어떤 모델의 $\text{train } R^2 = 0.99$, $\text{test } R^2 = 0.41$. 가장 가능성 높은 진단은? 24차 다항식 예제와 어떻게 같은 이야기인가?
- 답: **과대적합** — 모델이 훈련 데이터의 규칙 이 아니라 **잡음을 외움**. 24차 예제($\text{train } R^2=1.0000$, $\text{test } R^2=-63495$)가 이 현상의 **극단적 버전**. 두 경우 모두 “**훈련 점수가 높다**는 사실 자체”가 의심의 대상.
- (d) 새 데이터를 받아 실행 **전에**, 특징 벡터가 완전히 같은 행 두 개가 **서로 다른 라벨**을 갖고 있음을 발견. 가장 먼저 무엇을 해야 하는가?
- 답: **데이터 문제를 먼저 의심** — Aha! 데이터셋 사고가 정확히 이 상황. `df.duplicated(keep=False)` 로 몇 개인지 파악한 뒤, 하나를 제거할지 라벨을 재확인할지를 **도메인 지식을 바탕으로** 결정 (알고리즘을 바꾸는 문제가 아님).

1.3 마무리

한 줄 요약

모델은 파이프라인 다섯 단계 중 하나일 뿐 — 그리고 모델의 상한을 가장 결정적으로 좌우하는 단계는 모델이 아니라, “데이터가 얼마나 깨끗하고 충분히 이해되었는가”다.

- 파이프라인: 수집 → 정제 → EDA → 모델링 → 평가 — 결함은 위에서 아래로 증폭.
- train/test는 나누기 전에 통계량을 계산하면 누수 — “훈련에서 fit, 테스트에 apply”.
- 수학 전량은 내적(4) + 연쇄법칙(42) + 베이즈 정리 — 낫선 표기가 나올 때마다 이 절로.

이번 주차 정리

① 1.1 역사와 로드맵

- ▶ 역사는 직선이 아님 — **두 번의 AI 겨울**(1969 XOR 증명, 1986 역전파로 해소)과 2012 AlexNet.
- ▶ 돌파구의 반복 패턴: **새 수학이 아니라 데이터+ 계산의 재조합**. Block A(Ch. 2~7 고전 ML) → Block B(Ch. 9~16 신경망→생성모델).

② 1.2 문제 정식화와 세 갈래

- ▶ 알고리즘보다 먼저: $x \cdot y \cdot h$ 로 정의. “라벨이 있는가? 보상이 있는가?” 두 질문으로 지도/비지도/강화를 가름.
- ▶ 회귀 vs 분류 = **같은 모델, 다른 출력**(항등 vs 시그모이드 링크) · 모든 알고리즘의 뼈대 = J 정의 → **최소화**.

③ 1.3 파이프라인과 사전지식

- ▶ 모델링은 5단계 중 하나 — 더티 데이터(결측·중복·이상치)·EDA·**train/test 순서(누수 방지)**가 모델의 상한을 결정.
- ▶ 수학 전량 = **내적 · 연쇄법칙 · 베이즈 정리**.

다음 주차 — Chapter 2. 회귀 모델: 선형회귀와 로지스틱회귀

이 책의 첫 번째 모델. 그 도입부에는 이미 19세기 수학자가 잡음 섞인 점들 사이를 “모두를 가장 잘 맞추주는” 한 줄로 통과시켜야 할 문제가 등장한다 — 오늘 세운 **손실함수를 정의하고 최소화한다**는 틀과