

SVM과 커널

마진 최대화와 서포트 벡터 · 소프트 마진 · 커널 트릭

Machine Learning 1 · 5주차

한국과학영재학교 (KSA)

Week 5

이번 주차 개요

이 주차를 마치면

- 마진이 $2/\|w\|$ 임을 거리 공식으로 유도하고, “마진 최대화”를 제약 아래 $\|w\|$ 최소화 문제로 바꾼다.
 - **서포트 벡터**가 몇 개인지 손으로 확인하고, 로지스틱회귀와 대비한다.
 - **хини 손실** + C 가 과적합/과소적합을 조절하는 손잡이임을 예측한다.
 - XOR·동심원이 고차원으로 옮기면 분리되는 이유, **커널 트릭**의 원리를 설명한다.
-
- **5.1** — 무수히 많은 분할 직선 중 “가장 안전한 하나”를 기하학으로 고른다.
 - **5.2** — 라벨 오류 하나에도 해가 사라지는 하드 마진에 여유 변수 ξ 와 C 페널티를 도입한다.
 - **5.3** — “경계가 직선”이라는 마지막 전제를 내려놓고 고차원 내적을 커널 함수로 우회한다.

세 블록의 순서 = **전제를 하나씩 덜어내는** 과정. 5.2의 C 는 6장의 정규화 세기 λ 와 같은 종류의 트레이드오프.

5.1 마진 최대화와 서포트 벡터

SVM: 확률도 생성도 안 보는 분류기

- 로지스틱회귀 — “**확률**을 얼마나 잘 맞히는가”(손실)
- GDA/나이브베이지스 — “데이터가 어떻게 **생성**됐는가”(모델)
- SVM — 확률도 생성도 아예 안 보고, **순수한 기하학**만 묻는다

**두 클래스를 가르는 무수히 많은 경계선 중,
어떤 경계선이 새 데이터에 가장 안전한가?**


마진 최대화

- SVM은 **마진**(margin, 경계에서 가장 가까운 점까지의 거리)이 **가장 큰** 직선을 고른다.
- **서포트 벡터**: 경계에 가장 가까운 데이터 점들. 이 점들만 경계의 위치를 “떠받친다”.

kNN과의 공통 언어

kNN은 **예측** 시점에 거리를 재고, SVM은 **학습** 시점에 마진을 최대화한다 — 같은 “거리”, 정반대의 쓰임.

그림으로: 마진이 가장 넓은 경계



- 회색 선들도 전부 두 클래스를 완벽히 가르지만, 마진(경계와 가장 가까운 점 사이의 여유)은 제각각.
- 굵은 남색 선(과 점선 마진 경계)이 **마진을 최대화**한 경계.
- 오렌지 원 = **서포트 벡터** — 이 두 점만 경계를 결정한다.

왜 “직선이 무수히 많다”: 스케일 불변성

- 답: 직선 자체는 (w, b) 를 (음수가 아닌) 상수 k 로 곱해도 변하지 않는다:

$$k w^{\top} x + k b = 0 \iff w^{\top} x + b = 0$$

- (w, b) 와 $(3w, 3b)$ 는 정확히 같은 결정 경계. 이를 **스케일 불변성**(scale invariance)이라 부른다.

이 사실이 왜 중요한가

“ $\|w\|$ 를 최소화하자”를 **제약 없이** 풀면 $w \rightarrow 0$ 으로 마음대로 쪼그라든다 — 경계선은 한 치도 안 움직이는데 “마진” $2/\|w\|$ 만 끝없이 부풀러진다.

즉 스케일 불변성을 그대로 두면 마진 최대화는 **정해지지 않은** 문제. $\|w\|$ 를 “의미 있는 크기”로 만들려면 스케일을 못 박는 조건이 필요하다.

마진 제약: 스케일을 못 박는 자물쇠

- 마진 제약: 각 데이터가 올바른 쪽에 최소한 1만큼 떨어져

마진 최대화 문제

제약 $y^{(i)}(w^\top x^{(i)} + b) \geq 1$ 아래에서 $\|w\|$ 를 최소화 (마진은 $\frac{2}{\|w\|}$ 로 계산되므로 최소화 = 최대화).
이 제약을 정확히 등호로 만족시키는 점들이 서포트 벡터.

서포트 벡터: 경계를 떠받치는 소수의 점

- 제약이 등호로 성립(마진 경계 위)하는 점 = **서포트 벡터**. 이름 그대로 이 점들만 경계의 위치를 “떠받친다”.



SVM

- 마진 바깥의 점: 손실 **정확히 0**
- 경계 위치는 서포트 벡터만 결정
- “각진” 경계 — 가장자리의 가까운 몇 점에 민감

로지스틱회귀

- 모든 점이 손실에 기여 ($1 - \sigma(f) > 0$)
- 멀리 있는 점도 기울기에 미세한 영향
- “매끄러운” 경계 — 데이터 전체 분포에 민감

그림으로 읽기: 서포트 벡터만 vs 모든 점



- 왼쪽(SVM): 오렌지 테두리 = 서포트 벡터. 흐리게 표시된 점들은 경계에 전혀 영향을 주지 않는다.
- 오른쪽(로지스틱회귀): 모든 점이 똑같이 진하게 — 전부 손실에 기여한다.
- 같은 데이터, 다른 원칙 $\Rightarrow$ 다른 경계.


왜 마진은 $\frac{2}{\|w\|}$ 인가 (1/2)

w 벡터는 결정 경계에 수직이다 — $w^\top x + b = c$ 인 모든 점이 w 와 수직인 초평면에 있기 때문.

- w 방향의 단위벡터 $\hat{w} = w/\|w\|$, $w^\top x$ 는 w 방향으로 이동할 때 선형으로 변하므로 단위 이동마다 변하는 양 = 정확히 $\|w\|$.
- 역으로 $w^\top x + b$ 가 1만큼 변하려면 w 방향으로 $\frac{1}{\|w\|}$ 만 이동하면 된다.

그림으로: w 는 경계에 수직

w 방향으로 $1/\|w\|$ 이동하면 $w^\top x + b$ 가 정확히 1만큼 변한다



- 검은 선 = 결정 경계($w^\top x + b = 0$), 남색 점선 = 마진 경계($w^\top x + b = 1$).
- 빨간 화살표 = w 방향으로 이동한 거리, 정확히 $\frac{1}{\|w\|}$.
- 이 거리가 다음 쪽에서 마진 공식 $\frac{2}{\|w\|}$ 로 이어진다.

왜 마진은 $\frac{2}{\|w\|}$ 인가 (2/2)

- 양의 서포트 벡터 x_+ : $w^\top x_+ + b = 1$ (제약이 등호)
- 경계 위의 점 x_0 : $w^\top x_0 + b = 0$
- 두 값을 빼면 $w^\top (x_+ - x_0) = 1$
- **경계에서 서포트 벡터까지의 직선 거리**

$$\text{마진} = \frac{1}{\|w\|} + \frac{1}{\|w\|} = \frac{2}{\|w\|}$$

기하학적 그림이 완성된다

$\|w\|$ 가 작을수록 “마진 1”을 얻으려면 더 먼 거리까지 떨어져야 하므로 데이터가 넉넉한 여유를 얻는다. $\|w\|$ 를 작게 하는 것 = 마진을 넓게 하는 것. 로지스틱회귀의 w 가 “확률을 얼마나 급하게 바꾸는가”였다면, SVM의 w 는 “마진이 얼마나 좁은가”의 역수.

기능적 마진 vs 기하적 마진

스케일 불변성 때문에 “같은 점의 마진”을 재는 방식이 두 가지로 갈린다:

기능적 마진

$$y^{(i)}(w^\top x^{(i)} + b)$$

(w, b) 를 k 배로 스케일하면 k 배로 변한다.

기하적 마진

$$\frac{y^{(i)}(w^\top x^{(i)} + b)}{\|w\|}$$

스케일에 **무관** — 실제 거리로 잴 마진. 앞선 $\frac{1}{\|w\|}$ 가 바로 이 것.

최적화 문제의 구성

“마진을 최대화하자”에서 진짜 재고 싶은 것은 **기하적 마진**. 그래서 기능적 마진의 스케일을 제약 $y^{(i)}(w^\top x^{(i)} + b) \geq 1$ 으로 “1로 고정”해 두고, 그 아래 $\|w\|$ 를 최소화 — 이 식으로 기하적 마진 $\frac{2}{\|w\|}$ 의 최대화를 푼다.

스케일이 사라지는 것을 직접 계산으로

대칭 데이터 예: 최적해 $w = (1/6, 1/6)$, $b = 0$, 서포트 벡터 $(3, 3)$.

	기능적 마진	기하적 마진
--	--------	--------

$w = (1/6, 1/6), b = 0$	$1 \cdot (3/6 + 3/6) = 1$	$\frac{1}{\ (1/6, 1/6)\ } = \frac{6}{\sqrt{2}} \approx 4.24$
-------------------------	---------------------------	--

$w' = (1/2, 1/2), b' = 0$ (3배 스케일)	$1 \cdot (1/2 \cdot 3 + 1/2 \cdot 3) = 3$ (3배로 커짐)	$\frac{3}{\ (1/2, 1/2)\ } = \frac{6}{\sqrt{2}} \approx 4.24$ (그대로)
------------------------------------	--	--

- 경계선 $x_1 + x_2 = 0$ 은 아무것도 안 변했는데 기능적 마진은 3배로 커졌다.
- 실제 거리(기하적 마진)는 스케일에 무관하게 일정.

손으로 한 번: 대칭 데이터의 최적 경계

- 원점을 중심으로 **대칭** $\Rightarrow$ 최적 경계는 원점을 지나는 직선 $x_1 + x_2 = 0$ 방향일 것 ($w \propto (1, 1), b = 0$).
- $w = k(1, 1)$ 로 두고, 원점에 가장 가까운 점 $(3, 3)$ 이 마진 경계 위에 있다고 $y^{(i)}(w^\top x^{(i)} + b) = 1$ 놓으면:

$$1 \times (k \times 3 + k \times 3) = 6k = 1 \Rightarrow k = \frac{1}{6}$$

- 따라서 $w = (1/6, 1/6), b = 0$.

손으로 한 번: 6개 점의 제약 확인

점	$y^{(i)}(w^\top x^{(i)} + b)$	서포트 벡터?
(3, 3)	$1 \times (3/6 + 3/6) = 1.000$	O (등호)
(4, 3)	$1 \times (4/6 + 3/6) = 1.167$	X (여유)
(3, 4)	$1 \times (3/6 + 4/6) = 1.167$	X
(-3, -3)	$(-1) \times (-3/6 - 3/6) = 1.000$	O (등호)
(-4, -3)	$(-1) \times (-4/6 - 3/6) = 1.167$	X
(-3, -4)	$(-1) \times (-3/6 - 4/6) = 1.167$	X

- (3, 3)과 (-3, -3) **딱 두 점만** 정확히 등호 — 이 둘이 서포트 벡터.
- 마진: $\frac{2}{\|w\|} = \frac{2}{\sqrt{2}/6} = \frac{12}{\sqrt{2}} \approx 8.485$.

손 계산 결과의 검증


- 손 계산: $w \approx [0.167, 0.167], b = 0$.
- 서포트 벡터 2개 $(3, 3), (-3, -3)$ — 마진 경계 위에만 존재.

확인 문제

서포트 벡터가 아니었던 $(4, 3)$ 을 원점 방향으로 훨씬 가깝게 $(0.5, 0.5)$ 로 옮긴다면 최적 경계 w, b 가 바뀔까?

힌트: 원래 경계에 대입하면 $1 \times (0.5/6 + 0.5/6) \approx 0.167 < 1$ — 이 점이 이제 **마진을 위반**한다.
실제로 학습시키면 $w \approx (0.286, 0.286), b \approx 0.714$ 로 바뀌고, $(0.5, 0.5)$ 와 $(-3, -3)$ 이 **새로운** 두 서포트 벡터.

그림으로: 확인 문제의 두 상황



- **왼쪽:** 원래 6개 점 — 서포트 벡터(오렌지)는 $(3, 3)$, $(-3, -3)$ 뿐.
- **오른쪽:** $(4, 3) \rightarrow (0.5, 0.5)$ 로 옮기면 마진 안을 침범 — 서포트 벡터가 $(0.5, 0.5)$, $(-3, -3)$ 으로 바뀌며 경계 자체가 이동한다.
- 마진(연한 띠)의 폭도 함께 좁아진다.

대칭을 깨뜨리면 b 만 변한다 (병진 예제)

- 최적해: $w = (1/6, 1/6)$ — **변함없음**, 그런데 $b = -1/3$.

본질

데이터 전체를 이동시켜도 w 는 그대로, b 만 변한다 — “마진 최대화”의 본질은 두 클래스 간 **상대적 방향**(w)을 정하는 것이며, **어디에 놓이느냐**(b)는 데이터의 위치에 따라 달라진다.

실습: 마진과 서포트 벡터를 눈으로 보자

```
import numpy as np
from sklearn.svm import SVC
import matplotlib.pyplot as plt

# 대각선방향으로떨어진두클러스터
rng = np.random.default_rng(7)
X = np.vstack([rng.normal([5, 5], 0.8, (40, 2)),
               rng.normal([-5, -5], 0.8, (40, 2))])
y = np.r_[np.ones(40), -np.ones(40)]


clf = SVC(kernel="linear", C=1.0).fit(X, y)
w, b = clf.coef_[0], clf.intercept_[0]
sv = X[clf.support_] # 서포트벡터만

# 결정경계 ( $w.T x + b = 0$ )와 마진경계 ( $= \pm 1$ )를 축으로  $x_1$  해를  $x_2$  표현
x1 = np.linspace(-8, 8, 100)
f = lambda c: (-w[0]*x1 - b + c) / w[1] #  $w.T x + b = c \rightarrow x_2 = \dots$ 

fig, ax = plt.subplots(figsize=(6, 6))
for lbl, m in [(1, "red"), (-1, "blue")]:
    ax.scatter(X[y == lbl, 0], X[y == lbl, 1], color=m, label=f"y={lbl}")
ax.plot(x1, f(0), "k", lw=2, label="결정 경계 (f=0)")
ax.plot(x1, f(1), "g--", lw=1, label="마진 경계 (f=+1)")
ax.plot(x1, f(-1), "g--", lw=1, label="마진 경계 (f=-1)")
ax.scatter(sv[:, 0], sv[:, 1], s=120, facecolors="none",
            edgecolors="orange", lw=2, label="서포트 벡터")
ax.set_aspect("equal"); ax.legend(); plt.show()
```

그림으로 읽기: 마진 경계와 서포트 벡터

Decision boundary, margin boundaries, support vectors



- **마진 경계선**($f=\pm 1$)은 결정 경계($f=0$)와 **평행**.
- 두 마진 경계선 **사이에 데이터가 없음**.
- 오렌지 원: **서포트 벡터**만 마진 경계 위에.

코드의 마지막 두 줄이 경계에서 서포트 벡터까지의 실제 거리 $= 1/\|w\|$ 임을 직접 재서, 마진 공식 $2/\|w\|$ 가 추상적 수식이 아니라 **실제 거리**임을 확인.


노트북에서 확인하는 핵심 세 가지

- ① **마진 경계선이 경계에 평행**하며, 그 사이가 “마진” — 데이터는 마진 경계선 바깥에만 있다.
- ② **서포트 벡터는 마진 경계선 위에만 있다** — 그 밖의 점은 지워도 w, b 가 변하지 않는다.
- ③ **마진 너비 $2/\|w\|$ 가 실제 거리와 일치** — 경계에서 서포트 벡터까지의 유클리드 거리가 정확히 $1/\|w\|$ 인지 직접 재본다.

역사: “마진”이라는 생각의 기원

- 이진 분류기의 VC 차원 = “그 모델이 **모든 라벨링에** 완벽히 맞힐 수 있는 데이터의 최대 개수” — 모델의 **용량** 척도.
 - ▶ 용량이 작을수록(모델이 단순할수록) 과적합 위험이 줄어든다.
 - ▶ **마진**은 모델 복잡도를 규제한다

모델별 목적과 성질



Vladimir Vapnik
VC 차원(1960s) · SVM 공동 개발



Corinna Cortes
Vapnik과 함께 SVM 완성
(AT&T Bell Labs, 1995)


자주 하는 실수: “클러스터를 넓게 벌린다”

- 결정 경계는 오직 $(3, 3)$ 과 $(-3, -3)$ 두 점의 위치에만 의존한다.
- $(4, 3)$ 을 $(100, 100)$ 으로 옮겨도(다른 5개 점은 그대로) 다시 학습시킨 w, b 는 소수점까지 완전히 동일 — $(100, 100)$ 은 애초에 서포트 벡터가 아니었기 때문.
- 마진 최대화는 서포트 벡터 기준

실습으로 재현

서포트 벡터 **아닌** 점을 가장 바깥으로 크게 이동시켜 재학습하면 w, b 가 소수점 아래까지 동일. 반대로 로지스틱회귀는 같은 점 이동에도 w 가 달라진다 — “모든 점이 손실에 기여”하는 모델에서는 멀리 있는 점도 (비록 작게라도) 기울기에 영향을 주므로.

그림으로: 옮겨도 경계는 그대로



- 오렌지 = 서포트 벡터 $(3, 3)$, $(-3, -3)$ — 이 둘만 경계를 떠받친다.
- $(4, 3)$ 을 화면 밖 $(100, 100)$ 까지 옮겨도 검은 경계선은 **소수점까지 동일**.
- “클러스터를 넓게 벌린다”는 직관은 틀렸다 — 마진 최대화는 서포트 벡터 기준.

자주 묻는 질문 (1/2)

Q. 서포트 벡터가 몇 개나 되나요?

- 데이터에 따라 다르지만 보통 전체 중 소수 (위 예시: 6개 중 2개).
- 개수가 적을수록 “기억해야 할 정보”가 적다 — 예측 시에도 전체가 아닌 **서포트 벡터와만** 비교하면 된다(kNN은 전체 데이터를 다 봐야 하는 것과 대조).

Q. $w^\top x + b$ 의 값이 “1”이든 “0.5”든 뭐가 다른가요?

- 숫자 “1” 자체는 아무 의미 없다 — (w, b) 를 k 배로 쓰면 $w^\top x + b$ 도 k 배가 된다.
- 중요한 것은 **비율**: 제약이 기능적 마진을 “1로 고정”하는 자물쇠 역할을 하고, 그 고정이 있어야 $\frac{2}{\|w\|}$ 가 스케일에 무관한 실제 거리가 된다.
- 제약을 ≥ 0.5 로 쓰면 w 가 정확히 2배(경계 동일), 마진 $2/\|w\|$ 는 절반 — **결론은 결국 동일**.

자주 묻는 질문 (2/2)

Q. 라벨을 왜 굳이 $-1/+1$ 로 바꾸나요?

- $y^{(i)}(w^\top x^{(i)} + b)$ 하나의 식으로 “올바른 클래스 쪽에 있는가”와 “얼마나 여유 있게 있는가”를 동시에 표현하기 위한 표기상의 편의.
- $y = \pm 1$ 이면 “곱이 클수록 좋다”는 하나의 부등식으로 통일 — 0/1 라벨이었다면 클래스마다 부등호 방향이 다른 두 식을 따로 다뤄야 했다.

Q. 로지스틱회귀와 같은 $w^\top x + b = 0$ 인데, 뭐가 다른가요?

- 어떤 경계를 뽑을지가 다르다: 로지스틱회귀는 모든 점이 손실에 기여해 분포 전체에 민감 (매끄러운 경계), SVM은 마진 바깥 점의 손실이 정확히 0이라 오직 서포트 벡터만 경계를 결정(각진 경계).
- 이상치 견고성: 이상치가 서포트 벡터가 안 되는 한 SVM은 무시; 로지스틱회귀는 아무리 멀어도 아주 작은 기울기로 손실에 영향 — 서로 다른 트레이드오프.

5.2 소프트 마진: 완벽히 나뉘지 않는 데이터

도입: 하드 마진의 치명적인 전제

- 그런데 치명적인 전제: 데이터가 완벽히 선형분리 가능.

문제의 심각성

어떤 (w, b) 로도 제약을 모두 만족 못 하면(불일치, infeasible) 이차계획을 풀 수 없다 — 하드 마진 SVM은 라벨 오류 단 하나만 있어도 해 자체가 존재하지 않는 모델. 그대로 실전에 쓸 수 없다.

소프트 마진: 위반을 허용하는 법

“제약을 만족 못 하면, 얼마만큼 못 했는지 재서 벌을 부리고, 벌의 크기는 하이퍼파라미터로 조절한다.”

- 각 데이터마다 위반을 어느 정도 허용하는 **여유 변수**(slack variable) $\xi^{(i)} \geq 0$:

$$y^{(i)}(w^\top x^{(i)} + b) \geq 1 - \xi^{(i)}$$

$\xi^{(i)}$ 의 값	의미
0	5.1절 제약과 정확히 같음
0.5	마진 경계 안쪽으로 0.5쯤 들어와도 괜찮다 (정답, 마진 위반)
1	결정 경계(마진 0) 위에 있어도 괜찮다
> 1	경계 너머(반대쪽 영역)로 넘어가도 되는 허락

목적함수: 마진 최대화 vs 위반 최소화

- 마진 최대화 vs 위반 최소화 트레이드오프
- 힌지 손실로 다시 쓸 수 있다

C : 이 절의 유일한 손잡이

C 가 **크면** 위반에 더 엄격 $\Rightarrow$ 라벨에 충실 (과적합 위험). C 가 **작으면** 마진을 넓게 잡는 대신 위반을 더 허용 (과소적합 위험). 6장의 정규화 세기 조절과 **정확히 같은 종류**의 트레이드오프.

“힌지”의 모양과 C 라는 손잡이

$$L(f) = \max(0, 1 - f)$$


- $f < 1$: 기울기 -1 로 **선형 증가**
- $f \geq 1$: **정확히 0으로 꺾여** 평평해짐 ($f = 1$ 에서 “접힌”(kink) 삼각형 — 이름의 유래)

C : “이상치 용인도”를 조절하는 손잡이

C 크면 “위반을 무겁게 벌하라” = **라벨에 충실하게** 경계를 맞추라(과적합 위험). C 작으면 “라벨이 틀려도 괜찮으니 대신 마진을 넓게” (과소적합 위험).

2장의 **학습률**, 4장의 k 와 함께 모델의 “**데이터 충실도 vs 단순함**”을 조절. 5.3절 RBF에서는 여기에 경계 **구부러짐**을 조절하는 γ 가 더 생긴다.

그림으로: 힌지 손실의 모양



- $f \geq 1$ (마진 밖)이면 손실이 **정확히 0** — 힌지의 핵심 성질.
- $f = 1$ 에서 기울기가 꺾이는 지점(kink)이 “힌지”라는 이름의 유래.
- 점선(교차 엔트로피)은 아무리 잘 맞혀도 손실이 0이 안 됨 — 이 차이가 서포트 벡터 개념을 가능하게 한다.

손으로 한 번: 힌지 손실과 C 의 효과

점	$y^{(i)}(w^\top x^{(i)} + b)$	힌지 손실
$(3, 3), +1$	$0.2 \cdot 3 + 0.2 \cdot 3 = 1.2$	$\max(0, 1 - 1.2) = 0$
$(-3, -3), -1$	$(-1)(-0.6 - 0.6) = 1.2$	0
$(2, -3), +1$	$0.2 \cdot 2 + 0.2(-3) = -0.2$	$\max(0, 1.2) = 1.2$
$(-2, 3), -1$	$(-1)(-0.4 + 0.6) = -0.2$	1.2

전체 목적함수: $\frac{1}{2}\|w\|^2 = 0.04, \sum \xi^{(i)} = 2.4$ 이므로

$$C=0.1 : J = 0.04 + 0.1 \times 2.4 = 0.28$$

$$C=10 : J = 0.04 + 10 \times 2.4 = 24.04$$

- C 가 커질수록 이상치 손실이 지배

손으로 한 번: 힌지 손실의 그래디언트

$f = y^{(i)}(w^\top x^{(i)} + b)$, $L = \max(0, 1 - f)$ 의 그래디언트:

$$\frac{\partial L}{\partial w} = \begin{cases} -y^{(i)}x^{(i)} & \text{if } f < 1 \quad (\text{마진 위반}) \\ 0 & \text{if } f \geq 1 \quad (\text{마진 만족}) \end{cases} \quad \frac{\partial L}{\partial b} = \begin{cases} -y^{(i)} & \text{if } f < 1 \\ 0 & \text{if } f \geq 1 \end{cases}$$

- 마진을 만족하는 점의 기여는 **정확히 0**.
- 이 차이가 **서포트 벡터** 개념을 가능하게 한다.

학습 궤적으로 확인: 대칭 데이터

에폭	$w_1 (= w_2)$	b
1	0.0333	0.0000
10	0.1750	0.0000
100	0.1719	0.0000
2000	0.1735	0.0000

- 몇십 에폭 만에 $w \approx 0.17$ 로 수렴 — 5.1절의 정확해 $(1/6, 1/6) \approx (0.167, 0.167)$ 에 잘 붙는다.

소프트 마진의 세 가지 영역

영역	조건	$\xi^{(i)} = \max(0, 1 - f)$	의미
① 마진 바깥 정답	$f \geq 1$	0	손실 0, 경계에 영향 없음(서포트 벡터 아님)
② 마진 안 정답	$0 < f < 1$	$1 - f$	마진 일부 침범 — 경계에 기여(서포트 벡터)
③ 경계 너머	$f \leq 0$	≥ 1	오분류 상태 — 손실 1 이상, 가장 강하게 기여

- ξ 의 크기가 “문제의 심각도”를 연속적으로 재줌.
- $f = 0.9$ (②): $\xi = 0.1$ 으로 거의 정상. $f = -0.2$ (③): $\xi = 1.2$ 로 12배 비싼 오류.

실습: 소프트 마진의 세 영역을 눈으로 보자

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.svm import SVC

# 절5.1 대각선클러스터 + 이상치두개
rng = np.random.default_rng(7)
X = np.vstack([rng.normal([5, 5], 0.8, (40, 2)),
               rng.normal([-5, -5], 0.8, (40, 2)),
               np.array([[2.0, -3.0], [-2.0, 3.0]])])
y = np.r_[np.ones(40), -np.ones(40), [1.0, -1.0]]

clf = SVC(kernel="linear", C=1.0).fit(X, y)
wc, bc = clf.coef_[0], clf.intercept_[0]
sv = X[clf.support_] # 서포트벡터만
outs = X[80:82]      # 이상치두개


x1 = np.linspace(-8, 8, 100)
f_line = lambda c: (-wc[0]*x1 - bc + c) / wc[1] # f = c 의직선

fig, ax = plt.subplots(figsize=(6.5, 6.5))
for lbl, col in [(1, "red"), (-1, "blue")]:
    ax.scatter(X[y == lbl, 0], X[y == lbl, 1], color=col,
               alpha=0.6, label=f"y={lbl}")
ax.plot(x1, f_line(0), "k", lw=2, label="결정 경계 (f=0)")
ax.plot(x1, f_line(1), "g--", lw=1, label="마진 경계 (f=+1)")
ax.plot(x1, f_line(-1), "g--", lw=1, label="마진 경계 (f=-1)")
ax.scatter(sv[:, 0], sv[:, 1], s=160, facecolors="none",
           edgecolors="orange", lw=2.5, label="서포트 벡터")
ax.scatter(outs[:, 0], outs[:, 1], s=260, marker="*",
           facecolors="white", edgecolors="red", lw=1.5, label="이상치")
ax.set_aspect("equal"); ax.legend(loc="upper left", fontsize=9)
ax.set_title("소프트 마진: 이상치가마진안너머로 / 허용됨 (C=1)")
plt.show()

# 이상치가어느영역②③ (/)에 빠졌는지직접계산
for i in [80, 81]:
    m = y[i] * (wc @ X[i] + bc)
    print(f"이상치 {tuple(X[i])}: f={m:.3f} -> xi={max(0.0, 1-m):.3f}, "
          f"서포트{' 벡터' if i in clf.support_ else '아님'}")
print(f"서포트 벡터 {len(sv)개} / 전체 {len(X)개}, 마진 2/||w|| = {2/np.linalg.norm(wc):.3f}")
```

그림으로 읽기: 하드 마진과의 세 가지 차이

소프트 마진: 이상치가 마진 안/너머로 허용됨 ($C=1$)



- ① **마진 경계 안에 데이터가 들어와 있다** — 5.1절에선 $f = \pm 1$ 사이에 아무 점도 없었지만, 여기서는 이상치가 마진 안(또는 경계 너머)에 있다. 허용된 것이지 결함이 아니다.
- ② **서포트 벡터의 위치가 바뀌었다** — 이상치 두 개가 서포트 벡터에 포함(코드 출력: 인덱스 80, 81 모두 $f = +1.000$, $\xi = 0$). 이상치를 “받아안으려다” 마진 경계 위에 정확히 올려놓은 것.
- ③ **마진이 5.1절보다 좁아졌다** — $2/\|w\|$ 가 ≈ 8.5 보다 작다. 이상치를 받으려면 $\|w\|$ 가 커져 마진이 좁아진다 — C 가 조절하는 트레이드오프의 단면.

이상치는 “완벽한 이상치”(다른 클래스 근처)가 아니라 **경계 쪽 클러스터 사이에 놓인 점**. $C = 1$ 에선 어느 영역(② 또는 ③)에 빠지는지 예측해라.

실습: C 스윙 — 이상치를 무시할지 받아안을지

```
import numpy as np
from sklearn.svm import SVC

# 클러스터  $\pm(2.5, 2.5)$  스프레드 0.6, 각개 40 + 이상치  $(-1.6, 0.8)$ 
rng = np.random.default_rng(21)
n = 40
X = np.vstack([rng.normal([2.5, 2.5], 0.6, (n, 2)),
               rng.normal([-2.5, -2.5], 0.6, (n, 2)),
               np.array([[-1.6, 0.8]])])
y = np.r_[np.ones(n), -np.ones(n), [1.0]]

# 같은데이터를 C = 0.01, 0.1, 1, 10, 100 으로학습
Cs = [0.01, 0.1, 1.0, 10.0, 100.0]
print(f"{'C':>7s} 마진{' 2/||w||':>12s} {'b/||w||':>8s} "
      f"{'n_SV':>5s} 이상치{' f':>10s} 정상점{' 오분류':>12s}")
for C in Cs:
    clf = SVC(kernel="linear", C=C).fit(X, y)
    wc, bc = clf.coef_[0], clf.intercept_[0]
    om = y[-1] * (wc @ X[-1] + bc) # 이상치의기능적마진
    mis = (clf.predict(X[:-1]) != y[:-1]).sum()
    print(f"C:7.2f {2/np.linalg.norm(wc):12.3f} "
          f"{bc/np.linalg.norm(wc):+8.3f} {len(clf.support_):5d} "
          f"{om:10.3f} {mis:12d}")
```

C 스윙 결과

C	마진 $2/\ w\ $	$b/\ w\ $	서포트 벡터 수	이상치 f
0.01	6.01	+0.02	14	-0.16
0.1	4.61	+0.23	5	+0.08
1.0	2.30	+0.65	2	+1.00
10.0	2.30	+0.65	2	+1.00
100.0	2.30	+0.65	2	+1.00

- $C = 0.01$: 이상치 무시, 마진 6.01
- $C = 0.1$: 일부 수용, 마진 4.61
- $C \geq 1$: 완전 수용, 마진 2.30

C 스윙: “지수” 현상


- $C = 1$ 에서 이미 이상치를 완전히 수용했으므로 $C = 10, 100$ 으로 더 올려도 결과(경계·마진·SV)가 모두 동일.

실용적 함의: C 튜닝의 상한선


이 “지수” 현상은 C 튜닝의 실용적 상한선을 알려준다 — 검증셋 정확도가 더 이상 변하지 않는 C 이상은 과적합 위험만 키울 뿐.

C 스윙: 이상치를 무시할지(작은 C) 받아안을지(큰 C) — 마진 대 위반


C=0.01: 마진=6.01, n_SV=14, 이상치 $y(wTx+b)=-0.16$




C=0.1: 마진=4.61, n_SV=5, 이상치 $y(wTx+b)=+0.07$



C=1.0: 마진=2.30, n_SV=2, 이상치 $y(wTx+b)=+1.00$



C=100.0: 마진=2.30, n_SV=2, 이상치 $y(wTx+b)=+1.00$



- $C = 0.01$: 이상치(빨간 별)가 결정 경계 너머(엷은 색 영역)에 남아 있음.
- $C = 100$: 이상치가 마진 경계 위에 정확히 놓여 있음.
- 같은 데이터, 다른 $C \Rightarrow$ 다른 경계 — C 가 “경계의 위치”를 실제로 결정한다는 직접적 증거.

라벨 노이즈: C 가 과적합을 조절하는 방식

- C 가 클수록 틀린 라벨까지 맞춰 경계 이동

```
rng2 = np.random.default_rng(5)
n2 = 100
Xn = np.vstack([rng2.normal([3, 3], 1.5, (n2, 2)),
                rng2.normal([-3, -3], 1.5, (n2, 2))])
yn = np.r_[np.ones(n2), -np.ones(n2)]
pos_scores = Xn[:n2].sum(axis=1) # 경계원점()에 가까울수록 작음
flip_idx = np.argsort(pos_scores)[:30] # +1 중 경계가 가장 가까운 개 30
yn[flip_idx] = -1 # 라벨 15% 뒤집기
# ... SVC(C)와 을 LogisticRegression 각각 fit, train/test score 출력
```


라벨 노이즈 결과: 과적합의 교과서적 신호

모델	train	test	$b/\ w\ $
SVC $C = 0.01$	0.865	0.968	-1.88
SVC $C = 0.1$	0.995	0.877	-3.13
SVC $C = 1.0$	0.995	0.870	-3.22
SVC $C = 10$	0.995	0.875	-3.17
SVC $C = 100$	1.000	0.877	-3.13
로지스틱회귀	0.995	0.873	-3.17

- $C = 0.01$: **test 0.968, train 0.865**
- 이 패턴(**train**↑ **test**↓) = 과적합의 교과서적 신호, C 가 그 조절 밸브.

$b/\|w\|$: 경계가 얼마나 밀렸는가

- $b/\|w\|$ = 결정 경계의 **원점에서의 거리**(부호 포함) — “경계가 얼마나 밀렸는가”.
- C 가 클수록 라벨(=오류)에 충실 $\Rightarrow$ 경계가 오류 쪽으로 당겨짐 $\Rightarrow$ **일반화 성능 하락**.



- $C = 0.01$ (청색)의 경계가 라벨 오류(빨간 $\times$) **가장 멀리 떨어져 있음**.
- $C = 100$ (적색)과 로지스틱회귀(보라)가 오류 쪽으로 **가장 가깝게 밀려 있음**.
- 로지스틱회귀 $\approx C \approx 1$ 의 SVM과 거의 일치 — 교차 엔트로피가 힌지 손실과 “거의 같은” 모양이라 라벨 오류 반응이 유사.

힌지 손실 vs 교차 엔트로피: “기여가 사라지는” 차이

$y = +1$ 인 점의 w 그래디언트 기여 계수

f	힌지 기여	교차엔트로피 기여
-2.0	3.0000	0.8808
-1.0	2.0000	0.7311
-0.5	1.5000	0.6225
0.0	1.0000	0.5000
0.5	0.5000	0.3775
1.0	0.0000	0.2689
2.0	0.0000	0.1192
3.0	0.0000	0.0474

힌지

- $f \geq 1$ 에서 **정확히 0** — 그 점을 아예 무시
- “서포트 벡터만 경계를 결정”

교차 엔트로피

- 0으로 수렴만 ($f = 3$ 에서도 0.047)
- “모든 점이 손실에 계속 기여”

실습: 힌지 손실 경사하강법 구현

```
def hinge_loss_gradient_descent(X, y, C, alpha, epochs):
    # y[i]는 -1 또는 +1
    m, n = len(X), len(X[0])
    w, b = [0.0] * n, 0.0
    for _ in range(epochs):
        grad_w, grad_b = [0.0] * n, 0.0
        for i in range(m):
            margin = y[i] * (sum(w[j] * X[i][j] for j in range(n)) + b)
            if margin < 1: # 마진을 위반한 점만 그라디언트에 기여
                for j in range(n):
                    grad_w[j] += -y[i] * X[i][j]
                grad_b += -y[i]
        for j in range(n):
            grad_w[j] = w[j] + C * grad_w[j] / m # ||w||^2 항 + 힌지항
        grad_b = C * grad_b / m
        for j in range(n):
            w[j] -= alpha * grad_w[j]
        b -= alpha * grad_b
    return w, b
```

이 코드의 핵심 줄: `if margin < 1`

- `if margin < 1`: 마진 만족 시 `grad 0`

자주 하는 실수: C 를 “느낌”으로 고정하기

- C 를 한 번 정하면 그 값이 이상치를 얼마나 용인할지를 사실상 **결정**해버린다.

C 는 검증셋으로 튜닝하는 하이퍼파라미터

2장의 학습률, 4장의 k 와 마찬가지로 **검증셋 성능으로 튜닝**해야 한다 —

`sklearn.model_selection.GridSearchCV`로 여러 C 값(로그 스케일로 0.01, 0.1, 1, 10, 100)을 검증셋 정확도로 비교하는 것이 표준.

역사: “허용하는 마진”의 아이디어

- 실전 데이터는 노이즈가 있으므로 소프트 마진

1/C가 정규화 세기와 정확히 대응

목적함수를 데이터 수 m 기준으로 쓰면

$$\frac{1}{2m} \|w\|^2 + \lambda \sum \xi \quad (\lambda = 1/(mC))$$

6장의 L2 정규화 $\frac{\lambda}{2} \|w\|^2 +$ 손실과 구조적으로 동일한 형태.

“SVM의 C 튜닝”과 “로지스틱회귀의 정규화 세기 λ 튜닝”은 같은 종류의 하이퍼파라미터 튜닝 — C 가 작을수록 모델이 더 단순(편향↑ 분산↓).



AT&T Bell Labs, Holmdel, NJ

Cortes & Vapnik (1995) “Support-Vector Networks”의 소속 연구소 — 소프트 마진이 여기서 완성됐다.

이 절의 핵심 세 가지


- ① **소프트 마진: 제약 풀기 + 위반 페널티**
- ② **힌지 손실의 “비활성화” 성질**이 서포트 벡터 개념을 가능하게 함 — 마진 바깥의 점은 경계에 아무 영향을 주지 않는다.

5.3절(커널 트릭)으로 넘어가기 전, 연결고리

소프트 마진 목적함수 $\frac{1}{2}\|w\|^2 + C \sum \xi$ 에서 $w^\top x$ 가 **내적** 형태로만 등장한다. 커널 트릭은 이 $w^\top x$ 를 $K(x, x')$ 로 대체하는 것 — **소프트 마진 목적함수는 그대로 두고, 내적만 커널로 바꾼다.**

그림으로: C 스윙 — 마진 대 위반의 손잡이

C 스윙: 이상치를 무시할지(작은 C) 받아들일지(큰 C) — 마진 대 위반



- $C = 0.01$: 마진 6.01, 서포트 벡터 14개 — 위반을 너그럽게 허용, 마진이 넓다.
- $C = 1.0$ 부터 $C = 100.0$ 까지: 마진 2.30, 서포트 벡터 2개로 고정 — 위반을 거의 허용하지 않는 하드 마진에 수렴.
- C 가 작을수록 마진 폭, C 가 클수록 서포트 벡터 개수가 준다.

자주 묻는 질문 (1/2)

Q. C 가 무한대에 가까워지면?

- $C \rightarrow \infty$: 아주 작은 위반($\xi^{(i)} > 0$)에도 목적함수가 **폭발** $\Rightarrow$ 사실상 위반을 전혀 허용하지 않는 5.1절 **하드 마진**과 같아짐.
- $C \rightarrow 0$: 위반 페널티가 사라져 마진을 최대로 넓히는 것 ($w = 0$)만 남음 — **아무것도 분류하지 않는** 모델.
- 그래서 C 는 항상 이 두 극단 사이의 **적당한 값**을 찾는 문제.

Q. 힌지 손실 vs 교차 엔트로피의 차이?

- 둘 다 “마진(확률)이 부족할수록 손실 커진다”.
- 힌지는 마진이 **충분하면** (≥ 1) 손실이 **정확히 0**이 되어 그 점에 더 이상 신경 쓰지 않음.
- 교차 엔트로피는 아무리 확신 있게 맞혀도 손실이 정확히 0이 안 되고 계속 아주 조금씩 줄어듦.

자주 묻는 질문 (2/2)

Q. 서포트 벡터의 개수가 C 에 따라 변하나?

- C 스윙 표에서: $C = 0.01 \rightarrow 14$ 개, $C = 0.1 \rightarrow 5$ 개, $C \geq 1 \rightarrow 2$ 개.
- C 가 작을수록 **SV가 많아짐** — 이상치를 무시하고 마진을 넓히려면 더 많은 점이 마진 경계에 달라붙어야 하므로.
- SV 개수 = SVM의 **효과적 모델 크기**(예측 시 비교할 점의 수) — C 튜닝의 부수적 효과로 “모델의 간결함”도 함께 조절.

Q. 이상치가 많이 있으면 C 튜닝으로 해결되지 않나요?

- 이상치가 **데이터의 상당 부분**(예: 30% 이상)이면 어느 쪽을 택해도 일반화 성능이 떨어짐 — 작은 C 는 진짜 신호도 함께 무시, 큰 C 는 노이즈에 과적합.
- 이런 때는 **모델이 아니라 데이터 자체**의 문제를 먼저: 라벨링 품질 점검, 이상치 탐지(4장 kNN, 8장 앙상블), **주변부 잘라내기**(클러스터 밖에 고립된 의심점 전처리 제거).
- C 는 “몇 % 수준의 노이즈”를 조절하는 손잡이지, “데이터의 절반이 틀린” 문제를 해결하는 **마법이 아니다**.

5.3 커널 트릭: 선형분리가 안 되는 데이터

도입: 5.1~5.2절이 놓친 마지막 벽

- 5.1 하드 마진: 선형분리 가능을 **전제**
- 5.2 소프트 마진: 그 전제는 포기했으나, **결정 경계가 직선**이라는 전제는 여전히 유지
- 이번 절의 데이터: 노이즈가 **없어도** 직선으로는 **원리적으로** 못 나뉨

XOR

- 네 클러스터(± 1 근처)에서 $1 \cdot 3$ 사분면 = A, $2 \cdot 4$ 사분면 = B.
- 직선은 “한쪽 끝과 반대쪽 끝”을 가를 뿐, **대각선은 가를 수 없다.**



동심원

- 안쪽 원과 바깥쪽 원의 두 클래스.
- 직선이 아니라 **원**으로만 나뉨.

경계를 휘게 하면서도 5.1절의 모든 재산(마진 최대화, 서포트 벡터, $2/\|w\|$ 공식)을 유지할 수 있을까?

그림으로: 직선으로 원리적으로 못 나뉘는 두 패턴

노이즈가 없어도 직선(초평면)으로는 원리적으로 못 나뉜다





- XOR(왼쪽): 1·3사분면 vs 2·4사분면 — 대각선은 직선 하나로 못 자른다.
- 동심원(오른쪽): 안쪽/바깥쪽 원 — 원으로만 나뉜다.
- 노이즈를 없애도 여전히 못 나뉜다 — 5.2절의 소프트 마진으로도 해결 불가.

고차원으로 옮기면 보이는 것: 동심원

$x = (x_1, x_2)$ 를 $\phi(x) = (x_1, x_2, x_1^2 + x_2^2)$ 로 올리면:

- 안쪽 원환체(반경 ~ 0.4)의 모든 점 $\rightarrow$ 한 고도 $z \approx 0.4^2 = 0.16$ 에,
- 바깥쪽 원환체(반경 ~ 1.0)의 모든 점 $\rightarrow$ 다른 고도 $z \approx 1.0^2 = 1.0$ 에 붙는다.
- 세 번째 축 추가 시 두 고도로 벌어짐



그림으로: 동심원이 3차원에서 두 고도로 벌어짐



- 왼쪽: $\phi(x) = (x_1, x_2, x_1^2 + x_2^2)$ 로 올린 3차원 산점도 — 바깥쪽 원(파랑)은 $z \approx 1.0$, 안쪽 원(빨강)은 $z \approx 0.16$.
- 오른쪽: 그 사이 $z = 0.5$ 근방의 **평평한 분리 평면** 하나로 두 클래스가 완전히 갈린다.
- 3차원의 평면 $\equiv$ 원래 2차원의 원형 경계.

그림으로 읽기: 고도로 벌리면 평면이 자른다

- 좌: 동심원 $\rightarrow z = x_1^2 + x_2^2$ 축으로 들어올림.
- 우: 두 원환체, **평면** $z = 0.5$ 하나로 자름.
- 평면의 2차원 투영 = **원형** 경계.



일반 원리

곡면으로만 나뉘는 관계 $\rightarrow$ 곡면의
고도를 새 특징으로 추가 $\rightarrow$ **평면으로**
나뉘는 관계.

XOR도 동일: (x_1, x_2, x_1x_2) 로 올리면 평면
분리 문제.

차원 문제, 그리고 커널 트릭 한 문장

- **커널 트릭**(kernel trick, Cortès & Vapnik 1995)은 이걸 **피해간다**:
 - ▶ SVM의 최적화 문제를 **라그랑주 쌍대**로 다시 쓰면, 데이터가 항상 $\phi(x^{(i)}) \cdot \phi(x^{(j)})$ (**내적**) 형태로만 등장함을 알 수 있다.
 - ▶ 그러면 ϕ 를 직접 계산하지 않고, 이 내적값을 **곧바로** 계산해주는 **커널 함수** $K(x, x') = \phi(x) \cdot \phi(x')$ 만 있으면 충분.

이게 전부다

커널 트릭은 “새로운 모델”이 아니라, **같은 모델의 계산 방식을 고차원 내적으로만 다시 쓴 것.**

쌍대 문제: 내적이 드러나는 자리

$$\text{최대화 } \sum_i \alpha^{(i)} - \frac{1}{2} \sum_{i,j} \alpha^{(i)} \alpha^{(j)} y^{(i)} y^{(j)} \phi(x^{(i)}) \cdot \phi(x^{(j)}) \quad \text{s.t. } \alpha^{(i)} \geq 0, \sum_i \alpha^{(i)} y^{(i)} = 0$$

- 내적 $\phi(x^{(i)}) \cdot \phi(x^{(j)})$ 만 $K(x^{(i)}, x^{(j)})$ 로 교체

왜 내적으로만 나오게 된 것일까

직관: w =경계의 **방향**, $\alpha^{(i)}$ =각 점이 경계를 **떠받치는 세기**. KKT에 의해 비-SV의 α 는 0 $\Rightarrow$ $w = \sum_{i \in \text{SV}} \alpha^{(i)} y^{(i)} \phi(x^{(i)})$ (서포트 벡터의 **선형 결합**). w 가 SV들의 합으로 표현되는 순간 $w^\top \phi(x^{(j)})$ 는 $\sum_i \alpha^{(i)} y^{(i)} \phi(x^{(i)}) \cdot \phi(x^{(j)})$ 로 펼쳐져 — 데이터의 등장 방식이 **내적 쌍으로 통일**. “내적 쌍”만 계산할 수 있으면 ϕ 자체는 **영원히 볼 필요 없음**.

손으로 한 번: 6개 점을 2×2 커널 행렬로

- SV는 두 점뿐, 나머지 α 는 0
- 제약 $\sum_i \alpha^{(i)} y^{(i)} = 0$ 은 $\alpha_1(+1) + \alpha_4(-1) = 0 \Rightarrow \alpha_1 = \alpha_4 = a$ 강제.
- 쌍대 목적함수는 일변수 2차함수

2×2 커널 행렬과 꼭짓점

SV 두 점의 2×2 커널(내적) 행렬:

$$K = \begin{pmatrix} (3,3) \cdot (3,3) & (3,3) \cdot (-3,-3) \\ (3,3) \cdot (-3,-3) & (-3,-3) \cdot (-3,-3) \end{pmatrix} = \begin{pmatrix} 18 & -18 \\ -18 & 18 \end{pmatrix}$$

- $q = 18 + 18 + 2(1)(-1)(-18) = 72$.
- $f(a)$ 는 $f'(a) = 2 - qa = 0$ 에서 꼭짓점: $a^* = 2/q = 1/36$.
- KKT로 w 를 복원:

$$w = \sum_i \alpha^{(i)} y^{(i)} x^{(i)} = \frac{1}{36} (+1)(3,3) + \frac{1}{36} (-1)(-3,-3) = \left(\frac{1}{6}, \frac{1}{6}\right)$$

결과: 5.1절의 primal 손계산 해와 숫자 하나까지 일치

$b = 0$ (대칭성). 실습 노트 3부에서 이 계산을 코드로 돌려 6개 제약의 기능적 마진 $[1, 1.1667, 1.1667, 1, 1.1667, 1.1667]$ (두 SV만 정확히 = 1)과 기하적 마진 $2/\|w\| = 8.485$ 까지 **primal과 동일함**을 확인.

primal과 dual이 같은 해를 주는 것(강렬한 쌍대성)은 SVM이 **볼록 최적화** 문제이기 때문에 성립 — 이 절의 커널 트릭 이야기 자체가 이 성질에 의존.

우리가 계산한 것은 **2×2 내적 행렬**뿐 — primal에선 $w = (1/6, 1/6)$ 을 직접 들고 다녔지만, 쌍대에선 w 를 알 **필요 없이 커널값(내적)**으로만 복원. 이 구조가 RBF처럼 ϕ 가 무한차원인 경우에도 그대로 작동.

커널 함수: 내적을 우회한다

가장 널리 쓰이는 커널:

다항 커널(polynomial)

$$K(x, x') = (x \cdot x' + c)^d$$

“도수 d 이하의 모든 단항식”을 내포.

$(x \cdot x' + 1)^d$ 를 전개하면 도수 d 이하의 모든 단항식 $x_1^{a_1} x_2^{a_2} \cdots (a_1 + a_2 + \cdots \leq d)$ 이 (일정한 계수로) 전부 섞여 나온다.

RBF(가우시안) 커널

$$K(x, x') = \exp\left(-\frac{\|x - x'\|^2}{2\sigma^2}\right)$$

두 점이 가까울수록 1에, 멀수록 0에 가까운 **유사도 함수**. **무한 차원**의 ϕ 에 대응한다는 것이 알려져 있는데도, 커널 함수 자체는 **유클리드 거리** 하나로 계산.

다항 커널이 “도수 2”를 정확히 어떻게 담는가

- $d = 2$: $(x \cdot x' + 1)^2$ 를 전개하면

$$(x_1x'_1 + x_2x'_2)^2 + 2(x_1x'_1 + x_2x'_2) + 1$$

⇒ 도수 2 (x_1^2, x_2^2, x_1x_2), 도수 1 (x_1, x_2), 도수 0 (상수) 단항식 **전부** 포함.

- 도수 2 이하 단항식 공간 내적

XOR에는 도수 2가 정확히 필요하다

사분면 교차를 만드는 핵심 단항식이 x_1x_2 (도수 2)이므로: **도수 1**(=선형)은 원점을 기준으로 교차하는 양 클래스를 직선 하나로 못 나누어 50% 근처에 머물고, **도수 2**는 x_1x_2 항을 포함해 거의 완벽.

실습에서 $d = 1$ 은 정확도 0.74, $d = 2$ 는 1.00 — **커널의 “도수” 하나만 바꿨을 뿐.**

RBF 커널: “봉우리”의 유사도

$K(x, x') = e^{-\|x-x'\|^2/2\sigma^2}$ 는 두 점이 가까우면 ≈ 1 , 멀면 ≈ 0 인 “얼마나 닮았는가”를 재는 함수.

```
def rbf_kernel(x1, x2, sigma):  
    sq_dist = sum((x1[i] - x2[i]) ** 2 for i in range(len(x1)))  
    return math.exp(-sq_dist / (2 * sigma ** 2))
```

σ 작다(좁은 봉우리)

- 아주 가까운 점만 “비슷”
- γ 큼 $\Rightarrow$ 경계 구불
- 과적합 위험

σ 크다(넓은 봉우리)

- 멀리 있는 점도 “비슷”
- γ 작음 $\Rightarrow$ 경계 단순
- 과소적합 위험

RBF의 무한차원 실체, 실효 차원, 머서 조건

- $\|x - x'\|^2 = \|x\|^2 + \|x'\|^2 - 2x \cdot x'$ 로 넣고 $e^{2\gamma x \cdot x'}$ 를 테일러 전개하면, $\phi(x)$ 는 모든 도수의 모든 단항식에 가우시안 인자를 둔 무한개의 성분 $\phi_\alpha(x)$ 를 가진다.
- 실효 차원은 데이터 개수로 제한

머서(Mercer) 조건 — 유효 커널의 필요 조건

커널 함수가 유효하려면 커널 행렬이 모든 데이터에 대해 양의 준정부호(모든 고유값 ≥ 0)여야 한다. RBF: 60개 4차원($\gamma = 0.5$)에서 최소 고유값 $5.07 \times 10^{-3} > 0$, 랭크 60 — 직접 확인. 유한 절단만으로도 꽤 정확한 근사 — “무한차원”은 개념적 차원일 뿐 계산 비용이 무한하다는 뜻이 아님.

실습: RBF 커널로 비선형 분류

```
from sklearn.datasets import make_circles
from sklearn.svm import SVC
from sklearn.model_selection import train_test_split


X, y = make_circles(n_samples=200, noise=0.1, factor=0.4, random_state=0)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=0)

linear_svm = SVC(kernel="linear").fit(X_train, y_train)
rbf_svm     = SVC(kernel="rbf", gamma=2.0).fit(X_train, y_train)

print("선형 커널정확도 :", round(linear_svm.score(X_test, y_test), 3))
print("RBF 커널정확도 :", round(rbf_svm.score(X_test, y_test), 3))
```

make_circles: 바깥쪽 원환체(클래스 0, 반경 ~ 1.0)와 안쪽 원환체(클래스 1, 반경 ~ 0.4)가 동심원 모양으로 얹혀 있어 어떤 직선으로도 나눌 수 없음. 라벨 번호는 임의 배정에 불과 — 결과와 무관.

그림으로 읽기: 커널 하나만 바꿨을 뿐



- **선형 커널**(좌): 동심원을 직선 하나로 어정쩡하게 자를 뿐 — 정확도 **0.52**(동전 던지기 수준).
- **RBF 커널**(우): 원형 결정 경계로 안쪽 · 바깥쪽 원을 완벽히 분리 — 정확도 **1.00**.

서포트 벡터 개수가 핵심

선형 커널: 학습 데이터 **137개**($\approx 68\%$)를 SV로 끌고 옴. RBF 커널: **31개**만 SV로 쓰고 나머지 169개는 마진 바깥에 둬.

5.2절의 “서포트 벡터가 경계를 떠받친다”는 원칙이 **비선형 경계에도 그대로** 적용되는 직접적 증거.

실습: γ 스윕 — 경계가 얼마나 구불거릴 수 있는가

```
def plot_boundary(ax, clf, title, data=X, ydata=y):
    h = 0.05
    lims = [data[:,0].min()-0.5, data[:,0].max()+0.5,
            data[:,1].min()-0.5, data[:,1].max()+0.5]
    xx, yy = np.meshgrid(np.arange(lims[0], lims[1], h),
                          np.arange(lims[2], lims[3], h))
    Z = clf.predict(np.c_[xx.ravel(), yy.ravel()]).reshape(xx.shape)
    ax.contourf(xx, yy, Z, alpha=0.35, cmap="coolwarm")
    ax.scatter(data[ydata==0,0], data[ydata==0,1], c="blue", s=15,
               label="class 0 (outer)")
    ax.scatter(data[ydata==1,0], data[ydata==1,1], c="red", s=15,
               label="class 1 (inner)")
    ax.scatter(X_train[clf.support_][:,0], X_train[clf.support_][:,1],
               s=45, facecolors="none", edgecolors="k", lw=1.2,
               label="support vector")
    ax.set_title(title, fontsize=10); ax.set_aspect("equal")
    ax.legend(loc="lower right", fontsize=8)

fig, axes = plt.subplots(2, 2, figsize=(10, 9))
for ax, g in zip(axes.ravel(), [0.05, 0.3, 1.0, 30.0]):
    clf = SVC(kernel="rbf", gamma=g, C=1.0).fit(X_train, y_train)
    print(f"gamma={g:5.2f} : train {clf.score(X_train, y_train):.3f} "
          f"test {clf.score(X_test, y_test):.3f}  SV {len(clf.support_)}")
    plot_boundary(ax, clf, f"gamma = {g} (test acc {clf.score(X_test, y_test):.2f})")
fig.suptitle("RBF gamma sweep on concentric circles", fontsize=12)
plt.show()
```





γ 스윙 결과: 4단계

γ	train acc	test acc	서포트 벡터 수
0.05	0.514	0.467	136
0.30	0.993	1.000	74
1.00	1.000	1.000	34
30.00	1.000	1.000	85

- $\gamma = 0.3$: 원형 경계가 생기며 정확도가 1.0으로 오름.
- $\gamma = 30$: 각 점마다 좁은 봉우리가 생겨 경계가 학습 데이터 하나하나를 감싸는 형태로 심하게 구불거림(SV 85개 증가).

그림으로 읽기: γ 4단계 한눈에

RBF gamma sweep on concentric circles



- $\gamma = 0.05$: 거의 직선에 가까운 경계.
- $\gamma = 1.0$: 원형에 가깝게 수렴.
- $\gamma = 30$: 점 하나하나를 감싸는 형태로 구불거림.

직관

커널 SVM의 예측 = “새 점이 각 SV와 얼마나 비슷한가” (커널값)를 **가중 투표**. σ 작음(γ 큼)
 $\Rightarrow$ 아주 가까운 SV만 강하게 반영(복잡한 경계, 과적합 위험). σ 큼(γ 작음) $\Rightarrow$ 멀리 있는 SV까지 두루 반영(단순한 경계, 과소적합 위험).

실습: RBF 전개를 수치로 검증 — 교대 수렴

$\phi(x)$ 를 도수 합 $k \leq N$ 으로 절단하고, 부분합의 내적이 정확한 커널값 $K(x, x')$ 으로 수렴하는지:

```
def phi_terms(x, N): # 도수합 |alpha| <= N 인모든성분 phi_alpha(x)
    x1, x2 = x; out = []
    for a1 in range(N + 1):
        for a2 in range(N - a1 + 1):
            k = a1 + a2
            out.append(math.exp(-gamma * (x1*x1 + x2*x2))
                        * (2 * gamma) ** (k / 2) * x1 ** a1 * x2 ** a2
                        / (math.sqrt(math.factorial(a1))
                          * math.sqrt(math.factorial(a2))))
    return out
def rbf(x, z, g=gamma):
    return math.exp(-g * np.sum((np.asarray(x) - np.asarray(z)) ** 2))
x, z = (1.2, -0.7), (0.5, 1.1)
exact = rbf(x, z)
for N in [0, 1, 2, 5, 10, 20, 40]:
    s = sum(a * b for a, b in zip(phi_terms(x, N), phi_terms(z, N)))
    print(f"도수 합 <= {N:2d}: 부분합 = {s:.10f} 오차 ( {s - exact:+.2e})")
```

N (도수 절단)	부분합 내적	오차
0	0.0337	$+9.7 \times 10^{-3}$
1	0.0222	-1.8×10^{-3}
2	0.0242	$+2.0 \times 10^{-4}$
5	0.02399	-6.9×10^{-8}
10	0.0239928358	≈ 0

- 정확한 값 $K(x, z) = 0.0239928358$.
- $N = 0$: 0.0337로 **크고**, $N = 1$: 0.0222로 **작고**, $N = 2$: 다시 초과, $N \geq 5$ 에서 급격히 수렴 — 테일러급수의 교대 수렴(oscillating convergence).
- $N = 10$ 이면 오차 10^{-15} 수준(이중 정밀도의 한계).

핵심

ϕ 는 무한차원 벡터지만 커널 SVM은 ϕ 를 직접 계산하지 않는다 — 쌍대 문제의 구조가 그렇다. 실제로 계산하는 것은 커널값 $K(x, x')$ 뿐이고, 그 값은 유클리드 거리 하나로 계산된다. “무한차원”은 ϕ 의 개념적 차원일 뿐, 실제 계산 비용이 무한하다는 뜻이 아니다.

실습: 다항 커널로 XOR 분류

```
def phi2(x):
    # (x.x'+1)^2 를도수 2 이하단항식으로전개하면개의 6 성분이필요하다 :
    # x1^2, x2^2, 2*x1*x2 (-> sqrt2 계수), 2*x1, 2*x2 (-> sqrt2 계수), 1
    x1, x2 = x
    s2 = math.sqrt(2)
    return np.array([x1 ** 2, x2 ** 2, s2 * x1 * x2, s2 * x1, s2 * x2, 1.0])

# 커널값과명시적내적이일치하는지확인커널 (트릭의같은 "내적")
rng = np.random.default_rng(0)
Xs = rng.normal(size=(50, 2))
P = np.array([phi2(x) for x in Xs])
K_poly = ((Xs @ Xs.T + 1) ** 2) # (x.x' + 1)^2
K_exp = P @ P.T # phi2(x).phi2(x')
print("max |K_poly - K_explicit| =", np.max(np.abs(K_poly - K_exp)))
assert np.max(np.abs(K_poly - K_exp)) < 1e-10
print("일치: (x.x'+1)^2 는정확히의 phi2 내적이다")



# XOR 사분면데이터 : y = -sign(x1*x2), 개4 사분면클러스터
rng2 = np.random.default_rng(3)
n = 80
quads = np.array([[ 1, 1], [ 1, -1], [-1, 1], [-1, -1]])
labels = np.array([-1, 1, 1, -1])
Xq = np.vstack([rng2.normal(q * 3, 0.8, (n, 2)) for q in quads])
yq = np.repeat(labels, n)
perm = rng2.permutation(len(yq)); Xq, yq = Xq[perm], yq[perm]
# d=1 (linear) vs d=2 (poly, degree=2, coef0=1) 학습 + 정확도출력
```

커널 트릭의 직접 검증 + XOR 결과

- 커널 트릭 직접 검증: 최대 오차 10^{-14}

모델	정확도	서포트 벡터 수	비고
선형 (d=1)	0.74	319	대각선 교차를 못 나눔
다항 d=2	1.00	18	x_1x_2 항 포함

XOR quadrants: linear vs polynomial kernel degree 2



- 도수 하나만 바꿨을 뿐인데 SV가 319→18로 줄고 정확도 0.74→1.00.
- 선형(좌): 원점을 지나는 직선 하나에 머물며 대각선 교차를 못 나눔.
- d=2(우): 경계가 **쌍곡선형** ($x_1x_2 = c$ 곡선)으로 사분면을 따라 구부러짐 — “도수 2 단항식 x_1x_2 가 추가된” 효과의 시각화.

자주 하는 실수: γ 를 “느낌”으로 고르기


- gamma가 결정 경계 구불구불함 결정

수치적 증거: 앞 γ 스윙 표

$\gamma = 0.05$: test 0.467로 동전 던지기보다 나쁨(선형 0.517보다도 낮음) — RBF가 “거의 상수 행렬”에 가까워져 “모든 점이 비슷” $\Rightarrow$ 사실상 무작위. $\gamma = 30$: train/test 1.00 — 이 데이터는 노이즈가 적어 운 좋게 일반화되는 것. 노이즈 있는 실전 데이터에선 개별 노이즈 패턴까지 따라붙어 test가 급락.

검증셋으로 (C, γ) 를 함께 그리드 서치하는 것 =
5.2절 C 튜닝의 비선형 버전.

그림으로: γ 스위프 — 과소적합에서 과적합까지



- $\gamma = 0.05$: test acc 0.47 — 경계가 거의 직선, **과소적합** (동전 던지기보다 나쁨).
- $\gamma = 0.3 \sim 1.0$: test acc 1.00 — 두 원을 매끈하게 갈라내는 적당한 구불거림.
- $\gamma = 30.0$: train/test acc 1.00이지만 경계가 점마다 뾰족하게 감쌌 — 노이즈 있는 데이터라면 **과적합**으로 무너질 모양.

유명한 사례: 딥러닝 이전 시대, 우편번호를 읽던 SVM

- RBF 커널 SVM, 복잡한 패턴에서 한 자릿수 오차율

지금도

데이터가 수천~수만 개 수준으로 많지 않고 특징 수가 적당할 때는, 신경망보다 **학습이 훨씬 빠르고 하이퍼파라미터도 적은** 커널 SVM이 실무에서 여전히 합리적인 선택지.



손글씨 숫자 데이터셋 샘플(0~9, 다양한 필체)

1990년대 USPS 우편번호 인식에 RBF 커널 SVM이 거론 것과 같은 종류의 데이터.

이 절의 핵심 세 가지

SVM = 같은 문제, 다른 원칙

로지스틱회귀·GDA와 같은 문제(선형 결정 경계)를 “마진을 최대화한다”는 다른 원칙으로 풀고 — 원칙이 다르면 얻는 성질(서포트 벡터, 커널 트릭)도 달라진다.


- 1 고차원 = “휘어진 경계”를 “평평한 경계”로: 원형 데이터는 $z = x_1^2 + x_2^2$ 축을 추가하면 두 수평 고도로 벌어져 평면 하나로 잘림. XOR은 x_1x_2 축이 필요.
- 2 커널 트릭: 내적만 계산

6장(정규화와 모델 선택)으로 넘어가기 전, 연결고리

이번 절의 C, γ 튜닝은 6장의 교차 검증으로 체계화 — 검증셋 정확도로 (C, γ) 를 함께 그리드 서치가 표준 관행. 10장(신경망)에서 RBF의 “봉우리”와 CNN의 커널 필터는 수학적으로 다른 개념이지만, “원본 특징을 고차 항으로 변환해 선형 분류”한다는 큰 그림은 이어진다.

그림으로: XOR, 선형 대 다항 커널

XOR quadrants: linear vs polynomial kernel degree 2



- 왼쪽(선형 커널, $d = 1$): acc 0.74 — 대각선 하나로는 XOR의 네 사분면을 못 가른다.
- 오른쪽(다항 커널, $d = 2$): acc 1.00 — x_1x_2 항이 생기면서 사분면을 정확히 분리.
- 커널만 바꿨을 뿐 — 목적함수와 학습 절차는 그대로.

자주 묻는 질문

Q. 커널을 아무 함수나 써도 되나요?

- 아니다 — 어떤 ϕ 의 내적에 대응하려면 **머서 조건** (커널 행렬이 **양의 준정부호**)을 만족해야 함. 다항·RBF는 증명되어 안심하고 쓸 수 있지만, 아무 함수는 안 된다.

Q. ϕ 가 무한차원이면 어떻게 학습하나요?

- ϕ 자체를 **계산하지 않기 때문에** — 쌍대 문제 구조상 데이터는 **내적값**으로만 등장하고, RBF는 유클리드 거리 하나로 계산.
- “무한차원”은 **개념적** 차원일 뿐, 실제 계산 비용이 무한하다는 뜻이 **아님**.

Q. 다항 커널의 도수 d 는 어떻게 고르나요?

- d 는 “경계가 얼마나 복잡한 곡면일 수 있는가” 조절 — $d = 1$ 직선, $d = 2$ 포물선/쌍곡선형, $d = 3$ 더 복잡한 곡면. d 를 **키울수록 과적합 위험**. XOR에선 $d = 2$ 가 정확히 필요했지만, 실전은 **검증셋으로 튜닝**((C, d) 함께 그리드 서치, $d > 3$ 은 거의 안 씀).

이 “내적만 계산하면 고차원 변환을 우회한다”는 원리는 SVM에만 국한 **아님** — RBF 네트워크, Gaussian Processes, 신경망의 **커널 정리**(neural tangent kernel, Jacot et al. 2018)까지 이어진다.

이번 주차 정리

- **5.1 마진 최대화 = $\|w\|$ 최소화** — 스케일 불변성 때문에 제약 $y(w^\top x + b) \geq 1$ 이 필수, 마진 $2/\|w\|$, **서포트 벡터**만 경계를 떠받침 (로지스틱회귀의 “모든 점 기여”와 대조).
- **5.2 소프트 마진** — 여유 변수 ξ + **힌지 손실**로 노이즈를 허용, C 는 “이상치 용인도” 손잡이. 힌지의 **비활성화** 성질($f \geq 1$ 에서 그래디언트 0)이 SV 개념을 가능하게 함. $1/C \Leftrightarrow$ 6장의 정규화 세기 λ .
- **5.3 커널 트릭** — 고차원으로 휘어진 경계를 평평하게, 쌍대 문제에서 **내적만** 계산하면 ϕ 의 차원을 우회. RBF의 무한차원은 개념뿐, m 개 데이터의 커널 행렬 $\text{rank} \leq m$. γ (또는 도수 d)는 경계의 구불 복잡도 — (C, γ) 를 **함께** 검증셋으로 튜닝.

다음 주차 — Week 6. 정규화와 모델 선택

5.2절의 C 가 “마진을 넓게 잡을 것인가, 위반을 덜 허용할 것인가”를 조절하는 손잡이라면, 6장은 이 “충실도 vs 단순함”의 손잡이를 **L1/L2 페널티와 교차검증**이라는 일반 틀로 확장한다. SVM의 C 튜닝이 바로 그 첫 번째 사례다.