

Block A 캡스톤: 팀 프로젝트와 총정리

팀 프로젝트 4주 파이프라인 · Peer-Review · 중간고사 대비 총정리

Machine Learning 1 · 8주차

한국과학영재학교 (KSA)

Chapter 8

이번 주차 개요

- **8.1 팀 프로젝트** — 4주 파이프라인으로 정형 데이터에 Ch. 2-7 모델을 적용. **산출물은 높은 성능이 아니라 “성능 숫자를 정직하게 얻은 절차”**.
- **8.2 Peer-Review** — 이번엔 네가 심사위원. 체크리스트로 두 팀을 검토하고, 장·절을 명시한 반박 가능한 질문을 쓴다.
- **8.3 중간고사 대비 총정리** — 유도 템플릿 3가지를 종이에 재현하고, 장별 핵심 질문으로 자가진단.

이번 장을 마치면

모델·지표·전처리·분할을 스스로 골라 근거지을 수 있고, 3분할·베이스라인·“test 한 번” 절차를 실제로 수행해 보고서·발표로 제시할 수 있다.

같은 절차를 세 가지 언어(코드, 보고서, 리뷰)로 말할 수 있어야 이 프로젝트가 끝난 것이다.

8.1 팀 프로젝트: 데이터 선정부터 발표까지

왜 지금 프로젝트를 하는가


- 트리 기반 모델(Ch. 7)까지 끝내면 정형 데이터의 대표 도구를 **거의 다** 손에 쥘다 — Block B 신경망 없이도 실전 데이터셋 상당수를 다룰 수 있다.
- 지금이 “각 장의 코드가 **실제 데이터** 앞에서도 작동하는가”를 확인할 가장 좋은 시점.

검증의 성격이 달라진다

- Ch. 2-7 실습: 교재가 고른 데이터, 교재가 고른 모델.
- 이번엔 데이터 고르기, 모델 고르기, **나빠지면 원인을 찾아 다시 고르기**까지가 우리 몫.
- “코드가 동작한다”의 증거와 “내가 풀 수 있다”의 증거는 다르다.

전체 그림: 4주 파이프라인

팀 프로젝트 파이프라인 — 4주: 데이터 선정 → 발표 (Block A 캡션)



데이터·문제 정의(1주) → 3분할·전처리· 모델·val 튜닝(2-3주) →
test 한 번·수식적 정당화(3-4주) → 발표·peer-review(4주)

- 왼쪽→오른쪽으로 **데이터** → **파이프라인** → **평가** → **발표** 흐름.
- **붉은 점선**이 핵심: test에서 **누수** (Ch. 6.3)나 **과적합**(Ch. 4.1)이 보이면 돌아가서 다시.
- “한 번 지나가면 돌아올 수 없는 것”은 **test 한 번의 측정**뿐 — 그 외 모든 단계는 되돌아갈 수 있다.

일정과 마일스톤 M1-M4 I

주 해야 할 일

- 1 데이터 후보 2~3개 조사(크기·결측치·클래스 비율), 팀 회의, **문제 정의 문서**(행이 무엇인지, 라벨, 주 지)
- 2 3분할(Ch. 6.3)로 코드 스캐폴드, train으로만 fit하는 전처리, 1개 모델 엔드투엔드, 베이스라인 측정
- 3 나머지 모델 적용, val/교차검증(Ch. 6.2)으로 튜닝, **test 최종 측정(한 번만)**, 학습 곡선 도출
- 4 수식적 정당화 작성, 보고서·슬라이드 완성, **발표(5~7분)**, **peer-review 2팀**

왜 마일스톤이 이 모양인가

M2가 **베이스라인 숫자 한 줄**을 요하는 이유: 이 숫자를 봐야 “모델을 만들었다”고 말할 수 있는지 판정 가능.
M3가 **학습 곡선 한 장**을 요하는 이유: 최종 숫자만 제출하면 하이퍼파라미터를 어떻게 정했는지 검증 못 함
— 곡선이 있으면 val 곡선이 실제로 선택에 쓰였는지가 그림에서 드러남.

프로젝트 구조

- **데이터** — Kaggle, UCI Machine Learning Repository **중에서 정형(행/열) 데이터 하나** — 이미지·텍스트보다 표 형태가 Ch. 2-7 모델 검증에 적합.
- **적용** — Ch. 2-7 중 **최소 두 가지 모델** (예: 로지스틱회귀 + GBDT)을 같은 데이터에 적용해 비교.
- **필수: 수식적 정당화 ≥ 1 개** —
 - ① 정규화 적용했다면 Ch. 6 편향-분산 관점에서 왜 성능이 바뀌었는지,
 - ② GBDT 썼다면 Ch. 7 SHAP으로 예측 하나를 분해,
 - ③ 모델 여러 개 비교했다면 Ch. 2.3 PR-AUC로 불균형을 고려한 비교.
- **검증 원칙** — Ch. 6.3의 train/validation/test 3분할 준수, **테스트 성능은 딱 한 번만 확인.**

데이터 고르기 실전 가이드 5개

후보에 “점수”를 매겨보면 팀 회의가 쉬워진다:

- ① **행의 물리적 단위**를 한 문장으로 설명할 수 있는가 (환자? 거래? 주문?) — 설명이 안 되면 “예측 대상 단위를 일반화하는가”를 물을 수 없다.
- ② **레이아웃의 함정**이 있는가 — 같은 환자의 여러 검사 결과가 여러 행이면 무작위 분할이 누수 → GroupKFold 필요.
- ③ **시계열은 시간순**으로 나눠야 한다(6.3절 노트북 § 5).
- ④ **클래스 비율을 먼저 보고 지표를 정한다** — 99:1이면 정확도가 아니라 PR-AUC/재현율(Ch. 2.3 정확도의 함정).
- ⑤ **크기** — 100행 미만이면 CV 폴드가 너무 작아 숫자가 극도로 흔들림 → 500~10,000행이 편함.

후보 데이터셋 한 줄 점검표

데이터셋	크기	문제 정의	주의할 함정
breast cancer (UCI)	569×30, 약 4:6	조직이 악성인가	비교적 깨끗함 — “기본 코스”
Heart Failure (UCI)	1,000×14, 약 7:3	28일 내 사망	약간 불균형 — F1·PR-AUC 함께
Poker Hand (UCI)	1,025×13, 10클래스	패 손 등급	다중 클래스 — 베이스라인 10%(무작위)
Space Guests (Kaggle)	4,500×14, 균형	목적지 성좌	결측치 다수 — 대체를 train 으로만
Credit Card (Kaggle)	28만×31, 99.8:0.2	사기 탐지	극단 불균형 — 정확도 금지, PR-AUC 필수

권장 순서

“기본 코스” breast_cancer를 먼저 끝내고, 시간이 남으면 Credit Card 같은 극단 데이터로 **지표 선택의 중요성**을 재확인한다 — 8.2절에서 “정확도의 함정”을 근거로 리뷰할 실력이 된다.

베이스라인: “모델보다 먼저 봐야 할 숫자”

다수 클래스(majority-class) 모델

모델을 **아예 안 만들고도** 성능을 만드는 유일한 방법:
train에서 가장 많이 나온 클래스를 전부 예측.

- 클래스 비율 50:50 → 베이스라인 정확도 50%.
- 90:10 → 90%, 99.8:0.2 → 99.8%.
- 비율을 보면 베이스라인이 **자동으로 정해진다**.

“우리 test 정확도가 99.8%”라는 발표는, 베이스라인을 보지 않은 한 아무것도 말하지 않은 발표다.

Ch. 2.3 “정확도의 함정”을 숫자로 강제하는 체크 — 보고서는 모델 성능 숫자와 함께 **항상 베이스라인 숫자도** 함께 제시.

손으로 한 번: 베이스라인의 F1

8.2절 사기 탐지 데이터(99.8:0.2)에서 다수 클래스(정상)만 찍으면:

- 부정(fraud)에 대한 정확도는 $P = 1.0$ 이지만 **재현율** $R = 0$ — 부정 건을 하나도 못 잡음.
-

$$F_1 = \frac{2PR}{P + R} = 0$$

반대로 부정만 전부 맞히려는 극단(전부를 부정으로 찍기)에서는:

- 재현율은 $R = 1.0$ 이지만 정확도는 0.2% 수준으로 희석.
-

$$F_1 \approx 0.004$$

교훈

F1은 정확도보다 이런 극단적 모델을 더 가혹하게 (= 정확하게) 다뤄준다 — 바로 이것이 지표를 고르는 이유다.

모델 비교의 기준: val에서 정하고, test는 한 번만

“최소 두 모델을 비교한다”의 정확한 절차:

- ① 모든 후보 모델을 **train**으로만 fit하고, **val 성능으로 순위** 매기기 (하이퍼파라미터 포함이면 val 안에 Ch. 6.2 교차검증 사용).
- ② **val 순위 1등**을 최종 모델로 결정.
- ③ 그 모델 **만** test에 적용해 최종 숫자를 **한 번** 얻는다.

왜 “한 번”인가

test로 후보 m 개를 돌려봐서 가장 좋은 것을 고르면, 잡음 σ 기준으로 $\mathbb{E}[\max]$ 만큼 성능이 **부풀어 오른다**(Ch. 6.3 선택 편향 시뮬레이션). 형식적 원칙이 아니라 **정량적** 이유다.