

Block A 캡스톤: 팀 프로젝트와 총정리

팀 프로젝트 4주 파이프라인 · Peer-Review · 중간고사 대비 총정리

Machine Learning 1 · 8주차

한국과학영재학교 (KSA)

Week 8

이번 주차 개요

- **8.1 팀 프로젝트** — 4주 파이프라인으로 정형 데이터에 Week 2-7 모델을 적용. **산출물은 높은 성능이 아니라 “성능 숫자를 정직하게 얻은 절차”**.
- **8.2 Peer-Review** — 이번엔 네가 심사위원. 체크리스트로 두 팀을 검토하고, 장·절을 명시한 반박 가능한 질문을 쓴다.
- **8.3 중간고사 대비 총정리** — 유도 템플릿 3가지를 종이에 재현하고, 장별 핵심 질문으로 자가진단.

이번 장을 마치면

모델·지표·전처리·분할을 스스로 골라 근거지을 수 있고, 3분할·베이스라인·“test 한 번” 절차를 실제로 수행해 보고서·발표로 제시할 수 있다.

같은 절차를 세 가지 언어(코드, 보고서, 리뷰)로 말할 수 있어야 이 프로젝트가 끝난 것이다.

8.1 팀 프로젝트: 데이터 선정부터 발표까지

왜 지금 프로젝트를 하는가


- 트리 기반 모델(Week 7)까지 끝내면 정형 데이터의 대표 도구를 **거의 다** 손에 쥘다 — Block B 신경망 없이도 실전 데이터셋 상당수를 다룰 수 있다.
- 지금이 “각 장의 코드가 **실제 데이터** 앞에서도 작동하는가”를 확인할 가장 좋은 시점.

검증의 성격이 달라진다

- Week 2-7 실습: 교재가 고른 데이터, 교재가 고른 모델.
- 이번엔 데이터 고르기, 모델 고르기, **나빠지면 원인을 찾아 다시 고르기**까지가 우리 몫.
- “코드가 동작한다”의 증거와 “내가 풀 수 있다”의 증거는 다르다.

전체 그림: 4주 파이프라인

팀 프로젝트 파이프라인 — 4주: 데이터 선정 → 발표 (Block A 캡스톤)



데이터·문제 정의(1주) → 3분할·전처리·모델·val 튜닝(2~3주) → test 한 번·수식적 정당화(3~4주) → 발표·peer-review(4주)

전체 그림: 어떻게 읽는가

- 왼쪽→오른쪽으로 데이터 → 파이프라인 → 평가 → 발표 로 흐름.
- 붉은 점선이 핵심: test에서 누수 (Week 6.3)나 과적합(Week 4.1)이 보이면 돌아가서 다시.
- “한 번 지나가면 돌아올 수 없는 것”은 **test 한 번의 측정**뿐 — 그 외 모든 단계는 되돌아갈 수 있다.

일정과 마일스톤 M1-M4 I

주 해야 할 일

- 1 데이터 후보 2~3개 조사(크기·결측치·클래스 비율), 팀 회의, **문제 정의 문서**(행이 무엇인지, 라벨, 주 지)
- 2 3분할(Week 6.3)로 코드 스캐폴드, train으로만 fit하는 전처리, 1개 모델 엔드투엔드, 베이스라인 측정
- 3 나머지 모델 적용, val/교차검증(Week 6.2)으로 튜닝, **test 최종 측정(한 번만)**, 학습 곡선 도출
- 4 수식적 정당화 작성, 보고서·슬라이드 완성, **발표(5~7분)**, **peer-review 2팀**

왜 마일스톤이 이 모양인가

M2가 **베이스라인 숫자 한 줄**을 요하는 이유: 이 숫자를 봐야 “모델을 만들었다”고 말할 수 있는지 판정 가능.
M3가 **학습 곡선 한 장**을 요하는 이유: 최종 숫자만 제출하면 하이퍼파라미터를 어떻게 정했는지 검증 못 함
— 곡선이 있으면 val 곡선이 실제로 선택에 쓰였는지가 그림에서 드러남.

프로젝트 구조

- 정형 데이터 하나
- 두 가지 모델 비교
- 필수: 수식적 정당화 ≥ 1 개 —
- 3분할 준수, 테스트 1회

데이터 고르기 실전 가이드 5개

- ① **행의 물리적 단위**를 한 문장으로 설명할 수 있는가 (환자? 거래? 주문?) — 설명이 안 되면 “예측 대상 단위를 일반화하는가”를 물을 수 없다.
- ② **레이아웃의 함정**이 있는가 — 같은 환자의 여러 검사 결과가 여러 행이면 무작위 분할이 누수 → GroupKFold 필요.
- ③ **클래스 비율을 먼저 보고 지표를 정한다** — 99:1이면 정확도가 아니라 PR-AUC/재현율(Week 2.3 정확도의 함정).
- ④ **크기** — 100행 미만이면 CV 폴드가 너무 작아 숫자가 극도로 흔들림 → 500~10,000행이 편함.

후보 데이터셋 한 줄 점검표

데이터셋	크기	문제 정의	주의할 함정
breast cancer (UCI)	569×30, 약 4:6	조직이 악성인가	비교적 깨끗함 — “기본 코스”
Heart Failure (UCI)	1,000×14, 약 7:3	28일 내 사망	약간 불균형 — F1·PR-AUC 함께
Poker Hand (UCI)	1,025×13, 10클래스	패 손 등급	다중 클래스 — 베이스라인 10%(무작위)
Space Guests (Kaggle)	4,500×14, 균형	목적지 성좌	결측치 다수 — 대체를 train 으로만
Credit Card (Kaggle)	28만×31, 99.8:0.2	사기 탐지	극단 불균형 — 정확도 금지, PR-AUC 필수

권장 순서

“기본 코스” breast_cancer를 먼저 끝내고, 시간이 남으면 Credit Card 같은 극단 데이터로 **지표 선택의 중요성**을 재확인한다 — 8.2절에서 “정확도의 함정”을 근거로 리뷰할 실력이 된다.

베이스라인: “모델보다 먼저 봐야 할 숫자”

다수 클래스(majority-class) 모델

모델을 **아예 안 만들고도** 성능을 만드는 유일한 방법:
train에서 가장 많이 나온 클래스를 전부 예측.

- 클래스 비율 50:50 → 베이스라인 정확도 50%.
- 90:10 → 90%, 99.8:0.2 → 99.8%.
- 비율을 보면 베이스라인이 **자동으로 정해진다**.

“우리 test 정확도가 99.8%”라는 발표는, 베이스라인을 보지 않은 한 아무것도 말하지 않은 발표다.

Week 2.3 “정확도의 함정”을 숫자로 강제하는 체크 — 보고서는 모델 성능 숫자와 함께 **항상 베이스라인 숫자도** 함께 제시.


손으로 한 번: 베이스라인의 F1

- 부정(fraud)에 대한 정확도는 $P = 1.0$ 이지만 재현율 $R = 0$ — 부정 건을 하나도 못 잡음.

$$F_1 = \frac{2PR}{P + R} = 0$$

- 재현율은 $R = 1.0$ 이지만 정확도는 0.2% 수준으로 희석.

$$F_1 \approx 0.004$$



교훈

F1은 정확도보다 이런 극단적 모델을 더 가혹하게 (= 정확하게) 다뤄준다 — 바로 이것이 지표를 고르는 이유다.

모델 비교의 기준: val에서 정하고, test는 한 번만


- ① 모든 후보 모델을 **train**으로만 fit하고, **val 성능으로 순위** 매기기 (하이퍼파라미터 포함이면 val 안에 Week 6.2 교차검증 사용).
- ② **val 순위 1등**을 최종 모델로 결정.
- ③ 그 모델 **만** test에 적용해 최종 숫자를 **한 번** 얻는다.

왜 “한 번”인가

test로 후보 m 개를 돌려봐서 가장 좋은 것을 고르면, 잡음 σ 기준으로 $\mathbb{E}[\max]$ 만큼 성능이 **부풀어 오른다**(Week 6.3 선택 편향 시뮬레이션). 형식적 원칙이 아니라 **정량적** 이유다.

그림으로: 모델 비교 절차

모델 비교의 기준: val로 고르고, test는 한 번만



후보들은 **val**만 보고 순위가 매겨지고, 순위 1등만 **test**를 향해 딱 한 번 나아간다 — 나머지 후보는 test라는 화살표를 아예 지나가지 않는다.

Netflix Prize

[Home](#) [Rules](#) [Leaderboard](#) [Register](#) [Update](#) [Submit](#) [Download](#)

Leaderboard

10.05%

Display top leaders.



Rank	Team Name	Best Score	% Improvement	Last Submit Time
1	BellKor's Pragmatic Chaos	0.8558	10.05	2009-06-26 18:42:37
Grand Prize - RMSE <= 0.8563				
2	PragmaticTheory	0.8582	9.80	2009-06-25 22:15:51
3	BellKor in BigChaos	0.8590	9.71	2009-05-13 08:14:09
4	Grand Prize Team	0.8593	9.68	2009-06-12 08:20:24
5	Dace	0.8604	9.56	2009-04-22 05:57:03
6	BigChaos	0.8613	9.47	2009-06-23 23:06:52

Netflix Prize 공개 리더보드 (2009년 6월)

BellKor's Pragmatic Chaos — 10.05% 개선, 공개 순위를 보며 여러 팀이 반복 제출


선택 편향의 크기: 후보 50개면?

본 프로젝트 규모: 모델 5개 $\times$ 하이퍼파라미터 후보 10개 = **후보 50개**. 잡음 $\sigma = 0.02$ (F1 스케일)로 가정하면 부풀림 약 **0.045**.

“test F1 0.97”이 실제로는 0.925일 수 있다는 뜻이다.

- val로 고르면 **val**이 이 편향을 먹고, test는 한번만 쓰이므로 부풀림이 test에 **전**이 되지 않는다.
- 3분할 원칙은 “정직한 test 숫자”를 사기 위한 구조.

6.3절 원칙이 그림에서 바로 보인다: **train** 곡선은 “배운 것을” 재고, **val** 곡선만 “재는 것을” 한다.



GBDT 학습 곡선 — train F1은 10개 트리부터 거의 1.0(341건을 몇 그루면 외우기 쉬움), val F1은 0.93~0.97 사이로 느리게 이동. $n_{\text{estimators}}$ 는 **val 곡선으로만** 정한다.

실습: breast_cancer 한 흐름 9단계

단계	내용(실측)
1	문제 정의 — 행=환자, 라벨=양성/악성, 주 지표 F1
2	3분할: train 341 / val 114 / test 114 (stratify, unique id로 pairwise disjoint 기계 점검)
3	전처리: StandardScaler를 train으로만 fit
4	모델 5개 후보(로지스틱·kNN·트리·RF·GBDT) val F1 비교 → kNN(k=5)가 0.973로 1위
5	베이스라인: 다수 클래스의 val F1 0.774 — kNN이 0.198 상회해야 “모델을 만들었다”고 말할 수 있음
6	test 한 번: accuracy 0.939, F1 0.950, PR-AUC 0.979
7	선택 편향 시뮬레이션: test로 5개 후보 고르면 +0.023, 50개면 +0.045 부풀림
8	학습 곡선: GBDT $n_{\text{estimators}}$ vs train/val F1
9	SHAP 가산성 2-특징 장난감 손계산: $0.50 + 0.08 + 0.20 = 0.78 = f(\{A, B\})$

이 9단계가 곧 **보고서 6절** → **8.2 체크리스트 4항목**으로 매핑된다 — 같은 절차를 코드·보고서·리뷰 **세 가지 언어**로 말할 수 있어야 프로젝트가 끝난다.

보고서 구조 (M4) — 발표 슬라이드 = 보고서의 각 절 제목

절	분량	내용
1. 문제 정의	0.5p	행의 단위·라벨·주 지표·베이스라인 + “왜 이 지표를 골랐는가” 한 문장
2. 데이터와 전처리	1p	원본 통계(크기·결측치·이상치), train 으로만 fit 한 전처리 명시, 3분할 비율 + stratify 여부
3. 모델 선택과 이유	1~2p	후보 ≥ 2 개, 왜 이 후보들인가 (데이터 특성과 연결: 거리 기반이면 스케일링, 트리 기반이면 불필요), val 비교 표
4. 결과	1p	최종 test 숫자(한 번), 학습 곡선 1장, val 표
5. 수식적 정당화	1p	편향-분산·정규화·SHAP·PR-AUC 중 ≥ 1 개로 “왜 이 결과가 나왔는지”
6. 잘 안 된 부분과 원인 진단	0.5p	필수 — 없었으면 “무엇을 시도했다가 안 됐는가”. 이 절이 비어 있으면 “결과의 정직성” 항목을 의심받음

채점 기준 (rubric)

항목	비중	좋은 답
문제 정의와 데이터	15%	행의 단위·라벨·지표·베이스라인 명확, 지표 선택이 데이터 특성에 근거
방법론 적절성	25%	데이터 특성(불균형·차원·시계열·그룹)에 맞는 모델·전처리·분할, Week 2-
검증의 정직성	25%	3분할·train-fit·test 한 번·베이스라인·학습 곡선·val 튜닝이 추적 가능 할 것
수식적 정당화	20%	개념 ≥ 1 개로 “왜” 설명 + 설명이 관측(숫자)과 일치
결과의 정직성과 반성	15%	잘 안 된 부분을 숨기지 않고 Week 2-7 개념으로 원인 진단

50%가 절차인 이유

목적이 “높은 성능”이 아니라 “성능 숫자를 정직하게 얻는 절차”를 수행한 것을 증명하는 것이기 때문. 성능 0.60 이어도 절차가 정직하면 높은 점수, 0.99여도 test를 두 번 썼거나 베이스라인이 없으면 크게 감점.

수식적 정당화: 나쁜 설명 vs 좋은 설명

같은 결과(“정규화 적용 $\rightarrow$ test 정확도 0.89 $\rightarrow$ 0.93”)를 설명하는 두 문장:

나쁜 설명

“정규화를 넣으니까 성능이 좋아졌다.
정규화가 좋은 방법인 것 같다.”

관찰만 있고 **왜**가 없다.

좋은 설명


정규화 없이 train 0.99 / test 0.89 — 큰 격차(Week 4.1의 분산 큰 과적합). L2 추가 + Week 6.2 교차검증으로 λ 튜닝 $\rightarrow$ train 0.95로 약간 하락, test 0.93으로 상승 — **train/test 격차가 줄어든 것이 정규화가 실제로 분산을 줄인 증거.**

“성능이 올랐다”는 관찰과 “왜 올랐는지 설명할 수 있다”는 이해는 다른 수준의 성취다.

“살짝 훑쳐보기”가 얼마나 성능을 부풀리는가

최고 점 선택은 낙관 편향

후보 수 m	$\mathbb{E}[\max]$
1 (val로만)	≈ 0
5 (모델 5개)	≈ 0.023
50 (모델 $\times$ HP 10)	≈ 0.045
100	≈ 0.050



음영: 본 프로젝트 규모(5모델 $\times$ 10후보 $\approx$ 50) $\rightarrow$ 부풀림 약 0.045

읽는 법

“5개 모델을 test로 돌려보고 제일 좋은 것을 골랐다”는 행위는 F1 0.97의 결과에 **실제로 0.947일 수** 있다는 불확실성을 안고 있다. 후보가 **모델 수 $\times$ 하이퍼파라미터 수**의 곱으로 커지는 것이 이 편향이 4.5%p가 되는 이유.

자주 하는 실수 5가지

- ① 테스트로 모델 고르기
- ② 정규화 통계량 누수
- ③ 베이스라인 없이 성능 보고
- ④ 시계열 무작위 분할
- ⑤ 학습 곡선 없이 하이퍼파라미터 보고

발표: 5~7분의 설계도

순서	내용	시간
1	문제 정의	1분
2	데이터와 전처리	1분
3	적용한 모델과 이유	2분
4	결과와 수식적 정당화	2분
5	잘 안 됐던 부분과 원인 진단	1분

- 왜 이 모델을 골랐고 왜 이 결과가 나왔는지
- 마지막 1분이 가장 평가받는 부분

발표의 마지막 1분: 실패를 개념으로 해석하라

“모든 것이 잘 됐다”

“결과의 정직성과 반성” 항목에서 스스로 감점을 받는 발표 — 이 절이 비어 있다는 뜻.

점수받는 발표

“트리 깊이를 5로 늘리자 val F1이 0.97에서 0.95로 떨어졌다 — Week 7.3대로 GBDT가 잔차를 계속 쫓다 노이즈까지 학습하기 시작한 것으로 진단하고, 깊이를 3으로 고정했다.”

- 실패한 시도를 배운 개념으로 해석한 증거라서 더 높은 점수.

확인 문제 (1)

- 1. 팀이 train 70% / test 30%만 쓰고 하이퍼파라미터를 **test로** 고르겠다고 한다. 후보 10개, 잡음 $\sigma = 0.01$ 일 때 test 성능이 평균적으로 얼마나 부풀어 오르는가?

답: Week 6.3 $\mathbb{E}[\max]$ 계산 ($\sigma = 1$ 일 때 ≈ 1.53)에 $\sigma = 0.01$ 을 곱하면 ≈ 0.015 — test F1이 실제로 0.985인데 1.00으로 보고될 수 있다. 질문 예: “시드 5개로 val/test 순위의 불일치율을 재볼 수 있나요?”

- 2. breast_cancer(악성 62.7%)에서 다수 클래스 베이스라인의 val F1은 0.774였다. **정확도** 지표의 베이스라인은? 왜 정확도가 F1보다 “인정하기 쉬운” 숫자인가?

답: 정확도 베이스라인 $\approx 62.7\%$. 정확도는 소수 클래스 몇 건을 잡았는지를 **희석**한다 — 50:50이 아니면 모델과 베이스라인의 차이를 과소/과대 평가. F1은 희석 효과를 없애므로 적합.

확인 문제 (2)

- 3. 같은 데이터를 (a) 무작위 분할, (b) 환자(그룹) 분할로 나눠 kNN을 학습하면 (a)의 test RMSE가 비현실적으로 낮아진다. (a)가 왜 좋은 성적을 내는가?

답: (a)에서는 같은 환자의 여러 행이 train/test에 흩어져, kNN이 test 행의 k-이웃을 **같은 환자의 train 행**으로 찾아 “환자를 인식”한다 — 관계를 배운 것이 아니라 환자를 **외운** 것. 질문: “그룹 키 (환자 ID)가 있는가? GroupKFold로 재분할하면?”

- 4. “GBDT $n_{\text{estimators}}=300$ 을 val 곡선으로 정했다”는데, val F1이 300에서 **계속 상승 중**이다. 한계는?

답: 상승 중이면 “300이 최적”이 아니라 “관찰 범위 내 최선”. val이 $n \approx 150$ 에서 정점 후 하락했다면 300은 train F1=1.0 포화 상태에서 **잔차 (노이즈)를 쫓다 overfit한** 구간 — 150 부근(early stopping)을 골랐어야 함. 기준은 언제나 **val 정점**.

자주 묻는 질문

- **Q. 두 모델 성능이 거의 같으면?** 오히려 좋은 소재 — Week 6.3: 차이가 검증셋 표본 크기에 비해 작다면 “우연”일 수도 있다는 것 자체가 **통계적으로 중요한 관찰**. 예측이 어떤 포인트에서 갈리는지, 어느 쪽이 해석하기 쉬운지(로지스틱의 계수 vs GBDT의 SHAP)로 채운다.
- **Q. 결측치·이상치가 많은 데이터는 감점?** 아니다 — 오히려 전처리 결정(어떻게 채웠는지, 이상치를 제거·유지 했는지)과 **그 근거**가 좋은 평가 포인트. “지저분한 데이터를 다룬 판단 과정”이 실전에 훨씬 가깝다.
- **Q. 역할 분담은?** 데이터·코드·보고서·발표를 **팀 전체가 함께 결정**하되 작성은 나눠도 된다. “코드는 A, 보고서는 B”로 완전히 분리하면 B가 A의 코드를 모르는 채 정당화를 쓰게 됨(=“나쁜 설명”) — M2 중간코드 리뷰가 이를 강제.
- **Q. 4주 안에 안 끝날 것 같은데?** 성공 기준은 “높은 성능”이 아니라 **“정직한 절차”** — 모델을 2개로 줄이고(최소선은 2개) “시간 부족으로 3번째 모델을 못 돌렸다”를 정직하게 쓰는 것이 부풀리기보다 낫다.

8.2 Peer-Review

역전: 이번엔 네가 심사위원이다

- ML 결과는 **잘못된 것이 아니라 우연히 좋은 것처럼 보이는 것이** 너무나 쉽다:
 - ▶ test를 하이퍼파라미터 튜닝에 써서 (Week 6.3 선택 편향),
 - ▶ 클래스가 99.8:0.2로 기울어 있어서 (Week 2.3 정확도 의 함정),
 - ▶ train에 과적합해서 (Week 6.1).

그러므로

“좋은 결과”는 스스로를 증명하지 못한다 — 다른 누군가가 그 결과를 뒤집을 수 있는 구체적인 방법을 찾아내는지로 판단해야 한다.

Popper의 반증주의: 왜 “반박 가능”인가


Karl Popper, 1934년 The Logic of Scientific Discovery:

반증주의 (falsifiability)

한 주장은 “그것이 틀렸음을 보여주는 관측이 원칙적으로 상상이 가능한가”로 판별된다. 반박될 수 없는 주장은 과학이 아니다.

peer-review의 적용 좋은 질문이란 발표팀이 제대로 답하지 못하면 결과 자체가 흔들리는 질문:

- “더 잘 설명해 주세요” = 요청.
- “Week 6 교차검증 없이 λ 를 정했는데, 그 검증 성능이 우연일 가능성은 없는가?” = 반박.



Karl Popper — LSE 교수, 1980년경
(사진: Franz Barta, LSE Library)

Amgen 재현 실험 (2011)

- 생물제약 회사 Amgen이 1999~2005년 발표된 “주요(landmark)” 생물학 논문 **53편**을 직접 재현하려 했다.
- **6편밖에** 재현되지 못했다.
- 47편은 “잘못되었다기보다 재현이 안 된다” — 이후 **재현성 위기** 논쟁의 상징이 되었다.

peer-review의 정체

“남의 발표를 까탈스럽게 까는 절차”가 아니다 — Amgen이 스스로 했던 것과 동일한 행위: **내 결과도 남이 재현·반박할 수 있도록 미리 방어하는 것.**

네 발표 전에, 네가 심사할 때 던질 가장 날카로운 질문을 스스로 던져 답을 준비해 두는 것이 최선.



John Ioannidis (Stanford)

“Why Most Published Research Findings Are False”(2005) 저자 — 재현성 위기 논의의 학술적 배경

이번 주 진행: 세 단계 + 체크리스트

순서	내용	시간
1	다른 두 팀 발표 청취(각 5~7분, 8.1 형식)	50분 중 약 30분
2	체크리스트 기반 작성 리뷰 두 통 — 팀당 4개 항목 + 반박 가능한 질문 1개 이상	발표 직후
3	질의·토론: 리뷰어가 쓴 질문에 발표팀이 답변	나머지 시간

체크리스트 4항목 확인할 것

문제 정의	무엇을 예측/분류하려 했는지 명확한가
방법론 적절성	데이터 특성(불균형, 차원 수 등)에 맞는 모델을 골랐는가
수식적 정당화	요구사항을 충족했고, 그 설명이 실제로 타당한가
결과의 정직성	잘 안 된 부분을 숨기지 않고 원인을 분석했는가

8.1에서 “수식적 정당화”가 발표팀의 의무였다면, 이번 주는 그 정당화가 타당한지를 **리뷰어가 심사**한다.

채점 기준: “채웠는가”가 아니라 “구체적인가”

품질	특징	예시
1점 — 감상평	구체적 지적이 없음, 느낌만	“발표 잘 들었음”
2점 — 일반 지적	문제를 제기하지만 근거(개념)가 약함 — 발표팀이 “네”로 넘길 수 있음	“모델 선정이 부적절해 보입니다. 좀 더 살펴보주세요.”
3점 — 반박 가능	장·점을 명시 하고, 답이 나쁘면 결과가 흔들리는 질문	“불균형(99.9% Precision·Recall)을 보완할 수 있는 모델일 수 있

1점 → 3점: 공통 패턴

- 추상적 평가어를 구체적 관찰과 개념으로 교체
- “99.8:0.2 불균형에서 정확도만 비교했다(Ch02.3의 정확도의 함정)”(3점):

3점 질문의 구조

관찰 + 개념(장·절) + “왜 문제인지” — 세 칸 모두 채워져야 반박 가능.

손으로 한 번: 가상 발표에 체크리스트를 적용


가상 발표 요약

항목	판정
문제 정의	✓ 명확 — 이상거래 탐지, 이진 분류
방법론 적절성	× 99.8:0.2 극단 불균형에 정확도 를 썼다 — “정확도의 함정”(We
수식적 정당화	× 형식적으로만 충족 — 불균형에 맞는 지표(PR-AUC, 재현율)를
결과의 정직성	× “GBDT가 더 좋다”는 결론의 근거가 위 문제 때문에 약함

실습: “정확도 99.8%”를 코드로 검증 (1)

- 노트북은 발표의 설정(거래 10만 건, 사기 200건 = 0.2%)을 1차원 장난감 데이터로 재현하고, 임계값 분류자로 정확도·재현율·PR-AUC를 직접 계산.
- (1) “쓸모있는 모델”의 정확도는 “무조건 정상”보다 낮다: 사기를 약 90% 잡는 분류자(임계값 $t = 2.5$)의 정확도는 **99.37%** — 아무 모델 없이 전부 “정상”을 찍으면 **99.8%**(사기 1건도 못 잡는데도 정확도만으로는 더 낫다).

정확도 99.8%가 “모델이 좋다”는 증거가 아님을 보여주는 가장 직접적인 숫자.



왼쪽: 임계값 t 1.0→5.0을 올리면 정확도는 99.8%(무조건 정상, 붉은 점선) 부근에서 거의 움직임이 없음. 오른쪽: 같은 범위에서 재현율은 0에서 0.99까지 크게 변한다 — 정확도로 “동점”인 동안, 사기를 잡는 능력은 완전히 다름.

실습: 정확도 순위와 사기 잡기 순위 (2)

같은 분류자에서 임계값만 바뀌어도 정반대의 줄 서기:

임계값 t	정확도	Precision	재현율	F1
3.5	99.92%	86.1%	71.0%	77.8%
2.5	99.37%	22.8%	90.0%	36.3%
2.0	97.72%	7.8%	96.5%	14.5%

- 정확도로 줄 세우면 $t = 3.5$ 가 최고, $t = 2.0$ 이 최하.
- 사기를 실제로 잡는 능력(재현율)으로는 순서가 완전히 뒤집힌다 ($t = 2.0$ 이 최고).

교훈

“정확도가 높을수록 좋은 모델”이라는 직관이 불균형 데이터에서는 모든 것을 더 놓치는 방식을 최고로 뽑는 잘못된 기준이 된다.

실습: 동점의 함정 (3) — 의미를 가진 지표는 PR-AUC

- 발표 설정(로지스틱회귀 vs GBDT)을 실제 2차원 불균형 데이터로 재현하면: test 정확도는 **99.86% vs 99.80%** — 0.06%p 차이, **검증셋 잡음보다 작거나 같은 크기**.
- 그런데 PR-AUC는 **0.636 vs 0.071**로 확연히 달라진다 — 정확도 하나만 보면 “둘이 같다”, PR-AUC를 보자니 차이는 컸다.
- 참고: 이 장난감 실행에서 GBDT는 50개 트리·학습률 0.1로 양성 200개에 **과소적합**해 오히려 PR-AUC가 낮게 — “트리 수·학습률이 양성 개수에 비해 충분한가” 라는 리뷰 질문의 좋은 예시.

반박 가능성

“정확도만 보면 동점인데 PR-AUC를 보자니 다르다”는 리뷰어가 한 말이 실험에서 실제로 일어난 일이므로 **반박 가능** — 발표팀이 반박하려면 **숫자**(PR-AUC/재현율 + “0.1%p 차이가 이 크기보다 크다”)를 꺼내야 한다.

좋은 리뷰를 쓰는 과정

8.2 Peer-Review — '반박 가능한' 리뷰를 쓰는 과정

다른 팀 발표 + 슬라이드 읽기
(상대가 무엇을 주장하는지 파악)

체크리스트를 항목별로 적용

1. 문제 정의
무엇을 예측하려 했는지 명확한가

2. 방법론 적절성
데이터 특성에 맞는 모델인가

3. 수식적 정당화
요구사항을 충족하고 타당한가

4. 결과의 정직성

형식으로 고정한 흐름

- 1 발표 듣고
- 2 체크리스트 4항목 적용
- 3 각 항목에 구체적 관찰 기록
- 4 그것이 이 학기 개념(장·절)에 뿌리 박은 질문인지 검사
- 5 아니면 다시 쓰기

리뷰 템플릿 — 빈칸이 채워지지 않으면 3점 미만

팀이름

: _____ 리뷰어 : _____

1. 문제정의 -- 무엇을예측분류하려 / 했는지한문장 . 명확했는가?
2. 방법론적절성 -- 데이터의어떤특성불균형 (, 차원 , 결측치)에어떤모델이맞았는가
? 그선택에동의하는가 , 근거와함께 .
3. 수식적정당화 -- "최소 개1" (8.1)를 채웠는가? 어떤장의개념을썼고
 , 그설명이실제로 ** 타당한가?
4. 결과의정직성 -- 잘안된부분과그원인을분석했는가 ?
5. 반박가능한질문필수 (, 개1 이상)근거개념
 : Ch__ 절__ 개념 (: _____)질문
 : _____ 답이 (나쁘면결과가흔들려야한다)

빈칸 미채우면 3점 미만

자주 하는 실수: 리뷰가 감상평에 머무는 것

- 구체적인 주차·개념을 근거로 든 질문만이 “반박 가능”하다 — 발표팀이 답하려면 실제로 자신의 결과를 다시 들여다봐야 하기 때문.

채점의 축

peer-review 점수가 체크리스트를 “채웠는가”가 아니라 “그 안의 질문이 얼마나 구체적인가”로 매겨지는 이유가 여기에 있다.

확인 문제 (1)

- 1. “5%만 양성인 데이터에 신경망을 써서 정확도 95%를 냈다”는 발표. 가장 약한 부분은? Week 2.3 개념으로 반박 가능한 질문 하나를 쓰시오.

답: 정확도의 함정(Ch02.3) — **모두 음성**으로만 찍어도 95%. 질문: “Precision과 Recall(또는 PR-AUC)이 각각 얼마인가요? 무조건 음성 모델과 같은 수인데, 실제로 양성을 얼마나 더 잡는지 보여주세요.”

- 2. “**테스트셋**으로 여러 λ 중 가장 좋은 것을 골랐다”고 인정한 팀. Week 6.3의 어떤 원칙이 깨졌고, 왜 그 숫자가 낙관적인가?

답: “test를 하이퍼파라미터 선택에 쓰지 말고 딱 한 번만” 원칙 위반. 후보 중 **가장 잘 나온 것을** 고르면 잡음의 max를 고르는 것 — 후보가 많을수록 낙관적으로 읽힘(선택 편향). 올바르게: val로 λ 선택 후 test **한 번**.

확인 문제 (2)

- 3. “왜 반박 가능한(falsifiable) 질문이 좋은 리뷰의 기준인가?” 한 단락으로.

답: Popper의 반증주의처럼, 과학적 주장은 “틀렸음을 보이는 관측이 상상이 가능한가”로 판별된다. 좋은 리뷰 질문도 발표팀이 **제대로 답하지 못하면 결과가 무너지는** 질문이어야 한다. 감상평은 답이 아무리 나빠도 결과를 흔들지 못함. peer-review는 Amgen처럼 “내 결과도 남이 재현·반박할 수 있는가”를 **미리 방어**하는 과학적 행위.

- 4. “모델 선정이 적절해 보이지 않습니다”는 3단 채점 중 어디인가? 3점으로 어떻게 바꿀 수 있는가?

답: 근거(개념, 데이터 특성)가 없으므로 **2점**. 3점이라면 **관찰+개념+왜**를 채운다: “99:1 불균형에서 정확도로 비교했는데(관찰), Ch02.3 함정으로 ‘둘 다 항상 다수 클래스’ 모델일 수 있어(개념) Precision·Recall 또는 PR-AUC로 다시 비교해야 합니다(왜).”

확인 문제 (3) — 어떤 숫자를 신뢰하는가

- 5. 95% 불균형 데이터에서 “test 정확도 93%”를 헤드라인으로, 그 뒤에 “PR-AUC 0.55”도 함께 보고한 팀. “모델이 쓸모있는가”를 판단할 때 **어떤** 숫자를 신뢰해야 하는가?

답: **PR-AUC 0.55** 쪽. 95% 불균형에서는 정확도 93%가 **무조건 다수 클래스** 모델(95%)보다도 **낮다** — 정확도는 이 모델이 “무조건 다수”보다 못하다는 뜻일 뿐, 유용성의 **크기**를 말해주지 않는다. PR-AUC 0.55는 베이스레이트(0.05)보다 훨씬 높아 “우연보다 더 잘 잡고 있다”는 신호. **유용성**을 논할 때는 PR-AUC/재현율 기준.

판정 기준

정확도는 **순위를 정하는 데는**, PR-AUC/재현율은 **유용성을 논하는 데는** 사용할 수 있다 — 두 숫자를 **둘 다** 보고, 불균형이 심할수록 후자에 무게를 둔다.

자주 묻는 질문

- **Q. 우리 팀 발표에 대한 리뷰가 너무 비판적이면?** 비판적인 리뷰일수록 체크리스트의 목적에 가깝다 — 발표팀이 못 보고 지나친 문제를 찾아주는 것이지 인신공격이 아니다. 다만 리뷰어도 “왜 그 지적이 타당한지”를 **이 학기 개념으로 뒷받침**해야 한다.
- **Q. 시간이 부족하면 무엇을 우선?** “**방법론 적절성**”을 가장 먼저 — 문제 정의가 아무리 명확해도 데이터 특성에 안 맞는 모델(예: 불균형에 정확도)을 골랐다면 뒤의 **결과 해석 전체**가 흔들리기 때문.
- **Q. 발표팀이 “좋은 지적입니다”만 하면?** 그건 발표팀이 **아직 답하지 못했다는 증거**. 좋은 리뷰는 “좋은 지적”으로 넘길 수 **없는** 질문 — 답하려면 **새로운 계산·실험·그래프**를 꺼내야 하는 질문. “Precision·Recall을 보여주세요”는 그 자리에서 혼동행렬을 다시 써야 답 → **반박 가능**. “모델을 더 생각해보세요”는 어떤 답도 가능 → 반박 불가능. “좋은 지적”으로 끝나면 그 질문은 2점에 머문 것 — **구체적 산출물(어떤 그래프/계산)을 요구하는 쪽으로 재작성**.

8.3 중간고사 대비 총정리

새 개념이 없다 — “재현 가능한가”를 점검한다

- Block A 마지막: 재현 가능성 점검

이 절의 구조

시험에서 가장 자주 나오는 질문 유형 **4개**를 뽑고, 그중 “**손으로 써야 하는**” **3가지**(유도 템플릿 ①②③)를 실제로 종이에 풀고, 나머지는 자가진단 플로우와 확인 문제 9개로 채운다. 실습 노트북은 세 템플릿의 숫자를 코드로 검증.

장별 핵심 질문 — 자가진단 도구

장	핵심 질문	다시 봐야 할 개념
Ch02	같은 선형모델로 회귀와 분류를 어떻게 모두 푸는가	경사하강법, 정규방정식, 교차 엔트로피
Ch03	생성적 접근과 판별적 접근의 차이는 무엇인가	베이즈 정리, GDA/로지스틱회귀의 관계
Ch04	“가깝다”만으로 예측하는 것의 한계는 무엇인가	편향-분산, 차원의 저주
Ch05	확률이 아니라 마진으로 경계를 정하면 무엇이 달라지는가	서포트 벡터, 커널 트릭
Ch06	과적합을 손실함수로 어떻게 통제하는가	L1/L2 정규화, 교차검증
Ch07	트리를 어떻게 앙상블하고 예측을 어떻게 설명하는가	정보이득, RF vs GBDT, SHAP

- **목록으로 읽지 말고** “핵심 질문”에 한 문장으로 답할 수 있는가의 **자가진단 도구**로.

시험에서 반복되는 질문 유형 4가지

유형	예
① 유도(빈칸 완성)	“경사하강 1스텝 빈칸 채우시오”, “KKT에서 해를 구하시오”
② “X를 키우면?” 정성 추론	“C를 크게 하면?”, “ λ 를 0으로 하면?”, “트리 깊이를 늘리면?”
③ 모델 비교(장 넘나들기)	“kNN과 SVM은 왜 둘 다 스케일링이 필요한가?”, “RF와 GBDT의 차이는?”
④ 실전 코드·절차 판정	“이 파이프라인의 누수 지점은?”, “이 발표의 약점과 질문 하나”

시험 준비가 끝나는 구조

①②를 실제로 종이에 써보고, ③④는 기존 섹션(확인 문제, “자주 하는 실수”)을 훑으면 된다.

유도 템플릿 ①: 로지스틱회귀 경사하강 1스텝 I

문제

1차원 입력, $n = 3$ 샘플, $x = (1, 2, 3)$, $y = (0, 1, 1)$, 현재 $w = 0.1$, $b = 0$, 학습률 $\eta = 0.5$. 교차 엔트로피 손실

$$\ell = -\frac{1}{n} \sum_i [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)] \quad (\hat{p}_i = \sigma(wx_i + b))$$

에서 **경사하강 1스텝**을 손으로 수행하라. 4단계가 **예측 대입** → **손실 계산** → **경사** → **업데이트** — 손실이 무엇이든 이 순서만 지키면 같은 모양.

1단계 — 예측 대입. $z_i = wx_i + b = (0.1, 0.2, 0.3)$:

샘플	x_i, y_i	z_i	$\hat{p}_i = \sigma(z_i)$	$\hat{p}_i - y_i$
1	(1, 0)	0.1	0.524979	+0.524979
2	(2, 1)	0.2	0.549834	-0.450166
3	(3, 1)	0.3	0.574443	-0.425557

유도 템플릿 ①: 로지스틱회귀 경사하강 1스텝 II

$$\ell = -\frac{1}{3} [\log(0.475021) + \log(0.549834) + \log(0.574443)] = \frac{0.744436 + 0.597797 + 0.554336}{3} \approx 0.6322$$

3단계 — 경사. $\frac{\partial \ell}{\partial w} = \frac{1}{n} \sum_i (\hat{p}_i - y_i) x_i$ 에 대입:


$$\frac{1}{3} [(+0.524979)(1) + (-0.450166)(2) + (-0.425557)(3)] = \frac{0.524979 - 0.900332 - 1.276671}{3} = -0.550675$$

$\frac{\partial \ell}{\partial b} = \frac{1}{3} \sum_i (\hat{p}_i - y_i) = -0.116915$ 도 함께. **4단계 — 업데이트.**

$$w \leftarrow 0.1 - 0.5 \times (-0.550675) = 0.375338, \quad b \leftarrow 0 - 0.5 \times (-0.116915) = +0.058457$$

템플릿 ① “왜?”: 부호 읽기와 $(\hat{p} - y)x$

샘플 3($x = 3$)의 기여가 샘플 1($x = 1$)보다 2.4배 큰 이유



부호가 실제-예측 오차의 **방향**을, x_i 가 그 오차의 **가중치**를 정한다 — 샘플 3의 기여가 샘플 1의 2.4배인 것은 “더 틀려서”가 아니라 “큰 x 로 틀려서”다.

유도 템플릿 ②: SVM KKT — “C가 실제로 바꾸는 것” I

문제 — 1차원 4개 점:

점	x	y	역할
A	-1	+1	A와 같은 위치(다중점)
B	-1	+1	
C	+2	-1	
E	-0.2	-1	이상치 — -1인데 +1 쪽에 붙어 있음

목적함수

$$\min_{w,b} \frac{1}{2}w^2 + C \sum_i \xi_i \quad (\text{약분 } y_i(wx_i + b) \geq 1 - \xi_i, \xi_i \geq 0)$$

KKT 세 조건 + 정합성:

- ① $0 \leq \alpha_i \leq C$ — α 는 “점 i 에게 쓰인 위반 예산”. C 가 전체 예산이면 α 는 각 점에 배정된 몫.
- ② $\alpha_i \xi_i = 0$ — 마진 위반($\xi_i > 0$)을 하는 점은 α 가 상한 C 에 **꼭 차 있다**.
- ③ $\alpha_i (y_i f(x_i) - 1 + \xi_i) = 0$
 - ▶ $\alpha_i = 0$: 마진 바깥($y_i f(x_i) \geq 1$), 해에 영향 없음.

유도 템플릿 ②: SVM KKT — “C가 실제로 바꾸는 것” II


- ▶ $0 < \alpha_i < C$: 마진 위에 정확히 ($y_i f(x_i) = 1$).
- ▶ $\alpha_i = C$: 마진 안 또는 오분류 ($y_i f(x_i) \leq 1$).

정합성 (stationarity)

$$w = \sum_i \alpha_i y_i x_i, \quad \sum_i \alpha_i y_i = 0$$

이 문제에선 클래스 2:2라 $\alpha_A + \alpha_B = \alpha_C + \alpha_E$. 이제 C 를 0에서부터 올리며 각 구간의 해를 구한다. **이 4구간 풀이(구간 경계 = “어떤 α 가 상한/0에 닿는가”)가 템플릿.**

구간	C 범위	α	w, b	$\ w\ ^2$, 마진 $2/\ w\ $
I	$C \leq \frac{10}{57} \approx 0.175$	전부 = C	$(-3.8C, 1.9C)$	$14.44 C^2$; 마진 $\frac{2}{3.8C}$ ($52.6 \rightarrow 3.0$)
II	$\frac{10}{57} < C < \frac{5}{6}$	$\alpha_E = C, a = \frac{1}{9} + \frac{11}{30}C, \alpha_C = \frac{2}{9} - \frac{4}{15}C$	$(-\frac{2}{3}, \frac{1}{3})$ 고정	4/9 고정 ; 마진 3.0 고정
III	$\frac{5}{6} < C < \frac{25}{8}$	$\alpha_E = C, a = C/2, \alpha_C = 0$	$(-0.8C, 1 - 0.8C)$	$0.64 C^2$; 마진 $\frac{2.5}{C}$ ($3.0 \rightarrow 0.8$)
IV	$C \geq \frac{25}{8} = 3.125$	$a = \frac{25}{16}, \alpha_E = \frac{25}{8}, \alpha_C = 0$	$(-\frac{5}{2}, -\frac{3}{2})$ 고정	6.25 고정 ; 마진 0.8 고정



Vladimir Vapnik — 통계적 학습 이론의 일반화 오차 상한 공식 앞에서 (2001년 워크숍)

4구간 읽는 법 (1): I·II — 직감이 유일한 맞는 구간


- 구간 I: C 증가 시 마진 비례 팽창

핵심

C 가 바꾸는 것은 마진의 크기가 아니라 “**이상치 E의 위반을 얼마까지 사들이는가**”.

4구간 읽는 법 (2): III·IV + 실측

- **III**: E의 위반 비용이 커지자 ($C \geq 5/6$) $C(+2)$ 가 마진에서 빠짐($\alpha_C = 0$), 경계가 **왼쪽으로 미끄러지며** E를 감싸기 시작 ($w = -0.8C$). 마진은 $\frac{2.5}{C}$ 로 **줄어든다** (C를 올리면 마진이 줄어드는 구간!).
 $C = 25/16$ 에서 E가 올바르게 분류.
- **IV** ($C \geq 3.125$): E도 마진 위에 닿으면 해는 $w = -\frac{5}{2}$, $b = -\frac{3}{2}$ 로 **다시 정지** — 경계는 $A(-1, +1)$ 과 **이상치 E**(-0.2, -1)가 정한다(중점 -0.6, 반갭 0.4, 마진 0.8).



C 를 0.0001~100으로 올리며 실제 $\|w\|^2$ (파랑)을 그린 것. 실선이 두 번 꺾여 수평 (I: $14.44C^2 \rightarrow$ II: $4/9 \rightarrow$ III: $0.64C^2 \rightarrow$ IV: 6.25). 세 수직 점선(10/57, 5/6, 25/8)이 구간 경계. C 를 아무리 올려도 $\|w\|^2$ 는 6.25를 넘지 않음.

C를 100으로 올려도 $\|w\|^2 = 6.25$, 마진 0.8, 경계 $x = -0.6$ 은 변하지 않는다.

템플릿 ②의 답안 뼈대

- $C \geq C^*$ 이후 해는 C 에 무관

유도 템플릿 ③: “두 항의 구조” (적합도 + 단순성)


모델	목적함수	적합도 / 단순성 항	노브(트러스트)
Ridge (Ch06)	$\ell_{\text{MSE}} + \frac{\lambda}{2} \ w\ ^2$	ℓ_{MSE} : 데이터에 맞추기 / $\ w\ ^2$: 가중치 축소(분산↓)	λ ($0 \rightarrow \infty$)
Lasso (Ch06)	$\ell_{\text{MSE}} + \lambda \ w\ _1$	위와 같음 / $\ w\ _1$: 정확히 0 만드는 켄(kink)	λ
소프트 마진 SVM (Ch05.2)	$\frac{1}{2} \ w\ ^2 + C \sum_i \xi_i$	$C \sum \xi_i$: 위반 사들이기 / $\frac{1}{2} \ w\ ^2$: 마진 최대화	C ($0 \rightarrow \infty$)
GBDT (Ch07.3)	(반복) 잔차에 트리 적합 + η 로 축소	트리: 잔차 설명 / η (학습률), n (트리 수)	η, n
kNN (Ch04)	(파라미터 없음 — 전량 memorize)	“적합” = 전량 암기 / k : 이웃 평균으로 매끄럽게	k ($1 \rightarrow \infty$)

패턴 한 줄

적합도 항은 “데이터에 잘 맞추는 것”, 단순성 항은 “모델을 단순하게 유지하는 것”을 재고, 노브 하나가 둘의 비중을 조절한다.

그림으로: Ridge vs Lasso — 계수가 0에 도달하는가


두 항의 구조: 단순성 항이 $\|w\|^2$ (L2)냐 $\|w\|_1$ (L1)이나



합성 데이터(5특징) 실제 적합 경로 — L2는 $\lambda \uparrow$ 에도 0에 **가까워질 뿐**, L1은 일부 계수가 **정확히 0**에 도달.

템플릿 ③ 주의: 노브의 방향은 모델마다 반대

$\lambda \uparrow$: 단순해진다 vs $C \uparrow$: 적합해진다 --- 정반대 방향




Ridge λ 와 SVM C 는 역방향 — “노브를 크게 하면?” 문항에서 가장 흔한 0점은 이 방향을 헷갈리는 것.

편향-분산 스펙트럼: 같은 데이터, 네 모델

diabetes 데이터로 4개 모델 실측


모델	train R^2	val R^2	격차 (train – val)
Ridge($\lambda=10^{-4}$) [Ch02,06]	0.579	0.443	0.137
Ridge($\lambda=1$) [Ch06]	0.579	0.442	0.137
kNN($k=5$) [Ch04]	0.618	0.329	0.290
Tree(무제한 깊이) [Ch07.1]	1.000	-0.014	1.014

Flexibility spectrum: Ridge $\rightarrow$ kNN $\rightarrow$ Tree. Moving right, train keeps rising while val falls behind



스펙트럼 읽는 법 — 시험 답안 구조

- 모델 유연성 스펙트럼
- 격차가 큰 모델(오른쪽)은 **분산**이 크다 (Week 4.1: “모델 추정량이 train 데이터의 선택에 따라 크게 흔들린다”). 격차가 작은 모델(왼쪽)은 **편향**이 크다 (Week 6: “평균적으로 진실을 향한 systematic한 오차”).




트리의 val R^2 가 0 아래(음수)

train에서 1.000을 찍고도 검증 데이터에서는 **평균만 예측하는 모델보다 나쁘다**는 뜻 — Week 6.2 U자 곡선의 “ $\lambda \rightarrow 0$ 쪽 끝”이 실제로 이렇게 처져 있음을 보여주는 숫자. **“train $R^2=1.000$ 이니까 좋은 모델”이라는 답안은 이 한 줄로 반박된다.**

장을 넘나드는 동치성: GDA vs 로지스틱회귀

측정	값
로지스틱 test AUC	0.9934
GDA/LDA test AUC	0.9855
출력 확률 상관계수	0.900
$\cos(w_{\text{logit}}, w_{\text{GDA}})$	0.203
test 라벨 일치율	93.6%



결정 경계는 같고, 경계 벡터 방향은 다르다 — 정규분포 전제에 따라 동치성 범위가 달라진다

누수 원칙, 숫자로: 스케일러 fit의 위치

스케일러 fit 범위	val R ²
전체(train+val+test) — 원칙 위반	0.4417
train만 — 원칙 준수	0.4417

차이는 3×10^{-5} — “거의 없다”가 정답

diabetes는 “행 하나 = 독립 관측”이어서 train의 평균/표준편차와 전체의 것이 거의 같다. 누수가 크게 벌어지는 것은 Week 6.3의 환자 예처럼 **동일 실체 (환자, 계좌, 사용자)가 train과 val/test에 동시에 들어와 정보를 공유할 때다** — 그때는 fit의 위치가 아니라 **분할 자체가** 문제를 만든다.

시험 판정 기준: “누수가 커지는 조건(공유된 실체, 시간 순서)을 설명할 수 있는가”.

자가진단 5문항 + 40분 모의 문제

- 1 장별 핵심 질문 6문항 중 **한 문장도 멈추지 않고** 답할 수 있는 것이 몇 개인가? (5개 이상이면 양호)
- 2 템플릿 ① **4단계 빈칸 없이 쓰기**
- 3 템플릿 ②에서 “ $C \geq 25/8$ 이후 왜 $\|w\|^2 = 6.25$ 로 고정되는가”를 **KKT 세 조건**으로 쓸 수 있는가?
- 4 **편향-분산 언어로 2문장 진단**
- 5 8.2절 가상 발표(99.8:0.2, 99.7% vs 99.8%)에 대해, **장·절을 명시한** 반박 가능한 질문 하나를 쓸 수 있는가?

자주 하는 실수 6가지

- ① 경사 부호/계수 혼동
- ② C 를 키우면 마진이 무한히 커진다
- ③ “**train $R^2 = 1.000$ 이면 좋은 모델**”(§ 스펙트럼): 무제한 트리는 train 1.000 / val -0.014 — val(또는 gap)로만 판단.
- ④ Ridge λ 와 SVM C 를 같은 방향의 노브로 생각

확인 문제 1~4: 장 넘나들기 I

- 1. 로지스틱회귀(Ch02)와 GDA(Ch03)는 둘 다 어떤 공통된 최종 형태에 도달하는가?

답: 둘 다 $P(y=1|x) = \sigma(w^\top x + b)$ 라는 같은 시그모이드-선형 형태(Ch03.2). 다만 로지스틱회귀는 판별적으로 직접 학습하고, GDA는 정규분포를 가정한 생성적 모델링에서 베이즈 정리로 유도해내는 경로가 다르다.

- 2. kNN(Ch04)에서 k 를 1로 두는 것과 SVM(Ch05)에서 C 를 매우 크게 두는 것은 편향-분산 관점에서 어떤 공통점이 있는가?

답: 둘 다 모델을 데이터에 최대한 정확히 맞추려는 극단 — 분산이 커지고 (과적합 위험) 편향은 작아지는 쪽. $k=1$ 은 노이즈 하나에도 민감하고, C 가 매우 크면 이상치 하나까지 완벽히 분류하려 든다(Ch05.2).

- 3. Ridge(Ch06)와 소프트 마진 SVM(Ch05.2) 목적함수는 둘 다 “두 항의 합”. 각각 어떤 두 항인가?

답: Ridge는 “적합도(원래 손실) + $\lambda \times$ 가중치 크기”, SVM은 “ $\frac{1}{2} \|w\|^2$ (마진 최대화) + $C \times$ 위반 정도(히지 손실)”. 둘 다 “데이터에 잘 맞추기”와 “단순하게 유지하기” 사이 트레이드오프를 하나의 하이퍼파라미터(λ 또는 C)로 조절.

- 4. 나이브베이즈(Ch03.3)와 결정 트리(Ch07.1)는 왜 둘 다 특징 스케일링이 필요 없는가?

답: 나이브베이즈는 각 특징의 값을 $P(x_i=1)$ 를 독립적으로 추정할 뿐, 값들 사이의 거리를 계산 않는다.

확인 문제 5~7: 장 넘나들기 + 템플릿 ② I

- 5. RF(Ch07.2)와 GBDT(Ch07.3)의 트리 학습 방식(**독립 병렬** vs **순차적 잔차 학습**) 차이가, **라벨링 오류에 대한 취약성**에 어떤 영향을 주는가?

답: RF는 트리들이 서로 **독립** 적이라 한 트리가 라벨 오류를 과하게 학습해도 **다수결** 에서 다른 트리에 의해 희석. GBDT는 각 트리가 이전까지의 **잔차를 쫓으므로**, 라벨 오류가 만드는 이상한 잔차를 후속 트리들이 계속 따라가며 **과적합할 위험**이 더 크다(Ch07.3 FAQ).

- 6. Week 6.3의 데이터 누수(leakage) 원칙이 이번 프로젝트에서 **가장 흔히 깨지는 지점**은?

답: 정규화·표준화 통계량(평균, 표준편차)이나 결측치 대체값을 train/val/test로 나누기 **전에 전체 데이터로** 미리 계산하는 경우(Ch06.3) — fit은 반드시 **train에만** 적용하고, val/test에는 transform만 적용.

- 7. 템플릿 ②의 4점 문제에서, $C = 3.125$ 와 $C = 100$ 의 해(w^*, b^* , SV 집합)는 같다. KKT 조건으로 **왜** 같은지, 그리고 C 를 더 키워도 바뀌지 않는 마진의 **상한 값(0.8)**을 두 점의 지오메트리에서 직접 구해보자.

답: $C \geq 25/8$ 에서는 $A \cdot B(-1, +1)$ 과 이상치 $E(-0.2, -1)$ 가 모두 마진 위에 있고 ($0 < \alpha_i < C$), $C(+2)$ 는 **마진 바깥** ($\alpha_C = 0$) — 이 세 상태(마진 위/위/바깥)는 C 의 **크기에 의존하지 않으므로** KKT의 해도 C 에 무관. 마진의 상한은 **가장 가까운 다른 클래스 두 점**이 정한다: $A(-1, +1)$ 과 $E(-0.2, -1)$

확인 문제 8~9: 템플릿 ①③ I

- 8. 템플릿 ①에서 학습률을 $\eta = 0.5$ 대신 $\eta = 2$ 로 쓰면 1스텝 후의 w, b 는? “학습률을 크게 하면 항상 빨리 수렴한다”가 왜 **성급한 결론**인지, 이 숫자만으로 말할 수 있는 한계는?

답: $w = 0.1 - 2 \times (-0.550675) = 1.201350, b = 0 - 2 \times (-0.116915) = 0.233830$ — 스텝이 **정확히 4배**.

한계: 손실면이 볼록(교차 엔트로피는 볼록)이므로 이 방향의 큰 스텝은 손실을 **낮추기**는 한다, 그러나 스텝이 경사 변화율에 비해 너무 크면 다음 스텝에서 반대쪽으로 **오버슈팅**하며 손실이 튀어오를 수 있다 — 1스텝만으로는 “수렴”이 아니라 “더 큰 스텝”만을 볼 수 있다. (Ch09 Block B에서 학습률 스케줄링이 이 주제의 일반화.)

- 9. Lasso(Ch06.1)의 목적함수 두 항을 쓰고, “왜 L1은 가중치를 **정확히 0**으로 만들지만 L2는 (유한한 λ 에서는) 그렇지 않은가”를 한 문장으로 답하자.

답: $\min_w \ell_{\text{MSE}}(w) + \lambda \|w\|_1$. $\|w\|_1$ 은 $w_j = 0$ 에 **켄(kink)**을 만들어, 원래 손실 기울기의 절댓값이 λ 이하이면 정답이 그 켄에 딱 붙어 $w_j = 0$ 이 된다(Ch06.1의 소스 스로싱 $\mathcal{T}_\lambda$). 반면 $\|w\|^2$ 은 0에서 **기울기가 0인 매끄러운** 볼록함수라 w_j 를 0으로 **가까이 당기지만** 유한한 λ 로는 정확히 0까지 데려가지 못한다.

확인 문제 8~9: 템플릿 ①③ II

이번 프로젝트가 남기는 교훈

지금까지 배운 어떤 모델도 “항상 최선”이지 않다 — 실전에서는 데이터의 특성을 보고 어떤 도구를 쓸지 스스로 판단해야 한다.

자주 묻는 질문 + 시험 전날 세 숫자

- Q. 코딩 문제도? Week 2, 6, 7에서 반복 연습한 “핵심 줄이 빈칸으로 남겨진 함수를 완성하라” 형식이 가장 가까운 연습.
- Q. 여섯 장을 전부 같은 비중으로? 아니다 — “핵심 질문”에 스스로 답할 수 있는지가 가장 빠른 자가 진단. 손유도 문제(정규방정식, $GDA \leftrightarrow$ 로지스틱회귀 동치성, 마진 공식)는 그대로 다시 나올 가능성이 높아 우선순위 고.
- Q. “장 넘나들기” 연습법? 한 문항을 두 장의 언어로 각 한 문장씩 — 예: 확인 문제 4는 “Ch03.3의 언어: $P(x_j | y)$ 를 독립 추정하므로 거리 계산이 없다” + “Ch07.1의 언어: 순서($> \text{threshold}$)만 쓰므로 스케일에 불변”.

시험 전날 세 숫자	의미(장)
-0.5507	템플릿 ①의 1스텝 경사 (Ch02)
$C^* = 3.125$ 이후 $\ w\ ^2 = 6.25$ 고정	템플릿 ②의 마진 상한 0.8 (Ch05)
무제한 트리: train 1.000 / val -0.014, 격차 ≈ 1.0	S 스펙트럼 (Ch04·06·07)

세 숫자를 “어떤 가정에서, 왜” 나오는 수로 설명할 수 있으면 유도 문제의 빠대는 확보 — 숫자 자체는 실습 노트북에서 언제든지 재현.

이번 주차 정리

- ① **8.1 팀 프로젝트** — 4주 파이프라인 (문제 정의 → 3분할·train-fit·모델 비교 → test 한 번 → 보고·발표). 산출물은 **성능이 아니라 정직한 절차** — 베이스라인, 학습 곡선, 수식적 정당화(관찰 + 개념 + 왜).
- ② **8.2 Peer-Review** — Popper의 반증주의 + Amgen 재현 실험. 좋은 리뷰 = **구체적 관찰 + 장·절 개념 + “왜 문제인지”**. 정확도의 함정(99.8:0.2)은 PR-AUC/재현율로만 판별.
- ③ **8.3 총정리** — 세 숫자: -0.5507 (경사 1스텝), $C \geq 3.125$ 이후 $\|w\|^2 = 6.25$ (마진 상한 0.8), 무제한 트리 train 1.000/val -0.014 .

다음 주 — Week 9. 신경망 기초

직선 하나로 경계를 그을 수 없는 문제(XOR)를 **은닉층과 역전파**로 풀기. 이번 장에서 몸에 밴 “성능을 정직하게 재는 절차”와 “결과를 개념으로 설명하는 습관”은 층이 깊어질수록 오히려 더 절실해진다.