

CNN 기초와 응용

합성곱 · 출력크기 · FLOPs · 풀링 · 수용장 · ResNet · 탐지 · 분할 · 전이학습

Machine Learning 1 · 10주차

한국과학영재학교 (KSA)

Chapter 10

이번 주차 개요

이 챕터를 마치면

- 합성곱 출력 크기를 패딩·스트라이드와 함께 손으로 계산하고, 파라미터 수·FLOPs로 “왜 합성곱이 효율적인가”를 숫자로 설명
 - 합성곱·풀링이 “좁아지고 깊어지는” 구조를 만드는 역할을 설명하고, LeNet→ResNet까지 스킵 연결이 왜 깊은망을 가능하게 하는지 서술
 - 탐지·분할 헤드(R-CNN, IoU/NMS, 1×1 합성곱, U-Net)와 전이학습(특징 추출 vs 미세조정)이 언제·왜 유리한지 판단
-
- **10.1 합성곱, 출력 크기, 파라미터 수와 FLOPs** — MLP의 한계에서 출발해 파라미터 공유로 이어지는 “한 연산”을 계산한다
 - **10.2 풀링과 전형적인 CNN 구조** — 그 연산을 “구조”로 쌓고, 깊이의 한계에 부딪혀 스킵 연결(ResNet)을 만난다
 - **10.3 분류를 넘어서: 탐지, 분할, 전이학습** — 그 구조를 “새 문제”에 다시 쓴다

이 장을 관통하는 하나의 실: “재사용” — 새로 배울 것을 최소화하고, 이미 배운 것을 어디든 다시 쓰자.

10.1 합성곱, 출력 크기, 파라미터 수와 FLOPs

MLP로 이미지를 다루면 안 되는 이유

Chapter 9의 다층 퍼셉트론(MLP)에 이미지를 넣으려면 가로세로 픽셀을 **펼쳐서** 긴 벡터로 만들어야 한다.

- 200×200 흑백 이미지만 **4만 개의 입력**
- 첫 은닉층 뉴런 1000개면 그것만으로 **4천만 개의 가중치**
- “고양이가 왼쪽 위에 있든 오른쪽 아래에 있든 같은 고양이”라는 사실을 **전혀 활용 못 함**
- 픽셀 하나 위치만 옮겨도 **완전히 다른 입력**으로 취급

이미지의 공간 구조(위치 불변성)를 활용하려면?

합성곱: 작은 필터를 온 이미지에 재사용

핵심 아이디어는 허블·비셀(Hubel & Wiesel, 1962)의 시각피질 실험과 같다: 뉴런은 화면 전체가 아니라 **좁은 수용장**의 특정 방향 선분에만 반응한다.

- **합성곱**: $k \times k$ **필터(커널, kernel)**를 입력 위에서 **슬라이드**하며, 각 위치에서 겹치는 영역의 **원소별 곱의 합**을 계산
- 필터 값 자체가 **학습 대상 파라미터** — “모서리 탐지 필터”는 어느 위치에서든 모서리를 감지해야 하므로 위치마다 새로 배울 필요 없음

파라미터 공유 (parameter sharing)

이 재사용 덕분에 MLP보다 **훨씬 적은 파라미터**로 훨씬 큰 이미지를 다룰 수 있다.

conv2d 직접 구현해보기

```
def conv2d(image, kernel):
    img_h, img_w = len(image), len(image[0])
    k = len(kernel)
    out_h, out_w = img_h - k + 1, img_w - k + 1
    output = [[0.0] * out_w for _ in range(out_h)]
    for i in range(out_h):
        for j in range(out_w):
            total = 0.0
            for di in range(k):
                for dj in range(k):
                    total += image[i+di][j+dj] \
                        * kernel[di][dj]
            output[i][j] = total
    return output
```

- 입력 $n \times n \rightarrow$ 출력 $(n - k + 1) \times (n - k + 1)$
- 각 위치마다 필터와 원소별 곱의 합
- “합성곱층”이라는 용어는 후쿠시마의 네오코그니트론 (1980)에서 처음 사용

“합성곱”이라는 이름의 뜻: 뒤집기는 어디로?

신호처리의 정의로, 두 수열 f, k 의 합성곱은

$$(f * k)(i) = \sum_j k(j) f(i - j)$$

$i - j$ 에 주목: 커널이 **뒤집힌(flipped)** 모습으로 겹쳐진다. 그런데 우리 코드(`image[i+di][j+dj] * kernel[di][dj]`)는 뒤집기 없이 그대로 곱한다 — 신호처리 용어로 이것은 **상관(correlation)**이고 “합성곱”이 아니다.

그래도 아무도 신경 쓰지 않는 세 가지 이유:

- ① **필터 값은 학습 대상.** “정답 필터”가 따로 없으므로, 뒤집힌 버전이 다른 반응을 낸다면 가중치를 뒤집힌 것으로 학습시키면 그만 — 표현 가능한 함수 **집합**은 정확히 같다
- ② **고정 필터의 예외는 사실상 없음.** 뒤집기가 실질적 차이가 되는 경우는 “특정 주파수만 통과”하는 손설계 DSP 필터 정도
- ③ **이름의 기원.** LTI(선형 시불변) 시스템 이론의 “출력 = 임펄스 응답의 뒤집힌 버전과 입력의 합성곱” 표현에서 왔고, 네오코그니트론(1980) 이래 관성이 이어져 왔다

실무 규칙

코드와 수식에서는 “각 위치의 원소별 곱의 합”을 그냥 “합성곱”이라고 쓰면 된다 — 이 분야

손으로 한 번: 3×3 필터가 5×5 를 스캔

5×5 흑백 이미지(열 2에 흰선, 밝기 1, 배경 0)에 중심 열만 1인 3×3 필터(“수직선 탐지기”의 가장 단순한 버전):

		0	1	2	3	4
입력 5×5	0	0	0	1	0	0
	1	0	0	1	0	0
	2	0	0	1	0	0
	3	0	0	1	0	0
	4	0	0	1	0	0
필터 3×3	0	1	0			
	0	1	0			
	0	1	0			

$$\text{출력} = 5 - 3 + 1 = 3 \text{ 이므로 } 3 \times 3$$

	j=0	j=1	j=2
i=0	0	3	0
i=1	0	3	0
i=2	0	3	0

중심 위치 ($i=1, j=1$) 직접 계산 — 필터가 이미지의 중심 3×3 영역(행 1~3, 열 1~3)을 덮는다:

$$\begin{aligned} & 0 \cdot 0 + 1 \cdot 1 + 0 \cdot 0 \text{ (행 1)} \\ & + 0 \cdot 0 + 1 \cdot 1 + 0 \cdot 0 \text{ (행 2)} \\ & + 0 \cdot 0 + 1 \cdot 1 + 0 \cdot 0 \text{ (행 3)} \\ & = 0 + 1 + 0 + 0 + 1 + 0 + 0 + 1 + 0 = 3 \end{aligned}$$

나머지 8개 위치도 같은 방식으로 (실습 노트북 § 1에서 numpy로 9개 위치를 그대로 실행).

세 가지를 한꺼번에 보는 손계산

- ① 5×5 입력이 3×3 으로 “줄어든” 것은 $n_{\text{out}} = n - k + 1$ 의 **자연스러운 결과** (다음 절에서 정리)
- ② **어느 위치에서든** 같은 가중치가 같은 패턴에 반응 — 파라미터 공유의 구체적 모습
- ③ “수직선”이 **원본 스케일 그대로** 다음 층으로 전달 — 원본이 5칸짜리 선이든 500칸짜리 선이든, 출력 지도 위에서는 “ 3×3 지도의 중심 열이 밝다”로 **똑같이** 표현됨

“규모를 초월한” 특징의 기반

마지막 점이 합성곱이 스케일에 무관한 특징을 만드는 기반이며, 10.2~10.3에서 풀링·수용장이 이 아이디어를 확장한다.

출력 크기 공식: 미적분이 아니라 “세는 문제”

입력 $n \times n$, 필터 $k \times k$, 패딩 p (가장자리에 0을 두르는 픽셀 수), 스트라이드 s (필터가 한 번에 이동하는 칸 수)일 때:

$$n_{\text{out}} = \left\lfloor \frac{n + 2p - k}{s} \right\rfloor + 1$$

- 예: $n=28, k=3, p=0, s=1$ 이면 $28 - 3 + 1 = 26$
- 패딩 없이는 필터를 지날 때마다 이미지가 점점 작아진다
- $p = (k - 1)/2$ 로 하면(**same padding**) 출력 크기를 입력과 같게 유지

유도 — 필터가 다 들어가는 위치를 세자 (1D로 줄여):

- 필터는 입력 **안쪽**에 완전히 들어와야 하므로 시작 위치 최댓값은 $n - k$
- s 로 이동하면 시작 위치는 $0, s, 2s, \dots$ 중 $\leq n - k$ 인 것들 — 항의 개수 $\lfloor (n - k)/s \rfloor + 1$
- 패딩 p 는 입력을 $n \rightarrow n + 2p$ 로 만들어 준다 (좌·우 **두** 쪽에 p 씩 — 그래서 공식에는 $2p$)

“패딩은 왜 **2p**인가” — 이 공식에서 가장 많이 범하는 실수. 코드 padding=1 은 **한 변당 1픽셀**, 총 늘어나는 길이는 $2p$ 다.

패딩 · 스트라이드 바꾸며 직접 세어보기


8×8 입력, 3×3 필터 ($p = 0$), 스트라이드만

	s	시작 위치	개수
바꾸며:	1	0, 1, 2, 3, 4, 5	6
	2	0, 2, 4	3
	4	0, 4	2

직접 세는 것과 $\lfloor (8 - 3)/s \rfloor + 1$ 이 $s \neq 1$ 에서도 일치 — $s=4$: “5칸을 4칸씩 건너뛰면 0과 4 두 곳”. 수직·수평 방향은 독립적 — 사각형 입력이면 출력도 사각형.

명명: padding="valid" = 패딩 없음 (필터가 다 들어가는 위치만), padding="same" = k 가 홀수일 때 $p = (k - 1)/2$ 로 $n_{out} = n$.

28×28 input, 3×3 filter: valid filter starting positions (red ticks) = output size n_{out}



같은 28×28, $k=3$ 을 1D로 줄여 (p, s) 조합 4가지 — 회색은 패딩, 각 틱(tick)은 유효한 필터 시작 위치 하나. 틱의 개수가 곧

n_{out} : $p=0, s=1 \rightarrow 26 \cdot p=1, s=1 \rightarrow 28$ (same) ·

$p=0, s=2 \rightarrow 13 \cdot p=1, s=2 \rightarrow 14$. 네 숫자 모두

$\lfloor (28 + 2p - 3)/s \rfloor + 1$ 로 그대로 계산된다.

스트라이드 $s = 2$ 가 실제로 하는 일

- 1D에서 길이를 반으로, 2D에서는 가로·세로 둘 다 반으로
- $\Rightarrow$ 공간 **면적**은 **1/4**로 줄어든다
- 예: 224×224 에 $k=3, p=1, s=2$ 이면 $n_{\text{out}} = \lfloor (224 + 2 - 3)/2 \rfloor + 1 = \mathbf{112}$

AlexNet(2012)의 첫 합성곱 층

정확히 이 설정($224 \rightarrow 112$)으로 다운샘플링한다.

10.2절에서 2×2 풀링도 면적을 1/4로 줄여주는 것을 보게 되는데, “둘 중 무엇을 쓰느냐”는 질문이 생긴다 — 이 절 FAQ에서 비교한다.

파라미터 수 계산

C_{in} 개 입력 채널, C_{out} 개 출력 채널(= 필터 개수), 필터 $k \times k$ 인 합성곱 층의 파라미터 수(bias 포함):

$$\text{params} = (k \times k \times C_{in} + 1) \times C_{out}$$

- 예: $32 \times 32 \times 3$ 이미지, 3×3 필터, 출력 채널 16: $(3 \times 3 \times 3 + 1) \times 16 = \mathbf{448}$ 개뿐
- 같은 입력을 **완전연결층**(출력 뉴런 $32 \times 32 \times 16$)에 연결하려면 **수백만 개**가 필요하다

FLOPs는 “파라미터 수”와는 다른 질문이다.

- 파라미터 수 = “얼마나 많은 숫자를 저장해야 하는가”
- FLOPs = “몇 번의 곱셈-덧셈을 하는가” (속도)

FLOPs 공식: n_{out}^2 이 곱해진다

출력의 한 위치·한 채널을 계산하려면 $k \times k \times C_{\text{in}}$ 번 곱셈이 필요하고, 이것을 **모든 출력 위치 × 모든 필터** 로 반복:

$$\text{FLOPs} \approx n_{\text{out}}^2 \times C_{\text{out}} \times (k \times k \times C_{\text{in}})$$

- 파라미터 수 공식과 거의 똑같이 생겼지만, **파라미터 수엔 없던 n_{out}^2 이 곱해진다**
- 이유: 같은 필터(같은 파라미터)를 **출력 위치마다 재사용** 하니 파라미터는 적어도, 계산은 그 위치 수만큼 **반복**

예: 224×224 흑백 ($C_{\text{in}}=1$), 3×3 필터 1개, $p=0, s=1$: $n_{\text{out}} = 222$

$$\text{FLOPs} = 222^2 \times 1 \times 9 = 49,284 \times 9 = 443,556 \text{ (약 44만 MAC)}$$

필터를 64개 ($C_{\text{out}}=64$)로 늘리면 **정확히 64배** (약 2,839만 MAC) — **커널 개수를 늘리면 파라미터 수와 연산량이 똑같이 정비례**로 늘어난다.

손계산 표: 미니 LeNet 세 층의 비용

28×28 흑백을 세 합성곱 층 + 한 풀링으로 줄여가는 작은 네트워크:

층	연산	출력 크기	파라미터	FLOPs
입력	28×28×1	—	—	—
conv 1	k=3, $C_{out}=4$, p=0, s=1	26×26×4	40	24,336
conv 2	k=3, $C_{in}=4$, $C_{out}=8$, p=0, s=1	24×24×8	296	165,888
pool	2×2 max pooling (s=2)	12×12×8	0	(비교 연산 864회)
conv 3	k=3, $C_{in}=8$, $C_{out}=16$, p=0, s=1	10×10×16	1,168	115,200
합계		10×10×16	1,504	305,424

conv 2 FLOPs 직접: $n_{out} = 24$, $24^2 = 576$ 위치 $\times 8$ 필터 $\times 9 \times 4 = 36$ MAC = $576 \times 8 \times 36 = 165,888$. 실습 노트북 § 3에서 numpy로 그대로 재계산.

표를 읽는 법: “재고” vs “유량”, MLP 비교


- 1 **파라미터는 뒤로 갈수록 커지지만** ($40 \rightarrow 296 \rightarrow 1,168$) **FLOPs 최댓값은 conv 2** (165,888) — FLOPs는 n_{out}^2 에 비례하고 conv 2가 공간적으로 가장 크다 (24×24). conv 3은 채널 2배지만 공간 $1/4$ (10×10)라 오히려 적다
- 2 **풀링은 파라미터 0**, 비용도 곱셈-덧셈이 아니라 **비교** (4개 중 최댓값) — FLOPs 합계에서 무시할 만큼 작음

세 합성곱 층을 **같은 출력 체적** ($10 \times 10 \times 16 = 1,600$) 의 **완전연결층 하나** (784 입력 $\rightarrow$ 1,600 뉴런)로 대체하면: 파라미터 $784 \times 1,600 + 1,600 = 1,256,000$ (합성곱 스택의 **약 835배**), FLOPs 1,254,400 (**약 4.1배**).

“재고” vs “유량”

파라미터는 “재고” (층당 고정 저장), **FLOPs는 “유량”** (출력 위치마다 반복되는 계산) — “한 번에” 보는 대신 **작은 패치를 재사용**하는 합성곱이 **약 0.12%의 파라미터**, **1/4의 연산**으로 같은 체적의 특징을 만든다 — 게다가 **위치 불변성**이라는 귀납적 편향까지 덤. 한쪽만 보고 설계하면 안 된다.

좁아지고 깊어지는 CNN



- 위 그림의 네트워크: $32 \times 32 \times 3 \rightarrow \text{Conv } 5 \times 5 \text{ (6ch)} \rightarrow \text{Pool } 2 \times 2 \rightarrow \text{Conv } 5 \times 5 \text{ (16ch)}$
- 10.2절 전체를 관통하는 “**좁아지고 깊어진다**” 경향의 원형

합성곱을 거칠 때마다 공간 크기(가로×세로)는 줄고 채널 수(깊이)는 늘어나는 모습.

자주 하는 실수: 공식이 걸리는 두 곳

실수 1: “패딩은 출력에 더해지는 거다”

- $n=28, k=3, p=1, s=1$ 의 출력을 “ $28 + 2 = 30$ ” 이라고 — 패딩 픽셀이 출력을 만든다고 오해
- **패딩은 출력 위치를 새로 만들지 않는다** — “벗어나갈 것 같았던 위치”(필터가 원본 경계를 넘는 위치)를 **유효하게 만들어 주는 것뿐**
- 출력 = “패딩된 입력 안에서 필터가 완전히 들어가는 위치 수”
 $= \lfloor (28 + 2 - 3)/1 \rfloor + 1 = 28$
- 패딩의 정당한 용도는 “**same padding으로 크기를 유지**”, “출력을 키우는 것”이 아니다

연산량을 비교할 때는 “파라미터 몇 배”가 아니라 공식으로 직접 계산. (1×1 합성곱은 공간 크기 그대로 두고 채널만 선형 결합 — “경량으로 채널을 섞는다”는 용도로 VGG·ResNet 중간층에서 실전에 많이 쓰인다. 10.2에서 다시 만난다.)

실수 2: “FLOPs = 파라미터 $\times$ 고정 계수”

- FC에서는 샘플당 FLOPs $\approx 2 \times$ 파라미터라, 이 습관을 합성곱에도 적용하기 쉬움
- 그러나 **합성곱의 FLOPs/파라미터 비율은 n_{out}^2 이며 층마다 다름**
- 같은 224×224 , 64 출력 채널: $3 \times 3 = 640$ params, $\approx 2,839$ 만 MAC vs $1 \times 1 = 128$ params, ≈ 321 만 MAC
- 파라미터 비율 **5배**인데 FLOPs 비율은 **약 8.8배**

실습: 세 공식을 코드 한 페이지로

```
def out_size(n, k, p=0, s=1):  
    return (n + 2*p - k) // s + 1  
    # 1D 한방향의 출력 크기  
  
def conv_cost(n_in, k, c_in, c_out,  
              p=0, s=1):  
    n_out = out_size(n_in, k, p, s)  
    params = (k*k*c_in + 1) * c_out  
    flops = n_out**2 * c_out \  
            * (k*k*c_in)  
    return n_out, params, flops  
  
print(conv_cost(28, 3, 1, 4))      # (26, 40, 24336)  
print(conv_cost(26, 3, 4, 8))      # (24, 296, 165888)  
print(conv_cost(12, 3, 8, 16))     # (10, 1168, 115200)
```

- 합계 **1,504** — 손계산 표의 파라미터 합계와 정확히 일치
- “수식 → 코드 → 표”가 하나의 계산을 **세 번** 확인
- 세 공식(n_{out} , params, FLOPs)은 **독립이 아니라** 같은 $(n, k, p, s, C_{in}, C_{out})$ 에서 나란히 계산되는 **하나의 패키지**

핵심 공식 한눈에

항목	공식	무엇을 재나
출력 크기	$n_{\text{out}} = \lfloor (n + 2p - k)/s \rfloor + 1$	합성곱 후 공간 크기 (가로/세로 각각)
파라미터	$(k^2 C_{\text{in}} + 1) C_{\text{out}}$	저장해야 할 가중치 수 (bias 포함)
FLOPs	$n_{\text{out}}^2 C_{\text{out}} k^2 C_{\text{in}}$	곱셈-덧셈 횟수 (출력 위치마다 반복)
관계	$\text{FLOPs} \approx (\text{bias} \text{ 뺀 params}) \times n_{\text{out}}^2$	“재고”와 “유량”의 차이

세 공식은 하나의 패키지다 — “재사용”이 만드는 효율의 숫자.

FAQ 1·2: 필터 크기와 파라미터 수

Q. 필터 크기는 왜 보통 홀수(3×3 , 5×5)?

정확히 **중심 픽셀이 하나** 있어서 “어느 픽셀을 중심으로 보는가”가 자연스럽다. 짝수(2×2)는 중심이 픽셀 사이에 걸쳐서 대칭 해석이 어렵다. 실전에서는 **3×3 을 여러 겹** 쌓는 것이 더 널리 쓰인다 — 3×3 두 개는 5×5 하나와 **같은 수용장을 18 vs 25** 파라미터로 만든다.

Q. 파라미터가 적으면 항상 좋은 건가?

학습이 빠르고 과적합(Ch. 6) 위험은 줄지만 **표현력도 줄어든다** — Ch. 4.1의 편향-분산 트레이드오프가 그대로 적용. CNN이 이미지에서 유리한 이유는 “파라미터가 적어서”가 아니라, 그 적은 파라미터가 **위치 불변성**이라는 이미지의 실제 구조에 맞는 **귀납적 편향(inductive bias)**을 인코딩하고 있기 때문이다.

FAQ 3: 스트라이드 2 vs 2×2 풀링

둘 다 면적을 1/4로 줄이는데, 세 가지 차이:

- ① **정보 처리**: max pooling은 4개 중 3개를 **버리고** 최댓값 하나만 남김(미분 불가, 정보가 돌이킬 수 없이 사라짐). stride-2 합성곱은 각 창 안 $k^2 C_{in}$ 개를 **가중치로 합성**(미분 가능, “다운샘플링 직전에 뭘 살릴지”가 학습 대상)
- ② **자유도**: 풀링은 창 크기(2×2)와 축소율(1/2)이 함께 묶여, stride 합성곱은 필터 크기와 스트라이드를 **독립적**으로 고를 수 있다($5 \times 5, s=2$)
- ③ **역사**: LeNet·AlexNet·VGG 시절에는 max pooling이 표준 다운샘플러, **ResNet 이후** 고해상도 네트워크에서는 **stride-2 합성곱**이 주류 — 다운샘플링 자체를 네트워크가 학습

현대 네트워크는 둘을 섞어 쓰는 경우가 많다.

FAQ 4·5: FLOPs의 bias, PyTorch 확인

Q. FLOPs 공식에 bias의 “+1”이 없는데?

bias는 출력 위치당 **한 번만** 더해지는 값 — 그 비용 $n_{\text{out}}^2 C_{\text{out}}$ 은 주항 대비 **1 차수 낮은 차수 항**(일반 3×3 층에서 약 10% 미만). 표준 FLOPs 관례는 곱셈-덧셈(MAC) 수로 세고 bias를 무시.

Q. PyTorch에서 28×28 입력의 3×3 conv 출력이 정말 26×26 인가?

맞다 — `nn.Conv2d(1, 4, 3)`(기본 `padding=0, stride=1`)의 출력은 26×26 , `nn.Conv2d(1, 4, 3, padding=1)` 는 28×28 . PyTorch의 `padding` 인자는 이 절 공식의 **한 번당 패딩 수 p** 그대로(총 $2p$). $p = (k - 1)/2$ 의 `same-padding` 트릭도 똑같이 동작. (참고: 26×26 에 또 $p=0$ 의 3×3 을 쓰면 24×24 — 짝수/홀수가 층을 지나며 바뀌지만 “크기 장부” 문제일 뿐 오류가 아님.)

확인 문제 (10.1): 숫자 네 개

- ① **출력 크기.** 56×56 , $k=3$, $p=1$, $s=2 \rightarrow \lfloor (56 + 2 - 3)/2 \rfloor + 1 = \mathbf{28}$. (224→112 다운샘플링의 2배 크기 버전.)
- ② **파라미터·FLOPs.** 28×28 ($C_{in}=16$), 5×5 , $C_{out}=32$, $p=0$, $s=1$: (a) $n_{out} = 24$, (b) $(25 \times 16 + 1) \times 32 = \mathbf{12,832}$, (c) $24^2 \times 32 \times (25 \times 16) = \mathbf{7,372,800}$
- ③ **MLP 비교.** 앞 네트워크(1,504 / 305,424)와 같은 체적 FC(784→1,600) — FLOPs 비율은 “4배 안팎”인데 **파라미터 비율은 훨씬 큰 이유**를 한 문장으로
- ④ **실수 찾기.** “ 28×28 , $k=3$, $p=1$, **$s=2$** $\rightarrow (28 - 3 + 1)/2 + 2 = 15$ ” — 정답은 **14**. 패딩은 스트라이드로 나누기 전에 입력에 더해져야 한다: $\lfloor (28 + 2 - 3)/2 \rfloor + 1 = 14$

10.2 풀링과 전형적인 CNN 구조

최대 풀링: 이동에 둔감한 특징

합성곱 다음에는 보통 **풀링** 층으로 공간 크기를 줄인다. **최대 풀링(max pooling)**은 2×2 영역마다 **최댓값 하나만** 남긴다.

- 위치가 한두 칸 미세하게 움직여도 같은 최댓값이 뽑힐 가능성 높음 $\rightarrow$ 작은 이동에 **둔감한** (translation-invariant) 특징
- 풀링은 **학습 파라미터가 없음** — 순수한 **다운샘플링** 연산

4×4 특징지도를 1픽셀 오른쪽으로 살짝 옮기면 **다음 합성곱 층은 전혀 다른 16개의 숫자를** 보게 된다. 그런데 2×2 최대풀링을 적용하면 **두 경우 모두 같은 결과**:

$$\text{maxpool} = \begin{bmatrix} 1 & 3 \\ 1 & 4 \end{bmatrix} \quad (\text{원본과 1픽셀 이동, 동일})$$

“약간 세로선”은 살아남고, “정확히 어느 픽셀”은 버려진다

네 영역 각각(좌상·우상·좌하·우하)에서 원본의 최대값 (1, 3, 1, 4) 과 이동 후의 최대값 (1, 3, 1, 4) 이 같다.

핵심

“여기에 (대략) 세로선 같은 패턴이 있다”는 정보는 **살아남고**, “정확히 어느 픽셀에”는 정보는 **버려진다**.

- 최대풀링이 이동 불변성을 “완벽히” 주진 않는다 (2픽셀 이상 움직이면 풀링 셀 경계를 건너며 달라질 수 있음)
- 하지만 **한두 픽셀의 미세한 위치 변동**에 대해 특징지도를 “부드럽게” 만들어주는 효과는 확실

평균 풀링과 전역 평균 풀링

평균 풀링(average pooling) — 같은 영역의 **평균**을 남긴다.

- 최대풀링이 “이 지역의 **최대 반응**이 얼마나 컸는가”를 묻는다면, 평균풀링은 “**평균 반응**”
- 질감(texture) 같은 **분포 정보**를 더 잘 유지
그러나 실전에서는 **최대풀링이 압도적으로** 널리 쓰인다 — 소수 강한 반응이 “이 특징이 있다”는 **증거**이므로.

전역 평균 풀링(global average pooling, GAP) — 극단: 채널 전체($h \times w$ 모든 위치)의 **평균을 하나만** 남겨 공간 차원을 **아예 없앴**.

- “ 16×16 특징지도를 펼쳐 256개 숫자”가 아니라 “이 채널의 **평균 반응 1개**”
- 마지막 **완전연결층의 파라미터를 대폭 줄이는** 용도 (아래 VGG16에서)

풀링의 효과: 해상도 대 계산 비용

10.1절의 FLOPs 공식을 떠올리면 합성곱 연산량은 n_{out}^2 에 비례했다. 2×2 풀링은 한 번에 n 을 $n/2$ 로 줄이므로:

- **뒤이어서 오는 모든 합성곱 층의 연산량을 1/4로** 만든다
- 특징지도를 **2회** 풀링 $\rightarrow$ 공간 크기 1/4 (연산량 1/16), **3회** $\rightarrow$ 1/8 (1/64)

왜 대형 CNN은 224×224 를 7×7 로 줄이는가

“이미지 전체의 맥락”을 판단하려면 공간 해상도가 그 정도면 충분하고, **남은 용량을 특징의 수(채널) 쪽에 쓰겠다**는 설계 선택이다.

실습: 4×4 특징지도를 최대풀링으로

10.1절의 conv2d 코드와 같은 스타일로 최대풀링 직접 구현:

```
def max_pool(feature_map, pool_size=2):
    h, w = len(feature_map), \
           len(feature_map[0])
    out_h, out_w = h // pool_size, \
                   w // pool_size
    output = [[0.0] * out_w for _
               in range(out_h)]
    for i in range(out_h):
        for j in range(out_w):
            block = [
                feature_map[
                    i*pool_size+di
                    [j*pool_size+dj]
                    for di in range(pool_size)
                    for dj in range(pool_size)]
            output[i][j] = max(block)
    return output
```

```
fm = [[1, 0, 2, 1],
       [1, 0, 3, 1],
       [1, 0, 4, 1],
       [1, 0, 2, 1]]
```

- “원본” 특징지도를 그대로 넣으면
 $\begin{bmatrix} 1 & 3 \\ 1 & 4 \end{bmatrix}$ — 앞 계산과 **정확히 일치**
- 1픽셀 이동 버전도 **같은 결과** —
둔감함이 코드로

자주 하는 실수: 풀링을 “특징 추출”로 오해

정리

풀링은 학습 파라미터가 없는 순수 다운샘플링 연산이다. “특징을 추출한다”는 표현은 합성곱 층의 역할, 풀링의 역할은 이미 학습된 특징지도를 (a) 공간 해상도를 줄이고, (b) 미세한 위치 변동에 둔감하게 만드는 것.

이 구분을 섞으면 두 가지 흔한 설계 실수:

- **풀링을 너무 일찍, 너무 많이:** 첫 합성곱 직후 2×2 풀링을 하면 아직 “선분”을 감지하는 단계인데 해상도를 $1/4$ 로 줄여 **세부 정보를 잃음**. 실무에서는 **첫 두~세 합성곱 층은 풀링 없이**(스트라이드 1) 쌓고, 채널이 충분히 늘어난 뒤 풀링
- **풀링을 “합성곱의 대안”으로:** 풀링은 합성곱 이후에 쓰는 연산이지, 대신이 아니다. “ 3×3 합성곱이 비싸니까 2×2 풀링으로 대체”는 학습하는 가중치를 **아예 없애버리는 것** (스트라이드 2 합성곱은 학습 가능한 다운샘플링이라 혼용되기도 하지만, 근본적 차이가 “학습 여부”)

수용장: 뒤쪽 층이 “보게 되는” 원본 영역

풀링의 공간 축소를 다른 관점에서 보면 **수용장(receptive field)**의 **확대**. 합성곱 한 층은 입력의 $k \times k$ 영역만 직접 보지만, 출력을 **또** 합성곱·풀링하면 두 번째 층의 뉴런 하나가 “보게 되는” 원본 영역은 더 넓어진다.

각 층의 필터 크기 k_l , 스트라이드 s_l 일 때, l 번째 층 뉴런의 수용장 크기:

$$R_l = R_{l-1} + (k_l - 1) \cdot \prod_{j < l} s_j, \quad R_0 = 1$$

- 한 층의 뉴런은 직전 층의 뉴런 k_l 개를 “보는데”, 각 뉴런이 이미 원본의 R_{l-1} 픽셀을 대표
- 인접 k_l 개의 수용장을 합치면 겹치는 $(k_l - 1)$ 픽셀만 **새로** 보이고, 이 확장량이 이전 스트라이드 곱만큼 **스케일업**

수용장 손계산 + 풀링이 스케일업하는 기제

입력 32×32 예:

층	연산	k	s	R_l
0	입력	—	—	1
1	Conv	5	1	$1+4 \cdot 1 = 5$
2	MaxPool	2	2	$5+1 \cdot 1 = 6$
3	Conv	5	1	$6+4 \cdot 2 = 14$


단 세 층 만에, 마지막 합성곱 뉴런은 원본의 14×14 영역(32×32 의 약 19%)을 “본다”.

- $3 \times 3, s=1$ 만 계속 쌓으면 $R_l = 1 + 2l$ 으로 선형
- 풀링($s=2$)을 한 번만 끼워도 그 뒤의 모든 확장이 2배 스케일업
- 10층만 쌓아도 수십 픽셀, 풀링을 섞으면 이미지 전체가 한 뉴런의 수용장

짜을 이룬다

합성곱(패턴 감지)이 “무엇을 보는가”를 학습하고,
풀링(수용장 확대·해상도 축소)이 “얼마나 넓은 시야로 보게 하는가”를 결정.

16개 층을 쌓아도: 풀링이 시야를 2배로



16개 층을 쌓아도 풀링 없이 스트라이드 1 합성곱만 쌓으면 수용장이 33px(입력 32px과 비슷)에 그치는 반면, [Conv3, Conv3, Pool2] 블록 4개를 쌓으면 **76px** — 이미지의 2배. 스트라이드 2 풀링 한 번이 그 뒤의 모든 확장을 2배 스케일업.

- Ch. 4.2 MLP에서 “은닉층을 쌓을수록 결정경계가 더 복잡한 형태”라는 관측과 **같은 원리**
- **얇은 층**은 지역적 패턴(선, 모서리)을, **깊은 층**은 그 지역적 패턴을 **넓은 시야에서 조합한** 고수준 특징(눈, 바퀴)을 감지

CNN의 전형적인 구조

$\underbrace{[\text{합성곱} \rightarrow \text{ReLU} \rightarrow \text{풀링}]}_{\text{반복}} \quad \dots \quad \rightarrow \quad \text{완전연결층 1~2개} \rightarrow \text{분류}$

- 공간 크기는 **줄이고**, 채널(특징) 수는 **늘려** 가다가 마지막에 완전연결층을 붙여 분류
- **LeNet**(1998, LeCun 등)이 **손글씨 숫자 인식**에 처음 이 패턴을 성공적으로 적용한 이래 계층 구조 그대로 유지
- 얇은 층 = 선/모서리(저수준), 깊은 층 = 눈/코/바퀴 (고수준) — 허블·비셀의 **단순 세포** → **복합 세포** 계층 구조와 같은 원리

LeNet-5 (1998)를 10.1 공식으로 풀기

층	연산	출력 크기	채널	파라미터
—	입력	32×32	1	—
C1	5×5 Conv + sigmoid	28×28	6	$(25 \cdot 1 + 1) \cdot 6 = 156$
S2	2×2 MaxPool	14×14	6	0
C3	5×5 Conv + sigmoid	10×10	16	$(25 \cdot 6 + 1) \cdot 16 = 2,416$
S4	2×2 MaxPool	5×5	16	0
C5	5×5 Conv + sigmoid	1×1	120	$(25 \cdot 16 + 1) \cdot 120 = 48,120$
F6	완전연결 (tanh)	—	84	$(1 \cdot 120) \cdot 84 + 84 = 10,164$
OUT	완전연결 (softmax)	—	10	$84 \cdot 10 + 10 = 850$
합계				$\approx 6.2\text{만}$

각 행은 10.1의 합성곱 공식 $(k^2 C_{\text{in}} + 1) C_{\text{out}}$ 과 완전연결 공식 $C_{\text{in}} C_{\text{out}} + C_{\text{out}}$ 을 그대로 대입(합성곱은 bias 포함, 풀링은 0).

LeNet-5에서 중요한 관찰: “펼쳐서 FC에 넣기”

- 구조의 “형”보다 **완전연결층이 입력을 어떻게 받아들이는가가 중요** — F6은 C5의 특징지도 ($1 \times 1 \times 120$, 즉 120개 숫자)를 **펼쳐서** 입력으로 씀
- LeNet-5는 C5에서 공간 크기를 이미 1×1 로 줄여냈기 때문에 F6 입력이 120으로 **작지만** —
- **풀링을 덜 하고 채널을 크게 늘린 네트워크**에서는 이 “펼쳐진 벡터”가 **수만~수십만 길이가** 되어 **완전연결층이 파라미터의 대부분을 차지**

이 “펼쳐서 FC에 넣기”가 비효율이라는 인식이 10.3절 **전이학습**(“앞쪽 합성곱은 그대로 쓰고 마지막 FC 헤드만 재학습”)과 **전역 평균 풀링**의 동기가 된다.

공간 $32 \times 32 \rightarrow 1 \times 1$, 채널 $1 \rightarrow 120$ — “좁아지고 깊어진다” 경향의 **원형**.

AlexNet (2012)과 VGGNet (2014)

- 1990년대 후반~2012년 ImageNet 경쟁까지 “좁아지고 깊어진다” 패턴 거의 그대로
- **AlexNet**(Krizhevsky, Sutskever, Hinton, 2012): ImageNet 우승으로 CNN 시대 개막 — 원형은 LeNet과 같은 [Conv → ReLU → Pool] 반복, 다만 **채널**(64, 128, 256, 512)과 **깊이**를 크게 늘림

VGGNet(Simonyan & Zisserman, 2014)의 강력한 관찰

5×5 필터 하나를 3×3 필터 두 개로 대체하면, 같은 수용장(5×5)을 더 적은 파라미터로, 더 비선형으로(ReLU가 두 번 들어감) 만들 수 있다. 3×3만 쌓은 16층(VGG16)으로 같은 대회 2위(1위는 GoogLeNet, 2014) — “깊이 자체가 곧 힘”을 널리 퍼뜨림.

그런데 여기서 문제가 생겼다.

깊이 열화: 더 깊게 쌓으면 나빠진다

2015년, Kaiming He 등(마이크로소프트)이 이상한 현상을 발견: CNN을 더 깊게 쌓을수록 성능이 좋아질 줄 알았는데, 어느 지점을 넘으면 오히려 나빠졌다.


- **과적합이 아니다** — 학습 데이터에 대한 성능조차 나빠졌다 (training·validation이 같이 떨어짐)
- 층을 더해도 **그래디언트가 온전히 전달되지 못해** 깊은 층이 사실상 “학습이 안 되는” 문제 — Ch. 9의 그래디언트 소실이 CNN에서 **재발**

이 현상을 **깊이 열화(degradation)** 라고 부른다: “20층 네트워크는 뒤 10층을 **항등 함수**로 초기화하면 앞 10층 네트워크와 **정확히 동일**”하므로, 이론상 최소한 10층과 같은 성능을 내야 하는데 실제로는 나빠진다. ⇒ 원인은 과적합이 아니라 **최소값 찾기 최적화 문제**.


깊이 열화 재현: 스킵이 100%와 50%를 가른다

Depth degradation: same architecture and data, only skip connections differed

Loss: without skips, stuck at ln 2



Accuracy: skip connections take 50% -> 100%



24개 합성곱 층(3×3 Conv-Conv 블록 12개)을 세로줄/가로줄 데이터로 25 에폭 학습. 왼쪽: cross-entropy loss — 스킵 없이는 ln 2 근처에서 거의 움직임 없음. 오른쪽: train 정확도 — 스킵이 있는 버전만 100%에 도달. 구조·데이터·초기화 시드 모두 같고 **스킵 연결만** 달랐다.

- **평범 24층(스킵 없음):** loss ≈ 0.693 (ln 2, 동전 던지기), train_acc **0.500**으로 고정
- **잔차 24층(스킵 있음):** 15 에폭에 loss 0.355, **25 에폭 내 100% 도달**
- 매우 단순한 분류라 “학습 못 한다”가 **극단적으로** 드러난 예 — ImageNet에서는 점진적으로, 메커니즘은 같음

스킵 연결: $y = F(x) + x$

스킵 연결(skip / residual connection)은
그래디언트 곱셈 사슬에 **지름길**을 낸다 — 한
블록의 출력을 $F(x)$ 로 두는 대신, **입력을 그대로**
더한 $y = F(x) + x$ 로 정의:

```
def residual_block(x, F):  
    # F: 합성곱층몇개로 이루어진  
    # 함수에 (: Conv-ReLU-Conv)  
    return [F(x)[i] + x[i]  
            for i in range(len(x))]  
    # F(x) + x
```

왜 그래디언트를 살리는가(직관):
 $y = F(x) + x$ 를 x 로 미분하면

$$\frac{\partial y}{\partial x} = \frac{\partial F}{\partial x} + 1$$

- Ch. 9의 $\prod_l \sigma'(z_l) \cdot W_l$ 곱셈 사슬에서
 $\partial F / \partial x$ 가 아무리 작아져도(소실), “+1”
항 덕분에 그래디언트가 **최소 1은 유지된**
채 전달될 길 남음
- 입력을 “건너뛰어” 뒤쪽 층으로 **그대로**
흘려보내는 지름길

이 아이디어 덕분에 **100층이 넘는 CNN도 안정적으로** 학습할 수 있게 됐고, Ch. 12의
Transformer에도 (다른 형태로) 그대로 쓰인다.

“최소한 1”이 정말 성립하는가 — 수식과 수치

L 개의 잔차 블록을 쌓았을 때, 마지막 출력 x_L 에 대한 첫 입력 x_0 의 그래디언트는 연쇄법칙으로:

$$\frac{\partial x_L}{\partial x_0} = \prod_{l=1}^L \left(\frac{\partial F_l}{\partial x_{l-1}} + 1 \right)$$

이 곱을 전개하면(각 인자에서 “1”을 고르거나 “ $\partial F_l / \partial x_{l-1}$ ”을 고르는 모든 조합의 합) 정확히 한 항이 “모든 인자에서 1만 고른” = 1:

$$\frac{\partial x_L}{\partial x_0} = 1 + (\text{나머지 항들의 합})$$

스킵이 없으면 0에 수렴했을 경로에 항상 “1”이라는 바닥이 깔려 있다. 수치로도 확인: 무작위 초기화(표준편차 0.1)의 20층 FC에서 출력에 대한 입력의 그래디언트 노름:

- 스킵 없는 20층: $|dz/dx| \approx 2.5 \times 10^{-14}$ (사실상 0 — 그래디언트 소실)
- 스킵 있는 20층: $|dz/dx| \approx 8.2$ (신호 유지)

같은 가중치·구조, 스킵 연결만으로 약 330조 배 ($8.2 / 2.5 \times 10^{-14} \approx 3 \times 10^{14}$) 차이.

$F(x) + x$ 의 차원 매칭 + 항등 블록의 시작점

실무: 차원 매칭

더하려면 $F(x)$ 와 x 의 차원(채널 $\times$ 공간)이 **정확히 일치**해야 한다. “채널은 늘고 공간은 줄어든다” 패턴을 따르면 F 가 $64 \rightarrow 128$ 채널, $28 \times 28 \rightarrow 14 \times 14$ 변환할 때 x 는 그대로 — **1×1 합성곱**(공간 유지, 채널만 바꿈)으로 x 의 차원을 맞춰준 뒤 더한다 (필요하면 2×2 스트라이드 1×1 합성곱으로 공간도 동시 축소).

“항등 블록”이 왜 좋은 시작점인가

F 를 정규화된(0 근처) 작은 값으로 초기화하면 학습 시작 시점에 $F(x) \approx 0$ 이라 $y \approx x$ — **항등 함수로 시작**. “깊은 네트워크가 최적의 시작점을 얇은 네트워크의 항등 함수로 가질 수 있다” $\Rightarrow$ 학습이 “0에서 $F(x)$ 를 만들어야 한다”가 아니라 “이미 잘 동작하는 항등 함수 위에서 **잔차만** 미세 조정”. ResNet이 “깊은 망이 왜 어려운가”를 **표현력** 문제가 아니라 **최적화(초기화)** 문제로 재정의한 것.

배치 정규화: 스킵 연결의 “공범”

ResNet 논문은 스킵 연결과 함께 **배치 정규화(batch normalization)**(Ioffe & Szegedy, 2015)를 결합해 깊은 CNN의 학습 안정성을 크게 높였다. 합성곱 층 **사이에** 넣는 층으로, 각 **미니배치의 활성값 분포**를 평균 0·분산 1로 표준화한 뒤, 학습 가능한 γ (스케일)· β (오프셋)로 다시 곱해/더해 “표준화가 너무 강하지 않게” 조절:

$$\hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad y = \gamma \hat{x} + \beta$$

- μ_B, σ_B^2 = 해당 **미니배치 전체** 활성값의 평균·분산, $\epsilon = 0$ 나눗셈 방지 (예: 10^{-5})
- Ch. 9.2의 **초기화 문제**를 **층마다** 해결: 100층을 쌓아도 활성값 분산이 층마다 달라지는 (폭발/소실) 것을 **학습 중에도 0·1로 되돌려, 초기화 값에 덜 민감하게** 깊게 쌓을 수 있게

“깊게 쌓기”에 필요한 두 조건 — 그래디언트가 살아서 전달되고(스킵), 활성값이 적정 스케일로 유지되고(BN) — 를 **각각 독립적으로** 해결. (10.3에서 BN 통계 처리가 전이학습의 실전 함정이 되는 것 — μ_B, σ_B 가 **학습 시** 미니배치 기준이라 추론 시에는 **러닝된** 통계로 대체해야 함.)

실습: PyTorch SmallCNN + 파라미터 장부

세로줄 vs 가로줄(16×16 , 잡음 섞임)을 구분하는 아주 작은 CNN:

```
import torch, torch.nn as nn

class SmallCNN(nn.Module):
    def __init__(self):
        super().__init__()
        self.conv1 = nn.Conv2d(1, 8, 3,
                                padding=1)
        self.conv2 = nn.Conv2d(8, 16, 3,
                                padding=1)
        self.pool = nn.MaxPool2d(2)
        self.fc = nn.Linear(16*4*4, 2)
    def forward(self, x):
        x = self.pool(
            torch.relu(self.conv1(x)))
        x = self.pool(
            torch.relu(self.conv2(x)))
        x = x.view(x.size(0), -1)
        return self.fc(x)
```

층	연산	출력	II
—	입력 16×16	$16 \times 16 \times 1$	
Conv1	3×3 + ReLU (same)	$16 \times 16 \times 8$	
Pool1	2×2 MaxPool	$8 \times 8 \times 8$	
Conv2	3×3 + ReLU (same)	$8 \times 8 \times 16$	
Pool2	2×2 MaxPool	$4 \times 4 \times 16$	
FC	완전연결	2	

합계

Adam(lr=0.01) + CrossEntropyLoss. 초기
52%(동전 던지기) → 30 에폭 후 train/val **100%**.

10.3절에서 재사용할 **같은 모델**. 실습 노트북에서는 스킵 연결 있는/없는 두 버전으로 “깊이 열화” 실험을 직접 재현.

FAQ (10.2)

- 왜 풀링 다음에도 계속 합성곱을 쌓나? 풀링 하나는 공간 크기만 절반으로 줄일 뿐, **패턴의 복잡도는 높이지 못함**. [합성곱 → 풀링] 을 반복해야 뒤쪽 뉴런 하나가 점점 **넓은 수용장**을 보며, 그 위에서 더 복잡한 패턴(눈, 바퀴)을 조합.
- ResNet의 “+1”이 그래디언트 폭발을 일으키나? 아니 — 스킵이 매 블록마다 **곱이 아니라 덧셈**으로 기여하므로, Ch. 9.2의 “곱이 지수적으로 커지는” 폭발 메커니즘과 **다름**. 그래디언트가 **여러 경로의 합**으로 전달돼 오히려 신호를 더 **고르게 유지**.
- 최대풀링의 “최댓값 위치” 정보는? 최댓값 **그 자체만** 남기고 **어느 픽셀**이었던 정보는 **버림** — 이게 “미세 이동에 둔감”한 원리. **정확한 위치**가 필요한 문제(탐지)에서는 풀링을 거의 쓰지 않고 **스트라이드 2 합성곱**으로 다운샘플링, 또는 마지막에서 공간 **복원**(10.3 분할). “위치 보존”과 “이동 불변성”은 **트레이드오프**.
- 평균풀링을 쓰는 경우? 전역 평균풀링은 VGG16·현대 CNN의 마지막 분류층 **앞에서** FC 파라미터를 크게 줄이는 용도로. **지역** 평균풀링(2×2 평균)도 “질감 분포” 요약에 쓰이지만 최대풀링보다 널리 쓰이지 않음.
- “깊이 열화”가 과적합이 아닌 근거? ResNet 논문의 결정적 실험: 더 **깊은** 망의 **training** 정확도가 더 **얕은** 망의 training 정확도보다 **나쁨** — 과적합은 training이 오르고 validation만 떨어짐. “모델이 표현할 수 없어서”가 아니라 **최적화가 깊게 내려가지 못해서**.

확인 문제 (10.2)

- ① **수용장 손 계산.** $k=3, s=1$ 합성곱 3개 $\rightarrow 2 \times 2$ maxpool($s=2$) $\rightarrow k=3, s=1$ 합성곱 2개. 마지막 합성곱 뉴런의 수용장: $1 \rightarrow 3 \rightarrow 5 \rightarrow 8 \rightarrow 14 \rightarrow \mathbf{20}$. (풀링 한 번이 모든 **이후** 확장을 2배 스케일업.)
- ② **잔차 그래디언트 항.** $L = 3$ 블록에서 $(A_1 + 1)(A_2 + 1)(A_3 + 1)$ 을 분배법칙으로 완전히 전개하고, 모든 인자에서 “1”을 고른 항(= 정확히 1)을 지목. 이 항이 스킵 없는 $\prod_l A_l$ 에 존재하지 않는 “바닥”임을 한 문장으로.
- ③ **구조 비교.** LeNet-5(≈ 6.2 만, FC 11,014)와 SmallCNN(1,762)의 파라미터 분포(합성곱 vs FC 비율)를 비교하고, 10.3의 전이학습이 “앞쪽 합성곱은 고정, 마지막 분류층만 재학습”하는 설계가 왜 자연스러운지 LeNet-5 구조(C5가 공간 1×1 · 채널 120)를 들어 한 문단으로.

10.3 분류를 넘어서: 탐지, 분할, 전이학습

분류를 넘어서: 두 가지 새 문제

지금까지의 CNN은 “이미지 **전체**가 어떤 클래스인가”(분류)만 답했다. 실전 문제는 더 세밀한 답을 요구한다:

객체 탐지(Object Detection)

- “이미지 안에 사물이 **어디에**, 무엇이 있는가”
- 각 사물의 **위치**를 사각형 (bounding box, 4개 좌표)으로, 그 안의 **클래스**를 함께 예측


의미론적 분할(Semantic Segmentation)

- “**각 픽셀**이 어떤 클래스에 속하는가”
- 입력과 **동일한 크기**의 출력을 내며 각 픽셀에 클래스 라벨을 붙임
- 자율주행: “이 픽셀은 도로/보행자/차량”

탐지는 “위치까지 붙은 분류”다 — 분류는 벡터 1개를 내지만, 탐지는 사물 마다 (클래스, x, y, w, h)를 내야 하고 사물의 개수조차 모름. 어려운 부분은 “무엇을 보는가”(10.2가 이미 잘한다)가 아니라 “여러 개, 각기 다른 위치”를 **한 번의 전진전파**로 다루는가.

R-CNN (2014): “후보 → 특징 → 판정” 3단계

R-CNN 파이프라인 (2014) — 분류 CNN 위에 후보 생성 + SVM 헤드 + NMS를 붙인 것



R-CNN 파이프라인 — (1) 선택티브 서치로 ~2,000개 후보 박스,
(2) 각 후보를 224×224 로 줄여 CNN을 통과시켜 4,096차원 특징,
(3) 클래스별 SVM + 박스 회귀로 판정, (4) IoU 기반 NMS로 중복
박스 제거.

① **후보 지역: 선택티브 서치** (2012, 딥러닝이 아닌 기술)가 색·질감이 비슷한 인접 영역을 합치며 후보 박스 ~2,000개. 슬라이딩 윈도우(수백만 개) 대비 “미리 좁히기”가 통하는 이유: 사물은 실제로 그렇게 많지 않고 작지도 않은 경우가 대부분

② **특징 추출**: 2,000개 후보를 각각 224×224 로 비율만 맞춰 리사이즈하고, **분류용 CNN의 마지막 분류층을 제외한 부분을 그대로 통과** — 각 후보마다 4,096차원 특징 벡터 1개. “**분류로 배운 특징 추출기**”를 새 문제에 재사용하는 순간

③ **판정**: (a) **클래스별 SVM 하나씩** (Ch. 5의 SVM — 20개 클래스면 SVM 20개)로 “무엇이”, (b) **회귀 모델**로 “정확한 사물 경계기 미세 조정” 2,000 후보 × SVM

왜 3단계인가 + 대가: 속도, 그리고 후속 3세대

- “여기에 사물이 있을 법한가”(후보) / “여기에 무슨 패턴이 있는가”(CNN 특징) / “도대체 뭘까, 어디까지인가” (SVM+회귀) — **각 단계에 가장 잘 맞는 도구를 쓰는 분업**
- 대가는 **속도**: PASCAL VOC 2012 테스트(20,000장) 1 GPU 약 **463초** vs 슬라이딩 윈도우 약 **605초**(논문 수치, 약 1.3배)로 “**느리지만 정확했다**” — 2014년 ImageNet·PASCAL 탐지를 제패 (전 SOTA 대비 15%대 mAP 향상)

이후 연구 = “정확도를 유지한 채 **어떻게 빠르게 할 것인가**”:

모델	연도	속도화 전략
Fast R-CNN	2015	이미지 하나 를 한 번 통과시켜 특징맵을 만들고, 후보마다 해당 영역의 특징만 풀링으로 공유 재사용 — 2,000회 전진전파가 1회로 줄어 10배 이상 빠짐
Faster R-CNN	2015	후보 추출(셀렉티브 서치) 자체도 학습 가능한 합성곱 층(RPN , Region Proposal Network)으로 — “2012년 딥러닝 이전 기술”이 마지막 남은 고리
YOLO	2016	후보도 단계도 없애고, 특징맵의 격자 위치마다 (클래스, 박스 좌표)를 한 번의 전진전파로 직접 회귀 — 탐지를 “ 회귀 문제로 ” 재정의, 실시간 탐지의 표준

IoU: 박스의 겹침을 재는 법

탐지 모델은 같은 사물에 **겹치는 박스 여러 개**를 낸다. 그래서 학습이 **아닌** 고정 후처리 **NMS(Non-Maximum Suppression, 비최대 억제)**가 붙고, 여기서 “겹기”는 **IoU(Intersection over Union)**로 잰다:

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{\text{겹치는 면적}}{\text{합쳐진(겹침 한 번만) 면적}}$$

- $[0, 1]$ 에 있고 **1이면 완전 일치**
- Ch. 3의 **재카드 지수**(Jaccard index)가 **면적 버전**으로 “박스 두 개의 비슷함”을 재는 것

손으로: $A = [0, 0, 10, 10]$, $B = [1, 1, 11, 11]$ — 교집합 $[1, 1, 10, 10] \rightarrow$ 면적 $9 \times 9 = 81$, 합집합 $100 + 100 - 81 = 119$.

$$\text{IoU} = 81/119 \approx \mathbf{0.68}$$

왜 IoU인가 — “교집합/작은 박스”나 “박스 중심거리”가 안 되는 이유는 **스케일 불변성**: 중심거리는 박스가 크면 같은 겹기라도 “멀어” 보이고, 교집합/합집합 비율은 박스를 함께 키우면(스케일) **변하지 않음**. 탐지 **훈련 라벨링**에서도 쓰인다 — 예측 박스가 정답과 $\text{IoU} \geq 0.5$ 면 “탐지 성공”
정밀도 평가 규칙이 PASCAL VOC·COCO **표준**. 같은 함수가 학습·평가 양쪽에 들어가는 셈.

NMS를 한 번 따라가보자

1. 모든 (박스, 점수)를 점수 내림차순 정렬 2. 가장 점수 높은 박스를 보관하고, 그것과 겹기가 임계값(보통 0.5)을 넘는 모든 박스를 제거 3. 남은 박스에서 2를 반복


박스	좌표 $[x_0, y_0, x_1, y_1]$	점수
A	$[0, 0, 10, 10]$	0.90
B	$[1, 1, 11, 11]$	0.80
C	$[20, 0, 30, 10]$	0.75
D	$[21, 1, 31, 11]$	0.60

- A(0.90) 먼저 보관
- B와 IoU **0.68** > **0.5** → 제거
- 남은 C(0.75) 보관, D와 IoU 0.68 → 제거
- 결과: A와 C만 남음 — 4개 박스에서 사물 2개. A,B 쌍과 C,D 쌍의 IoU가 같은 값 **0.68**을 두 번 씌으로써 “제거 기준은 점수가 아닌 겹기”임을 보임

NMS (threshold 0.5): 4 candidate boxes → 2 objects (only A and C remain)

A-B pair: IoU ≈ 0.68

C-D pair: IoU ≈ 0.68



4개 박스 중 NMS(임계값 0.5)가 A와 C를 남기고 B, D를 제거

A와 B의 겹기(거짓)인 0.68을 차지해 B가 억제되는

분할: “격자 위치마다 붙은 분류기”

10.2의 분류 네트워크를 끝까지 펼쳐보자 — VGG 계열처럼 224×224 입력이 2×2 최대풀링을 **5번** 거치면 공간 크기는 $224/2^5 = 7$ 로 줄고, 마지막 합성곱 층의 출력은 7×7 **격자**(채널 512개). **분류 헤드**란 그 격자를 **펼쳐서** 1,000개 클래스 점수 하나로 모으는 층일 뿐이다.

의미론적 분할 헤드

1개의 헤드 대신, **49개의 격자 위치마다 “클래스 1,000개” 출력을 공유 가중치로 붙인다** — 마지막 층을 “ $512 \rightarrow 1,000$ 선형층”이 아니라 **출력 채널 1,000개의 1×1 합성곱**으로 바꾸면, 격자 **각 위치**에서 512개 특징을 1,000개 클래스 점수로 변환하고 그 가중치는 49개 위치가 **공유**(1×1 합성곱이 “위치당 분류기” — 10.1 FAQ의 “채널만 선형 결합”). 파라미터는 $512 \times 1,000 + 1,000$ **하나분**만 추가되지만, 답의 형태가 “벡터 1개”에서 **7×7 클래스 지도**로 바뀐다.

“각 픽셀”이 아니라 7×7 격자점인 이유: 풀링이 공간 정보를 반으로 줄인 5번의 결과 — 실제 분할 모델은 풀링을 줄이고 U-Net처럼 해상도를 **되살리는** 구조를 쓴다.

왜 공유가 올바른 편향인가 + U-Net

- “이 픽셀이 도로인가”의 정답은 이미지 좌상단이었던 우하단이었던 **같은 법칙**으로 결정됨 — 10.1에서 “고양이가 어디에 있든 같은 고양이”라 **합성곱**이 위치마다 가중치를 공유한다면, 분할에서는 “도로인지 아닌지의 판단법이 어디에서든 같다”라 **헤드**가 위치를 공유하는 것 — 합성곱의 **재사용 원리**가 **파이프라인의 다른 위치**에서 다시 등장

해상도 복원: U-Net(Ronneberger 등, 2015) — “ 7×7 격자 예측을 224×224 원본으로 되돌린다”는 것은 공간 크기를 5번 **더블업**(업샘플링)하는 문제, **풀링의 역방향**. “줄여가는” **코더**(encoder) 끝에 업샘플링으로 “늘려가는” **디코더**(decoder)를 **대칭**으로 붙여 **U자** 형태.

- 디코더만으로는 **어디가** 도로인지(정확한 경계)를 되찾기 어려움 — 위치 정보는 풀링에 이미 **버려짐**
- 해결책은 10.2의 **스킵 연결** — 코더의 **초기 층**(위치 정보가 아직 살아 있는 층)의 특징맵을 디코더의 **해당 레벨**에 **그대로 건너뛰어 더함**

ResNet이 스킵 연결로 **깊이**를 쌓을 수 있게 했다면, U-Net은 스킵 연결로 **해상도**를 되찾은 셈. U-Net이 **의료 영상 분할**(병리 슬라이드, 초음파)의 표준인 이유: “**몇십 장의 라벨만으로도** 쓸만하게 학습된다” — 전이학습·소데이터 이야기와 정확히 겹치는 지점.

전이학습: 처음부터 다시 배우지 않는다

대규모 데이터(ImageNet, 수백만 장)로 **미리 학습된 CNN의 앞쪽 층**들은 선/모서리/질감 같은 **아주 범용적인** 패턴을 감지하도록 학습돼 있다 — “고양이를 구분하는 능력”이 아니라 “**이미지를 보는 능력**” 자체에 가깝다. **전이학습(Transfer Learning)**은 이 사전학습된 앞쪽 층을 **그대로 재사용**하고, 마지막 몇 층만 새 문제에 맞게 다시 학습시킨다:

특징 추출(feature extraction)

- 사전학습된 층의 가중치를 **전부 고정 (freeze)**, **마지막 분류층만** 새로 학습
- **데이터가 적을 때** 특히 유리 — 새로 학습할 파라미터가 훨씬 적기 때문

미세조정(fine-tuning)

- 사전학습된 가중치를 **학습의 시작점으로만** 쓰고, 전체(또는 뒤쪽 일부) 층을 **낮은 학습률로** 계속 학습
- **새 데이터가 어느 정도 있을 때** 특징 추출보다 더 좋은 성능

“앞쪽 층은 범용하다”는 말의 첫 증거

- 추측이 아니라 **보여준 것** — AlexNet 논문 (Krizhevsky 등, 2012)이 학습된 **첫 합성곱 층의 필터를 그림으로 인쇄**했고, 거기서는 방향/색 대비를 감지하는 **Gabor 같은 필터**들이 늘어섬
- 장 머리에서 허블·비셀이 고양이 시각피질에서 본 **단순 세포의 수용장과 동일한 종류**의 패턴
- ImageNet 1,000개 클래스를 구분하기 위해 학습된 네트워크의 첫 층이 “고양이 특화”가 아니라 “**모서리 감지**”에 쓰였다는 뜻

전이학습이 이용하는 비대칭

층이 깊어질수록 특징이 눈·바퀴·사물 부분으로 “사물화”되는 계층 구조(10.2) 때문에, **앞으로 갈수록 재사용 가치가 높다** — **앞쪽 = 범용, 뒤쪽 = 특화**.

같은 작업에서 세 팔(arm) 비교

10.2의 SmallCNN(세로줄/가로줄 분류) 위에서 — 동일 아키텍처·동일 데이터(300 학습/200 검증)·동일 30 에폭, **다만 어느 층이 갱신되는가만 바꿈**:

팔	갱신되는 층	갱신 파라미터 (전체 1,762 중)
A. 스크래치(scratch)	전체	1,762
B. 특징 추출(frozen)	마지막 분류층(fc)만	514
C. 미세조정(fine-tuning)	전체 (낮은 학습률 0.001)	1,762

- 이 장난감 작업은 데이터가 충분하고 패턴이 단순해서 **세 팔 모두 검증 100%**에 도달
- 포인트는 어느 쪽이 더 좋은가가 아니라, B가 전체 파라미터의 **29%(514/1,762)**만 건드리고도 **같은 결과**를 냈다는 점
- 실제 문제에서 **데이터가 적으면 차이는 극적으로** 벌어진다 — A는 300장에 1,762개를 배우려다 **과적합**(Ch. 6)으로 검증 정확도가 처지고, B는 “새로 배울 것도 514개뿐”이라 같은 300장으로 충분히 배운다
- SmallCNN의 **합성곱 층이 1,248개(71%)**라는 장부가 전이학습의 “혜택 크기”를 직접 재주는 셈

세 팔의 코드: 동결은 requires_grad로

```
model = SmallCNN()
for p in model.conv1.parameters():
    p.requires_grad = False
for p in model.conv2.parameters():
    p.requires_grad = False

# requires_grad=True인 파라미터만
# 옵티마이저에 전달 -- fc 층만 학습됨
opt = torch.optim.Adam(
    filter(lambda p: p.requires_grad,
           model.parameters()), lr=0.01)
```

- 전체 1,762개 중 실제로 학습되는 파라미터는 **514개**뿐
- **30 에폭 후 검증 정확도 90%** 도달
- 학습 전후로 conv1 가중치를 직접 비교하면 **완전히 동일** —
requires_grad=False 로 고정된 층은 역전파 대상에서 **아예 제외**되어, .backward() 를 아무리 호출해도 가중치가 **단 한 번도** 갱신되지 않음

두 단계 전이: “다른” 작업에서 배운 특징

실전 전이학습은 **다른(보통 훨씬 큰) 작업**에서 배운 가중치를 가져온다: (1) **큰 데이터셋**(4,000장, period 3 줄무늬 — “ImageNet”의 위장)에서 SmallCNN 학습(100%) → (2) **합성곱 가중치를 copy_로 복사**, 합성곱 **동결**하고 **작은 데이터셋**(300장, period 4 — “새 문제”)의 **헤드만** 20 에폭 학습 → **검증 정확도 100%**.

```
pre = SmallCNN() # 단계1: 큰데이터에서사전학습
# ... 15 에폭학습 ... # 학습정확도 100%

model = SmallCNN()
with torch.no_grad(): # 단계2: 가중치복사
    for d, s in zip(model.conv1.parameters(),
                    pre.conv1.parameters()):
        d.copy_(s)
    # ... 도conv2 동일하게 ...
for p in model.conv1.parameters():
    p.requires_grad = False # 합성곱동결
# ... 도conv2 ...
opt = torch.optim.Adam(
    filter(lambda p: p.requires_grad,
           model.parameters()), lr=0.01)
# ... 20 에폭 ... # 검증정확도 100%
```

어떤 데이터를 언제 쓸 것인가 + 왜 이게 되는가

새 문제의 상황

데이터가 적다(수십~수백 장)
데이터가 어느 정도 있고, 사전학습 도메인과 비슷하다
데이터가 충분하고, 도메인이 크게 다르다

추천 방식

특징 추출 — 헤드만 학습, 나머지 동결
미세조정 — 낮은 학습률, 뒤에서부터 순차 동결 해제
스크래치도 고려 — 사전학습의 **편향(bias)**이 오히려

- 세 번째 줄이 **초보자가 놓치는 경우** — X-ray(2차원 투영, 흑백)에 RGB 자연영상의 ImageNet 특징을 그대로 없으면, “색 대비”라는 ImageNet의 핵심 신호가 **잡음**. 전이학습은 **데이터가 없을 때의 보험**이지, 도메인이 아무리 달라도 무조건 이득인 마법이 아님
- 실전 트릭: 순차 동결 해제(unfreezing)** — “마지막 층부터 뒤로 **한 층씩**” 해제, “수렴하지 않으면 다음 층을 하나 더 푼다”. 앞뒤 비대칭의 **거울상**: 층이 깊을수록 특징이 범용이라(10.2) **덜** 바뀌어야 하고, 얇을수록 도메인 특화라 **더** 바뀌어도 안전
- 왜 이게 되는가(Ch. 6)**: 정규화가 “모델을 **덜 유연하게** 만들어 분산을 줄인다”면, 전이학습은 “**시작점을 좋게 해서**” 동일한 목표 달성 — Ch. 4.1의 **편향-분산 프레임워크**가 다시 등장

자주 하는 실수 (10.3)

실수 1: 사전학습 모델의 정규화 통계를 무시

사전학습된 모델은 보통 특정 정규화(예: ImageNet의 **채널별 평균·표준편차**로 입력 표준화)를 적용받은 데이터로 학습됐다. 새 데이터에 이 정규화를 **빼먹거나 다른 값**을 쓰면, 필터들이 “본 적 없는 스케일의 입력”을 받아 성능이 예상보다 훨씬 나빠진다. **모델이 학습될 때 가정했던 데이터 분포를 추론 시점에도 정확히 재현해야 한다** — 사전학습 모델을 쓸 때는 반드시 **학습 전처리 파이프라인(평균/표준편차, 이미지 크기)**을 문서에서 확인하고 그대로 맞추는 것이 첫 단계.

실수 2: 높은 학습률로 미세조정하며 사전학습 가중치를 망침

사전학습 가중치는 사전학습 손실 지형에서 **좋은 지역**에 놓인 점. 큰 학습률(예: 0.01)로 시작하면 그 좋은 지역 경계를 **한 발로 뛰어넘는** 셈 — 범용 특징이 파괴되어 “전이한 모델”이 “전이를 안 한 것”보다 **나빠짐**. 미세조정은 스크래치 대비 **10~100배 낮은** 학습률(예: 0.001 또는 0.0001)로, 가능하면 “순차 동결 해제” 순서로 — 학습률은 “그래디언트 한 걸음의 대담함”(Ch. 9)이고, 좋은 시작점 위에서는 **작은 걸음이 정답**.

한눈에 보기: 같은 특징 추출기, 다른 헤드

문제	출력 형태	특징 추출기 위에 붙는 헤드	
분류	벡터 1개(K개 클래스 점수)	격자 펼치기 + 선형층 1개	V
객체 탐지	(클래스, 박스 좌표 4개) × N개 사물	후보 생성 + 박스별 분류기(SVM) + NMS	R
의미론적 분할	입력과 같은 크기의 클래스 지도	위치별 공유 1×1 합성곱 (출력 채널 = 클래스 수)	U
전이학습	(위 중 아무거나)	헤드만 재학습, 또는 낮은 학습률로 전체 미세조정	—

장 마무리

네 줄 전부 10.2의 “**합성곱 스택**”이라는 **같은 줄기에 다른 헤드**를 붙인 것 — 헤드의 차이에 따라 답의 **형태만** 바뀐다(벡터 → 박스 목록 → 픽셀 지도). CNN은 “**이미지의 국소적 패턴은 위치와 무관하게 재사용될 수 있다**”는 하나의 통찰을, **합성곱이라는 연산 하나로 구현한 것** — 전이학습·탐지·분할·ResNet은 서로 다른 문제를 풀지만 전부 그 재료를 “**어떻게 재사용·재조합·안정화할 것인가**”를 답하는 응용.

FAQ (10.3)

- **분할이 분류보다 더 어려운 이유?** 격자 위치 는 고정되어 NMS 문제가 없지만 (1) **라벨 비용**: 분류는 이미지 1장에 라벨 1개, 분할은 **픽셀마다** 라벨(의료 영상 1장에 수백만 개, 전문의가 직접 그려야 함). (2) **경계**: 7×7 격자(풀링 5번) 해상도로는 “도로의 가장자리”가 흐려진다 → U-Net이 스킵으로 해상도를 되찾아야 함. (3) **클래스 불균형** 극단: 자율주행 프레임에서 “보행자” 픽셀은 0.1% 미만 — 정확도 99% 모델이 보행자를 **전부** “도로”로 분류할 수도 있음(Ch. 2의 정확도 함정, 픽셀 스케일에서 재발).
- **미세조정 학습률이 낮은 이유?** (실수 2) — 사전학습 가중치는 좋은 손실 지역 위에 있고, 큰 학습률은 그 지역을 벗어나 범용 특징을 파괴. 작은 걸음($1/10 \sim 1/100$)은 “**좋은 점의 근처에서**” 새 작업에 적응하는 것이지, 처음부터 배우는 게 아님.
- **데이터 100장뿐인데 전이학습을 해도 되나?** 그것이 전이학습의 **주식 용례**. 전제는 새 도메인이 사전학습 도메인과 “너무 다르지 않다”(가정 풍경 → 주차장 풍경은 OK, RGB 자연영상 → X-ray는 큰 점프). 100장 수준에서는 **특징 추출**(헤드만 학습)이 가장 안정적.
- **구별할 클래스가 ImageNet에 없는데? 되 며, 그게 표준 경우**. 앞쪽 층은 “고양이를 구분하는 능력”이 아니라 “**모서리를 보는 능력**”이라, ImageNet 1,000개 클래스에 없던 사물도 그 사물의 **모서리·질감**으로 앞쪽 층이 특징을 뽑아냄. 바꿔야 할 것은 **마지막 헤드**(출력 1,000개 → K개)뿐.

확인 문제 (10.3): 숫자 네 개

- ① **격자 크기.** 224×224 입력이 2×2 최대풀링을 5번 $\rightarrow 224/2^5 = 7$, “위치별 분류기” **49개**
- ② **IoU.** 박스 $[2, 3, 8, 9]$ 와 $[4, 3, 10, 7]$: 교집합 $[4, 3, 8, 7]$ 면적 **16**, 각 박스 면적 **36**과 **24** $\rightarrow$ 합집합 **44** $\Rightarrow$ $\text{IoU} = 16/44 = 4/11 \approx \mathbf{0.36}$
- ③ **NMS.** 앞 표의 4개 박스(A 0.90, B 0.80, C 0.75, D 0.60)에 임계값 0.5 $\rightarrow$ **A와 C가 남음** (A-B 쌍과 C-D 쌍의 IoU가 **둘 다** 0.68 — “점수가 높은 쪽이 살아남는다”는 규칙만으로는 답이 안 나옴)
- ④ **헤드 파라미터.** 2048차원 특징을 1,000개 클래스 로 미세조정: $2048 \times 1000 + 1000 = \mathbf{2,049,000}$ — VGG-16 전체 1억 3,800만 파라미터에서 $\approx 1.5\%$. (“전이학습이 왜 저렴한가”의 숫자적 답)

이번 주차 정리

- ① **합성곱 = 재사용의 연산** — $n_{\text{out}} = \lfloor (n + 2p - k)/s \rfloor + 1$, params $(k^2 C_{\text{in}} + 1)C_{\text{out}}$, FLOPs에 n_{out}^2 이 곱해진다. 미니 LeNet이 MLP 대비 **0.12%의 파라미터, 1/4의 연산**.
- ② **좁아지고 깊어진다** — 합성곱이 “무엇을”(패턴), 풀링이 “얼마나 넓은 시야로”(수용장)를 결정. 깊이 열화는 **최적화 문제**이고, 스킵 연결의 “+1”이 그래디언트 바닥을 깔아 **100층이 넘는 CNN**을 가능하게 함.
- ③ **같은 줄기, 다른 헤드** — 분류(벡터 1개) / 탐지(박스 + NMS) / 분할(위치별 공유 1×1 합성곱) / 전이학습(앞쪽 동결, 헤드만 재학습). “**앞쪽 = 범용, 뒤쪽 = 특화**” 비대칭이 전이학습의 핵심.

다음 주 — Chapter 11. 시퀀스 모델

CNN이 가중치를 **공간**(이미지 위 위치)에 걸쳐 재사용한다면, RNN은 같은 가중치를 **시간**(시퀀스의 시점)에 걸쳐 재사용한다. 공간과 시간, 두 축에서 “**작은 단위 패턴을 재사용해 큰 구조를 쌓는다**”는 동일한 원리를 본 셈이다 — 이번 주차의 “재사용”이 바로 그 연결고리.