

동적계획법 (Dynamic Programming)

벨만 최적방정식과 정책평가 · 정책 반복과 GridWorld 실습 · 가치 반복, 수렴 증명, 모델
기반의 전제

Machine Learning 2 · 4주차

한국과학영재학교 (KSA)

Chapter 4

이번 주차 개요

Chapter 3에서 MDP를 정식화했지만, “무한히 먼 미래까지 내다보아야 하는 것처럼 보이는” 누적 보상 최대화 문제는 여전히 **계산 불가능**해 보인다. 벨만의 통찰은 이 무한함을 **재귀적 관계**로 다시 쓸 수 있다는 것(3.3절 벨만 기대방정식). 이번 장은 그 재귀식을 **실제로 계산하는 절차**를 다룬다.

이 챕터를 마치면

- 벨만 기대방정식으로 주어진 정책의 V^π, Q^π 를 **반복적 정책평가**로 계산한다.
- 정책 반복의 두 단계가 왜 필요하고, **“멈추면 최적”**인지를 정책개선 정리(단조 증가) + 유한성으로 설명한다.
- 가치 반복(평가 한 번 + 바로 개선)을 비교하고, **축소 사상(바나흐 고정점 정리)**이 수렴을 보장함을 설명한다.

세 차시 (5칸 GridWorld 위에서 직관이 쌓인다)

- 1 **4.1 벨만 최적방정식과 정책평가** – 연립방정식 직접 풀이 vs 반복, V^π/Q^π 다리, 최적방정식 유도.
- 2 **4.2 정책 반복과 GridWorld 실습** – 평가→개선을 GridWorld에서 돌리고 “멈추면 최적”을 정리로, 수정된 정책 반복까지.
- 3 **4.3 가치 반복, 수렴 증명, 모델 기반 전제** – “한 줄 차이”인 가치 반복, k 스텝 내다보기, 바나흐 고정점 정리, 전제 한계.

한 줄 감각: 벨만방정식은 **연립방정식이 아니라 반복 대입으로 푸는 것**. 이 감각은 Ch. 6

TD(경험으로 근사)와 Ch. 8 DP(시계열로 근사)

4.1 벨만 최적방정식과 정책평가

이 절에서 무엇을 만들 것인가

이 절은 세 가지를 만든다.

- ① 3.3절의 벨만 기대방정식을 “풀기 위한 도구”로 다시 읽는 법 — 벨만 연산자 T^π 로.
- ② 3-state 순환 MDP를 반복 없이(연립 일차방정식 직접 풀이)와 반복으로(정책평가) 두 길로 풀어 비교해, “같은 고정점의 다른 길”임을 체감.
- ③ V^π 와 Q^π 사이의 다리 $Q^\pi(s, \pi(s)) = V^\pi(s)$ 와, 여기에 max 를 넣은 벨만 최적방정식.

4.2·4.3절의 모든 알고리즘은 4.1절의 이 세 가지 (연산자 반복 · Q^π 점수표 · max)의 조합일 뿐이다.

복습: 벨만 기대방정식과 벨만 연산자 T^π

결정론적 정책(각 상태에서 정확히 한 행동 $\pi(s)$)로 쓰면:

$$V^\pi(s) = R(s, \pi(s)) + \gamma \sum_{s'} P(s'|s, \pi(s)) V^\pi(s')$$

직관: “지금 상태의 가치 = 지금 당장 받는 보상 + 할인된 다음 상태들의 가치의 기댓값.” — 게임이 끝날 때까지 통째로 계산 대신, **한 스텝 앞만 내다보는 계산을 반복**하면 정확한 답에 도달한다.

확률적 정책 일반형 $\pi(a|s)$ 로 쓰면 우변이 **가중합**:

$$V^\pi(s) = \sum_a \pi(a|s) \left[R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^\pi(s') \right]$$

이 전체를 **벨만 연산자** T^π (“가치함수를 먹여 우변을 돌려주는 함수의 함수”)라 부른다. 모든 반복법은 **이 연산자를 같은 값에 계속 대입**:


$$V_0 \xrightarrow{T^\pi} V_1 \xrightarrow{T^\pi} \dots \xrightarrow{T^\pi} V^\pi$$

이 관점이 4.3절 “왜 수렴하는가” 증명의 핵심.

V^π 와 Q^π : 동전의 양면, 그리고 2×2

행동가치함수 $Q^\pi(s, a)$ — “상태 s 에서 행동 a 를 강제 한 번 취하고, 그 다음부터 π 를 따른다”의 가치 — 는 V^π 와 같은 방식으로 재귀되고, 다리 $Q^\pi(s, \pi(s)) = V^\pi(s)$ 로 서로를 정의하는 **동전의 양면**:

$$Q^\pi(s, a) = R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^\pi(s')$$



네 개의 벨만방정식: 기대 vs 최적 $\times V$ vs Q 로 2×2 .

	기대(π 를 따른다)	최적(max)
V	V^π (4.1절 = 오늘)	V^* (4.2-4.3절)
Q	Q^π	Q^* (Ch. 9 DQN)

이번 절의 모든 코드와 수식이 이 다리(V-방정식 $\leftrightarrow$ Q-방정식 사이)를 통해 오간다.

실습 (1/3): 3-state 순환 MDP를 두 길로

“연립 일차방정식”을 직접 만든다. 3.3절 2상태 왕복 예(행동 1개)를 **확률적 전이** 3상태 버전으로 ($\gamma = 0.9$): 상태 0: +1, **항상** 1로. 상태 1: +2, 2로 0.7 / 0으로 0.3. 상태 2: 0, **항상** 0으로. 행동을 하나뿐이므로 정책은 자명 — **평가할 것: 상태 0·1·2의 가치?**

```
P = {0: {0: [(1.0, 1)]},  
      1: {0: [(0.7, 2), (0.3, 0)]},  
      2: {0: [(1.0, 0)]}}  
R = {0: {0: 1.0}, 1: {0: 2.0}, 2: {0: 0.0}}  
policy = [0, 0, 0]; gamma = 0.9
```

방법 1 (연립방정식 직접 풀이): 세 방정식 $V(0) = 1 + 0.9V(1)$,
 $V(1) = 2 + 0.9(0.7V(2) + 0.3V(0))$, $V(2) = 0.9V(0)$ 를 대입·정리하면 $0.2467V(0) = 2.8 \Rightarrow$
 $V(0) \approx 11.3498$, $V(1) \approx 11.4998$, $V(2) \approx 10.2148$. (검산: $1 + 0.9 \times 11.4998 \approx 11.3498 \checkmark$.
Ch. 2.2 정규방정식과 같은 가족.)

실습 (2/3): 방법 2 — 반복적 대입(sweep)

같은 값을 직접 풀지 않고 반복법으로. V 를 0으로 시작해 $0 \rightarrow 1 \rightarrow 2$ 순서로 **in-place** 한 스텝씩

갱신:	sweep	$V(0)$	$V(1)$	$V(2)$	최대 변화 Δ
	1	1.0000	2.2700	0.9000	2.2700
	2	3.0430	3.3886	2.7387	2.0430
	3	4.0497	4.8188	3.6448	1.4302
	5	6.1635	6.6902	5.5471	0.9530
	7	7.6514	8.0469	6.8862	0.6565
	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$(\approx \times 0.9\text{씩})$
	88	11.3498	11.4998	10.2148	$< 10^{-6} \rightarrow \text{종료}$

확인할 것

88회 sweep을 거치고 나서야 $\Delta < 10^{-6}$ — 방법 1과 **같은 값**(11.3498, 11.4998, 10.2148). 두 방법은 “**같은 고정점을 찾는 다른 길**”이다.

실습 (3/3): 이 예가 보여주는 세 가지

- ① **“연립방정식”의 실질.** “벨만방정식을 풀다” = n 개 미지수 $V(s)$ 에 대한 n 개 일차방정식. 3개면 손으로, 100개면 100×100 역산(귀찮지만 가능), 100만 개면 **사실상 불가능**.
- ② **수렴은 “느리다”가 정석.** 오류가 sweep마다 대략 $\times \gamma$ 배. $\gamma = 0.9$ 이면 절반까지 ≈ 6.6 회, 10^{-6} 까지 ≈ 120 회. $\gamma = 0.99$ 라면 “수백~수천 sweep”.
- ③ **수렴은 초기값에 무관.** 0으로 시작해도 $V = [100, -50, 10]$ 처럼 아무렇게나 잡아도 **같은** V^π 로 수렴(4.3절 바나흐 고정점 정리).

이 반복적 정책평가는 Sutton·Barto(2018) 표준 교과서 4장 “Dynamic Programming”과 동일. 4.3절 연습 2의 **비순환** MDP는 “터미널부터 거꾸로 대입”만으로 답이 나오는 특수 경우.

반복적 정책평가: 코드

상태가 많으면 다음을 값이 더 이상 안 바뀔 때까지 반복 근사:

```
def policy_evaluation(P, R, policy, gamma, theta=1e-6):
    n_states = len(P)
    V = [0.0] * n_states
    while True:
        delta = 0                                # 매 sweep 시작마다초기화 !
        for s in range(n_states):
            a = policy[s]
            v_new = R[s][a] + gamma * sum(prob * V[next_s]
                                           for prob, next_s in P[s][a])
            delta = max(delta, abs(v_new - V[s]))
            V[s] = v_new                          # in-place: 갱신된값을즉시사용
        if delta < theta:
            break
    return V
```

매 sweep마다 모든 상태의 $V(s)$ 를 벨만 우변으로 갱신. 우변의 $V(s')$ 는 아직 **정확한 값이 아닌** 추정치인데도, $\gamma < 1$ 이면 정확한 V^π 로 수렴(**수축 사상**, 4.3절 증명).

in-place(가우시) vs synchronous(야코비)

in-place (가우시) — 위 코드

- sweep **안에서도**, 앞쪽 상태가 갱신된 값을 뒤쪽이 **즉시** 사용.
- sweep 중반 V 는 “어떤” 가치함수의 우변도 아니지만, $\gamma < 1$ 이면 같은 고정점으로 수렴.

synchronous (야코비)

- sweep을 **완전히 끝낸** 뒤에야 갱신 (V 는 이전 sweep의 값).
- V_{new} 리스트를 따로 모았다가 교체.

실용적 차이

둘 다 **같은** 답에 수렴하지만 **속도**는 다를 수 있다. sweep당 비용은 동일하고, in-place가 갱신 정보가 sweep 안에 전파돼 보통 **2~10배** sweep 수를 아낀다.

“정보의 전파”로 보는 수렴

“왜 우변에 아직 안 폰 값이 들어가도 될까?”

답은 **전파(propagation)** 직관. 5칸 GridWorld(칸 4가 목표, 걸음마다 -1 , $\gamma = 0.9$)에서 “오른쪽” 정책을 평가하면: sweep 1에서 “목표가 가까울수록 -1 ”이라는 **약간 정확한** 정보가 퍼지고, sweep 2에서 **한 칸 더** 왼쪽으로 이동, 계속되면 $-1 - 0.9 - 0.9^2 - \dots$ 의 꼬리 합으로 수렴.

경험칙


“정보는 한 sweep에 한 칸 전파된다.” $\Rightarrow$ sweep 수 $\approx$ 목표까지 최대 거리 $\times$ (할인이 충분히 작아질 때까지의 횟수). 순환 MDP에서는 “순환 한 바퀴 전파”.

손으로 한 sweep: “왼쪽” 정책을 0에서 시작해 in-place로 돌리면 sweep 1 $\rightarrow$

$[-1.0000, -1.9000, -2.7100, -3.4390, 0]$, sweep 2 $\rightarrow [-1.9000, -2.7100, \dots]$ — 첫 sweep에서 -1 이 한 칸, 두 번째에서 $-1.9 = -1 + 0.9 \times (-1)$ 이 한 칸 전파. 수렴값 -10 은 $\sum_{k=0}^{\infty} (-1)(0.9)^k = \frac{-1}{1-0.9} = -10$ — 벽에 막혀 왼쪽으로 밀리는 **무한 루프**의 가치(약 133 sweep).

두 정책 나란히: “왼쪽”의 나뻐를 정량화

“왼쪽” 정책은 이 GridWorld에서 **나쁜 정책**이지만, 그 “나뻐”를 정량화하는 것이 $V^{\text{left}}(s) = -10$.



두 정책의 반복적 정책평가 수렴 곡선 ($V(0)$, in-place sweep 단위).

	V
right	$[-3.439, -2.710, -1.900, -1.000, 0]$
left	$[-10.000, -10.000, -10.000, -10.000, 0]$

- “오른쪽”은 **5 sweep** 만에 수렴 — 4.2절 “정책 반복이 첫 sweep에서 멈춘다”와 일치.
- “왼쪽”은 벽(칸 0)에 막혀 무한 루프 → **133 sweep**. 가치(-10)가 γ 로 할인돼 **유한**하게 수렴 — “ $\gamma < 1$ 이면 무한 합 이 수렴”(3.2절)과 같은 원리.

θ 가 결과에 미치는 영향은 작다 — $\theta = 1e-4$ vs $1e-8$ 로 수렴시키면 최대 차이가 $< 10^{-4}$. θ 는 수렴 판정 기준(정밀도)이지, 답 자체를 결정하는 파라미터가 아니다.

행동가치 Q^π : “다음 행동을 포함해” 평가

$V^\pi(s)$ 는 “정책이 시키는 대로 행동하면”의 가치. 4.2절 정책개선은 “이 상태에서 **이 특정 행동**을 하면?”을 각 상태·행동마다 직접 재문는다 — 그 답이 $Q^\pi(s, a)$. V^π 와 같은 재귀 구조이되, “첫 스텝 행동을 a 로 **강제로 고정**”한 것.

V^π 를 안다 $\iff Q^\pi$ 를 안다

다리 $V^\pi(s) = \sum_a \pi(a|s) Q^\pi(s, a)$ 로 정리하면, 어느 한쪽을 안다면 다른 쪽은 즉시 계산.

“오른쪽” 정책에서 $V^{\text{right}} = [-3.439, -2.710, -1.900, -1.000, 0]$ 와 $Q(s, a) = R(s, a) + 0.9 V(s')$ 로 직접 채운 Q^π 표:

s	$Q(s, \text{left})$	$Q(s, \text{right})$	행의 arg max
0	-4.095	-3.439	right
1	-4.095	-2.710	right
2	-3.439	-1.900	right
3	-2.710	-1.000	right
4	0.000 (동점)	0.000 (동점)	right (목표라 무의미)

이 표의 굵은 값을 행마다 따면 “오른쪽” 정책은 자기 자신을 되돌려준다 — 자신의 Q^π 기준으로 이미 개선

불가(policy-stationary), 곧 “이 MDP에서 최적”을 암시. 반면 “왼쪽”의 Q^{left} 는 모든 칸에서 right가 left보다 낫다

벨만 최적방정식: max 한 글자가 가르는 두 문제

강화학습이 정말로 풀고 싶은 문제는 “가장 좋은 정책을 찾는 것”. 최적 가치 $V^*(s)$ 는:

$$V^*(s) = \max_a \left[R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^*(s') \right]$$

기대방정식과의 차이

형태는 거의 같지만, 특정 $\pi(s)$ 가 고른 행동 하나 대신 모든 행동 중 최선($\max_a$). 이 한 글자가 “이 정책이 얼마나 좋은가 평가”와 “가장 좋은 정책 찾기”라는 두 문제를 가른다.

왜 “정의”인가 — 원리 최적성

모든 정책($2^5 = 32, 4^{100} \approx 10^{60}$ 개)을 직접 비교할 수는 없는데, 이 식은 “비교”를 각 상태에서 한 스텝만으로 압축. 근거: **원리 최적성**(최적 경로의 부분 경로도 최적) — s' 이후의 선택은 s 이전 선택과 독립(마르코프 성질)이라, “각 상태 한 스텝만 최적”을 재귀적으로 이르면 “전체적으로 최적”. (이 성질이 없는 비마르코프 문제에서는 DP 자체가 적용 불가.)

Q^* 버전: DQN의 출발점

$$Q^*(s, a) = R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^*(s') = R(s, a) + \gamma \sum_{s'} P(s'|s, a) \max_{a'} Q^*(s', a')$$

$V^* = \max_a Q^*$ 이므로 Q^* 만으로 닫혀:

$$\pi^*(s) = \arg \max_a Q^*(s, a)$$

Q^* 를 알면 최적 정책이 직접 주어진다

이 관점이 **Chapter 9 (DQN, Mnih et al., 2015)**의 출발점 — DQN은 V^* 표가 아니라 Q^* 표(신경망)를 배우고, $\arg \max$ 로 정책을 읽어낸다. 이번 절에서 Q^π 표를 직접 채워본 경험은, DQN의 “Q값을 추정하는 신경망”이 **무엇을** 추정하는지 이해하는 데 바로 쓰인다.

역사: “벨만”과 “동적계획법”의 이름

리처드 벨만(Richard Bellman, 1920~1984) — 2차대전 중 탄약 포대에 “최적 포사거리 배분” 문제를 풀던 미군 수학자. 전후 물자배분·비행 경로 최적화로 “**동적계획법**”이라는 이름 자체를 만들었다.

- 큰 문제 = 작은 부분 문제 + 재귀 로 쪼개는 재귀 구조로 풀어, 1957년 저서 Dynamic Programming and Its Applications에서 정리.
- “**동적**” = 시간(시간에 따라 상태가 바뀐다), “**계획법**” = 계획(미래 보상을 계획적으로 최대화).

“재귀적 구조로 큰 문제를 쪼개는” 이 패턴은 **컴퓨터과학 전반**에서 반복: 강화학습(DQN, 정책기반)·컴퓨터그래픽스·자연어처리(최장 공통 부분열). 강화학습에서는 “미래의 **불확실한** 보상을 어떻게 지금 계산할 것인가”에 적용 — 4.1~4.3절의 모든 알고리즘은 같은 패턴의 세 가지 변주(기대/최적 $\times V/Q$).

자주 하는 실수 (1/2)

- V^π 와 V^* 를 섞어 쓴다. “정책평가에서 V^* 를 계산한다”는 말은 무의미 — 정책평가는 주어진 π 의 V^π 만 계산할 뿐, “최적인가”를 판단하지 않는다. 상첨자(π vs $*$)를 항상 확인할 습관.
- ‘delta’를 sweep 밖에서 초기화한다. ‘delta’ 는 매 sweep 시작에 0으로. sweep 앞에서 한 번만 만들고 누적하면 “첫 sweep의 큰 변화”가 이후 모든 sweep 의 ‘delta’를 덮어서 수렴 판정 안 되고 무한 루프.
- 터미널을 보상 0으로만 “처리”한다. 목표 칸에서 어디로 전이하는지(P 에 self-loop, 보상 0)를 명시하지 않으면 “0 다음에 또 0의 무한 루프”로 계산 — 우연히 0이 나와도 이유가 다름. 1.3절 terminated/truncated 구분과 같은 정신: 종료 조건을 코드에 명시적으로 드러내라.

자주 하는 실수 (2/2)

- $\gamma = 1$ 을 아무 고민 없이 쓴다. 축소 사상 성질 $\|TV_1 - TV_2\| \leq \gamma \|V_1 - V_2\|$ 이 $\gamma = 1 < 1$ 이 아니므로 성립하지 않고 수렴이 보장되지 않는다(유한 에피소드만). 보상이 무한히 계속되는 문제에서 리턴 자체가 발산. “할인 없이 다 더하기”는 보상 합이 유한한 문제에만 안전.
- “sweep 1회 = 하나의 상태만 갱신”이라고 오해. sweep = 모든 상태 한 바퀴(for s in range(n_states) 한 바퀴). “sweep 100회” = $n_states \times 100$ 번의 개별 갱신. sweep 수와 개별 갱신 수를 혼동하면 계산량(n_states 배)을 과소평가.

실습: 5칸 GridWorld에서 두 정책 나란히

4.2절의 5칸 GridWorld(칸 0~4, 칸 4가 목표, 걸음마다 -1 , $\gamma = 0.9$)에 두 정책을 모두 평가 — 이 비교가 4.2절 정책개선을 예고:

```
n_states, n_actions, gamma = 5, 2, 0.9    # 0=left, 1=right
P, R = {}, {}
for s in range(n_states):
    P[s], R[s] = {}, {}
    for a in range(n_actions):
        if s == 4:
            P[s][a], R[s][a] = [(1.0, 4)], 0.0    # 목표 = 종료
        else:
            ns = max(0, s-1) if a == 0 else min(4, s+1)
            P[s][a], R[s][a] = [(1.0, ns)], -1.0

policy_right = [1, 1, 1, 1, 0]    # 모든칸에서오른쪽    ""
policy_left  = [0, 0, 0, 0, 1]    # 모든칸에서왼쪽    ""

V_right = policy_evaluation(P, R, policy_right, gamma)
V_left  = policy_evaluation(P, R, policy_left, gamma)
# V_right: [-3.439, -2.710, -1.900, -1.000, 0.000]
# V_left : [-10.000, -10.000, -10.000, -10.000, 0.000]
```

“오른쪽”이 모든 칸에서 “왼쪽”보다 낫다($-3.439 > -10, \dots$). 이 상태별 비교가 4.2절 정책개선의 본체 — “각

- Q. 정책평가는 왜 한 번에 안 풀고 반복으로 근사? 상태가 적으면 연립 일차방정식으로 한 번에 풀 수도(Ch. 2.2 정규방정식 같은 닫힌 해). 하지만 상태가 많아지면 직접 풀이($O(n^3)$ 행렬 역산)가 반복법보다 **비싸지는** 경우가 많아, 실전에선 **반복적 정책평가를 표준**.
- Q. “이 정책이 최적인가”를 정책평가만으로 판별할 수 있나요? **아니다** — 주어진 π 의 V^π 만 계산할 뿐. 판별하려면 4.2절 **정책개선 단계**: $\arg \max_a [R + \gamma \sum P V^\pi]$ 가 현재 $\pi(s)$ 와 **모든** 상태에서 일치하는가 확인. “아무것도 안 바꾸는 정책”이 바로 **최적 정책**(4.2절 핵심 정리).
- Q. γ 가 1에 가까울수록 더 느려지나요? **맞다** — γ 가 **축소율**이라 매 sweep 오류가 γ 배로 줄어듦. $\gamma = 0.9$: 10^{-6} 까지 ≈ 120 sweep, $\gamma = 0.99$: ≈ 1381 sweep(**10배**). 이 사실이 4.2·4.3절에도 그대로.

Q. P 를 모르면? Ch. 5–7(MC, TD, Q-learning) 이 그 문제 — 이 절 반복법이 **모델 기반의 정답 기준**이므로 model-free의 “정확성”을 이 절 값과 비교해 평가.

4.1절 마무리: 세 개의 도구

4.1절에서 만든 것

- ① **벨만 연산자** T^π — “가치함수를 먹여 우변을 돌려주는” 함수. 모든 반복법 = 이것을 같은 값에 계속 대입.
- ② **V^π/Q^π 다리** $Q^\pi(s, \pi(s)) = V^\pi(s) - V/Q$ 방정식 사이를 오가는 두 줄짜리 다리.
- ③ **벨만 최적방정식** — 기대방정식의 $\pi(s)$ 을 $\max_a$ 로 바꾼 것. **최적 정책**을 정의하는 방정식, 원리 최적성이 “정의”임을 담보.

예습 확인 문제: ① 2상태 순환 MDP에서 $V(S_0) \approx 14.737$ 이 $1 + 0.9V(S_1)$ 을 만족하는지 계산. ② $V^{\text{right}}(0) = -3.439$ 를 닫힌 형태로: $\sum_{k=0}^3 (-1)(0.9)^k = \frac{1-0.9^4}{1-0.9} \times (-1)$. ③ $\theta = 1e-2$ 로 바꾸면 sweep 4~5 근처에서 멈춘다 — 멈춘 sweep의 $V(0)$ 을 세어봐라.

4.2 정책 반복과 GridWorld 실습

정책 반복: 두 단계가 서로를 먹여 살린다


정책 반복 (Policy Iteration, Sutton·Barto)은 최적해를 향해 두 단계를 번갈아 반복한다:

- 1 정책평가: 현재 π 의 V^π 를 계산(4.1절).
- 2 정책개선: 각 상태에서 V^π 기준으로 더 나은 행동이 있으면 바꾼다:

$$\pi'(s) = \arg \max_a \left[R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^\pi(s') \right]$$

멈춤 신호

정책이 더 이상 안 바뀔 때까지 반복하면 최적 정책에 도달. “개선이 아무것도 바꾸지 않았다”는 순간이 멈춤 신호.



평가가 개선행동(각 행 $\arg \max$)을 산출하고, 개선이 다음 평가의 대상(새 정책)을 산출. 두 단계가 **서로의 출력을 입력으로** 먹는 구조.

왜 이 두 단계인가 + 개선 = Q^π 표 행별 argmax

평가 alone은 “지금 정책이 얼마나 좋은가” 만 답하고, “어떻게 **고쳐야** 하는가”를 말해주지 않음(4.1절 FAQ: 정책평가만으론 “최적인가” 판별 불가).

개선 alone은 “더 나은 행동”을 V^π 기준으로 판단해야 하는데, **정책이 바뀌면 V^π 자체가 바뀌어** 다시 계산 필요 → 한 발도 못 뺌.

핵심 연결

개선 식의 우변 $R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^\pi(s')$ 는 4.1절 $Q^\pi(s, a)$ 그 자체. 즉 4.1절이 직접 채운 Q^π 표가 **정책개선의 점수표**이고, 개선은 각 행에서 최댓값을 따는 동작. “오른쪽” 정책은 자기 Q^π 기준으로 이미 바꿀 것이 없는 상태 (정책개선의 **고정점**).

이론 (1/3): 질문 1 — “안 나빠지는가”?

질문 1. 개선한 정책이 정말로 안 나빠지는가? (가치가 감소하면 “최적해”라는 말 자체가 성립하지 않음.)

정책개선 정리 (단조 증가)

π' 가 π 를 모든 상태에서 동시에 개선한 정책이면, 모든 s 에서 $V^{\pi'}(s) \geq V^{\pi}(s)$.

(i) $V^{\pi'}$ 의 **정의**로, $\max$ 가 특정 성원 이상이라는 자명한 사실:

$$V^{\pi'}(s) = \max_a \left[R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^{\pi'}(s') \right] \geq R(s, \pi'(s)) + \gamma \sum_{s'} P(s'|s, \pi'(s)) V^{\pi'}(s')$$

이론 (2/3): 증명은 두 줄

(ii) $\pi'(s)$ 의 정의(V^π 기준 argmax)로, $\pi'(s)$ 의 점수가 모든 행동 중 최대 $\rightarrow$ 현재 $\pi(s)$ 보다 작을 수 없다:

$$R(s, \pi'(s)) + \gamma \sum_{s'} P(s'|s, \pi'(s)) V^\pi(s') \geq R(s, \pi(s)) + \gamma \sum_{s'} P(s'|s, \pi(s)) V^\pi(s') = V^\pi(s)$$

(마지막 등호: 벨만 기대방정식.)

두 줄 합치기:

$$V^{\pi'}(s) \geq R(s, \pi'(s)) + \gamma \sum_{s'} P(s'|s, \pi'(s)) V^\pi(s') \geq V^\pi(s) \quad \square$$

한 칸 손계산으로 체감. “왼쪽” 정책($V = -10$ 모든 칸)에서 칸 3:

$Q(3, \text{left}) = -1 + 0.9 \times (-10) = -10$, $Q(3, \text{right}) = -1 + 0.9 \times 0 = -1 \rightarrow \text{right}$ 이김 $\rightarrow V^{\pi'}(3) = -1$ (목표에 1걸음), 이전 -10 보다 **나아짐**. 칸 0은 π' 에서도 왼쪽 $\rightarrow V^{\pi'}(0) = -10$
그대로 — “같거나 낫다”는 칸마다(점순) 성립.

이론 (3/3): 멈춤 = 최적, 그리고 유한성

질문 2. 멈춤 지점이 “최적”인가? 멈춤 조건: 모든 s 에서 $\pi(s) \in \arg \max_a Q^\pi(s, a)$ (자기 기준으로 바꿀 것이 없음). 이 조건에서 **직접** 읽히는 것:

$$V^\pi(s) = \max_a \left[R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^\pi(s') \right] \quad (\text{모든 } s)$$

이것은 4.1절 **벨만 최적방정식**. 해는 **유일**(4.3절 바나흐)이므로 $V^\pi = V^*$ — **“개선의 고정점에서 멈췄다” = “가치가 V^* 다”**. (실습 ‘stable’ 플래그의 수학적 정체.)

유한성

결정론적 정책 총수 m^n (유한) + 가치 감소하지 않음(위 정리) + **동점 처리 고정**(항상 최소 행동 번호) → 정책 수열은 유한집합 위 **결정적 함수의 궤적** → 언젠가 멈추거나 **주기 궤**도 진입. 주기 궤 안의 모든 정책은 **같은 가치**를 갖고, 그 값은 벨만 최적방정식을 만족 → **어느 경우든 가치 기준의 최적**. (고전적 결과: 바깥 반복 $\leq n(m-1)$ 회.)

실전적 상한 + “평가만 하면 안 된다”는 반례

단조 증가는 “나빠지지 않는다”지만 “얼마나 빨리 좋아지는가” 는 주지 않음. 수축 성질(4.3절)로부터:

$$\max_s |V^{\pi'}(s) - V^{\pi}(s)| \leq \frac{1-\gamma}{\gamma} \max_s |V^*(s) - V^{\pi}(s)|$$

실무적 메시지

초기 정책이 아무리 엉망이어도, γ 가 1에서 충분히 멀지만 한 바퀴(평가+개선)에 오차가 고정 비율(γ 배)로 줄어든다. $\gamma = 0.99$ 처럼 1에 가까우면 상한도 느려져 전체 비용이 크게 불어남.

“평가만 하면 안 된다”는 반례


“왼쪽” 정책($V = -10$)을 **평가만** 하면 “가치 -10 이다”가 전부. 개선 단계를 한 번만 끼워도 칸 3이 **right**로 바뀌고($V(3) : -10 \rightarrow -1$), 그 정보가 다음 평가에서 칸 2로, 다음에 칸 1로 퍼짐. **평가 alone**은 점수만 찍고, **개선 단계**가 점수표를 “갈아탈 방향”으로 번역 — 두 단계의 곱(점수 측정 $\times$ 방향 추출)이 정책 반복의 힘.

실습: 5칸 GridWorld의 policy_iteration

```
def policy_iteration(P, R, n_actions, gamma):
    policy = [1] * n_states # 처음엔무조건오른쪽
    while True:
        V = policy_evaluation(P, R, policy, gamma) # 1. 평가
        stable = True
        for s in range(n_states): # 2. 개선
            best_a = max(range(n_actions),
                          key=lambda a: R[s][a]
                          + gamma * sum(p*V[ns] for p, ns in P[s][a]))
            if best_a != policy[s]:
                policy[s] = best_a
                stable = False
        if stable: # 멈춤: 바뀐것이없으면
            return V, policy
```

실행 결과: $V = [-3.439, -2.710, -1.900, -1.000, 0.000]$, $\text{policy} = [1, 1, 1, 1, 0]$, **outer 2회**, sweep 총합 **10**. 시작 정책이 이미 “무조건 오른쪽”이라 첫 정책평가에서 곧바로 최적이 나왔고, 개선 단계에서 “더 바꿀 게 없다”는 것만 한 번 확인. $V(0) = -3.439$ 는 “칸 0→4까지 4번 이동의 할인 비용” ($-1 - 0.9 - 0.81 - 0.729 \approx -3.439$) 과 정확히 일치.

5칸 GridWorld의 V^* 와 π^* — 정답 기준



5칸 GridWorld의 최적 가치함수 V^* 와 최적 정책 π^* .

- 칸 4(목표, 종료)에서 칸 0까지 각 칸의 V^* 는 “목표까지 걸음 수의 할인 비용”: $-1, -1 - 0.9, -1 - 0.9 - 0.81, \dots$
- 최적 정책: 모든 칸에서 “오른쪽”.
- 이 $V^* = [-3.439, -2.710, -1.900, -1.000, 0]$ 가 이번 장 모든 알고리즘(정책 반복·수정된 정책 반복·가치 반복)의 정답 기준.

정책 반복 수렴 속도는 초기 정책을 얼마나 잘 골랐는지에 따라 크게 달라짐 — 이제 의도적으로 “최악의 출발”을 해본다.

최악의 출발: “왼쪽”에서 시작하면 한 칸씩 전파

“왼쪽” 정책(벽에 붙어 무한 루프 $\rightarrow V = -10$)에서 시작:

outer	정책	sweep	V
1	$[L, L, L, L, \cdot] \rightarrow [L, L, L, R, \cdot]$	133	$[-10, -10, -10, -10, 0]$
2	$[L, L, L, R, \cdot] \rightarrow [L, L, R, R, \cdot]$	133	$[-10, -10, -10, -1, 0]$
3	$[L, L, R, R, \cdot] \rightarrow [L, R, R, R, \cdot]$	133	$[-10, -10, -1.9, -1, 0]$
4	$[L, R, R, R, \cdot] \rightarrow [R, R, R, R, \cdot]$	133	$[-10, -2.71, -1.9, -1, 0]$
5	$[R, R, R, R, \cdot] \rightarrow (\text{변화 없음})$	5	$[-3.44, -2.71, -1.9, -1, 0]$

($L = \text{left}, R = \text{right}, \cdot =$

목표. 총 $133 \times 4 + 5 = 537$ sweep.)

왜 칸 3이 가장 먼저 바뀌는가?

outer 1에서 V^{left} 가 모두 -10 인 상태에서 $Q(3, \text{left}) = -10$ 인데 $Q(3, \text{right}) = -1 + 0.9 \times 0 = -1$ — 목표($V = 0$)가 바로 옆인 칸 3에서만 right가 압도적으로 낫다. 칸 0~2는 $Q(s, \text{right}) = -10$ 으로 left와 동점 $\rightarrow$ ‘max’가 기존 left를 그대로 둔다.

정보 전파(바깥 반복 버전) + 세 방법 나란히

- outer 2에서 칸 3의 값이 -1 로 갱신되자 칸 2에서 right가 이긴다:
 $Q(2, \text{right}) = -1 + 0.9 \times (-1) = -1.9 > -10$. 이 “목표가 가까워졌다”는 정보가 바깥 반복마다 한 칸씩 왼쪽으로 전파 — 4.1절 “한 sweep에 한 칸 전파”의 바깥 반복 버전.

같은 알고리즘, 시작 정책만 바뀌도

“오른쪽” 출발: 총 sweep 10 vs “왼쪽” 출발: 총 sweep 537 — 약 54배 차이. “정책 반복 속도는 초기 정책에 민감하다”의 실질, 그리고 4.3절 가치 반복이 “초기 정책에 무관하게 V^* 로 직접 간다”는 설계 의도의 동기.

“왼쪽” 출발, $\theta = 10^{-6}$ 기준 세 방법:

방법	바깥 반복	내부 sweep	총 sweep	과대해석 금지 — 위는 벽에
정책 반복 (완전 수렴)	5	$133 \times 4 + 5$	537	
수정된 정책 반복 ($k = 2$)	5	2×5	10	
수정된 정책 반복 ($k = 1$) = 가치 반복	5	1×5	5	

붙은 무한 루프를 $\gamma = 0.9$ 로 할인까지 다 풀어내는 최악 경로. 다른 MDP에선 한 번에 여러 칸 바뀌어 완전 수렴이 더 빠질 수도. 표에서 확실한 것만: 세 방법은 모두 정확히 같은 V^* 와 같은 최적에 도달.

수정된 정책 반복: k sweep만 평가 후 개선

정책평가를 끝까지 수렴시키지 않고 k sweep만 돌린 뒤 바로 개선(modified policy iteration):

```
def modified_policy_iteration(P, R, n_actions, gamma, k):
    """k = 내부정책평가 sweep 수. k이면=1 가치반복과동일 ."""
    policy = [0] * n_states # 왼쪽에서 시작
    V = [0.0] * n_states
    while True:
        for _ in range(k): # 평가: k 만sweep
            for s in range(n_states):
                a = policy[s]
                V[s] = R[s][a] + gamma * sum(p * V[ns] for p, ns in P[s][a])
            stable = True
            for s in range(n_states): # 개선: argmax
                best_a = max(range(n_actions),
                             key=lambda a: R[s][a] + gamma * sum(p * V[ns] for p, ns in P[s][a]))
                if best_a != policy[s]:
                    policy[s] = best_a
                    stable = False
        if stable:
            return V, policy
```

실행(모두 “왼쪽” 출발, 정책 변화 여부로 멈춤): $k = 1, 2, 3, 5$ 모두 바깥 반복 5, 최종

$V = [-3.439, -2.710, -1.900, -1.000, 0]$ 동일 (총 sweep = $5k$).

$k = 1$ 은 가치 반복: “같은 연산의 다른 분해”

$k = 1$ 확인

“평가 1 sweep” = 각 상태의 V 를 $\max_a[\text{보상} + \text{할인 미래값}]$ 으로 갱신하는 한 바퀴(정책을 “평가 중”에 argmax 로 교체), “개선”은 이미 그 sweep 안의 argmax 로 **흡수**. 두 표현(평가+개선 분리 vs 한 sweep에 통합)은 **동일한 연산의 다른 분해**.

k 를 1에서 ∞ (완전 수렴)로 늘리면 가치 반복에서 정책 반복으로 **연속적으로** 이어진다:

$$\text{가치 반복}(k = 1) \rightarrow k = 2 \rightarrow k = 3 \rightarrow \dots \rightarrow \text{정책 반복}(k = \infty)$$

k 가 작아도 왜 최적인가

k sweep의 정책평가 연산 $T^{\pi, k}$ 는 “ T^{π} 를 k 번 적용”이므로 여전히 γ^k -**축소 사상**. 바나흐 정리(4.3절)와 “고정점에서 멈추면 최적” 논증은 **변함 없이 적용** — 수렴 속도만 k 에 따라 변한다.

실무적으로 k 는 “평가 한 sweep의 비용 대비 얼마나 정확한 V^{π} 가 필요한가”의 **trade-off**.

자주 하는 실수

- “평가 → 개선” 순서를 뒤집거나, 개선 전에 평가를 안 한다. 개선 식의 V^π 는 현재 정책 가치. 이전 V 로 개선하면 “낮은 점수표로 갈아탈 방향을 고르는” 셈 → 단조 증가 전제가 깨짐. $V = \text{policy_evaluation}(\dots)$ 을 while 안쪽에 두는 것이 맞고, 루프 밖에서 한 번만 계산해 재사용하면 안 된다.
- 개선 단계에서 일부 상태만 고친다. (예: “값이 가장 나쁜” 상태부터) 단조 증가는 모든 상태를 동시에 개선할 때 성립. 순서대로 하나씩 고치면 “고친 상태의 기준 V 와 안 고친 상태의 기준 V 가 다를” 수 있어 증명이 직접 적용되지 않음(변형도 보통 수렴하지만 다른 논증 필요).
- $\arg \max$ 동점을 “임의로” 처리하고 결과를 믿는다. 동점 MDP에선 결과 정책이 처리 규칙(행동 순서, ‘max’ 첫 발견)에 따라 달라지지만 가치 (V^*)는 항상 같음. “유일한 최적”이 아니라 “최적 중 하나”. ‘max’가 첫 최댓값을 반환해 행동 순서 $[0, 1, 2, \dots]$ 에 편향.
- “몇 번이면 끝나는지” 문제 없이 예측한다. $n(m-1)$ 은 최악의 경우 상한. 실제로는 초기 정책에 따라 2번~상한에 가까움까지 다양. “예상 소요 시간”으로 착각하면 큰 MDP에서 당황.

다섯 번째: $\text{delta} < \text{theta}$ (내부 평가 수렴)와 stable (외부 “변화 여부”)는 서로 다른 판정 두 개. θ 를 너무 느슨하게(예: 1) 쓰면 “거의 안 된” V^π 로 개선 → 잘못된 $\arg \max$.

실습: 동점 MDP — 정책은 다르고, V^* 는 유일

“동점이 있으면 결과 정책은 달라져도 **가치는 항상 같다**”를 작은 MDP로 확인. 상태 0이 두 개의 문(행동 0, 1)을 갖고 각각 방 1 / 방 2(각각 +1 주고 **self-loop 종료**)로 가는 3상태 MDP:

```
# 상태 0: 두개의문 . 방 1,2: self-loop 종료()
P[0][0], R[0][0] = [(1.0, 1)], 1.0    # 문 a0 -> 방 1 (+1, 종료)
P[0][1], R[0][1] = [(1.0, 2)], 1.0    # 문 a1 -> 방 2 (+1, 종료)
P[1][0], R[1][0] = [(1.0, 1)], 0.0    # 방 1: self-loop
P[2][1], R[2][1] = [(1.0, 2)], 0.0    # 방 2: self-loop
# 나머지( P, 은 R 0. 방 1는 2 어떤행동을해도자기자신 )

def policy_iteration_tie(P, R, n_actions, gamma, tie_break):
    policy = [0] * n_states
    while True:
        V = policy_evaluation(P, R, policy, gamma)
        stable = True
        for s in range(n_states):
            qs = [R[s][a] + gamma * sum(p*V[ns] for p, ns in P[s][a])
                  for a in range(n_actions)]
            best = max(qs)
            candids = [a for a in range(n_actions) if abs(qs[a] - best) < 1e-12]
            chosen = candids[0] if tie_break == 'first' else candids[-1]
            if chosen != policy[s]:
                policy[s] = chosen
                stable = False
```

동점 실행 결과: 정책 2가지, V^* 1가지

동점 처리	결과 policy	V
'first' (최소 행동 번호)	[0, 0, 0]	[1.0000, 0.0000, 0.0000]
'last' (최대 행동 번호)	[1, 1, 1]	[1.0000, 0.0000, 0.0000]

- 상태 0에서 두 행동: $Q(0, \text{left}) = 1 + 0 = 1$, $Q(0, \text{right}) = 1 + 0 = 1$ — 완벽한 동점.
- 결과 정책은 완전히 다르고([0, 0, 0] vs [1, 1, 1]), V 는 완전히 같다([1, 0, 0]).

유한성 논증이 약속한 그대로

동점 MDP에서 “최적 정책”은 유일하지 않을 수 있다(여기서 2개 이상 공존), 하지만 “최적 가치 V^* ”는 유일. 실전에서 동점이 중요한 이유: (a) 같은 V^* 를 전제로 정책은 추가 기준(더 안전한 행동 선호, 물리적 비용)으로 골라야 하며, (b) “정책이 다르다”는 이유로 “알고리즘 실패”로 판단하면 안 된다 — V^* 가 일치하면 성공.

FAQ

- Q. 정책개선에서 “더 나은 행동”이 여러 개 동점이면? 이론적으로 동점 중 아무거나 골라도 성질(가치 감소 안 함) 유지. 실전: ‘max’가 첫 번째 최댓값 반환 → 순서에 따라 결과 정책은 달라져도 가치(V)는 항상 같음.
- Q. 정책평가를 항상 끝까지(수렴까지) 해야 하나요? 아니다 — 수렴시키지 않고 몇 번만 돌린 뒤 바로 개선해도 결국 최적 정책으로 수렴 (수정된 정책 반복). 극단적으로 딱 한 번만 하면 → 4.3절 가치 반복과 정확히 같아짐.
- Q. “왼쪽” 537 vs “오른쪽” 10 sweep, 같은 알고리즘인데 왜? 평가 단계의 sweep 수가 초기 정책에 따라 달라짐. “왼쪽”은 벽에 붙은 무한 루프를 10^{-6} 까지 풀어내야 133 sweep, “오른쪽”은 5 sweep. 바깥 반복 횟수도 5 vs 2. 두 요인이 곱해져 총 계산량이 초기 정책에 민감.
- Q. 실전에서 어디에 쓰나요? 상태 공간이 작고 P, R 를 정확히 아는 문제(작은 그리드, 재고 관리, 스케줄링)엔 지금도 그대로. “ P 를 모른다”(Ch. 5-7)나 “상태가 너무 크다”(Ch. 9 DQN, Mnih et al., 2015)엔 직접 쓰지 않고, 대신 이 절의 논증 구조(평가→개선→단조 증가→고정점=최적)가 TD·Q-learning의 “왜 수렴하는가” 논의의 뼈대로 재사용. (DQN의 residual 검사 = “Q-망이 벨만 최적방정식을 만족하는가”.)

4.2절 마무리

4.2절에서 만든 것

- ① **정책 반복** = 평가 $\rightarrow$ 개선을 번갈아, “개선이 아무것도 안 바꿀 때” 멈춤.
- ② **정책개선 정리(단조 증가) + 유한성** $\rightarrow$ “멈추면 최적”(멈춤 = 벨만 최적방정식 성립, 해 유일 $\Rightarrow V^\pi = V^*$).
- ③ **수정된 정책 반복**(평가 k sweep + 개선) — $k = 1$ 은 **가치 반복**, $k = \infty$ 는 **정책 반복**. “같은 알고리즘의 k 스펙트럼”.

예습 확인 문제: ① “멈춤 = 벨만 최적방정식 성립” 논증을 세 문장 이내로 요약. ② outer 3에서 $V(2) = -1.9 = -1 + 0.9 \times V(3) = -1 - 0.9$ (“칸 2에서 목표까지 2걸음의 할인 비용”) 검증. ③ $k = 10$ 인 modified_policy_iteration의 총 sweep = $5 \times 10 = 50$, 바깥 반복 **5**(k 와 무관). ④ $\gamma = 0.99$, $\Delta_0 = 13.44$ 에서 $\Delta < 0.01$ 까지 $13.44 \times 0.99^k < 0.01$ 을 log 로 풀면 $k \approx 717$ 바퀴 $\Rightarrow$ 정책 반복도 γ 에 민감.

4.3 가치 반복, 수렴 증명, 그리고 모델 기반이라는 전제

가치 반복: “한 줄 차이”가 최적을 찾는다

가치 반복 (Value Iteration)은 정책평가와 개선을 합쳐서, 평가를 끝까지 수렴시키지 않고 딱 한 번만 하고 바로 개선하는 것을 매 스텝 반복 — 벨만 최적방정식 자체를 반복 대입으로 직접 푸는 것:

```
def value_iteration(P, R, n_actions, gamma, theta=1e-6):
    n_states = len(P)
    V = [0.0] * n_states
    while True:
        delta = 0
        for s in range(n_states):
            v_new = max(R[s][a] + gamma * sum(prob * V[next_s]
                                                for prob, next_s in P[s][a])
                        for a in range(n_actions)) # <- max_a
            delta = max(delta, abs(v_new - V[s]))
            V[s] = v_new
        if delta < theta:
            break
    policy = [max(range(n_actions),
                    key=lambda a: R[s][a] + gamma * sum(prob * V[next_s]
                                                         for prob, next_s in P[s][a]))
              for s in range(n_states)]
    return V, policy
```

“한 줄”의 차이: $a = \pi(s) \rightarrow \max_a$

$a = \text{policy}[s]$ 로 고른 한 행동이 아니라, $\max_a [\dots]$ 로 각 상태에서 가장 좋은 행동을 그때그때 고르는 것이 전부다. 이 “한 줄”이 “주어진 정책을 평가”와 “최적인 정책을 찾기”를 가르는 전부.

4.1절 벨만 연산자 관점에서 더 명확하다:

- **정책평가** = 정책 연산자 T^π 를 반복하는 것: $V \xrightarrow{T^\pi} \dots$
- **가치 반복** = 최적 연산자 $T^*V(s) = \max_a [R + \gamma \sum P V]$ 를 반복하는 것:
 $V \xrightarrow{T^*} V_1 \xrightarrow{T^*} V_2 \rightarrow V^*.$

둘은 4.1절 벨만방정식 2×2 표에서 “기대” 열과 “최적” 열의 차이에 해당.

$T^\pi \rightarrow T^*$: 기대 열 vs 최적 열

벨만 연산자 관점에서: 정책평가 = 정책 연산자 T^π 를 반복($V \xrightarrow{T^\pi} \dots$), 가치 반복 = 최적 연산자 를 반복:

$$T^*V(s) = \max_a \left[R(s, a) + \gamma \sum_{s'} P(s'|s, a) V(s') \right] \quad (V \xrightarrow{T^*} V_1 \xrightarrow{T^*} V_2 \rightarrow V^*)$$

4.1절 2×2 표에서 “기대” 열 vs “최적” 열의 차이에 해당.

T^* 를 k 번 적용 = “ k 스텝만 내다보기”

5칸 GridWorld, $V_0 = [0, 0, 0, 0, 0]$ 로 시작해 T^* 를 한 번씩만(synchronous) 적용:

k	$V_k(0)$	$V_k(1)$	$V_k(2)$	$V_k(3)$
0	0.000	0.000	0.000	0.000
1	-1.000	-1.000	-1.000	-1.000
2	-1.900	-1.900	-1.900	-1.000
3	-2.710	-2.710	-1.900	-1.000
4	-3.439	-2.710	-1.900	-1.000
5	-3.439	-2.710	-1.900	-1.000

지평선이 한 칸씩 넓어지고, $k = 4$ 에서 고정

$V_k(s)$ 의 해석: “ s 에서 출발해 **정확히** k 스텝만 최적으로 행동(이후 보상 0)할 때의 할인 누적 보상”.

- V_1 : “한 걸음만” — 목표(칸 4) 아니면 전부 -1 .
- V_2 : 칸 0,1,2는 두 걸음 안에 못 닿아 -1.9 , 칸 3은 한 걸음이면 목표라 -1 .
- V_3 : 칸 0은 여전히 못 닿아 -2.71 .

지평선(horizon)이 매 스텝 한 칸씩 오른쪽으로 넓어진다



4.1절 “정보는 한 sweep에 한 칸 전파”와 **정확히 같은 현상**. $k = 4$ 가 되면 칸 0에서도 목표까지 거리(4칸)를 다 보게 되어 **고정**(-3.439). $k = 4$ 에서 더 이상 안 변한다 — 목표까지 **최장 거리 4**이므로 “4스텝만”과 “무한히” 보는 것이 **같은 답**.

이 직관의 두 의미

(1) k 가 충분히 크면 V_k 가 V^* 에 수렴 — “왜”가 아니라 “몇 스텝이면”의 눈금자(목표까지 최대 거리 + γ^k 가 충분히 작아질 때까지의 k). (2) “내다보는 스텝 수를 늘려가며 근사”는 Ch. 14 **MPC** (Mayne et al., 2000)과 **동일 사상** — MPC는 매 결정 시점 “앞으로 k 스텝만”을 고르고 k 키울수록 장기 계획 반영, 가치 반복은 k 를 **소수로 키워** $k = \infty (= V^*)$ 까지 달아가는 절차.

실습: 정책반복 vs 가치반복, 같은 고정점

```
V_vi, policy_vi = value_iteration(P, R, n_actions, gamma)
# V          = [-3.439, -2.710, -1.900, -1.000, 0.000] # 정책반복과동일
# policy     = [1, 1, 1, 1, 0]                       # 정책반복과동일
# 반복횟수   : 5
```



(좌) 지평선을 한 칸씩 넓혀가는 과정, (우) 오차 로그 곡선 —
실측 오차(파란 점선)가 바나흐 상한 γ^k (검정) 아래를
따라감.

- 두 알고리즘 모두 **정확히 같은 V^* 와 최적 정책 — 같은 고정점**(벨만 최적방정식) 을 찾아가기 때문(해 유일, 아래 증명).
- “수렴까지 **계산의 성격**”이 다름:
정책반복은 바깥 반복 2번(내부 평가 sweep 총 10) vs 가치반복은 단일 루프 5번.
- **일반적으로**: 정책반복은 바깥 반복은 적지만 각 반복(평가)이 **무거울 수** 있고, 가치반복은 **가볍지만** 반복 횟수가 더 필요할 수 있음. 어느 쪽이 총 계산량이 적을지는 문제마다 다름.

in-place vs synchronous: 여기서 왜 일치하나?

위 value_iteration은 **in-place**(sweep 중에도 갱신된 값을 사용)인데, 이 5칸 예에서는 synchronous와 **매 스텝 값이 정확히 일치** — 위 표의 V_k 행이 바로 두 버전 공통의 추적계적.

이유: 최적 전이가 오른쪽 방향뿐

이 GridWorld의 **최적 전이가 오른쪽 방향만**이므로, sweep을 **0→4 순서**로 돌리면 갱신 정보가 “아직 안 갱신된 → 이미 갱신된 상태로만” 흘러간다(sweep 순서가 정보 흐름과 **반대** 방향).

sweep 순서 = 정보 흐름 방향이면

sweep 순서가 정보 흐름과 **같은** 방향(예: 상태 순서를 4→0 으로 뒤집으면)이면 in-place가 **한 sweep 안에** 정보를 더 멀리 전파해 더 빠르게 수렴할 수 있다 (4.1절). 같은 고정점으로 수렴한다는 보장은 **변하지 않음** — 차이는 속도뿐.

정책반복과 가치반복: “같은 알고리즘의 두 극한”

수정된 정책 반복을 k 에 따라 나열(5칸, 4.2절의 초기 정책 “무조건 오른쪽”에서 출발, V 는 sweep마다 이어서 쓰는 warm start):

k	이름	바깥 반복	총 sweep	결과 $V(0)$
1	가치 반복	5	5	-3.439
2	수정된 정책반복	4	8	-3.439
4	수정된 정책반복	2	8	-3.439
∞	정책 반복	2	10	-3.439

“다른 알고리즘”이 아니라 연속 스펙트럼

가치반복과 정책반복은 따로따로 배운 “다른 알고리즘”이 아니라, **같은 프레임워크의 연속 스펙트럼 양 끝단**이다. k 를 키우면 **바깥 반복은 줄고** 각 반복이 **무거워지며**, 극단 $k = 1$ 이 **가치반복**, $k = \infty$ 가 **정책 반복**.

k 가 적어도 최종 답은 그대로

“평가 횟수 k 가 적다고 최종 답이 안 나온다?”

- $k = 1$ 부터 $k = \infty$ 까지 모두 정확히 같은 V^* 에 도달 — 차이점은 오직 바깥 반복 횟수와 총 sweep 수(= 총 계산량)뿐.
- k 를 줄이면 개선이 “아직 정확하지 않은” V 기준으로 이루어지지만, 정책은 한 번도 나빠지지 않으며(4.2절 단조 증가) 유한한 정책 개수($2^5 = 32$ 개) 안에서 최적 정책에 착근.

실전 표준 트릭

“정확한 답”은 변하지 않으니 총 계산량만 줄이려 k 를 작게(2~10 정도) 잡는다. k 가 너무 작으면 개선의 방향 감각이 떨어져 바깥 반복이 늘고, 너무 크면 각 반복이 비싸지는 — 이 trade-off가 k 라는 하나의 수로 조절되는 구조.

왜 이 반복이 수렴하는가: γ -축소 사상

“적어도 하나의 최적 정책이 항상 존재한다”는 사실은 자명하지 않다 — 어떤 상태에선 π 가, 다른 상태에선 π' 이 나올 수 있어 “모든 정책 중 최댓값”이라는 개념 자체가 무너질 수도 있다.

이 문제는 4.1·4.3절의 우변(벨만 기대·최적방정식)을 하나의 연산자 T 로 보면 풀린다: T 는 γ -축소 사상(contraction mapping)이다 — 임의의 V_1, V_2 에 대해:

$$\|TV_1 - TV_2\|_{\infty} \leq \gamma \|V_1 - V_2\|_{\infty}$$

의미

T 를 한 번 적용할 때마다 두 함수의 (최대) 차이가 최소 γ 배로 줄어든다.

바나흐 고정점 정리

바나흐 고정점 정리 (Banach fixed point theorem)

축소 사상은 항상 **유일한 고정점**을 가지며, **어디서 출발해** 반복해도 **그 고정점에 수렴**한다.

벨만 연산자에 적용하면:

- 벨만 최적방정식을 만족하는 V^* 가 **존재하고 유일**하다.
- **가치 반복**(임의의 값에서 시작해 T 를 반복)이 실제로 **그 값에 도달**한다.
- V^* 를 알면, 각 상태에서 그 max 를 달성하는 **결정론적 정책** π^* 를 만들 수 있다 — 행동 집합이 **유한**하므로 유한집합의 최댓값은 **항상 어딘가에서 달성**된다.

4.2절의 “멈춤 = 최적” 논증이 여기서 완결: 멈춤 조건이 벨만 최적방정식이고, 그 해가 **유일**하니 멈춘 정책의 가치가 바로 V^* 다.

증명은 “존재”이지 “계산 가능성”이 아니다

중요한 구별

이 증명이 보장하는 건 “존재”이지 “계산 가능성”이나 “저장 가능성”이 아니다.

- **바둑**처럼 상태 수가 **초천문학적으로** 많으면 (약 10^{170}), π^* 가 이론적으로 존재해도 모든 상태에 대해 표로 저장하는 것 자체가 불가능. 표 대신 신경망으로 근사하는 방법이 필요 — **Ch. 9 DQN**(Mnih et al., 2015).

같은 수학의 또 다른 얼굴

“반복 대입이 수렴한다”는 증명은, 그래프 위에서 무작위 걷기의 정상분포를 구하는 **PageRank**(Brin & Page, 1998) 알고리즘과 정확히 같은 수학(축소 사상의 반복 적용). (ML1 Ch. 13.3에서 이미 만났다.)

모델 기반이라는 전제: P 를 “정확히” 안다

이번 장의 모든 알고리즘은 전이확률 $P(s'|s, a)$ 를 **정확히 알고 있다는** 전제 위에 서 있다.

이 전제가 뜻하는 것

체스라면 “이 수를 두면 상대는 어떻게 반응할 확률이 얼마인가”를 미리 다 알아야 한다는 뜻.
현실에서는 대부분 이걸 알 수 없다.

- Chapter 5-6은 이 모델을 몰라도 경험만으로 학습하는 방법(몬테카를로, 시간차 학습).
- Chapter 9는 “상태가 너무 커서 표를 못 쓰는” 문제를 신경망 근사로 다룬다.

이 장을 받치는 뼈대

최적해 = 벨만방정식의 고정점. 모델 기반이라는 제약이 있지만, 이후 모든 장의 **기준점**: Ch. 6 TD = 이 반복을 “모델 대신 **경험으로**” 근사한 것, Ch. 9 DQN = 같은 벨만 최적방정식의 고정점을 신경망으로 찾아가는 것.

동적계획법의 핵심 아이디어

“큰 문제 = 작은 부분 문제 + 재귀”

이 패턴은 **컴퓨터공학 전반**에서 반복해서 등장한다. 강화학습은 그 패턴을 “미래의 **불확실한** 보상을 어떻게 **지금** 계산할 것인가”라는 문제에 적용한 것.

- 재귀 구조(벨만방정식)로 **무한한 미래**를 한 스텝으로 압축.
- 그 반복이 **항상 정답에 수렴**한다는 것 자체가, **축소 사상(contraction mapping)**이라는 하나의 수학적 성질로 보장된다.

표준 참고: Sutton & Barto(2018) 4장 “Dynamic Programming” / David Silver UCL 강화학습 강의 / Stanford CS234. 4.1~4.3절의 모든 알고리즘은 “재귀로 큰 문제를 쪼개는” 같은 패턴의 세 가지 변주(기대/최적 $\times V/Q$)일 뿐이다.

연습문제 (핵심 확인)

- ① **(코딩)** 3-state MDP에서 policy_evaluation과 value_iteration (핵심 줄이 빈칸)을 완성 — **차이점 한 줄:** policy_evaluation은 $a = \text{policy}[s]$ 를 따르고, value_iteration은 $\max_a$ 를 취하는 것뿐.
- ② **(손유도, 비순환)** $0 \rightarrow 1 \rightarrow 2$ (종료, 각 보상 -1 , $\gamma = 0.9$) MDP: 터미널 $V(2) = 0$ 부터 **거꾸로 대입(backward induction)**만으로 $V(1) = -1 + 0.9 \times 0 = -1$, $V(0) = -1 + 0.9 \times (-1) = -1.9$ — **연립방정식도 반복도 필요 없는** 특수 경우.
- ③ **(손유도, 축소 사상)** T 가 γ -축소 사상이고 $TV^* = V^*$ 라면, 임의의 초기값 V_0 에서

$$\|V_n - V^*\|_\infty \leq \gamma^n \|V_0 - V^*\|_\infty$$

$\rightarrow \gamma < 1$ 이므로 $\gamma^n \rightarrow 0 \Rightarrow$ **어떤 V_0 로 잡아도 같은 V^* 로 수렴.**

이 세 문제는 4.1절(반복) · 4.2절(수정된 정책 반복) · 4.3절(축소 사상 수렴)의 **핵심 한 줄**을 각각 확인하게 한다.

FAQ: 실전에서 쓰나요?

Q. 실전 강화학습에서 정책반복·가치반복을 직접 쓰나요?

- 조건이 맞으면 쓰인다: 상태 공간이 작고 P, R 을 정확히 아는 문제 (작은 그리드월드, 재고 관리 등)라면 지금도 그대로 — 정확한 최적해를 빠르게 준다.
- 대부분의 실전 문제는:
 - ▶ P 를 모른다(model-free) → Ch. 5-7(경험만으로 학습).
 - ▶ 상태 공간이 너무 커서 표로 나타낼 수 없다 → Ch. 9 DQN(신경망으로 근사).
- 이번 강의 알고리즘들은 “정답이 무엇인지” 를 규명하는 이론적 뼈대로서 이후 모든 강의 기준점 역할.

예습 확인 문제: ① 3-state MDP($0 \rightarrow 1, 1 \rightarrow 2, 2$ 는 종료, 각 보상 $-1, \gamma = 0.9$) — 비순환이므로 터미널부터 거꾸로 대입만으로 $V(2) = 0, V(1) = -1, V(0) = -1.9$ — 연립방정식도 반복도 필요 없다. ②

$\|TV_1 - TV_2\|_\infty \leq \gamma \|V_1 - V_2\|_\infty$ 와 고정점 $TV^* = V^*$ 로부터 $\|V_n - V^*\|_\infty \leq \gamma^n \|V_0 - V^*\|_\infty \rightarrow \gamma < 1$ 이므로 $\gamma^n \rightarrow 0 \Rightarrow$ 어떤 초기값 V_0 로 시작해도 같은 V^* 로 수렴.

4.3절 마무리

4.3절에서 만든 것

- ① **가치 반복** = policy_evaluation의 “한 줄”($a = \pi(s) \rightarrow \max_a$) — 최적 연산자 T^* 를 반복 대입.
- ② T^* 를 k 번 = k 스텝만 내다보기 — 지평선이 한 칸씩 넓어지고, k 가 목표까지 최대 거리에 달하면 고정.
- ③ **바나흐 고정점 정리** — T 가 γ -축소 사상 $\Rightarrow$ 고정점 **유일** + 어디서든 **수렴** $\Rightarrow$ “멈추면 최적” 완결.
- ④ **모델 기반 전제**(P 를 정확히) — 이 장의 모든 알고리즘이 서 있는 땅, 그리고 Ch. 5-6 (model-free) · Ch. 9 (근사)가 채울 빈자리.

4주차 정리

- ① **4.1 벨만방정식을 “풀다”는 = 반복 대입** — 벨만 연산자 T^π 를 같은 값에 대입하면(연립방정식 직접 풀이와 같은 고정점을 찾되, n 이 커지면 반복만이 표준) 초기값에 무관하게 V^π 로 수렴. V^π/Q^π 다리, 그리고 max 한 글자로 가르는 벨만 최적방정식(원리 최적성).
- ② **4.2 정책 반복: “멈추면 최적”** — 평가→개선의 두 단계. 단조 증가(증명은 두 줄) + 유한성 $\Rightarrow$ “개선의 고정점 = 벨만 최적방정식 성립 = V^* ”. k 스펙트럼: $k = 1$ 가치 반복 $\dots$ $k = \infty$ 정책 반복.
- ③ **4.3 가치 반복과 바나흐** — T^* 반복은 “ k 스텝만 내다보기”를 $k = \infty$ 까지. 축소 사상(바나흐 고정점 정리)이 존재·유일성·수렴을 하나의 성질로 보장. “모델 기반” 전제의 한계 = Ch.5-6·9의 동기.

다음 주 — Chapter 5. 몬테카를로 방법

“ P 를 정확히 안다”는 전제를 버린다. 에피소드를 실제로 플레이하며 경험만으로 V^π, Q^π 를 추정하는 방법 — 그리고 이 장이 세운 정답 기준 (벨만 고정점, V^* 표)과 비교하며 model-free 알고리즘의 “정확성”을 평가하는 법.