

시간차 학습 (Temporal-Difference Learning)

TD(0) 한 스텝 갱신 · SARSA와 CliffWalking · Q-learning과 경로 비교

Machine Learning 2 · 6주차

한국과학영재학교 (KSA)

Chapter 6

이번 주차 개요

- **6.1 TD(0)** — 갱신식과 **TD 오차**를 이해하고, 7-state random walk에서 손으로 한 에피소드를 따라가며 MC(불편하지만 분산 큼)와 TD(편향 있되 분산 작음)의 트레이드오프를 설명한다.
- **6.2 SARSA** — 행동을 고르려면 $V(s)$ 만으론 부족하고 $Q(s, a)$ 가 필요한 이유를 설명하고, on-policy 알고리즘 SARSA를 코드로 구현한다.
- **6.3 Q-learning** — $Q(s', a')$ 을 $\max_{a'} Q(s', a')$ 로 바꾼 한 줄의 차이가 on-policy와 off-policy를 가르는 근본 선택임을 설명하고, CliffWalking의 경로 차이(안전 17스텝 vs 최단 13스텝)를 풀이한다.

이 챕터의 두 갈림

“어떤 가치함수를 갱신하느냐”는 6.1→6.2($V \rightarrow Q$), “목표값의 다음 행동을 어떻게 채우느냐”는 6.2→6.3($a' \rightarrow \max$)에서 바뀐다. 이 두 갈림을 붙잡으면 DQN(Ch. 9)·액터-크리틱(Ch. 11)까지 이어지는 on-policy / off-policy의 큰 축이 미리 놓인다.

6.1 TD(0): 한 스텝만 보고 갱신한다, TD vs MC

위치: TD(0)는 DP와 MC의 정가운데

- Ch. 5 MC의 장점은 “모델 불필요”였지만, 대가는 **에피소드 끝까지의 기다림**이었다.
- **시간차 학습**(TD)은 그 기다림 자체를 없앤다 — 한 스텝만 진행하고, “지금 추정치”와 “방금 관찰한 보상 + 다음 상태 추정치”의 차이만큼 **즉시** 갱신.
- 모델도 필요 없고, 끝날 때까지 기다릴 필요도 없다 — 강화학습에서 가장 널리 쓰이는 절충안.

	목표값	대가
DP	기댓값 정확히 계산	모델 P, R 필요
MC	에피소드 끝의 실제 리턴 평균	끝까지 기다림
TD(0)	한 스텝 보상 + 다음 상태 추정치	매 스텝 즉시

“정확한 기댓값”(DP)과 “완전한 샘플”(MC) 사이에서, **덜 정확하지만 훨씬 빨리 도착하는 추정치**를 중간 목표로 쓰는 것.

TD(0) 갱신식

Ch. 4의 벨만방정식 $V^\pi(s) = R(s, \pi(s)) + \gamma V^\pi(s')$ 의 우변 기댓값을, 실제로 한 번 관찰한 **샘플 하나로** 대체한다:

$$V(s) \leftarrow V(s) + \alpha [r + \gamma V(s') - V(s)]$$

TD 오차(TD error)

대괄호 안 $r + \gamma V(s') - V(s)$. “아직 확실하지 않은 추정치를 가지고 스스로를 갱신한다”는 뜻에서 **부트스트래핑**(bootstrapping)이라 부른다.

- MC: 목표 = 실제 리턴 G_t (에피소드 끝까지의 실제 보상 합)
- TD: 목표 = $r + \gamma V(s')$ (한 스텝 실제 보상 + 다음 상태 **추정치**)
- 부트스트래핑 덕분에 **에피소드가 끝나지 않아도**, 심지어 끝이 없는 과업에서도 매 스텝 학습 가능.

7-state random walk — 환경과 참값

- 상태 0 ~ 6이 일렬. 매 스텝 확률 1/2로 좌/우로 1칸 이동.
- 0, 6은 **터미널**. 매 스텝 보상 +1(“아직 끝나지 않은 시간”이 가치에 반영되도록).
- $\gamma = 1$, 정책은 “동전던지기” 고정 — 이번 절은 **예측** 문제(5.1절 MC 예측과 같음).

$V^*(i)$ 는 i 에서 출발해 0 또는 6에 닿을 때까지의 **보상 총합** = **기대 흡수 시간**. 대칭적 무작위 유량의 표준 결과로,


$$V^* = [0, 5, 8, 9, 8, 5, 0] \quad (T_i = i(6 - i))$$

검산: $V_i = 1 + \frac{1}{2}V_{i-1} + \frac{1}{2}V_{i+1}$ 에 $V_3 = 1 + \frac{1}{2}(8 + 8) = 9$ 성립. 직관도 정확히 맞다 — 가장 멀리서도 3스텝, 양 끝으로 가장 빠르게 빨려가는 상태 3이 최고 가치 9.

손계산: 첫 에피소드 $3 \rightarrow 4 \rightarrow 5 \rightarrow 6$

$\alpha = 0.5$, 초기 $V = [0, 0, 0, 0, 0, 0]$, 운 좋게 오른쪽 끝에 한 번에 닿는 에피소드. 실제 리턴 $G = +3$. 매 스텝 $r = 1, \gamma = 1$:

스텝	전이	목표 $r + \gamma V(s')$	갱신
t	$3 \rightarrow 4$	$1 + 0 = 1$	$V(3) \leftarrow 0.5$
$t+1$	$4 \rightarrow 5$	$1 + 0 = 1$	$V(4) \leftarrow 0.5$
$t+2$	$5 \rightarrow 6(\text{터미널})$	$1 + 0 = 1$	$V(5) \leftarrow 0.5$



한 스텝 전이에서 실제 보상 r (파랑)과 부정확한 추정치 $V(s')$ 이 목표값 $r + \gamma V(s')$ 에서 만난다 — 에피소드가 끝나지 않았는데도 $V(4)$ 를 0.5로 갱신한다.

첫째 — 한 에피소드 만에 “방향”은 맞췄지만 “크기”는 틀림 (참값 $9 \cdot 8 \cdot 5$ 에 $0.5 \cdot 0.5 \cdot 0.5$).

MC라면 이 한 에피소드에서 $V(3) = V(4) = V(5) = G = 3$ 로 한 번에 갱신(매방문, $\alpha = 1$). 둘 다 참값과 멀지만, MC = “unbiased한 큰 점프”, TD = “biased한 작은 점프”.

둘째: 정보 전파와 셋째: 로컬성

- **둘째 — 정보 전파.** 에피소드 종료 직후 $V(5) = 0.5$ 가 “알려진 사실”이 되자, **다음에** 상태 4가 방문되면 목표값이 $1 + V(5) = 1.5$ 로 **자동으로** 커진다.
- 5의 갱신된 정보가 4의 다음 목표에, 4의 정보가 3의 목표에 — **한 스텝씩, 시간차로** 전파. 이 현상이 바로 “Temporal-Difference”의 **본체**.
- MC엔 이런 전파가 불필요 — 에피소드 끝에서 G 를 **일괄** 알려주기 때문. 대신 매번 “끝”을 기다리는 대가.
- **셋째 — 갱신 목표는 에피소드와 무관.** $4 \rightarrow 5$ 스텝의 목표 $1 + V(5) = 1$ 은 이 에피소드가 끝내 얼마를 주느냐를 **아무것도** 반영하지 않는다.

로컬성: 부트스트래핑의 힘이자 약점

그 스텝에서 관찰된 r 과 그 순간의 추정치 $V(5)$ 만으로 목표가 정해진다. 약점(편향)이 어떻게 “분산이 작음”으로 환원되는지 숫자로 확인한다.

TD vs MC: 편향과 분산

	몬테카를로	시간차 학습(TD)
목표값	실제 리턴 G_t (끝까지)	$r + \gamma V(s')$ (한 스텝+추정치)
갱신 시점	에피소드 종료 후	매 스텝 즉시
편향/분산	편향 없음(불편), 분산 큼	편향 있음(추정치 사용), 분산 작음

- MC의 G_t 는 실제로 관찰된 보상의 합이라 편향이 없으나, 에피소드 하나가 **긴 시퀀스의 모든 확률성**을 통째로 담고 있어 분산이 크다.
- TD의 목표값은 $V(s')$ 이 **아직 부정확한 추정치**라 편향이 있으나, 한 스텝의 무작위성만 반영해 분산이 훨씬 작다.

Ch. 4.1의 편향-분산 트레이드오프가 여기서도 다른 형태로 다시 등장한다.

목표값 분포를 숫자로: 1000 에피소드

7-state random walk에서 두 방법의 **목표값 분포**를 실제 펼쳐보기 (노트북, 시드 42, 상태 3에서 1000에피소드):

방법	$V(3)$ 추정	쓴 목표값	목표값의 산포
MC(매방문)	≈ 9.3	리턴 G	평균 9.3, 표준편차 ≈ 7.3 , 범위 3~51
TD(0), $\alpha=0.1$	≈ 10.0	$1 + V(s')$	평균 7.6, 표준편차 ≈ 3.0 , 범위 1~11.7
참값 $V^*(3)$	9	—	—

- MC의 각 목표값(리턴)은 **에피소드 전체의 운**을 담는다 — 3스텝에 끝나기도, 51스텝을 방황하다 끝나기도.
- TD의 각 목표값은 “보상 1 + 옆 상태 추정치”뿐 — V 가 자리를 잡으면 5~10의 좁은 범위에서만 다님(표준편차는 MC의 절반 이하).

“TD의 분산이 작다”는 무엇이나

- 표의 “분산 큼/작음”은 갱신 한 번에 쓰이는 목표값이 얼마나 흔들리느냐의 이야기.
- 초기 $V(s') = 0$ 이라 TD 목표값이 1로 시작해 범위가 1~11.7까지 벌어지지만, 표준편차는 MC의 절반 이하.
- 편향 쪽도 숫자로: 첫 에피소드에서 상태 4의 목표값 $1 + V(5) = 1$ 은 참값 8과 **크게** 어긋남.

부트스트래핑의 가격표

$V(s')$ 가 부정확한 한, TD의 목표값은 참값을 **체계적으로 어긋나 있는**(= 편향된) 상태다. MC의 목표값 G 는 어떤 에피소드가 아무리 운이 없어도 **평균으로는 정확하다**(불편). “작은 분산”을 얻는 대가로 “임시적인 편향”을 쓴다 — 그리고 그 편향은 V 가 수렴할수록 **자동으로 사라진다**.

최종 추정치 전체의 산포는 α 스케줄과 샘플 수의 문제 (아래 “자주 하는 실수” 세 번째에서 계속).

TD 오차: “예측 오차”로 읽는 갱신식

$$V(s) \leftarrow V(s) + \alpha \underbrace{\left[r + \gamma V(s') - V(s) \right]}_{\text{TD 오차 } \delta}$$

- 상태 s 에 도착했을 때 “여기서는 대략 $V(s)$ 값이다”라고 **예측**한다.
- 한 스텝 진행 뒤, 관찰한 r 과 도착 상태의 추정치 $V(s')$ 을 합치면 **사후** 평가 $r + \gamma V(s')$ 이 생긴다.
- 두 것의 차이가 예측 오차:

$$\delta = \underbrace{r + \gamma V(s')}_{\text{사후 평가}} - \underbrace{V(s)}_{\text{사전 예측}}$$

- $\delta > 0$: “예상보다 좋았다” → 추정치 **올림**. $\delta < 0$: “예상보다 나빴다” → **내림**.
- 손계산 첫 에피소드: 세 스텝 모두 $\delta = 1 - 0 = +1$ — “0으로 예측해 두었는데 목표값이 1이라 전부 기대 이상”.

$\delta = 0$ 인 지점: 벨만방정식

- $\delta = 0 \iff V(s) = r + \gamma V(s')$ (확률적 환경에선 기댓값으로) — 이 바로 **벨만 기대방정식**.
- 즉 “TD 오차가 계속 0이 되는 상태” = 벨만방정식의 해 = **참값** V^π .
- Ch. 4.3의 바나흐 고정점 정리가 “해는 유일하고 이 반복은 그 해로 수렴”을 **모델 기반** 반복에 대해 보장했던 원리가, 여기서는 “샘플로 추정치 갱신을 반복하면 고정점으로 수렴한다”로 다시 나옴.

이 신호는 책의 마지막까지

“예측 오차 신호”는 Ch. 11 액터-크리틱의 **크리틱의 오차** (어드밴티지)로 이어지는 TD 오차의 일반화다.

처음엔 모든 상태가 “낙관적으로” 갱신당하고, 이후 “실망”하는 갱신($\delta < 0$)이 섞이면서 참값을 향해 수렴한다.

실습: 7-state random walk에서 TD(0)

노트북 핵심은 다음 함수 **하나**. 세 줄의 코드가 전부다:

```
import random

def td0_random_walk(seed=42, n_episodes=1000, alpha=0.1, gamma=1.0, start=3):
    rng = random.Random(seed)
    V = [0.0] * 7 # 터미널 V(0)=V(6)은=0 항상고정
    for _ in range(n_episodes):
        s = start
        while s not in (0, 6):
            sp = s + rng.choice([-1, 1])
            r = 1.0 # 매스텝 +1
            V[s] += alpha * (r + gamma * (0.0 if sp in (0, 6) else V[sp]) - V[s])
            s = sp
    return V

V = td0_random_walk()
print([round(v, 2) for v in V]) # 참값 [0, 5, 8, 9, 8, 5, 예0] 가까움
```

코드 세 줄 읽기 — “모델이 없다”는 뜻

- (1) $sp = s + \text{rng.choice}([-1, 1])$ — 환경의 유일한 무작위성.
- (2) $V[s] += \alpha * (\dots)$ — TD(0) 갱신식 자체.
- (3) $(0.0 \text{ if } sp \text{ in } (0, 6) \text{ else } V[sp])$ — **터미널 처리**.

“모델을 쓰지 않는다”는 것의 의미

우리가 $P(s' | s)$ 를 알고 있느냐는 이 예제에서는 부차적. 알고리즘이 갱신식에 쓰는 것은 **실제로 관찰된** (s, r, s') 한 줄뿐이다.

- “모델이 없다” = 확률을 **사용하지 않고** 배운다는 것이지, 확률을 모른다는 뜻이 **아니다**(여기는 알고 있다).
- 확률이 알려졌다면 이 예제에서는 Ch. 4의 DP가 더 효율적 — TD의 가치는 확률을 **모를 때**에 있다. 그 “모를 때”의 표준 예제 **CliffWalking**은 6.2절에서 만난다.

고정점: TD(0)는 어디로 수렴하나

V 가 더 이상 움직이지 않는(고정점) 지점에서 목표값 $r + \gamma V(s')$ 가 $V(s)$ 와 **항상** 같아야 하므로, 고정점은 π 의 벨만 기대방정식의 해 $= V^\pi$. (여기서는 정책이 동전던지기 하나뿐 — “더 나은 정책으로의 개선”은 6.2절 이후.)

MC의 수렴 조건

- 에피소드가 **유한**히 끝나고
- 모든 상태가 **충분**히 방문

(불편한 샘플 평균이므로)

TD(0): MC보다 한 가지 까다로움

- 에피소드가 유한한 것
- 모든 상태가 **무한**히 방문
- 학습률 α 가 **적절**히 줄어드는 것

Robbins-Monro 조건

$\sum_k \alpha_k = \infty$ 이고 $\sum_k \alpha_k^2 < \infty$. 이유(Ch. 2 증분 평균의 직관): α 가 계속 크면(예: 항상 0.5) 잡음이 섞인 목표값이 계속 들어와, 추정치가 참값에 “착지”하지 못하고 **주위를 맴돈다**.
노트북에서 $\alpha = 0.5$ vs 0.1 비교 — 0.5 쪽이 참값 9 근처에서 더 크게 흔들린다.

자주 하는 실수 (1/2)

- **터미널로 들어가는 마지막 스텝을 갱신하지 않는다.** if $sp \in (0, 6)$: break 를 갱신 앞에서 처리하면, 보상을 실제로 준 마지막 전이(예: $5 \rightarrow 6$)의 상태 5가 **영원히** 갱신되지 않는다 — “끝이 어디인가”가 가장 강하게 알려지는 전이인데.

정답: 갱신을 먼저, 종료 판단을 나중에 `done = (sp in (0,6)); V[s] += ...; if done: break` (6.2절 SARSA 코드도 “갱신 $\rightarrow$ break” 순서)

- $\alpha = 1$ 을 “가장 빠르니까” 쓴다. $V(s)$ 가 목표값으로 **통째** 대체됨 — “증분 평균”이 아니라 “마지막 관찰 기억”. 잡음이 큰 목표값(리턴 범위 3~51의 MC 등)을 쓰면 추정치가 **마지막 한 번의 운**에 끌려다닌다. “분산이 작다”는 표의 결론은 $0 < \alpha < 1$ 의 **증분 평균**이 전제일 때 성립한다.

자주 하는 실수 (2/2)

- “TD가 MC보다 정확하다”로 “분산이 작다”를 기억한다. 고정 α 의 TD는 참값에 정확히 착지하지 않는다(편향 + 떨림). MC는 불편하고, 샘플이 무한히 모이면 정확히 V^π 로 수렴. “TD의 목표값 분산이 작다” = 같은 수의 스텝을 버는 동안 갱신 한 번의 흔들림이 작다 — “최종 오차가 반드시 작다”는 뜻이 아니다. 최종 품질은 α 스케줄과 방문 횟수의 문제.
- $V(s')$ 를 “갱신 전 값”으로 쓰겠다며 순서를 걱정한다. 위 코드는 in-place 방식(에피소드 내 이미 갱신된 값이 있으면 그것을 쓴다). 수렴 정리는 보통 synchronous(전체 복사본)로 서술되지만, 실장에서는 in-place가 표준이고 수렴에 해가 되지 않는다. “어느 쪽이 정확한가”를 묻지 말고, 한 가지를 고르고 일관되게 쓰면 된다.

확인 문제

- ① (손계산) 7-state random walk, $\alpha = 0.5$, $V_0 = 0$. 첫 에피소드 $3 \rightarrow 4 \rightarrow 5 \rightarrow 6$. (a) 갱신 직후 $V(3)$, $V(4)$, $V(5)$ 는? (b) **다음** 에피소드에서 4가 다시 5로 이동할 때 목표값은 얼마로 바뀌는가? 이 차이가 정보 전파의 어떤 방향($5 \rightarrow 4$?)을 보여주는가? (c) 같은 에피소드를 MC(매방문, $\alpha = 1$)로 처리했으면?
- ② (개념) “TD의 분산이 작다”에서 분산의 대상이 **목표값**임을 숫자(MC 리턴 범위 3~51, $\sigma \approx 7.3$ vs TD 목표값 $\sigma \approx 3.0$)로 설명하라. “MC는 편향이 없다”의 **정확한** 조건(무엇의 평균, 언제 성립)은?
- ③ (코드 진단) break가 갱신 **앞**에 있는 루프 (다음 프레임) — 어떤 상태의 학습을 빼먹게 되는가?

확인 문제 3: 코드 진단

루프의 문제를 찾아, 그것이 **어떤 상태의 학습**을 빼먹게 되는지 설명하라:

```
while s not in (0, 6):  
    sp = s + rng.choice([-1, 1])  
    r = 1.0  
    if sp in (0, 6):  
        break  
    V[s] += alpha * (r + gamma * V[sp] - V[s])  
    s = sp
```

- **힌트:** break는 $V[s] += \dots$ 전에 있다. $5 \rightarrow 6$ 스텝의 갱신은 어디에 갔는가?
- (4) (개념) $\gamma = 0$ 이면 갱신식은 $V(s) \leftarrow V(s) + \alpha(r - V(s))$ 로 줄어든다. $V(s')$ 이 목표값에 들어오지 않는다는 직관을 바탕으로, 이 환경의 참값 $V^*(i)$ 가 모든 내부 상태에서 맞는지 구하고, “내다보기 0스텝”이라는 표현과 어떻게 일치하는지 설명하라.

역사: “Temporal-Difference” 이름의 유래

- 이름은 갱신식 구조를 그대로 번역: 추정치가 **시간 방향**으로 **차이**를 만드는 것 — $V(s')$ (시각 $t+1$)과 $V(s)$ (시각 t)의 **차**가 갱신을 이끈다.
- MC = “현재 추정치” vs “에피소드 끝의 실제 리턴”, DP = “현재 추정치” vs “정확한 기댓값”.
- TD는 “현재 추정치” vs **한 스텝 앞의 추정치** — “시간의 차이”가 목표값 재료가 되는 **유일한** 방법.

1983, mountain car

Barto·Sutton·Anderson(1983)의 *Neural learning of the optimal way to climb a mountain car*에서 처음 제안. **mountain car** 문제: 계곡 바닥의 자동차가 모멘텀을 만들어 언덕 중 어느 쪽이든 올라가게. 물리 모델이 복잡해 DP로 정확히 풀기 어렵고, MC처럼 에피소드를 기다리면 너무 느린 — **정확히 TD가 필요한** 환경.

1984년 Sutton 박사논문(CMU, 지도 A. Barto)이 체계화 → 1989년 Watkins의 Q-learning → 2013년 DQN(Ch. 9) — 모든 off-policy TD 학습의 뼈대가 이 “한 스텝의 차이”에 놓여 있다.

자주 묻는 질문 (1/2)

- **Q. “TD(0)의 (0)”은?** 한 스텝만 앞을 내다보고 바로 부트스트래핑(0-step lookahead 이후 부트스트랩). Ch. 7의 n -step TD는 n 스텝 실제 관찰 후 부트스트랩: $n = 1$ 이면 TD(0), $n = \infty$ (끝까지)면 사실상 MC.
- **Q. 부정확한 $V(s')$ 를 쓰는데도 왜 정확히 수렴하나?** 처음엔 $V(s')$ 이 부정확하나, 매 갱신마다 그 오차가 TD 오차만큼 줄고, 줄어든 값이 다시 다음 목표값에 쓰이면서 오차가 **전체적으로** 계속 줄어든다 — Ch. 4.3 바나흐 고정점과 같은 원리(차이: 샘플 기반).
- **Q. 에피소드 내 갱신 순서(in-place)가 결과에 영향?** 단기적으로는 조금, 수렴 결과(고정점)에는 영향 없음. synchronous와 in-place는 둘 다 같은 고정점 V^π 로 수렴 — 일관되게 한 방식을 쓰면 된다.

자주 묻는 질문 (2/2)

- **Q. “Temporal difference”가 실제로 차이를 이루는 양은?** $\delta = r + \gamma V(s') - V(s)$ 안에서 $V(s') - V(s)$ 가 “ $t+1$ 추정치와 t 추정치의 차”. 관찰된 r 에 더해 **인접한 두 시점의 가치 추정치의 차**가 학습 신호를 만든다. MC(리턴과 추정치의 차)와 DP(정확한 기댓값과 추정치의 차)는 이 “차”의 한쪽을 추정치가 아닌 것으로 채우므로 “temporal difference”라 부르지 않는다.
- **Q. 정책이 하나뿐이라 “예측”만 하고 “개선”은 안 하나?** 그렇다 — 이번 절(5.1절 MC 예측과 함께)은 **정책 예측** 문제. “더 나은 정책으로 갈아타기”는 6.2절에서 $V(s) \rightarrow Q(s, a)$ 로 바꾸고, 행동 선택이 $\arg \max_a Q(s, a)$ 로 읽히는 순간부터. TD 갱신식 뼈대는 **전혀** 바뀌지 않는다 — 바뀌는 것은 “어떤 가치함수를 갱신하느냐”뿐.

6.2 SARSA와 CliffWalking 실습

$V(s)$ 에서 $Q(s, a)$ 로

- Ch. 4의 $V(s)$ 는 “상태의 가치”. 이것만으론 **다음 행동을 고를 수 없다** — 어느 행동이 좋은 다음 상태로 이어지는지 알려면 전이확률 P 가 필요(Ch. 5.2에서 짚은 이유).
- 그래서 TD도 $V(s)$ 대신 한 걸음 더 세분화한 **Q-함수** $Q(s, a)$ 를 학습: “상태 s 에서 a 를 한 뒤, 그 이후 정책을 따랐을 때의 기대 누적 보상”.

벨만방정식과 같은 방식으로 정의 — 다음 상태를 **행동 a 로** 이동한다는 것만 다름:

$$Q^\pi(s, a) = R(s, a) + \gamma \sum_{s'} P(s' \mid s, a) V^\pi(s')$$

V 와 Q 의 관계 — 한 줄

$V^\pi(s) = \sum_a \pi(a \mid s) Q^\pi(s, a)$: **상태 가치는 그 상태의 행동 가치들의 정책가중 평균**. Q 를 알면 V 는 이 평균으로 바로 얻어지지만, 반대(V 에서 행동을 고르는 것)는 P 가 필요 — Q 가 이득.

탐욕 정책: Q표에서 바로 행동이 읽힌다

Q를 V 없이, Q만으로 쓰면:

$$Q^\pi(s, a) = R(s, a) + \gamma \sum_{s'} P(s' | s, a) \sum_{a'} \pi(a' | s') Q^\pi(s', a')$$

- “어떤 행동을 고를지”도 Q표에서 바로 — **탐욕 정책** (greedy policy):

$$\pi(s) = \arg \max_a Q(s, a)$$

- Q를 학습한다 = “가치 평가”와 “행동 선택”을 **한 표로** 모두 해결.

작은 예 — Q표의 모양을 잡자

상태 셋 장난감 MDP: $A(\text{출발}) \cdot B \cdot G(\text{도착, 터미널})$. A 에서 $\text{right} \rightarrow -1$ 로 B , $\text{down} \rightarrow$ 절벽 -100 받고 A 로. B 에서 $\text{right} \rightarrow G(\text{보상 } 0, \text{종료})$. $\gamma = 1$.

작은 예: backward induction

거꾸로 계산하면:

$$Q^*(B, \text{right}) = 0, \quad Q^*(A, \text{right}) = -1 + 1 \cdot 0 = -1$$

$$Q^*(A, \text{down}) = -100 + Q^*(A, \text{right}) = -101$$

(절벽에서 A로 돌아와 다시 최선의 right를 고르는 것까지 포함)

- A의 두 행동: -1 대 -101 — 어떤 행동이 좋은지가 표의 한 행에 그대로 적혀 있다.
- V만 있었다면 “어느 행동이 나은지”를 알기 위해 각 행동을 P 로 시뮬레이션 해야 하는데, Q 는 바로 그 비교의 결과를 미리 계산해 두어 있다.
- 이 장난감에서 A에 서 있는 “절벽 바로 위” 처지가, 이번 절의 CliffWalking에서 SARSA가 학습할 처지와 정확히 같은 구조.

SARSA: 실제로 고른 행동을 쓴다

SARSA(State-Action-Reward-State-Action) — 이름 자체가 갱신에 필요한 다섯 요소를 그대로 나열. 실제로 다음에 **고른** 행동 a' 의 Q값을 목표로 TD 갱신:

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma Q(s', a') - Q(s, a)]$$

다섯 요소는 **한 줄의 궤적**에서 온다:

- s, a — 현재 상태와 거기서 **행동 정책(behavior policy, 여기서는 ϵ -greedy)으로 고른 행동**.
- r, s' — 환경이 **관찰되게** 주는 보상과 다음 상태.
- $a' - s'$ 에 **도착한 뒤에** 다시 같은 행동 정책으로 고르는 행동.

앞의 네 개는 “경험”, 마지막 a' 는 “다음에도 지금 같은 방식으로 행동하겠다”는 선택이 갱신식에 반영되는 지점 — 이 “**실제로 고른 것을 쓴다**”는 점이 **SARSA**를 정의한다.

SARSA 코드

```
import random

def epsilon_greedy(Q, s, epsilon, n_actions):
    if random.random() < epsilon:
        return random.randrange(n_actions)
    return max(range(n_actions), key=lambda a: Q[s][a])

def sarsa_train(env_step, n_states, n_actions, n_episodes, alpha, gamma,
                epsilon, start_state):
    Q = [[0.0] * n_actions for _ in range(n_states)]
    for _ in range(n_episodes):
        s = start_state
        a = epsilon_greedy(Q, s, epsilon, n_actions)
        for _ in range(200):
            ns, r, done = env_step(s, a)
            na = epsilon_greedy(Q, ns, epsilon, n_actions)
            Q[s][a] += alpha * (r + gamma * Q[ns][na] - Q[s][a]) # 실제로고른 na
            s, a = ns, na
            if done:
                break
    return Q
```

SARSA는 지금 실제로 따르는 정책(탐험을 포함한 ϵ -greedy 그 자체)의 가치를 학습한다 —

무엇에 수렴하나: Q^b 이지 Q^* 가 아니다

TD 오차가 0이 되는 지점을 찾으면, SARSA 갱신식의 고정점은 행동 정책 b 의 벨만 기대방정식 — $Q(s, a)$ 정의식에서 정책이 ϵ -greedy인 경우:

$$Q(s, a) = R(s, a) + \gamma \sum_{s'} P(s' \mid s, a) \sum_{a' \sim b} Q(s', a')$$

핵심

SARSA가 수렴하는 곳은 b 정책 자체의 Q-함수 Q^b 이지, 최적의 Q^* 가 아니다. “내가 지금 이렇게(탐험까지 포함해) 행동할 때의 가치”를 배우는 것.

이 구분이 CliffWalking에서 어떤 **경로 차이**로 이어지는지 아래 실습에서 구체적으로 본다.

CliffWalking 환경

Gymnasium의 CliffWalking-v1 — 4×12 격자에서, 출발점 바로 옆 한 줄이 **전부 절벽**(밟으면 -100 을 받고 출발점으로 회귀). 목표까지의 최단길이 정확히 절벽 바로 옆을 스치는 길이라, “짧지만 위험한 길” vs “길지만 안전한 길”의 선택이 극명하게 드러남.

항목	내용
상태	48개 (0~47), $(row, col) = \text{divmod}(s, 12)$
행동	4개: 0=위, 1=오른쪽, 2=아래, 3=왼쪽
출발/목표	$(3, 0) = 36$ / $(3, 11) = 47$ (터미널, 보상 0)
절벽	$(3, 1) \sim (3, 10)$ — 밟으면 $-100 + (3, 0)$ 회귀
벽 밖 이동	그 자리에 남고 보상 -1
시간 벌점	이동 자체에도 매 스텝 -1

두 후보 경로 — 그리고 절벽은 최선이 아니다

- **짧은 길** ($\gamma = 1$ 최적): $(3, 0) \rightarrow (2, 0) \rightarrow (2, 1) \rightarrow \dots \rightarrow (2, 11) \rightarrow (3, 11)$, **13스텝**, 리턴 -12. 절벽(3행) **바로 위**(2행)를 통째로 스침.
- **안전한 길**: 절벽에서 두 칸 이상 떨어질 만큼 위쪽(0~1행)을 돌아가는 **17스텝**, 리턴 -16.

“절벽 자체가 최선”인 정책은 존재하지 않음

$\gamma = 1$ 최적 Q값에서 절벽 바로 위 (2, 1)의 Q(위,오른쪽,아래,왼쪽) = -12, -10, -112, -12 — down(절벽)은 압도적으로 나쁨. $\gamma = 0.99$ 로 바꾸면 -11.4, -9.6, -111.3, -11.4 — 수치는 달라져도 “절벽 행동의 Q가 ≈ -111 로 벌어진다”는 구조는 동일.

즉 **모든** 합리적 정책은 절벽을 밟지 않되, “절벽 옆을 스치느냐, 멀리서 돌아가느냐”가 유일한 선택지 — 이 선택이 on-policy(SARSA)와 off-policy(Q-learning)에서 **다르게** 풀린다.

SARSA 실습 코드

```
import gymnasium as gym

env = gym.make("CliffWalking-v1")
n_states, n_actions = env.observation_space.n, env.action_space.n

def sarsa_train_gym(env, n_episodes, alpha, gamma, epsilon):
    Q = [[0.0]*n_actions for _ in range(n_states)]
    for ep in range(n_episodes):
        s, _ = env.reset(seed=ep)
        a = epsilon_greedy(Q, s, epsilon, n_actions)
        for _ in range(500):
            ns, r, term, trunc, _ = env.step(a)
            na = epsilon_greedy(Q, ns, epsilon, n_actions)
            Q[s][a] += alpha*(r + gamma*Q[ns][na] - Q[s][a])
            s, a = ns, na
            if term or trunc:
                break
    return Q
```

결과 (500에피소드, $\alpha = 0.5$, $\gamma = 1.0$, $\epsilon = 0.1$, 시드 42):

- 마지막 100에피소드 **평균 리턴** ≈ -31 수준.
- 학습 끝난 Q표로 **탐욕적**($\epsilon = 0$) **롤아웃**하면 **17스텝** — **절벽을 피하는 안전 경로**.

배운 Q표: 경로를 읽어보자

1000에피소드 주 학습 결과. 두 칸만 떼어내도 스토리가 읽힌다:

상태	Q(위)	Q(오른쪽)	Q(아래)	Q(왼쪽)
(3, 0) 출발	-21.2	-124.7	-27.2	-35.5
(2, 1) 절벽 옆	-17.1	-59.0	-146.5	-20.1

- (3, 0)에서 right = -124.7 — “여기서 절벽 방향으로 가겠다는 가치에 **추락 위험 전체**가 가격에 들어 있다” (ϵ -greedy 관점의 가치 평가).
- (2, 1)에서 down = -146.5는 -100보다도 작음 — 추락 후 **출발점으로 돌아가 다시 걸어와야 하는** 대가까지 반영된 값.

Q-table learned by SARSA (1000ep, $\epsilon=0.1$, seed 42) — color: max_a Q(s,a) (darker = lower), arrows: greedy actions, blue: learned path, red dashed: $\gamma=1$ optimal 13-step path



칸 색 = $\max_a Q(s, a)$ (어두울수록 낮음), 화살표 = 탐욕 행동. 파랑 실선 = SARSA가 배운 17스텝 안전 경로, 빨강 점선 = $\gamma = 1$ 최적 13스텝 경로. 검은 칸 = 절벽.

왜 안전 경로인가 — 메커니즘 1: 탐험 위험이 가격에

ϵ -greedy 정책의 “가치”에 탐험 위험이 이미 가격으로 포함되어 있다. SARSA는 Q^b (행동 정책 b 의 Q함수)를 학습 — 절벽 옆 칸에서 “오른쪽”의 기대값은 그 다음 칸에서 ϵ -greedy가 실제로 무엇을 고를지를 기대값으로 반영해야 한다. 절벽 바로 위에서는 그 기대에 “무작위로 down을 고르고 추락한다”는 시나리오가 $\epsilon \times \frac{1}{4}$ 만큼 섞인다.

근사 계산(4행동, $\epsilon=0.1, \gamma=1$, 추락 후 리턴 무시)	값
---	---

한 스텝에서 추락할 확률	$0.1 \times \frac{1}{4} = 0.025$
짧은 길 13스텝 중 절벽 바로 위 칸	10스텝 $((2, 1) \sim (2, 10))$
한 에피소드에서 최소 1번 추락할 확률	$1 - (1 - 0.025)^{10} \approx 0.22$
짧은 길의 ϵ -greedy 기대 리턴	$\approx 13(-1) + 0.22(-100) \approx -35$
안전한 길	$\approx 17(-1) \approx -17$

같은 짧은 길을 걸어도, 탐험이 섞인 정책으로 걸으면 -35 로, 안전 길로 걸으면 -17 로 안는다.

왜 안전 경로인가 — 버그가 아니라 정석

핵심 판단

SARSA가 “탐험 포함 정책의 리턴”을 평가하는 알고리즘이므로, -17 을 -35 보다 큰 가치로 판단하고 안전하게 돌아가는 경로를 배우는 것은 **버그가 아니라 정석**.

- **메커니즘 2: 실제 추락 스텝이 Q표를 직접 뒤흔들다.** 추락이 반복될 때마다 절벽 옆 칸들의 Q값은 ≈ -109 쪽으로 계속 갱신당하고, 그 칸들에 기대를 걸던 “절벽 옆을 따라 가자” 전략의 Q값도 부트스트랩을 통해 함께 낮아진다.
- $(2, 0)$ 에서 right의 목표값 $-1 + \gamma \mathbb{E}_{a' \sim b}[Q(s', a')]$ 안에는 2.5%의 $Q(s', \text{down}) \approx -109$ 가 섞여 있다.

“절벽 옆을 따라 걷기”의 가치에 추락 위험이 **스스로 반영**되는 구조다. (위 메커니즘 1과 아래 손계산이 이 구조의 숫자.)

손으로 한 스텝: 무작위 down이 골랐을 때

$s = (2, 1)$ (절벽 맨 왼쪽 칸 바로 위), $Q(s) = [\text{위} - 1, \text{오른쪽} - 1, \text{아래} 0, \text{왼쪽} - 1]$. $\varepsilon = 0.1$ -greedy가 무작위로 down을 고름 $\rightarrow$ 절벽, $r = -100$, $s' = (3, 0)$ 회귀.

$Q(s') = [\text{위} - 2, \text{오른쪽} - 5, \text{아래} - 9, \text{왼쪽} - 4]$, s' 에서 무작위 행동이 또 down이라 $a' = \text{down}$ 이 실제로 골라짐. $\alpha = 1, \gamma = 1$.

SARSA — 실제로 고른 a' 의 값을 쓴다:

$$\text{목표} = -100 + (-9) = -109$$

$$Q(s, \text{down}) \leftarrow 0 + 1 \cdot (-109 - 0) = -109$$

Q-learning(비교용) — 최선의 값을 쓴다:

$$\text{목표} = -100 + \max(-2, -5, -9, -4) = -102$$

$$Q(s, \text{down}) \leftarrow -102$$

본질


한 번의 갱신 차이는 7에 불과. 하지만 본질은 “7의 차이”가 아니라, **SARSA의 목표값에 “실제로 나쁜 행동을 고른” 사건 자체가 들어갔느냐다.**

학습 곡선: 추락이 사라지는 과정

1000에피소드, 시드 42, $\epsilon = 0.1$ 고정:

- 첫 100에피소드 평균 리턴 약 -65 → 마지막 100에피소드 약 -19로 상승.
- 절벽 추락이 한 번 이상 일어난 에피소드 비율: **28%** → **0%**로 떨어짐.
- 곡선 아래로 툭툭 떨어지는 -100 이하 리턴 = “아직 안전 경로를 모르니 절벽 옆을 시험하다 떨어진다”.
- 후반 추락 소멸 = “절벽 옆 칸들의 Q값이 뚝 떨어졌으니 이제 그 옆을 안 간다”는 학습의 결과.

SARSA learning curves on CliffWalking (seed 42)



이 학습 곡선은 6.3절의 Q-learning과 같은 환경에서 나란히 비교된다.

ϵ 감쇠: 경로의 모양까지 바뀐다

같은 SARSA를 $\epsilon : 0.3 \rightarrow 0.01$ (에피소드마다 $\times 0.997$)로 감쇠시키며 1000에피소드 학습:

- 마지막 100에피소드 평균 리턴 ≈ -16 .
- 최종 경로가 달라진다 —
 - ▶ $\epsilon = 0.1$ 고정: 절벽 옆 칸 (2, 1)을 한 번 스침.
 - ▶ decay: $(3, 0) \rightarrow (2, 0) \rightarrow (1, 0) \rightarrow (1, 1) \rightarrow (0, 1) \rightarrow \dots$ — 절벽 옆 칸을 하나도 스치지 않음.

왜

SARSA가 “탐험이 섞인 정책의 가치”를 배우는 알고리즘이므로, 학습 중의 ϵ 이 어떤 값을 갖고 있었는가가 배운 경로의 모양을 결정한다. (decay가 Q-learning에서 어떤 역할을 하는지는 6.3절에서 같은 환경으로 다시 본다.)

자주 하는 실수 (1/3)

- 갱신 뒤 $s, a = ns, na$ 를 $s = ns$ 만 하면 **“SARSA”가 아니다**. 다섯 번째 요소 a' 는 “다음 상태에서 실제로 고른 행동”. s 는 갱신하고 a 를 안 하면, 다음 `env.step(a)`는 새 상태에 옛 행동을 실행하게 되고, 이전 갱신의 목표값에 쓰인 $Q(s', na)$ 는 실제로 이어지는 궤적과 맞지 않게 된다. (s, a, r, s', a' 가 한 줄의 실제 전이를 나타내지 않으면, 그 갱신은 “한 적도 없는 경로”의 가치를 학습시킨다.)
- **“ γ 는 항상 1보다 작아야 한다”고 배운다**. 에피소드 과업(유한히 끝나는 CliffWalking처럼)에서는 리턴이 원래 유한하므로 $\gamma = 1.0$ 도 문제없다 — 이 실습도 6.3절과 비교 가능하게 $\gamma = 1.0$ 사용. “ $\gamma = 1$ 이면 무한 리턴의 합이 발산”이라는 걱정은 끝이 없는 **continuing 과업**의 이야기.

자주 하는 실수 (2/3): 학습 도중 리턴

- “**학습 도중 리턴이 낮으면 학습이 안 된 것**”이라고 판단한다. SARSA의 학습 도중 리턴은 **행동 정책(ϵ -greedy)의 리턴**이지, 배운 정책의 품질이 아니다.
- 이번 절의 SARSA는 학습 내내 17스텝 안전 길을 걸어 리턴이 -17 근처를 맴돌지만, **배운 정책 자체는 전혀 문제없다.**
- “배운 정책이 좋은가”를 판정하려면 $\epsilon = 0$ **탐욕적 롤아웃**을 봐야 한다.

이 구분이 중요한 이유

“**학습 도중 리턴(행동 정책)**” vs “**탐욕적 롤아웃(배운 정책)**”의 구별은 6.3절의 “자주 하는 실수”에서 Q-learning과 나란히 다시 다뤄진다.

확인 문제

- 1 SARSA 갱신식 $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma Q(s', a') - Q(s, a)]$ 의 다섯 요소 (s, a, r, s', a') 중 환경이 “관찰”로 주는 것과 에이전트가 “고르는” 것은 각각 무엇인가? 그리고 a' 를 이동 **후** s' 에서 고르는 것이 아니라, 이동 **전**에 고른 a 를 그대로 a' 로 써버리면 고정점이 더 이상 어떤 실제 정책의 벨만방정식도 아닌 이유를, “ s' 에서 정책이 실제로 고릴 행동 분포”와 비교해 설명하라.
- 2 (수치) $\varepsilon = 0.1$, 4개 행동, $\gamma = 1$. (a) 한 스텝에서 무작위 행동이 down일 확률은? (b) 짧은 길 13스텝 중 절벽 바로 위 10스텝을 지나며, 한 에피소드에서 **최소 1번** 절벽을 밟을 확률을 추정하라. (c) (b)를 써서 짧은 길의 ε -greedy 에이전트 한 에피소드 기대 리턴을 근사(추락 후 리턴 무시)하고, 안전 길(-17)과 비교해 “SARSA가 짧은 길을 피하는 이유”를 한 문장으로 완성하라.

확인 문제 3: 코드 진단

아래 SARSA 루프의 문제를 찾아, 그것이 어떤 잘못된 학습 데이터를 만들어내는지 설명하라:

```
for _ in range(500):  
    ns, r, term, trunc, _ = env.step(a)  
    na = epsilon_greedy(Q, ns, epsilon, n_actions)  
    Q[s][a] += alpha*(r + gamma*Q[ns][na] - Q[s][a])  
    s = ns          # ←무엇을빼먹었는가 ?  
    if term or trunc:  
        break
```

- **힌트:** 갱신식에는 na 가 쓰이지만, 루프 상태는 $s = ns$ 만 갱신된다. 다음 `env.step(a)`에서 실행되는 a 는 어느 상태의 행동인가?

역사: SARSA의 이름과 CliffWalking의 유래

- **Q-learning** — 1989년 Chris Watkins 박사 논문(6.3절에서 더 다룸).
- **SARSA** — 1994년 케임브리지 Rummery와 Niranjan의 *On-line Q-learning using Connectionist Systems*. 제목이 말해주듯 당시엔 Q-learning의 “온라인(실시간 버전)”으로 포지셔닝.
- 훗날 남게 된 이름 = 갱신에 필요한 다섯 요소(현재 **State**·**Action**·**Reward**, 다음 **State**·**Action**)를 그대로 나열한 S-A-R-S-A.

1990년대 초: on/off-policy는 아직 중앙 개념이 아니었다

SARSA = “TD로 행동을 학습하는 **그냥** 방법”, Q-learning = “거기에 max을 집어넣은 **수정**”으로 제시. 그런데 “그냥 방법”과 “수정”이 **다른 고정점** (Q^b vs Q^*)에 수렴한다는 사실이 Sutton-Barto 교과서(1998)에서 **CliffWalking 예제**와 함께 정형화되면서, 비로소 강화학습을 지배하는 **근본 축**이 됨.

이 실습의 CliffWalking-v1은 정확히 그 교과서 예제 — 40년 넘게 “on-policy vs off-policy를 보여주는 표준 실험”.

자주 묻는 질문 (1/2)

- **Q. ϵ -greedy는 Ch. 2.1의 그 함수와 완전히 같은 건가?** 그렇다 — 밴딧에서 “가장 좋아 보이는 팔을 $1 - \epsilon$ 로, 무작위 팔을 ϵ 로 고른다”던 전략을, “팔” 대신 “행동”, “추정 보상” 대신 “Q값”에 그대로 적용. 밴딧이 상태가 하나뿐인 특수한 MDP(Ch. 3.1 FAQ)라는 관점에서 이 재사용은 우연이 아니다.
- **Q. SARSA는 왜 매 스텝(온라인) 학습하나?** TD(0)의 정의 자체가 “한 스텝만 보고 즉시 갱신”(6.1절) — SARSA는 그 TD(0) 갱신을 $V(s)$ 대신 $Q(s, a)$ 에 적용한 것뿐. 같은 이유(끝날 때까지 기다릴 필요 없음)로 매 스텝 즉시.

자주 묻는 질문 (2/2)

- **Q. 안전한 경로를 배운 것이 “위험 회피(risk-averse)”인가?** 기술적으로는 아니다 — SARSA에는 “위험 회피 효용함수” 같은 것이 없다. 다만 **탐험이 섞인 정책의 리턴을 평가**하는 알고리즘이므로, “절벽에 떨어질 확률”이 그 기대값의 한 항으로 **자동으로** 들어온다. 위험 회피로 **보이는** 것은 on-policy 성격의 **부수적 결과**. (진짜 “떨어질 확률 자체를 최소화” 목표가 필요하다면 기대 리턴이 아닌 다른 목표(예: CVaR)를 설계해야 — 이 강의 범위 밖.)
- **Q. $\gamma = 1.0$ vs 0.99 어느 것을?** 에피소드 과업에선 둘 다 문제없다. $\gamma = 1$ = “보상이 언제 와도 동등하게 평가”, 0.99 = “가까운 보상을 아주 조금 더 좋아한다”. 이 실습은 6.3절 비교를 위해 $1.0 - 0.99$ 로 바뀌도 “절벽 회피”라는 질적 구조는 동일.

6.2 소결 — SARSA가 답하는 질문

“지금 실제로 이렇게(**탐험을 포함해**) 행동할 때, 이것이 얼마나 좋은가”를 평가 — 실제로 고른 행동을 TD 목표값으로 써 **행동 정책 자기 자신**의 질문에 답. 그 “답”의 모양 = 절벽을 피하는 **17스텝** 안전 경로, Q표 숫자($-124.7, -146.5$)에 그대로 읽힘. 다음 6.3절은 이 갱신식의 한 항 $Q(s', a')$ 을 max으로 바꿔, 질문이 “**이상적인** 정책은 얼마나 좋은가”로 바뀔 때 경로를 본다.

6.3 Q-learning과 SARSA · Q-learning 경로 비교

위치: TD(0)는 두 갈래로 갈라진다

- 6.1: TD(0)는 “한 스텝만 보고, 다음 상태의 **추정치**로 부트스트랩”. 6.2: 그 갱신을 $Q(s, a)$ 에 적용한 **SARSA**.
- 의문: SARSA 갱신식에서 다음 행동의 Q값을 **어떤** 행동의 Q값으로 썼는가?

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma Q(s', a') - Q(s, a)]$$

여기서 a' 는 **실제로 고른** 다음 행동.

갈림길

이 “실제로 고른 것”을 그대로 쓴다는 선택이 지금 6.3절의 갈림. **Q-learning**은 이 한 칸만 다르게 채운다 — 실제로 무엇을 골랐든 상관없이, **다음 상태에서 최선의 행동**을 가정하고 그 Q값을 목표로. 이 한 줄의 차이($Q(s', a')$ vs $\max_{a'} Q(s', a')$)가 두 알고리즘을 근본적으로 갈라놓으며, “실제 행동하는 정책의 가치”를 배우느냐 vs “이상적인 최적 정책의 가치”를 배우느냐의 문제로 이어진다.

Q-learning: 모델 없이, 최선의 다음 행동을 가정

실제로 무엇을 골랐든 상관없이, **항상 다음 상태에서 최선의 행동을 가정**하고 그 Q값을 목표로:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

```
def q_learning_update(Q, s, a, r, s_next, alpha, gamma):  
    max_next_q = max(Q[s_next].values()) if isinstance(Q[s_next], dict) \  
        else max(Q[s_next])  
    td_error = r + gamma * max_next_q - Q[s][a]  
    Q[s][a] += alpha * td_error  
    return Q
```

Q-learning은 행동 정책이 무엇이든(ϵ -greedy로 무작위 탐험을 섞어도) **목표 정책**(최적 정책)의 가치를 직접 학습 — Ch. 5.3의 언어로 **off-policy**. $Q(s, a)$ 를 알면 최적 정책은 $\pi^*(s) = \arg \max_a Q(s, a)$ 로 **즉시** 얻어진다.

왜 max인가 — 같은 경험, 다른 목표값

SARSA와 Q-learning 갱신식은 $r + \gamma(\dots)$ 의 괄호 안 **한 항만** 다르다. 그 차이가 얼마나 근본적인지, **같은 한 스텝**에 대해 두 알고리즘이 각각 어떤 목표값을 계산하는지 숫자로:

손으로 한 스텝: s 에서 a 를 하고 $r = -1$ 받아 s' 로. s' 에서 두 행동 a_1, a_2 : 현재 $Q(s', a_1) = 0, Q(s', a_2) = 5$. ϵ -greedy가 무작위로 a_1 (Q값 0인 “나쁜” 행동)을 고름. $\alpha = 0.5, \gamma = 1.0$, 갱신 중인 $Q(s, a) = 0$.

SARSA(실제로 고른 a_1 사용):

$$\text{목표} = -1 + 1.0 \times 0 = -1$$

$$Q(s, a) \leftarrow 0 + 0.5(-1 - 0) = -0.5$$

Q-learning(최선 $\max = 5$ 사용):

$$\text{목표} = -1 + 1.0 \times 5 = +4$$

$$Q(s, a) \leftarrow 0 + 0.5(4 - 0) = +2.0$$

부호가 다르다

같은 경험에 대해 SARSA는 -0.5 로, Q-learning은 $+2.0$ 로 갱신. 이 차이가 곧 두 알고리즘이 “배우는 것”의 차이 — 6.2절 CliffWalking에서 이 차이가 **경로의 모양**으로 드러난다.

max 뒤에 숨은 “낙관적 부트스트래핑”

$\max_{a'} Q(s', a')$ 을 쓰는 것은 단순히 “더 큰 수를 쓰는 것”을 넘어서, **아직 한 번도 고르지 않은 행동의 가치까지 갱신에 끌어들이는** 효과가 있다.

- 위 손계산에서 a_2 는 이 스텝에서 실제로 **고르지 않았**는데도, Q-learning의 목표값에 $Q(s', a_2) = 5$ 가 들어갔다.
- 즉 다음 상태의 “최선”이라는 **가정 하나로, 실제로 겪지 않은 경로의 가치까지** 지금 추정치에 반영.

이 “가정”은 **두 날을 가진 칼**이다:

- **장점 — 탐험을 가속.** 아직 시도하지 않은 행동이 “좋은 것 같으면” 그 $Q(s', a')$ 가 높게 부트스트랩되어 $\arg \max_a Q(s, a)$ 가 곧바로 그 행동을 가리키게 되어 탐험이 자연스레 유도됨. SARSA처럼 “실제로 고른 것”만 갱신하면, 한 번도 시도하지 않은 행동은 **영원히 낮은 Q값**에 머물러 탐험이 더딤.
- **단점 — 낙관론이 위험을 과소평가.** “다음 상태에서 최선은 a_2 일 것이다”라는 가정이, 실제로 ϵ -greedy가 가끔 “나쁜” a_1 을 고를 수 있다는 **현실을 무시**. CliffWalking에서 Q-learning이 “절벽 바로 옆” 최단 경로를 선호하는 이유가 바로 이 낙관론 — “다음 칸에선 최선을 고를 테니 위험한 칸 옆을 지나도 된다”는 가정이, 학습 도중에는 실제로 절벽에 떨어지는 사고로 이어진다.

on-policy vs off-policy: 같은 데이터, 다른 대상

	행동 정책 b	목표 정책 π	갱신에 쓰는 다음 행동	이름
SARSA	ε -greedy	같은 ε -greedy	실제로 고른 a'	on-policy
Q-learning	ε -greedy	탐욕적 ($\varepsilon = 0$)	$\arg \max_{a'} Q(s', a')$	off-policy

핵심

행동 정책(b , 실제로 행동을 고르는 정책)과 **목표 정책**(π , 가치를 평가/학습하려는 정책)의 관계로 표현: $b = \pi$ 이면 on-policy, 다르면 off-policy. SARSA = “내가 지금 이렇게(탐험 포함) 행동할 때”의 가치를 배우고, Q-learning = “나는 항상 최선만 고를 텐데”라는 **이상적 정책**의 가치를 배운다.

왜 중요도 샘플링이 필요 없는가 — 5.3절 연결

- Ch. 5.3: off-policy MC는 행동/목표 정책의 **리턴 분포**가 다르므로 중요도 가중치 $\rho = \prod_t \pi(a_t | s_t) / b(a_t | s_t)$ 로 보정해야.
- 그런데 Q-learning은 off-policy임에도 **중요도 샘플링을 쓰지 않는다**.

이유

Q-learning은 “목표 정책의 **리턴 분포**를 샘플로 추정”하는 것이 아니라, **벨만 최적방정식의 고정점**을 샘플로 근사하기 때문. $\max_{a'} Q(s', a')$ 라는 목표값 자체가 “목표(탐욕적) 정책이었다면 다음에 이렇게 갔을 것”을 **직접** 부트스트랩 하므로, 행동 정책이 실제로 어떻게 움직였는지에 대한 보정(가중치)이 구조적으로 불필요.

MC는 “리턴을 평균”해야 하므로 보정 필요, TD는 “한 스텝 목표값”을 쓰므로 보정 불필요 — 같은 off-policy 문제를 **분포 보정(중요도 샘플링)**과 **고정점 근사(부트스트래핑)**라는 전혀 다른 두 도구로. 이것이 Ch. 9(DQN)에서 경험재현 버퍼(다른 정책이 모은 데이터를 재사용)를 자유롭게 쓸 수 있는 이유이기도 하다.

같은 CliffWalking에서 SARSA와 Q-learning을 각각 500에피소드 ($\alpha = 0.5, \gamma = 1.0, \varepsilon = 0.1$) 학습(스크래치패드 실행 검증):

SARSA	-31.46
Q-learning	-53.33

SARSA가 배운 정책	-17.0
Q-learning이 배운 정책	-13.0

■ SARSA (17스텝, 안전)
■ Q-learning (13스텝, 최단)
■ 절벽

두 숫자는 **각각 다른 방향**으로 읽어야 한다 —
아래 두 프레임에서.

읽기 1: 학습 후 탐욕적 실행(-17 vs -13)

- Q-learning이 배운 정책이 절벽 바로 옆을 스치는 **더 짧은**(13스텝) 경로를 찾았다 — 목표 정책(탐욕적) 관점에서는 이게 **진짜 최적**이기 때문.
- 그림에서 Q-learning의 빨강 경로는 절벽(검정) 바로 위를 13스텝으로 지나고, SARSA의 파랑 경로는 절벽에서 한 칸 이상 떨어질 만큼 위쪽으로 올라가 17스텝을 걸어서 간다.
- **목표(탐욕적) 정책으로만 보면**, Q-learning의 13스텝이 **진짜 최단**.

읽기 2: 학습 중 평균 리턴(-31 vs -53)

- 학습 **도중**에는(여전히 ϵ -greedy로 가끔 무작위 행위가 섞이는 상황) 오히려 **SARSA가 더 좋은 성적**.
- Q-learning이 배우려는 “절벽 바로 옆 최단 경로”는 탐험으로 인한 무작위 행동 한 번이 바로 **절벽 추락(-100)**으로 이어지는 위험한 경로.
- SARSA는 **자신이 실제로 행동하는 방식**(탐험 포함)까지 감안해 가치를 매기므로 그 위험을 자연스럽게 피하는 경로를 선호.
- 같은 $\epsilon = 0.1$ 이여도, “절벽 옆을 스치는 경로”를 걷는 동안에는 무작위 행위가 절벽으로 빠질 **확률**이 “위쪽을 우회하는 경로”보다 훨씬 높으므로, 학습 도중의 평균 리턴은 SARSA가 유리.

핵심: 답하는 질문이 다르다

Q-learning vs SARSA

Q-learning = “**이상적으로 항상 최선을 다한다면**”이라는 가정 아래 최적 경로를 찾고, SARSA = “**실제로 가끔 실수(탐험)할 수 있다**”는 현실을 감안한 경로를 찾는다. 어느 쪽이 “더 낫다”가 아니라, **애초에 답하는 질문이 다르다**.

- 실전 선택 기준:
 - ▶ “**학습 도중에도 안전이 중요한가**”(로봇 제어처럼 실제 사고가 나면 안 되는 경우) → **SARSA** 계열 선호.
 - ▶ “**학습은 시뮬레이터에서 안전하게, 최종 배포만 최적이면 되는가**” → **Q-learning**도 무방.
- **학습 도중 리턴의 격차(-31 vs -53)를 “학습이 잘 되고 있다”는 지표로 쓰지 말 것.** 이 격차는 두 알고리즘이 **다른 정책을 평가**하고 있기 때문이지, Q-learning이 더 “나쁘게” 학습해서가 아니다. 오히려 최종(탐욕적) 리턴에서는 Q-learning이 앞선다.

off-policy 학습을 모니터링할 때는 “**학습 도중의 행동 리턴**”이 아니라 **목표 정책으로 평가한 리턴**($\epsilon = 0$ 롤아웃, 또는 별개 평가 정책의 리턴)을 보라는 교훈 — 이 “평가 정책과 학습 정책을 분리해서 보는” 습관이 Ch. 9(DQN)과 Ch. 11(PPO)의 학습 곡선 읽기로 이어진다.

ϵ 을 줄여가며: 탐험에서 착취로

5.2절 MC 제어에서 ϵ 을 에피소드가 진행됨에 따라 줄여가며 학습(ϵ -decay)하는 것을 봤다. Q-learning에서도 decay가 **같은 역할**: ϵ 을 처음엔 크고(탐험 많이), 나중에 0으로(착취, exploitation) 줄이면:

학습 초반(ϵ 큼)

- 거의 모든 행동이 시도되어 Q 값들이 충분히 방문.
- $\max_{a'} Q(s', a')$ 가 **믿을 만한** 값이 됨.
- 수렴 조건의 “모든 (상태, 행동) 쌍이 무한히 방문”을 실질적으로 만족.

학습 후반($\epsilon \rightarrow 0$)

- 행동이 거의 탐욕적.
- 학습 도중 리턴이 최종 성능을 반영.
- Q-learning은 여기서 “절벽 옆 최단 경로”를 **안정적으로** 학습.

반면 ϵ 을 0.1로 **고정**하면: SARSA는 “탐험이 영원히 섞인” 정책의 가치를 계속 갱신해 **절벽을 피하는 경로에 머물러** 있고, Q-learning은 “탐험이 조금씩 섞이더라도 최선을 고를 테니”라는 낙관론으로 절벽 옆을 스치는 경로를 학습. **decay의 유무가 “배우는 정책”에 따라 배운 경로의 모양까지 바꾼다.**

자주 하는 실수 (1/2)

- **max을 $Q[s_next][a_next]$ 로 써서 “Q-learning” 이라고 생각한다.** $\max_{a'} Q(s', a')$ 의 max은 다음 상태 s' 의 모든 행동 a' 에 대한 최대이지, 실제로 고른 a' 의 값이 아니다. 실제로 고른 a' 의 값을 쓰면 그것이 SARSA다.

코드로: $\text{target} = r + \gamma \max(Q[ns])$ (Q-learning) vs $\text{target} = r + \gamma Q[ns][na]$ (SARSA) — **max()의 유무**가 두 알고리즘을 가르는 전부. na를 max 안에 잘못 넣거나 빼먹으면 둘 다 아닌 “어중간한 경로”(절벽도 안 피하고, 최단 길로도 안 감)를 만든다.

- **터미널 상태에서 max을 계산한다.** 목표(종료) 상태에서는 다음 상태가 없으므로 $\max_{a'} Q(s', a')$ 는 0이어야. $\max(Q[goal])$ 를 0이 아닌 값으로 쓰면 “한 번 더” 갱신되어 리턴에 실제로 존재하지 않는 미래 보상까지 더하는 오차. 항상 $\text{max_next_q} = \max(Q[ns])$ if not done else 0.0 처럼 done 플래그로 0을 강제.

자주 하는 실수 (2/2)

- **“Q-learning이 항상 더 낫다”고 배운다.** 핵심은 두 알고리즘이 다른 질문에 답한다는 것 — “Q-learning이 SARSA보다 좋다”는 진술은 애초에 성립하지 않는다. 학습 도중의 안전이 중요한 환경(로봇 제어)은 SARSA, 시뮬레이터에서 학습한 뒤 최종 성능만 중요한 환경은 Q-learning. “어느 쪽이 좋다”가 아니라 **“어떤 질문을 하고 있는가”**를 먼저 물어야.
- **학습 도중 리턴(-31 vs -53)을 “학습 품질”로 해석.** -31 / -53은 **행동 정책(ϵ -greedy)**의 리턴이지 **목표 정책의 리턴**이 아니다. Q-learning이 “더 나쁘게” 학습한 것이 아니라, “더 위험한 (그러나 최종적으로는 더 짧은) 경로”를 탐험하며 배우는 과정에서 중간 성적이 나빠진 것. 학습 품질 판단은 **탐욕적($\epsilon = 0$) 롤아웃**의 리턴에서 — 그곳에서는 Q-learning(-13)이 SARSA(-17)보다 낫다.

확인 문제

- 1 SARSA 갱신식과 Q-learning 갱신식 중 **SARSA**에 해당하는 코드를 골라라: (a) $Q[s][a] += \alpha(r + \gamma Q[ns][na] - Q[s][a])$ (b) $Q[s][a] += \alpha(r + \gamma \max(Q[ns])) - Q[s][a]$. 고른 답에 대해 on-policy인지 off-policy인지, na (실제로 고른 다음 행동)가 목표값에 포함되는지를 근거로 설명하라.
- 2 위 “손으로 한 스텝”에서 $Q(s', a_1) = 0$, $Q(s', a_2) = 5$ 대신 $Q(s', a_1) = Q(s', a_2) = 3$ (두 행동 Q값이 같음)이었다면, SARSA와 Q-learning은 **같은** 목표값을 계산하는가? 같은 경험을 받았을 때 두 갱신식의 차이가 $Q(s', \cdot)$ 의 값 분포에 따라 어떻게 달라지는지 설명하라. (힌트: $\max$ 가 “실제로 고른 것”과 언제 일치하고 언제 다른가?)
- 3 CliffWalking에서 $\varepsilon = 0$ (탐험 없음)로 고정하고 학습시켰다면, SARSA와 Q-learning이 배운 경로는 **같은가?** 이유를, “행동 정책 = 목표 정책”인 경우 on/off-policy 차이가 소멸한다는 관점에서 설명하라. (힌트: $\varepsilon = 0$ 이면 “실제로 고른 a' ”와 “ $\arg \max_{a'} Q(s', a')$ ”이 언제나 같은 행동.)

역사: 이름 붙이기가 차이를 요약한다

- **Q-learning** — 1989년 Chris Watkins 박사 논문. “Q”는 행동가치함수 $Q(s, a)$ (어원: Quality, “상태-행동 쌍의 품질”)에서 — “Q-함수를 **샘플만으로** 학습하는” 알고리즘.
- **SARSA** — Q-learning에 대해 “max를 쓰지 말고 **실제로 고른 다음 행동**의 Q값을 쓰자”는 단순한 수정. 이름 = 갱신에 필요한 다섯 요소(S-A-R-S-A)를 그대로 나열.

이름 붙이기가 차이를 요약

Q-learning은 **무엇을** 배움(모델 없이 Q-함수)에 초점, SARSA는 **어떻게** 갱신(실제 행동을 따름)에 초점. 같은 TD(0) 뼈대 위에, “max를 넣느냐/넣지 않느냐” 한 줄이 **off-policy(이상적) / on-policy(현실)** — 강화학습을 지배하는 **가장 근본적인 축**을 만들어냄.

이후 DQN(Ch. 9, off-policy) · 정책기반(PPO 등, Ch. 11) · Actor-Critic (온/오프 혼용)까지, “행동 정책 vs 목표 정책”이라는 이 분류가 계속 다시 등장한다.

자주 묻는 질문 (1/2)

- **Q. 학습 후 ϵ 을 0으로 낮추면 SARSA도 결국 짧은 길을 택하나? 아니다** — SARSA가 학습한 Q값 자체가 “탐험이 있는 상황”을 전제로 계산된 값이라, 그 Q값 기준으로 탐욕적으로 행동해도 **여전히 안전한(먼) 경로**를 선호하는 정책이 나온다. Q값을 다시 학습시키지 않는 한, ϵ 을 실행 시점에만 낮춰도 저장된 Q값 자체는 바뀌지 않는다.
- **Q. 실전에서 하나를 골라야 한다면?** 먼저 “학습 자체가 실제 위험한 환경에서 일어나는가”(로봇이 실제로 넘어지거나 다칠 수 있는 상황)를 물어라 — 그렇다면 **SARSA**류가 유리. 반대로 시뮬레이터에서 안전하게 충분히 학습한 뒤 배포 시 **최적 성능만** 중요하다면, 목표 정책 자체의 최적성을 직접 학습하는 **Q-learning** 같은 off-policy 방법이 유리.

자주 묻는 질문 (2/2)

- **Q. Q-learning의 max**은 “다음 상태의 모든 행동”에 대한 건데, 행동이 연속이거나 매우 많으면? 이 강의의 **Table Q-러닝**(행동을 이산적으로 열거)에서는 max이 유한한 표에서 최대를 찾는 단순 연산. 행동 공간이 연속(로봇 각도·속도)이거나 매우 크면 표 자체가 불가능해져 **함수 근사**(Ch. 9 DQN)로 넘어가야 — 이때 $\max_a Q(s', a)$ 는 “함수 $Q(s', a)$ 를 행동 a 로 관해 최대화”로 일반화. 원리는 같고, “표에서 max”가 “최대화(optimization)”로 바뀐.
- **Q. 둘 다 수렴하나, 하나만? 둘 다**, 같은 조건(모든 (상태, 행동) 쌍이 무한히 방문 + α 가 Robbins-Monro)이면. 다만 수렴하는 값이 다르다: Q-learning은 Q^* (최적 행동가치), SARSA는 ϵ -greedy 행동 정책 자체의 Q^π . “둘 다 수렴”이라 해도 도달하는 지점이 다르다 — “다른 질문”이 수렴 결과값으로도 나타난다.

왜 Q-learning이 수렴하는가 (직관)

- Ch. 4.3: $Q^*(s, a)$ 는 유한한 MDP라면 반드시 존재하고 **유일**(벨만 최적방정식, 바나흐 고정점 정리).
 - Q-learning은 그 값을 직접 계산하지 않고 **샘플 기반 업데이트만으로** 근사하는데도, 정확히 그 값에 도달한다는 것이 증명됨:
 - ▶ 충분히 모든 상태-행동 쌍을 **무한히 방문**하고
 - ▶ 학습률 α 를 **적절히 줄여**나가면
- 참값 $Q^*(s, a)$ 로 수렴(Robbins-Monro).
- 직관: **TD 오차가 0이 되는 지점**이 정확히 벨만 최적방정식을 만족하는 지점 $\rightarrow$ TD 오차를 계속 줄여나가는 업데이트는 결국 그 고정점으로 수렴.

SARSA의 수렴 직감도 똑같이

다만 고정점이 Q^* 가 아니라 ϵ -**greedy 정책의** Q^π . SARSA의 TD 오차 0인 지점은 $Q(s, a) = r + \gamma \mathbb{E}_{a' \sim b}[Q(s', a')]$ (행동 정책 b 의 다음 행동에 대한 **기대**, max이 아님) = 그 행동 정책의 벨만 **기대**방정식.

6.3 소결: 같은 부트스트래핑, 다른 고정점

- “TD 오차 0 = 해당 고정점”이라는 **같은 논리**가, max(Q-learning) vs **기대**(SARSA)라는 목표값의 차이에 따라 **다른 고정점**(Q^* 최적 vs Q^π 정책특정)으로 귀결.

이 챕터의 한 줄

시간차 학습은 MC의 “모델이 필요 없다”는 장점과 DP의 “한 스텝만 보고도 갱신한다”는 장점을 하나로 합친 것. Q-learning과 SARSA의 차이는, 똑같은 부트스트래핑 아이디어를 “**이상적인 목표 정책**”에 적용하느냐 “**실제 행동 정책**”에 적용하느냐 — **아주 작지만 결과는 크게 갈리는 선택.**

이번 주차 정리

- ① **TD(0)는 DP와 MC의 정가운데** — 모델 없이, 한 스텝 보상 + 다음 상태 추정치로 매 스텝 즉시 갱신(부트스트래핑). MC(불편, 분산 큼) vs TD(편향, 분산 작음)의 트레이드오프는 “갱신 한 번의 목표값 흔들림”의 차이.
- ② **SARSA = on-policy** — 실제로 고른 다음 행동 a' 를 목표에 써, 행동 정책 b 자체의 Q^b 를 학습. CliffWalking에서는 탐험 위험이 ϵ -greedy 가치에 가격으로 들어와 **절벽을 피하는 17스텝** 안전 경로를 배움.
- ③ **Q-learning = off-policy** — a' 를 $\max_{a'}$ 로 바꾼 한 줄이 on/off-policy를 가르치는 전부. “이상적인 최선만 고를 텐데”라는 낙관적 부트스트래핑으로 **절벽 옆 13스텝** 최단 경로를 배움. 학습 도중 리턴(-31 vs -53)은 **다른 질문**의 결과이지 품질이 아님.

다음 주 — Chapter 7. n-step TD와 적격흔적

TD(0)는 한 스텝만, MC는 끝까지 — “몇 스텝을 실제로 볼 것인가” 라는 하나의 다이얼 위의 양 끝. Chapter 7은 이 다이얼의 모든 지점을 아우르는 **n-step 부트스트래핑**과 **적격흔적**(eligibility traces)을 다루고, 경험뿐 아니라 **학습된 모델**까지 함께 쓰는 계획(planning, Dyna-Q)으로 나아간다.