

Block A 캡스톤: 팀 프로젝트와 총정리

팀 프로젝트 구조와 발표 · Peer-Review · 중간고사 대비

Machine Learning 2 · 8주차

한국과학영재학교 (KSA)

Chapter 8

이번 주차 개요

- Chapter 2~7: 밴딧, MDP, DP, MC, TD, n-step — 표 기반(tabular) 강화학습 이론 전체를 훑었다.
- 이번 장은 **새 개념 0개** — 그 이론을 Gymnasium의 표 기반 환경에서 **직접 구현·비교**하고, 중간고사를 준비하는 장.
- **역전**: 환경·알고리즘·시드를 고르는 것, 그리고 **심사자가 되는 것**까지가 이번 주.

이 챕터를 마치면

- 두 개 이상 알고리즘을 **시드 ≥ 3 + greedy ($\epsilon = 0$) 평가 분리** 프로토콜로 비교·보고 (8.1).
- 결과를 Ch 2~7 개념(on/off-policy, 편향-분산)으로 **수식적으로 정당화**, 잘 안 된 부분까지 숨기지 않고 진단 (8.1).
- 4항목 체크리스트로 다른 팀 발표를 심사, **3점(반박 가능한) 질문**을 작성 (8.2).
- 손유도 템플릿 3종의 빈칸을 스스로 채우고, 20문항 자가진단으로 준비도를 재봄 (8.3).

8.1 팀 프로젝트: 구조와 발표

왜 지금 프로젝트를 하는가

- Ch 2~7: 밴딧 → n-step TD · Dyna-Q까지 표 기반 RL 이론을 손에 쥐 — Sutton & Barto 표준 교과서와 거의 1:1.
- 지금까지 해본 것: “**교재가 고른 환경, 교재가 고른 파라미터, 교재가 고른 시드**”에서 코드가 동작하는지 확인.
- 지금 필요한 것: 한 단계 위로 — **환경을 고르고, 알고리즘 두 개를 고르고, 결과가 흔들리면 시드와 프로토콜을 점검해서 다시 고르는 것까지.**
- “코드가 동작한다”는 증거 $\neq$ “이 문제를 내가 설계하고 평가할 수 있다”는 증거.

프로젝트를 마치면 손에 넣는 것

보고서 + 발표 + peer-review — “설계하고 평가할 수 있다”의 증거.

프로젝트 구조: 환경 · 2개 이상 알고리즘 · 필수 요구사항

- **환경**: Gymnasium의 표 기반(이산 상태·행동) 환경 하나 — FrozenLake-v1, CliffWalking-v1, Taxi-v4 등.
- **적용**: Ch 4~7 알고리즘 **최소 두 가지**를 같은 환경에 적용 (예: Q-learning vs SARSA, MC 제어 vs n-step TD) → 학습 곡선과 최종 정책 비교.
- **필수 — 수식적 정당화 최소 1개**:
 - ▶ Q-learning/SARSA 비교 → Ch 6.2~6.3 on/off-policy로 정책이 왜 다르게 학습됐는지 설명.
 - ▶ ϵ/α 변경 실험 → Ch 6.3 수렴 조건과 연결.
 - ▶ Dyna-Q 사용 → Ch 7.3 계획 스텝 수와 학습 속도를 **직접 측정**.

환경 고르는 실전 가이드: 점수를 매기는 4가지 기준

기준	왜인가
(1) 상태-행동 공간 크기	상태가 많으면(Taxi 500개) 표를 채우는 에피소드 수가 급증
(2) 보상 구조가 “학습 중”과 “최종 정책”을 갈라놓나	CliffWalking처럼 실수에 비례하지 않게 큰 벌(-100) → on/off-policy 차이가 극적으로 드러나 6.3절을 숫자로 보여줌
(3) 확률적 전이	FrozenLake 미끄럼 → “같은 정책이어도 에피소드가 매번 달라지는” RL 특유의 불확실성 체감
(4) 코드 재사용성	Ch 6.3·7.3 강의 코드가 거의 그대로 적용되는가. 시작 상태 다중 여부(Taxi)·에피소드 길이 상한 확인

Gymnasium 레지스트리 이름은 버전에 따라 달라짐 — 최근 버전에서 Taxi-v3는 deprecated → Taxi-v4 사용.
CliffWalking은 `gym.make("CliffWalking-v1")` 로 바로 사용 (4×12 격자, 시작=좌하단, 목표=우하단, 사이를 절벽이 가로막음).

후보 환경 비교표

환경	상태×행동	보상 구조	난이도	잘 어울리는 비교
FrozenLake-v1	16×4 (미끄럼)	도착 +1, 그 외 0 (구멍=종료)	낮	MC(Ch 5.3) vs SARSA(Ch 6.3) 전이에서 시드 안정성
CliffWalking-v1	48×4	스텝 -1, 절벽 -100, 도착 0	중	SARSA vs Q-learning — 6 클래식 비교
Taxi-v4	500×6	성공 +20, 불법 -10, 스텝 -1	높	n-step vs TD(0) (Ch 7.2), D (Ch 7.3)

선택은 자유이지만

선택이 **Ch 4~7의 개념 검증 목적**에 근거해야 한다. (상태 수 · 보상 구조 · 확률 전이 중 무엇이 이 비교를 정당화하는지)

비교 프로토콜 (1/3): 시드 ≥ 3 — 왜인가

- “한 번의 실행”은 아무것도 말해주지 않는다:
 - ▶ ϵ -greedy 탐험의 무작위성,
 - ▶ (FrozenLake처럼) **환경 전이 자체**의 무작위성,
 - ▶ 정책 초기화.
- → **같은 코드 · 같은 파라미터를 그대로 돌려도 매번 다른 학습 곡선이 나온다.**
- **시드를 바꾸는 것**은 “실험을 다시 하는 것”이 아니라 “우연에 좌우되는지 재검사하는 것”.

프로토콜의 세 규칙

- 1 **시드 ≥ 3** (예: 0, 1, 2)으로 알고리즘을 **전부 다시** 학습.
- 2 학습 도중 성과와 학습 후 평가 성과를 반드시 **분리해** 보고.
- 3 비교는 **시드별 숫자 자체**(예: “-13 / -13 / -13”)를 표로 제시하고, 평균 $\pm$ 표준편차나 “일관된 경향”으로 결론.

비교 프로토콜 (2/3): 학습 중 리턴 vs 학습 후 평가

학습 도중 (탐험 포함)

- 마지막 100 에피소드 평균 리턴
- $\varepsilon > 0$ 상태 $\rightarrow$ “탐험이 섞인 행동”의 성과

학습 후 (평가)

- $\varepsilon = 0$ (탐욕적)으로 고정, 에피소드 수(예: 200개) 평균 리턴
- **모든 알고리즘 · 모든 시드에 동일한 평가 프로토콜**

둘이 왜 다른가

학습 도중 리턴 = **탐험이 섞인 정책**의 성과.

학습 후 greedy 리턴 = **배운 정책**의 순수 성과.

$\rightarrow$ 두 숫자는 **다른 대상**의 측정값. (8.2절 패턴 2·8.1 확인 문제 3의 핵심)

“최종 greedy 리턴 -13이 나왔으므로 잘 배웠다”는 발표는 이 두 층을 구분한 뒤에야 성립한다.


실측: CliffWalking, 시드 0/1/2 (고정 $\varepsilon = 0.1$)

$\alpha = 0.5, \gamma = 1.0, \varepsilon = 0.1$ 고정, 500 에피소드

시드	SARSA 학습중	SARSA greedy	Q-learning 학습중	Q-learning greedy
0	-31.5	-17 (17스텝)	-49.6	-13 (13스텝)
1	-25.6	-17 (17스텝)	-51.2	-13 (13스텝)
2	-23.6	-17 (17스텝)	-48.6	-13 (13스텝)

- (1) **학습 도중**: SARSA(-24 ~ -32)가 Q-learning(약 -50)보다 **오히려 낮다** - 6.3절 그대로, Q-learning이 배우는 “절벽 바로 옆 최단 경로”는 탐험 중 무작위 한 번이 -100으로 이어지는 경로.
- (2) **학습 후**: Q-learning 13스텝 최단(-13), SARSA 17스텝 안전(-17) - **세 시드 모두** 일관. 차이는 우연이 아니라 on/off-policy **설계 차이**, 시드별 표는 그 재현을 보여준다.

왜 시드 ≥ 3 인가: 편차는 실행해 보지 않고는 모른다



CliffWalking 학습 곡선(50 에피소드 이동평균). 시드 0/1/2를 얹은 선으로 겹침 — 시드마다 곡선이 **달라야 정상**. 이 실험에서는 격차가 작았으나 **우연**일 수 있음.

- CliffWalking 시드 간 편차가 작았던 것은 **우연**일 수 있고, 미리 아는 방법은 없다.
- 확률적 전이 환경(FrozenLake, 실습 § 6): 같은 코드·파라미터를 시드만 바꿔도 **같은 알고리즘의 greedy 평가가 0.045 / 0.090 / 0.125로 2.8배** 벌어짐.
- 시드 편차의 크기는 환경(확률 전이 여부, 상태 공간, 학습 예산)에 달려 **실행하지 않고 알 수 없다**.

시드별 표는 형식적 서류가 아니라 “결론의 신뢰도를 확인할 수 있는 유일한 수단”.

ϵ 감쇠 스케줄도 하이퍼파라미터다

- Ch 6.3: ϵ 를 내내 고정하면 “탐험이 줄면서 배움이 뎀프닝된다”. 프로젝트에서는 보통 **초반 높은 ϵ 로 넓게 방문 $\rightarrow$ 서서히 감쇠.**
- “이 스케줄이 결과를 바꾸는가”는 **실험하지 않으면 답이 없다** — 실습: 스케줄 하나만 500 에피소드 1.0 $\rightarrow$ 0.01 선형 감쇠로, **같은 파라미터·같은 시드로 재실행.**
- 결과: greedy 평가(SARSA -17/ -17/ -17, Q-learning -13/ -13/ -13)가 **한 치도 달라지지 않았다.**

부정적 결과(negative result)도 결과다

“이 환경·이 학습 예산에서 스케줄 선택이 성능에 민감하지 않다”는 관찰도 보고서에 적어야 한다.

- (a) **두 알고리즘 모두에게 동일한 스케줄** — 한쪽에만 감쇠 쓰면 “감쇠의 효과”와 “알고리즘의 차이”가 뒤섞임.
- (b) 다른 환경·예산에서 스케줄이 차이를 만들면 그 차이는 **수식적 정당화**의 일부가 되어야 한다.


선형 ε 감쇠 스케줄 (핵심 코드)

```
def make_epsilon_schedule(n_episodes, eps_start=1.0, eps_end=0.01):  
    def eps_fn(episode): # 선형감쇠  
        return max(eps_end,  
                    eps_start + (eps_end - eps_start) * episode  
                    / n_episodes)  
    return eps_fn
```

- $t = 0$ 에서 $\varepsilon = 1.0$ (전부 탐험) $\rightarrow t = n_episodes$ 에서 0.01로 선형 하강, max가 하한을 보장.
- 이 함수를 두 알고리즘 모두에 똑같이 전달하는 것이 “한 요인만 바꾸는” 비교 실험의 원칙.

전체 그림: 4주 파이프라인

팀 프로젝트 파이프라인 — 4주: 환경 선정 → 발표 (Block A 캡스톤)



환경·문제 정의(1주) → 알고리즘 ≥ 2 개 구현·시드 ≥ 3 ·학습
곡선(2~3주) → 수식적 정당화·보고서 (3~4주) →
발표·peer-review(4주).

- 흐름: 환경 → 구현·비교 → 평가·정당화 → 발표.
- 붉은 점선(평가 → 구현·비교)이 핵심 — 시드 간 편차가 비정상적으로 크거나 평가 프로토콜 결함이 발견되면 돌아가서 다시.
- “한 번 지나가면 돌아올 수 없는” 것은 최종 발표 뿐 — 그 외 모든 단계는 되돌아갈 수 있다.

일정과 마일스톤 M1~M4 (4주, 각 주 = 수업 3회)

주	마일스톤	해야 할 일	제출물
1	M1	환경 후보 2~3개 조사(상태 수·보상 구조·확률 전이 여부), 팀 회의, 문제 정의 문서 (어떤 MDP인지·어떤 지표 쓸지·베이스라인(무작위 정책) 리턴)	문제 정의 + 환경 선택(1p)
2	M2	Ch 6.3/7.3 코드에서 두 알고리즘 구현, 베이스라인 리턴 측정 , 시드 3개 중 1개에서 엔드투엔드 동작 확인	중간코드 리뷰 (코드 + 베이스라인 숫자 1줄)
3	M3	나머지 시드 실행, ϵ/α 튜닝 (모두 동일 프로토콜), greedy 평가 ($\epsilon = 0$), 시드 비교 표 도출	학습 곡선 1장 + 시드 비교 표
4	M4	수식적 정당화, 보고서·슬라이드 완성, 발표(5~7분) , peer-review 2팀	보고서 + 발표 + 리뷰 2건

M1·M2는 팀 전체가 **모여 함께** 결정하는 것.

왜 마일스톤이 이 모양인가

M2: 베이스라인 숫자 1줄

- 이 숫자를 보고야 비로소 “배운 정책이 무작위보다 나은가”를 판정.
- 절벽 예제: 무작위 정책은 500스텝 상한까지 돌아다니며 절벽을 반복 타격 → 평균 리턴 $-5,010$ (실측 100 에피소드).
- 이 제로점 덕분에 “greedy 평가 -17 ”이 의미 있는 숫자인지 바로 확인.

M3: 시드 비교 표

- “greedy 리턴 -13 ” 한 줄만 내면 시드 1개에서 우연인지, 시드 3개에서 일관된지 검증 불가.
- 표가 있어야 § 비교 프로토콜을 실제로 지켰는지가 제출물에서 바로 드러남.

공통 원리

제출물이 “결과 1줄”이 아니라 “결과 + 그 결과를 얻은 절차의 흔적” 일 때, 채점(과 8.2의 리뷰)이 같은 언어로 작동한다.

손으로 한 번: “수식적 정당화”의 좋은/나쁜 예

설정: 어떤 팀이 CliffWalking에서 “Q-learning이 SARSA보다 최종 평가 점수가 더 높았다 (-13 vs -17)”라는 결과를 얻었다.

나쁜 설명

“Q-learning이 SARSA보다 점수가 더 높았다. Q-learning이 더 좋은 알고리즘인 것 같다.”

좋은 설명 (요약)

학습 도중(탐험 포함)은 SARSA가 더 높았다 (-31 vs -53) — Q-learning은 **목표 정책(항상 최선)의 가치를 배우는 off-policy** 방법이라 절벽 옆 최단 경로를 학습했고, 그 경로는 탐험 실수 한 번이 -100 으로 이어진다. SARSA는 **실제 행동 방식(탐험 포함)까지 감안하는 on-policy**라 안전한 경로를 선호. 탐험 없이 평가하면 Q-learning 경로가 더 짧아 -13 vs -17 이지만, 이건 “더 좋은 알고리즘”이 아니라 “두 알고리즘이 애초에 다른 질문에 답하고 있다”.

같은 숫자를 말해도, 좋은 설명은 숫자 뒤의 알고리즘의 설계 차이를 짚어낸다 — 이것이 “수식적 정당화”의 실제 의미.

보고서 구조 (M4): 4~6페이지, 6절

절	내용
1. 문제 정의 (0.5p)	MDP 5요소(Ch 3.1): 상태·행동·전이·보상·할인율, 주 지표(greed 평가 평균 리턴), 베이스라인(무작위 정책 리턴)
2. 알고리즘 선택과 이유 (1p)	후보 ≥ 2 개, 왜 이 알고리즘을 이 환경에 골랐는가(보상 구조·상태 수와 연결), 하이퍼파라미터($\alpha, \gamma, \varepsilon$ 스케줄)와 선택 근거
3. 실험 프로토콜 (1p)	시드 목록, 학습 에피소드 수, 평가 프로토콜($\varepsilon = 0$, 에피소드 수, 모든 알고리즘 동일) 명시 — 없으면 8.2 체크리스트에서 바로 감점
4. 결과 (1p)	시드 비교 표, 학습 곡선 1장(여러 시드를 한 그림에 얹은 선으로), greedy 정책 경로 시각화
5. 수식적 정당화 (1p)	Ch 2~7 개념 ≥ 1 개로 “왜 이 결과” — § 손으로 한 번의 좋은 예 문체
6. 잘 안 된 부분과 원인 진단 (0.5p)	필수. 없었으면 “무엇을 시도했다가 안 됐는가”를 씀 — “모두 잘 됐습니다” 보고서는 이 절이 비어 있다는 뜻

발표 슬라이드 = 보고서의 각 절 제목 — 발표는 보고서의 요약.

채점 기준 (rubric): 정직성이 절반

항목	비중	좋은 답
문제 정의와 환경	15%	MDP 5요소·지표·베이스라인이 명확하고, 선택이 Ch 4~7 개념 검증 목적에 근거
방법론 적절성	20%	환경 특성에 맞는 알고리즘·파라미터 선택, 근거가 Ch 4~7 개념으로 설명
실험 프로토콜의 정직성	25%	시드 ≥ 3 , 동일 평가 프로토콜, 베이스라인, ϵ 스케줄이 보고서에서 추적 가능할 만큼 명시
수식적 정당화	20%	배운 개념 ≥ 1 개로 “왜”를 설명했고, 관측한 숫자와 일치
결과의 정직성과 반성	20%	불안정했던 시드·구간을 숨기지 않고, 원인을 Ch 4~7 개념으로 진단

우선순위

greedy가 -13이어도 프로토콜이 정직하고 정당화가 타당하면 고득점. -13이어도 **시드가 1개였다면** “실험 프로토콜의 정직성”에서 큰 감점 — 8.2에서 다른 팀을 리뷰할 때도 정확히 이 순서.

자주 하는 실수 5가지 (1/2)

- ❶ **시드 1개 실험으로 결론** — CliffWalking에서 편차가 작았 = 이 환경의 성질이지 **보장**이 아님. FrozenLake(확률 전이)는 시드만 바뀌도 greedy 평가가 0.045/0.090/0.125로 2.8배. 리뷰 질문: “시드를 몇 개로 확인했나요? 시드 간 greedy 평가의 표준편차가 알고리즘 간 차이보다 큰가요?”
- ❷ **평가 시에도 ϵ 커둔 채 비교** — “배운 정책의 성능”이 아니라 “탐험 10%가 섞인 행동의 성능” 측정. 게다가 **비대칭적** — 탐험이 섞이면 SARSA “안전 경로”의 우위가 상대적으로 줄어듦.

각각이 Ch 2~7의 어떤 원칙을 깨는지 짚어두면 8.2에서 “반박 가능한 질문”으로 바로 바뀐다.

자주 하는 실수 5가지 (2/2)

- ③ 알고리즘마다 다른 ϵ 스케줄 — “Q-learning 고정 0.1, SARSA 감쇠”는 알고리즘 차이에 스케줄 효과가 뒤섞임 (한 요인만 바꾸는 것이 비교 실험의 원칙).
- ④ 베이스라인 없이 “잘 배웠다” 발표 — 절벽 환경에서 무작위 정책 평균 리턴은 $-5,000$ 수준(실측 $-5,010$). 측정 없이 말하는 것과 “측정해서 아는 것”이 보고서 수준을 가른다.
- ⑤ “곡선이 잘 올라갔으니 성공”으로 진단 건너뛰기 — 잘 올라가도 시드 간 편차와 평가 프로토콜을 확인해야 “성공” — 없다면 “무엇을 시도했다가 안 됐는가”가 필수 절의 존재 이유.

발표: 5~7분, 마지막 1분이 가장 평가받는다

- 구조: 문제 정의(1분) → 알고리즘과 이유(2분) → 학습 곡선/최종 정책 비교 + 수식적 정당화(2~3분) → **잘 안 됐던 부분과 원인 진단(1분)**.
- “최종 greedy 리턴 -13이었다”보다 “**왜 이 알고리즘을 이 환경에 골랐고, 왜 이 결과가 나왔는지**”를 설명하는 쪽에 더 높은 점수.


“모든 것이 잘 됐다”는 발표는 스스로 감점

예: “Q-learning greedy -13, SARSA -17 — 4스텝 차이가 시드 3개에서 재현됐고, 6.3절 on/off-policy 차이(절벽 옆 최단 vs 안전 경로)로 설명된다. 다만 FrozenLake 2차 실험에서는 MC greedy 0.045/0.090/0.125, SARSA 0.245/0.525/0.730으로 시드마다 크게 벌어져, “MC가 못 한다”는 결론은 내리지 못했다 — 시드 5개로 재확인을 계획한다.” — **실패에 가까운 실험까지 배운 개념으로 해석한 증거.**

Block B Ch 16.1(신경망 RL 캡스톤)도 동일한 구조 — 이 습관(시드, 평가 분리, 반박 가능한 질문)이 학기 말까지 이어진다.

실습: 미니 프로젝트를 한 흐름으로 (6단계)

- 1 **CliffWalking-v1** — 4×12 격자, 절벽 -100 (6.3절과 같은 `gym.make("CliffWalking-v1")`).
- 2 **SARSA와 Q-learning 구현** — Ch 6.3의 두 갱신 규칙 그대로.
- 3 **고정 $\epsilon = 0.1$, 500 에피소드, 시드 0/1/2** — 학습 도중 리턴 vs greedy 평가 비교.
- 4 **greedy 정책 경로 시각화** — 절벽 옆 최단(13스텝) vs 안전(17스텝)이 눈에 보도록.
- 5 **ϵ 감쇠(1.0 $\rightarrow$ 0.01) 재실행** — 같은 파라미터·시드로 스케줄 하나만 바꿔 greedy 평가 변화 확인 (변하지 않음 — 부정적 결과도 결과).
- 6 **FrozenLake-v1: MC 제어(첫방문, Ch 5.3) vs SARSA** — 1000 에피소드, 시드 3개. 확률 전이 환경에서는 같은 알고리즘의 greedy 평가도 시드마다 크게 벌어짐 (MC: 0.045/0.090/0.125).



greedy 정책 경로 — SARSA(파랑)는 절벽에서 떨어진 위쪽 17스텝, Q-learning(빨강)은 절벽 바로 옆 13스텝. 6.3절 on/off-policy 차이를 한 장에.

확인 문제 (1/2): 절차가 개념을 요구할 때

Q1. 시드 2 하나만 돌려 Q-13, SARSA-17을 얻고 “Q-learning이 더 좋다”고 결론

- 시드 1개의 greedy 평가는 “무작위성 한 번”의 결과 — 시드 2가 **우연히** 편차가 작은 시드였을 수 있음.
- 재실행: “SARSA-17/ -17/ -17, Q-13/ -13/ -13”처럼 **시드별 숫자가 일관**되면, 결론은 “greedy 평가에서 Q-learning이 4스텝 꾸준히 앞선다 — 6.3절 on/off-policy 설계 차이”로 **격상**.
- 단, “이 환경에서 편차가 작았음”은 환경의 보장이 아님 (FrozenLake)임을 함께 적어야 **정직한 보고**.
- 또한 이 비교는 “**탐욕적 실행** 시 어느 정책이 나은가”의 답이지 “더 좋은 알고리즘”의 답이 아님.

Q2. “ ϵ 스케줄을 종료 시점에 0.1로, 최종 평가는 탐험 없이 했다”는 프로토콜 문장의 결함

- $\epsilon = 0.1$ 이면 매 스텝 10% 확률로 무작위 행동이 들어감 → “탐험 없이”와 **모순**.
- 고쳐 쓰기: (a) 학습 스케줄: $1.0 \rightarrow 0.01$ 선형 감쇠, (b) 최종 평가: $\epsilon = 0$ (greedy), 200 에피소드, 모든 알고리즘·시드에 **동일** — 학습 스케줄과 평가 프로토콜을 따로 명시.

확인 문제 (2/2): 두 층의 불확실성, 좋은 정당화

Q3. “MC 분산이 크므로 greedy 평가 에피소드를 10,000개로 늘리자” — 학습/평가 에피소드 수는 각각 어떤 불확실성을 줄여주나

- **평가** 에피소드 = **고정된** 정책의 성능 측정 **오차**만 줄임 — 나쁜 정책 10,000번 = 나쁜 정책의 정확한 평균.
- **시드** = **어떤 정책이 학습됐는가**의 학습 과정 무작위성 — FrozenLake처럼 0.045/0.090/0.125(2.8배) 흩어지는 것은 측정 오차가 아니라 **학습 결과의 차이**, 평가 에피소드로 사라지지 않음. (ML1 8.1: “어떤 모델이 나왔는가” vs “재는 오차”)

Q4. “ ϵ -greedy라 학습이 진행된다면 탐험 비중이 줄고 성과가 좋아졌다” — 좋은 예인가

- **나쁜 예**에 가깝다 — 장치를 기계적으로 서술할 뿐, 6.3절 개념 + **실측 숫자의 일치**가 없음.
- 좋은 예는 **정의(ϵ -greedy) + 환경 구조(-100) + 실측 숫자의 삼박자**: 고정 $\epsilon = 0.1$ 에서 Q 학습중 리턴 (시드 평균 ≈ -50)이 SARSA(≈ -26)의 2배로 나쁘다 — $\epsilon = 0.1$ 이면 절벽 옆 13스텝 경로에서 에피소드당 $1 - 0.9^{13} \approx 0.73$ 확률로 무작위 행동이 1회 이상, 그것이 “아래”면 $-100 \rightarrow$ 학습중 손실의 대부분이 절벽 사고. (참고: $1 - 0.9^{13} \approx 0.73$, $1 - 0.99^{13} \approx 0.12$ — 절벽 사고 기대 빈도 **예측**은 성립하지만, 실제로 학습중 리턴이 그만큼 개선되지는 않음: ϵ 감소의 부정적 결과.)

자주 묻는 질문 (8.1)

질문	핵심 답
두 알고리즘 성능이 거의 같으면	“비슷하다”는 것 자체가 관찰 — 학습중/학습후를 나눠 보면 겉보기엔 비슷해도 다른 트레이드오프라는 것을 발견할 수 있음
매번 결과가 달라 비교가 안 되면 시드 몇 개가 정석인가	ε 여러 개로 반복 실행한 평균(과 가능하면 분산) 비교가 표준적 방법 실행 비용 vs 결론 안정성의 절충 — 표 기반 환경은 시드당 몇 초~분 → 3~5개 현실적 하한 , 10개면 더 단단. 표준편차 1개 안에 겹치면 정직한 결론 = “유의미한 차이 관측 불가”
코드를 처음부터 써야 하나	강의 코드 재용이 전제 — (a) 재사용한 부분(Ch 6.3 갱신 규칙)과 (b) 팀이 수정·추가한 부분(환경 인터페이스, 시드 처리, 평가 프로토콜)을 구분
성공 기준은 “깨끗한 숫자”가 아니라 “정직한 절차” — “시간 부족으로 3시드로만 확인, SARSA 시드 간 편차가 커서 5시드 재확인 권장”을 “잘 안 된 부분”에 쓰는 것이 감추는 것보다 항상 낫다	시간이 부족해 시드를 5→3개로 줄였으면

8.2 Peer-Review

왜 Peer-Review인가: 이번 주에는 네가 심사위원이다

- 4주 파이프라인에서 4주째는 **역전** — 발표팀이었던 각 팀이 **다른 두 팀의 발표를 심사**하고 리뷰 **2통**을 작성.
- 채점 대상은 리뷰의 양이 아니라 질: “4항목을 다 썼는가”가 아니라 “**그 질문이 반박 가능한 질문인가**”.

근거 (ML1 8.2에서 그대로 이어받음)

- Popper의 **반증주의**: 한 주장은 “그것이 틀렸음을 보여주는 관측이 상상이 가능한가”로 판별.
- Amgen 재현 실험(2011): 53편의 'landmark' 논문 중 **6편 만** 재현. **좋은 결과는 스스로를 증명하지 못하고, 결과가 남이 재현·반박할 수 있도록 만들어졌는지가 기준.**
- 강화학습에서는 이 위험이 **더 높음** — 결과를 내는 **과정 자체**가 무작위(시드, 탐험)라 “우연히 좋은” 확률이 학습모델보다 훨씬 큼.

이번 주는 어떻게 진행되는가

순서	내용	시간 배분
1	다른 두 팀의 발표 청취(팀당 5~7분, 8.1 형식 그대로) + 보고서·슬라이드 열람	약 30분
2	작성 리뷰 2통 — 팀당 체크리스트 4항목 + 반박 가능한 질문 1개 이상 (개념의 장·절 명시)	발표 직후
3	질의·토론 — 리뷰어가 쓴 질문에 발표팀이 그 자리에서 답변	나머지 시간

- 핵심은 2번의 **작성 리뷰**. 3번 토론은 “발표팀이 그 질문에 **실제로** 답할 수 있는가”를 가르는 자리.
- **3점 질문** = 답하려면 **새로운 계산·실험**(시드 재실행, $\varepsilon = 0$ 재평가, α 민감성 등)을 꺼내야 하는 질문.
“네, 알겠습니다”로 넘어가는 질문은 2점에 머물러.
- 8.1에서 “수식적 정당화”가 발표팀의 의무였다면, 이번 주 그 정당화가 타당한지를 리뷰어가 심사.

Peer-Review 체크리스트 4항목

항목	확인할 것
1. 환경 설명	상태·행동·보상이 명확히 정의됐는가 — “CliffWalking을 썼다” 한 줄 + 주 지표 (학습중 리턴? greedy 평가? 에피소드 길이?) 없으면 뒤의 모든 숫자가 “무엇의 평균”인지 모름. 8.1의 학습중/학습후 분리 가 이 항목의 핵심.
2. 알고리즘 선택	이 환경의 어떤 특성 (상태 공간, 보상 구조, 확률 전이)이 그 비교를 정당화하는가. FrozenLake(16×4) vs Taxi(500×6)의 n-step vs MC는 설계 난이도가 완전히 다르다. 선택은 자유, 설명 가능한 연결 이 필요.
3. 수식적 정당화	요구사항(≥ 1 개)은 형식, 이 항목은 내용 : 짙은 개념(Ch 6.3 on/off-policy)이 실측 숫자 (학습중 -50 vs -32 , greedy -13 vs -17)와 일치하는가. 숫자 없는 문장은 “어디에나 붙을” 설명.
4. 결과의 정직성	시드 ≥ 3 , 시드별 숫자 표, 불안정했던 시드·구간이 사라지지 않고 들어갔는가. “결과가 좋았나”가 아니라 “ 정직한 절차로 얻어졌나”.

4항목 = 8.1 rubric의 축 — 리뷰어와 발표팀이 **같은 기준표**를 공유해야 “감점”과 “좋은 지적”이 같은 언어.

채점 기준: “채웠는가”가 아니라 “구체적인가”

리뷰 품질	특징	예시 (CliffWalking)
1점 — 감상평	구체적 지적 없음, 느낌만	“학습 곡선이 꾸준히 올라가서 잘된 것 같습니다.”
2점 — 일반 지적	문제를 제기하지만 근거(개념) 약함, 발표팀이 “네”로 넘길 수 있음	“시드를 하나 더 돌려서 확인해보는 게 좋을 것 같습니다.”
3점 — 반박 가능한 질문	이 학기 개념(장·절) 명시 + 답이 나쁘면 결과가 흔들림	“최종 평가가 $\epsilon = 0$ 로 했나요? $\epsilon = 0.1$ 으로 평가한 채로는 Q-45, SARSA-21로 결론이 뒤집힙니다(Ch 6.3 on/off-policy 경로 차이).”

1점→3점의 공통 패턴

추상적 평가어(“잘됐다”, “확인해보라”)를 (a) 구체적 관찰 + (b) 이 학기 개념(Ch NN) + (c) 왜 문제인지 (숫자)로 교체하는 것.

손으로 한 번: 가상 발표 (팀 “절벽우회”)

발표 요약

“CliffWalking에서 SARSA와 Q-learning을 비교했다. $\alpha = 0.5$, $\gamma = 1.0$, $\varepsilon = 0.1$ 고정, 500 에피소드, **시드 0**으로 학습했다. 학습 곡선이 꾸준히 올라가서 잘 됐다. 최종 평가(학습된 정책 200 에피소드)에서 **SARSA** -21.3, **Q-learning** -45.3이라 SARSA가 더 좋은 알고리즘이다. Ch 6.3에서 SARSA가 절벽을 피하는 안전 알고리즘이라 배웠으니 일치한다.” — 문제인 곳은 숫자가 아니라 **프로토콜**.

- **환경 설명** — 환경은 명확(4×12 , 절벽 -100) 하지만 **주 지표 모호**: “200 에피소드”가 $\varepsilon = 0$ 인지, 학습 때 쓰던 0.1인지 문장에 없음 → 8.1이 **분리**를 요구한 이유.
- **알고리즘 선택** — SARSA vs Q-learning은 절벽 -100 보상 구조에 가장 잘 맞는 비교 → **통과**.

가상 발표 리뷰: 정당화와 정직성

- **수식적 정당화** — Ch 6.3을 인용했지만 인용과 관측이 **연결되어 있지 않아**: “SARSA가 안전 알고리즘”은 학습 도중 성과에 관한 이야기인데, 발표 숫자는 최종 평가 비교. 게다가 그 평가가 $\epsilon = 0$ 이 아니라면 Ch 6.3의 설명은 그 상황에 해당하지 않음 → 개념을 끌고 와 숫자에 끼워 맞추는 = 형식만 있는 정당화.
- **결과의 정직성** — 세 가지가 **사라져 있음**:
 - ▶ (1) **시드 1개** — 시드 1개의 “최종 평가”는 학습 과정의 우연 (8.1: SARSA 시드 2번 -200 고착 사례).
 - ▶ (2) **베이스라인(무작위) 부재** — “잘 배웠다”의 기준점 자체.
 - ▶ (3) **평가 ϵ 미명시** — S 실습에서 이것이 **결론의 방향**을 가름한 변수.

3점 질문 (이 발표를 향해)

“최종 200 에피소드 평가는 $\epsilon = 0$ 로 했나요? 같은 학습 결과를 $\epsilon = 0.1$ 로 평가하면 $Q - 45.3$, SARSA -21.3 으로 **SARSA가 더 좋아 보이고**, 반대로 $\epsilon = 0$ 이면 $Q - 13$, SARSA -17 으로 **순위가 뒤집힙니다**(Ch 6.3: 절벽 옆 경로는 탐험 한 번이 -100). **두 프로토콜 모두 시드 3개로 재실행 해주세요.**”

3점인 이유: 답하려면 **새 실험**($\epsilon = 0$ 재실행 + 시드 2개 추가)이 필요하고, 그 실험을 돌리면 결론이 흔들릴 수 있음.

“우연히 좋은” 패턴 5가지 (1/2)

ML1에서 원천 = 테스트셋 유출·정확도의 함정·과적합. 강화학습에는 검증/테스트셋 자체가 없으니 학습 과정의 무작위성이 같은 역할. 8.1 실수 5가지의 리뷰어 눈 버전.

패턴	겉보기	실제로는	반박 가능한 질문(근거)
1. 시드 1개 학습 곡선	“곡선이 잘 올라가네”	학습 과정의 우연 — ϵ -greedy + (FrozenLake 등) 전이 무작위성, 같은 코드도 매번 다른 곡선	“시드 2개 더 돌리면 greedy 평가 표준편차가? 알고리즘 간 차이 그 편차보다 큰가요?”(8.1 § 비 프로토콜)
2. 평가 시에도 ϵ 커둔 채	“최종 정책의 성과다”	“탐험이 섞인 행동”의 성과 — CliffWalking에서 탐험 혼입 시 Q만 급격히 망가지고($-13 \rightarrow -45$), SARSA는 거의 안 흔들림($-17 \rightarrow -21$)	“최종 평가가 $\epsilon = 0$ 이었나요? $\epsilon = 0.1$ 로 하면 순위가 뒤집힙니다(Ch 6 경로 차이)”(§ 실습 2)
3. 알고리즘마다 다른 ϵ 스케줄	“각자가 최적의 설정으로”	한 요인만 바꾸는 비교 실험 원칙 위반 — 알고리즘 차이와 스케줄 효과가 뒤섞임	“두 알고리즘에 같은 스케줄 적용했나요? 한쪽만 감쇠했다 어떻게 분리했나요?”(8.1 § 자주 하 실수)

“우연히 좋은” 패턴 5가지 (2/2): 4·5

패턴	겉보기	실제로는	반박 가능한 질문(근거)
4. 하이퍼파라미터 “적당히” 하나	“ $\alpha = 0.5$ 로 학습”	민감성 미검증 — Ch 7.2 n 튜닝처럼 α 가 크면 (0.5) Q값이 노이즈에 크게 흔들려 정책이 달라질 수 있음	“ α 를 0.1로 줄이면 결론이 변하나요?” (Ch 7.2 튜닝) 민감성을 확인했나요?” (Ch 7.2 튜닝)
5. 베이스라인 없이 “잘 배웠다”	“-13이 나왔다”	기준점 없이 “나다”를 말할 수 없음 — 무작위 정책 평균 리턴 (약 -5000)을 재야 “실제로 이득인가” 판정 가능	“무작위 정책의 평균 리턴은? 배 정책이 그 대비 얼마나 나은 측정 했나요?” (8.1 M2)

패턴 2가 특히 RL 특유인 이유

비대칭성 — 탐험 혼입 시 두 알고리즘이 다른 방향의 크기로 망가지는 것. Ch 6.3 on/off-policy 경로 차이를 **정량적**으로 이해해야 짚어낼 수 있는, 이번 학기 개념이 직접 작동하는 지점.

실습 (1/3): 발표팀 재현 + $\varepsilon = 0$ 재평가

- 1 발표팀 재현 — CliffWalking에서 SARSA·Q-learning, 시드 0, $\alpha = 0.5$, $\gamma = 1.0$, $\varepsilon = 0.1$ 고정, 500 에피소드. **평가도 $\varepsilon = 0.1$ 으로 200 에피소드 $\rightarrow$ SARSA -21.3 vs Q-learning -45.3 (발표팀 숫자 재현).**
- 2 패턴 2 검증 — **평가 ε 을 0으로** — 같은 학습 결과를 $\varepsilon = 0$ (탐욕적)으로 200 에피소드 재평가 $\rightarrow$ **Q-learning -13 (13스텝) vs SARSA -17 (17스텝): 순위가 뒤집힌다.**


왜 Q-learning 쪽만 크게 망가지나 (손계산)

- **Q-learning (13스텝):** 절벽 바로 위(2행)를 11스텝 이동 — 스텝당 추락 확률 $0.1 \times \frac{1}{4} = 0.025 \rightarrow$ 12스텝 중 한 번이라도 $1 - 0.975^{12} \approx 0.26$.
 $\approx 0.74(-13) + 0.26(-107) \approx -38$.
- **SARSA (17스텝):** 0~1행 위쪽 우회 — 추락하려면 랜덤 두 번(연이어 “아래”) 필요, 스텝당 0.025^2 로 2차적 $\rightarrow \approx -20$ 부근.

실습 (2/3): 비대칭의 기원 + 시드·베이스라인

- 손계산(약 -38 / 약 -20)과 시뮬레이션(-45.3 / -21.3)이 **같은 크기·같은 순서**. Q 쪽 차이는 추락 시 깊이 분포 + 랜덤 우회 스텝의 추가 비용.
- “절벽과 한 스텝” 경로와 “절벽과 두 스텝” 경로는 ϵ 이 섞이는 순간 추락 확률이 1차 vs 2차로 갈라서 성과 격차가 크게 벌어진다.
- ③ **패턴 1 검증 — 시드 2개 추가** — 시드 1, 2로 같은 프로토콜 재실행 → 시드별 greedy 표. (이번 실행에서는 3시드 모두 -13 / -13 / -13 , -17 / -17 / -17 로 일관. 단, 8.1처럼 설정이 조금만 달라지면 SARSA 시드 2번 -200 고착도 — “시드 3개”가 **형식이 아니라 정량적** 요구인 이유.)
- ④ **패턴 5 검증 — 베이스라인** — 무작위 정책 500 에피소드 → 평균 약 -5036 (평균 486스텝, 절벽 반복 추락). 배운 정책(-13 / -17)의 이득이 **측정된** 기준점 위에서 확인.
- ⑤ **리뷰 작성** — 실습 숫자를 근거로 3점 리뷰를 템플릿으로 완성.

실습 (3/3): 평가 ϵ 의 비대칭



$\epsilon = 0 \sim 0.3$ 으로 200 에피소드 평가. $\epsilon = 0$ 이면 Q 앞선다(-13 vs -17)가, 탐색이 조금만 섞이면 Q 급락($\epsilon = 0.1 \rightarrow -45$, $0.3 \rightarrow -182$)해 SARSA가 뒤집어 앞선다. SARSA 우회 경로는 거의 안 흔들림(-17 $\rightarrow$ -39).

핵심 태도

리뷰어는 발표팀의 실험을 자기 손으로 재실행할 수 있는 사람. “이 학습 곡선, 시드를 바꿔서 다시 돌려도 같은 모양이 나올까요?”라는 질문은 리뷰어가 실제로 다시 돌려본 적 있는 질문일 때 가장 날카롭다.

“평가 때 ϵ 을 켜둔 채” 비교하면 결론의 방향이 뒤집히는 구조.

좋은 리뷰를 쓰는 과정: 체크리스트 → 반박 가능한 질문

발표+보고서로 주장 파악 → 4항목 적용 → 각 항목에 질문 초안(답이 **새로운 계산·실험**이어야 함) → “개념(장·절)을 근거로 들고, 답이 새 실험인가?” 분기: 예 → **채택**, 아니오 → 감상평으로 떨어지고 다시 쓰기 → 3단계(1/2/3점)로 자기 채점.

- 흐름: 발표를 듣고 → 4항목에 적용 → 각 항목에서 **구체적 관찰**을 적고 → 이 학기 개념(장·절)에 뿌리를 박은 질문인지 검사 → 아니면 **다시 쓰기**.
- RL 버전의 특징: ML1 템플릿에서 **5번을 두 칸으로 늘림** — “근거가 되는 **개념**” + “반박하려면 어떤 **새 실험**이 필요한지”.
- 답이 **새 실험**이어야만 질문이 3점.

리뷰 템플릿 (5번의 두 칸이 핵심)

칸	내용
1. 환경 설명	상태·행동·보상·주 지표(greedy 평가 리턴? 학습중 리턴?)가 보고서에서 추적 가능한가? 베이스라인(무작위) 리턴 은 명시됐는가?
2. 알고리즘 선택	이 환경의 어떤 특성(상태 수, 보상 구조, 확률 전이) 이 비교를 정당화하는가? 그 연결이 Ch4~7 개념으로 설명되는가?
3. 수식적 정당화	“ ≥ 1 개”(8.1)를 채웠는가? 짚은 개념이 실제로 관측한 숫자 와 일치하는가(단순 인용이 아닌가)?
4. 결과의 정직성	시드 ≥ 3 , 시드별 숫자 표, 평가 프로토콜 ($\epsilon = 0$? 에피소드 수?) 명시. 불안정한 시드·구간이 정직하게 보고됐는가?
5. 반박 가능한 질문(필수, 1개 이상)	근거가 되는 개념: Chapter __ 절 __ (개념: __) 발표팀이 답하려면 필요한 새 실험/계산: __ 질문: __ (발표팀이 답이 나쁘면 결과가 흔들리는 것이어야)

3점 도달 조건

5번의 “개념”과 “새 실험” 두 칸이 모두 채워져야 3점. 둘 중 하나가 비어 있으면 **반박 불가능한 리뷰**.

자주 하는 실수: 학습 곡선 한 번만 보고 결론 내리기

- RL에서 특히 부실한 리뷰: “곡선이 잘 올라갔으니 성공”. 먼저 물어야 할 것:
 - ▶ 그 곡선이 **무작위 시드 하나만** 돌린 결과인가, 여러 번 반복해 **일관된 경향**인가?
 - ▶ ϵ 이 충분히 감소했는가(또는 고정된 채 **최종 정책 평가까지 탐험이 섞여** 있지는 않은가)?
- 구조적으로 더 위험한 이유: 곡선의 “오르다/안 오르다”가 **학습의 진전과 분리될 수 있기 때문**.

Montezuma's Revenge (DQN, 2015; R2D2, 2019)

DQN 에이전트는 수백만 스텝을 학습해도 **점수가 거의 0**에 머물러 “아무것도 배우지 못한다”고 판단됐고, 2019년 모델 기반 R2D2가 처음 풀었을 때 “점수 0”이 난이도/방법의 한계였음이 확인됨. **하나의 지표가 평탄했다만으로는 “배우지 못했다”를 결정할 수 없다.**

학습 곡선 3문: 리뷰어가 던지는 질문

곡선을 보고 던져야 할 질문 3가지

- ① **시드** — 이 곡선은 시드 몇 개의 평균(또는 시드별 범위)인가요? 시드 1개라면 “일관된 경향”을 말할 수 없다.
- ② **ϵ 스케줄** — 학습 도중 ϵ 이 어떻게 변했나요? 평가 때 $\epsilon = 0$ 이었나요?
- ③ **지표 분리** — 곡선이 “학습 중 리턴”인지 “학습 후 평가 리턴”인지? 둘은 다른 대상의 측정값이다(8.1 § 비교 프로토콜).

“곡선이 평탄해서 못 배운 것 같다”(1점 인상평) 대신, “그 평탄한 구간에서 **에피소드 길이나 보이지 않는 중간 지표**(특정 구역 도달 여부, Q값의 변화)는 개선됐나요? 평탄한 것이 **측정하지 않은 지표** 때문은 아닌가요?”(3점)로 번역하는 것.
3문 = § 5가지 패턴 1·2번 + 8.1 § 비교 프로토콜의 리뷰어 언어 압축.

우리 팀 발표를 리뷰하기: 발표 전 셀프-리뷰

- 최선의 전략: 네가 심사할 때 던질 수 있는 가장 날카로운 질문을, 네 발표 전에 스스로 던져보고 답을 준비해두는 것.
- § 5가지 패턴의 5개 질문을 자기 팀 보고서에 적용:
 - ▶ (1) 시드 3개 greedy 평가 표가 보고서에 있는가?
 - ▶ (2) 평가 프로토콜 문장($\varepsilon = 0, 200$ 에피소드, 모든 알고리즘·시드에 동일)이 있는가?
 - ▶ (3) 무작위 정책 리턴이 실측 숫자로 적혀 있는가?
 - ▶ (4) $\alpha \cdot \varepsilon$ 민감성을 한 줄이라도 검토했는가?
 - ▶ (5) 불안정한 시드·구간이 “잘 안 된 부분” 절에 사라지지 않고 있는가?

왜 발표 전인가

이 5가지에 답이 없다면, 발표 전에 해결해두는 것이 발표 중에 3점 리뷰를 받는 것보다 **항상 낫다**. Block B Ch 16.1도 동일한 구조(발표 → peer-review) — 이 셀프-리뷰 습관이 학기 말까지 이어진다.

확인 문제 (1/2): 리뷰어가 될 때의 판단력

Q1. “시드 3개를 돌려 greedy가 $-13/ -14/ -12$ 로 Q-learning이 안정적이다” — 이 편차는 무엇의 편차이고, 무엇의 편차가 아니인가

- 세 숫자 = 세 개의 서로 다른 정책의 greedy 평가 (학습 과정의 무작위성/시드가 만든) — “어떤 정책이 학습됐는가”의 편차이지, “그 정책을 재는 **측정 오차**”가 아님.
- 평가 에피소드를 늘려도 **사라지지 않음**. 각 시드 자체(-13 등)는 200 에피소드 측정의 평균이라 **그 시드의 측정 오차**만 줄어듦.
- “안정적이다”라 말하려면 **두 층을 구분**: “시드 간 편차 ± 1 , 각 시드 측정 오차 $\pm 0.x$ ”.

Q2. “학습에 $\epsilon = 0.1$ 쓰고, 최종 평가는 학습된 정책으로 200 에피소드”의 모순

- $\epsilon = 0.1$ 이면 매 스텝 10% 확률로 무작위 $\rightarrow$ “학습된 정책으로”도 **탐험이 섞인** 측정.
- CliffWalking에서 이는 **결론의 방향을 가름**: $\epsilon = 0.1$ 평가 $\rightarrow$ SARSA -21.3 vs Q -45.3 (SARSA 우위); $\epsilon = 0 \rightarrow$ Q -13 vs SARSA -17 (**순수 역전**). 질문: “최종 평가가 $\epsilon = 0$ (greedy)였나요? $\epsilon = 0.1$ 으로 재평가하면 순위가 뒤집힙니다(Ch 6.3) — 두 프로토콜 모두로 시드 3개를 재실행해주세요.”

확인 문제 (2/2): 2점 → 3점으로 바꾸기

Q3. “Q-learning이 off-policy라 SARSA보다 높았다. 이는 Ch 6.3 이론과 일치한다”로 끝난 정당화

- 2점 — 개념(Ch 6.3)은 인용했지만 **관측 숫자가 없고** 발표팀이 “네, 이론이 맞습니다”로 넘길 수 있음.
- 3점 변환(**관찰 + 개념 + 왜 문제인지**): “off-policy 라는 설명은 학습 도중 리턴(SARSA -24 vs Q -49)에는 **반대 방향**을 예측 — 절벽 옆 경로는 탐험 한 번이 -100이라 학습중에는 더 낮게 나와야. greedy(-13 vs -17)가 높다는 것만으론 경로 길이 차이일 수 — 13스텝 vs 17스텝으로 연결한 설명이 있습니까?”

Q4. “왜 $\gamma = 1.0$ 인가요? 0.95로 하면?”이 3점인가

- 이대로는 2점 — γ 는 하이퍼파라미터가 아니라 **MDP의 정의**(Ch 3.1 5요소)에 속함. “왜 $\gamma = 1.0$?”은 “왜 이 문제를 풀어요?”에 가까워 **문제 정의**의 문제.
- 같은 의도의 3점: “여러분이 **해결하려는 문제**가 할인율에 민감한가요? $\gamma = 0.95$ 로 바꾸면 greedy 정책의 경로가 달라지는데, 이 환경에서 $\gamma = 1.0$ 이 자연스러운가 — 그 선택이 8.1 “문제 정의” 절에 근거와 함께 명시됐나요?” → 체크리스트 **1번(문제 정의)**으로 연결되는 개념 있는 질문.

확인 문제 Q5 + 자주 묻는 질문

Q5. “시드 3개: SARSA –17/ – 17/ – 17, Q –13/ – 13/ – 13. Q-learning이 더 좋다”
→ 리뷰어 “Q-learning이 항상 더 좋은가요?”

- **정직한 범위:** “이 환경·이 설정(α, ϵ 스케줄, 500 에피소드)에서 시드 3개로 확인한 한도에서 Q의 greedy 평가가 앞선다”. 이 실험 **외부로**(다른 환경· α ·스케줄)의 일반화는 지지되지 않음.
- **말하지 말아야 할** 추론: “Q-learning이 더 좋은 알고리즘이다” — 이 비교는 탐욕적 실행 시 어느 정책이 나은가의 답이지 알고리즘 우열의 답이 아님(학습중에는 SARSA가 앞서며, 6.3절 on/off-policy 차이로 설명).

FAQ — (a) 하이퍼파라미터 선택 근거까지 물어보는가? **그렇다**, “적당히” 고른 값이 결과에 얼마나 큰 영향(Ch 7.2 n 튜닝)을 주는지 = 방법론 적절성의 핵심. (b) “문제 없이 잘한 팀”에서 3점 질문? “보이지 않는 것 $\neq$ 확인되지 않은 것 — 3점은 항상 **확인되지 않은 영역**(시드 5개, α 민감성, 다른 평가 프로토콜)에서. (c) 발표팀이 그 자리에서 답 못 하면 점수? **리뷰어 점수(질문 품질)와 발표팀 점수는 따로** — 리뷰어는 질문을, 발표팀은 답을. (d) 결과가 정말 나빴던 팀? **“나쁜 결과”는 좋은 리뷰의 대상** — “그 진단이 Ch 4~7 개념으로 타당하나요?” 방법론만 보고, 사람은 보지 않는 것. (e) 10분뿐인데? 4항목 모두에 3점 질문이 **아님** — 4항목 다 확인 후 **가장 날카로운 질문 1개**를 5번 칸에. 시간이 부족하면 “실험 프로토콜의 정직성”(시드, 평가 ϵ , 베이스라인)을 **먼저** — 이 결함은 뒤의 결과 해석 전체를 흔듦.

8.3 중간고사 대비 총정리

이 절: 새 개념 0개, 하는 일 세 가지

- (1) Ch 2~7 이론을 “손으로 재현할 수 있는 형태”로 압축.
- (2) 준비도를 스스로 재는 **자가진단** 제시.
- (3) 8.1에서 4주간 쌓아온 프로젝트 절차를 복습 자료로 재작성.

시험의 성격

시험은 “**Block A의 개념을 새로운 MDP에 적용하는 것**”이므로, 암기는 쓸모가 없고 이 절은 “**스스로 유도하는 습관**” 하나에 맞추어져 있다.

특히 “벨만방정식을 터미널부터 거꾸로 대입해 직접 풀기”(Ch 4)와 “TD 오차의 수렴 조건 논증”(Ch 6)이 다른 MDP에도 그대로 적용되는지가 좋은 복습.

장별 핵심 질문 (Ch 2~7)

장	핵심 질문	다시 볼 개념
Ch 02	상태 없이도 탐험-활용 딜레마가 있는가	ϵ -greedy, 낙관적 초기화, UCB
Ch 03	RL 문제를 어떻게 수학적으로 정식화하는가	MDP 5요소, 마르코프 성질, 할인율
Ch 04	모델을 알 때 최적 정책을 어떻게 계산하는가	벨만방정식, 정책반복/가치반복, 축소 사상
Ch 05	모델 없이 에피소드 결과만으로 배울 수 있는가	첫방문 MC, MC 제어, 중요도 샘플링
Ch 06	에피소드가 끝나길 기다리지 않고 배울 수 있는가	TD 오차, Q-learning vs SARSA
Ch 07	MC와 TD 사이, 경험 재사용은 어떻게 하는가	n-step TD, 적격흔적, Dyna-Q

시험 형식 (참고)

100분, 4문항 — ① 템플릿 ①(거꾸로 대입)을 새 MDP에 적용, ② 벨만방정식·정책반복 유도/수렴 논증, ③ MC/TD 갱신 규칙의 수치 계산(경로 따르기), ④ 개념 비교 단답(SARSA vs Q, 편향-분산, on/off-policy). **모든 문항은 계산 과정을 보여야 한다** — 최종 답만 맞고 과정 없으면 과정이 맞던 지점까지만 부분점.

유도 템플릿 ①: 거꾸로 대입 (backward induction)

- **빠대**: 전이가 “앞으로만” 흐르는 MDP에서 벨만방정식 $V^\pi(s) = R(s, \pi(s)) + \gamma V^\pi(s')$ 를 터미널에서 출발해 거꾸로 한 칸씩 대입하면 연립방정식을 풀지 않아도 풀린다.
- **왜 동작하나**: 전이 그래프가 사이클 없이 한 방향 ($0 \rightarrow 1 \rightarrow 2$ 사슬, 유한 스텝 후 “끝” 보장)이면 연립방정식의 마지막 줄이 더 이상 다른 상태를 참조하지 않음 $\rightarrow$ 해가 터미널에서 “퍼져 나간다”. (Ch 3 3칸 보드게임, Ch 5 블랙잭, 7.3의 5×5 격자)

작은 예제: 3-state 사슬, $\gamma = 0.9$ ($0 \rightarrow 1: -1, 1 \rightarrow 2: -1, 2 = \text{터미널}$)

$$V(2) = 0 \text{ (터미널)} \quad V(1) = -1 + 0.9 V(2) = -1 \quad V(0) = -1 + 0.9 V(1) = -1.9$$

정확성 확인(답안에 한 줄): $V = (-1.9, -1, 0)$ 를 벨만방정식 양변에 다시 대입해 좌우가 일치하는가?

자주 하는 실수 — (1) 터미널 진입 보상 자체를 빼먹기, (2) **대입 방향을 거꾸로** 쓰기($V(1) = -1 + 0.9V(0)$ 로). 대입 방향은 “다음 상태의 값이 이미 알려진 쪽” = 전이 화살표와 반대.

유도 템플릿 ②: 후보+검증 (candidate & verify) — 뼈대·해

- **뼈대**: (1) 최적값의 **후보** 추측, (2) 그 후보가 성립한다고 가정하고 방정식 풀기, (3) 각 상태에서 후보 행동이 정말로 다른 행동보다 나은지 **검증**.
- 벨만 **최적**방정식 $Q^*(s, a) = R + \gamma \max_{a'} Q^*(s', a')$ 의 max는 “argmax인 행동을 모르면 펼칠 수 없는” 함수 → **검증이 선택이 아니라 필수**.

작은 예제 (강의에서 안 써본 새 MDP, $\gamma = 0.9$)

상태 S, G, T. S: “run”은 0.7 확률로 G, 0.3 확률로 S로 미끄러짐 (보상 0); “rest”는 S에 남음(보상 -1). G: “collect”로 T(보상 +3). T=터미널.

- **Step 1 (후보)**: +3의 유일한 길 = G에서 collect → $Q^*(G, \text{collect}) = 3$. S에서 rest는 매 스텝 -1 → 후보: **run@S, collect@G**.
- **Step 2 (해)**: run@S 가정 하에 $V^*(S) = 0.9(0.7 V^*(G) + 0.3 V^*(S)) = 1.89 + 0.27 V^*(S)$
— 자기 자신으로 돌아오는 확률 $0.9 \times 0.3 = 0.27$ 때문에

$$V^*(S) = \frac{1.89}{1 - 0.27} = \frac{189}{73} \approx 2.589$$

유도 템플릿 ②: 검증이 안전장치인 이유

Step 3 (검증): run이 정말 rest보다 나은가

$$Q^*(S, \text{run}) = 2.589 > Q^*(S, \text{rest}) = -1 + 0.9 \times 2.589 = 1.330 \quad \checkmark$$

일치 $\rightarrow$ 후보 성립, 답: $V^*(S) = 2.589, V^*(G) = 3$.

- **Step 3은 형식이 아니라 안전장치** — Step 1의 추측이 틀렸다면 Step 2의 값은 “틀린 정책을 최적인 것처럼 놓고 푼 값”, Step 3의 부등호가 뒤집힘. (계산이 $Q(\text{rest}) = 3.5 > Q(\text{run})$ 이었다면 = “후보가 틀렸으니 다시 추측하라”는 신호.)

정책반복(Ch 4.2)과의 연결

이 템플릿은 “improve + evaluate” 루프를 **손으로 단축**한 것. $\pi_0 = \text{rest}@S$ 로 시작했다면 정책평가 $V^\pi(S) = \frac{-1}{1-0.9} = -10$, improve에서

$Q^\pi(S, \text{run}) = 0.9(2.1 + 0.3 \times (-10)) = -0.81 > -10$ 으로 run 교체, 재평가에서 다시 2.589 — **1회 반복에 같은 답**. “후보 추측은 정책반복을 손으로 건너뛰는 단축키”를 시험에서 말하면 이 템플릿은 끝.

유도 템플릿 ③: 축소 사상 $\rightarrow$ 기하급수 감소

빠대 (“ T 는 γ -축소 사상”이 주어졌을 때)

- 1 오차를 $\|V_n - V^*\|$ 로 표기.
- 2 V^* 가 고정점 $\rightarrow \|V_n - V^*\| = \|TV_{n-1} - TV^*\| \leq \gamma \|V_{n-1} - V^*\|$.
- 3 n 번 반복: $\|V_n - V^*\| \leq \gamma^n \|V_0 - V^*\|$.
- 4 $\gamma < 1 \Rightarrow \gamma^n \rightarrow 0 \rightarrow$ 수렴.

- **왜 표준인가:** 4.3절 빈칸채움 풀백이 정확히 이 4줄. Ch 6 TD(0)/Q-learning 수렴 논증도 같은 빠대에 조건 교체 — “TD 오차 0인 Q ” $\leftrightarrow$ “고정점”, “ α 충분히 작고 모든 (s,a) 무한 방문”이 축소 조건 역할(확률적 설정은 기댓값에서만 축소 성립 — Ch 06 FAQ 복습).
- **자주 하는 실수:** Step 2에 쓸 “ V^* 는 고정점” 전제를 잊음 — 없으면 $TV_{n-1} - TV^*$ 를 처리할 근거 없음. Q-learning 버전은 6.3절 연습문제 3의 세 조건 (α 충분히 작음, 모든 (s,a) 무한 방문, TD 오차 0 $\Leftrightarrow$ 벨만 최적방정식의 해)을 빠뜨리지 않는 것이 채점 기준.

숫자 감각: $\gamma = 0.9$ 인 기하급수 감소

반복 수 n	γ^n	뜻
5	0.590	초기 오차의 59% 이하로
10	0.349	
20	0.122	약 1/8
50	0.0052	초기 오차의 99.5%가 사라짐

“오차가 1% 이하가 되기까지 몇 번?” = $\gamma^n < 0.01$ 을 n 에 대해 풀기: $n > \ln 0.01 / \ln 0.9 \approx 44$ 번.

3가지 템플릿(거꾸로 대입 / 후보+검증 / 축소 사상 수렴)이 시험 손유도 문항의 **전부**를 덮는다 — 뼈대를 외우는 것이 아니라 **각 뼈대의 빈칸을 스스로 채우는 것**이 목표.


시험에서 쓰는 한 줄

“ γ -축소 사상 + 고정점 + $\gamma < 1$ 이 주어지면, 오차는 γ^n 배로 기하급수 감소해 **임의 초기값에서 수렴**한다.” — 이 3개 전제(축소, 고정점, $\gamma < 1$)를 **모두** 명시해야 논증 완성.

Block A 개념 지도: 한 질문에 여섯 각도

- 여섯 장 = “미래의 불확실한 보상을 지금 어떻게 수치화할 것인가”라는 한 질문에 여섯 가지 각도에서 답한 것. 복습 = 주제 6개 훑기가 아니라 **답들 사이의 관계**를 다시 그리는 일.
- 구조: 위 = 문제 정식화(Ch 2~3: 밴딧 → MDP 5요소 → 리턴/할인율). 가운데 = 4가지 경로 — 모델 기반 (벨만 → 정책반복/가치반복, Ch 4) vs 모델 프리 (MC Ch 5 → TD Ch 6 → n-step·적격흔적·Dyna-Q Ch 7). 아래 = 모든 경관을 가로지르는 **공통 축**: 편향-분산, 탐험(ϵ -greedy·낙관적 초기화·UCB), 수렴(목표값 오차→0, α 작게, 무한 방문), on/off-policy. 오른쪽 = Block B(Ch 9~16) 화살표: Q 표를 **신경망** 으로(DQN), 로봇 시뮬레이션.

Block A(Ch02~07) 개념 지도 — 한 질문에 여섯 각도의 답



개념 지도를 읽는 법: 시험 기법 두 가지

(1) “질문이 지도의 어디를 가리키는지”

- “SARSA는 on-policy인가” = 가운데 행(TD 박스)과 아래 행(on/off-policy 축)이 만나는 **엣지**.
- “왜 $n = 5$ 가 $n = 1$ 보다 좋은가” = n-step 박스와 **편향-분산 축**의 엣지.
- “어떤 박스와 어떤 축의 교차점인가”를 5초 안에 짚으면 **답을 그 축의 용어로** 말할 수 있다.

(2) “엣지가 곧 '왜'다”

- 박스(개념 **정의**) 자체를 묻는 문항은 드뭄.
- 빈출 문항은 거의 전부 **엣지**: 왜 MC→TD인가, 왜 ϵ -greedy가 모든 박스에 붙는가, 왜 γ 는 1보다 작은가.
- **박스는 외우기 쉬운데, 엣지가 시험이다.**

복습 우선순위는 시험 빈출 순서와 거의 같음: (1) MC→TD, (2) TD $\leftrightarrow$ 편향-분산(n 의 다이얼), (3) TD $\leftrightarrow$ on/off-policy(SARSA vs Q), (4) MDP $\rightarrow$ 모든 박스. 네 개를 한 문장씩 말할 수 있으면 지도는 끝.

확인 문제: 장을 넘나드는 복습 4개 (답)

질문	답 (핵심)
1. Ch 2 밴딧과 Ch 3 MDP의 관계	밴딧 = 상태가 하나뿐 이고 어떤 행동을 해도 같은 상태로 전이하는 특수한 MDP . 탐험-활용 딜레마는 이 특수 경우에도 그대로, Ch 5~6의 ϵ -greedy = 그 전략의 MDP 전체 확장
2. 정책반복/가치반복(Ch 4) vs MC/TD(Ch 5~6)의 근본 차이	Ch 4는 전이확률 $P(s' s, a)$ 를 정확히 안다고 가정 하고 벨만방정식을 반복 대입(모델 기반). Ch 5~6은 P 를 몰라도 실제 경험 으로부터 추정(모델 프리) — 단, 둘 다 “벨만방정식이라는 같은 재귀 구조 ”에 기대
3. MC / TD(0) / n-step의 목표값을 편향-분산으로 한 줄	MC: 실제 리턴 G_t 를 그대로 → 편향 없으나 분산 큰 / TD(0): 한 스텝 실제 + 추정치 → 분산 작으나 편향 있는 / n-step: 그 사이(n 이 다이얼, U자 트레이드오프)
4. SARSA vs Q-learning의 on/off-policy 구분이 실전에서 중요한 이유	학습이 실제 위험한 환경 에서 일어나면 학습 도중의 안전까지 고려하는 SARSA(on-policy) 계열이 유리. 시뮬레이터 에서 충분히 학습하고 최종 배포만 중요하다면 목표 정책의 최적성을 직접 배우는 Q-learning(off-policy) 이 유리(Ch 6.3)

한 줄 요약

Ch 2~7의 모든 알고리즘은 “**미래의 불확실한 보상을 지금 어떻게 수치화할 것인가**”에 대한 답 — 이제 이 질문에 **신경망**을 결합해
표에 담을 수 없을 만큼 큰 문제로 나아갈 차례.

복습 자가진단: 20문항 (10초에 한 문장) 1~10

#	장	한 문장 질문
1	Ch 02	밴딧에서 “지금까지 몇 번 당겼는가”가 상태에 들어가야 하는 이유는?
2	Ch 02	ϵ -greedy, 낙관적 초기화, UCB — 각각 탐험을 유도하는 방식 한 단어로
3	Ch 03	MDP 5요소 중 보상함수를 제외한 네 가지를 쓰시오
4	Ch 03	$\gamma < 1$ 이 단순 편의가 아니라 필수인 경우는?
5	Ch 02→03	밴딧과 MDP의 관계를 한 문장으로
6	Ch 04	벨만 방정식과 벨만 최적방정식의 차이를 한 문장으로
7	Ch 04	“T는 γ -축소 사상이다”를 수식 없이 한 문장으로
8	Ch 04	모든 상태가 전이 한 번 만에 터미널에 닿는 MDP에서 정책평가는 몇 번의 반복이면 끝나고 왜?
9	Ch 05	첫방문 MC가 왜 편향 없는가?
10	Ch 05→06	MC 제어와 SARSA는 갱신하는 “목표값”이 어떻게 다른가?

기준: **10초 안에 한 문장**으로 답할 수 있으면 O, 막히면 ☒. 18개 이상 = 준비 완료, 15~17 = ☒가 모인 장 위주로 “자주 하는 실수”+확인 문제 재독, 12~14 = § 유도 템플릿 3가지 손으로 재풀기, 12 미만 = § 복습 주간 일정을 **건너뛰지** 않기.

복습 자가진단: 11~20 + 답 (한 줄)

#	장	한 문장 질문
11	Ch 05/06	MC와 TD(0)의 목표값을 각각 수식으로
12	Ch 06	“TD 오차가 0”이 “벨만방정식을 만족한다”와 같은 말인 이유는?
13	Ch 06	SARSA와 Q-learning의 차이를 한 문장으로
14	Ch 06	CliffWalking에서 “더 짧은 경로”를 배운 알고리즘은? 학습중 리턴이 오히려 더 나쁜 이유는?
15	Ch 07	n-step 리턴 $G_t^{(n)}$ 을 수식으로, $n = 1$ 과 $n = \infty$ (유한)는 무엇으로 퇴화하는가?
16	Ch 07	적격흔적 감쇠율 $\gamma\lambda$ 에서 λ 의 역할?
17	Ch 07	Dyna-Q의 모델이 저장하는 것은? 계획 한 스텝의 비용(대가)은?
18	Ch 05/06	같은 정책의 가치 추정 시 분산 큰 쪽: MC vs TD(0)?
19	Ch 05/06	off-policy가 무엇이고, 왜 중요도 샘플링이 필요한가?
20	Ch 06	Q-learning이 Q^* 로 수렴해도 행동 정책(ϵ -greedy)이 최적이라 말하지 못하는 이유는?

답(한 줄) 예 — 6: 주어진 정책의 가치 평가 vs 최선의 가치를 찾음, 차이 = max 한 줄. 9: 방문 후 실제로 실현된 리턴을 그대로 쓰므로 무편향(부트스트래핑 없음). 12: $\delta = (\text{목표값} - \text{현재 추정})$ 가 모든 (s,a)에서 0인 것 $\Leftrightarrow$ 해당 방정식의 해인 것. 14: **Q-learning**(절벽 옆 13스텝) — 학습중 ϵ 실수 한 번이 -100이라 학습중 리턴은 더 나쁨. 15:

$G_t^{(n)} = \sum_{k=0}^{n-1} \gamma^k R_{t+k+1} + \gamma^n V(s_{t+n}); n = 1 \rightarrow \text{TD}(0), n = \infty \rightarrow \text{MC}$. 17: (s,a)마다 **마지막으로 관찰한** (r, s') ; 계획 = 모델 오차(부정확한 예측의 복리 증식)가 대가. 20: 수렴 대상은 목표 정책(탐욕)의 Q^* 이지, 탐험 수단인 ϵ -greedy 행동 정책이 아님. (나머지: 1 횟수 없으면 “10회 중 5득점”과 “1회 5득점” 구별 불가 / 2 확률적 랜덤·못 간 값을 크게·불확실성 상한 보너스 / 3 $S, \mathcal{A}, P$, 초기 상태 분포 / 4 무한 호라이즌(할인 없는 무한 합은 발산, 축소 사상 논증 전제) / 5 상태 하나뿐인 특수 MDP / 7 거리가 γ 배 이하로 줄어듦 / 8 한 번($V(s) = R + \gamma \cdot 0$) / 10 MC=방문 후 에피소드 끝까지 실제 리턴, SARSA=다음 실제 고른 행동의 1스텝 목표값 / 11 MC $G_t = R_{t+1} + \gamma R_{t+2} + \dots$, TD(0) $R_{t+1} + \gamma V(s_{t+1})$ / 13 실행하는 정책의 가치 (SARSA) vs 탐욕 정책의 가치(Q) — 갱신식에 max 여부 / 16 $\lambda = 0$ 이 TD(0), $\lambda = 1$ 이 MC에 가까움 / 18 MC / 19 행동 정책과 목표 정책이 다른 것, 보정에 가중치(중요도) 필요)

복습 주간 일정 (시험 전 1주)

요일	시간	할 일
월	30분	20문항 자가진단 1차 → ☒가 모인 2~3개 장 특정
화	2시간	§ 유도 템플릿 3가지의 예제를 전부 손으로 풀고 노트북으로 검증
수	2시간	특정 장의 “자주 하는 실수” + 해당 장 확인 문제 재독
목	90분	8.1 프로젝트 노트북을 처음부터 재실행 — “코드의 각 단계를 설명할 수 있는가”에 집중
금	1시간	이 절 확인 문제 4개 + 8.1 확인 문제 4개를 참고 없이 풀어보기
토 오전	30분	20문항 자가진단 2차 — 월요일과 ☒ 개수 비교
일	—	새로운 내용 금지 — 충분한 수면

순서가 왜 이 모양인가

유도가 재독보다 먼저 — 손으로 유도한 뒤에야 “막힌 지점”이 명확해져 재독이 “다 읽어보기”가 아니라 “막힌 지점만 파기”가 됨. **실험이 마지막** — 프로젝트 코드가 “새로운 MDP에 개념을 적용” 그 자체의 가장 좋은 연습이고, 공식이 손에 익은 뒤에야 코드 각 줄에 붙을 개념이 보이기 때문.

자주 하는 실수 (복습판) 1/2

- 갱신식을 외우되 “왜”는 놓치기 — Q-learning 갱신식
 $Q \leftarrow Q + \alpha[r + \gamma \max_{a'} Q(s', a') - Q]$ 를 떠올려도, “목표값이 $r + \gamma \max$ 인 이유”를 묻으면 멈춤. **시험은 과정을 묻는다.** 정답의 길 = 6.3절 두 문장 유도: “벨만 최적방정식의 좌변을 현재 추정치로, 우변을 그대로 쓰고, 추정치를 목표값으로 **한 발** 다가간다.”
- “수렴했다”와 “좋다”를 혼동하기 — 수렴은 **추정값**의 성질(고정된 값에 가까워지는가)이고, 좋다(최적에 가까움)는 **정책**의 성질. 탐험이 부족한 정책은 틀린 값으로 정확히 수렴할 수 있음(8.1의 SARSA – 500 고착 = 극단). “수렴했으니까 문제 없다”는 답안은 **감점**.

자주 하는 실수 (복습판) 2/2

- γ 를 “세 개 역할” 없이 외우기 — (1) 리턴 정의의 “미래를 얼마나 세게 셀지”(Ch 03), (2) 축소 사상의 축소 계수(Ch 04), (3) 적격흔적 감쇠 $\gamma\lambda$ 의 한 인자(Ch 07). “왜 γ 는 1보다 작은가?”에 세 역할로 답해야 완전.
- 편향-분산을 Ch 05에만 쓰기 — n-step의 n (Ch 07), ε 스케줄(8.1), Dyna의 `planning_steps`(Ch 07)은 전부 “두 극단 사이 다이얼”이라는 같은 구조. “편향-분산”이 MC/TD 맥락에서만 나오면 이 학기의 절반은 아직 손에 안 들어온 것.
- 프로젝트 “잘 안 된 부분”을 복습 자료로 안 쓰기 — “이 실험의 이상한 결과를 원인으로 진단하라”형 문항의 자료는 정확히 8.1 보고서의 그 절. 자기 프로젝트의 실패 한 건을 개념으로 해석한 능력은 어떤 참고서로도 대체되지 않음.

연습문제 (1/3): 손유도 — 거꾸로 대입 + n-step

1. (손유도, Tier B) 3-state MDP, $\gamma = 0.9$

State $0 \rightarrow 1$ (보상 -1), State $1 \rightarrow 2$ (보상 -1), State $2 = \text{종료}$ ($V(2) = 0$). 템플릿 ①대로 터미널부터 거꾸로 대입.

- 힌트: $V(2) = 0 \rightarrow V(1) = ? \rightarrow V(0) = ?$.
- 정확성 확인: 4.3절 policy_evaluation로 같은 MDP를 돌려 값 일치 여부 비교(실습 노트북 § 1).

2. (개념, Tier A) n 을 1에서 ∞ 로 키울 때

편향은 **줄고**(부트스트래핑 추정치 비율 감소) 분산은 **증가**(실제 리턴의 무작위성 증가) — 각 이유를 한 문장. “최적의 n 은 문제마다 다르다” = 7.2절의 **U자 곡선**: 작은 n 은 편향 지배, 큰 n 은 분산 지배, 바닥이 문제별 최적.

연습문제 (2/3): 수렴 논증 빈칸 + TD(0) 코딩

3. (손유도, Tier C) 수렴 논증의 빈칸 채우기 (4.3절 연습문제 3 같은 형식):

가정
: 는 T γ 축소- 사상이고, V 는 $*$ 의 T 고정점 ($T V^* = V^*$).
 $V_{n+1} = T V_n$.
Step 1: $||V_1 - V^*|| = ||T V_0 - T V^*|| \leq \gamma * ||V_0 - V^*||$
Step 2: $||V_2 - V^*|| \leq \gamma * ||V_1 - V^*||$
 $\leq \gamma^2 * ||V_0 - V^*||$
Step 3: $||V_n - V^*|| \leq \gamma^n * ||V_0 - V^*||$ 결론
: $\gamma < 1$ 이므로 $\gamma^n \rightarrow 0$, 따라서 $V_n \rightarrow V^*$.

4. (코딩) TD(0) 가치 갱신의 빈칸 채우기

```
def td0_update(V, s, r, ns, done, alpha, gamma):  
    target = r + (0.0 if done else gamma * V[ns])  
    V[s] += alpha * (target - V[s])
```

정확성 확인: (a) done=True일 때 목표값이 r 되는지 출력으로 확인, (b) 7.2절 random walk에서 $\alpha = 1.0$ vs 0.1
비교로 “ α 가 너무 크면 수렴하지 않고 흔들린다” 관찰.

연습문제 (3/3) + 자주 묻는 질문

5. (개념, Tier A) 이 절의 산출물

§ 복습 자가진단 20문항에서 본인이 ☐를 표시한 것 중 **3개**를 골라, 각각에 해당하는 **장·절**과 “말했어야 할 한 줄”을 **자기 언어**로 쓴다. 시험은 정확히 “그 세 문장에 답할 수 있는가”를 묻는 자리.

FAQ — (a) 코딩 문제도 나오는가? **그렇다** — ML1 8.3과 같은 형식, 핵심 로직이 빈칸인 함수 완성. Ch 4/6/7의 “TD 갱신 규칙을 코드로 정확히 옮기기”가 가장 가까운 연습. (b) Block B(Ch 9~16) 준비? **Q-함수(Ch 6) + 벨만 최적방정식(Ch 4)**을 확실하게 — DQN은 사실상 “Q-learning의 Q-테이블을 **신경망**으로 바꾼 것” 이고, 나머지(TD 오차, 경험재현, off-policy)는 이번 학기 개념의 재사용. (c) 여섯 장을 똑같은 비중으로? **아니** — 20문항 자가 진단으로 막힘이 없는 장은 가볍게, ☐가 모인 장에 시간을. **손유도 문제**(거꾸로 대입·후보+검증·축소 사상·TD 수렴)는 시험에서 그대로 나올 가능성이 높아 우선순위 높임. (d) 프로젝트 vs 시험 준비? **이분법이 성립하지 않음** — “개념을 새 MDP에 적용”의 가장 좋은 연습 자료는 **자신의 프로젝트 코드**이고, 프로젝트가 훈련시킨 “프로토콜의 정직성”(시드 ≥ 3 , 평가 분리, 베이스라인)은 시험의 실험 해석 문항에서 **직접 점수**로 환산.

8주차 정리

- ① **8.1 팀 프로젝트** — 시드 $\geq 3 + \text{greedy}(\varepsilon = 0)$ **평가 분리** 프로토콜, 베이스라인, 수식적 정당화(개념+실측 숫자 삼박자). 채점의 절반 = “실험 프로토콜의 정직성” + “결과의 정직성”.
- ② **8.2 Peer-Review** — 4항목 체크리스트(환경 설명·알고리즘 선택·수식적 정당화·결과의 정직성) + **3점 반박 가능한 질문**(개념 명시 + 답이 새 실험이어야). RL 특유의 “우연히 좋은” 패턴 5가지, 특히 패턴 2의 **비대칭**(1차 vs 2차 추락 확률).
- ③ **8.3 총정리** — 새 개념 0개. 손유도 템플릿 3종 (거꾸로 대입 / 후보+검증 / 축소 사상 수렴) + 개념 지도의 **엣지가 시험**.

다음 주 — Chapter 9. DQN

이 주에 체득한 **Q-함수 · 벨만 최적방정식 · on/off-policy**가 곧 DQN의 뼈대 — Q-테이블을 **신경망**으로 통째로 바꾸고, 타겟 네트워크와 경험 재현으로 표 기반에서 불가능했던 **연속 상태 공간**으로 나아간다. 시드·평가 분리·반박 가능한 질문의 습관이 Block B 캡스톤까지 그대로 이어진다.