

고급 시뮬레이션: MuJoCo와 Isaac Sim

MuJoCo 정밀 물리 실습 · GPU 병렬의 원리 · 정밀도×속도 도구 선택 · 자율주행
시뮬레이션

Machine Learning 2 · 14주차

한국과학영재학교 (KSA)

Chapter 14

이번 주차 개요

이 챕터를 마치면

- ① Gymnasium 래퍼 없이 **MuJoCo** XML로 로봇을 직접 정의하고, 무작위 정책과 PD 제어 정책으로 D항(속도 피드백)이 왜 필요한지 궤적으로 설명할 수 있다.
- ② “시간 방향 의존성” 때문에 한 환경은 병렬화할 수 없고, 병렬의 대상은 **환경(초깃값이 다른 복제본)**임을 실측 숫자로 설명할 수 있다.
- ③ GPU 가속의 핵심(모든 상태를 한 텐서에 담아 커널 한 번)을 ML1 Ch. 10.1의 CNN과 비교해 설명하고, numpy로 1,000개 진자를 동시에 시뮬레이션할 수 있다.
- ④ 정밀도 축×속도 축 실측 steps/s로 네 도구(Gymnasium · PyBullet · MuJoCo · Isaac Sim) 고르는 **30초 결정 절차**를 스스로 적용할 수 있다.
- ⑤ 자율주행의 Onboard/Offboard 루프가 policy iteration/Dyna 구조와 같은 모양인 이유와 **SceneDiffuser**의 역할을 개념 수준으로 설명할 수 있다.

● **14.1** XML 진자 정의 · 무작위 vs PD 제어 · 30줄 래퍼 · LCP 접촉

● **14.2** CPU의 “하나씩” 한계 · 커널 한 번 · 1,000 진자 실측 76배

● **14.3** 네 도구 한 표 · 정밀도/속도 두 축 · 30초 결정 절차

● **14.4** Waymo Onboard/Offboard 루프 · policy iteration · diffusion 시나리오

14.1 MuJoCo와 정책 학습 실습

장난감 환경에서 실체 물리엔진으로

- Ch. 13의 Gymnasium 기본 환경: 물리를 **간단한 근사식**으로 계산 — 빠르지만 접촉·마찰은 거칠게 흉내만 냄
- 실전 로봇 연구: 접촉(contact), 마찰 등 중요한 물리 현상은 **훨씬 정교한 물리엔진**이 필요

도구	특징
MuJoCo (2012, Todorov) Isaac Sim (NVIDIA)	CPU에서 도는 정밀 물리엔진 — 접촉·마찰을 LCP로 매 스텝 해결 GPU로 수천 개 시뮬레이션을 동시에 — 렌더링 포함

이번 장이 줄곧 묻는 질문

같은 강화학습 알고리즘 위에 시뮬레이터를 교체했을 때, 무엇이 바뀌고 무엇이 그대로 남는가?

정밀하고 빠른 물리는 어디까지 필요한가, 그 비용을 누가 지불하는가 — 실측 숫자까지 붙여 답한다.

이 장의 위치: 알고리즘은 그대로, 시뮬레이터만 올린다

- Ch. 13의 전제: “**시뮬레이터 안에서 먼저 익히고, 이후에 실물로 옮긴다**” (PPO로 Reacher 학습 · 평가 프로토콜 · reality gap 대응)
- 이번 장: **알고리즘은 그대로 두고**, 시뮬레이터 자체를 실전 연구 수준으로 올리는 장

직접 확인해볼 사실

같은 `env.step()` 위에 **물리엔진만 바꾸면 된다** — 14.1에서 30줄 래퍼로 시연, 14.2에서는 “GPU로만 옮긴다”로 그 차이를 실측한다.

- 다음 장(Ch. 15)은 물리 모델이 **주어지지 않는** 문제 — 모델이 학습될 대상이 되는 경우 (MCTS · World Models)
- 시뮬레이터가 주는 경험인지, 배운 모델이 주는 경험인지에 따라 **경험을 모으는 방식**이 달라진다 — 그 계산부터 짚어둔다

MuJoCo: XML로 모델, mj_step으로 시뮬레이션

MuJoCo(Multi-Joint dynamics with Contact)는 관절·접촉·마찰을 물리적으로 정확하게 계산하는 엔진 — 2021년 무료 공개 후 로봇 RL 연구의 사실상 표준. 모델은 **XML**로 정의한다:

```
import mujoco
xml = """
<mujoco>
  <worldbody>
    <light name="top" pos="0 0 1"/>
    <geom type="plane" size="1 1 0.1"/>
    <body pos="0 0 1">
      <joint type="free"/>
      <geom type="sphere" size="0.1" rgba="1 0 0 1"/>
    </body>
  </worldbody>
</mujoco>
"""

model = mujoco.MjModel.from_xml_string(xml)
data = mujoco.MjData(model)
for step in range(5):
    mujoco.mj_step(model, data) # 물리법칙에따라한스텝전진
print("스텝5 후공의높이 : ", round(data.qpos[2], 4))
```

자유낙하로 검산: 한 스텝 ≈ 0.002 초

- free 관절: 위치 q_{pos} 7개 성분, 속도 q_{vel} 6개 — 공 하나만 떠 있어도 상태가 이 정도
- 방향을 4차원 **쿼터니언**으로: 유러 각은 **짐벌 락** 기이점에서 계산이 깨지지만, 쿼터니언은 안 깨진다
- 5스텝: $1.0000 \rightarrow 0.9994$ m (아직은 아주 조금)

검산: 50스텝(≈ 0.1 초)

자유낙하 공식 $h = 1 - \frac{1}{2}gt^2$ 의 예측은 **0.951 m** — 실제 시뮬레이션 값 **0.95 m**으로 거의 정확히 일치. 즉 mj_step 한 번 = 물리 시간 약 **0.002초**.

- 같은 API(MjModel / MjData / mj_step)로 다리가 여러 개인 로봇, 로봇팔, 인간형까지 표현
- Gymnasium의 HalfCheetah · Ant · Humanoid — Ch. 13.2의 Reacher-v5 · Ant-v5도 이 엔진 위에 있다

환경이 바뀌어도 알고리즘은 그대로 (선언)

- Ch. 9-13에서 배운 DQN·PPO: 환경이 CartPole이든 MuJoCo 기반 로봇이든 **바뀌지 않는다**
- `env.step()` 인터페이스만 지키면, 물리엔진이 훨씬 정교해져도 **알고리즘 쪽 코드는 그대로**

이 절에서 할 일

선언을 멈추고 **시연**으로 바꾼다 — Gymnasium 래퍼 없이 MuJoCo API를 직접 써서 진자 하나를 정의하고 제어한다.

관절(joint) hinge: 한 축만 회전

액추에이터(actuator) motor: 그 관절에 토크를 가하는 모터

실습: XML로 진자 + PD 제어 정책

```
import mujoco
import numpy as np
xml = """
<mujoco>
  <option gravity="0 0 -9.81"/>
  <worldbody>
    <body pos="0 0 1">
      <joint name="hinge" type="hinge" axis="0 1 0"
        damping="0.1"/>
      <geom type="capsule" fromto="0 0 0 0 0 -0.5"
        size="0.02" mass="1"/>
    </body>
  </worldbody>
  <actuator>
    <motor joint="hinge" gear="1" ctrlrange="-5 5"/>
  </actuator>
</mujoco>
"""

model = mujoco.MjModel.from_xml_string(xml)
data = mujoco.MjData(model)
data.qpos[0] = 3.0      # 목표(0)에서 멀리떨어뜨려시작
mujoco.mj_forward(model, data)
```

진자 모델의 요소들

- q_{pos} : 1개 — 힌지 각도 θ q_{vel} : 1개 — 각속도 $\dot{\theta}$
- $\theta = 0$: 막대가 아래로 수직인 **자연 휴식 상태** (목표)
- $damping=0.1$: 관절 자체의 마찰 — 속도에 비례해 반대 방향 힘을 **자동**으로 가함


항목	의미
capsule fromto	축(0,0,0)에서 끝(0,0,-0.5)까지 0.5 m 막대
ctrl	우리가 매 스텝 직접 지정하는 토크
실제 힘	ctrl + 마찰력 합산

$$\text{토크} = -3\theta - 0.5\dot{\theta} - \textbf{P항: 각도만큼 반대 힘} / \textbf{D항: 각속도만큼 "브레이크"}$$

200스텝 비교: 무작위 vs PD

200스텝 실행 검증 (seed 0):

정책	결과
무작위 정책	평균 $ \theta = 2.97$ (초기 3.0에서 거의 안 줄어듦)
PD 제어 정책	평균 $ \theta = 1.69$, 최종 $\theta = -0.065$



파란 실선(PD): 큰 진폭으로 흔들리다가 진폭이 줄며 거의 0(목표)에 안착. **회색 선(무작위):** $\pm\pi$ 안에서 이리저리 떠돌다 처음 위치(약 3.0) 근처에 그대로 머문다. θ 단위: 라디안.

● Ch. 13.2에서 이미 본 패턴 — 이번엔 **래퍼 없이** `MjModel / MjData / mj_step`을 직접 다룸

“평균 1.69인데 최종 -0.065” — 모순인가

- 모순이 아니다 — 두 정책이 어디에 있느냐가 아니라 어떻게 움직이느냐를 보여주는 차이
- PD는 감쇠 진동: 진폭이 갈수록 작아지는 진동

숫자가 다른 이유

200스텝 **중간**에는 여전히 큰 각도에서 자주 지남 $\Rightarrow$ 평균이 1.69로 높다. 200스텝 **끝**에는 이미 중심(0) 근처 $\Rightarrow$ 최종값 -0.065. 완전한 안착($|\theta| < 0.1$ 그리고 $|\dot{\theta}| < 0.1$)은 약 **680스텝**쯤에야 온다.

- 무작위 정책은 평균도 최종값도 2.9 — “처음과 거의 같은 자리”에 있다는 점이 핵심

실전: Gymnasium이 아직 환경을 만들어 두지 않은 커스텀 로봇을 RL로 제어하려면, 정확히 이 수준(XML로 모델 정의 + ctrl 배열에 행동)에서 Gymnasium 환경 클래스를 직접 작성한다.

자주 하는 실수: D항을 빼거나 부호를 뒤집으면

“PD가 마법처럼 보인다” — 그 마법의 대부분은 **D항** ($-0.5 \dot{\theta}$)에서 온다. 이득만 바꿔 200스텝 실행 검증:

정책 (토크)	200스텝 후 $ \theta $	결과
완전한 PD $-3\theta - 0.5\dot{\theta}$	0.065	목표(0)에 접근
P만 -3θ	1.31 (각속도까지 11.5!)	크게 진동만 함
너무 약한 PD $-1\theta - 0.2\dot{\theta}$	0.69	거의 못 줌
부호 오류 $+3\theta - 0.5\dot{\theta}$	7.62	발산(목표와 반대)
제어 없음 (0)	2.60	처음 그대로

왜 P만으로 “위험한 고속 진동”인가

- P항(“각도가 크면 반대 방향으로 힘”)만으론: 막대가 **중심을 지날 때마다 관성으로 과속** $\Rightarrow$ 한쪽 끝까지 쏘아올리고, 다시 반대쪽으로
- 마찰(damping)이 아주 적어 에너지가 거의 안 줄므로 $|\theta| \approx 1.3$, 각속도 11.5에 갇힘
- **D항**: 각속도에 비례해 “지금은 빨리 가니까 브레이크” 힘을 덧붙여 **진동을 죽여준다**
- 부호 오류($+3\theta$): “각도가 크면 더 크게 **같은 방향으로**” $\Rightarrow$ 시스템에 **에너지 주입** $\Rightarrow$ 발산
- $\theta = 0$ 이 **안정 균형점**(아래로 처진 상태)인지 **불안정 균형점**(위에서 균형)인지 틀리면, 아무리 잘 학습해도 안착하지 않는다

확인: D항 없이 학습은 될까?

RL과의 직결

정책 그래디언트로 “어떤 토크가 좋은가”를 배우려면, 좋은 정책 (D항 포함)과 나쁜 정책(P만)의 리턴이 확실하게 달라야 한다.

- P만으로 200스텝을 못 넘기거나 발산 $\Rightarrow$ 보상 신호가 “이 정책은 처참하다” $\Rightarrow$ **학습이 오히려 쉬워짐**
- **약하지만 P만** 같은 “아까운 실패”(0.69) $\Rightarrow$ 보상 차이가 작아 **신호가 희미해진다**

원리

물리적으로 안정하지 않은 정책은, 강화학습이 **수학적으로** 배우기 전에 물리 시뮬레이션이 먼저 **안정적으로** 살아야 하는 이유다.

물리 시뮬레이터를 Gymnasium “환경”으로 감싸기

- Ch. 9–13의 알고리즘(DQN, PPO)을 이 MuJoCo 진자에 그대로 달아본다
- 필요한 것은 **딱 하나** — MuJoCo를 (s, a, r, done)을 돌려주는 reset() / step() 인터페이스로 **감싸는** 작은 클래스

reset()

- q_{pos} 초기화
- (상태, 정보) 반환

step(action)

- ctrl에 행동 넣고 mj_step
- (다음 상태, 보상, 종료 여부) 반환

이 30줄 클래스는 Reacher-v5 · Ant-v5가 내부에서 하는 일의 **미니판**이다.

30줄 래퍼: MuJoCoPendulum

```
class MuJoCoPendulum:
    """raw MuJoCo 진자를 Gymnasium 스타일 (s, a, r, done) 환경으로감싼다 ."""
    def __init__(self, seed=0):
        self.model = mujoco.MjModel.from_xml_string(xml) # 위의 xml
        self.data = mujoco.MjData(self.model)
        self.rng = np.random.default_rng(seed)
        self.max_steps = 200

    def reset(self, seed=None):
        if seed is not None:
            self.rng = np.random.default_rng(seed)
        self.data.qpos[0] = 3.0 # 목표에서먼각도
        self.data.qvel[0] = 0.0
        mujoco.mj_forward(self.model, self.data)
        self.t = 0
        return np.array([self.data.qpos[0], self.data.qvel[0]]), {}

    def step(self, action):
        self.data.ctrl[0] = float(np.clip(action, -5, 5)) # 토크한도
        mujoco.mj_step(self.model, self.data)
        th = self.data.qpos[0]
        reward = -th * th # 예0 가까울수록보상금
        self.t += 1
        done = self.t >= self.max_steps
```

핵심 메시지: 시연된 사실

이 MuJoCoPendulum에 PD 정책을 그대로 걸어 200스텝:

정책	결과
----	----

PD	최종 $(\theta, \dot{\theta}) = (-0.065, -6.26)$, 누적 보상 -777
----	--

무작위	평균 $ \theta = 2.97$
-----	----------------------

⇒ 바로 위에서 mj_step을 직접 돌린 결과와 **완전히 같다**.

이번 절의 핵심

“환경이 CartPole이든 MuJoCo 로봇이든 **알고리즘은 바뀌지 않는다**” — 이번엔 선언이 아니라 **30줄 래퍼로 시연된 사실**. gym.make("Pendulum-v1")을 MuJoCoPendulum()로 바꾸는 **한 줄**만 고치면 DQN·PPO 코드가 그대로 동작한다.

왜 MuJoCo가 “정밀”한가: LCP 접촉

- “정밀”은 속도나 모델 크기가 아니다 — 핵심은 **접촉(contact)**을 푸는 방식
- 공이 바닥에 **닿는 순간**은 단순 미분방정식이 아니다:

두 조건이 “동시에”

비침투(non-penetration): 겹쳐 들어가면 안 되지만 — **비음(non-negativity)**: 겹치지 않을 땐 힘 필요 없음 $\Rightarrow$ 수학적으로 **선형 보완 문제(LCP, Linear Complementarity Problem)**라는 특별한 형태의 최적화

- MuJoCo는 이 LCP를 **매 스텝**에서 안정적으로 풀어낸다

LCP를 매 스텝 푸는 것의 값

- ① 공이 바닥에 부딪혀 튕기거나 멈추는 행위가 **계산이 깨지지 않고**(폭주/NaN 없이) 자연스러워짐
- ② 다리 로봇의 발이 바닥에 붙었다 떨어지기를 반복하는 **걸음** 같은 복잡한 접촉도 같은 식으로 처리

반대편: “단단한 막대” 방식

접촉을 강제 제약으로만 푸는 엔진: **여러 접촉이 동시에** 일어나는 경우(예: 네 다리로 서 있는 로봇) 제약이 서로 충돌해 **계산이 불안정**해지기 쉬움

- 14.2 · 14.3에서 “다리 로봇을 학습시킬 땐 왜 정말 물리엔진이 필요한가”를 논할 때, 그 필요성의 **뿌리**가 바로 이 LCP 접촉 솔버에 있다

역사: 모델 기반 제어의 물리엔진

- 2012, Todorov: “MuJoCo: A physics engine for model-based control” (IROS 2012)
— 이름은 **Multi- Joint dynamics with Contact**
- 처음부터 “로봇 재현”이 아니라 **모델 기반 제어** (시스템 모델을 알고, 그 모델을 최적 제어에 넣는 방식)의 **재현성과 속도**를 위해 설계
- 접촉을 LCP로 푸는 것 역시 이 **최적화 관점의 자연스러운 결과**
- 2021: 무료 오픈소스화 ⇒ GPU 병렬 시뮬레이터 (14.2 Isaac Sim)가 없어도 **CPU에서 정밀 로봇 물리**가 가능
- OpenAI gym에서 DeepMind 로봇 연구까지 **사실상 표준 물리엔진**

이번 절의 XML로 모델 정의 + ctrl에 값 넣기 = 이 “모델 기반”의 “모델”을 **손으로 만져보는 것**.

자주 묻는 질문 (14.1)

- **Q. q_{pos} · q_{vel} · $ctrl$ 은?** q_{pos} = 위치 자유도(관절 각도, 물체 위치), q_{vel} = 그 시간 미분(각속도, 속도)
— MDP 상태 S 가 바로 이 (q_{pos}, q_{vel}) 의 조합. $ctrl$ = 액추에이터에 가하는 제어 입력(토크) — MDP의 행동 A 에 해당.
- **Q. 왜 굳이 MuJoCo API를 직접 쓰나?** 기존 환경(Reacher, Ant)은 Gymnasium 래퍼가 편리하지만, “세상에 없는 새로운 로봇”을 시뮬레이션하려면 XML로 직접 정의해야 한다 — Gymnasium의 MuJoCo 환경도 내부적으로 정확히 이 API를 감싸고 있을 뿐이다.

자주 묻는 질문 (14.1): PPO를 그대로 돌리면?

- **Q. 직접 만든 환경에 Ch. 13.2 PPO를 그대로?** `reset()` / `step()` 시그니처를 지키면 env 인자로 `MuJoCoPendulum()`을 받기만 하면 된다. **두 가지 실전 차이:**
 - ① **보상의 스케일** — PPO의 GAE·어드밴티지 정규화는 보상 범위에 민감. 진자의 “-각도²” 보상이 `CartPole`의 “+1/스텝”보다 절대값이 크면 **정규화 파라미터를 다시 맞춰야** 한다
 - ② **시드 결정성** — `Gymnasium`은 `env.reset(seed=...)`로 결정적 시드를 보장, 직접 만든 클래스는 `reset`에서 시드를 `np.random.default_rng`에 넘겨줘야 “같은 시드 → 같은 궤적”이 성립 (코드에서 `self.rng`가 그 역할)

확인 문제 예시: `done`을 `abs(th) < 0.1`로 바꾸면 PPO의 리턴 G_t 길이에 어떻게 영향을 주는가? (“에피소드가 목표 달성 시 조기 종료” + 성공/실패를 보상과 연결하는 방식)

14.2 NVIDIA Isaac Sim과 GPU 가속의 원리

Isaac Sim: GPU로 수천 개를 동시에

- **Isaac Sim** (NVIDIA): Omniverse 플랫폼 위의 로봇 시뮬레이션 환경 — 물리 계산 **자체**를 GPU에서 병렬로 수행
- 같은 로봇 환경을 CPU에서 하나씩 순차로 도는 대신, **수천 개의 복제본**을 GPU 위에서 동시에
- 사실적인 렌더링(카메라 센서 시뮬레이션)까지 — “**픽셀을 보고 판단하는**” 로봇 정책 학습에도 널리 사용

단, 이번 학기 실습에서는 시연 영상으로만

최소 사양: **RTX 4080 (16GB VRAM)**급 이상, **RT 코어** 필요 — RT 코어가 없는 A100 · H100류 데이터센터 GPU는 **미지원**. 학교의 GPU가 바로 H100/H200 계열이라 실습에서 직접 돌릴 수 없다.

그렇다면 오늘 50분은 무엇을 하는가

Isaac Sim을 못 돌리더라도, “Isaac Sim이 빠르다”고 말할 때 **그 빠름이 수학적으로 어디서 오는지**는 CPU 위에서, numpy 한 줄로 직접 재볼 수 있다.

단계	내용
----	----

- | | |
|-----|---|
| (1) | CPU가 환경 스텝을 “ 하나씩 ”만 돌릴 수 있는 이유를 숫자 로 확인 |
| (2) | Isaac Sim이 그 한계를 어떻게 우회하는지 (모든 상태를 한 배열에 담아 커널을 한 번 호출) 구조도로 보 |
| (3) | 그 아이디어를 14.1의 진자를 1,000개 복제 해 numpy로 직접 시뮬레이션 · 실험 |
-

- 실측 머신: 학교 서버 CPU (2026-08, 워밍업 200스텝 제외)

먼저 숫자로: 같은 CPU에서 40배

환경	물리 수준	초당 스텝 수
CartPole-v1 (Gymnasium 기본)	단순 근사	약 242,000
Pendulum (MuJoCo, 14.1의 진자)	정밀(단일 관절)	약 246,000
Ant-v5 (MuJoCo, 사족보행)	정밀(복잡한 접촉)	약 5,900

- 같은 CPU에서도 환경에 따라 약 **40배** 차이 — “CPU”라는 틀이 속도를 정하는 게 아니라, **어떤 물리를 계산하느냐**가 정한다 (14.1의 LCP 접촉이 매 스텝 푸는 계산이 그 차이의 정체)
- 10억 스텝이면: CartPole $10^9 / 2.4 \times 10^5 \approx 4,100\text{초} \approx$ **약 1.2시간**
- 같은 10억 스텝을 Ant(5,900 steps/s)로: $\approx 1.7 \times 10^5\text{초} \approx$ **약 2일**

왜 속도를 2배 · 100배 · 수천 배로 늘리기가 이렇게 어려운가

- 현대 CPU: 8~64개 코어 — 코어가 16개면 **독립 작업** 16개까지 동시 가능
- 그런데 “환경 하나를 스텝시키기”는 **독립 작업이 아니다**

한 환경의 t 스텝은 같은 환경의 $t - 1$ 스텝 결과가 나와야만 계산이 시작된다.

- 이 의존성을 깨는 방법은 “같은 환경의 시간을 잘게 나누는 것”이 **아니다**
- ⇒ **서로 다른 환경**(=초깃값이 다른 복제본)을 코어마다 하나씩 맡기는 것
- 예: 16코어 CPU로 Ant 16개를 병렬 ⇒ Ant 16개 환경 스텝을 동시 계산 — 이것이 “CPU 병렬”의 **전부**

그 “전부”가 문제: CPU 병렬의 상한선

- 16코어 $\times$ 5,900 steps/s $\approx$ **약 9.4만 steps/s**가 실질적 상한 (코어당 메모리 대역폭, 스레드 간 동기화 오버헤드를 감안하면 실제로는 그보다 낮음)
- Ant 10억 스텝: 2일 $\rightarrow$ **약 12시간**으로 줄어드는 것뿐 — “이틀을 기다리자”에서 “하루를 포기하자”

결론

수천 개 복제본이 필요한 **대규모 보행 연구**(14.3: 10억+ 스텝)에서는 이 상한선이 **결정적**이다. 바로 이 벽을 부수러 온 것이 **GPU**이고, 그 벽을 실제로 부수고 그대로 시뮬레이터로 상품화한 것이 **Isaac Sim**이다.

GPU 가속 시뮬레이션의 원리: CNN의 구조


- CPU 기반 시뮬레이터(MuJoCo, Gymnasium 기본): 한 번에 **환경 하나**를 스텝 — 경험을 더 모으려면 더 많은 시간
- GPU 가속 시뮬레이터: 물리 계산 **자체**를 대규모 병렬 연산으로 다시 설계

ML1 Ch. 10.1의 CNN 아이디어

“같은 연산을 위치마다 반복한다” — 이번엔 “**같은 물리 스텝을 로봇 복제본마다 반복한다**”. 수천 개 환경을 GPU 코어에 흩뿌려 동시 계산.

- 결과: 초당 모을 수 있는 (상태, 행동, 보상) 경험의 양이 CPU 대비 **수십~수백 배**까지
- Ch. 9의 **경험재현 버퍼**가 순식간에 채워지는 셈

데이터가 GPU 위에서 어떻게 배치되는가



CPU: 환경 스텝을 하나씩 순서대로 (C1→C2→C3→...). GPU: 4096개 환경의 상태를 한 개의 연속 텐서 배열에 나란히 담아 물리 스텝 커널 1회 호출로 4096개 환경의 다음 상태를 동시 계산.

- 그림의 핵심: “모든 환경의 상태를 한 개의 연속 배열(텐서)에 나란히 담는다”
- GPU가 빠른 이유: “코어가 많아서”가 아니라, 코어 개수와 데이터가 나란히 배열된 길이가 일치하기 때문

커널 한 번의 의미

- NVIDIA GPU: 수천~수만 개의 가벼운 코어(CUDA 코어) — 모두 같은 연산을 나란히 놓인 데이터 요소마다 수행 하도록 설계
- “4,096개 환경의 상태”를 하나의 큰 텐서 ($4096 \times$ 상태차원)로 모으면:

“커널 한 번”

물리 스텝을 계산하는 **커널(kernel) 함수를 한 번만** 호출하면 수천 개의 코어가 각자 자신의 환경의 물리 스텝을 동시에 처리. 함수를 4,096번 호출하는 게 아니라, 한 번의 함수 호출 안의 연산이 수천 개로 나뉜다 — 이것이 CPU 순차 호출과의 근본적 차이.

CNN의 병렬 vs Isaac Sim의 병렬

	CNN의 병렬 (ML1 10.1)	Isaac Sim의 병렬
반복되는 단위	같은 필터 (파라미터)를 위치마다 적용	같은 물리 스텝 (코드)을 복제본마다 적용
공유되는 것	파라미터 (무게)	프로그램 (물리 법칙, 코드)
달라지는 것	입력 픽셀 (위치마다 다름)	상태 (초기조건이 다른 복제본)
병렬의 방향	공간(픽셀 위치)	시간 대신 환경 (독립 실행 실체)

공통 뼈대

“한 번 작성된 연산을, 나란히 놓인 서로 다른 데이터 요소에 동시에 적용한다.” CNN은 한 입력 안에서 **공간적으로** 병렬, Isaac Sim은 한 물리 법칙 안에 **환경 단위로** 병렬.

“복제되는 것은 초깃값”

- 그래서: CNN이 배운 “가중치”가 **필터** 자체인 반면, Isaac Sim에서 복제되는 것은 “초깃값”
- 수천 개의 진자가 **같은 물리 법칙**(같은 코드)을 따르되, θ_0 만 다르다

CNN

- 공유: **파라미터(필터)**
- 변하는: 입력 픽셀

Isaac Sim

- 공유: **프로그램(물리 법칙, 코드)**
- 변하는: 상태(초기조건)

이 구분이 다음 실습(1,000개 진자를 θ_0 만 다르게 시작)의 **설계**에 그대로 쓰인다.

커널 한 번: 한 스텝이 지나면 (4단계)

Isaac Sim 계열 GPU 물리엔진(Warp 기반, MuJoCo-XLA의 CUDA 경로와 같은 원리)의 한 스텝 순서:

단계	내용
1. 행동 배치	4,096개 환경 각자의 행동 a_i 를 텐서 $A \in \mathbb{R}^{4096 \times d_a}$ 로 수집
2. 역학 커널	모든 복제본의 미분방정식(관성, 중력, PD/모터 법칙)을 한 번의 커널 호출 로 계산 — CUDA 코
3. 접촉 커널	복제본마다 “무엇이 무엇과 닿는가”를 동시에 검사 (4,096개 진자가 각각 바닥에 닿았는지 동
4. 통합	2~3의 결과를 모든 복제본에 동시 적용해 다음 상태 q_{t+1} 산출

호출 횟수가 “ $4,096 \times 4$ ”에서 “4”로

- CPU로 **순차**: $4,096 \times (4\text{단계})$ 만큼의 **연속된 호출**
- GPU: 4단계 $\times$ **1회의 호출**

“수천 배”의 정수적 기원

호출 횟수(순차성)가 “ $4,096 \times 4$ ”에서 “4”로 줄어드는 것. 코어가 4,096개이든 16,384개이든, 호출 한 번 안의 연산이 데이터 길이만큼 나뉜다는 구조가 동일하다.

- CPU 버전(MuJoCo mj_step)과의 구조적 차이: “환경 i 에 ctrl 하나”인 인자가, GPU 버전에서는 **배열 전체**가 함수 인자가 됨

오버헤드 문제: 왜 “커널 한 번”이 큰 차이인가

- CPU: 함수 호출과 결과 수령에 드는 시간(호출 오버헤드, 캐시 미스, 브랜치 예측 실패)은 **호출 한 번마다 발생**
- 4,096번 호출 $\Rightarrow$ 4,096번 그 오버헤드를 치른다

GPU의 구조

커널 발기 오버헤드는 일단만 치르고, 그 안에서 수천 개 코어가 **동일한 명령**을 나란히 놓인 데이터에 동시 수행(**SIMT, single-instruction multiple-thread**) $\Rightarrow$ 오버헤드가 **데이터 길이와 무관하게 상수로 묶여 버린다**.

- **아몰달의 법칙(Amdahl's Law)**과 연결하면, GPU 병렬의 “몇 배까지 빨라질 수 있는가”의 **이론적 상한**이 왜 존재하는지 볼 수 있다 (아래 확인)

확인: Amdahl의 법칙

파이프라인을 (a) 환경 스텝(병렬화 가능, 비율 p)과 (b) 정책 업데이트 + 동기화(병렬화 불가, 비율 $1 - p$)로 나눌 때, N 코어 병렬화 후의 전체 가속은

$$\frac{1}{(1 - p) + p/N}$$

- $N \rightarrow \infty$ 해도 가속은 $\frac{1}{1 - p}$ 에 수렴 — **순차 부분이 10%**($p = 0.9$)면, 코어가 무한이어도 **최대 10배**에 그침
- $p = 0.99 \Rightarrow 100$ 배, $p = 0.999 \Rightarrow 1,000$ 배

Isaac Sim의 엔지니어링

“환경 스텝 $\times$ 수천”을 달성하려면 p 가 **0.999 이상**. 실제로: 환경 스텝을 **VRAM 안에서 순환**(호스트 $\rightarrow$ VRAM 왕복 최소화) + 정책 업데이트를 환경 스텝 사이에 **삽입(overlap)** $\Rightarrow 1 - p$ 를 극도로 작게. “코어 수만 많으면 된다”가 아니라, **순차 부분을 어떻게 줄이느냐**가 GPU 시뮬레이터 설계의 진짜 문제.

실습: 1,000개 진자를 하나의 배열로

Isaac Sim을 못 돌리더라도, 그 데이터 구조는 **numpy**로 정확히 재현할 수 있다.

- “4,096개 환경의 상태를 하나의 텐서에 담는다” = N 개 진자 각도 θ_i 와 각속도 $\dot{\theta}_i$ 를 2차원 배열 `theta[N]`, `thetadot[N]`에 넣고, 한 번의 **numpy 연산**으로 전체 배열을 **동시 업데이트**
- **numpy**가 배열 전체에 같은 연산을 **벡터화**해 한 번에 수행 = GPU 커널이 수천 개 데이터에 같은 연산을 **동시** 수행하는 것의 **CPU 위 미니판** (CPU의 SIMD + BLAS가 처리)

14.1 진자의 물리 스텝

$\ddot{\theta} = -(g/\ell) \sin \theta - b\dot{\theta} + \tau/I$, $\ell = 0.5 \text{ m}$, $I \approx 1/12 \text{ kg} \cdot \text{m}^2$, $b = 0.1$ — **RK4**(4차 Runge-Kutta)로 $\Delta t = 0.002 \text{ s}$ 한 스텝

step_batch: 한 줄의 numpy 연산이 N개 진자를 “동시”

```
def step_batch(theta, thetadot, torque, dt=0.002, b=0.1, L=0.5, m=1.0):
    """개N 진자의물리러한번의 numpy 연산으로동시스템 (RK4)."""
    def f(th, thd, tau):
        return thd, -(9.81/L)*np.sin(th) - b*thd + tau # 각가속도
    # RK4: 단계4 미분계산—각단계가 numpy 배열전체에동시에적용
    k1t, k1v = f(theta, thetadot, torque)
    k2t, k2v = f(theta+0.5*dt*k1t, thetadot+0.5*dt*k1v, torque)
    k3t, k3v = f(theta+0.5*dt*k2t, thetadot+0.5*dt*k2v, torque)
    k4t, k4v = f(theta+dt*k3t, thetadot+dt*k3v, torque)
    theta += dt/6*(k1t + 2*k2t + 2*k3t + k4t)
    thetadot+= dt/6*(k1v + 2*k2v + 2*k3v + k4v)
    return theta, thetadot
```

torque가 (N,) 배열이면, f 안의 $\text{np.sin}(\text{th}) \cdot \text{b} \cdot \text{thd}$ 등 모든 연산이 **N개 요소에 동시** 적용 — 이것이 “커널 한 번”의 CPU 미니판. 대조: `for i in range(N): step(theta[i])` (CPU 순차).

실측: 약 76배

N=1,000, 2,000스텝 (=4s 시뮬레이션), 같은 머신:

실행 방식	벽 시간	초당 환경스텝 수
CPU 순차 (진자를 하나씩, Python 루프)	약 8.4 s	약 239,000
배치 (numpy 벡터화, 1,000개 동시)	약 0.11 s	약 18,150,000

76배의 성분


“CPU 순차”의 239,000 steps/s는 14.1 MuJoCo 진자(약 246,000)와 **정확히 같은 수준** — 진자 하나를 스텝시키는 비용은 물리 자체에 의해 결정된다. 76배는 물리 계산이 빨라진 게 **아니다**: (a) Python이 매 진자마다 함수 호출·인덱싱하던 **오버헤드 소거**, (b) 하나의 배열 연산 안의 연산이 **1,000개 진자 만큼 나뉘** 것. 물리 계산 자체는 같은 CPU에서 그대로.

배치는 필요조건, GPU는 실행 장치

- 진짜 GPU 병렬은 여기서 한 단계 더: numpy가 CPU의 8~16개 SIMD 레지스터로 처리하는 같은 배열 연산을, GPU의 수천 개 코어가 한 번에 수행

구분

“배치”가 데이터 구조의 필요조건(없으면 GPU 병렬 자체를 할 수 없다)이라면, GPU가 그 배치 구조를 실제로 수천 코어로 동시에 실행하는 장치.



1,000개 진자를 $\theta_0 \in [-2.5, 2.5]$ 에서 무작위 시작, PD 토크로 2,000스텝(=4s). 모든 궤적이 같은 물리 법칙(같은 코드)을 따르되, 출발점이 궤적의 모양으로 남는다 — 하단 분포가 θ_0 균등분포 $\rightarrow$ 4초 뒤 0 중심으로 수렴.



“경험률이 1,000배가 되는가?”

이 절의 가장 중요한 개념적 분기점. 답: **환경 스텝** 기준으로는 예, **정책 업데이트** 기준으로는 아니오.

(1) 환경 스텝

- 4s 시뮬레이션의 벽 시간: CPU 순차 1개
진자 약 $0.008s \times 1,000 = 8s$ (순차 1,000개) → 배치 **약 0.11s**
- 경험 수집 속도 약 **76배** (위 실측) $\Rightarrow$ Ch. 9
경험재현 버퍼가 “순식간에 채워지는” 이유

(2) 정책 업데이트

- 1,000개 궤적이 동시에 모였다고, 그 1,000개 트랙을 정책 그래디언트에 **한 번에 쓸 수는 없다**
- Ch. 11.2 PPO 미니배치는 **연속된** (상태, 행동, 리턴) 튜플을 요구 — 1,000개 독립 트랙을 하나로 묶으면 각 트랙 리턴이 자기 초깃값 분포에서 와서 **분산이 커짐** (GAE가 일부 처리)

결론

GPU 병렬은 “**경험을 모으는 속도**”를 키우고, “**경험을 쓰는 효율**”은 별개 축. 14.3에서 정확히 이 둘을 독립 축으로 정리한다.

자주 하는 실수 (1): “코어가 많으니까 자동으로 빨라진다”

실수	왜 틀린가
“GPU 코어가 16,384개니까 16,384배 빠진다”	Amdahl: 순차 부분(동기화, VRAM↔host 복사, 정책 업데이트)이 병렬화되면 상수로 묶임 . 환경 스텝만 볼 때 이론적 상한은 코어 수지만, 전체 파이프라인(경험 수집 → 미니배치 → 업데이트)의 속도는 병렬화 불가 부분 이 정한다. 실제 Isaac Sim 벤치마크도 “환경 스텝 × 수천”이지 “×16,384”가 아니다

실수 2: “배치(텐서)로 모으는 것 = GPU 병렬” — 배치는 필요조건이지 충분 조건이 아님. numpy가 CPU에서 벡터화해도 코어는 8~16개. GPU가 그 같은 배치를 수천 코어로 동시 실행해야 **진짜 GPU 병렬**. “배치로 썼으니까 빠르다”는 CPU 76배(numpy 벡터화 + 오버헤드 제거)와 GPU 수천 배를 혼동.

자주 하는 실수 (2): 미니배치와 규모

실수	왜 틀린가
“1,000개 환경이 동시에 돌면 PPO 미니배치도 1,000개가 된다”	미니배치는 연속된 트랙 의 (s,a,G) 튜플을 묶는 것. 1,000개 독립 트랙을 하나로 묶으면 분산이 커지고 GAE의 편향-분산 trade-off가 달라짐. 실무에서는 경험 수집을 1,000배 빨리하고, 미니배치 크기는 알고리즘이 요구하는 크기로 유지 (수집을 빨리 → 같은 미니배치 크기로 더 자주 업데이트)
“GPU가 빠르니까 CartPole 실습도 GPU로”	CartPole 24만 steps/s × 책의 12만 스텝 = 0.5초 . GPU로 옮겨도 최소 오버헤드(데이터 복사, 동기화) 때문에 오히려 느려질 수 있음. GPU 병렬의 값은 총 스텝 수가 CPU에서 수 시간~날 단위가 될 때 (1억+, 14.3)만 드러남 — 규모 미만의 작업에 GPU는 과잉

GPU 병렬을 결정하는 것

“코어 수 $\times$ 데이터 길이”가 아니라, “**병렬화 가능한 부분** $\times$ **코어 수**”로 결정된다.

- “순차 부분”이 **작을수록**(환경 스텝이 대부분이고, 동기화가 스텝 경계마다 한 번이면) $\rightarrow$ 이 곱에 **가깝**
- “순차 부분”이 **크면**(정책 업데이트가 환경 스텝과 1:1이면) $\rightarrow$ Amdahl 상한이 **훨씬 낮아진다**

확인 문제 예시: 환경 스텝 99%($p = 0.99$) + 정책 업데이트 1%인 시뮬레이터에서 1,000코어 병렬화 후 전체 가속
 $= 1/((1 - p) + p/N) \approx 990$ 배, $N \rightarrow \infty$ 상한 = 100배. (힌트: $1/((1 - p) + p/N)$, $p = 0.99$, $N = 1000$)

역사: CUDA에서 Isaac Sim까지

Isaac Sim의 “GPU로 수천 개를 동시에”는 새것이 아니다:

단계	시점	내용
CUDA	2007	“GPU 코어에 데이터를 나란히 놓고, 커널을 한 번 호출하면 수천 개 코어가 동시에 수행”하는 프로그래밍 모델 공개 — 그전 GPU는 렌더링 전용
MuJoCo-XLA	2021 (Todorov 등)	14.1의 MuJoCo를 TPU/GPU로 자동 병렬화 — 정밀 물리(LCP 접촉)를 그 구조에 자동 이동
Isaac Sim	2023 (NVIDIA)	로봇 시뮬레이터 전체 (물리 + 렌더링 + 센서)를 그 모델 위로 상품화

한 줄 요약

세 단계 모두 “공유하는 것은 코드, 달라지는 것은 상태”라는 같은 뼈대 위에, **순차 부분을 줄이고 배치 크기를 크게** 하는 엔지니어링의 진화.

“RT 코어가 필요하다”는 제약의 정확한 이유

- Isaac Sim은 물리만 GPU로 돌리는 게 아니라, **렌더링(카메라 센서 시뮬레이션)까지 GPU에서**
- 실시간 렌더링을 위해 광선 추적(ray tracing)을 쓰면 GPU의 **RT 코어** 필요 — A100 · H100류 데이터센터 GPU는 학습용이라 RT 코어가 **없음**

정확한 이유

“학교 GPU(H100)로 Isaac Sim을 못 돌린다”는 제약은 **렌더링 축(시각적 리얼리즘)**에서 온다. 물리만이라면 **MuJoCo-XLA로 H100에서도 돌릴 수 있다** — “GPU가 없어서 못 한다”가 아니라, **“렌더링을 하려면 이 GPU가 아니다”**라는 정확한 이유 (14.3의 Q3가 이 지점을 다룬다).

자주 묻는 질문 (14.2)

- **Q. GPU 가속에서도 DQN/PPO를 그대로? 그렇다** — 알고리즘은 “환경이 한 번에 경험을 몇 개 주는가”와 무관하게 정의. 다만 실전 구현은 수천 개 복제본 데이터를 **한꺼번에 배치**로 처리하도록 최적화 (Ch. 9.3 미니배치 개념의 자연스러운 확장) — 알고리즘 수학은 그대로, 구현만 조정.
- **Q. Isaac Sim을 못 써본 건 손해인가? 개념적으로는 크지 않다** — 핵심 가치는 “같은 알고리즘을 훨씬 빠르게 많이 학습”시키는 **계산 효율성**이지, 새 알고리즘을 배우게 하는 게 아님. MuJoCo로 배운 워크플로가 나중에 적합한 GPU가 생기면 **그대로 Isaac Sim으로, 규모만 키워** 이식.

자주 묻는 질문 (14.2): “한 번”이 진짜 한 번인가

- Q. 4,096개 환경이 진짜 동시에인가? 구조적으로는 “한 번” — 호출은 한 번, 그 안에서 수천 개 코어가 동시에 수행.
- 물리적으로: GPU의 SM(Streaming Multiprocessor)이 워프(32개 스레드) 단위로 스케줄링 $\Rightarrow$ 4,096개 환경이 완벽히 동시에 끝나는 건 아님 — 대부분이 동시에, 일부는 다음 워프 스케줄링에서
- 하지만 호출 오버헤드가 일단만 치러지므로, 순차 4,096회 호출에 비해 총 시간은 수천 분의 1

핵심

“완벽한 동시성”이 아니라, “호출 오버헤드를 상수로 묶는다”는 것이 핵심.

Q. MuJoCo-XLA vs Isaac Sim? 둘 다 “정밀 물리를 GPU/TPU로 병렬화”하지만 범위가 다름: MuJoCo-XLA = 물리만(LCP 포함, 렌더링 없음, CPU MuJoCo와 완전히 같은 물리). Isaac Sim = 물리+렌더링+센서(RT 코어 필요, 물리 엔진도 NVIDIA Warp 기반). “정밀 물리만 GPU로”면 MuJoCo-XLA, “물리+카메라로 판단하는 정책”이면 Isaac Sim.

14.3 어떤 도구를 언제 쓰는가

원리가 아니라 숫자로

- 14.1: MuJoCo 직접 다룸 / 14.2: Isaac Sim GPU 병렬 원리
- 이번 절: “어떤 작업을 어떤 도구로 풀어야 하는가”를 **원리가 아니라 숫자로** 정리

이 절을 마치면:

- ① 정밀도 · 속도라는 두 개의 축으로 도구를 비교하는 눈
- ② 내 작업이 그 두 축에서 어디에 찍히는지 재는 방법
- ③ 30초 안에 도구를 고르는 **결정 절차**

네 도구를 한 표로

도구	실행 위치	정밀도	속도(대량 병렬)	이번 학기 사용
Gymnasium 기본	CPU	낮음~중간	느림	기본 실습
PyBullet	CPU	중간	느림	로봇팔/사족보행 실습
MuJoCo	CPU	높음	느림	정밀 제어 실습
NVIDIA Isaac Sim	GPU	높음	매우 빠름(수천 배 병렬)	시연만(하드웨어 제약)

- 개인 노트북에서 직접 돌려보고 싶다면 → **Gymnasium/PyBullet**
- 접촉·마찰까지 **정밀하게** 맞춰야 하는 연구라면 → **MuJoCo**
- **대량의 경험**을 매우 빠르게 모아야 하는 대규모 학습이라면 (그리고 적합한 GPU가 있다면) → **Isaac Sim**

이 절의 뼈대 (두 질문)

핵심 선언

시뮬레이션 도구가 달라져도 **강화학습 알고리즘 자체는 바뀌지 않는다** — 바뀌는 건 **물리적 정확도와 계산 속도의 트레이드오프**뿐. 어떤 도구를 쓸지는 “**얼마나 정밀해야 하는가**”와 “**얼마나 많은 경험이 필요한가**”라는 두 질문에 대한 답으로 결정된다.

- 셋 다 Ch. 9–13 알고리즘을 그대로 엮을 수 있는, “**환경을 바꿔 끼우는**” 문제라는 점은 동일
- 아래에서 각 “질문”이 **실제로 무엇을 재는지**를 하나씩 풀고, 둘이 만나는 지점에서 도구를 고르는 절차를 숫자까지 붙여 다룬다.

첫 번째 질문: “얼마나 정밀해야 하는가?”

- “정밀도”를 모호한 말이 되지 않게 14.1의 **접촉(contact)**에서 시작
- 공이 바닥에 **닿는 순간**은 단순 미분방정식이 아니라 **LCP**라는 특별한 최적화 (비침투 + 비음이 동시에)
- MuJoCo가 LCP를 매 스텝 안정적으로 풀어: (1) 공이 부딪혀 튕다 멈추는 행위가 **NaN·폭주 없이** 자연스럽게, (2) 다리 로봇의 발이 바닥에 붙었다 떨어지는 **걸음** 같은 복잡한 접촉도 같은 식으로

핵심 정지점

정밀도는 “화면이 사실적인가”가 아니라, “정책이 배우는 물리가 진짜와 얼마나 같은가”를 말한다. 두 가지가 서로 다른 축이다.

두 축: 물리 정밀도 vs 시각적/센서 리얼리즘

물리 정밀도

- 접촉, 마찰, 관성, **접촉력(contact force)**이 물리 법칙에 얼마나 충실한가
- **로봇 제어**에서 이 축이 **가장 중요**
- 다리로 서 있는 로봇의 발이 미끄러지지 않도록 하는 제어는, **접촉력이 정확하게** 계산되는 엔진 위에서 배워야 실제로 **이식**
- 14.1의 “부딪혀 안착”이라는 **동역학** 자체가 이 축의 문제

시각적/센서 리얼리즘

- 카메라로 본 **픽셀**이 얼마나 사실적인가
- **시각적으로 판단하는** 정책(픽셀 입력)을 만들 때 중요
- Isaac Sim이 사실적 렌더링을 지원하는 이유가 바로 이것 — 14.2의 “픽셀을 보고 판단하는 로봇 정책” 대목이 이 축

왜 이 구분이 중요한가

- “화면이 예쁘니까” Isaac Sim을 고르면: 실제로는 **물리 정밀도**가 필요한 작업을 **비싼 GPU** 위에서 돌리는 셈이 되기 쉬움
- 반대로, 접촉력이 정확해야 하는 다리 로봇을 “CartPole도 되는데”라며 **가장 단순한 환경**에서 배우면: 13.1의 **현실 격차(reality gap)**가 그 단순함에서 **이미 박혀** 있다 — 시뮬레이터 자체가 물리를 너무 약하게 근사하고 있기 때문

축 A: 물리

- 접촉력 정확도
- **로봇 제어**의 핵심

축 B: 센서

- 렌더링 리얼리즘
- **픽셀 입력 정책**의 핵심

정밀도 축을 작업별로 대입하면

작업 (Chapter)	필요한 정밀도	이유
CartPole, Pendulum (9~11)	낮음~중간	단일 막대/진자. 접촉 없음, 물리 근사만으로도 충분
Reacher, 2관절 로봇팔 (13) 사족보행/인간형 보행 (13.2)	중간 높음	관절 운동은 있지만 자발적인 강한 접촉 없음 발이 바닥에 붙었다 떨어지는 반복 접촉. 접촉력 정확도가 핵심
카메라로 판단하는 정책	높음(센서) + 물리	렌더링 리얼리즘과 물리 정밀도 둘 다 필요

정밀도 축의 결론

“**접촉이 얼마나 중요한가**”로 결정된다. 접촉이 거의 없으면(Pendulum) Gymnasium 기본 환경, 관절이 있지만 강한 접촉이 없으면(Reacher) PyBullet/MuJoCo 어느 쪽이든 충분, **발이 바닥을 차는 보행**이라면 MuJoCo급 정밀 LCP 접촉이 **필수**.

두 번째 질문: “얼마나 많은 경험이 필요한가?”

- “속도”는 모호한 “빠르다”가 아니라, **초당 몇 번의 (상태, 행동, 보상) 경험을 모을 수 있는가**
 - 이 정의가 중요한 이유: Ch. 9-13의 **모든** 알고리즘이 결국 이 경험 데이터를 먹고 작동
- ① **경험재현 버퍼**(Ch. 9.3): 버퍼가 차야 미니배치 샘플링 시작
 - ② **GAE**(Ch. 11.2): 에피소드 **분할**을 모아야 보너(bootstrapping) 값을 추정
 - ③ **PPO** 정책 그래디언트: 충분한 수의 (상태, 행동, 리턴) 트플 위에서 그래디언트 하강

결론

알고리즘이 필요로 하는 **총 경험 수**가 정해지면, **초당 스텝 수**가 그 학습의 **실시간 길이**를 결정.

실측(학교 서버 CPU, 2026-08)

먼저 책에서 실제로 돌린 실행의 총 스텝 수:

실행	총 스텝 수	계산	⇒ 이
11.2 Pendulum PPO	120,000	300 iter × 400 스텝	
13.3 Reacher PPO	76,800	150 iter × 512 스텝	

책의 PPO 실습들은 **약 8만~12만 스텝**이면 “배우는 것”이 끝남. 이제 각 엔진의 초당 스텝 수로 나누면:

엔진 (환경)	초당 스텝 수	120,000 스텝에 걸리는 시간
Gymnasium 기본 (CartPole-v1)	약 247,000	약 0.5 초
MuJoCo (Ant-v5)	약 6,200	약 20 초


노트북 재현: `gym.make(...)` 후 `step()` 반복 + `time.perf_counter()`, 워밍업 200스텝 제외. 이 숫자는 이 책의 실습 수준에서 CPU의 절대 상한선을 재는 것.

표 읽는 법: “CPU니까 느리다”가 아니다

같은 CPU에서 40배

가장 단순한 환경(CartPole, 물리 근사)이 가장 정밀한 로봇 시뮬레이션(Ant, MuJoCo)보다 **약 40배 빠름**. “CPU니까 느리다”가 아니라, **정밀한 물리를 계산하는 비용이 CPU를 40배 느리게 만든다** — 14.1에서 LCP 접촉을 매 스텝 푸는 데 드는 계산이 이 차이의 정체.

같은 CPU에서: 물리 근사 vs 정밀 물리 시뮬레이션 속도



초당 스텝 수 비교(로그 스케일). CartPole $\approx 247,000$ steps/s, Ant $\approx 6,200$ steps/s. 100만 스텝에 걸리는 시간: CartPole ≈ 4 초, Ant ≈ 2.7 분 — 둘 다 “CPU”인데 어떤 물리를 계산하느냐에 따라 40배로 갈린다. “느림”의 크기를 실감하라.

규모를 단계별로: 총 스텝 수 ÷ 초당 스텝 수

환경 스텝만의 실 시간(오른쪽은 14.2의 “수천 개 복제본 동시 스텝”을 **경험률 2,000배**로 단순화한 GPU 병렬):

총 스텝 수	단일 CPU (Ant)	GPU 병렬 ×2,000
책의 PPO (약 12만)	약 20 초	(CPU면 충분)
사족보행 (1,000만)	약 27 분	약 0.8 초
대규모 보행 (1억)	약 4.5 시간	약 8 초
초대규모 (10억)	약 2 일	약 1.3 분

“GPU ×2,000”는 **환경 스텝**의 병렬화일 뿐 — 정책 네트워크의 순전파·그래디언트 계산은 **별도** (바로 아래 “확인”).

이 표가 이 절의 핵심

- 책의 12만 스텝은 CPU 한 대면 **20초** — 개인 노트북 + CPU로 이번 학기 실습을 전부 할 수 있다. 이것이 “이번 학기 실습은 MuJoCo를 기본으로 골랐다”는 FAQ의 계산적 근거

반전

같은 Ant가 **10억 스텝**이면: 단일 CPU 약 **2일**, GPU 병렬은 약 **1.3분**. GPU 병렬의 “수천 배”라는 값은 **10만 스텝이 아니라 1억~10억 스텝**에서야 비로소 “2일짜리 작업”과 “몇 분짜리 작업”의 차이가 된다.

속도 측의 결론

“총 스텝 수 ÷ 초당 스텝 수 = 실 시간”이고, 이 실 시간이 내가 기다릴 수 있는 범위(분~수 시간)를 넘는 규모(여기선 **1억 스텝 이상**, 환경 스텝만 수 시간)에서만 **GPU 병렬이 필수**. 그 이하 규모에서는 CPU 정밀(MuJoCo)이 더 느리지만 **기다릴 만한 시간**이니, “정밀도 우선”이 그대로 합리적 선택.

확인: “초당 스텝 수”와 “학습 효율”은 같은가

아니다


초당 스텝 수는 **경험을 모으는 속도**일 뿐, 그 경험이 **얼마나 잘 쓰이는가**(정책 그래디언트의 품질, 버퍼 재사용률 등)는 **별개의 문제**. GPU가 경험을 1,000배 빨리 모아도, 알고리즘이 그 경험을 0.1배의 효율로만 쓴다면 **순 학습 시간은 100배**가 된다.

- Ch. 9의 “경험재현”이 경험을 **재사용**해 효율을 높이는 기법인 이유가 바로 이것
- **GPU**가 “**빠르게 모으는**” 축, **경험재현**이 “**효과적으로 쓰는**” 축을 담당

독립 축

이 두 축이 **독립**해서 **곱해져** 총 학습 시간을 만든다.

30초 결정 절차: 두 축이 만나는 지점



Q1. 강한 접촉이 핵심인가? 발이 바닥을 차는 보행, 물체가 부딪혀 튕기는 조작이 핵심인가?

- 아니오 → 정밀 LCP 접촉 불필요 → **Gymnasium 기본 환경** (CartPole, Pendulum)
- 예 → 다음

Q2. 단일 CPU로 수 시간~날 단위까지 기다릴 수 없는 대규모(1억+ 스텝)인가?

- 아니오 (초~분~수 시간이면 OK — 책의 12만 스텝, 1,000만도 CPU 27분(환경 스텝만)) → **MuJoCo (CPU, 정밀)**
- 예 → 다음

Q3. 적합한 GPU가 있는가? (Isaac Sim: RTX 4080/16GB급 이상, RT 코어 필요)

왜 정밀도(Q1)가 첫 질문인가

정밀도 = 필요충분 조건, 속도 = 비용 절감

정밀도(Q1)가 **필수 조건**이기 때문 — 정밀도가 부족하면 그 이상 속도가 빨라도 **잘못된 물리를 빠르게 배우는 것**(13.1의 현실 격차가 그 출발점). 정밀도가 **충족된 이후**에야 속도(Q2, Q3)가 “어느 CPU/GPU”의 선택이 된다.

정밀도 (Q1)

- **필수 조건** — 부족하면 속도 무의미
- “잘못된 물리를 빠르게 배우는” 것을 막음

속도 (Q2, Q3)

- 정밀도 충족 **이후**의 선택
- “어느 CPU/GPU”를 쓸지의 **비용 절감 문제**

자주 하는 실수: CartPole 벤치마크로 “CPU면 충분”

실수	왜 틀린가
“CartPole로 247,000 steps/s를 보고 CPU는 25만 스텝/초니까 빠르다”	그 숫자는 물리 근사 환경의 속도. 정밀 로봇(Ant)은 같은 CPU에서 40배 느린 6,200 steps/s. 어떤 물리를 계산하느냐 가 속도를 정한다
“화면이 사실적이니까” Isaac Sim을 정밀 제어 작업에 GPU가 1,000배 빠르다며 책의 8만 스텝 실습도 GPU로	시각적 리얼리즘(렌더링) ≠ 물리 정밀도 . 접촉력이 정확한 작업은 물리 정밀도 가 필요, 렌더링은 센서 속 8만 스텝은 CPU에서 초~분 단위로 끝남(위 표). GPU 병렬의 값(수천 배)은 1억+ 스텝 에서야 “2일 ↔ 1분”으로 드러남. 규모 미만의 작업에 GPU는 과잉
“정밀한 엔진이 항상 더 좋다”며 MuJoCo를 CartPole에도	MuJoCo로 CartPole을 돌리면 40배 느리고 , 정밀 LCP 접촉이 불필요 한 작업에 계산 비용만 지름

공통 원리: 작업에 대해 “상대적”

속도와 정밀도는 작업에 대해 상대적이다

“이 작업에 **필요한** 정밀도”와 “이 작업에 **필요한** 경험 수”를 **먼저 재고**, 그 뒤에 “이 환경의 steps/s”를 **대입**해야 한다. **역순**(환경이 빠르니까/정밀하니까 쓰자)으로 시작하면 앞 표의 실수를 한다.

● 정밀도 = 필요충분 조건 + 속도 = 그 안에서 비용 절감

확인 문제 예시: 13.2 사족보행 1,000만 스텝. (a) 단일 CPU MuJoCo(Ant, 약 6,200 steps/s) 환경 스텝만 실 시간 $\approx$ **27분**. (b) 정책 계산·업데이트를 환경 스텝의 2배로 가정 $\Rightarrow$ 총 $\approx$ **81분**. (c) Isaac Sim이 경험률을 2,000배 $\Rightarrow$ (b)의 총 실 시간은 $\approx$ **0.04분(약 2.5초)**으로 줄어듬.

역사: 도구를 고른 사람들

- **MuJoCo** (2012, Todorov): “로봇 재현”이 아니라 **모델 기반 제어의 재현성과 속도**를 위해 설계 — 접촉을 LCP로 푸는 것이 이 **최적화 관점의 자연스러운 결과**. 2021 무료 오픈소스화 → “CPU에서 정밀 로봇 물리”가 **대중화**
- **Isaac Sim** (NVIDIA, 2023 정식 출시): **속도 축을 극단으로** — “같은 물리 스텝을 GPU 위에서 수천 개 복제본에 흠뻑려” CPU의 **순차** 한계를 **병렬**로 부수기
- CPU 쪽도 멈추지 않음: **MuJoCo-XLA**(2021~) — MuJoCo 물리를 TPU/GPU로 **자동 병렬화**, 전용 시뮬레이터가 없어도 정밀 물리를 대량으로

도구 선택의 역사

정밀도 축을 지키면서 속도 축을 계속 늘려온 역사 — MuJoCo(정밀, CPU) → MuJoCo-XLA(정밀, GPU/TPU 자동 병렬) → Isaac Sim(정밀+센서, GPU 전용 병렬).

교훈: 도구를 고르는 건 “어떤 알고리즘을 쓸 것인가”가 아니라 **“이 작업이 정밀도·속도 두 축에서 어디에 찍히느냐”를 재는 일**. 두 축이 **독립**이라 한 축이 빠르면 다른 축을 소홀히 해도 된다는 **허용**을 준다. 두 축을 혼동하면(빨라서=좋다, 정밀해서=좋다) “잘못된 물리를 빠르게” 또는 “필요 없는 정밀에 비싸게” 두 실수 중 하나를 한다.

자주 묻는 질문 (14.3)

- **Q. PyBullet 대신 왜 MuJoCo로?** 둘 다 로봇팔/사족보행 실습에 쓸 수 있지만, PyBullet은 설치 시 별도 C++ 컴파일 과정이 있는 반면, MuJoCo는 `pip install gymnasium[mujoco]`만으로 **컴파일 없이** 바로 설치 $\Rightarrow$ 이번 학기 기본으로 MuJoCo. PyBullet은 이미 그 환경이 갖춰진 프로젝트/개인 환경에서 유효한 선택지. **어떤 CPU 물리엔진을 쓰든 DQN · PPO 코드 그대로 재사용.**
- **Q. “속도” 기준은 정확히 무엇을 재나?** “초당 몇 번의 (상태, 행동, 보상) 경험을 모을 수 있는가”. CPU 엔진은 **하나씩** 순차 스텝, GPU 가속 엔진은 **수천 개** 동시 스텝.

자주 묻는 질문 (14.3): GPU가 없다면

- Q. “GPU가 있어야 Isaac Sim”인데, GPU가 전혀 없다면 대규모(1,000만 스텝) 학습은 못하는 것인가? 아니다 — 1,000만 스텝을 CPU MuJoCo로 돌리면 환경 스텝만 약 27분. “느리지만 가능”
- GPU가 필요한 이유: “못 한다”가 아니라, 대규모를 반복해 실험해야 하는 연구에서 시간을 줄여주는 것

GPU가 없다면 세 가지 대응

(a) 규모를 줄여(예: 100만 스텝) CPU로, (b) **MuJoCo-XLA**로 TPU/GPU 자동 병렬, (c) GPU 클러스터에 제출하는 방식. 도구를 못 “쓰는” 것이 아니라, 어떤 GPU를 쓰느냐의 문제.

Q. 벤치마크 숫자(247,000 / 6,200)는 내 노트북에서 같은가? 같은 값은 아님(CPU 주파수, 코어 수, 메모리, OS 차이) — 그러나 **비율**(정밀 물리가 CPU를 수십 배 느리게 한다는 사실)은 대부분의 CPU에서 유지. 결론(두 축, 30초 절차)은 변하지 않고, **절대 숫자**만 재측정하면 되는 것. 실습 노트북 코드를 자기 머신에서 돌려 자기 숫자로 대체하는 것이 정석.

14.4 산업 사례: 자율주행 시뮬레이션 (Waymo의 Onboard/Offboard 루프)

산업 규모로 확장: 자율주행 시뮬레이션

- 14.1: XML로 로봇 정의 → “환경이 바뀌어도 알고리즘은 그대로” 확인
- 14.2: Isaac Sim GPU 병렬의 “수천 배”가 수학적으로 어디서 오는지 보임
- 14.3: 정밀도 × 속도 두 축으로 도구 고르는 기준

이번 절

“시뮬레이터를 실전 연구 수준으로 쓴다”는 주제를 산업 규모, 즉 자율주행 시뮬레이션 스택으로 확장. **Waymo**의 자율주행 스택 구조를 예로:

- ① 실차를 굴리는 **Onboard**와 **Offboard** 두 루프
- ② 이 구조가 강화학습의 **policy iteration/Dyna**와 같은 모양인 이유
- ③ Offboard 루프를 현실적 시나리오로 채우는 diffusion 기반 도구 **SceneDiffuser**(Waymo, 2024)

ML1 13.4와 15.4처럼 “지도” 수준 — 깊은 유도 없이 개념과 대표 논문을 잇는 가벼운 절.

왜 실차는 두 개의 루프로 나누는가

- 이번 학기 실습의 로봇(Reacher, 사족보행)은 **시행착오**로 배울 수 있었다 — 시뮬레이터 안의 스텝은 **싸고**, 실패는 **무료**였기 때문
- **실차는 그럴 수 없다:**
 - ▶ 실차의 한 스텝 = **물리적 시간**으로 수백 밀리초
 - ▶ “실패하는 실험”은 **무료도 안전하지도** 않음

루프	실행 위치	하는 일	제약
Onboard	실차 안, 실시간	센서 → Perception → Planner: 매 순간 주변을 인식해 즉시 경로/제어 결정	수십 밀리초 안에 결정해야 하고, 차를 멈춰놓고 “생각”할 수 없음
Offboard	데이터센터, 사후	같은 Planner를 시뮬레이터 에서 대량의 주행 시나리오(에피소드)로 돌려 평가 · 재학습	느리도록 돌릴 수 있지만, 평가가 믿을 만하려면 “현실적으로” 만들어야

Onboard 루프: 실차 안의 실시간 경로

- 실차 안에서 **매 순간** 도는 실시간 경로
- **Perception**(인지 — 주변 차량·보행자·신호등 인식)이 **정밀지도(HD map)**를 참조하며 결과를 **Planner**에 넘김

Planner

그 순간의 **궤적과 제어**(가감속/조향)를 냄.

- 제약: **수십 밀리초** 안에 결정해야 하고, 차를 멈춰놓고 “생각”할 수 **없음**
- “생각할 시간”이 아예 없는 환경이어서, 오프라인에서 미리 잘 만들어 온 Planner가 실차에 올라가 있는 것

Offboard 루프: 데이터센터에서 평가·재학습

- 같은 **Planner**를 차에서 꺼내, 시뮬레이터에서 **대량의** 주행 시나리오(에피소드)로 다시 굴림
- 평가 지수: **안전**(충돌/근접) · **승차감** · **주행 진행률**

평가 결과의 반영처

→ **정책 재학습 + 시나리오 선택** (다음에 어떤 시나리오를 더 돌릴지)

- 느리도록 돌릴 수 있지만, 평가가 **믿을 만하려면** 시나리오가 “**현실적으로** 만들어져야 한다”
- 이 “현실성” 문제가 바로 **SceneDiffuser**의 등장 이유 (뒤에서)

두 루프가 만나는 한 점: Planner

- 두 루프를 잇는 다이어그램에서 화살표가 두 개:
 - ▶ Perception $\leftrightarrow$ 지도: Perception이 본 것으로 지도를 갱신
 - ▶ Simulation $\leftrightarrow$ Planner: Simulation의 평가로 Planner를 향상
- 두 루프는 “향상시킬 대상인 Planner” 한 점에서 만남

구조의 핵심

Onboard는 정책을 돌리는 쪽, Offboard는 정책을 만들고 고치는 쪽 — 하나의 시스템이 실차/데이터센터 두 장소에 걸쳐 나뉘어 있는 구조.

Ch. 13의 전제가 실차 규모에서 만나는 곳

- Ch. 13의 전제: “시뮬레이터 안에서 먼저 익히고, 이후에 실물로 옮긴다”
- Ch. 13에서 **현실 격차(reality gap)**와 **도메인 무작위화**를 작은 로봇의 맥락에서 다룸

자율주행에서의 격차

“실물”이 **함부로 실험할 수 없는 도로**이기 때문에, Offboard 시뮬레이션은 이 책의 이전 어떤 예시보다 “**실물에 닮아 있어야**” 평가의 의미가 있다. ⇒ 현실 격차가 **전문의 핵심 문제**가 됨.

어디서 강화학습의 모양이 보이는가

Planner가 상태를 보고 행동을 정하는 구조는 **MDP의 모양** 그대로:

MDP 요소	자율주행에서
상태	Perception의 결과: 주변 물체의 위치·속도·궤적 + 자신의 주행 상태
행동	Planner가 정한 궤적/제어
환경의 다이내믹스 평가(보상)	다른 에이전트(차량, 보행자)가 자신의 행동에 어떻게 반응하는가 안전·승차감·진행률 같은 에피소드 지표

policy iteration의 모양

“Offboard 시뮬레이션에서 롤아웃 → 평가 → Planner 갱신”의 순서는 정확히 **policy iteration**의 모양 — 시뮬레이터가 7.3절의 **Dyna** 구조에서 “환경 모델”의 역할을 담당. 14.3의 “총 스텝 수 ÷ 초당 스텝 수 = 실 시간” 계산도 차 규모에서 동일.

차이 하나: “모델”이 시나리오 분포

- 다만 **실 환경** 한 스텝(실차)이 학습에 쓰기에 **너무 비싸고 위험** ⇒ 학습·평가 경험의 거의 전부를 시뮬레이터가 만들어 줌
- **로봇 문제**: “모델” = **시뮬레이터 자체**(사람이 쓴 물리식)
- **주행**: 다른 에이전트의 다이내믹스는 어떤 시뮬레이터에도 주어져 있지 않음 — 보행자의 행동에는 “물리식”이 없음

주행의 “모델”

시뮬레이터 물리만이 아니라, **시나리오의 분포** 그 자체 — 다른 에이전트가 어디에 있고 어떻게 움직이는지는 **데이터로부터 배운다**.

15.4(World Models)의 **known model** → **learned model** → **imagination** 구분이 여기서 다시 쓰임 — learned model이 대신하는 부분이 바로 “**현실적인 교통 상황 생성**” 부분.

Offboard의 병목: 시나리오를 어떻게 만들 것인가

로그 리플레이 (실제 기록 장면 재실행)

- 커버리지 문제
- “지금까지 실제로 일어났던 것뿐”
- 정확히 테스트하고 싶은 **희귀 상황** (주차 차량 사이에서 보행자가 갑자기 튀어나오는 경우)이 부족

완전 무작위 생성

- 반대 문제: 무엇이든 만들 수 있지만, **실제로는 일어나지 않는** 비현실적 교통 (한 차선에 10대가 겹치는 경우)까지
- ⇒ 평가가 **믿을 만하지** 않음

정리

Offboard 루프의 병목 = “**시나리오를 어떻게 만들 것인가**”. 재현만으로는 희귀 상황 부족, 무작위만으로는 현실성 부족 — 둘 다 부족한 틈이 있음.

SceneDiffuser (Waymo, 2024): 틸을 메우는 도구

핵심 아이디어

주행 데이터에서 “주변 에이전트의 위치와 궤적”의 결합 분포를 배운 **diffusion 모델**로, 다양하면서도 현실적이고 조절 가능한 장면 초기화(initialization)와 롤아웃 생성.

- “현실적인 시작점”을 공급받은 뒤, 실제 물리 시뮬레이터가 그 장면에서 롤아웃을 진행 — 생성모델과 시뮬레이터가 나뉘어 역할
- 조건화(자신 상태 + 지도)로 “그 교차로, 그 속도에서의 시나리오” 골라 샘플링 가능

이후 도시 규모로 확장하는 SceneDiffuser++ (2025)도 “generative world model”로 이어지고, 15.4 World Models와 같은 흐름.

ML1 Ch. 15.2의 diffusion과 같은 원리

- 대상이 다를 뿐, **이미지 생성**으로 배운 diffusion과 같은 원리
- 이미지는 **픽셀 벡터**, 주행 장면은 **에이전트 위치/궤적 벡터** — 둘 다 “분포로 볼 수 있는 고차원 데이터”

정방향 / 역방향

정방향: 가우시안 노이즈를 데이터에 **점진적으로** 섞음. **역방향:** 그 노이즈를 **점진적으로** 예측·제거하는 네트워크 ε_θ 학습. **추론:** 순 노이즈에서 출발해 한 단계씩 되돌리면, 배운 분포의 샘플 하나(여기서는 “**현실적인 주변 상황**”)이 “복원”.

- 다른 점: 대상이 픽셀이 아니라 **구조화된 궤적** — 네트워크는 “그림”이 아니라 **일관되고, 움직이고, 서로 충돌하지 않는** 에이전트 배치를 **내야** 함

diffusion이 여기에서 유리한 이유

- 다중 에이전트 상호작용의 **결합 분포**를 배우므로, 각 에이전트를 **독립 무작위**로 배치하는 것과 달리:
 - ▶ “차선이 같은 차량들의 추종”
 - ▶ “보행자의 동시 이동” 같은 상관 관계를 잡아냄

조건화 ⇒ “조절 가능”

자신의 상태와 지도로 조건화하면, “그 교차로, 그 속도에서의 시나리오”를 골라 샘플링할 수 있음
— “조절 가능한 시뮬레이션 초기화와 롤아웃”이라는 논문 제목의 의미.

역할

diffusion 모델이 물리 시뮬레이터의 “현실적인 시작점”을 공급하는 생성적 사전분포(prior)로 쓰이는 것 — 이것이 이 도구의 역할. 이후 도시 규모로 확장하는 SceneDiffuser++(2025)도 “generative world model”로 이어지고, 15.4 World Models와 같은 흐름.

이 절의 교훈을 한 문장으로

핵심

실차의 Onboard 루프는 “정책을 돌리는 것”이고, Offboard 루프는 “환경 모델 안에서 정책을 평가하고 바꾸는 것”이다.

- 자율주행의 두 루프 구조 = Ch. 7.3에서 본 **policy iteration/Dyna**의 산업 규모 버전
- “환경 모델”(시나리오)을 채우는 **핵심 기술** = “현실적인 교통이란 무엇인가”를 배운 **생성모델**

이 장의 주제도 변하지 않는다

“알고리즘은 그대로, 시뮬레이터만 바꾼다” — 차 규모에서도 변하는 건 “모델이 얼마나 현실적이어야 하는가”의 스케일일 뿐. 그것이 바로 시나리오 **재생**이 아니라 시나리오 **생성**이 활발한 연구 분야가 된 이유.

확인 문제 예시: Offboard에서 완전 무작위 샘플링이 diffusion 같은 생성모델을 대신할 수 없는 이유 — 각 에이전트를 “**독립적으로**” 배치하면 **상관 관계(추종, 동시 이동)**가 망가지고, 로그 리플레이로는 **희귀 상황의 커버리지**가 부족.

확인 문제 (14.4): MDP 네 요소 대응시키기

Onboard 루프 — Perception → Planner → 제어 — 는 MDP의 모양을 한다.

	실차 (Onboard)	Offboard 시뮬레이션
환경의 다이내믹스	실제 도로 위의 다른 차량·보행자의 실제 반응 (측정 불가, 관찰만)	시뮬레이터의 물리 + 학습된 장면 분포 가 만든 가상 에이전트 반응
평가	사고 여부, 정지 시간 등 사후 기록된 실차 지표 (실험 비용 극대)	에피소드마다 저렴하게 재계산되는 안전·승차감·진행률 지표

- **상태** = Perception의 결과, **행동** = Planner의 궤적/제어 (양쪽 동일)
- 차이: 실차의 한 스텝은 **물리적 시간 + 위험**, Offboard의 한 스텝은 **수 밀리초 + 실패 무료**

확인 문제 (14.4): 무작위 대신 생성모델

“Offboard 루프에 시나리오를 채운다”에서, **완전 무작위 샘플링**이 diffusion 같은 생성모델을 대신할 수 없는 이유:

- ① 각 에이전트를 **독립적으로** 배치하면 **상관 관계**가 망가진다 — “차선이 같은 차량의 추종”, “보행자의 동시 이동” 같은 결합 구조가 사라져 **비현실적인 교통** (한 차선 10대 겹침)까지 생성
- **로그 리플레이**로는 **희귀 상황의 커버리지**가 부족 — “실제로 일어났던 것뿐”이라, 바로 테스트하고 싶은 상황(주차 차량 사이에서 보행자 돌출)은 거의 없

연결: World Model(15.4)과의 공통점

15.4 World Model은 **학습된 스텝 다이내믹스 모델** (다음 상태 예측)로 경험을 만들고, 자율주행 Offboard는 **물리 시뮬레이터 + 학습된 장면 분포**로 경험을 만든다. 둘 다 “**학습된 모델**”이 “**현실적 상황 생성**”을 대신하는 것 — 학습의 대상(스텝 vs 장면 분포)만 다를 뿐이다.

이번 주차 정리

- ① **14.1 — 정밀 물리를 손으로** — XML로 로봇 정의 ($MjModel / MjData / mj_step$), 무작위 vs PD 200스텝($|\theta|$: 2.97 vs 1.69/최종 -0.065), **D항 없이는 관성 과속 진동·부호 오류면 발산**. 30줄 래퍼로 “환경이 바뀌어도 알고리즘은 그대로” **시연**. 정밀의 뿌리 = 매 스텝 **LCP 접촉 해결**.
- ② **14.2 — 수천 배의 기원** — 한 환경은 **시간 방향 의존성** 때문에 병렬화 불가, 병렬의 대상은 **환경(초깃값이 다른 복제본)**. “모든 상태를 한 텐서에, **커널 한 번**” — CNN과 같은 뼈대(공유는 코드, 차이는 상태). numpy 1,000 진자 실측 **76배**. Amdahl: 순차 부분이 상한.
- ③ **14.3 — 두 축으로 고르기** — **정밀도(물리 vs 센서) × 속도** (총 스텝 수 ÷ 초당 스텝 수). 같은 CPU에서 **40배**, 10억 스텝이면 CPU **2일** vs GPU **1.3분** ⇒ 1억+ 스텝에서야 GPU 필수. 30초 결정 절차: **정밀도 = 필요충분, 속도 = 비용 절감**.
- ④ **14.4 — 산업 규모** — Waymo Onboard/Offboard = **policy iteration/Dyna**의 산업 버전. 시나리오를 채우는 **SceneDiffuser** = “현실적 교통이란 무엇인가”를 배운 **생성모델**(ML1 15.2 diffusion의 대상 교체).

다음 주 — Chapter 15. 모델기반 RL과 몬테카를로 트리 탐색(MCTS)

이번 장은 **사람이 쓴 물리 모델**이 주어지는 문제였다. 다음 장은 그 물리 모델이 **주어지지 않는** 문제 — 모델이 학습될 대상이 되는 경우(Dyna, MCTS, World Models)로 넘어간다. 시뮬레이터가 주는 경험인지, 배운 모델이 주는 경험인지에 따라 **경험을 모으는 방식**이 어떻게 달라지는지 보게 된다.