Machine Learning 1: 머신러닝 첫걸음 2027. X. XX (예정)

기말 프로젝트 공고 (샘플)

Spring 2027

1. 프로젝트 개요

9∼15주차에서 배운 딥러닝 기법(신경망 기초·역전파, CNN, 시퀀스 모델, 어텐션·트랜스포머, 그래프 표현학습, 표현학습, 잠재변수 생성모델)을 실제 데이터에 적용하는 학기 후반 8주에 걸쳐 진행하는 팀 프로젝트이다. 중간 프로젝트 (8주차)의 절차를 **딥러닝 무대**에서 다시 수행하며, 이번에는 "왜 고전 머신러닝이 아니라 딥러닝인가"를 직접 증명해야 한다. 목표는 "높은 성능" 자체가 아니라 **비판적 사고력을 기르는 것**이다. 성능 숫자를 정직하게 얻는 절차를 실제로 수행하고, "이 숫자를 믿어도 되는가"를 스스로 따져 보며 보고한다.

진행 순서: **데이터 선정** → **Abstract** → **구현** → **검증** → **보고서 제출** → **동료평가**.

2. 필수 요구사항

- **데이터**: Kaggle, UCI, Hugging Face Datasets 중에서 선택 (이미지·텍스트·시퀀스 등 비정형 데이터도 가능).
- **적용 알고리즘**: 9∼15주차 중 **최소 하나의 딥러닝 기법**(CNN, RNN/Transformer, 프롬프팅 응용, 또는 EM/VAE 계열 생성모델)을 실제 데이터에 적용한다.
- **수식적 정당화 최소 1개**: (1) CNN 구조라면 파라미터 수/연산량 공식으로 설계를 정당화, (2) 정규화(dropout 등)를 썼다면 그 효과를 설명, (3) 생성모델이라면 ELBO나 min-max 목적함수를 실제 구현과 연결.
- **GBDT 비교 (필수)**: 같은 데이터에 GBDT(또는 랜덤 포레스트)를 **베이스라인**으로 돌려, 신경망이 이보다 나은지 확인한다. 이것이 보고서에서 "왜 딥러닝인가"를 답하는 근거의 출발점이 된다.
- **검증 원칙**: train/validation/test 3분할을 중간 프로젝트와 동일하게 준수하고, **테스트 성능은 딱 한 번**만 확인한다.

3. 정형/비정형 판정 가이드

중간 프로젝트의 5개 데이터 선정 기준(행의 물리적 단위, 레이아웃 함정, 시계열, 클래스 비율, 크기)은 그대로 적용되며, 기말 프로젝트에서는 다음 기준이 추가된다: **"원시 특징"이 이미 정형으로 추출되어 있는가?**

경우	예	판정
수치·범주 열로만 구성된 표	매출표, 센서 로그	**정형** — GBDT와 비교해야 한다
픽셀·음파·토큰인 원시 배열	이미지, 오디오, 문장	**비정형** — 손으로 특징을 만들기 어려우니 신경망이 특징 추출기 역할을 한다
애매한 경우	이미 임베딩으로 벡터화된 텍스트	원시 토큰으로 직접 모델링하는 선택도 가능 — 그 이유를 Abstract에 적어야 한다

데이터 가게와 데이터 월드컵도 활용한다. `smhanlab.com/book-ml/datashop`에는 이미지·텍스트·시계열·그래프처럼 딥러닝이 어울리는 현장 데이터(품질 검사 영상, 한국어 리뷰, 음성, 위성 영상, 링크 예측, 차량 궤적 등)도 진열되어 있다. 데이터마다 적힌 행의 단위, 라벨, 크기, 함정을 위 기준으로 먼저 점검하고, 후보를 정하기 어려우면 **데이터 월드컵**(`.../datashop/worldcup/`)으로 후보를 2~3개로 좁힌다. 정형으로 쓸 수 있는 데이터를 골랐다면 GBDT 베이스라인과의 비교가 더 중요해진다.

4. 일정 (후반 8주)

시기	해야 할 일	제출
기말 1주(9주차)	팀 구성, 데이터 후보 2~3개 조사, 정형/비정형 판정	
기말 2주(10주차)	행·라벨·지표·베이스라인, "왜 딥러닝인가" 초안, 적용할 신경망 계획	**Abstract** (1p)
기말 3~5주	3분할 스캐폴드, train으로만 fit한 전처리, **GBDT 베이스라인**, 신경망 적용, validation 튜닝, **test 최종 측정(한 번만)**, 학습 곡선(에포크 단위)	
기말 6주(14주차)	보고서 완성, 영상 제작	**보고서 + 영상 제출**: 보고서 PDF + 코드 + **영상** + 학습 곡선 + GBDT 비교
기말 7주(15주차)	제출된 다른 팀 보고서 읽기	
기말 8주(16주차, 기말고사 기간)	다른 팀 2개에 대한 peer-review 작성	**동료평가** 제출 (리뷰 2건)

학습 곡선은 **에포크** 단위(중간 프로젝트의 트리 개수와는 다른 축)이다. 최종 숫자만으로는 에포크 수를 어떻게 정했는지 검증할 수 없다 — validation 곡선이 실제로 쓰였는지가 그림에서 드러나야 한다.

5. 보고서 구조

중간 프로젝트의 6절 구조를 그대로 쓰되, 2절과 5절이 기말 프로젝트용으로 바뀐다.

1. **문제 정의** (0.5p): 행의 단위, 라벨, 주 지표, **두 층의 베이스라인**(무작위·GBDT), **정형/비정형 판정과 그 근거**.
2. **데이터와 전처리** (1p): 원본 통계, train으로만 fit한 전처리 명시(이미지 스케일링, 텍스트 토크나이저/패딩 등), 분할 비율.
3. **모델 선택과 이유** (1~2p): 적용한 딥러닝 기법 1개 이상과 그 구조(층·크기)를 파라미터 수 공식으로 정당화, 왜 GBDT가 아니라 이 기법인가.
4. **결과** (1p): 최종 test 숫자(한 번), 에포크 학습 곡선 1장, GBDT·무작위와의 비교표.
5. **수식적 정당화** (1p, **필수 1개**): 파라미터 수/정규화 효과/ELBO 중 하나.
6. **재현 방법** (0.5p): 데이터 출처, 분할, 시드, 하이퍼파라미터, 실행 명령. 다른 사람이 같은 숫자를 다시 얻을 수 있어야 한다.

7. **한계와 잘 안 된 부분** (0.5p, **필수**): 학습이 안 된/과적합된 부분을 배운 개념으로 진단.

6. 채점 기준 (Rubric)

다섯 항목을 각 20%로 채점한다. 목적은 "높은 성능"이 아니라 **주장을 정직하고 재현 가능하게 입증**하는 것이다.

항목	비중	좋은 답
1. 주장의 명확성 (clarity)	20%	무엇을 주장하는지 첫 문단에서 한 문장으로 알 수 있고, 행의 단위·라벨·지표가 명확하며, 결과가 주장과 이어짐. 수식·개념을 읽기 쉽게 쓰고, 같은 내용을 되풀이하거나 기호를 불필요하게 늘려 혼잡하게 만들지 않음
2. 비교 대상 (baseline)	20%	**GBDT 베이스라인**과 신경망이 같은 분할·같은 지표로 비교되고, "왜 고전 머신러닝이 아니라 딥러닝인가"에 구체적 숫자로 답함
3. 확장성 (scalability)	20%	다른 데이터 하나(또는 데이터 크기를 줄인 실험)에서도 결론이 유지되는지 확인하고, 구성 요소 제거·민감도 실험으로 어디까지 통하는지 보임
4. 재현성 (reproducibility)	20%	데이터 출처·분할 방식·전처리·하이퍼파라미터·랜덤 시드·코드 실행 방법이 적혀 있어 다른 사람이 같은 숫자를 다시 얻을 수 있음. test를 한 번만 썼고 어디서 썼는지 추적 가능
5. 한계의 솔직함 (limitations)	20%	잘 안 된 부분, 약한 가정, 일반화되지 않을 조건을 숨기지 않고 원인을 진단함. 성능이 낮아도 한계가 정직하면 높은 점수

성능이 좋아 보여도 test를 두 번 썼거나 비교 대상이 없거나 재현이 불가능하면 크게 감점받는다.

7. 동료평가 (Peer-Review)

- **보고서**: 결론에서 **"왜 고전 머신러닝이 아니라 딥러닝인가"**에 구체적 근거로 답해야 한다.
- **Peer-Review**: 기말 8주차에 다른 두 팀의 보고서에 대해 작성 리뷰를 각 1통씩 제출한다. 각 리뷰는 아래 5항목 체크리스트와, 반박 가능한 질문을 1개 이상 포함해야 한다.

Peer-Review 체크리스트 (채점 기준과 같은 5항목)

항목	확인할 것
주장의 명확성 (clarity)	무엇을 주장하는지 분명한가, 수식·개념이 이해하기 쉽고 중복·혼잡 없이 쓰였는가
비교 대상 (baseline)	비교 대상이 있는가 (GBDT 베이스라인 포함)
확장성 (scalability)	다른 데이터에도 적용 가능한가
재현성 (reproducibility)	다른 사람이 다시 해 볼 수 있는가
한계 (limitations)	한계를 솔직하게 적었는가

8. 팀 구성 및 제출 방식

- **팀 구성**: 팀당 인원 및 팀 편성 방식은 추후 공지.
- **제출물**: Abstract(기말 2주), 보고서(PDF)와 코드, **영상**(기말 6주), peer-review 2건 (기말 8주). 영상은 문제, 방법, 결과, 한계를 설명하는 영상 1편이며, 길이와 형식은 추후 공지한다.
- **제출 방법 및 마감**: 추후 공지 (LMS/과제 제출 시스템 및 마감 일시는 별도 안내 예정).