Machine Learning 1: 머신러닝 첫걸음 샘플

기말 프로젝트 샘플 (Abstract · 보고서 · 동료평가)

Spring 2027

아래는 **가상의 팀**이 쓴 샘플입니다. 수치는 형식을 보이기 위한 예시이며 실제 실험 결과가 아닙니다. 형식과 분량의 기준으로만 참고하세요.

① Abstract 샘플 (기말 2주차 제출, 1쪽)

제목: Fashion-MNIST에서 작은 CNN과 GBDT 비교: 딥러닝이 필요한가
팀: 김OO, 이OO, 박OO

문제 정의. 행 하나는 **옷 사진 한 장**(28×28 흑백), 라벨은 10종류 중 하나이다. 클래스가 균형이라 주 지표는 정확도와 macro-F1이다.

왜 딥러닝인가 (초안). 픽셀 784개를 그대로 표처럼 넣으면 이웃 픽셀의 구조를 모델이 모른다. 합성곱이 이 구조를 쓰는지가 가설이며, GBDT와의 차이로 검증한다.

데이터와 분할. Fashion-MNIST 70,000장. 공식 train 60,000장을 50,000/10,000으로 나눠 train/validation으로 쓰고, 공식 test 10,000장은 마지막에 한 번만 쓴다.

베이스라인. 픽셀 784개를 입력으로 한 **GBDT**. 같은 train/validation으로 튜닝한다.

계획. 합성곱 2층의 작은 CNN을 만들고, 에포크 곡선으로 조기 종료 지점을 정한다. 데이터 증강(좌우 반전)과 드롭아웃의 효과를 구성 요소 제거 실험으로 확인한다.

② 보고서 샘플 (기말 6주차 제출, 축약본)

1. 문제 정의. 사진 한 장이 행, 라벨은 10종류. 주 지표는 정확도와 macro-F1. 베이스라인은 GBDT(픽셀 입력).

2. 데이터와 전처리. 공식 test는 한 번만 사용했다. 픽셀 값은 0–1로 스케일링(데이터 전체 상수 255로 나눔, 통계량 누수 없음).

3. 모델 선택과 이유. 합성곱이 이웃 픽셀의 모양을 쓰는지 보기 위해 CNN을, 구조를 모르는 비교 대상으로 GBDT를 골랐다.

모델 (validation)	정확도	비고
GBDT (픽셀 784)	0.89	베이스라인
CNN 2층	0.91	
CNN 2층 + 데이터 증강	0.92	
CNN 2층 + 증강 + 드롭아웃	0.93	에포크 15에서 종료

4. 결과. 최종 test는 한 번만: CNN 0.92, GBDT 0.88. 학습 곡선(에포크 단위)에서 에포크 15 이후 validation이 내려가기 시작해 15에서 멈췄다.

5. 수식적 정당화와 왜 딥러닝인가. 합성곱은 파라미터를 위치마다 공유해 3×3 필터 하나로 어디서든 같은 모양을 찾는다. 같은 크기의 완전연결층보다 파라미터가 적다. 그 결과 GBDT보다 test 정확도가 4%p 높았다. 다만 정확도 차이가 크지 않아, 표 데이터였다면 GBDT로 충분했을 것이다.

6. 재현 방법. 공식 Fashion-MNIST, 시드 0, 배치 16, 에포크 15, 학습률 0.001. `run.sh` 한 줄로 다시 실행된다.

7. 한계와 잘 안 된 부분. 배치 정규화를 넣었더니 validation이 오르락내리락해서 뺐다. 배치 크기가 작아(16) 통계가 불안정했다고 진단했다.

③ 동료평가 샘플 (기말 8주차 제출)

평가 대상: 다른 팀의 "영화 리뷰 감성 분류" 보고서 **작성자**: 이OO

항목	평가
주장의 명확성	LSTM이 TF-IDF보다 낫다는 주장이 분명하다.
비교 대상	TF-IDF + 로지스틱회귀 베이스라인이 없다. 왜 딥러닝인가가 정확도가 높아서 한 줄이다.
확장성	영화 리뷰만 다뤘다. 다른 도메인(상품 리뷰)에서의 확인이 없다.
재현성	데이터 출처, 시드, 에포크 수, 실행 명령이 모두 있어 다시 해 볼 수 있다. 좋다.
한계	긴 문장에서 성능이 떨어지는 것을 보이고 원인을 진단했다. 좋다.

반박 가능한 질문. TF-IDF + 로지스틱회귀 같은 단순한 베이스라인을 돌렸나요? 그 정확도와 LSTM의 차이가 계산 비용을 감당할 만큼인가요?