# 문제 정형화와 평가지표

## Problem Formulation · Metrics · Baselines

Machine Learning and Deep Learning

KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

# 오늘의 질문




투수가 **공을 던지기 전에**,
이번 공이 **홈런일까?**를 맞히는 **AI**를
만들었다.

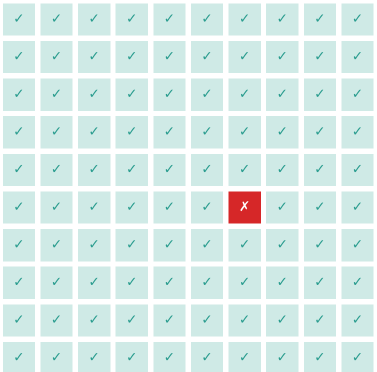
2024년 6월 MLB 투구 116,355개에서

**정확도 99.21%**

좋은 모델일까?

2024 MLB 정규시즌 6월 (Baseball Savant)

# 답: 이 AI는 모든 공에 “홈런 아님”이라고만 했다



공 100개 중 **홈런 1개** 꼴 (0.79%)

| | |
|---|---|
| 2024년 6월 MLB 투구 | 116,355 |
| 그중 홈런 | 921 (0.79%) |
| 홈런 아님 | 115,434 |
| 맞힌 공 (전부 “아님”) | 115,434 |
| 정확도 | $\frac{115{,}434}{116{,}355} = \mathbf{99.21\%}$ |
| 잡아낸 홈런 | **0 개** |

홈런이 드물어서 **아무것도 안 해도** 99%

6월 오타니가 받은 공 498개 중 홈런 12개, 하나도 못 맞힌다

## 머신러닝 문제 = 다섯 칸 채우기

| | | |
|---|---|---|
| ① | **한 행은 무엇?** | 예시 하나의 단위: 공 하나 (투구), 타석 하나, 타자 한 명 |
| ② | **입력** $X$ | **던지기 전** 정보만: 볼카운트 · 타자 · 투수 **O**, 구종 · 비거리 **X** |
| ③ | **출력** $y$ | 맞히려는 것: 이 공이 홈런? 스윙할까? 구속은? |
| ④ | **평가지표** | 무엇으로 채점하나: 정확도, MAE, 정밀도 · 재현율 … |
| ⑤ | **기준선** | 머리 안 쓰는 답의 점수: 가장 흔한 답 (“홈런 아님”), 평균 |

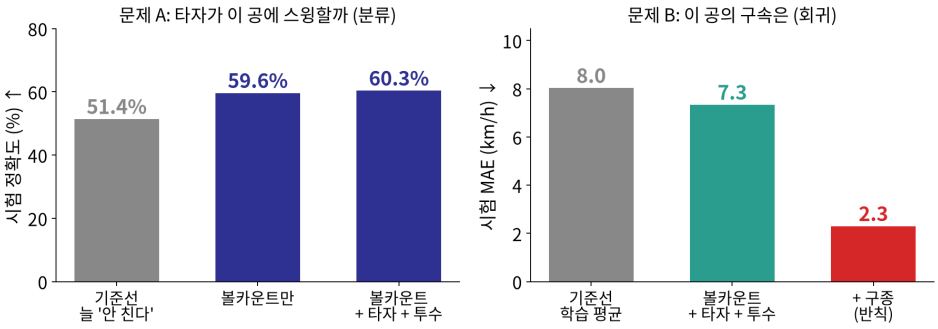
다섯 칸이 정해져야 **“잘했다”를 말할 수 있다**

## 출력 $y$ 의 모양이 문제의 종류를 정한다

| 출력 $y$ | 문제 종류 | 예 |
|---|---|---|
| 범주 하나 | **분류** (classification) | 이 공이 홈런인가, 스윙할까 (예/아니오) |
| 숫자 하나 | **회귀** (regression) | 공의 구속, 타구 비거리 |
| 숫자 여러 개 | 물체 찾기 (detection) | 중계 화면에서 공을 감싼 상자 (좌표 4개) |
| 글 · 그림 | 생성 | 다음 단어, 그림 (14주차 이후) |

같은 데이터라도 $y$ **를 무엇으로 정하느냐**에 따라 다른 문제가 된다

# 같은 공, 두 문제: 스윙할까? 구속은?




문제 A: $y$ = 스윙할까 $\rightarrow$ **정확도**　　문제 B: $y$ = 구속 (km/h) $\rightarrow$ **MAE**

2024년 6월 MLB 투구 115,940개, 입력 = 던지기 직전 볼카운트 · 타자 · 투수, 6/1∼23 학습 · 6/24∼30 시험 (27,916개), 로지스틱회귀 / 선형회귀.

**구종**은 던진 뒤에야 안다. 넣으면 구속 MAE 가 2.3로 확 줄지만 **반칙**이다 (답과 거의 같은 정보)

# 회귀의 채점: MAE 와 RMSE

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n} |\, y_i - \hat{y}_i \,| \qquad \text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

$y_i$ = 정답, $\hat{y}_i$ = 예측, 둘 다 $y$ **와 같은 단위** (m, 개)

오차 [1, 1, 1, 9]: $\text{MAE} = \frac{1+1+1+9}{4} = \mathbf{3}$ RMSE $= \sqrt{\frac{1+1+1+81}{4}} = \sqrt{21} = \mathbf{4.58}$

RMSE 는 제곱하니까 **크게 틀린 하나**에 더 큰 벌을 준다. 무엇이 더 나쁜지에 따라 고른다

## 기준선: 머리를 안 쓴 답은 몇 점인가

| 문제 | 기준선 | 점수 |
|---|---|---|
| 스윙할까 (분류) | 늘 “안 친다”라고 답 | 정확도 **51.4%** |
| 구속 (회귀) | 늘 학습 데이터의 평균 구속 (143.6km/h) | MAE **8.0km/h** |
| 모든 공 (분류) | 늘 “홈런 아님”이라고 답 | 정확도 **99.21%** |

모델 점수는 **기준선과 비교**해서 읽는다

## 시험 데이터 = 모델이 “실제로 만날” 데이터

| 나누는 법 | 결과 |
|---|---|
| 무작위로 섞기 | **X**: 같은 경기 · 같은 타석의 앞뒤 공이 학습과 시험에 나뉜다 |
| **날짜 순서대로** | **O**: 6월 1∼23일로 학습, 24∼30일로 시험 (오늘 쓰는 두 문제 모두) |

미래를 섞어 학습하면 **시험 점수가 거짓말**을 한다

## 투구 데이터 열어 보기: 한 행 = 공 하나

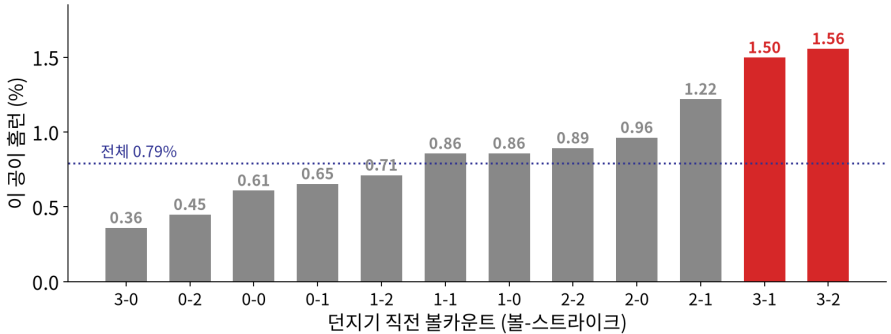
| 공 | 던지기 직전 볼카운트 | 구종 | 구속 | 결과 | 홈런? |
|---|---|---|---|---|---|
| 1 | 0-0 | 직구 | 160 km/h | 헛스윙 | 0 |
| 2 | 0-1 | 체인지업 | 140 km/h | 볼 | 0 |
| 3 | 1-1 | 체인지업 | 142 km/h | 볼 | 0 |
| 4 | 2-1 | 직구 | 160 km/h | 헛스윙 | 0 |
| 5 | 2-2 | 직구 | 161 km/h | 볼 | 0 |
| 6 | **3-2** | 직구 | 161 km/h | 타격 $\rightarrow$ **홈런** | **1** |

2024-06-05 오타니의 한 타석 (Baseball Savant). **타석** = 타자가 들어서서 결과가 나올 때까지, 공 여러 개 (6월 평균 3.87개)

입력 $X$: **던지기 직전 볼카운트** · 타자 · 투수 출력 $y$: 이 공이 홈런인가 (0/1)

볼카운트는 타석 안에서 공마다 바뀌고, 새 타석이 시작되면 0-0 으로 돌아간다

# 던지기 직전 볼카운트는 도움이 될까?




0-2 에서는 **0.45%**, 3-2 에서는 **1.56%**: 볼카운트에 따라 3배 넘게 다르다

2024년 6월 MLB 투구 116,355개. 3-0 이 낮은 건 타자가 거의 치지 않기 때문 (볼 하나면 볼넷)

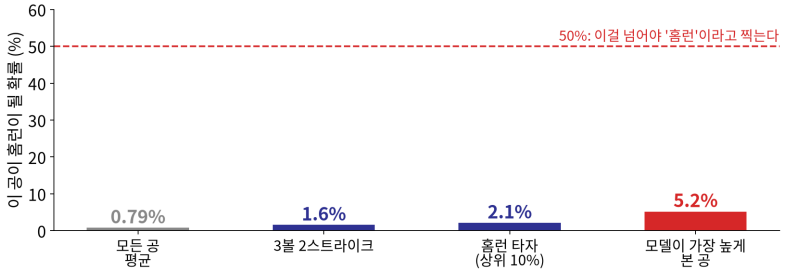
# 정확도의 함정: 드문 것을 찾는 문제

| | 전부 “홈런 아님” | 규칙: 볼카운트가 3-1 · 3-2 면 “홈런” |
|---|---|---|
| 정확도 | **99.21%** | 92.39% |
| 잡아낸 홈런 | **0 개** | **126개** |

홈런을 **하나도 못 잡는** 쪽이 정확도는 더 높다

홈런이 드물어서, “아님”을 맞힌 수가 점수를 거의 다 차지한다

# 던지기 전 정보로 홈런을 맞힐 수 있을까?




볼카운트 · 타자 · 투수를 다 넣어도 확률은 **두세 배** 오를 뿐, **50%는 근처에도 못 간다**

그래서 모델은 모든 공에 "홈런 아님". 못 맞히는 문제도 있다 → **정확도 대신 다른 잣대**로 봐야 한다

6/1~23 학습 · 6/24~30 시험, 입력 = 볼카운트 · 타자 · 투수 (원-핫), 로지스틱회귀. 홈런 타자 = 6월 1~23일 공 150개 이상 받은 타자 중 홈런 비율 상위 10%

## 그래서 세는 법을 바꾼다: 정밀도와 재현율

| | 실제 홈런 | 실제 아님 |
|---|---|---|
| **“홈런”이라고 함** | **126** (잡았다) | **8,063** (헛짚었다) |
| **“아님”이라고 함** | **795** (놓쳤다) | (나머지) |

$$\text{재현율 (recall)} = \frac{\text{잡았다}}{\text{실제 홈런 전부}} = \frac{126}{126+795} = \mathbf{13.7\%}$$

$$\text{정밀도 (precision)} = \frac{\text{잡았다}}{\text{“홈런”이라고 한 것 전부}} = \frac{126}{126+8{,}063} = \mathbf{1.54\%}$$

전부 “홈런 아님”은 재현율 0%. 자세한 계산과 둘 사이의 줄다리기는 3주차 (정밀도와 재현율)

## 한 행을 무엇으로 정하나: 공 vs 타석 vs 타자

| | 한 행 = 공 하나 | 타석 하나 | 타자 한 명 |
|---|---|---|---|
| 행 수 | 116,355 | 30,060 | 480 |
| $y = 1$ 인 행 | 921 | 921 | 310 |
| 홈런 비율 | **0.79%** | 3.06% | **64.6%** |
| 현실의 질문 | 이 공이 홈런? | 이 타석이 홈런? | 이 타자가 이번 달 홈런? |

같은 기록, 다른 문제. “홈런 비율”이 숫자마다 다른 이유

2024년 6월 MLB. 타석은 홈런으로 끝났으면 1, 타자는 6월에 홈런을 한 번이라도 쳤으면 1

## 지표를 정하면, 모델은 그 지표만 쫓는다

| 지표 | 이 점수를 최대로 만드는 가장 쉬운 방법 |
|---|---|
| 정확도 | 전부 “홈런 아님” → 99.21% |
| 재현율 | 전부 “홈런” → 100% (그런데 아무 정보가 없다) |
| 정밀도 | 가장 확실한 공 하나만 “홈런” → 100% (나머지는 다 놓친다) |

지표는 **현실에서 무엇이 손해인지**에서 거꾸로 정한다

예: 홈런 예측으로 하이라이트 카메라를 미리 돌린다면, 놓친 홈런 장면 하나 vs 헛돌린 카메라 한 번

## 문제풀이

1. 다섯 칸을 채워 보자: (a) 스팸 문자 거르기 (b) 내일 서울 최고 기온 (c) 사진 속 고양이 위치 찾기
2. 예측 $[10, 20, 30, 40]$, 정답 $[12, 18, 30, 50]$. MAE 와 RMSE 는?
3. 어떤 타자가 공 1,000개를 받아 홈런 8개를 쳤다. 매번 “홈런 아님”의 정확도는? 재현율은?
4. 공마다 홈런을 맞히는 모델의 입력에 “타구 비거리”를 넣었더니 정확도가 크게 올랐다. 무엇이 잘못됐나?
5. 학생 성적 데이터에서 시험 데이터를 무작위로 뽑았는데, 같은 학생의 다른 학기 기록이 학습 데이터에 있다. 무엇이 문제일까?

## 실습: 문제를 직접 정해 보기

1. 6월 투구: 스윙할까 (분류) · 구속 (회귀), 정확도 · MAE · 기준선 직접 구현
2. 6월 투구 116,355개: 전부 “아님” 99.21%, 볼카운트 규칙의 정밀도 · 재현율, 한 행 = 공 $\rightarrow$ 타석 $\rightarrow$ 타자 (0.79% $\rightarrow$ 3.06% $\rightarrow$ 64.6%)

투구 데이터는 Baseball Savant 에서 받는다 (로그인 없이, 처음엔 5분쯤)

▶ Colab에서 실습 노트북 열기

# 정리

문제 = **다섯 칸**: 한 행 · 입력 $X$ · 출력 $y$ · 평가지표 · 기준선

같은 데이터라도 $y$ 와 **한 행**을 다르게 정하면 다른 문제 (공 vs 타석 vs 타자)

점수는 **기준선과 비교**해서 읽는다 (99.21% 도 “아무것도 안 함”일 수 있다)

시험 데이터는 실제로 만날 데이터처럼: 시간 순서, 사람 · 지역 단위

지표는 **현실의 손해**에서 거꾸로 정한다 (놓친 홈런 vs 헛돌린 카메라)

# 이미지 · 데이터 출처

- 투구 (p.1, p.5): Baseball Savant (MLB Statcast), 2024-06 정규시즌 모든 투구 CSV; 게임 화면: 컴투스프로야구2021 (컴투스) 캡처, 아래 자막만 덧그림