로지스틱회귀 (Logistic Regression)

숫자 대신 확률을 예측하기

Machine Learning and Deep Learning

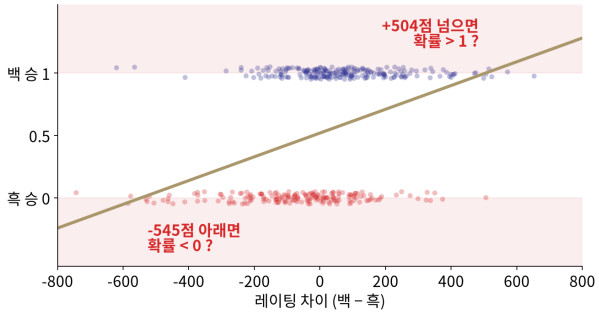
KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

lichess 한 판: 이름 옆 숫자가 레이팅



백 **1159** 대 흑 **1442**: 283점 높은 흑이 이겼다

오늘의 질문: 레이팅이 200점 높으면 몇 % 이길까?

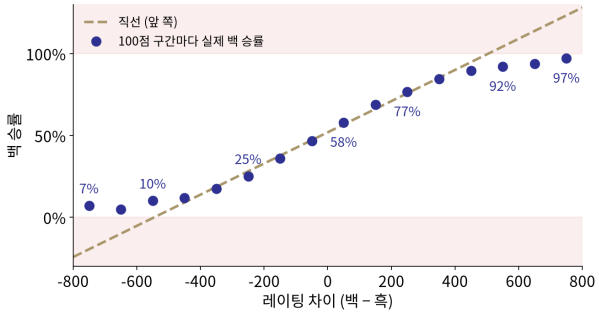


백 한 사람 기준으로: 레이팅 차이로 **이기면 1, 지면 0**을 예측: 직선을 그으면?

온라인 체스 lichess, 2013년 1월 승패가 난 117,003판 중 400판 표시 레이팅 = 게임 랭크 점수 (MMR)와 같은 것

백 · 흑은 레이팅과 상관없이 정해진다: 백이 더 높은 판 52%, 흑이 더 높은 판 48% (앞 쪽처럼 $x < 0$)

점을 세어 보면: 비율은 S 자

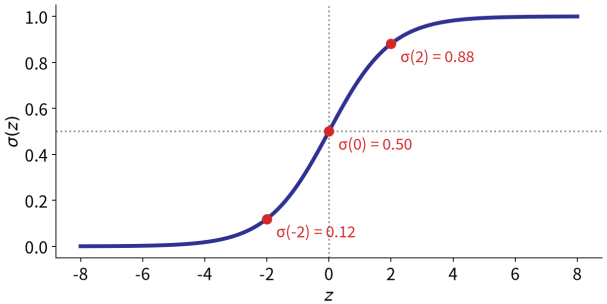


100점 구간마다 백 승률: -500 점이면 10%, 비슷하면 반반, $+500$ 점이면 92%

예측할 것은 0 / 1 이 아니라 **이 비율 = 확률** 0 과 1 사이에서 **S 자**로 눕는다

차이가 클수록 승률이 오르지만, 아무리 강해도 100% 는 못 넘는다: 직선은 끝에서 빗나간다

시그모이드: 아무 수나 0과 1 사이로



$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

z 가 크면 $\to 1$, z 가 작으면 $\to 0$

$z = 0$ 이면 정확히 0.5

로지스틱회귀 모델

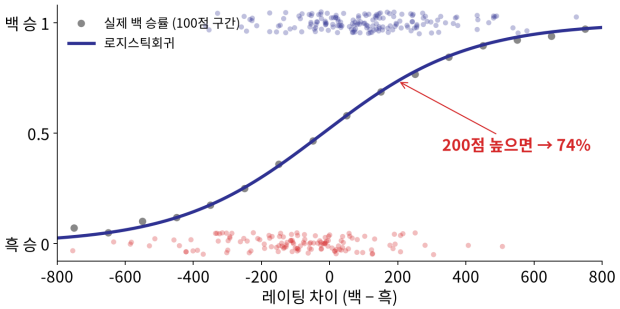
$$\hat{y} = \sigma(\underbrace{w_0 + w_1 x}_{z}) = P(\text{white wins} \mid x)$$

선형회귀의 직선 z 를 그대로 쓰고, 마지막에 σ 만 씌운다 $\rightarrow$ S 자 곡선

x = 레이팅 차이 (백 $-$ 흑) 출력 $\hat{y}$ = **백이 이길 확률**

이름은 “회귀”지만 하는 일은 **분류** 수식에서는 백 승을 ‘white wins’ 로 쓴다

12만 판으로 학습하면



$$\hat{y} = \sigma(0.09 + 0.0047\,x)$$

백이 200점 높으면 → 백 승률 74%

레이팅을 정하는 **Elo 공식** $\frac{1}{1+10^{-x/400}} = \sigma(0.0058\,x)$ 도 같은 꼴: 레이팅 시스템이 곧 로지스틱회귀

Elo: 이 방식을 만든 아르파드 엘로 (Arpad Elo) 의 이름, 약자가 아니다. 레이팅 숫자를 “Elo 점수”라고도 부른다

결정 경계: $z = 0$ 인 곳

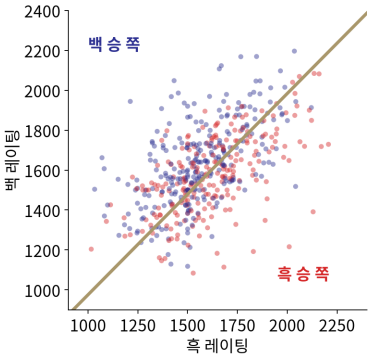
$$\hat{y} \geq 0.5 \iff z = w_0 + w_1 x \geq 0 \iff x \geq -\frac{w_0}{w_1} = -\frac{0.09}{0.0047} \approx -20$$

백은 **20점 약해도** 반반: 먼저 두는 쪽이 유리하다 (레이팅이 같으면 $\sigma(0.09) \approx$ **52%**)

시그모이드는 $z = 0$ 에서 0.5 (p.4) $\rightarrow$ **경계는 직선 $z = 0$ 이 정한다**

절편 w_0 에도 뜻이 있다: 실력이 같을 때의 백의 이점

특징이 둘이면: 경계는 직선



특징을 백 레이팅 a, 흑 레이팅 b 따로 넣으면

$$z = 0.15 + 0.00466\,a - 0.00470\,b$$

경계 $z = 0$ 은 평면 위의 **직선** $\quad a \approx b - 32$

두 계수가 **크기는 같고 부호만 반대**

$\rightarrow$ 모델이 스스로 "**차이**만 중요하다"를 찾았다

1,000 점끼리든 2,000 점끼리든 차이가 같으면 승률도 같다 (Elo 의 생각)

w_1 을 읽는 법: 오즈

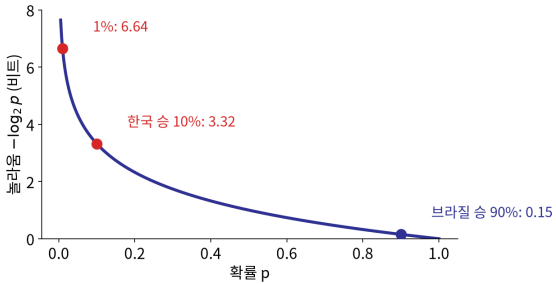
$$z = \ln \frac{p}{1-p} \qquad \text{odds} = \frac{p}{1-p} = \frac{\text{백 승 확률}}{\text{흑 승 확률}}$$

100점 높으면 z 가 $100\,w_1$ 만큼 커진다 $\rightarrow$ 오즈가 $e^{0.47} \approx$ **1.6배**

Elo 공식은 **400점마다 오즈 10배**로 정해 둔 것 $(10^{x/400})$ 데이터에서는 6.5배

예: 반반 (오즈 1) $\rightarrow$ 100점 높으면 오즈 1.6, 확률 $1.6/2.6 \approx 62\%$

놀라움 (정보량): 드물수록 크다



$$I(x) = -\log_2 p(x)$$

브라질 승 (90%)	0.15 비트
반반 (50%)	1 비트
한국 승 (10%)	**3.32 비트**
1% 사건	6.64 비트

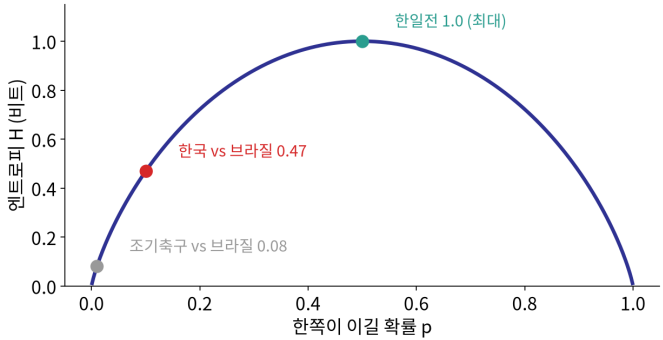
엔트로피 = 놀라움의 평균

$$H = \sum_i p_i \cdot \big(- \log_2 p_i \big) = - \sum_i p_i \log_2 p_i$$

한국 vs 브라질: $0.9 \times 0.15 + 0.1 \times 3.32 = \mathbf{0.47}$ 비트

경기를 보기 **전**, 결과가 평균적으로 얼마나 놀라울지 = 불확실함의 크기

팽팽할수록 엔트로피가 크다



조기축구 vs 브라질 (1%): **0.08** 한국 vs 브라질: 0.47 한일전 (반반): **1.0, 최대**

조기축구팀이 이기면 놀라움은 6.64 로 크지만, 1% 라서 평균에는 거의 기여하지 않는다

교차 엔트로피: 내 예측으로 잰 놀라움

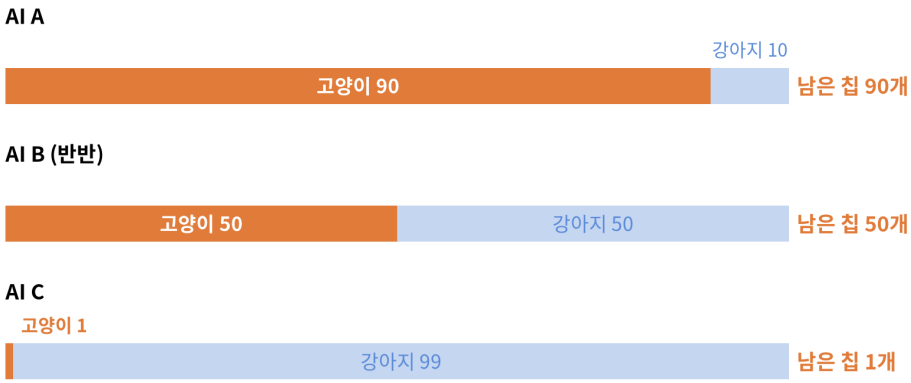
$$H(p, q) = -\sum_i \underbrace{p_i}_{\text{실제}} \log_2 \underbrace{q_i}_{\text{내 예측}}$$

엔트로피는 실제 확률 p 로 놀라움을 쟀다. 교차 엔트로피는 **모델이 말한 확률** q 로 잰다

경기가 끝나 정답이 나오면 p = (이긴 쪽 1, 진 쪽 0) $\rightarrow$ 합에서 한 항만 남는다: $-\log_2 q_{\text{정답}}$

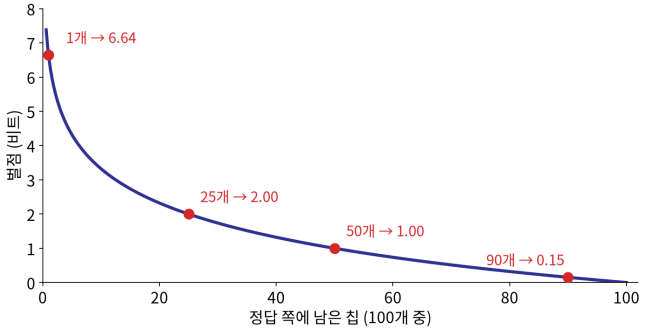
정답에 0.9 를 줬으면 0.15 비트, 0.1 을 줬으면 **3.32 비트**: 모델이 **정답을 얼마나 놀라워했나**

칩 100개를 나눠 걸기



AI는 칩 100개를 답마다 나눠 건다. **정답 쪽에 건 칩만 남는다**

남은 칩이 적을수록 큰 벌점



$$\text{벌점} = -\log_2 \frac{\text{남은 칩}}{100}$$

100개 → 0　　50개 → 1　　25개 → 2

칩이 절반이 될 때마다 벌점 +1

90개 → **0.15**　　1개 → **6.64**

밑은 아무거나: $\log_2$ → **비트**, $\ln$ → **냇**

ML 코드는 보통 ln. 값만 상수배 (p.17)

정답에 0개를 걸었다면

강아지에 전부 걸었다

고양이 0

강아지 100 — **벌점 ∞**

모르겠으니 반반

고양이 50 | 강아지 50 — **벌점 1.00**

정답에 하나도 안 걸면 **파산: 벌점** ∞. 모를 땐 반반이 낫다 (틀려도 1점)

로지스틱회귀의 손실: 교차 엔트로피

$$L = -\big[\, y \ln \hat{y} + (1-y) \ln(1-\hat{y}) \,\big]$$

y: 정답 (1 또는 0)　　$\hat{y} = \sigma(z)$: 1일 확률 (시그모이드 출력)

$y = 1$ 이면　$L = -\ln \hat{y}$　(1에 건 칩)

$y = 0$ 이면　$L = -\ln(1-\hat{y})$　(0에 건 칩)

실제 코드는 $\log_2$ 대신 자연로그 ln　6.64 비트 $= 6.64 \times \ln 2 \approx 4.60$ (값만 상수배)

12만 판 전체의 손실: 평균

$$J(\boldsymbol{w}) = -\frac{1}{m}\sum_{i=1}^{m}\left[\, y^{(i)} \ln \hat{y}^{(i)} + (1 - y^{(i)}) \ln(1 - \hat{y}^{(i)}) \,\right]$$

판마다 **정답 쪽에 건 확률**에 $-\ln$, 그리고 평균

예: 백이 이긴 판 ($y = 1$) 에 $\hat{y} = 0.74$ 였다면 $-\ln 0.74 = 0.30$, 졌다면 ($y = 0$) $-\ln 0.26 = 1.35$

왜 오차 제곱(MSE)이 아닐까: 벌점의 크기

	MSE $(1-\hat{y})^2$	**교차 엔트로피** $-\ln \hat{y}$
정답에 0.9	0.01	0.11
반반 0.5	0.25	0.69
확신하고 틀림 0.01	**0.98**	**4.60**
정답에 0	1 (최대)	∞

MSE는 아무리 크게 틀려도 벌점이 1을 넘지 못한다

더 큰 이유: 기울기

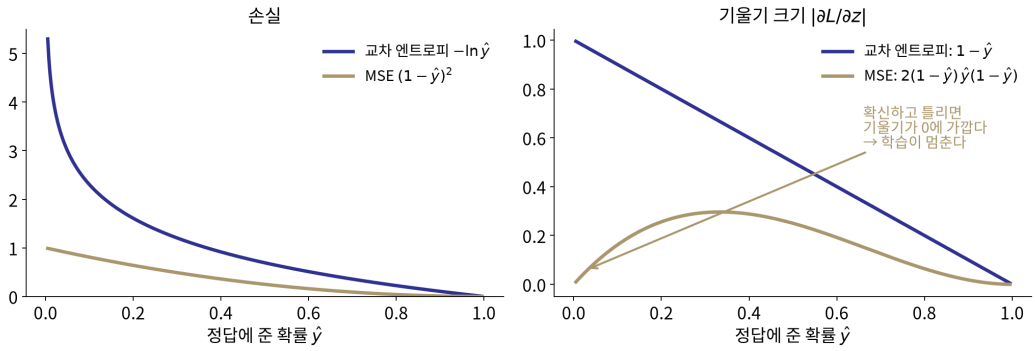
정답 $y = 1$, $\hat{y} = \sigma(z)$, $\dfrac{\partial \hat{y}}{\partial z} = \hat{y}(1 - \hat{y})$ (시그모이드의 미분)

교차 엔트로피: $\dfrac{\partial L}{\partial z} = -\dfrac{1}{\hat{y}} \cdot \hat{y}(1 - \hat{y}) = \mathbf{-(1 - \hat{y})}$ 약분

MSE: $\dfrac{\partial L}{\partial z} = -2(1 - \hat{y}) \cdot \hat{y}(1 - \hat{y})$ 그대로

확신하고 틀려서 $\hat{y} \approx 0$ 이면, MSE의 기울기는 $\hat{y}$ 가 곱해져 0에 가깝다

그림으로: 손실과 기울기



오른쪽: 교차 엔트로피는 틀릴수록 기울기가 크고, MSE는 확신하고 틀린 왼쪽 끝에서 기울기가 사라진다 (p.20)

기울기: 선형회귀와 똑같은 모양

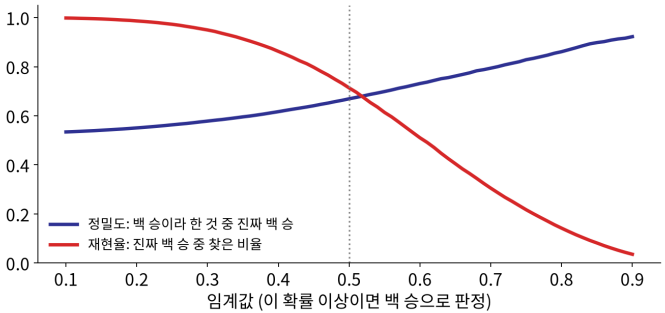
$$\frac{\partial J}{\partial w_j} = \frac{1}{m} \sum_{i=1}^{m} \left(\hat{y}^{(i)} - y^{(i)} \right) x_j^{(i)}$$

선형회귀: $\hat{y} = z$ 로지스틱회귀: $\hat{y} = \sigma(z)$

"오차 $\times$ 입력의 평균"이라는 모양은 같다 $\rightarrow$ 경사하강법 코드도 한 줄만 다르다

시그모이드의 미분 $\hat{y}(1-\hat{y})$ 이 교차 엔트로피의 $1/\hat{y}, 1/(1-\hat{y})$ 과 약분되어 생긴 결과

0.5 만이 답은 아니다: 임계값



임계값을 올리면 **정밀도** ↑ **재현율** ↓ 무엇을 놓치면 더 곤란한지로 정한다

0.5 에서: 백 승이라 한 판의 67% 가 진짜 백 승, 진짜 백 승 61,926판 중 71% 를 찾았다

문제풀이

1. $\sigma(0)$ 은? $\sigma(z) = 0.9$ 이면 z 는? ($\ln 9 \approx 2.2$)
2. 모델 $\hat{y} = \sigma(-6 + 1.5\,x)$. (a) 결정 경계 x 는? (b) $x = 4$ 일 때 $\hat{y}$ 는?
3. $w_1 = 0.7$ 이면 x 가 1 늘 때 오즈는 몇 배? ($e^{0.7} \approx 2.0$)
4. 정답 $y = 1$, 예측 $\hat{y} = 0.8$, 입력 $x = 3$. 이 데이터 하나의 $\partial J / \partial w_1$ 은? (p.22)

실습

1. 선형회귀 코드에서 한 줄 바꿔 로지스틱회귀 구현 (“200점 높으면 74%” 재현, Elo 와 비교)
2. 백 레이팅 · 흑 레이팅을 따로 넣고 100점당 오즈 배수 읽기
3. 임계값을 바꿔 정밀도 · 재현율 보기, PR 곡선과 PR-AUC

lichess 체스 117,003판 (2013년 1월, CC0)

▶ Colab에서 실습 노트북 열기

정리

모델 $\hat{y} = \sigma(w_0 + w_1 x)$ = 1일 확률

결정 경계 $z = 0$ (특징이 여럿이어도 곧은 경계)

해석 x 가 1 늘면 오즈가 e^{w_1} 배

학습 교차 엔트로피 + 경사하강법 (기울기는 선형회귀와 같은 모양)

판정 임계값은 정밀도 · 재현율을 보고 정한다

체스 12만 판 백이 200점 높으면 74%, 100점마다 오즈 1.6배, Elo 도 로지스틱