교차 엔트로피 (Cross-Entropy)

확신하고 틀리면 크게 벌 받는다

Machine Learning and Deep Learning

KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

오늘의 질문

정답은 고양이인데, AI는 '강아지 99%'

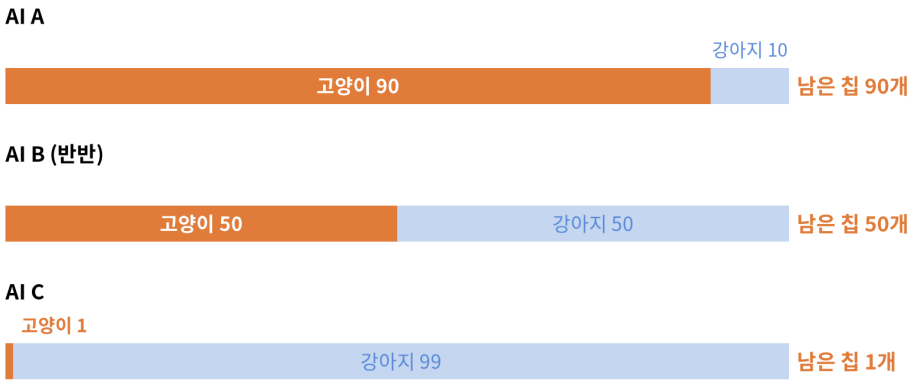
고양이 1



벌점은?

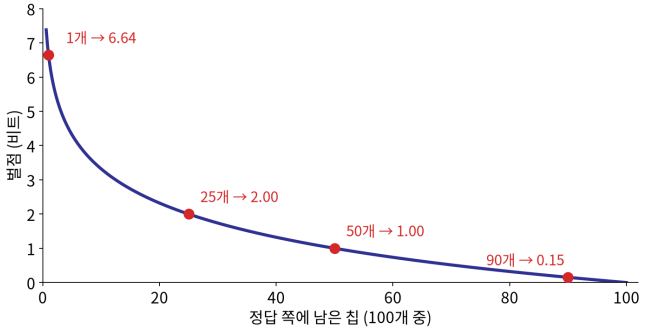
고양이 사진을 보고 “강아지 99%”라고 확신한 AI. 벌점을 몇 점 줘야 할까?

칩 100개를 나눠 걸기



AI는 칩 100개를 답마다 나눠 건다. **정답 쪽에 건 칩만 남는다**

남은 칩이 적을수록 큰 벌점



$$\text{벌점} = -\log_2 \frac{\text{남은 칩}}{100}$$

100개 → 0　　50개 → 1　　25개 → 2

칩이 절반이 될 때마다 벌점 +1

90개 → **0.15**　　1개 → **6.64**

밑은 아무거나: $\log_2$ → **비트**, $\ln$ → **냇**

ML 코드는 보통 ln. 값만 상수배 (p.8)

정답에 0개를 걸었다면

강아지에 전부 걸었다

고양이 0



벌점 ∞

모르겠으니 반반



벌점 1.00

정답에 하나도 안 걸면 **파산: 벌점** ∞. 모를 땐 반반이 낫다 (틀려도 1점)

칩의 비율 = 확률

$$L = -\log q_{\text{true}}$$

$$\Longrightarrow \quad H(p,q) = -\sum_{k=1}^{K} \underbrace{p_k}_{\text{true}} \log \underbrace{q_k}_{\text{predicted}}$$

q	AI가 각 답에 건 칩의 비율	예: 고양이 0.01, 강아지 0.99
p	정답 (정답 칸만 1)	고양이 1, 강아지 0
$H(p,q)$	교차 엔트로피	$-(1 \cdot \log_2 0.01 + 0 \cdot \log_2 0.99) = 6.64$

정답 칸만 1이라 합에서 정답 항 하나만 남는다 $\rightarrow$ 왼쪽 식

p와 q를 바꿔 넣으면? $-\sum q \log p$

$$H(q,p) = -\sum_{k=1}^{K} \underbrace{q_k}_{\text{predicted}} \log \underbrace{p_k}_{\text{true}}$$

정답이 고양이 $\rightarrow$ $p = (1,0)$ 정답이 아닌 칸은 $\log 0 = -\infty$

잘 맞힌 AI	$q = (0.9, 0.1)$	$-(0.9 \cdot \log_2 1 + 0.1 \cdot \log_2 0) = \infty$
확신하고 틀린 AI	$q = (0.01, 0.99)$	$-(0.01 \cdot \log_2 1 + 0.99 \cdot \log_2 0) = \infty$

오답에 칩을 하나라도 걸면 무조건 ∞: 잘 맞힌 AI와 틀린 AI를 구별 못 해 학습이 안 된다

log는 AI가 건 칩 q에 씌운다 순서가 중요: $H(p,q) \neq H(q,p)$, 코드도 `log_loss(y_true, y_pred)`

정답이 $(1, 0)$ 이 아니라면?

예: 사람 10명에게 물었더니 7명은 고양이, 3명은 강아지 $\rightarrow$ $p = (0.7,\ 0.3)$

$H(p, q) = -(0.7 \log_2 q_{\text{cat}} + 0.3 \log_2 q_{\text{dog}})$ 이제 항이 하나만 남지 않는다

AI의 예측 q	계산	벌점
$(0.99,\ 0.01)$	$-(0.7 \log_2 0.99 + 0.3 \log_2 0.01)$	2.00
$(0.9,\ 0.1)$	$-(0.7 \log_2 0.9 + 0.3 \log_2 0.1)$	1.10
$(0.5,\ 0.5)$	$-(0.7 \log_2 0.5 + 0.3 \log_2 0.5)$	1.00
$(0.7,\ 0.3)$	$-(0.7 \log_2 0.7 + 0.3 \log_2 0.3)$	**0.88** (최소)

정답 비율 그대로 $q = p$ 로 걸 때 벌점이 가장 작다 최솟값은 0이 아니라 $H(p)$

쓰는 곳: 사람마다 답이 갈리는 데이터, 라벨 스무딩 $(0.9, 0.1)$, 큰 모델의 확률을 따라 배우는 증류

로지스틱회귀의 손실이 바로 이것

$$L = -\big[\, y \ln \hat{y} + (1-y) \ln(1-\hat{y}) \,\big]$$

y: 정답 (1 또는 0)　　$\hat{y} = \sigma(z)$: 1일 확률 (시그모이드 출력)

$y = 1$ 이면　$L = -\ln \hat{y}$　(1에 건 칩)

$y = 0$ 이면　$L = -\ln(1-\hat{y})$　(0에 건 칩)

실제 코드는 $\log_2$ 대신 자연로그 ln　6.64 비트 $= 6.64 \times \ln 2 \approx 4.60$ (값만 상수배)

왜 오차 제곱(MSE)이 아닐까: 벌점의 크기

	MSE $(1-\hat{y})^2$	**교차 엔트로피** $-\ln \hat{y}$
정답에 0.9	0.01	0.11
반반 0.5	0.25	0.69
확신하고 틀림 0.01	**0.98**	**4.60**
정답에 0	1 (최대)	∞

MSE는 아무리 크게 틀려도 벌점이 1을 넘지 못한다

더 큰 이유: 기울기

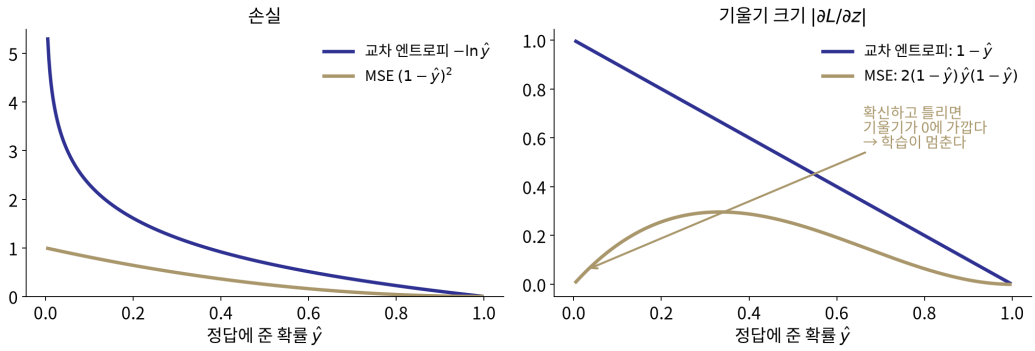
정답 $y = 1$, $\hat{y} = \sigma(z)$, $\dfrac{\partial \hat{y}}{\partial z} = \hat{y}(1 - \hat{y})$ (시그모이드의 미분)

교차 엔트로피: $\dfrac{\partial L}{\partial z} = -\dfrac{1}{\hat{y}} \cdot \hat{y}(1 - \hat{y}) = \mathbf{-(1 - \hat{y})}$ 약분

MSE: $\dfrac{\partial L}{\partial z} = -2(1 - \hat{y}) \cdot \hat{y}(1 - \hat{y})$ 그대로

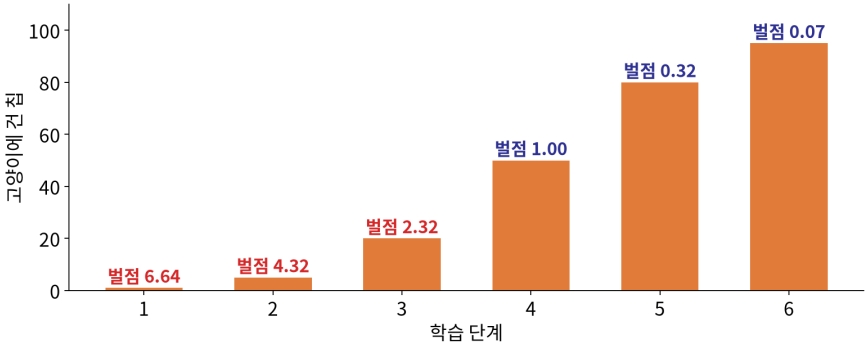
확신하고 틀려서 $\hat{y} \approx 0$ 이면, MSE의 기울기는 $\hat{y}$ 가 곱해져 0에 가깝다

그림으로: 손실과 기울기



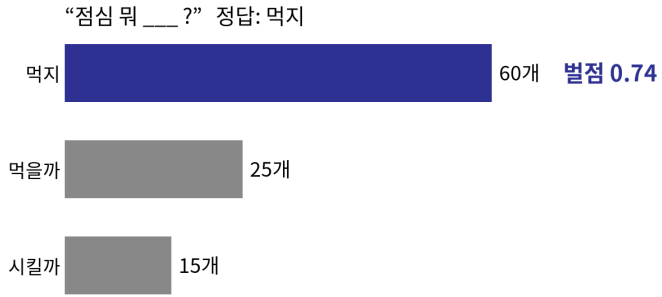
오른쪽: 교차 엔트로피는 틀릴수록 기울기가 크고, MSE는 확신하고 틀린 왼쪽 끝에서 기울기가 사라진다 (p.10)

학습 = 정답 쪽에 칩을 더 거는 과정



고양이 칩 1개 → 95개 벌점 **6.64** → **0.07**

챗GPT도 같은 벌점을 받는다



다음 단어 후보들에 칩을 나눠 걸고, 정답 단어에 건 칩으로 벌점을 받는다

언어 모델의 사전학습 = 다음 단어(토큰)의 교차 엔트로피를 줄이는 것 (15주차)

문제풀이

1. 칩 100개 중 정답에 25개를 걸었다. 벌점(비트)은?
2. 고양이 · 강아지 · 토끼에 칩을 (70, 20, 10)개 걸었다. 정답이 강아지일 때 벌점(비트)은? ($\log_2 5 \approx 2.32$)
3. 로지스틱회귀에서 $y = 0, \hat{y} = 0.9$. 교차 엔트로피(ln)는? ($\ln 10 \approx 2.30$)
4. 정답에 100개를 다 걸면 벌점은 0이다. 그러면 항상 한쪽에 다 거는 게 좋을까?

실습

1. 칩 비유를 코드로: 벌점 손계산 → scikit-learn `log_loss` 와 맞춰 보기
2. 유방암 진단 데이터: 같은 로지스틱회귀를 교차 엔트로피 vs MSE 로 학습해 비교
3. 셰익스피어 글: 다음 글자에 칩 나눠 걸기 (고르게 vs 세어서) 벌점 비교

Breast Cancer Wisconsin (569명, scikit-learn 내장) · Tiny Shakespeare (약 100만 글자)

▶ Colab에서 실습 노트북 열기

정리

교차 엔트로피 정답에 건 확률 q 에 대해 $-\log q$

확신하고 틀리면 벌점이 끝없이 커진다 (0개 $\to \infty$)

시그모이드와 만나면 기울기가 $\hat{y} - y$ 로 약분 $\to$ 틀릴수록 크게 고친다

분류 모델도, 언어 모델도 같은 벌점으로 학습한다