과대적합과 과소적합 (Overfitting & Underfitting)

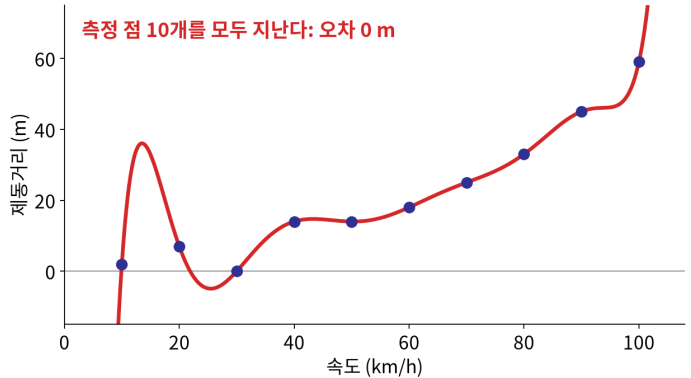
완벽한 곡선이 새 데이터를 틀리는 이유, 그리고 교차 검증

Machine Learning and Deep Learning

KSA 2027-Spring

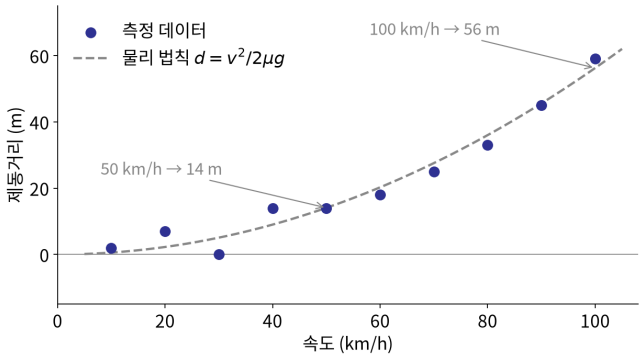
Sumin Han (suminhan@ksa.hs.kr)

오늘의 질문



측정한 점을 모두 지나는 곡선. **이 모델로 처음 보는 속도의 제동거리도 맞힐 수 있을까?**

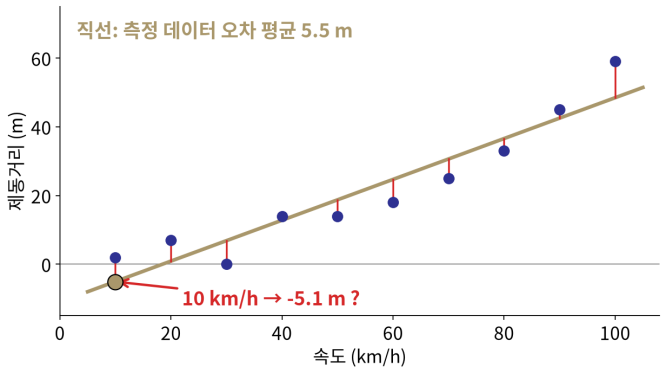
제동거리: 속도가 2배면 4배



제동거리 = 브레이크를 밟고 멈출 때까지 가는 거리 $d = \dfrac{v^2}{2\mu g}$

v: 속도 $\mu = 0.7$: 마른 아스팔트의 마찰계수 (가정) g: 중력가속도 점: 법칙 + 측정 오차 (예시)

직선으로 맞추면: 과소적합



10 km/h 에서 실제 2 m 를 -5.1 **m** 로 예측 $\rightarrow$ 제동거리가 음수? **너무 단순하다**

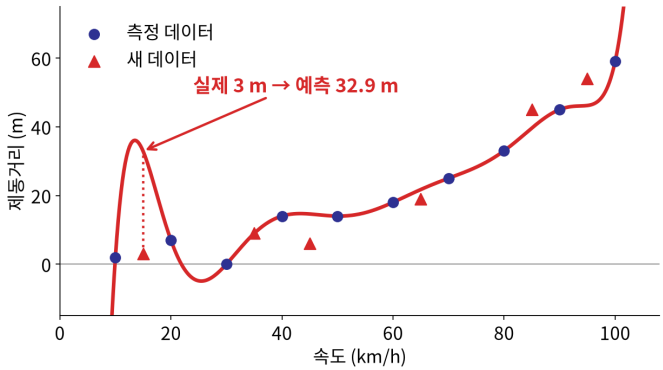
오차를 숫자 하나로: 평균 절대 오차

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^{m} \left| h(x^{(i)}) - y^{(i)} \right|$$

10 km/h: $|-5.1 - 2| = 7.1$ m 점 10개의 평균 $\rightarrow$ **5.5 m**

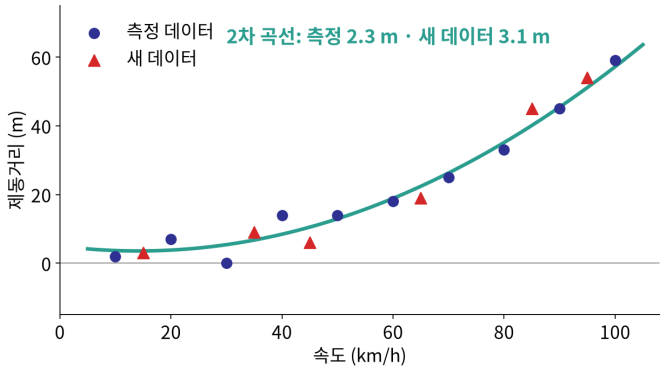
m: 데이터 수 절댓값: 위로 틀리든 아래로 틀리든 같은 거리 단위가 미터 그대로라 읽기 쉽다

구불구불 곡선을 새 데이터에 대 보면



측정 데이터 오차 **0 m** 새 데이터 6개 오차 **9.1 m** 15 km/h 에서 3 m 를 32.9 m 로

2차 곡선: 물리 법칙과 같은 모양



$$h(x) = w_0 + w_1 x + w_2 x^2$$

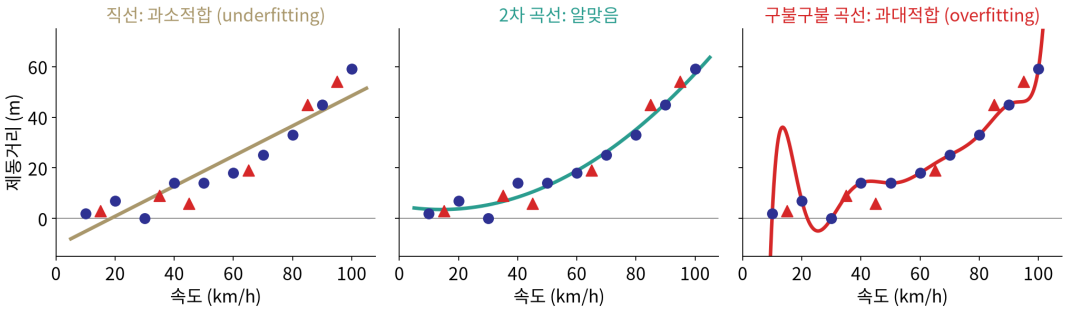
측정 **2.3 m** 새 데이터 **3.1 m**

세 모델의 성적표

	직선	2차 곡선	구불구불 곡선 (9차)
측정 데이터 오차	5.5 m	2.3 m	**0 m**
새 데이터 오차	6.4 m	**3.1 m**	**9.1 m**

측정 데이터에서 1등 $\neq$ 새 데이터에서 1등

너무 단순하거나, 너무 외우거나



과소적합: 가진 데이터도 못 따라간다

과대적합: 가진 데이터를 외워서 새 데이터를 틀린다

9차 곡선은 왜 점을 외울 수 있나

$$h(x) = \underbrace{w_0 + w_1 x + w_2 x^2 + \cdots + w_9 x^9}_{\text{10 weights}}$$

숫자 10개를 마음대로 고를 수 있다 = 점 10개를 **정확히** 지나게 할 수 있다

직접 만들기: 점 x_1 에서만 y_1, 나머지 9개 점에서는 0 $\rightarrow$ $y_1 \dfrac{(x-x_2)(x-x_3)\cdots(x-x_{10})}{(x_1-x_2)(x_1-x_3)\cdots(x_1-x_{10})}$

괄호가 **9개** $\rightarrow$ 9차. 점 10개 몫을 이렇게 하나씩 만들어 더하면 끝

잡음까지 그대로 따라가느라 점 사이에서 출렁인다 데이터가 많아지면 외우기 어려워진다

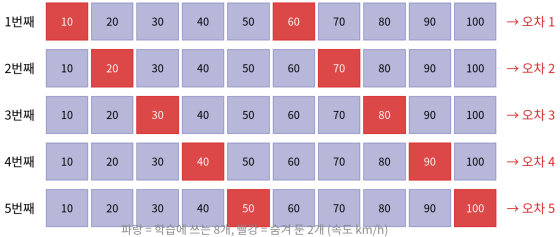
문제: 새 데이터는 미리 없다

모델을 고를 때는 아직 **새 데이터**가 없다

그러면 **가진 데이터 일부를 숨겨 두고**, 숨긴 데이터로 시험한다

숨긴 데이터 = 검증 데이터 (validation) 학습에는 절대 쓰지 않는다

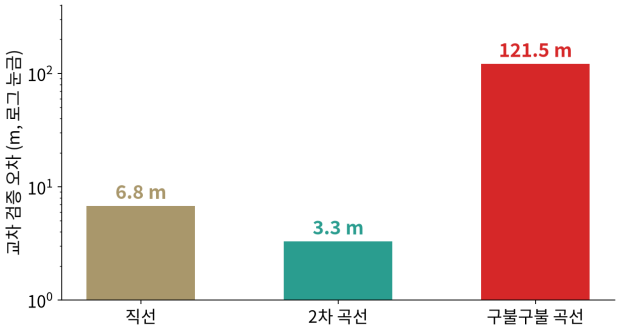
5겹 교차 검증: 돌아가며 한 조각씩 숨기기



$$\text{CV} = \frac{1}{5}\sum_{k=1}^{5} \text{MAE}_k$$

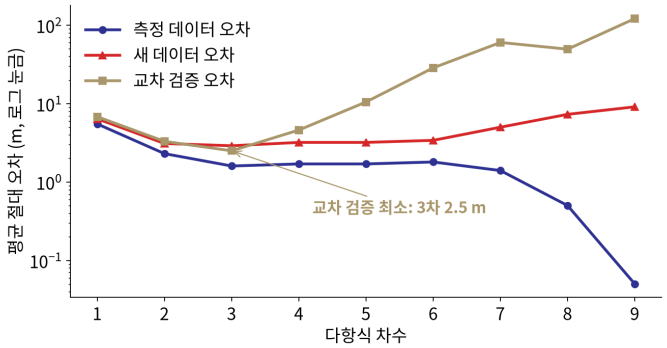
점 10개 → 2개씩 5조각. 한 조각은 숨기고 8개로 학습 → 숨긴 2개의 오차. 다섯 번 반복해서 평균 (k-fold cross validation)

교차 검증으로 고르기



직선 6.8 m 2차 곡선 **3.3 m** 구불구불 곡선 **121.5 m** → **2차 곡선**

차수를 1부터 9까지 전부 재 보면



측정 오차는 계속 줄지만, 교차 검증 오차는 **U자**: 2차 3.3 m · 3차 2.5 m 에서 바닥

둘이 비슷하면 단순한 쪽을 고른다 (9차의 측정 오차 0 m 는 로그 눈금이라 바닥에 붙여 그렸다)

문제풀이

1. 점 4개 $(1,2),(2,3),(3,5),(4,6)$ 에 모델 $h = 1.4x + 0.5$. (a) 네 오차 $|h - y|$ 는? (b) MAE 는?
2. 어떤 모델의 측정 데이터 오차 1 m, 교차 검증 오차 40 m. 다른 모델은 12 m, 13 m. 각각 무엇인가?
3. 점 20개로 5겹 교차 검증을 한다. 한 번 학습할 때 몇 개로 학습하고 몇 개로 검증하나? 모델은 모두 몇 번 학습하나?
4. 점 10개에 9차 다항식이 항상 모든 점을 지날 수 있는 이유는?

실습

1. 슬라이드 데이터: 직선 · 2차 · 9차를 맞추고 MAE 재기 → 성적표 재현 (p.7)
2. 5겹 교차 검증 직접 구현 → 6.8 / 3.3 / 121.5 m 재현
3. 실제 자동차 50대의 속도와 제동거리: 교차 검증으로 차수 고르기

cars (Ezekiel, 1930; R 기본 데이터)

▶ Colab에서 실습 노트북 열기

정리

과소적합 너무 단순해서 가진 데이터도 못 따라간다 (두 오차 모두 큼)

과대적합 가진 데이터를 외워서 새 데이터를 틀린다 (측정 오차만 작음)

학습에 쓴 데이터의 오차로는 모델을 고를 수 없다

교차 검증 돌아가며 숨겨 두고 맞혀 본 오차의 평균으로 고른다