GBDT 와 SHAP

앞 나무의 실수를 고쳐 가는 숲, 그리고 “왜 그렇게 답했나”

Machine Learning and Deep Learning

KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

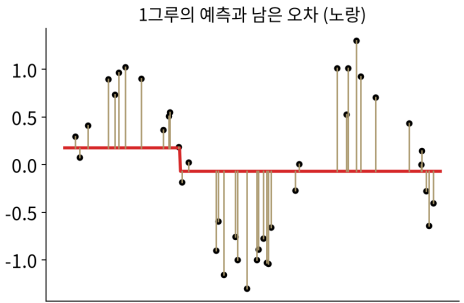
오늘의 질문

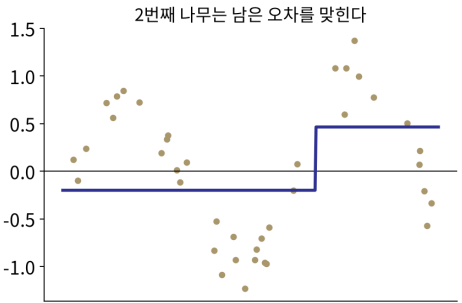
타이타닉 승객 두 명. 둘 다 **26살**.

AI 가 본 생존 확률: **96%** vs **13%**

무엇이 둘을 갈랐을까? AI 의 답을 **이유별로** 나눌 수 있을까?

부스팅: 앞 나무가 틀린 만큼을 다음 나무가 고친다

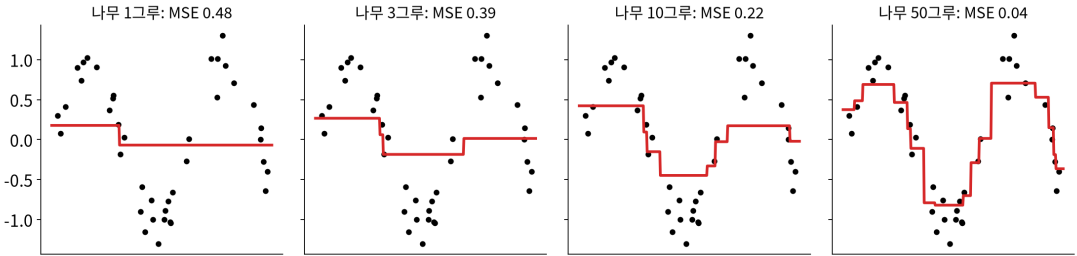




랜덤 포레스트: **동시에** 키워 투표

부스팅: **차례로** 키워 **더한다**

작은 나무를 쌓아 가면



질문 하나짜리 나무도 50그루 쌓으면 학습 MSE 0.48 → 0.39 → 0.22 → **0.04**

식으로: 그레이디언트 부스팅

$$F_m(x) = F_{m-1}(x) + \eta\, h_m(x)$$

F_{m-1}	지금까지 쌓은 나무들의 예측 합
h_m	새 나무: 지금의 **남은 오차** (손실의 기울기 반대 방향) 를 맞히도록 학습
η	학습률: 새 나무를 얼마나 믿을지 (보통 0.01 ∼ 0.3)

GBDT = Gradient Boosting Decision Tree 경사하강법을 **함수** 공간에서 하는 것

타이타닉 GBDT

데이터	승객 1,309명, 특징 5개: 등급 · 성별 · 나이 · 요금 · 가족 수
모델	깊이 3 나무 **200그루**, 학습률 0.05
학습 데이터 오답률	1그루 38.2% → 10그루 20.1% → 200그루 **13.9%**
5겹 교차 검증 정확도	**80.7%**

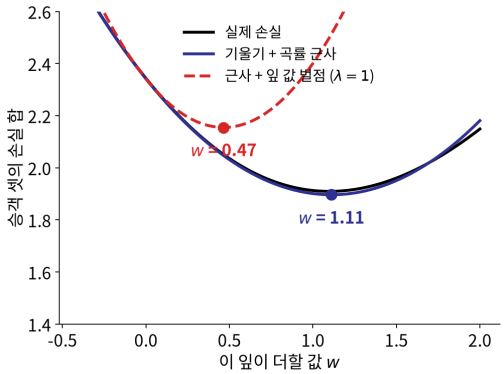
그런데 200그루의 합이라 **왜 그렇게 답했는지 보이지 않는다**

랜덤 포레스트 vs GBDT

	랜덤 포레스트	GBDT
나무 키우기	동시에, 독립적으로	**차례로**, 앞 나무의 실수를 보고
나무 크기	깊게 (끝까지)	얕게 (깊이 $3 \sim 8$)
줄이는 것	분산 (흔들림)	편향 (덜 배움)
나무를 늘리면	안정될 뿐	**과대적합될 수 있다** $\rightarrow$ 조기 종료
튜닝	거의 필요 없음	학습률 · 나무 수 · 깊이

실전에서는 XGBoost · LightGBM · CatBoost (범주형 열에 강함) 를 쓴다 $\rightarrow$ 다음 두 쪽

XGBoost: 기울기에 곡률까지 보고, 잎 값에 벌점을 준다



$$w = -\frac{G}{H + \lambda}$$

w	이 잎이 더할 값
$G = \sum g_i$	기울기 합, $g = p - y$
$H = \sum h_i$	곡률 합, $h = p(1-p)$
λ	잎 값 벌점: 크면 조심스럽게

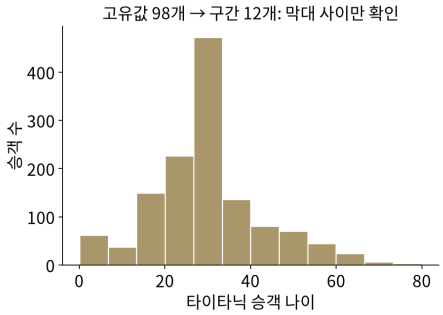
지금 확률 $p = 0.4$, 답 $y = 1, 0, 1$ 인 승객 셋

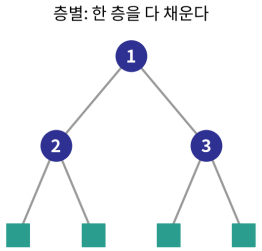
$G = -0.6 + 0.4 - 0.6 = -0.8$,

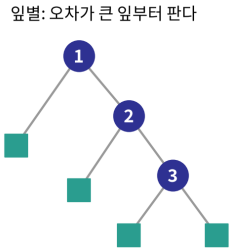
$H = 3 \times 0.24 = 0.72$

$\lambda = 0$: $w =$ **1.11** $\lambda = 1$: $w =$ **0.47**

LightGBM: 값을 구간으로 묶고, 오차가 큰 잎부터 키운다







항공편 번호 고유값 6,585개 → 구간 최대 **255**개만 확인

항공편 10만 건: sklearn 10.8초, XGBoost **0.2초**, LightGBM **0.4초**

정확도는 셋 다 약 65%

표 데이터에선 왜 아직도 나무가 이길까?

2015년 캐글 우승 해법 **29**개 중 **XGBoost 17**개 vs 딥러닝 11개

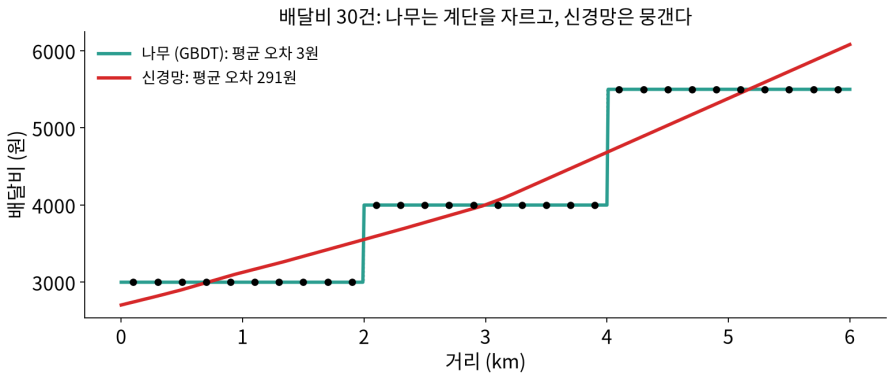
Chen & Guestrin, XGBoost (KDD 2016), 1장

표 데이터 **45**개, 1만 건 안팎이면 **나무 모델**이 앞선다

Grinsztajn, Oyallon & Varoquaux, Why do tree-based models still outperform deep learning on tabular data? (NeurIPS 2022)

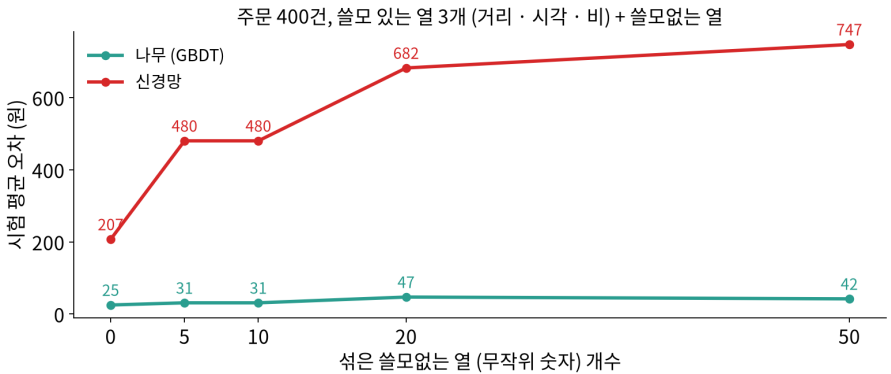
사진 · 글 · 소리에선 딩러닝이 이겼는데, **표**에선 왜? 이유 세 가지

이유 1: 표의 답은 계단 모양이 많다



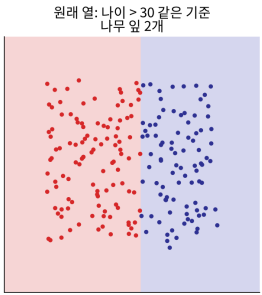
나무는 “2km 보다 먼가?” 로 **한 번에 자른다** 신경망은 **부드럽게 뭉갠다**

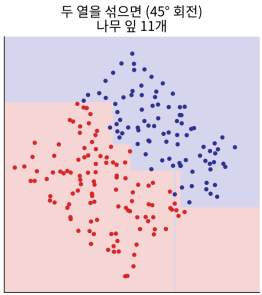
이유 2: 쓸모없는 열이 섞여 있다



나무는 쓸모없는 열을 **안 고르면 그만** 신경망은 모든 열을 **가중합으로 섞는다**

이유 3: 표의 열은 하나하나 뜻이 있다

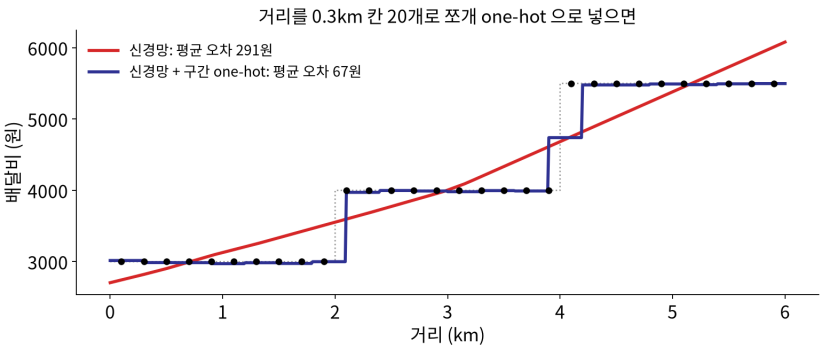




나무는 **열 하나를 골라 축을 따라** 자른다 열을 섞으면 계단을 여러 번 그려야 한다

논문: 열을 무작위로 섞으면(회전) 순위가 뒤집혀 신경망이 나무보다 앞선다
신경망은 처음부터 열을 섞으므로 돌리든 말든 똑같이 배운다

그러면 신경망에 숫자를 쪼개 넣으면?



거리를 칸으로 쪼개 넣으면 **291원** → **67원** 그래도 나무 **3원**에는 못 미친다

칸 경계는 우리가 **미리 정해 준다** 나무는 자를 곳을 **스스로 찾는다**

참고: 범주형 열(도시 · 요일)은 원래 one-hot 으로 넣는다

반대로, 신경망이 이기는 데이터

	표 데이터 (**나무**)	사진 · 교통 센서 (**신경망**)
열	나이 · 연봉 · 도시: 단위와 뜻이 다 다름	픽셀 · 센서 속도: 모두 같은 종류
쓸모없는 열	자주 섞여 있음	거의 없음, 이웃끼리 관계가 있음
답의 모양	계단 (“30살 넘으면”)	시간 · 공간을 따라 대체로 부드러움
순서	열 순서에 뜻이 없음	옆 픽셀, 옆 센서가 중요

데이터의 성질에 맞는 모델을 고른다 내 논문의 리뷰어도 **“왜 이 모델?”** 을 묻는다

SHAP: 정보를 하나씩 알려 주며 확률이 오른 만큼을 잰다

1등석 여성 승객 (26살). 정보를 하나씩 알려 준다:

아는 정보	생존 확률	오른 만큼
아무것도 모름 (승객 평균)	38.2%	
+ 성별 (여성)	68.8%	**+30.6**
+ 등급 (1등석)	87.8%	**+19.0**
+ 나머지 (나이 · 요금 · 가족)	96.0%	+8.2

그런데 **순서**를 바꾸면 오른 만큼이 달라진다 (등급부터 알려 주면 등급 +13.1)

해결: 모든 순서의 평균 (섀플리 값)

$$\phi_j = \frac{1}{\text{순서의 수}} \sum_{\text{모든 순서}} (j \text{를 알려 줬을 때 오른 만큼})$$

정보 3가지 $\rightarrow$ 순서 $3! = 6$ 가지 1등석 여성: **성별** $+34.0$**, 등급** $+22.6$**, 나머지** $+1.3$

평균 $38.2 + 34.0 + 22.6 + 1.3 =$ **96.0** 몫의 합 = **정확히** 모델의 답

게임 이론의 공정한 기여 나누기 (Shapley, 1953) SHAP = SHapley Additive exPlanations (Lundberg & Lee, 2017)

“모르는 정보”는 어떻게 처리하나

모델은 성별을 꼭 넣어야 답한다. 성별을 “모른다”는 건?

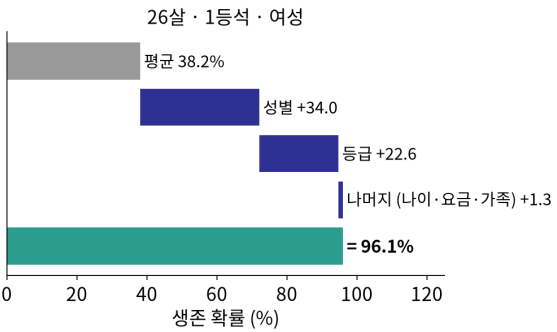
성별 자리에 **여러 승객의 실제 성별**을 넣어 보고 평균

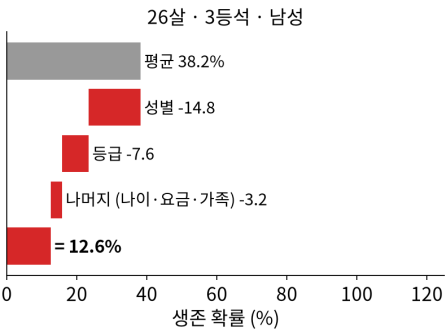
나무로 보면: 모르는 질문에서는 **양쪽 길을 다 가서** 비율대로 섞는다

1등석 여성: 다 알면 93% 성별을 모르면 남 64 · 여 36 비율로 섞어 **44%**

(깊이 2 짜리 설명용 나무 하나로 계산한 예)

두 승객의 몫

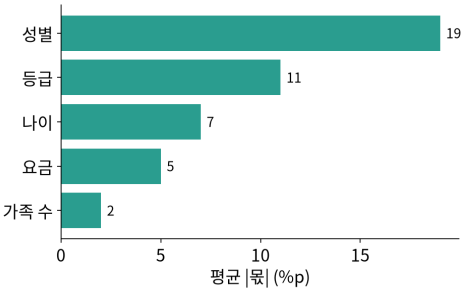


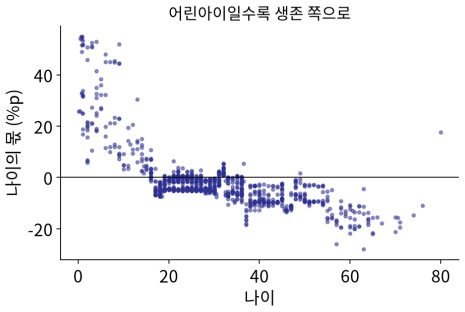


같은 26살, **성별** ($+34.0$ vs -14.8) 과 **등급** ($+22.6$ vs -7.6) 이 갈랐다

그날 밤 여성과 아이를 먼저 구명보트에 태웠다고 알려져 있다

모든 승객으로 모아 보면





평균 |몫| (%p): 성별 **19** 등급 11 나이 7 요금 5 가족 2

SHAP 을 읽을 때 주의할 점

모델 설명이다	모델이 무엇을 보고 답했는지일 뿐, 원인을 증명하지 않는다
얽힌 특징	등급과 요금처럼 함께 움직이면 몫이 나뉘어 보인다
계산량	정보 n 개면 순서 $n!$ 개 $\rightarrow$ 나무는 빠른 공식 (TreeSHAP)

SHAP 은 나무뿐 아니라 신경망 (이미지 · 텍스트) 까지 **어떤 모델에도** 쓸 수 있다

문제풀이

1. 첫 나무가 모든 승객에게 0.4 를 예측했다. 실제 답이 1, 0, 1 인 세 승객의 남은 오차는? 학습률 0.5 인 두 번째 나무가 이 오차를 정확히 맞히면 새 예측은?
2. 정보 A, B 두 개. 아무것도 모를 때 50, A 만 알 때 70, B 만 알 때 60, 둘 다 알 때 90. A 와 B 의 섀플리 값은? 합은?
3. GBDT 의 학습률을 0.5 에서 0.05 로 줄였다. 나무 수는 어떻게 해야 하나?
4. 주문 표에 “주문 번호 열이 섞여 있다. 나무와 신경망 중 어느 쪽이 더 흔들릴까? 왜? (p.9)

실습

1. 부스팅 직접 구현: 깊이 1 나무로 남은 오차를 차례로 맞히기 → MSE 0.48 → 0.04
2. 타이타닉 GBDT: 학습률 · 나무 수 바꿔 보기, 조기 종료
3. SHAP: 두 승객의 몫 직접 계산 (6가지 순서) + `shap` 라이브러리로 확인
4. sklearn · XGBoost · LightGBM 비교: 정확도와 학습 시간 (타이타닉 · 항공편 10만 건)

Titanic (OpenML; Vanderbilt titanic3) · Airlines (OpenML 1169)

▶ Colab에서 실습 노트북 열기

정리

GBDT 작은 나무를 차례로, 앞의 **남은 오차**를 맞히며 더한다 ($F \leftarrow F + \eta h$)

타이타닉 200그루 · 교차 검증 80.7% 나무가 많으면 과대적합 $\rightarrow$ 조기 종료

XGBoost: 곡률 + 잎 값 벌점 **LightGBM**: 구간 + 잎별 성장

SHAP 정보를 알려 줄 때 오른 만큼을 **모든 순서로 평균** (섀플리 값)

표 데이터는 **나무**: 계단 · 쓸모없는 열 · 열마다 뜻 신경망은 쪼개 넣으면 나아진다

몫의 합 = 모델의 답 26살 두 승객을 가른 것: 성별 · 등급