분포 함수 (Distribution Functions)

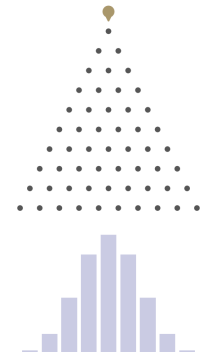
가우시안 · 스튜던트 t · 푸아송 분포, 그리고 베이즈 분류까지

Machine Learning and Deep Learning

KSA 2027-Spring

Sumin Han (suminhan@ksa.hs.kr)

오늘의 질문

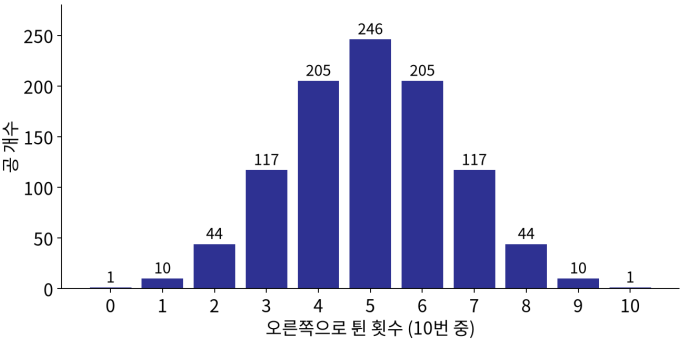


못이 10줄 박힌 판

공은 못을 만날 때마다
왼쪽 · 오른쪽으로 **반반** 튄다

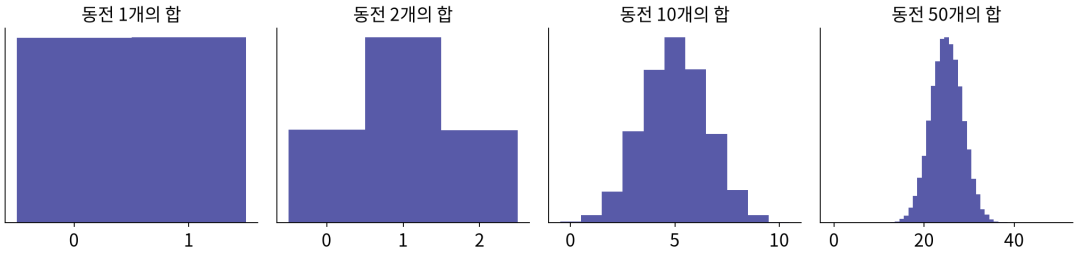
공 1000개를 떨어뜨리면
어디에 가장 많이 쌓일까?

가운데 246개, 양 끝 1개



오른쪽으로 k번 튀는 길의 수 $= \binom{10}{k}$ 공 개수 $\approx 1000 \times \frac{\binom{10}{k}}{2^{10}}$

작은 효과가 많이 더해지면 종 모양



동전(0 또는 1)을 여러 개 더할수록 **종 모양**에 가까워진다

키 (유전자 수백 개 + 영양 + …), 측정 오차, 시험 점수 $\rightarrow$ 작은 효과 여럿의 합이라 종 모양이 흔하다 (중심극한정리)

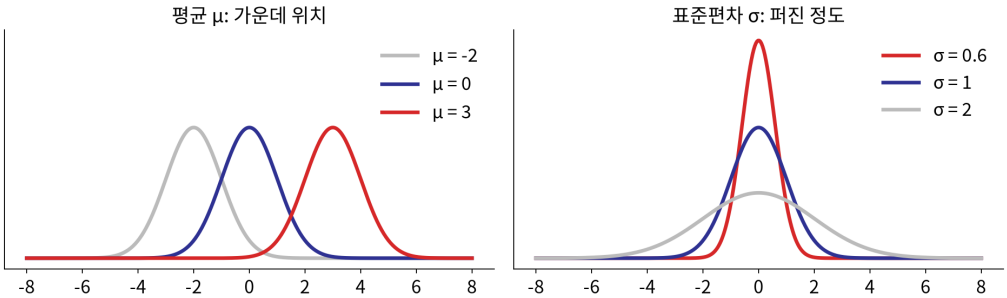
가우시안 분포: 숫자 두 개로 정해진다

$$p(x) = \frac{1}{\sqrt{2\pi}\,\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

μ	평균 (mean)	종의 가운데
σ	표준편차 (standard deviation)	종이 퍼진 정도 (σ^2: 분산)
$\frac{1}{\sqrt{2\pi}\sigma}$	높이 맞춤	전체 넓이가 1 이 되게

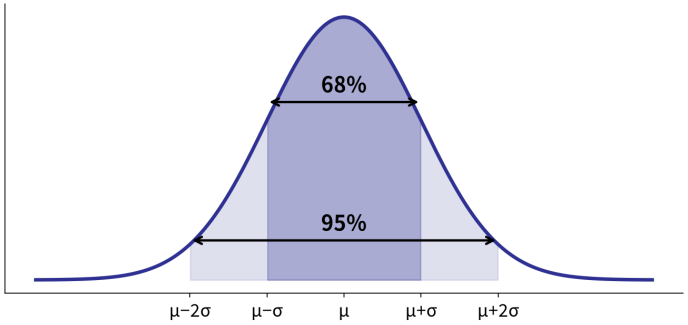
줄여서 $\mathcal{N}(\mu, \sigma^2)$ 로 쓴다

μ 는 위치, σ 는 폭



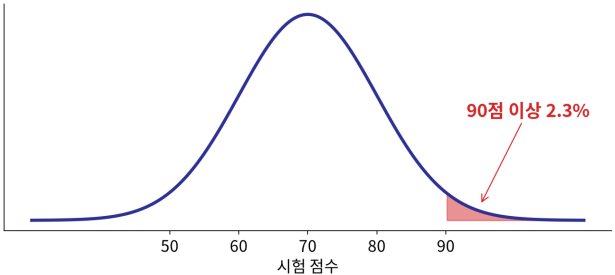
μ: 종이 **옆으로 이동** σ 를 키우면 **낮고 넓게** (넓이는 항상 1)

평균에서 σ 1개 안에 68%, 2개 안에 95%



어떤 μ, σ 든 같다 $\pm 3\sigma$ 안에는 99.7%

평균 70, 표준편차 10 인 시험에서 90점 이상은?



$$z = \frac{x - \mu}{\sigma} = \frac{90 - 70}{10} = 2$$

평균에서 σ 2개 위 $\rightarrow$ 95% 밖의 한쪽 절반 $\approx$ **2.3%**

데이터에서 μ, σ 구하기

키 5명: 168, 172, 174, 176, 180 cm

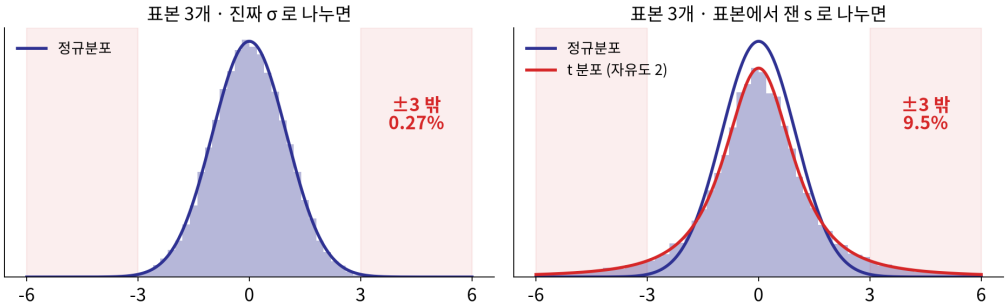
$$\hat{\mu} = \frac{1}{m}\sum_{i=1}^{m} x^{(i)} = \frac{870}{5} = 174$$

$$\hat{\sigma}^2 = \frac{1}{m}\sum_{i=1}^{m} \left(x^{(i)} - \hat{\mu}\right)^2 = \frac{36+4+0+4+36}{5} = 16$$

$\hat{\sigma} = 4$ cm $\quad\rightarrow\quad$ 이 데이터를 가장 잘 설명하는 종 $= \mathcal{N}(174,\ 4^2)$

데이터가 나올 확률(가능도)을 가장 크게 하는 값 (최대가능도 추정, MLE) $\quad\hat{\mu}$: 데이터로 추정한 값

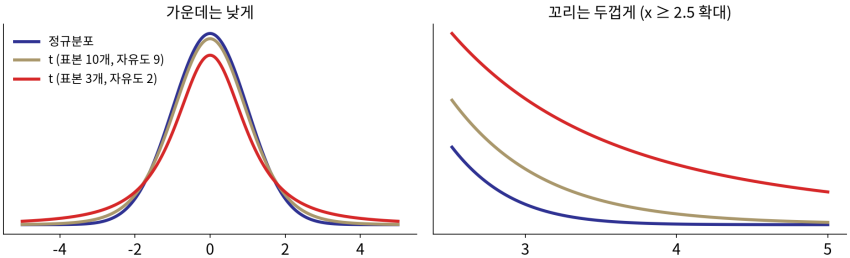
표본이 3개뿐이라면? 1908년 기네스 맥주 공장



평균 $\bar{x}$ 를 표준화할 때 진짜 σ 대신 **표본에서 잰** s 로 나누면 꼬리가 두꺼워진다

정규분포에서 3개 뽑기를 2만 번 s 가 우연히 작으면 값이 크게 튄다 고셋 (Gosset), 가명 ‘Student’

스튜던트 t 분포: 가운데는 낮고, 꼬리는 두껍다

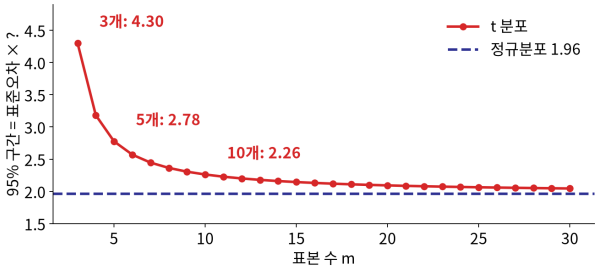


$$t = \frac{\bar{x} - \mu}{s/\sqrt{m}} \qquad s^2 = \frac{1}{m-1}\sum_{i=1}^{m}\left(x^{(i)} - \bar{x}\right)^2 \qquad \text{자유도} = m - 1$$

± 3 밖: 정규 **0.27%** t(자유도 2) **9.5%**

$m-1$: 평균을 데이터로 정해서 하나 줄어든 수

표본이 적으면 95% 구간을 넓게



키 5명 (p.8): $\bar{x} = 174$

$$s^2 = \frac{80}{5-1} = 20, \quad s = 4.47$$

표준오차 $\frac{s}{\sqrt{5}} = \frac{4.47}{2.24} = 2.0$

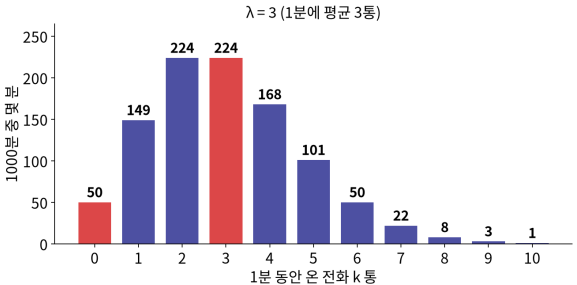
평균의 95% 구간

t (자유도 4): $174 \pm 2.78 \times 2.0 = 174 \pm \mathbf{5.6}$

정규: $174 \pm 1.96 \times 2.0 = 174 \pm 3.9$

표본이 늘면 t 분포 $\rightarrow$ 정규분포 (30개면 2.05)

푸아송 분포: 1분에 전화가 몇 통 올까?



고객센터에 1분에 평균 **3통**

$$P(k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

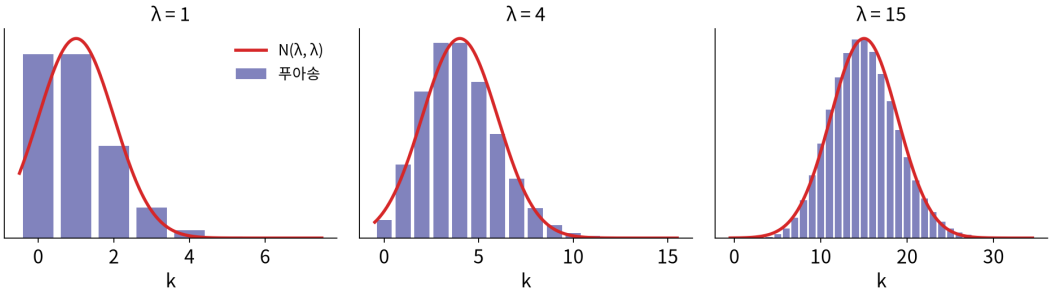
λ: 평균 횟수 (rate) k: 실제로 온 횟수

$P(0) = e^{-3} = 0.050$ → 1000분 중 **50분**은 0통

$P(3) = \frac{3^3 e^{-3}}{3!} = 0.224$ → **224분**

정해진 시간 · 공간에서 **드문 일이 몇 번** 일어나는지 (접속 수, 주문 수, 불량 개수)

λ 가 커지면 푸아송도 종 모양

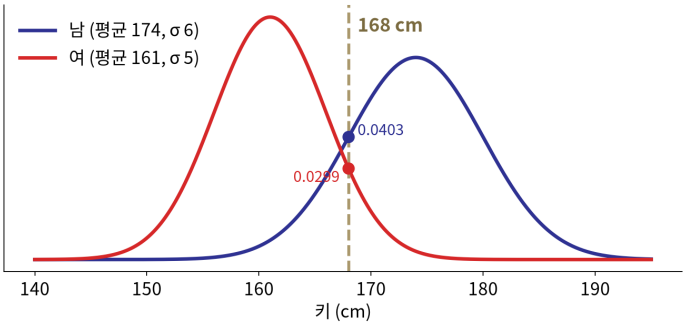


평균 $=$ 분산 $=\lambda$ 데이터에서 $\hat{\lambda}=$ 평균 횟수 (MLE)

λ 가 크면 $\approx \mathcal{N}(\lambda, \lambda)$

1분 $=60$초, 매초 $\frac{3}{60}$ 확률로 오는 전화 60개의 합 $\rightarrow$ 골턴 보드처럼 작은 동전의 합 (p.2)

종 두 개로 분류하기: 키 168 cm 는 남? 여?



각 그룹의 키를 가우시안으로: 남 $\mathcal{N}(174, 6^2)$ 여 $\mathcal{N}(161, 5^2)$ (예시)

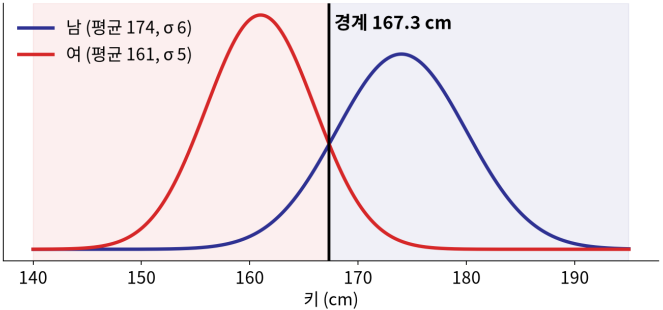
168 cm 에서 종의 높이: 남 0.0403 여 0.0299

베이즈 정리로 확률까지

$$\underbrace{P(\text{male} \mid 168)}_{\text{posterior}} = \frac{0.0403 \times 0.5}{\underbrace{0.0403 \times 0.5 + 0.0299 \times 0.5}_{\text{evidence}}} = 0.57$$

0.0403, 0.0299	가능도 likelihood	남 · 여라면 168 cm 가 나올 정도 (종의 높이)
0.5	사전확률 prior	키를 보기 전 남 · 여일 확률 (반반 교실)
0.57	사후확률 posterior	168 cm 를 본 뒤 남일 확률

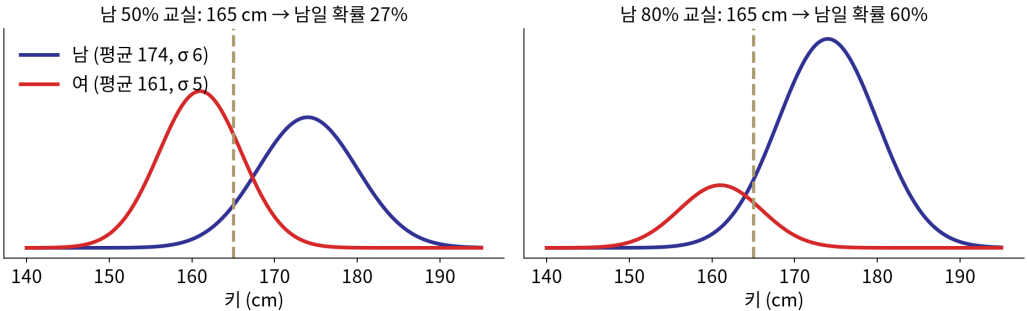
두 종이 만나는 곳이 경계



사전확률이 반반이면 두 종의 높이가 같은 **167.3 cm** 가 경계

σ 가 다르면 경계가 둘일 수도 있다 (아주 멀리 가면 넓은 종이 다시 이긴다)

교실이 바뀌면: 사전확률



같은 165 cm 라도 남 50% 교실 → 남일 확률 **27%** 남 80% 교실 → **60%**

문제풀이

1. 공 1000개, 못 10줄인 골턴 보드에서 오른쪽으로 정확히 2번 튀는 길은 몇 가지? 그 칸에 쌓이는 공은 약 몇 개?
2. 평균 70, 표준편차 10 인 시험. (a) 50 점 이하는 약 몇 %? (b) 60 점과 80 점 사이는?
3. 데이터 2, 4, 6, 8 의 $\hat{\mu}$ 와 $\hat{\sigma}$ 는?
4. 3번 데이터로 평균의 95% 구간을 t 분포로 (자유도 3 $\to$ 3.18). 정규 1.96 을 쓰면?
5. 1분에 평균 2통 오는 전화. 1분 동안 (a) 한 통도 안 올 확률은? (b) 정확히 2통 올 확률은? ($e^{-2} = 0.135$)
6. 남 · 여의 가능도가 0.02, 0.06 이고 남 75% 교실이다. 남일 사후확률은?

실습

1. 골턴 보드 시뮬레이션: 공 1000개 $\rightarrow$ 246 근처, 줄 수를 늘리며 종 모양 보기
2. 실제 데이터에 종 맞추기: 펭귄 3종의 날개 길이, $\hat{\mu} \cdot \hat{\sigma}$ 와 68% 규칙 확인
3. 가우시안으로 분류: 날개 길이로 펭귄 종 맞히기, 사전확률 넣고 빼기

Palmer Penguins (Gorman et al., 2014)

▶ Colab에서 실습 노트북 열기

정리

작은 효과가 많이 더해지면 **종 모양** = 가우시안 분포 (정규분포)

μ (위치) 와 σ (폭) 두 숫자로 정해진다 $\pm 1\sigma$ 68%, $\pm 2\sigma$ 95%

데이터에서: $\hat{\mu}$ = 평균, $\hat{\sigma}^2$ = 평균에서 떨어진 거리 제곱의 평균

표본이 적으면 **스튜던트 t 분포**: 꼬리가 두꺼워 95% 구간이 넓다 (자유도 $m-1$)

횟수를 세면 **푸아송 분포**: λ 하나로 정해진다 (평균 $=$ 분산 $=\lambda$)

그룹마다 종을 맞추고 **베이즈 정리** $\rightarrow$ 분류 (가능도 = 종의 높이)