word2vec 단어를 벡터로

함께 나오는 단어를 보면 그 단어를 안다

Machine Learning and Deep Learning

KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

오늘의 질문: 왕 − 남자 + 여자 = ?

$$\text{king} - \text{man} + \text{woman} = \textbf{?}$$

단어를 숫자 벡터로 바꾸면 **뜻으로 계산**할 수 있을까?

원-핫 (단어마다 칸 하나): 모든 단어 사이 거리가 같다

고양이 $\leftrightarrow$ 강아지 $=$ 고양이 $\leftrightarrow$ 자동차

비결: 함께 나오는 단어를 보면 그 단어를 안다

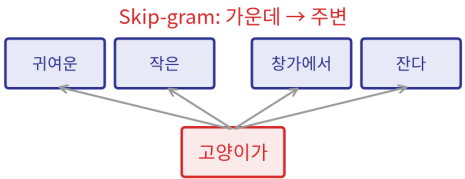


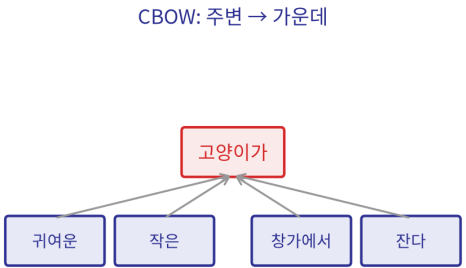
"You shall know a word by the company it keeps" (Firth, 1957)

고양이가 자리에 **강아지가** 와도 주변이 같다 $\rightarrow$ 두 단어의 벡터를 가깝게

사과 · 자동차는 이런 주변에 잘 안 나온다 $\rightarrow$ 멀게

두 가지 연습 문제: Skip-gram · CBOW





	Skip-gram	CBOW (Continuous Bag-of-Words)
문제	가운데 단어로 주변 단어 맞히기	주변 단어들 (평균) 로 가운데 맞히기
특징	느리지만 **드문 단어**에 강하다	빠르고 흔한 단어에 강하다

식으로: 함께 나오면 내적을 크게

단어마다 벡터 두 개: 가운데일 때 $\mathbf{v}_w$, 주변일 때 $\mathbf{u}_w$ (보통 100 ∼ 300칸)

$$\text{손실} = -\log\sigma(\mathbf{v}_c \cdot \mathbf{u}_o) - \sum_{k=1}^{K} \log\sigma(-\mathbf{v}_c \cdot \mathbf{u}_{n_k})$$

c, o	창 안에서 **실제로** 함께 나온 쌍 → 내적을 크게
$n_1, \ldots, n_K$	아무렇게나 뽑은 단어 K 개 (네거티브) → 내적을 작게

단어 7만 개 전부에 softmax 를 하는 대신 네거티브 5개만 흔한 단어 (the, of) 는 솎아 낸다

손으로 한 번

$\mathbf{v}_{\text{고양이}} = (1, 0, 1)$, 함께 나온 $\mathbf{u}_{\text{잔다}} = (1, 1, 0)$, 네거티브 $\mathbf{u}_{\text{자동차}} = (0, -1, 1)$

함께 나온 쌍	$\mathbf{v} \cdot \mathbf{u} = 1,\ \sigma(1) = 0.73$	$-\ln 0.73 = 0.31$
네거티브	$\mathbf{v} \cdot \mathbf{u} = 1,\ \sigma(-1) = 0.27$	$-\ln 0.27 = 1.31$
손실		**1.63**

기울기: $\mathbf{v}_{\text{고양이}}$ 를 잔다 쪽으로, 자동차 반대쪽으로 조금 옮긴다

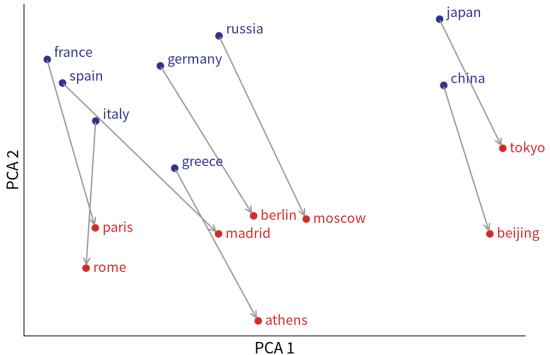
실험: 위키백과 1,700만 단어로 직접 학습

text8 (영어 위키백과 일부) 단어 7만 개 100칸 쌍 5,600만 개 CPU 약 2분

단어	가장 가까운 단어 (코사인 유사도)
cat	dog 0.71, cats, rabbits, albino, rat
computer	computers 0.81, computing, hardware
apple	**macintosh** 0.83, iigs, iic (과일이 아니라 회사)
korea	taiwan 0.79, thailand, seoul, china

뜻을 알려 준 적이 없다 주변 단어만 맞혔을 뿐

벡터로 비유 풀기: $b - a + c$와 가장 가까운 단어



나라 $\rightarrow$ 수도 화살표가 거의 나란하다

paris $-$ france $+$ germany	**berlin**
tokyo $-$ japan $+$ korea	**seoul**
he $-$ man $+$ woman	**she**
bigger $-$ big $+$ small	**smaller**
king $-$ man $+$ woman	**5위**: queen

유명한 king $\rightarrow$ queen 은 우리 작은 학습에선 5위 (1위 aquitaine)

Google 비유 문제로 채점

Mikolov 외 (2013) 의 비유 문제 **19,544**개 (예: Athens : Greece = Baghdad : ?)

	문제	3만 단어 안에 있는 것	1위로 맞힘
의미 (수도, 통화, 가족 · · ·)	8,869	4,103	**23.3%**
문법 (비교급, 과거형, 복수 · · ·)	10,675	8,165	**29.1%**

3만 개 단어 중 정확히 1위여야 정답 찍으면 0.003%

데이터를 늘리고 (Google News 약 1,000억 단어), 벡터를 키우면 (300칸) 훨씬 높아진다

한계와 다음 걸음

단어마다 벡터 **하나** “apple” 은 회사든 과일이든 같은 벡터

“bank” 는 은행 · 강둑이 섞인다

편향도 배운다 글에 있는 성별 · 직업 고정관념이 벡터에 (Bolukbasi 외 2016)

문장 전체 단어 벡터를 평균 내면 순서를 잃는다

→ 문맥에 따라 벡터가 달라지는 **BERT** (2018) 다음: 임베딩, BERT

문제풀이

1. 창이 앞뒤 2칸이면, 5단어 문장 “귀여운 작은 고양이가 창가에서 잔다” 에서 (가운데, 주변) 쌍은 몇 개?
2. 손 계산에서 $\mathbf{u}_{\text{잔다}}$ 가 $(2, 0, 2)$ 였다면 첫 항 $-\ln \sigma(\mathbf{v} \cdot \mathbf{u})$ 는? ($\sigma(4) \approx 0.982$)
3. 단어 7만 개, 100칸이면 학습하는 숫자는 모두 몇 개? (벡터 두 벌)
4. 원-핫 벡터로는 king $-$ man $+$ woman 계산이 왜 쓸모없을까?

실습

1. 창에서 (가운데, 주변) 쌍 만들기, 손 계산 손실 1.63
2. PyTorch 로 Skip-gram + 네거티브 샘플링 직접 학습 (text8 일부)
3. 가까운 단어 · 비유 풀기 (paris − france + germany)

text8 (Matt Mahoney, 영어 위키백과 일부)

▶ Colab에서 실습 노트북 열기

정리

word2vec: 함께 나오는 단어를 맞히는 연습으로 단어 벡터를 배운다 (2013)

Skip-gram (가운데 $\rightarrow$ 주변) · CBOW (주변 $\rightarrow$ 가운데) 네거티브 샘플링

1,700만 단어 · 2분: cat $\rightarrow$ dog, paris $-$ france $+$ germany $=$ berlin

비유 문제 의미 23% · 문법 29% 한계: 단어마다 벡터 하나 $\rightarrow$ BERT