어텐션 (Attention)

비슷한 만큼 섞어 온다

Sumin Han (suminhan@ksa.hs.kr)
Machine Learning and Deep Learning · 한국과학영재학교 (KSA)
2027학년도 1학기 · 12주차 (5/3–5/7)

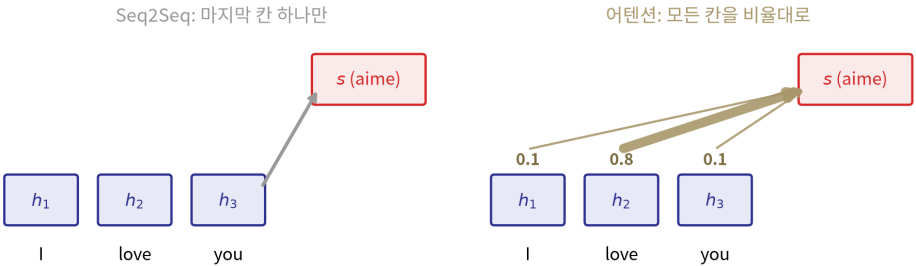
오늘의 질문: 왜 피곤할까?

나는 밤새 게임을 해서 **피곤하다**.

사람은 바로 안다: 피곤한 이유 = 밤새 게임을 한 것 ("해서", "나는" 은 덜 중요)

AI 는 단어마다 **어느 단어를 얼마나 볼지** 정해야 한다 $\rightarrow$ **어텐션**

시작: Seq2Seq 의 벡터 하나를 벗어나기



디코더가 단어를 쓸 때마다 인코더의 **모든 칸**을 다시 보고, 필요한 칸을 더 많이 섞는다

Bahdanau, Cho, Bengio (2014) 섞는 비율도 학습으로 정해진다

도서관 비유: Query · Key · Value

Query $\mathbf{q}$	내 질문	지금 단어가 찾는 것
Key $\mathbf{k}_j$	책마다 붙은 색인 카드	각 단어가 “나는 이런 단어” 라고 내건 것
Value $\mathbf{v}_j$	책 내용	실제로 가져올 정보

질문을 모든 색인 카드와 비교 $\rightarrow$ 비슷할수록 높은 비율 $\rightarrow$ 그 비율대로 내용을 섞어 온다

식으로

점수 $e_j = \dfrac{\mathbf{q} \cdot \mathbf{k}_j}{\sqrt{d}}$ (내적: 비슷할수록 크다)

비율 $\alpha_j = \mathrm{softmax}(e)_j = \dfrac{\exp(e_j)}{\sum_i \exp(e_i)}$ (합이 1)

결과 $\mathbf{z} = \sum_j \alpha_j \mathbf{v}_j$

여러 단어를 한꺼번에: $\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\dfrac{QK^\top}{\sqrt{d}}\right) V$

d: 벡터 칸 수 이 꼴 (scaled dot-product) 은 트랜스포머 논문 (Vaswani 외 2017)

손으로 한 번: “피곤하다” 가 보는 곳

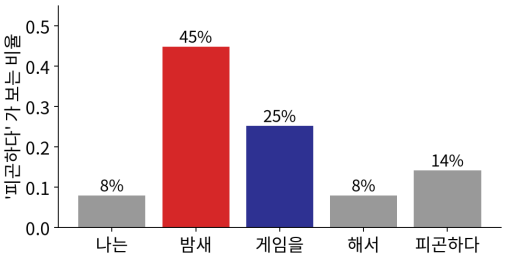
단어	벡터 (예시)
나는	(0, 0, 2)
밤새	(3, 0, 0)
게임을	(2, 2, 0)
해서	(0, 1, 0)
피곤하다	(1, 0, 0)

Q = K = V = 이 벡터 $\quad d = 3$

점수 $= \mathbf{q}_{\text{피곤하다}} \cdot \mathbf{k}/\sqrt{3}$

밤새 $3/1.73 = \mathbf{1.73}$ 게임을 $2/1.73 = 1.15$

자기 자신 $1/1.73 = 0.58$ 나는 · 해서 0



새 벡터 $= 0.45 \cdot$ 밤새 $+0.25 \cdot$ 게임을 $+ \cdots =$ **(1.99, 0.58, 0.16)**

원래 (1, 0, 0) 에 밤새 · 게임을의 뜻이 섞였다

왜 $\sqrt{d}$ 로 나누나

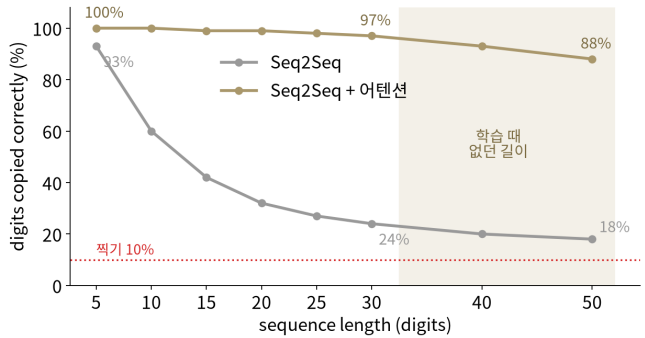
칸마다 평균 0, 분산 1 인 무작위 벡터의 내적: 분산 $= d$, 표준편차 $= \sqrt{d}$

	$d = 3$	$d = 512$
내적의 표준편차	1.7	**22.6**
$\sqrt{d}$ 로 나누면	1	1

점수가 수십이면 softmax 가 0 아니면 1 $\rightarrow$ 한 단어만 보고 기울기도 0 근처

$\sqrt{d}$ 로 나눠 점수의 크기를 칸 수와 상관없이 맞춘다

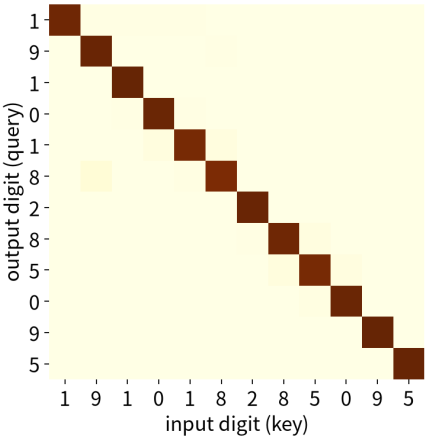
실험: Seq2Seq 에 어텐션을 더하면



지난 시간의 숫자열 베끼기 (벡터 32칸) 길이 30: **24%** → **97%**

학습 때 없던 길이 50 도 88% 통째로 맞힌 비율 (길이 30): 0% → 92%

어텐션 지도: 어디를 봤나



칸 = 출력 숫자 (행) 가 입력 숫자 (열) 를 보는 비율 α

대각선: k 번째 숫자를 쓸 때 k 번째 입력을 본다

시키지 않았는데 스스로 배웠다

번역에서는 어순이 다른 곳에서 대각선이 꺾인다 (Bahdanau 외 2014 그림 3: 영어 European Economic Area ↔ 프랑스어 zone économique européenne)

번역의 보조에서 주인공으로

2014	Bahdanau 외	RNN 번역에 어텐션: BLEU 17.8 → **26.8**
2015	Luong 외	점수를 내적으로 (오늘 실험의 방식)
2017	Vaswani 외	**셀프 어텐션**만으로 트랜스포머

번역 (교차) 어텐션	Q = 디코더, K · V = 인코더
셀프 어텐션	Q · K · V 모두 같은 문장 (“피곤하다” 예)

문제풀이

1. 점수가 (2, 0, 0) 이면 비율 α 는? ($e^2 \approx 7.39$) 밸류가 (10), (0), (0) 이면 결과는?
2. 손 계산에서 “피곤하다” 벡터를 (0, 1, 0) 으로 바꾸면 어느 단어를 가장 많이 볼까?
3. 입력 단어 n 개, 출력 단어 m 개인 번역에서 점수는 몇 개 계산하나? Seq2Seq 와 비교하면?
4. 실험에서 어텐션 모델은 학습 때 없던 길이 50 도 88% 맞혔다. Seq2Seq 는 왜 못할까?

실습

1. numpy 로 어텐션 함수 $\rightarrow$ 손 계산 재현, $\sqrt{d}$ 실험
2. Seq2Seq 에 어텐션 더하기 (PyTorch) $\rightarrow$ 숫자열 베끼기 길이별 정답률
3. 어텐션 지도 그리기

▶ Colab에서 실습 노트북 열기

정리

어텐션: 질문 (Q) 을 모든 색인 (K) 과 비교 → softmax 비율 → 내용 (V) 을 섞는다

softmax$(QK^\top/\sqrt{d})\,V$ $\sqrt{d}$: 칸이 많아도 점수 크기를 맞춘다

“피곤하다” → 밤새 45% 베끼기 길이 30: 24% → **97%**, 지도는 대각선

2014 번역의 보조 → 2017 셀프 어텐션만으로 트랜스포머 (다음 시간)