# GAN 생성적 적대 신경망 (Generative Adversarial Network)

## 위조범과 경찰이 겨루며 함께 는다

Machine Learning and Deep Learning

KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

## 오늘의 질문: “진짜 같다” 를 어떻게 손실로 만들까?

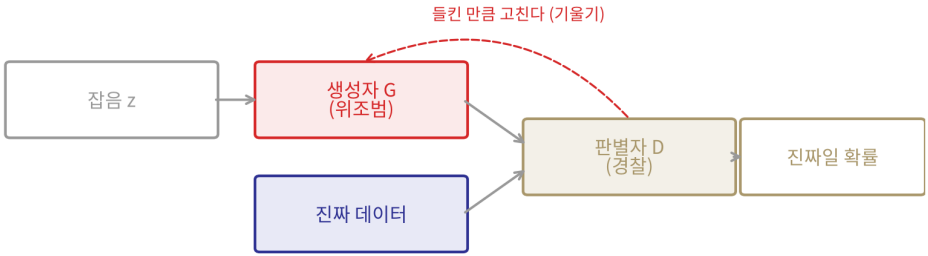
VAE: 원래 그림과 **칸마다** 비교 (복원 오차) → 평균 내다 보니 흐리다

진짜 같음은 칸마다 비교로 못 잰다: 같은 7 도 쓰는 법이 수천 가지

아이디어: 진짜와 가짜를 가려내는 **신경망을 하나 더** 두고, 그걸 속이게 하자

Goodfellow 외 (2014) “Generative Adversarial Nets”  요슈아 벤지오 교수 팀

# 위조범과 경찰




생성자 $G$ 잡음 $\mathbf{z} \to$ 가짜 목표: $D$ 가 가짜를 진짜라고 믿게

판별자 $D$ 그림 $\to$ 진짜일 확률 목표: 진짜는 1, 가짜는 0

## 식으로: 두 사람의 게임

$$\min_G \max_D \; \mathbb{E}_{\mathbf{x}\sim\text{진짜}}\big[\log D(\mathbf{x})\big] + \mathbb{E}_{\mathbf{z}}\big[\log\big(1 - D(G(\mathbf{z}))\big)\big]$$

$D$ 한 걸음 진짜는 1, 가짜는 0 으로 맞히는 이진 교차 엔트로피를 줄인다

$G$ 한 걸음 가짜에 대해 “진짜 (1)” 를 정답으로 한 교차 엔트로피를 줄인다 (실전 꼴)

번갈아 $D$ 한 걸음, $G$ 한 걸음, $\cdots$

이상적인 끝: 가짜가 진짜와 같아지면 $D$ 는 무엇이든 **1/2**

## 손으로 한 번: 판별자의 점수

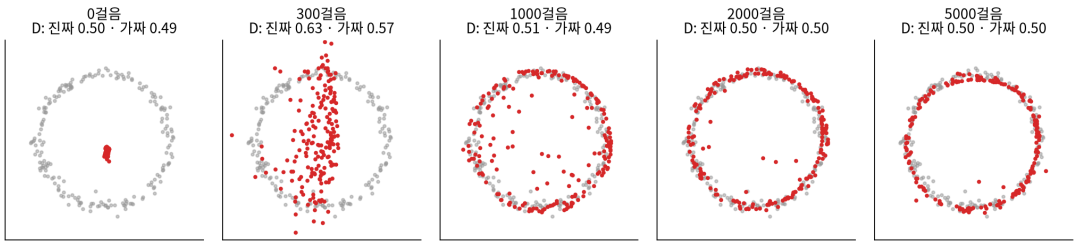
판별자가 진짜 그림에 0.9, 가짜 그림에 0.2 를 줬다

$D$ 의 손실 $\quad -\ln 0.9 - \ln(1-0.2) = 0.105 + 0.223 = \mathbf{0.33}$

$G$ 의 손실 $\quad -\ln 0.2 = \mathbf{1.61}$ (들켰다: 크다)

끝에 $D$ 가 모두 0.5 를 주면: $D$ 손실 $2\ln 2 = 1.39$, $G$ 손실 $\ln 2 = 0.69$

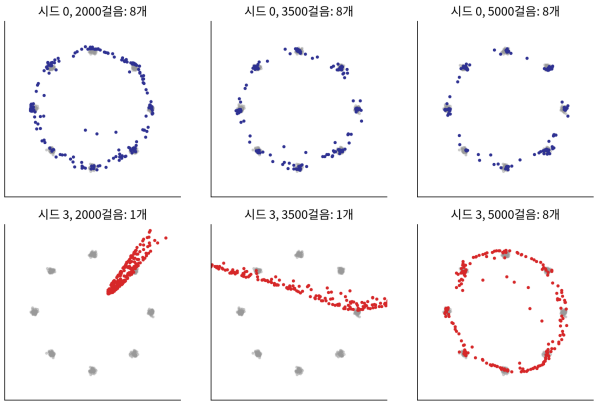
# 실험 1: 고리 모양 데이터




회색 = 진짜 (반지름 2 고리), 빨강 = 생성자의 가짜  같은 잡음 200개로 단계별

300걸음: 판별자가 진짜에 0.63  5,000걸음: 진짜도 가짜도 **0.50**

# 실험 2: 불안정한 학습 · 모드 붕괴



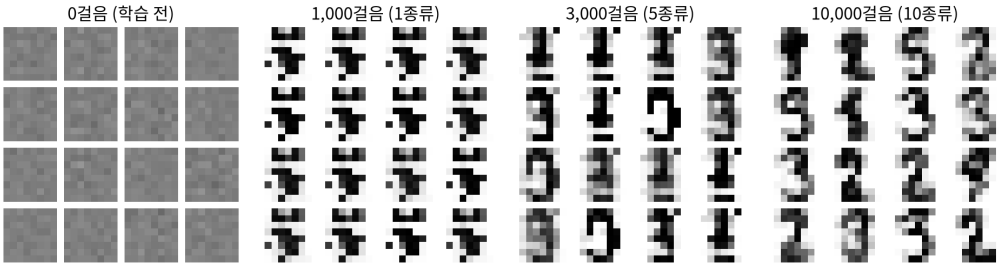

봉우리 8개, 같은 설정 · 시드만 다르게

시드 5개 중 4개: 1,500걸음에 **8개** 모두

시드 3: 4,500걸음까지 **0** ∼ **1개** 를 맴돌다 5,000걸음에야 8개

생성자가 판별자의 약한 곳 한 군데만 노리면 한 모양만 만든다 (모드 붕괴)

# 실험 3: 손글씨 숫자




1,000걸음: 2,000장 **모두 “5”** (모드 붕괴)  3,000걸음: 5종류  10,000걸음: **10종류**

숫자 판정 = 원본으로 학습한 로지스틱 회귀  확신 (확률 0.9 이상) 36%, 원본 사진은 77%

## GAN 이 연 길

| | |
|---|---|
| 2014 | GAN (Goodfellow 외): 흐릿한 작은 그림 |
| 2015 | DCGAN: 합성곱으로, 안정적인 학습 요령 |
| 2017 | CycleGAN: 말 $\leftrightarrow$ 얼룩말, 사진 $\leftrightarrow$ 그림 (짝 없는 변환) |
| 2018 $\sim$ 2019 | StyleGAN: 진짜 같은 1024 $\times$ 1024 얼굴 (딥페이크 논란도) |
| 2020 $\sim$ | 확산 모델이 주도: 학습이 안정적이고 다양하다 (다음 덱) |

장점: 한 번에 빠르게 생성, 선명 약점: 불안정한 학습, 모드 붕괴

## 문제풀이

1. 판별자가 진짜에 0.6, 가짜에 0.6 을 줬다. $D$ 의 손실과 $G$ 의 손실은? ($\ln 0.6 \approx -0.51$, $\ln 0.4 \approx -0.92$)
2. 판별자가 너무 잘해서 가짜에 항상 0.0001 을 주면, $\log(1 - D(G(z)))$ 를 줄이는 생성자의 기울기는 어떻게 될까?
3. 모드 붕괴가 생기면 2,000장을 뽑았을 때 무엇이 보일까? 어떻게 알아챌 수 있을까?
4. VAE 와 GAN 을 “흐림 · 다양함 · 학습 안정성” 으로 비교해 보라.

## 실습

1. 판별자 · 생성자 손실 손 계산 (0.33, 1.61)
2. 2차원 GAN: 고리 · 봉우리 8개, 덮은 봉우리 수 세기
3. 손글씨 숫자 GAN, 단계별 그림 · 종류 수

▶ Colab에서 실습 노트북 열기

# 정리

**GAN**: 생성자 (위조범) vs 판별자 (경찰), 번갈아 학습 (2014)

판별자: 진짜 1 · 가짜 0  생성자: 가짜를 "진짜" 로 믿게  끝: $D = 1/2$

고리: 5,000걸음에 진짜 · 가짜 모두 0.50  봉우리 8개: 시드 하나는 오래 1개

숫자: 1,000걸음 전부 "5" (모드 붕괴) $\rightarrow$ 10,000걸음 10종류  다음: 확산 모델