Machine Learning 1: 머신러닝 첫걸음 2027. X. XX (예정)

Final Exam — Solutions

Spring 2027

1. **(*8 points*)** 입력 $32 \times 32 \times 3$ 에 5×5 필터 *16* 개(스트라이드 *1*, 패딩 *0*)를 적용한다. [(*a*)] 출력 크기와 파라미터 수(편향 포함)를 구하라. [(*b*)] 이어서 2×2 최대 풀링을 하면 출력 크기는?

정답. (a) 출력 $(32 - 5)/1 + 1 = 28$ 이므로 $28 \times 28 \times 16$. 파라미터 $5 \cdot 5 \cdot 3 \cdot 16 + 16 = 1216$.

(b) $14 \times 14 \times 16$. 풀링에는 학습 파라미터가 없다.

2. **(*6 points*)** 입력 *32*, 필터 *5*, 패딩 *2*, 스트라이드 *2* 일 때 출력 한 변의 길이는? 입력과 같은 크기를 유지하려면 스트라이드 *1* 에서 패딩이 몇이어야 하는가?

정답. $\lfloor (32 + 4 - 5)/2 \rfloor + 1 = 15 + 1 = 16$. 같은 크기는 패딩 2 $(= (5-1)/2)$.

3. **(*6 points*)** $y = x + F(x)$ 일 때 $\partial y / \partial x$ 를 쓰고, 이것이 깊은 망의 학습을 쉽게 하는 이유를 설명하라.

정답. $\partial y/\partial x = 1 + \partial F/\partial x$. F 의 기울기가 작아져도 1 이 더해져 기울기가 입력까지 거의 그대로 전달된다. 또 F 가 0 이 되면 항등 함수이므로 층을 더해도 성능이 나빠지지 않게 학습하기 쉽다.

4. **(*8 points*)** 한 배치의 한 채널 값이 $2, 4, 6, 8$ 이다. 정규화한 값(ϵ 무시)을 구하라. 추론 시에는 배치 평균·분산 대신 무엇을 쓰는가?

정답. 평균 5, 분산 $(9+1+1+9)/4 = 5$, 표준편차 ≈ 2.236. 값은 $\approx -1.34, -0.45, 0.45, 1.34$. 추론 시에는 학습 중 모아 둔 이동평균 통계를 쓴다.

5. (*6 points*) $p = 0.5$ 드롭아웃에서 학습 때 살아남은 뉴런 출력에 *2* 를 곱하는(*inverted dropout*) 이유와 추론 때의 처리를 쓰라.

정답. 절반이 꺼지므로 다음 층에 들어가는 합의 기댓값이 절반으로 줄어든다. 2 를 곱해 학습 때와 기댓값을 맞춘다. 추론 때는 드롭아웃을 끄고 모든 뉴런을 그대로 쓴다.

6. (*8 points*) [(*a*)] 벡터 $(1,0)$ 과 $(1,1)$ 의 코사인 유사도는? [(*b*)] *t-SNE* 그림에서 군집 사이의 거리와 군집의 크기를 곧이곧대로 해석하면 안 되는 이유는? [(*c*)] *word2vec* 은 무엇을 맞히며 학습하는가?

정답. (a) $1/\sqrt{2} \approx 0.707$.

(b) t-SNE 는 가까운 이웃 관계를 보존하도록 지도를 그려서 먼 거리와 크기는 의미가 없고, 매개변수(perplexity)에 따라 모양이 달라진다.

(c) 주변 단어(또는 가운데 단어).

7. (*8 points*) [(*a*)] 입력 *2,* 은닉 *3* 인 단순 *RNN* 의 파라미터 수(편향 포함)는? [(*b*)] 같은 크기의 *LSTM* 은? [(*c*)] *LSTM* 이 긴 문장에서 기울기 소실을 줄이는 이유는?

정답. (a) $3 \cdot 2 + 3 \cdot 3 + 3 = 18$.

(b) 게이트 3개와 후보 1개로 4배, 72.

(c) 셀 상태가 덧셈으로 갱신되고 망각 게이트가 1 에 가까우면 기울기가 거의 그대로 흐르기 때문.

8. (*8 points*) 질의 $q = (1,0)$, 키 $k_1 = (1,0)$, $k_2 = (0,1)$, 값 $v_1 = (10,0)$, $v_2 = (0,10)$, $d_k = 2$ 이다. 스케일 점곱 어텐션의 가중치와 출력을 구하라 ($e^{0.707} \approx 2.03$). $\sqrt{d_k}$ 로 나누는 이유는?

정답. 점수 $= (1,0)/\sqrt{2} = (0.707, 0)$. 소프트맥스: $2.03/(2.03+1) \approx 0.67, 0.33$. 출력 $= 0.67\,(10,0) + 0.33\,(0,10) \approx (6.7,\ 3.3)$. 점곱이 차원에 따라 커져 소프트맥스가 포화되는 것을 막기 위해 $\sqrt{d_k}$ 로 나눈다.

9. (*6 points*) [(*a*)] 셀프 어텐션에 위치 인코딩이 필요한 이유는? [(*b*)] 길이 n 인 입력에서 셀프 어텐션의 계산량은 n 에 대해 어떻게 늘어나는가? [(*c*)] *BERT* 와 *GPT* 의 학습 목표 차이는?

정답. (a) 어텐션은 단어 순서를 모르는 집합 연산이라 "Dog bites man" 과 "Man bites dog" 를 구분하지 못한다.

(b) n^2 에 비례(모든 쌍의 점수).

(c) BERT 는 가려진 단어 맞히기(양방향), GPT 는 다음 단어 맞히기(왼쪽에서 오른쪽).

10. (*8 points*) 노드 A 의 특징이 *2* 이고 이웃 B, C 의 특징이 *4*, *6* 이다. 자기 자신을 포함한 평균 집계를 한 층 한 뒤 A 의 값은? 층을 너무 많이 쌓으면 어떤 문제가 생기는가?

정답. $(2+4+6)/3 = 4$. 층이 깊어지면 모든 노드의 값이 비슷해지는 과평활(over-smoothing)이 생긴다.

11. (*6 points*) 인코더가 $N(\mu, \sigma^2) = N(1, 1)$ 을 내놓았다. $N(0,1)$ 과의 KL 은? ($\mathrm{KL} = \frac{1}{2}(\sigma^2 + \mu^2 - 1 - \ln\sigma^2)$) 이 항이 *VAE* 손실에서 하는 역할은?

정답. $\frac{1}{2}(1+1-1-0) = 0.5$. 잠재 공간이 표준 정규분포 근처에 모이게 해서, 무작위로 뽑은 z 도 디코더가 그럴듯한 그림으로 바꿔 주게 한다(재구성 항과의 균형).

12. (*8 points*) [(*a*)] *GAN* 에서 생성자가 완벽할 때 판별자의 출력은? [(*b*)] 모드 붕괴란? [(*c*)] 확산 모델에서 $\bar{\alpha}_t = 0.64$ 이면 $x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon$ 의 두 계수는?

정답. (a) 진짜와 가짜를 구분할 수 없어 0.5.

(b) 생성자가 판별자를 속이기 쉬운 몇 가지 결과만 반복해서 다양성을 잃는 현상.

(c) 0.8 과 0.6 ($0.8^2 + 0.6^2 = 1$ 이라 분산이 유지된다).

13. **(***14 points***)** *BERT* 를 감성 분류에 쓰는 두 단계(사전학습, 미세조정)를 설명하고, 미세조정에 데이터가 적어도 되는 이유를 쓰라.

정답. 사전학습: 라벨 없는 큰 글 모음에서 가려진 단어를 맞히며 언어 일반을 배운다. 미세조정: 적은 라벨 데이터로 분류 머리를 붙여 전체를 조금 다시 학습한다. 사전학습에서 이미 단어와 문장 구조의 표현을 얻었으므로 새로 배울 양이 적다.