Machine Learning 1: 머신러닝 첫걸음 2027. X. XX (예정)

기말 프로젝트 공고 (샘플)

Spring 2027

1. 프로젝트 개요

9∼15주차에서 배운 딥러닝 기법(신경망 기초·역전파, CNN, 시퀀스 모델, 어텐션·트랜스포머, 그래프 표현학습, 표현학습, 잠재변수 생성모델)을 실제 데이터에 적용하는 학기 후반 8주에 걸쳐 진행하는 팀 프로젝트이다. 중간 프로젝트 (8주차)의 절차를 **딥러닝 무대**에서 다시 수행하며, 이번에는 "왜 고전 머신러닝이 아니라 딥러닝인가"를 직접 증명해야 한다.

진행 순서: **데이터 선정** → **Abstract** → **구현** → **검증** → **보고서 제출** → **동료평가**.

2. 필수 요구사항

- **데이터**: Kaggle, UCI, Hugging Face Datasets 중에서 선택 (이미지·텍스트·시퀀스 등 비정형 데이터도 가능).
- **적용 알고리즘**: 9∼15주차 중 **최소 하나의 딥러닝 기법**(CNN, RNN/Transformer, 프롬프팅 응용, 또는 EM/VAE 계열 생성모델)을 실제 데이터에 적용한다.
- **수식적 정당화 최소 1개**: (1) CNN 구조라면 파라미터 수/연산량 공식으로 설계를 정당화, (2) 정규화(dropout 등)를 썼다면 그 효과를 설명, (3) 생성모델이라면 ELBO나 min-max 목적함수를 실제 구현과 연결.
- **GBDT 비교 (필수)**: 같은 데이터에 GBDT(또는 랜덤 포레스트)를 **베이스라인**으로 돌려, 신경망이 이보다 나은지 확인한다. 이것이 보고서에서 "왜 딥러닝인가"를 답하는 근거의 출발점이 된다.
- **검증 원칙**: train/validation/test 3분할을 중간 프로젝트와 동일하게 준수하고, **테스트 성능은 딱 한 번**만 확인한다.

3. 정형/비정형 판정 가이드

중간 프로젝트의 5개 데이터 선정 기준(행의 물리적 단위, 레이아웃 함정, 시계열, 클래스 비율, 크기)은 그대로 적용되며, 기말 프로젝트에서는 다음 기준이 추가된다: **"원시 특징"이 이미 정형으로 추출되어 있는가?**

경우	예	판정
수치·범주 열로만 구성된 표	매출표, 센서 로그	**정형** — GBDT와 비교해야 한다
픽셀·음파·토큰인 원시 배열	이미지, 오디오, 문장	**비정형** — 손으로 특징을 만들기 어려우니 신경망이 특징 추출기 역할을 한다
애매한 경우	이미 임베딩으로 벡터화된 텍스트	원시 토큰으로 직접 모델링하는 선택도 가능 — 그 이유를 Abstract에 적어야 한다

데이터 가게와 데이터 월드컵도 활용한다. `smhanlab.com/book-ml/datashop`에는 이미지·텍스트·시계열·그래프처럼 딥러닝이 어울리는 현장 데이터(품질 검사 영상, 한국어 리뷰, 음성, 위성 영상, 링크 예측, 차량 궤적 등)도 진열되어 있다. 데이터마다 적힌 행의 단위, 라벨, 크기, 함정을 위 기준으로 먼저 점검하고, 후보를 정하기 어려우면 **데이터 월드컵**(`.../datashop/worldcup/`)으로 후보를 2~3개로 좁힌다. 정형으로 쓸 수 있는 데이터를 골랐다면 GBDT 베이스라인과의 비교가 더 중요해진다.

4. 일정 (후반 8주)

시기	해야 할 일	제출
기말 1주(9주차)	팀 구성, 데이터 후보 2~3개 조사, 정형/비정형 판정	
기말 2주(10주차)	행·라벨·지표·베이스라인, "왜 딥러닝인가" 초안, 적용할 신경망 계획	**Abstract** (1p)
기말 3~5주	3분할 스캐폴드, train으로만 fit한 전처리, **GBDT 베이스라인**, 신경망 적용, validation 튜닝, **test 최종 측정(한 번만)**, 학습 곡선(에포크 단위)	
기말 6주(14주차)	보고서 완성	**보고서 제출**: 보고서 PDF + 코드 + 학습 곡선 + GBDT 비교
기말 7주(15주차)	제출된 다른 팀 보고서 읽기	
기말 8주(16주차, 기말고사 기간)	다른 팀 2개에 대한 peer-review 작성	**동료평가** 제출 (리뷰 2건)

학습 곡선은 **에포크** 단위(중간 프로젝트의 트리 개수와는 다른 축)이다. 최종 숫자만으로는 에포크 수를 어떻게 정했는지 검증할 수 없다 — validation 곡선이 실제로 쓰였는지가 그림에서 드러나야 한다.

5. 보고서 구조

중간 프로젝트의 6절 구조를 그대로 쓰되, 2절과 5절이 기말 프로젝트용으로 바뀐다.

1. **문제 정의** (0.5p): 행의 단위, 라벨, 주 지표, **두 층의 베이스라인**(무작위·GBDT), **정형/비정형 판정과 그 근거**.
2. **데이터와 전처리** (1p): 원본 통계, train으로만 fit한 전처리 명시(이미지 스케일링, 텍스트 토크나이저/패딩 등), 분할 비율.
3. **모델 선택과 이유** (1∼2p): 적용한 딥러닝 기법 1개 이상과 그 구조(층·크기)를 파라미터 수 공식으로 정당화, 왜 GBDT가 아니라 이 기법인가.
4. **결과** (1p): 최종 test 숫자(한 번), 에포크 학습 곡선 1장, GBDT·무작위와의 비교표.
5. **수식적 정당화** (1p, **필수 1개**): 파라미터 수/정규화 효과/ELBO 중 하나.
6. **재현 방법** (0.5p): 데이터 출처, 분할, 시드, 하이퍼파라미터, 실행 명령. 다른 사람이 같은 숫자를 다시 얻을 수 있어야 한다.
7. **한계와 잘 안 된 부분** (0.5p, **필수**): 학습이 안 된/과적합된 부분을 배운 개념으로 진단.

6. 채점 기준 (Rubric)

다섯 항목을 각 20%로 채점한다. 목적은 "높은 성능"이 아니라 **주장을 정직하고 재현 가능하게 입증**하는 것이다.

항목	비중	좋은 답
1. 주장의 명확성 (clarity)	20%	무엇을 주장하는지 첫 문단에서 한 문장으로 알 수 있고, 행의 단위·라벨·지표가 명확하며, 결과가 주장과 이어짐
2. 비교 대상 (baseline)	20%	**GBDT 베이스라인**과 신경망이 같은 분할·같은 지표로 비교되고, "왜 고전 머신러닝이 아니라 딥러닝인가"에 구체적 숫자로 답함
3. 확장성 (scalability)	20%	다른 데이터 하나(또는 데이터 크기를 줄인 실험)에서도 결론이 유지되는지 확인하고, 구성 요소 제거·민감도 실험으로 어디까지 통하는지 보임
4. 재현성 (reproducibility)	20%	데이터 출처·분할 방식·전처리·하이퍼파라미터·랜덤 시드·코드 실행 방법이 적혀 있어 다른 사람이 같은 숫자를 다시 얻을 수 있음. test를 한 번만 썼고 어디서 썼는지 추적 가능
5. 한계의 솔직함 (limitations)	20%	잘 안 된 부분, 약한 가정, 일반화되지 않을 조건을 숨기지 않고 원인을 진단함. 성능이 낮아도 한계가 정직하면 높은 점수

성능이 좋아 보여도 test를 두 번 썼거나 비교 대상이 없거나 재현이 불가능하면 크게 감점받는다.

7. 동료평가 (Peer-Review)

- **보고서**: 결론에서 **"왜 고전 머신러닝이 아니라 딥러닝인가"**에 구체적 근거로 답해야 한다.
- **Peer-Review**: 기말 8주차에 다른 두 팀의 보고서에 대해 작성 리뷰를 각 1통씩 제출한다. 각 리뷰는 아래 5항목 체크리스트와, 반박 가능한 질문을 1개 이상 포함해야 한다.

Peer-Review 체크리스트 (채점 기준과 같은 5항목)

항목	확인할 것
주장의 명확성 (clarity)	무엇을 주장하는지 분명하게 썼는가
비교 대상 (baseline)	비교 대상이 있는가 (GBDT 베이스라인 포함)
확장성 (scalability)	다른 데이터에도 적용 가능한가
재현성 (reproducibility)	다른 사람이 다시 해 볼 수 있는가
한계 (limitations)	한계를 솔직하게 적었는가

8. 팀 구성 및 제출 방식

- **팀 구성**: 팀당 인원 및 팀 편성 방식은 추후 공지.
- **제출물**: Abstract(기말 2주), 보고서(PDF)와 코드(기말 6주), peer-review 2건(기말 8주).
- **제출 방법 및 마감**: 추후 공지 (LMS/과제 제출 시스템 및 마감 일시는 별도 안내 예정).