Machine Learning 1: 머신러닝 첫걸음 2027. X. XX (예정)

중간 프로젝트 공고 (샘플)

Spring 2027

1. 프로젝트 개요

1∼7주차에서 배운 고전 머신러닝 기법(회귀, 생성모델 기반 분류, 거리 기반 모델, SVM, 정규화와 모델 선택, 트리 기반 모델)을 **실제 정형(tabular) 데이터**에 적용하는 학기 전반 8주에 걸쳐 진행하는 팀 프로젝트이다. 목표는 "높은 성능" 자체가 아니라, **그 성능 숫자를 정직하게 얻는 절차**를 실제로 수행하고 보고하는 것이다.

진행 순서: **데이터 선정** → **Abstract** → **구현** → **검증** → **보고서 제출** → **동료평가**.

2. 필수 요구사항

- **데이터**: Kaggle 또는 UCI Machine Learning Repository의 정형(행/열) 데이터 하나 (이미지 · 텍스트 제외 — 표 형태가 Ch.2∼7 모델 검증에 적합).
- **적용 알고리즘**: 1∼7주차 중 **최소 두 가지** 모델(예: 로지스틱회귀 + GBDT)을 같은 데이터에 적용해 비교한다.
- **수식적 정당화 최소 1개**: 예 — 정규화를 적용했다면 편향-분산 관점에서 왜 성능이 바뀌었는지, GBDT를 썼다면 SHAP으로 예측 하나를 분해, 여러 모델을 비교했다면 PR-AUC로 불균형을 고려한 비교.
- **검증 원칙**: train/validation/test 3분할을 준수하고, **테스트 성능은 딱 한 번**만 확인한다. 전처리는 반드시 train으로만 fit한다.
- **학습 곡선 필수 제시**: 최종 숫자만으로는 하이퍼파라미터를 어떻게 정했는지 검증할 수 없다 — validation 곡선이 실제로 선택에 쓰였는지가 그림에서 드러나야 한다.

3. 데이터 고르기 실전 가이드

1. **행의 물리적 단위**를 한 문장으로 설명할 수 있는가 (환자? 거래? 주문?) — 설명이 안 되면 예측 대상 단위를 일반화할 수 있는지 물을 수 없다.
2. **레이아웃의 함정**이 있는가 — 같은 개체의 여러 행이 있으면 무작위 분할 시 데이터 누수가 발생할 수 있다(그룹 단위 분할 필요).
3. **시계열이면 시간순**으로 분할해야 한다.
4. **클래스 비율을 먼저 보고 지표를 정한다** — 비율이 99:1처럼 극단적이면 정확도가 아니라 PR-AUC/재현율을 사용한다.
5. **크기** — 100행 미만이면 교차검증 폴드가 너무 작아 숫자가 심하게 흔들린다. 500∼10,000행 정도가 다루기 편하다.

데이터를 어디서 찾나: 데이터 가게와 데이터 월드컵. `smhanlab.com/book-ml/datashop`에는 산업·서비스 현장의 데이터(신용카드 연체, 통신사 이탈, 호텔 예약, 부동산, 전력, 택시 수요, 공정 불량 등)가 데이터마다 **행의 단위, 라벨, 크기, 클래스 비율, 알려진 함정**과 함께 진열되어 있다. 위 5가지 기준을 가게 안의 설명에서 먼저 확인하고, 노트북(.ipynb)을 받아 데이터가 어떻게 생겼는지 직접 열어 본다. 무엇을 고를지 모르겠다면 **데이터 월드컵**(`.../datashop/worldcup/`)에서 32개 데이터를 이상형 월드컵으로 비교하며 끌리는 순서를 정하고, 우승 데이터와 4강 데이터를 팀 회의의 후보 2∼3개로 쓴다. 가게에 없는 데이터(Kaggle, UCI)도 같은 5가지 기준으로 직접 검사한다.

4. 일정 (전반 8주)

시기	해야 할 일	제출
1∼2주	팀 구성, 데이터 후보 2∼3개 조사 (크기·결측치·클래스 비율)	
3주	문제 정의(행의 단위, 라벨, 주 지표), 선택한 데이터, 베이스라인과 적용할 모델 계획	**Abstract** (1p)
4∼5주	3분할 스캐폴드, train으로만 fit하는 전처리, 베이스라인, 모델 적용, validation 튜닝, **test 최종 측정(한 번만)**, 학습 곡선	
6주 (중간고사 기간)	보고서 완성	**보고서 제출**: 보고서 PDF + 코드 + 학습 곡선
7주	제출된 다른 팀 보고서 읽기	
8주 (중간고사 기간)	다른 팀 2개에 대한 peer-review 작성	**동료평가** 제출 (리뷰 2건)

Abstract에 베이스라인 계획을 넣는 이유: 이 숫자를 봐야 "모델을 만들었다"고 말할 수 있는지 판정할 수 있다. 학습 곡선을 요구하는 이유: 최종 숫자만 제출하면 하이퍼파라미터를 어떻게 정했는지 검증할 수 없다.

5. 보고서 구조

1. **문제 정의** (0.5p): 행의 단위, 라벨, 주 지표, 베이스라인, "왜 이 지표를 골랐는가" 한 문장.
2. **데이터와 전처리** (1p): 원본 통계(크기 · 결측치 · 이상치), train으로만 fit한 전처리 명시, 3분할 비율과 stratify 여부.
3. **모델 선택과 이유** (1∼2p): 후보 2개 이상, 왜 이 후보들인가(데이터 특성과 연결: 거리 기반이면 스케일링, 트리 기반이면 불필요), validation 비교표.
4. **결과** (1p): 최종 test 숫자(한 번), 학습 곡선 1장, validation 비교표.
5. **수식적 정당화** (1p): 편향-분산, 정규화, SHAP, PR-AUC 중 1개 이상으로 "왜 이 결과가 나왔는지".
6. **재현 방법** (0.5p): 데이터 출처, 분할, 시드, 하이퍼파라미터, 실행 명령. 다른 사람이 같은 숫자를 다시 얻을 수 있어야 한다.
7. **한계와 잘 안 된 부분** (0.5p, **필수**): 안 된 부분이 없었다면 무엇을 시도했다가 안 됐는지를 쓴다.

6. 채점 기준 (Rubric)

다섯 항목을 각 20%로 채점한다. 목적은 "높은 성능"이 아니라 **주장을 정직하고 재현 가능하게 입증**하는 것이다.

항목	비중	좋은 답
1. 주장의 명확성 (clarity)	20%	무엇을 주장하는지 첫 문단에서 한 문장으로 알 수 있고, 행의 단위·라벨·지표가 명확하며, 결과가 주장과 이어짐
2. 비교 대상 (baseline)	20%	베이스라인(항상 다수 클래스, 정규화 없는 모델)과 모델 두 가지 이상이 같은 분할·같은 지표로 비교됨. 비교 없는 숫자는 해석하지 않음
3. 확장성 (scalability)	20%	다른 분할(그룹·시간순)이나 다른 데이터 하나에서도 같은 절차가 통하는지 확인하고, 안 통하는 조건을 적음
4. 재현성 (reproducibility)	20%	데이터 출처·분할 방식·전처리·하이퍼파라미터·랜덤 시드·코드 실행 방법이 적혀 있어 다른 사람이 같은 숫자를 다시 얻을 수 있음. test를 한 번만 썼고 어디서 썼는지 추적 가능
5. 한계의 솔직함 (limitations)	20%	잘 안 된 부분, 약한 가정, 일반화되지 않을 조건을 숨기지 않고 원인을 진단함. 성능이 낮아도 한계가 정직하면 높은 점수

성능이 좋아 보여도 test를 두 번 썼거나 비교 대상이 없거나 재현이 불가능하면 크게 감점받는다.

7. 동료평가 (Peer-Review)

- **Peer-Review**: 8주차에 다른 두 팀의 보고서에 대해 작성 리뷰를 각 1통씩 제출한다. 각 리뷰는 아래 5항목 체크리스트와, 근거를 대야만 답할 수 있는 반박 가능한 질문을 1개 이상 포함해야 한다.

Peer-Review 체크리스트 (채점 기준과 같은 5항목)

항목	확인할 것
주장의 명확성 (clarity)	무엇을 주장하는지 분명하게 썼는가
비교 대상 (baseline)	비교 대상이 있는가 (베이스라인과 모델 두 가지 이상)
확장성 (scalability)	다른 데이터에도 적용 가능한가
재현성 (reproducibility)	다른 사람이 다시 해 볼 수 있는가
한계 (limitations)	한계를 솔직하게 적었는가

8. 팀 구성 및 제출 방식

- **팀 구성**: 팀당 인원 및 팀 편성 방식은 추후 공지.

- **제출물**: Abstract(3주), 보고서(PDF)와 코드(저장소 링크 또는 압축 파일, 6주), peer-review 2건(8주).
- **제출 방법 및 마감**: 추후 공지 (LMS/과제 제출 시스템 및 마감 일시는 별도 안내 예정).