PCA 주성분 분석 (Principal Component Analysis)

가장 넓게 퍼진 방향으로 그림자를 낸다

Machine Learning and Deep Learning

한국과학영재학교 (KSA)

오늘의 질문: 숫자 두 개를 하나로 줄이려면?

학생	수학	물리
1	95	92
2	35	47
3	73	76
⋮	⋮	⋮
20	65	56

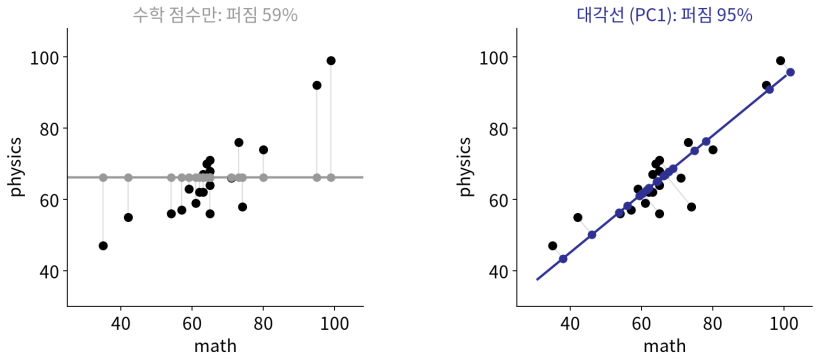
20명 점수 (설명용 예시)

학생마다 숫자 2개 $\rightarrow$ **1개**로 줄이고 싶다

수학 점수만 남기면?
평균을 내면?
가장 **정보를 많이 남기는** 한 숫자는?

특징이 수십 · 수백 개면: 그림으로 보고, 저장을 줄이고, 다음 모델을 빠르게

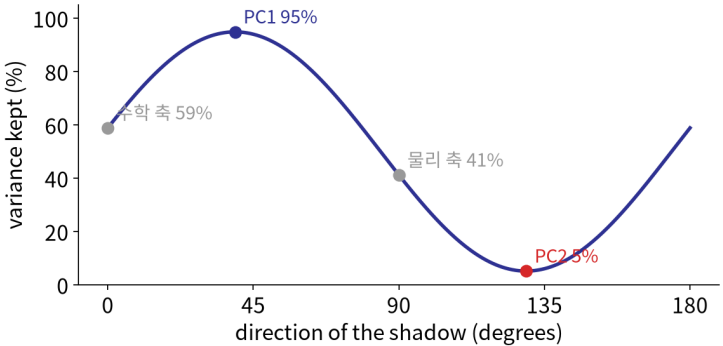
그림자를 내 보자



점을 한 직선에 수직으로 내리면 (그림자 = 투영) 숫자 하나가 된다

그림자가 **넓게 퍼질수록** 학생들의 차이가 많이 남는다 수학 축 59% 대각선 95%

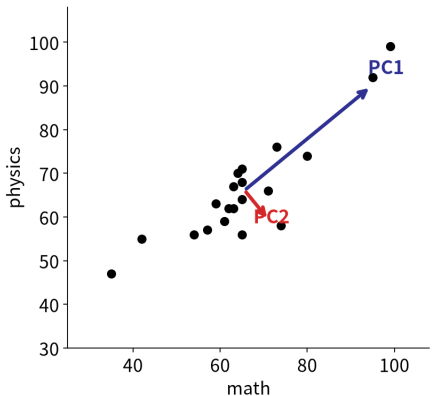
방향을 돌려 보면



가장 넓게 퍼지는 방향 (39°) = **제1 주성분 PC1** 남는 퍼짐 **95%**

그와 수직 (129°) = **PC2** 나머지 **5%** 두 비율의 합 = 100%

주성분의 뜻



PC1 $0.77 \cdot$ 수학 $+0.63 \cdot$ 물리 “둘 다 잘함”

PC2 $0.63 \cdot$ 수학 $-0.77 \cdot$ 물리 “수학이 더 셈”

주성분 = 원래 특징들의 **가중합** (방향 벡터, 길이 1)

두 점수가 함께 움직여 (상관) 한 방향에 몰린다

평균을 뺀 점수에 곱한다 (평균: 수학 65.6, 물리 66.1)

식으로: 공분산 행렬의 고유벡터

방향 $\mathbf{u}$ ($\|\mathbf{u}\| = 1$) 로 그림자를 냈을 때의 분산 $= \mathbf{u}^\top S\,\mathbf{u}$, S = 공분산 행렬

$$\max_{\|\mathbf{u}\|=1} \mathbf{u}^\top S\mathbf{u} \quad \Rightarrow \quad S\mathbf{u} = \lambda\mathbf{u}$$

답 = S 의 **고유벡터**, 그 방향의 분산 = **고유값** λ

$$S = \begin{pmatrix} 217.8 & 162.8 \\ 162.8 & 152.4 \end{pmatrix} \quad \lambda^2 - 370.2\,\lambda + 6685.7 = 0 \quad \Rightarrow \quad \lambda_1 = \mathbf{351.2},\ \lambda_2 = 19.0$$

설명 분산 비율 $351.2/370.2 = \mathbf{95\%}$

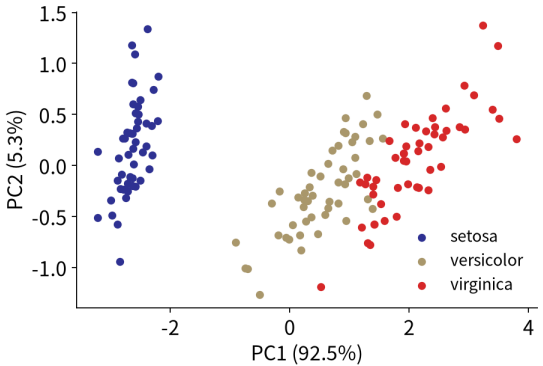
PCA 절차

1. 특징마다 **평균을 뺀다** (단위가 다르면 표준화까지)
2. 공분산 행렬 S 를 구한다 ($d \times d$)
3. 고유값 · 고유벡터를 구해 큰 순서로 정렬
4. 위에서 k 개 방향에 그림자 $\rightarrow$ 숫자 k 개 (설명 분산 비율로 k 를 고른다)

붓꽃 4개 측정값: 그대로 92.5 + 5.3 = **97.8%** 표준화하면 73.0 + 22.9 = 95.9%

꽃잎 길이처럼 cm 값이 큰 특징이 분산을 독차지 $\rightarrow$ 단위가 다르면 표준화가 필요

4차원 붓꽃을 평면에



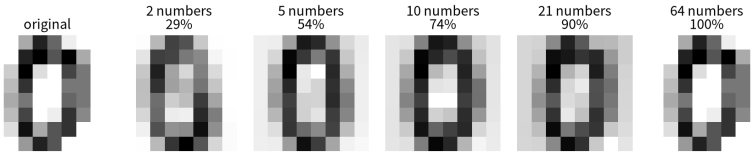
붓꽃 150송이, 측정값 4개
(꽃받침 · 꽃잎의 길이 · 너비)

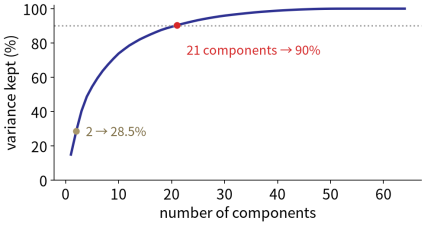
PC1 하나로 setosa 가 **깨끗이** 갈라진다

이름표를 쓰지 않았다: **비지도 학습**

색은 그린 뒤에 칠했다

압축: 손글씨 숫자 64칸을 몇 개로?





1,797장, $8 \times 8 = 64$칸 성분 **21개**로 90% 2개로는 28.5% 뿐

쓰임과 한계

고유얼굴 (1991)	Turk & Pentland: 얼굴 사진의 주성분으로 얼굴 인식
시각화	수십 차원 데이터를 2 · 3차원으로 먼저 그려 본다
전처리	특징을 줄여 다음 모델을 빠르게, 잡음 줄이기
유전체	사람들의 유전 변이 PC1 · PC2 가 지도처럼 출신 지역을 드러낸다

한계: **직선** 방향의 그림자만 휘어진 구조, 뭉친 무리는 놓친다 → t-SNE

문제풀이

1. 고유값이 6, 3, 1 인 3차원 데이터를 2차원으로 줄이면 퍼짐이 몇 % 남나?
2. $S = \begin{pmatrix} 5 & 0 \\ 0 & 1 \end{pmatrix}$ 이면 PC1 방향과 설명 분산 비율은?
3. PC1 이 $(0.77, 0.63)$ 일 때, 평균을 뺀 점수 (10, 10) 인 학생의 PC1 값은?
4. 키 (cm) 와 몸무게 (kg) 를 표준화 없이 PCA 하면 무엇이 문제일까? 키를 mm 로 바꾸면?

실습

1. 학생 점수: 각도별 퍼짐 $\rightarrow$ 공분산 · 고유분해로 PC1 (95%) 직접 구하기
2. `sklearn PCA` 와 비교, 붓꽃 4 $\rightarrow$ 2차원 (표준화 전후)
3. 손글씨 숫자 압축 · 복원: 성분 수 바꾸기

▶ Colab에서 실습 노트북 열기

정리

PCA: 그림자가 **가장 넓게 퍼지는** 방향 = PC1, 그와 수직으로 PC2, $\cdots$

= 공분산 행렬의 고유벡터, 퍼짐 = 고유값 학생 점수: 수학만 59% $\rightarrow$ PC1 95%

평균 빼기 (단위 다르면 표준화) $\rightarrow S \rightarrow$ 고유분해 $\rightarrow$ 위 k 개로 투영

붓꽃 4 $\rightarrow$ 2: 97.8% 숫자 64 $\rightarrow$ 21: 90% 한계: 직선만 $\rightarrow$ t-SNE