train / val / test 와 데이터 누수

시험 데이터는 마지막까지 손대지 않는다

Machine Learning and Deep Learning

한국과학영재학교 (KSA)

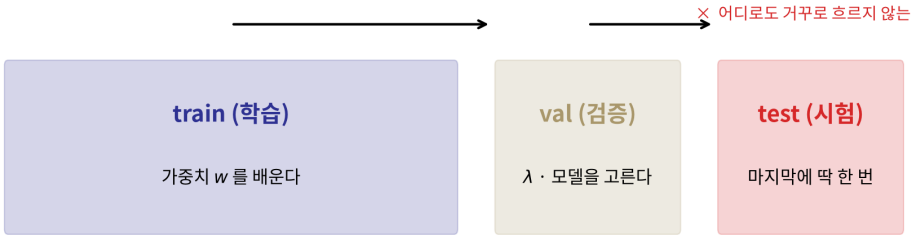
오늘의 질문

100명에게 **아무 뜻 없는 난수** 5,000개씩. 정답은 **동전 던지기**.

이 데이터로 동전 앞뒤를 맞히는 AI: **교차 검증 정확도 87%**

찍으면 50% 가 정상이다. **무엇이 잘못됐을까?**

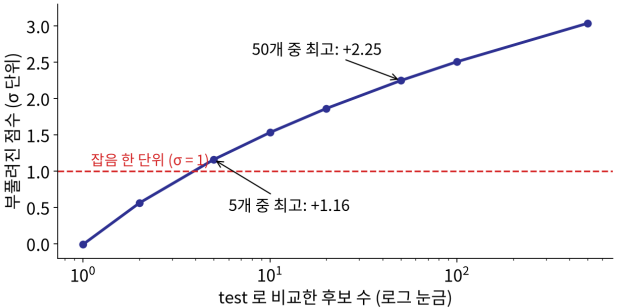
세 데이터의 역할



정보는 **train** → **val** → **test** 한 방향으로만 흐른다

val 은 교차 검증으로 대신할 수 있다 (train 안에서 돌아가며). test 는 **따로 떼어 두고 마지막에 한 번**

test 로 여러 번 고르면: 운이 점수에 섞인다



진짜 실력이 모두 같은 (0) 후보들을 test 로 비교해 최고를 고르면

5개 중 최고: $+1.16\sigma$ 50개 중 최고: $+2.25\sigma$ $\rightarrow$ 후보가 많을수록 더 부풀려진다

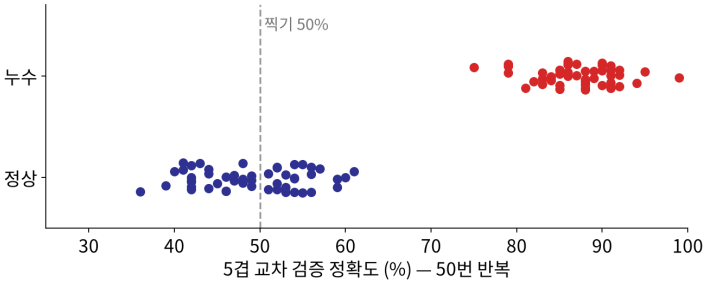
데이터 누수 (Data Leakage)

시험 데이터의 정보가 학습 과정에 **몰래 새어 들어가는 것**

1. 고르기 · 전처리를 **전체 데이터**로 한 뒤에 나눈다
2. 같은 **사람 (환자)** 의 데이터가 학습과 시험 양쪽에 들어간다
3. **미래** 데이터로 학습하고 과거를 시험한다

공통점: 실제로 쓸 때는 **없을** 정보를 시험 때 썼다

누수 1: 전체 데이터로 특징을 고르면



전체 100명으로 숫자 20개를 고른 뒤 교차 검증 → **87%**

고르기를 각 조각의 **학습 80명 안에서만** → **49%** (찍기와 같다)

누수 1: 표준화도 학습 데이터로만

데이터 $1, 2, \ldots, 10$ train $= 1 \sim 7$, test $= 8, 9, 10$

평균 · 표준편차를 구한 곳	평균	표준편차	test 의 z
전체 $1 \sim 10$ (**누수**)	5.5	2.872	0.87, 1.22, 1.57
train $1 \sim 7$ (**정상**)	4.0	2.0	2.0, 2.5, 3.0

test 는 사실 학습 범위 **밖**의 큰 값인데, 누수 통계로 보면 **평범해 보인다**

해결: 전처리도 모델의 일부 $\rightarrow$ train 으로 fit, val · test 에는 apply 만 (scikit-learn `Pipeline`)

누수 2: 같은 환자가 학습과 시험 양쪽에

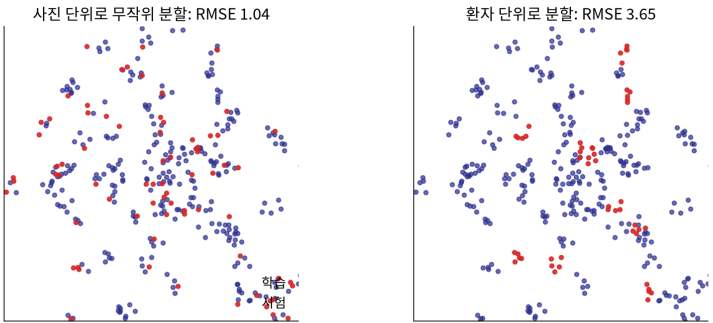
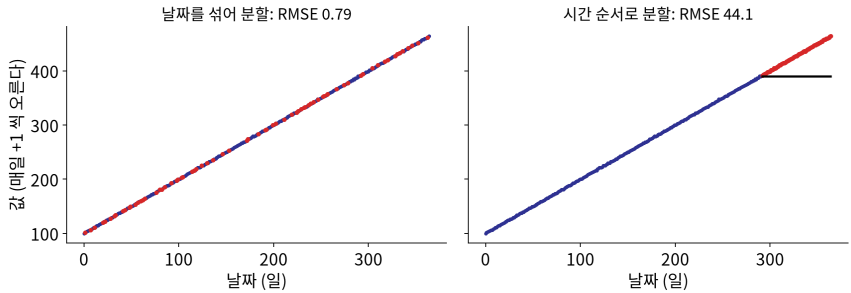


사진 단위로 섞으면 RMSE **1.04** 환자 단위로 나누면 **3.65**

환자 100명 × 사진 5장 (예시). 같은 환자의 다른 사진으로 맞힌 것 = 진단이 아니라 **환자 알아보기**

누수 3: 미래로 과거를 맞히기



날짜를 섞으면 RMSE **0.79**　　시간 순서로 나누면 **44.1**

섞으면 시험 날짜 양옆이 학습 데이터라 사이만 메우면 된다. 실제 예측은 **내일**을 맞히는 일

누수를 막는 규칙

test 를 제일 먼저 떼어 둔다	그래프 그리기보다도 먼저
전처리 · 고르기는 train 으로만	`Pipeline` 으로 묶는다
단위를 지켜 나눈다	사람 · 환자 단위 (`GroupKFold`)
시간을 지켜 나눈다	과거로 학습, 미래로 시험 (`TimeSeriesSplit`)
test 는 딱 한 번	보고 다시 고치면 더 이상 test 가 아니다

질문 하나로 점검: “**실제로 쓸 때도 이 정보가 있을까?**”

전체 흐름: 당뇨병 데이터 442명

1. 나누기: train **265** · val **88** · test **89**
2. 릿지 λ 후보 5개를 train 으로 학습, val 로 비교 $\rightarrow \lambda = 0.1$ (val RMSE 58.07)
3. test 로 **한 번** 잰다 $\rightarrow$ test RMSE **53.79** 이 숫자를 보고한다
4. (잘못) test 로 다시 고르면 $\rightarrow$ 그 숫자는 test 에서 운 좋은 값일 뿐

숫자는 notebooks/ml1/chapter06_3 과 같은 분할 (`random_state=0`)

문제풀이

1. 다음 중 누수인 것을 모두 고르라. (a) 전체 데이터로 결측치를 평균으로 채운 뒤 나눴다 (b) train 으로 구한 평균을 test 결측치에 채웠다 (c) 학생의 1학기 · 2학기 성적을 따로 행으로 두고 무작위로 나눴다
2. 내일 미세먼지를 예측하는 모델을 5겹 교차 검증 (섞음) 으로 평가했더니 아주 좋았다. 어떻게 다시 평가하겠나?
3. 같은 test 로 모델 20개를 비교해 가장 좋은 점수 92% 를 보고했다. 무엇이 문제인가? 어떻게 고치나?

실습

1. 동전 실험 직접 해 보기: 전체로 고르기 vs `Pipeline` (찍기 근처로)
2. 환자 누수 · 시간 누수 재현: `GroupKFold`, `TimeSeriesSplit`
3. 당뇨병 3분할 파이프라인: val 로 고르고 test 는 한 번

Diabetes (Efron et al., 2004; scikit-learn)

▶ Colab에서 실습 노트북 열기

정리

train: 배우기 val (교차 검증): 고르기 **test: 마지막에 한 번**

test 로 여러 번 고르면 운이 섞인다 (50개 중 최고 $+2.25\sigma$)

누수: 전체로 전처리 (87% vs 49%), 같은 환자 (1.04 vs 3.65), 미래 (0.79 vs 44.1)

“실제로 쓸 때도 이 정보가 있을까?”