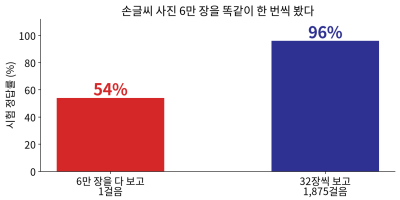
확률적 경사하강법 (SGD)

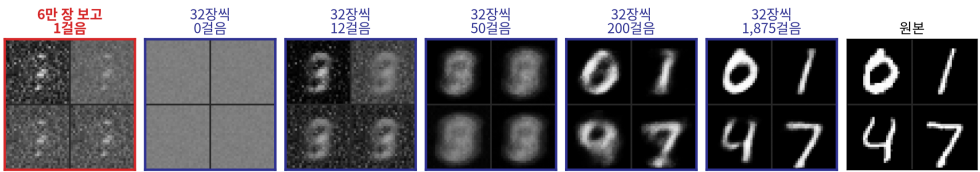
일부만 보고 자주 걷는 경사하강법

Machine Learning and Deep Learning

한국과학영재학교 (KSA)

오늘의 질문





같은 손글씨 사진 6만 장(MNIST)을 한 번씩. 위: 숫자 맞히기 · 아래: 숫자 다시 그리기(오토인코더)

SGD: 6만 장 = 32장 × 1,875걸음

복습: 경사하강법

$$w \leftarrow w - \alpha \frac{\partial J}{\partial w}$$

α: 학습률 (한 걸음의 크기) $\frac{\partial J}{\partial w}$: 비용이 늘어나는 방향

한 걸음마다 $\frac{\partial J}{\partial w}$ 를 새로 구한다

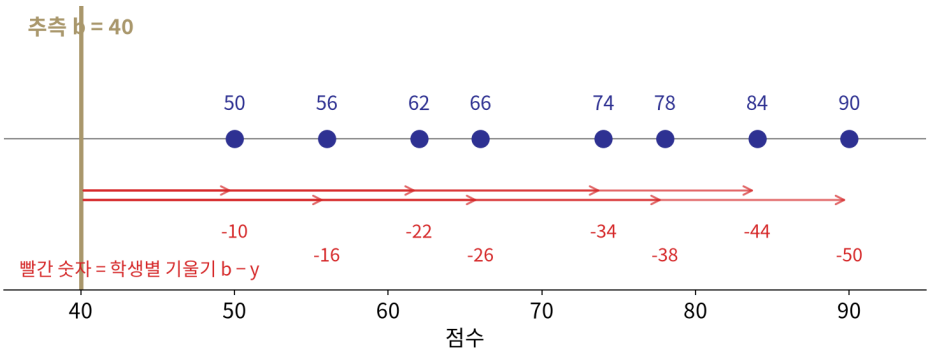
비용은 평균, 기울기도 평균

$$J(w) = \frac{1}{m}\sum_{i=1}^{m} \ell_i(w) \qquad \Rightarrow \qquad \frac{\partial J}{\partial w} = \frac{1}{m}\sum_{i=1}^{m} \frac{\partial \ell_i}{\partial w}$$

ℓ_i: 데이터 i 하나의 손실 m: 데이터 수

전체 기울기 = 데이터 하나하나의 기울기의 평균

가장 단순한 모델로 세어 보기



모델 $\hat{y} = b$ (숫자 하나로 8명의 점수를 맞힌다) 손실 $\ell_i = \frac{1}{2}(b - y_i)^2$ 기울기 $\frac{\partial \ell_i}{\partial b} = b - y_i$

전체 기울기로 한 걸음

점수 y_i	50	56	62	66	74	78	84	90
기울기 $b - y_i$	-10	-16	-22	-26	-34	-38	-44	-50

$$\frac{\partial J}{\partial b} = \frac{-10 - 16 - 22 - 26 - 34 - 38 - 44 - 50}{8} = \textbf{-30}$$

$$b \leftarrow 40 - 0.5 \times (-30) = \textbf{55}$$

학습률 $\alpha = 0.5$ 최적값은 평균 점수 70

문제: 데이터가 많으면?

손글씨 숫자 MNIST	60,000장
사진 분류 ImageNet	1,281,167장

한 걸음 = 사진 전부의 기울기를 구한 뒤에야 한 번

학습은 보통 수천 수만 걸음이 필요하다

아이디어: 몇 명만 뽑아서 어림한다

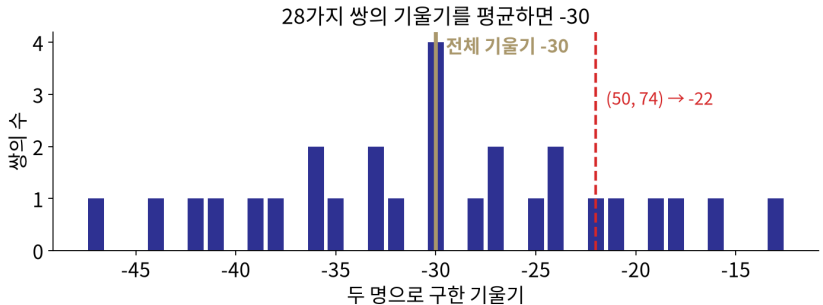
무작위로 2명을 뽑았다: **50점, 74점**

$$g_{\mathcal{B}} = \frac{(40-50)+(40-74)}{2} = \frac{-10-34}{2} = \textbf{-22}$$

	기울기	방향
8명 전체	-30	b 를 올려라
2명 ($\mathcal{B}$)	-22	b 를 올려라

$\mathcal{B}$: 뽑은 데이터 묶음 (미니배치) 값은 다르지만 방향은 같다

28가지 쌍을 모두 세어 보면



8명에서 2명을 고르는 방법 $\binom{8}{2} = 28$가지 하나하나는 틀려도 **평균은 정확히** -30

왜 정확히 같을까: 직접 세기

학생 한 명은 28쌍 중 **7쌍**에 들어간다 (나머지 7명 중 짝 하나를 고른다)

$$\frac{1}{28}\sum_{\text{28쌍}}\frac{g_a+g_b}{2} = \frac{1}{28}\cdot\frac{7}{2}\sum_{i=1}^{8} g_i = \frac{1}{8}\sum_{i=1}^{8} g_i = \frac{\partial J}{\partial b}$$

$g_i = b - y_i$: 학생 i 의 기울기 $\quad \frac{7}{2\cdot 28} = \frac{1}{8}$

유도: 미니배치 기울기의 기댓값

$$g_{\mathcal{B}} = \frac{1}{B}\sum_{i\in\mathcal{B}} g_i$$ 미니배치 기울기

$$\mathbb{E}\big[g_{\mathcal{B}}\big] = \frac{1}{B}\sum_{i=1}^{m} P(i\in\mathcal{B})\, g_i$$ 기댓값의 선형성

$$= \frac{1}{B}\sum_{i=1}^{m} \frac{B}{m}\, g_i$$ m 개 중 B 개를 무작위로

$$= \frac{1}{m}\sum_{i=1}^{m} g_i \;=\; \frac{\partial J}{\partial w}$$ (p.3)

B: 배치 크기 $\quad P(i\in\mathcal{B}) = \dfrac{B}{m}$: 데이터 i 가 뽑힐 확률 (앞 쪽: $\frac{7}{28} = \frac{2}{8}$)

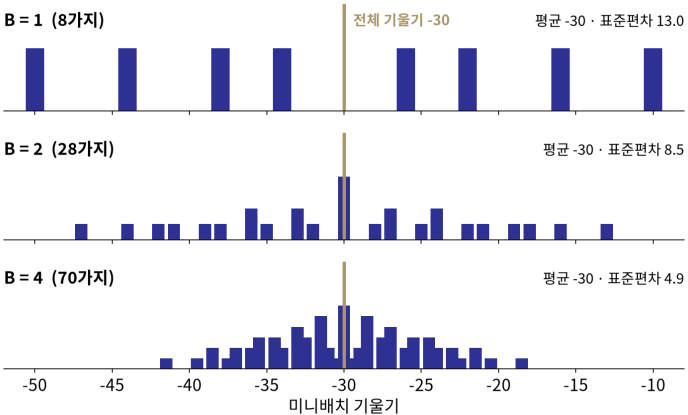
결과

$$\mathbb{E}\left[g_{\mathcal{B}} \right] = \frac{\partial J}{\partial w}$$

미니배치 기울기는 **평균적으로 정확하다**

한 번 한 번은 틀리지만, 틀리는 쪽이 한 방향으로 치우치지 않는다

몇 명을 뽑을까?



평균은 늘 -30. 많이 뽑을수록 덜 흩어진다 표준편차 13.0 $\rightarrow$ 8.5 $\rightarrow$ 4.9

확률적 경사하강법 (SGD)

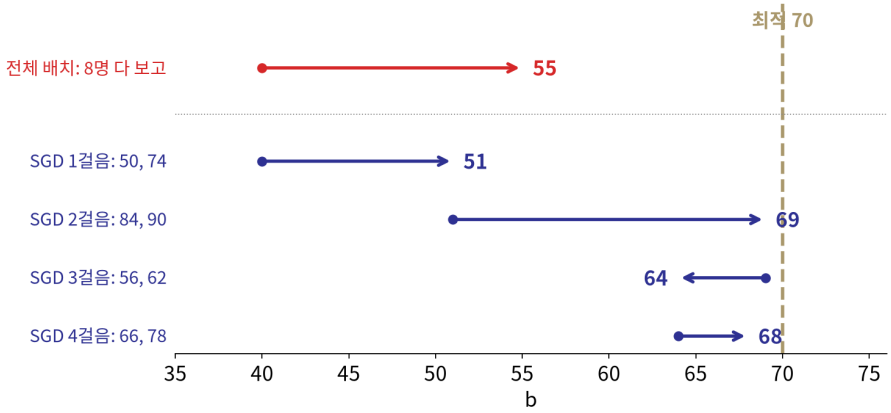
에폭마다 데이터 m 개를 섞는다

앞에서부터 B 개씩 자른 미니배치 $\mathcal{B}$ 마다

$$w \leftarrow w - \alpha\, g_{\mathcal{B}}$$

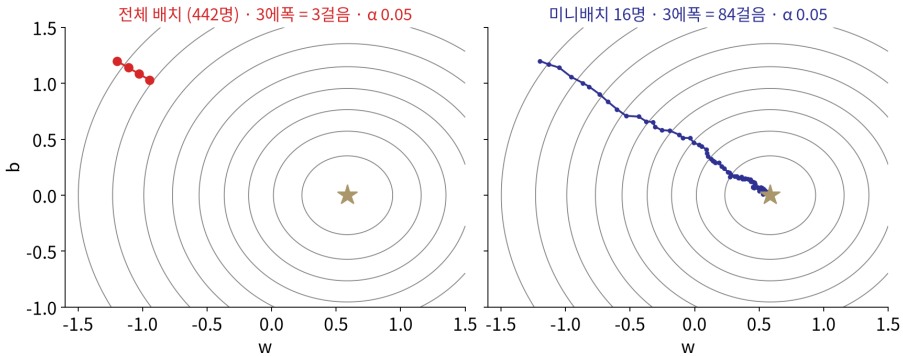
배치 크기	batch size B	한 걸음에 쓰는 데이터 수
걸음	step, iteration	가중치를 한 번 고치는 것
에폭	epoch	데이터 전체를 한 바퀴 $= m/B$ 걸음

1에폭 직접 해 보기 ($B = 2, \alpha = 0.5$)



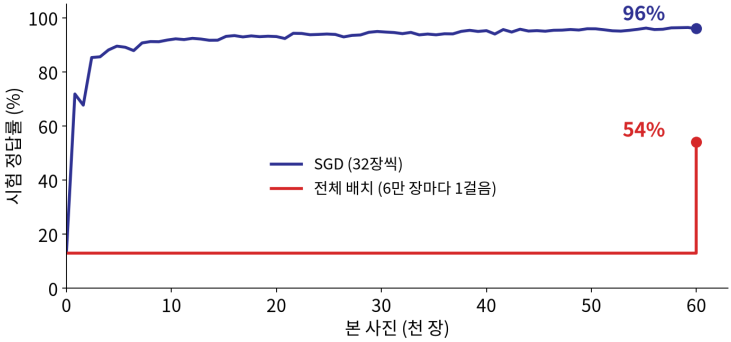
8명을 한 번씩 본 것은 같다. 전체 배치는 **55**, SGD 는 4걸음 만에 **68**

2차원에서 보면



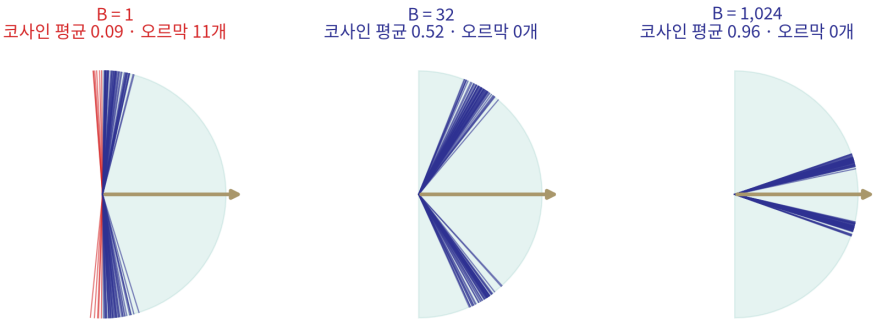
diabetes: BMI 로 1년 뒤 진행 정도 예측, $\hat{y} = wx + b$ 같은 학습률 $\alpha = 0.05$, 같은 3에폭 뒤 비용 J: 전체 배치 2.03, SGD **0.33** (최솟값 0.33)

손글씨 6만 장 (MNIST)



SGD 는 800장(25걸음) 만에 72% 전체 배치로 96% 에 닿으려면 **318걸음 = 318에폭**

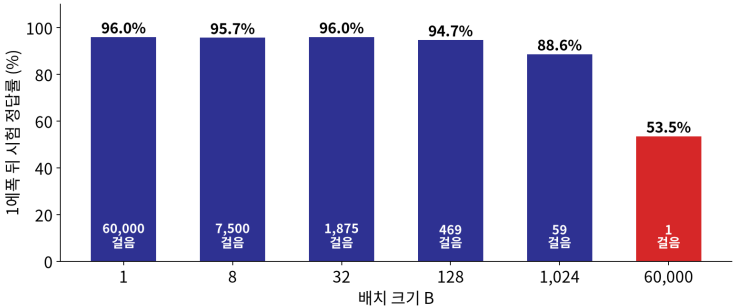
어림인데 왜 될까



금색 = 전체 기울기의 내리막 방향 · 초록 = 내리막 쪽 반 · 빨강 = 오르막을 가리킨 미니배치

학습 전 MNIST 신경망, 배치 크기마다 미니배치 100개의 기울기 방향을 전체 기울기와 비교 (코사인 유사도)

배치 크기 고르기



1에폭 시간 (이 실험의 CPU): $B = 1$ 4.5초, $B = 32$ 0.3초　　같은 6만 장인데 한 장씩은 **15배** 느리다

작은 B: 걸음 많음 · 많이 흔들림　　큰 B: 정확함 · 걸음 적음 · 한 번에 여러 장을 동시에 계산

1951년부터

Robbins · Monro (1951)

Robbins & Monro, A Stochastic Approximation Method, Annals of Mathematical Statistics

틀린 값으로 여러 번 고쳐도 **평균적으로 맞으면** 답에 다가간다

지금의 딥러닝 학습은 거의 모두 미니배치 위에서 걷는다 $\rightarrow$ 이번 주: 모멘텀 · Adam

문제풀이

1. 데이터 50,000개, 배치 크기 100. 1에폭은 몇 걸음인가? 10에폭은?
2. 점수 60, 64, 80, 84 인 4명, 모델 $\hat{y} = b$, 지금 $b = 50$.
   (a) 전체 기울기는? (b) 미니배치 {60, 64} 의 기울기는? (c) $\alpha = 0.5$ 로 (b) 한 걸음 가면 b 는?
3. 4명에서 2명을 고르는 6가지 쌍의 기울기를 모두 구해 평균이 (a) 와 같은지 확인하라.

실습

1 미니배치 기울기 1,000개를 뽑아 평균이 전체 기울기와 같은지 확인 · 배치 크기별 흩어짐

2 SGD 직접 구현 (섞기 · 자르기 · 걷기) 후 전체 배치와 비용 비교

3 PyTorch 로 MNIST 54% vs 96% 재현 · 배치 크기 바꿔 보기

diabetes (442명, scikit-learn 내장) · MNIST 손글씨 (6만 장)

▶ Colab에서 실습 노트북 열기

정리

전체 기울기 데이터 하나하나의 기울기의 평균

미니배치 기울기 B 개만 뽑아 어림, **평균적으로 정확** ($\mathbb{E}[g_{\mathcal{B}}] = \partial J/\partial w$)

SGD 에폭마다 섞고, B 개씩 잘라 걷는다 (1에폭 $= m/B$ 걸음)

배치 크기 작으면 흔들림 · 크면 걸음 수 부족, 속도까지 보고 고른다