Seq2Seq 시퀀스투시퀀스 (Sequence to Sequence)

읽는 신경망 하나, 쓰는 신경망 하나

Machine Learning and Deep Learning

한국과학영재학교 (KSA)

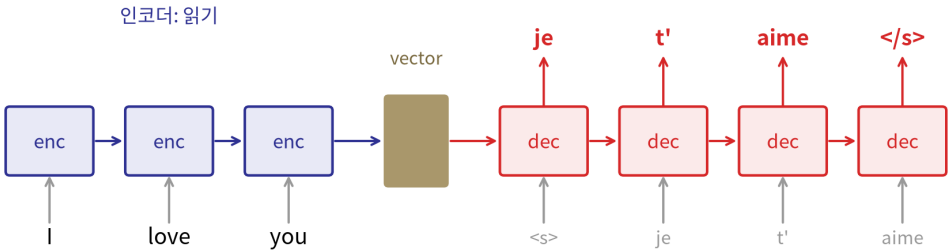
오늘의 질문: 길이가 다른 문장을 어떻게 번역할까?

I love you $\longrightarrow$ Je t'aime

영어 **3**단어 $\rightarrow$ 프랑스어 **2**단어 순서도 다르다 (te = you 가 동사 앞)

앞에서 본 RNN: 한 칸 읽을 때마다 한 칸 내놓는다 $\Rightarrow$ 입력과 출력의 길이가 같아야

Seq2Seq: 다 읽고 나서 쓴다



인코더 RNN 이 문장을 **벡터 하나**로 → 디코더 RNN 이 단어를 하나씩

</s> (끝) 가 나오면 멈춘다 그래서 길이가 달라도 된다

Sutskever, Vinyals, Le (Google, 2014) 같은 해 Cho 외 (GRU 를 제안한 논문) 도 같은 구조

식으로

인코더 $\mathbf{h}_t = \mathrm{RNN}_{\mathrm{enc}}(\mathbf{h}_{t-1}, \mathbf{x}_t), \quad \mathbf{v} = \mathbf{h}_T$

디코더 $\mathbf{s}_0 = \mathbf{v}, \quad \mathbf{s}_k = \mathrm{RNN}_{\mathrm{dec}}(\mathbf{s}_{k-1}, y_{k-1})$

다음 단어 $P(y_k \mid y_{<k}, \mathbf{x}) = \mathrm{softmax}(W\mathbf{s}_k)$

$$P(\mathbf{y} \mid \mathbf{x}) = \prod_k P(y_k \mid y_{<k}, \mathbf{x})$$

손실 = 정답 단어마다 $-\log P$ 를 더한 것 (교차 엔트로피)
입력 문장이 통째로 **벡터 v 하나**를 지나간다

배울 때와 쓸 때

	디코더에 넣는 앞 단어	
배울 때	**정답** 단어 (<s>, je, t')	teacher forcing: 한 번에 모든 칸을 계산
쓸 때	**자기가 쓴** 단어	한 단어씩, 가장 확률 높은 단어를 고른다 (greedy)

논문: 후보 문장 몇 개를 함께 이어 가는 **빔 서치** (beam search) 후보 2개로도 충분

첫 단어를 틀리면 다음 단어도 틀리기 쉽다: 틀린 단어가 다시 입력으로 들어가니까

실험: 영어 숫자 말 → 숫자

0 ∼ 999 를 영어로 쓴 말 → 숫자　800개로 배우고, 본 적 없는 200개로 시험

입력 (단어 1 ∼ 4개)	출력 (글자 1 ∼ 3개)	
six hundred ninety six	696	O
eight hundred one	801	O
forty six	46	O
nine hundred fifty two	952	O
seventy	77	정답 70

시험 정답률 **99.5%** (200개 중 199개)　틀린 1개: **0 이 말에 없는** seventy

논문: 영어 → 프랑스어 (WMT'14)

모델 LSTM **4층** × 1,000칸 문장 하나 = 숫자 **8,000**개 (4층 × **h**, **c** × 1,000)

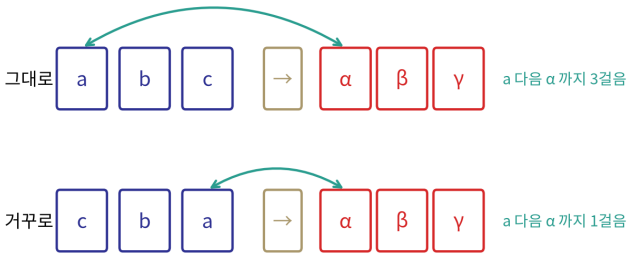
데이터 문장 쌍 1,200만 개

결과 BLEU **34.8** (LSTM 5개 앙상블) vs 기존 통계 번역 33.3

신경망만으로 큰 번역 대회에서 기존 방법을 **처음** 넘었다

BLEU: 기계 번역이 사람 번역과 단어 묶음 (1 ∼ 4단어) 이 얼마나 겹치는지 0 ∼ 100 점

요령: 입력을 거꾸로 넣기

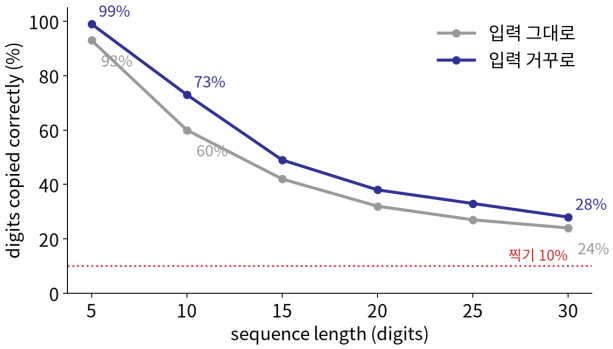


입력 단어 순서만 뒤집었더니 BLEU **25.9** → **30.6**

첫 단어끼리 가까워져 **연결을 배우기 쉬워진다**

뒤 단어끼리는 멀어져서 평균 거리는 같다

실험: 벡터 하나는 비좁다



숫자열을 **그대로 베끼기** 벡터 32칸 (GRU) 길이 5: **93%** → 길이 30: **24%**

통째로 맞힌 비율: 길이 5 에서 89% (거꾸로 99%), 길이 20 부터 0%

한계와 다음 걸음: 어텐션

문장이 길수록 벡터 하나에 다 담기 어렵다 (논문은 거꾸로 넣기 덕에 긴 문장도 버텼다)

Seq2Seq 디코더는 **마지막** 벡터 $\mathbf{v}$ 하나만 본다

어텐션 단어를 쓸 때마다 인코더의 **모든 칸** $\mathbf{h}_1, \ldots, \mathbf{h}_T$ 를 다시 본다

"je" 를 쓸 때는 I 를, "aime" 를 쓸 때는 love 를 주로 본다 $\rightarrow$ 다음 시간

어텐션: Bahdanau, Cho, Bengio (2014)

문제풀이

1. 디코더가 세 단어에 확률 0.5, 0.8, 0.9 를 주고 </s> 에 0.5 를 주었다. 문장 전체의 확률과 손실 ($-\ln$) 은?
2. 입력 a b c d 를 그대로 / 거꾸로 넣을 때, a 를 읽은 뒤 α 를 쓰기까지 각각 몇 걸음?
3. 디코더가 </s> 를 내놓지 못하면 어떻게 될까? 실제로는 어떻게 막을까?
4. 실험 A 에서 “seventy” $\rightarrow$ 77 처럼 틀린 이유를, 출력 길이와 벡터의 관점에서 설명해 보라.

실습

1. 영어 숫자 말 만들기 `words(904)` → nine hundred four, 데이터 준비
2. GRU 인코더-디코더 학습 (teacher forcing) → greedy 로 번역, 틀린 예 보기
3. 숫자열 베끼기: 길이별 정답률, 입력 그대로 vs 거꾸로

▶ Colab에서 실습 노트북 열기

정리

Seq2Seq: 인코더가 문장을 **벡터 하나**로, 디코더가 한 단어씩 </s> 까지

배울 때는 정답 단어를 (teacher forcing), 쓸 때는 자기가 쓴 단어를 넣는다

2014 영어 $\rightarrow$ 프랑스어 BLEU 34.8 > 통계 번역 33.3 거꾸로 넣기 25.9 $\rightarrow$ 30.6

한계: 벡터 하나는 비좁다 (베끼기 93% $\rightarrow$ 24%) 다음: 어텐션