ML1 중간·기말 예상 문제

각 덱의 핵심 개념과 계산을 확인하는 연습용 문제입니다. 제목을 누르면 풀이가 펼쳐집니다. 실제 시험 문항이 아니며, 범위는 Syllabus의 주차 구성을 따릅니다.

중간고사 예상 문제 · 1~7주차

고전 기계학습과 신경망 기초(역전파까지). 계산기 없이 풀 수 있게 숫자를 맞췄습니다.

1 분류 지표 계산 — 3주차

혼동행렬이 TP=40, FP=10, FN=20, TN=130 이다. 정확도, 정밀도, 재현율, F1 을 구하고, 질병 검사에서 재현율이 더 중요한 이유를 한 줄로 쓰시오.

풀이 정확도 = 170/200 = 0.85. 정밀도 = 40/50 = 0.8. 재현율 = 40/60 ≈ 0.667. F1 = 2TP/(2TP+FP+FN) = 80/110 ≈ 0.727. 환자를 놓치는 것(FN)이 건강한 사람을 한 번 더 검사하는 것(FP)보다 훨씬 위험하기 때문이다.

2 최소제곱 직선 — 2주차

점 (1,2), (2,4), (3,5) 에 직선 $y = wx + b$ 를 최소제곱으로 맞추시오.

풀이 x 평균 2, y 평균 11/3. Sxy = (−1)(−5/3)+0+(1)(4/3) = 3, Sxx = 2 이므로 w = 3/2 = 1.5, b = 11/3 − 1.5·2 = 2/3 ≈ 0.667.

3 경사하강법 두 걸음 — 2주차

$L(w) = (w-3)^2$ 을 $w_0 = 0$, 학습률 0.25 로 두 번 갱신한 w_2 를 구하시오. 학습률을 1.5 로 키우면 어떻게 되는가?

풀이 $L' = 2(w-3)$. $w_1 = 0 - 0.25\cdot(-6) = 1.5$. $w_2 = 1.5 - 0.25\cdot(-3) = 2.25$. 학습률 1.5 이면 $w_1 = 9$ 로 최솟값을 넘어가고, 매 걸음 오차가 2배씩 커져 발산한다. (학습률 1 이면 0 과 6 사이만 오가며 수렴하지 못한다.)

4 교차 엔트로피 — 2주차

정답 클래스에 모델이 확률 0.8 을 준 경우와 0.1 을 준 경우의 손실 $-\ln p$ 를 각각 구하고($\ln 0.8 \approx -0.223$, $\ln 0.1 \approx -2.303$), 손실이 더 큰 쪽이 왜 학습에 더 센 신호가 되는지 설명하시오.

풀이 0.223 과 2.303. 틀리게 확신할수록 손실이 크게 늘고($-\ln p$ 는 $p \to 0$ 에서 무한대), 소프트맥스와 함께 쓰면 기울기가 (예측 − 정답) 이 되어 많이 틀린 만큼 크게 고친다.

5 과대적합 진단

3주차

다항식 차수를 1, 3, 15 로 올렸더니 학습 오차는 0.9, 0.4, 0.01 이고 검증 오차는 1.0, 0.5, 2.3 이었다. 각 차수의 상태를 진단하고, 차수 15 모델을 고치는 방법 두 가지를 쓰시오.

> **풀이** 차수 1 은 과소적합(둘 다 큼), 3 은 적절, 15 는 과대적합(학습 ≪ 검증). 해결: 데이터 늘리기, 정규화(L1/L2), 모델 단순화, 조기 종료 중 둘.

6 SVM 마진

3주차

결정경계 $w \cdot x + b = 0$ 에서 $w = (3, 4)$ 일 때 마진 폭(양쪽 서포트 벡터 사이 거리)은? 서포트 벡터가 아닌 점을 지워도 경계가 변하지 않는 이유는?

> **풀이** 폭 $= 2/\|w\| = 2/5 = 0.4$. 경계는 마진 위에 놓인 서포트 벡터들만으로 정해지고, 나머지 점의 제약은 이미 여유 있게 만족되므로 해가 달라지지 않는다.

7 엔트로피와 정보 이득

4주차

양성 5, 음성 5 인 노드를 (양성 4, 음성 0) 과 (양성 1, 음성 5) 로 나눴다. 정보 이득을 구하시오. 같은 노드에서 (양성 6, 음성 2) 의 지니 불순도는? ($\log_2 6 \approx 2.585$, $\log_2 1.2 \approx 0.263$)

> **풀이** 부모 엔트로피 = 1. 왼쪽 0. 오른쪽 $H = (1/6)(2.585) + (5/6)(0.263) \approx 0.431 + 0.219 = 0.650$. 가중평균 $= 0.6 \cdot 0.650 = 0.390$. 정보 이득 ≈ 0.61. 지니 $= 1 - (0.75^2 + 0.25^2) = 0.375$.

8 랜덤 포레스트와 GBDT

4주차

두 방법이 나무를 합치는 방식의 차이를 쓰고, 각각 어떤 오차(편향/분산)를 주로 줄이는지 쓰시오.

> **풀이** 랜덤 포레스트는 부트스트랩과 특징 무작위 선택으로 서로 다른 깊은 나무를 병렬로 만들어 평균내므로 분산을 줄인다. GBDT 는 얕은 나무를 순서대로 쌓으며 앞선 모델의 잔차(손실의 기울기)를 다음 나무가 맞추므로 편향을 줄인다.

9 나이브 베이즈

5주차

스팸 비율 0.4, 단어 w 가 스팸에 나올 확률 0.5, 정상 메일에 나올 확률 0.1 이다. w 가 있는 메일이 스팸일 확률은? 나이브 베이즈의 '나이브'는 무슨 가정인가?

> **풀이** $(0.4 \cdot 0.5)/(0.4 \cdot 0.5 + 0.6 \cdot 0.1) = 0.2/0.26 \approx 0.769$. 클래스가 주어지면 특징들이 서로 조건부 독립이라는 가정.

10 정규화와 교차검증 5주차

(a) L1 과 L2 정규화가 가중치에 주는 효과의 차이를 쓰시오. (b) 100 개 데이터에 5-겹 교차검증을 하면 한 번에 학습·검증에 쓰는 개수는? (c) 하이퍼파라미터를 검증 점수로 고른 뒤 같은 검증 점수를 최종 성능으로 보고하면 안 되는 이유는?

> **풀이** (a) L1 은 일부 가중치를 정확히 0 으로 만들어 특징을 고르고, L2 는 모든 가중치를 고르게 작게 줄인다. (b) 학습 80, 검증 20. (c) 검증 점수에 맞춰 골랐으니 낙관적으로 치우친다(누수). 건드리지 않은 테스트 세트에서 한 번만 재야 한다.

11 k-means 한 번 돌리기 6주차

1차원 점 1, 2, 9, 10 을 중심 1 과 2 에서 시작해 한 번 갱신하시오. 수렴할 때까지 돌리면 최종 중심은?

> **풀이** 할당: 1 → 중심 1, 나머지 2, 9, 10 → 중심 2. 갱신: 중심 1, 중심 (2+9+10)/3 = 7. 다시 할당하면 2 가 중심 1 쪽(거리 1 대 5)으로 옮겨져 {1,2} 와 {9,10} 이 되고, 최종 중심은 1.5 와 9.5.

12 PCA 6주차

공분산 행렬의 고유값이 6, 3, 1 이다. 첫 두 주성분이 설명하는 분산 비율은? PCA 전에 특징을 표준화하는 이유는?

> **풀이** (6+3)/10 = 90%. 단위가 큰 특징이 분산을 지배해 주성분이 그 방향으로만 쏠리는 것을 막기 위해.

13 역전파 손으로 계산 7주차

$h = \mathrm{ReLU}(w_1 x)$, $\hat{y} = w_2 h$, 손실 $L = \tfrac{1}{2}(\hat{y} - t)^2$. $x = 2$, $w_1 = 0.5$, $w_2 = 3$, $t = 4$ 일 때 $\partial L/\partial w_2$ 와 $\partial L/\partial w_1$ 을 구하시오.

> **풀이** 순전파: $h = \mathrm{ReLU}(1) = 1$, $\hat{y} = 3$, $L = 0.5$. $\partial L/\partial \hat{y} = \hat{y} - t = -1$. $\partial L/\partial w_2 = -1 \cdot h = -1$. $\partial L/\partial h = -1 \cdot w_2 = -3$, $\mathrm{ReLU}'(1) = 1$ 이므로 $\partial L/\partial w_1 = -3 \cdot 1 \cdot x = -6$.

14 기울기 소실 7주차

시그모이드의 도함수 최댓값은 0.25 이다. 10 층을 연쇄 법칙으로 거치면 기울기는 최대 얼마로 줄어드는가? ReLU 가 이를 어떻게 완화하는가?

> **풀이** $0.25^{10} \approx 9.5 \times 10^{-7}$. ReLU 는 양수 구간의 도함수가 1 이라 층을 지나도 기울기가 줄지 않는다(음수 구간은 0 이 되는 대가).

15 **SGD 와 Adam** 7주차

(a) 데이터 1000 개, 배치 50 이면 1 에폭에 파라미터를 몇 번 갱신하는가? (b) 모멘텀과 Adam 이 보통 경사하강법보다 나은 점을 각각 한 줄로 쓰시오.

> **풀이** (a) 20 번. (b) 모멘텀은 이전 방향을 누적해 골짜기에서 진동을 줄이고 평평한 구간을 빨리 지난다. Adam 은 기울기의 이동평균과 제곱의 이동평균으로 파라미터마다 학습률을 자동으로 조절한다.

기말고사 예상 문제 · 9~15주차

CNN 에서 트랜스포머, 표현 학습, 생성 모델까지.

1 합성곱 출력 크기와 파라미터

9주차

입력 32×32×3 에 5×5 필터 16 개(스트라이드 1, 패딩 0)를 적용한 출력 크기와 파라미터 수(편향 포함)를 구하시오. 이어서 2×2 최대 풀링을 하면?

풀이 출력 $(32-5)/1+1 = 28$ 이므로 28×28×16. 파라미터 $5\cdot5\cdot3\cdot16 + 16 = 1216$. 풀링 후 14×14×16. 풀링에는 학습 파라미터가 없다.

2 패딩과 스트라이드

9주차

입력 32, 필터 5, 패딩 2, 스트라이드 2 일 때 출력 한 변의 길이는? 입력과 같은 크기를 유지하려면 스트라이드 1 에서 패딩이 몇이어야 하는가?

풀이 $\lfloor (32 + 4 - 5)/2 \rfloor + 1 = 15 + 1 = 16$. 같은 크기는 패딩 2 ($(5-1)/2$).

3 ResNet 의 잔차 연결

9주차

$y = x + F(x)$ 일 때 $\partial y/\partial x$ 를 쓰고, 이것이 깊은 망의 학습을 쉽게 하는 이유를 설명하시오.

풀이 $\partial y/\partial x = 1 + \partial F/\partial x$. F 의 기울기가 작아져도 1 이 더해져 기울기가 입력까지 거의 그대로 전달된다. 또 F 가 0 이 되면 항등 함수이므로 층을 더해도 성능이 나빠지지 않게 학습하기 쉽다.

4 배치 정규화

9주차

한 배치의 한 채널 값이 2, 4, 6, 8 이다. 정규화한 값(ε 무시)을 구하시오. 추론 시에는 배치 평균·분산 대신 무엇을 쓰는가?

풀이 평균 5, 분산 $(9+1+1+9)/4 = 5$, 표준편차 ≈ 2.236. 값은 $\approx -1.34, -0.45, 0.45, 1.34$. 추론 시에는 학습 중 모아 둔 이동평균 통계를 쓴다.

5 드롭아웃

9주차

$p = 0.5$ 드롭아웃에서 학습 때 살아남은 뉴런 출력에 2 를 곱하는(inverted dropout) 이유와, 추론 때의 처리를 쓰시오.

풀이 절반이 꺼지므로 다음 층에 들어가는 합의 기댓값이 절반으로 줄어든다. 2 를 곱해 학습 때와 기댓값을 맞춘다. 추론 때는 드롭아웃을 끄고 모든 뉴런을 그대로 쓴다.

6 임베딩과 시각화 — 10주차

(a) 벡터 (1,0) 과 (1,1) 의 코사인 유사도는? (b) t-SNE 그림에서 군집 사이의 거리와 군집의 크기를 곧이곧대로 해석하면 안 되는 이유는? (c) word2vec 은 무엇을 맞히며 학습하는가?

> **풀이** (a) $1/\sqrt{2} \approx 0.707$. (b) t-SNE 는 가까운 이웃 관계를 보존하도록 지도를 그려서 먼 거리와 크기는 의미가 없고, 매개변수(perplexity)에 따라 모양이 달라진다. (c) 주변 단어 (또는 가운데 단어).

7 RNN 파라미터 수 — 11주차

입력 2, 은닉 3 인 단순 RNN 의 파라미터 수(편향 포함)는? 같은 크기의 LSTM 은? LSTM 이 긴 문장에서 기울기 소실을 줄이는 이유는?

> **풀이** RNN: $3\cdot2 + 3\cdot3 + 3 = 18$. LSTM 은 게이트 3개와 후보 1개로 4배, 72. 셀 상태가 덧셈으로 갱신되고 망각 게이트가 1 에 가까우면 기울기가 거의 그대로 흐르기 때문.

8 어텐션 계산 — 12주차

질의 $q = (1,0)$, 키 $k_1 = (1,0)$, $k_2 = (0,1)$, 값 $v_1 = (10,0)$, $v_2 = (0,10)$, $d_k = 2$ 이다. 스케일 점곱 어텐션의 가중치와 출력을 구하시오($e^{0.707} \approx 2.03$).

> **풀이** 점수 $= (1, 0)/\sqrt{2} = (0.707, 0)$. 소프트맥스: $2.03/(2.03+1) \approx 0.67, 0.33$. 출력 $= 0.67\cdot(10,0) + 0.33\cdot(0,10) \approx (6.7, 3.3)$. $\sqrt{d_k}$ 로 나누는 이유는 점곱이 차원에 따라 커져 소프트맥스가 포화되는 것을 막기 위해서다.

9 트랜스포머의 구성 — 12주차

(a) 셀프 어텐션에 위치 인코딩이 필요한 이유는? (b) 길이 n 인 입력에서 셀프 어텐션의 계산량은 n 에 대해 어떻게 늘어나는가? (c) BERT 와 GPT 의 학습 목표 차이는?

> **풀이** (a) 어텐션은 단어 순서를 모르는 집합 연산이라 “Dog bites man” 과 “Man bites dog” 를 구분하지 못한다. (b) n^2 에 비례(모든 쌍의 점수). (c) BERT 는 가려진 단어 맞히기(양방향), GPT 는 다음 단어 맞히기(왼쪽에서 오른쪽).

10 그래프 합성곱 — 13주차

노드 A 의 특징이 2 이고 이웃 B, C 의 특징이 4, 6 이다. 자기 자신을 포함한 평균 집계를 한 층 한 뒤 A 의 값은? 층을 너무 많이 쌓으면 어떤 문제가 생기는가?

> **풀이** $(2+4+6)/3 = 4$. 층이 깊어지면 모든 노드의 값이 비슷해지는 과평활(over-smoothing)이 생긴다.

11 VAE 와 KL 발산 14주차

인코더가 $N(\mu, \sigma^2) = N(1, 1)$ 을 내놓았다. $N(0,1)$ 과의 KL 은? ($KL = \frac{1}{2}(\sigma^2 + \mu^2 - 1 - \ln \sigma^2)$) 이 항이 VAE 손실에서 하는 역할은?

> **풀이** $\frac{1}{2}(1 + 1 - 1 - 0) = 0.5$. 잠재 공간이 표준 정규분포 근처에 모이게 해서, 무작위로 뽑은 z 도 디코더가 그럴듯한 그림으로 바꿔 주게 한다(재구성 항과의 균형).

12 GAN 과 확산 모델 14주차

(a) GAN 에서 생성자가 완벽할 때 판별자의 출력은? (b) 모드 붕괴란? (c) 확산 모델에서 $\bar{\alpha}_t = 0.64$ 이면 $x_t = \sqrt{\bar{\alpha}_t}\cdot x_0 + \sqrt{(1-\bar{\alpha}_t)}\cdot \varepsilon$ 의 두 계수는?

> **풀이** (a) 진짜와 가짜를 구분할 수 없어 0.5. (b) 생성자가 판별자를 속이기 쉬운 몇 가지 결과만 반복해서 다양성을 잃는 현상. (c) 0.8 과 0.6 ($0.8^2 + 0.6^2 = 1$ 이라 분산이 유지된다).

13 사전학습 언어 모델 15주차

BERT 를 감성 분류에 쓰는 두 단계(사전학습, 미세조정)를 설명하고, 미세조정에 데이터가 적어도 되는 이유를 쓰시오.

> **풀이** 사전학습: 라벨 없는 큰 글 모음에서 가려진 단어를 맞히며 언어 일반을 배운다. 미세조정: 적은 라벨 데이터로 분류 머리를 붙여 전체를 조금 다시 학습한다. 사전학습에서 이미 단어와 문장 구조의 표현을 얻었으므로 새로 배울 양이 적다.