Machine Learning 2: 강화학습 2027. X. XX (예정)

기말 프로젝트 공고 (샘플)

Fall 2027

1. 프로젝트 개요

9∼15주차에서 배운 심층강화학습 도구(함수근사와 DQN, 정책기반 강화학습, PPO, 모방학습과 RLHF, 로봇 시뮬레이션, MCTS)를 **연속제어 환경**에 직접 적용하는 학기 후반 8주에 걸쳐 진행하는 팀 프로젝트이다. 목표는 "좋은 정책을 만드는 것" 자체가 아니라, **그 성능 숫자를 정직하게 얻는 절차**를 실제로 수행하고 보고하는 것이다.

진행 순서: **환경 고르기** → **Abstract** → **구현** → **평가** → **보고서 제출** → **동료평가**. 이 과정에서 "시드 ≥ 3 · 무작위 정책 베이스라인 · 학습/평가 분리"라는 실험 프로토콜을 지켜야 한다.

2. 필수 요구사항

- **환경**: PyBullet 또는 Gymnasium의 연속제어(또는 이산제어) 환경 중 하나 (아래 3절 후보 참고, 팀별로 다른 환경 선택 가능).
- **적용 알고리즘**: 9∼15주차 중 **최소 1개**의 방법(DQN, PPO, 모방학습, MCTS 등)으로 정책을 학습한다.
- **수식적 정당화 최소 1개**: 배운 개념(예: PPO 클리핑의 안정성 효과, 모방학습의 복합 오차, 도메인 무작위화의 sim-to-real 격차 완화)으로 "왜 이 결과가 나왔는지"를 설명해야 한다.
- **학습 곡선 필수 제시**: 에피소드별 누적 보상 곡선은 "학습이 실제로 되고 있는가"를 보여주는 기본 증거이다.
- **베이스라인 필수**: 무작위 정책의 평균 리턴을 먼저 측정해, "배운 정책이 실제로 무작위보다 나은가"를 판정할 기준점을 마련한다.
- **시드** ≥ 3, 모든 시드에 **동일한 평가 프로토콜**(학습 후 결정적 정책 $a = \mu$, 동일 에피소드 수)을 적용한다.

3. 환경 후보 (예시)

환경	상태×행동	보상 구조	잘 어울리는 개념
Pendulum-v1	3×1 (연속)	항상 음수, 0이 완벽	PPO 클리핑 효과
CartPole-v1	4×2 (이산)	생존 시 −1, 쓰러지면 종료	DQN vs PPO 비교
MountainCar-v0	2×3 (이산)	스텝당 −1 (희소)	GAE λ 트레이드오프
HumanoidStandup-v5	348×17 (연속)	포텐셜 기반 shaping	도메인 무작위화, MuJoCo

환경은 임의로 고르지 않는다. "검증하고 싶은 개념이 돋보이는 무대가 무엇인가"를 기준으로 알고리즘과 환경을 짝짓는다 — 예를 들어 PPO 클리핑의 효과를 보이고 싶다면 연속 행동 공간인 Pendulum이, 도메인 무작위화 효과를 보이고 싶다면 물리적으로 더 풍부한 MuJoCo 환경이 적합하다.

4. 일정 (후반 8주)

시기	해야 할 일	제출
기말 1주(9주차)	팀 구성, 환경 후보 2∼3개 조사	
기말 2주(10주차)	문제 정의(MDP 5요소, 주 지표), 환경, 무작위 정책 베이스라인, 적용할 심층 알고리즘 계획	**Abstract** (1p)
기말 3∼5주	알고리즘 구현, 시드 3개 이상 실행, 하이퍼파라미터 조정(모든 시드에 동일), 학습 곡선	
기말 6주(14주차)	보고서 완성, 영상 제작	**보고서 + 영상 제출**: 보고서 PDF + 코드 + **영상** + 학습 곡선 + 시드 비교표
기말 7주(15주차)	제출된 다른 팀 보고서 읽기	
기말 8주(16주차, 기말고사 기간)	다른 팀 2개에 대한 peer-review 작성	**동료평가** 제출 (리뷰 2건)

5. 보고서 구조

1. **문제 정의** (0.5p): MDP 5요소, 상태·행동 차원과 범위, 전이·보상(이론적 리턴 범위 포함), 할인율, 주 지표(학습 후 결정적 평가의 평균 리턴), 베이스라인.
2. **알고리즘 선택과 이유** (1p): 왜 이 환경에 이 알고리즘을 골랐는가, 하이퍼파라미터와 그 선택 근거.

3. **실험 프로토콜** (1p): 시드 목록, 학습 예산, 평가 프로토콜(결정적 $a = \mu$, 에피소드 수, 모든 시드 동일) 명시.

4. **결과** (1p): 시드 비교표, 학습 곡선 1장(여러 시드를 함께 표시), 같은 정책의 여러 측정치(학습 도중/결정적/베이스라인) 비교.

5. **수식적 정당화** (1p): 배운 개념 1개 이상으로 "왜 이 결과가 나왔는지" 설명.

6. **재현 방법** (0.5p): 환경 버전, 시드 목록, 에피소드 수, 하이퍼파라미터, 실행 명령. 다른 사람이 같은 곡선을 다시 얻을 수 있어야 한다.

7. **한계와 잘 안 된 부분** (0.5p, **필수**): 안 된 부분이 없었다면 무엇을 시도했다가 잘 안 됐는지를 쓴다.

6. 채점 기준 (Rubric)

다섯 항목을 각 20%로 채점한다. 목적은 "좋은 정책"이 아니라 **주장을 정직하고 재현 가능하게 입증**하는 것이다.

항목	비중	좋은 답
1. 주장의 명확성 (clarity)	20%	무엇을 주장하는지 첫 문단에서 한 문장으로 알 수 있고, MDP 5요소·주 지표가 명확하며, 결과가 주장과 이어짐
2. 비교 대상 (baseline)	20%	무작위 정책과 표 기반 또는 단순 알고리즘 베이스라인이 같은 시드·같은 평가 프로토콜로 비교되고, "왜 심층 강화학습이 필요한가"에 숫자로 답함
3. 확장성 (scalability)	20%	다른 환경 하나(또는 환경 난이도 변경)에서도 결론이 유지되는지 확인하고, 구성 요소 제거·민감도 실험으로 어디까지 통하는지 보임
4. 재현성 (reproducibility)	20%	환경 버전·시드 목록·에피소드 수·평가 프로토콜·하이퍼파라미터·실행 방법이 적혀 있어 다른 사람이 같은 곡선을 다시 얻을 수 있음
5. 한계의 솔직함 (limitations)	20%	불안정했던 시드·구간, 약한 가정, 통하지 않을 환경 조건을 숨기지 않고 원인을 진단함. 성능이 낮아도 한계가 정직하면 높은 점수

시드 하나만 보여 주거나, 무작위 정책 비교가 없거나, 재현이 불가능하면 크게 감점받는다.

7. 동료평가 (Peer-Review)

- **Peer-Review**: 기말 8주차에 다른 두 팀의 보고서에 대해 작성 리뷰를 각 1통씩 제출한다. 각 리뷰는 아래 5항목 체크리스트와, 반박 가능한 질문을 1개 이상 포함해야 한다.

Peer-Review 체크리스트 (채점 기준과 같은 5항목)

항목	확인할 것
주장의 명확성 (clarity)	무엇을 주장하는지 분명하게 썼는가
비교 대상 (baseline)	비교 대상이 있는가 (무작위 정책과 단순 알고리즘 포함)
확장성 (scalability)	다른 환경에도 적용 가능한가
재현성 (reproducibility)	다른 사람이 다시 해 볼 수 있는가
한계 (limitations)	한계를 솔직하게 적었는가

8. 자주 하는 실수 (미리 확인할 것)

1. 시드 1개만 돌리고 결론을 내리는 것 (시드 간 편차가 방법 간 차이보다 클 수 있다).
2. 학습 도중의 리턴(탐험 포함)을 최종 정책 성능으로 보고하는 것.
3. 최종 평가 수치가 예뻐질 때까지 하이퍼파라미터를 계속 조정하는 것(평가에 대한 과적합).
4. 베이스라인 없이 "잘 배웠다"고 주장하는 것.
5. 결정적 평가가 샘플링 평가보다 낮게 나오는 것을 버그로 오해하는 것 (정상적인 현상일 수 있다).

9. 팀 구성 및 제출 방식

- **팀 구성**: 팀당 인원 및 팀 편성 방식은 추후 공지 (예: 팀당 1~3인, 자유 구성 또는 무작위 배정).
- **제출물**: Abstract(기말 2주), 보고서(PDF)와 코드, **영상**(기말 6주), peer-review 2건 (기말 8주). 영상은 문제, 방법, 결과, 한계를 설명하는 영상 1편이며, 길이와 형식은 추후 공지한다.
- **제출 방법 및 마감**: 추후 공지 (LMS/과제 제출 시스템 및 마감 일시는 별도 안내 예정).