섀넌 엔트로피 (Shannon Entropy)

놀라움을 숫자로, 그리고 결정 트리의 정보 이득

Machine Learning 1

한국과학영재학교 (KSA)

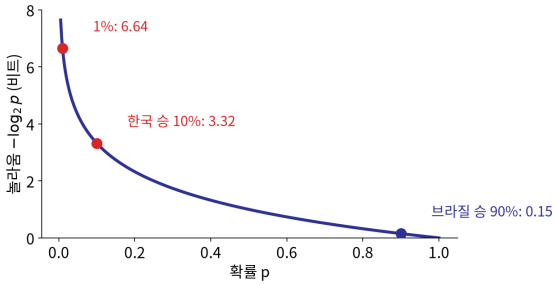
오늘의 질문

브라질이 한국을 이기면 → 그러려니

한국이 브라질을 이기면 → **온 나라가 난리**

같은 “경기 결과 하나”인데 왜 무게가 다를까? **놀라움을 숫자로 잴 수 있을까?**

놀라움 (정보량): 드물수록 크다



$$I(x) = -\log_2 p(x)$$

브라질 승 (90%)	0.15 비트
반반 (50%)	1 비트
한국 승 (10%)	**3.32 비트**
1% 사건	6.64 비트

왜 하필 로그일까

독립인 두 사건이 함께 일어날 확률은 **곱** 그런데 놀라움은 **더해져야** 자연스럽다

$$-\log_2(p_1 p_2) = -\log_2 p_1 - \log_2 p_2$$

동전 한 번 앞면: 1 비트 동전 세 번 모두 앞면 ($\frac{1}{8}$): **3 비트**

1 비트 = 예 · 아니오 질문 하나의 답 8 가지 중 하나 = 질문 3 번 ($2^3 = 8$)

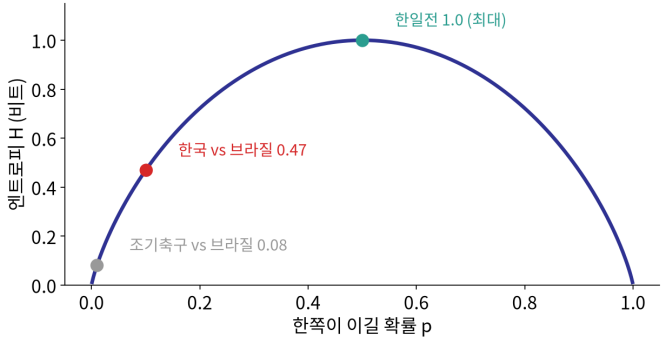
엔트로피 = 놀라움의 평균

$$H = \sum_i p_i \cdot \left(-\log_2 p_i \right) = -\sum_i p_i \log_2 p_i$$

한국 vs 브라질: $0.9 \times 0.15 + 0.1 \times 3.32 = \mathbf{0.47}$ 비트

경기를 보기 **전**, 결과가 평균적으로 얼마나 놀라울지 = 불확실함의 크기

팽팽할수록 엔트로피가 크다



조기축구 vs 브라질 (1%): **0.08** 한국 vs 브라질: 0.47 한일전 (반반): **1.0, 최대**

조기축구팀이 이기면 놀라움은 6.64 로 크지만, 1% 라서 평균에는 거의 기여하지 않는다

결과가 여러 개면

경우	확률	엔트로피
동전	$\frac{1}{2}, \frac{1}{2}$	1
세 종 붓꽃 (50송이씩)	$\frac{1}{3}, \frac{1}{3}, \frac{1}{3}$	$\log_2 3 = 1.585$
주사위	$\frac{1}{6} \times 6$	$\log_2 6 = 2.585$
날씨 (맑음, 흐림, 비, 눈)	$\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}$	**1.75**

k 가지가 모두 같은 확률이면 $\log_2 k$ 로 최대 고르지 않으면 더 작다

엔트로피 = 평균 질문 수

날씨 맞히기 스무고개: "맑음?" → "흐림?" → "비?"

날씨	확률	필요한 질문	확률 × 질문
맑음	$\frac{1}{2}$	1	0.5
흐림	$\frac{1}{4}$	2	0.5
비	$\frac{1}{8}$	3	0.375
눈	$\frac{1}{8}$	3	0.375
		평균	**1.75**

흔한 것부터 물으면 평균 질문 수 = 엔트로피 (압축 · 부호화의 원리)

결정 트리에서: 정보 이득

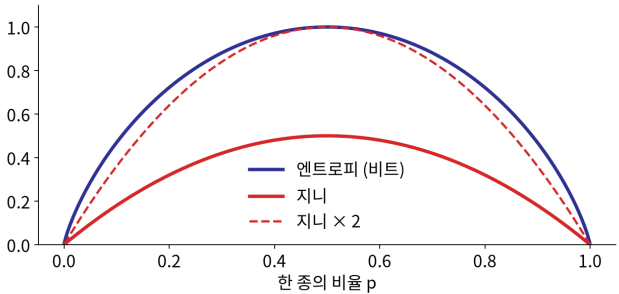
정보 이득 = 질문 전 엔트로피 − 질문 후 엔트로피 (꽃 수로 가중 평균)

$$\text{꽃잎 길이} < 2.45: \quad 1.585 - \left(\frac{50}{150} \cdot 0 + \frac{100}{150} \cdot 1\right) = \mathbf{0.918}$$

$$\text{꽃잎 너비} < 1.75: \quad 1.585 - 0.899 = 0.686$$

지니로 고를 때와 **같은 질문**을 고른다 다음 질문 (너비 1.75): 정보 이득 0.69

지니와 엔트로피: 거의 같은 모양



둘 다 반반일 때 최대, 한 종만 있으면 0 지니 $\times 2$ 와 엔트로피는 거의 겹친다

scikit-learn `criterion="gini"` (기본) / `"entropy"` 결과 트리는 대개 비슷하다

엔트로피는 어디로 이어지나

교차 엔트로피 (2주차)	모델 q 의 놀라움으로 잰 평균 $-\sum p \log q$
KL 발산 (15주차)	교차 엔트로피 $-$ 엔트로피 = 모델이 틀려서 **더** 놀란 양
언어 모델 (17주차)	다음 글자 · 단어의 놀라움을 줄이도록 학습

이름의 유래: AI 모델 “Claude” 는 섀넌의 이름 (Claude Shannon) 에서 따왔다고 알려져 있다

문제풀이

1. 확률 $\frac{1}{4}$ 인 사건의 놀라움은? 확률 $\frac{1}{1024}$ 이면?
2. 결과가 A 75%, B 25% 인 경기의 엔트로피는? ($\log_2 3 \approx 1.585$)
3. 사과 4 · 귤 4 인 칸을 (사과 4) / (귤 4) 로 나눴다. 정보 이득은?
4. 8가지 결과가 모두 같은 확률이면 엔트로피는? 이 결과를 알아내는 데 예 · 아니오 질문이 몇 번 필요한가?

실습

1. 놀라움 · 엔트로피 함수 직접 구현 → 0.47, 1.75 재현
2. 정보 이득으로 결정 트리 질문 고르기, `criterion="entropy"` 와 비교
3. 실제 글: 셜록 홈스 소설의 글자 엔트로피 → 왜 압축이 되는가

The Adventures of Sherlock Holmes (Project Gutenberg)

▶ Colab에서 실습 노트북 열기

정리

놀라움 $-\log_2 p$ 드물수록 크다, 독립 사건이면 더해진다

엔트로피 $H = -\sum p \log_2 p$ 놀라움의 평균 = 불확실함 = 평균 질문 수

팽팽할수록 최대 (두 결과면 반반에서 1 비트, k 가지면 $\log_2 k$)

정보 이득 = 질문 전 − 질문 후 엔트로피 결정 트리가 질문을 고르는 기준