# GBDT 와 SHAP

## 앞 나무의 실수를 고쳐 가는 숲, 그리고 “왜 그렇게 답했나”

Machine Learning 1

한국과학영재학교 (KSA)

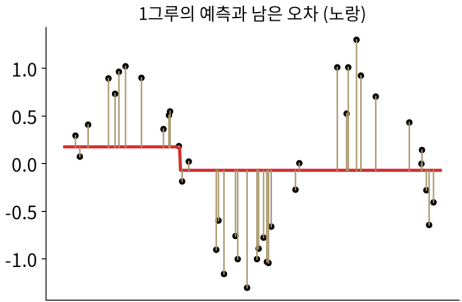
# 오늘의 질문

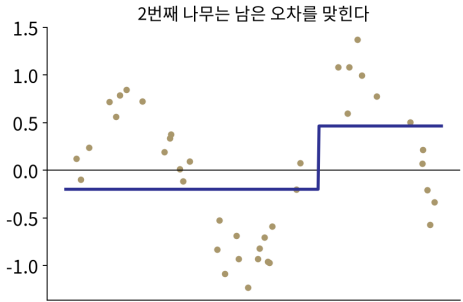
타이타닉 승객 두 명. 둘 다 **26살**.

AI 가 본 생존 확률: **96%** vs **13%**

무엇이 둘을 갈랐을까? AI 의 답을 **이유별로** 나눌 수 있을까?

# 부스팅: 앞 나무가 틀린 만큼을 다음 나무가 고친다

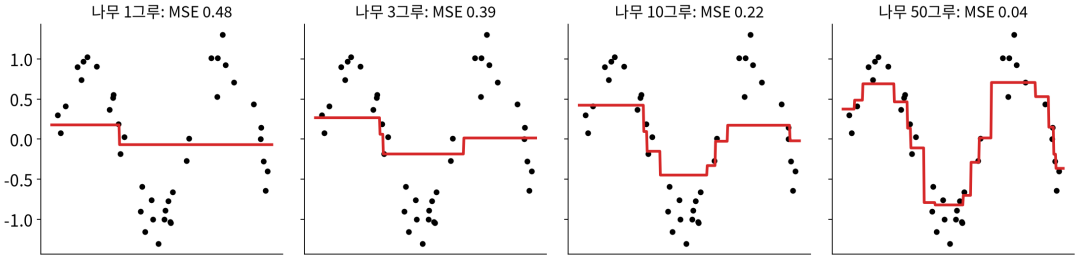



랜덤 포레스트: **동시에** 키워 투표

부스팅: **차례로** 키워 **더한다**

# 작은 나무를 쌓아 가면




질문 하나짜리 나무도 50그루 쌓으면 학습 MSE 0.48 → 0.39 → 0.22 → **0.04**

# 식으로: 그레이디언트 부스팅

$$F_m(x) = F_{m-1}(x) + \eta\, h_m(x)$$

| | |
|---|---|
| $F_{m-1}$ | 지금까지 쌓은 나무들의 예측 합 |
| $h_m$ | 새 나무: 지금의 **남은 오차** (손실의 기울기 반대 방향) 를 맞히도록 학습 |
| $\eta$ | 학습률: 새 나무를 얼마나 믿을지 (보통 0.01 ∼ 0.3) |

GBDT = Gradient Boosting Decision Tree  경사하강법을 **함수** 공간에서 하는 것

# 타이타닉 GBDT

| | |
|---|---|
| 데이터 | 승객 1,309명, 특징 5개: 등급 · 성별 · 나이 · 요금 · 가족 수 |
| 모델 | 깊이 3 나무 **200그루**, 학습률 0.05 |
| 학습 데이터 오답률 | 1그루 38.2% → 10그루 20.1% → 200그루 **13.9%** |
| 5겹 교차 검증 정확도 | **80.7%** |

그런데 200그루의 합이라 **왜 그렇게 답했는지 보이지 않는다**

# 랜덤 포레스트 vs GBDT

| | 랜덤 포레스트 | GBDT |
|---|---|---|
| 나무 키우기 | 동시에, 독립적으로 | **차례로**, 앞 나무의 실수를 보고 |
| 나무 크기 | 깊게 (끝까지) | 얕게 (깊이 3 ∼ 8) |
| 줄이는 것 | 분산 (흔들림) | 편향 (덜 배움) |
| 나무를 늘리면 | 안정될 뿐 | **과대적합될 수 있다** → 조기 종료 |
| 튜닝 | 거의 필요 없음 | 학습률 · 나무 수 · 깊이 |

XGBoost, LightGBM, CatBoost: GBDT 를 빠르게 만든 라이브러리, 표 데이터 대회의 단골

# SHAP: 정보를 하나씩 알려 주며 확률이 오른 만큼을 잰다

1등석 여성 승객 (26살). 정보를 하나씩 알려 준다:

| 아는 정보 | 생존 확률 | 오른 만큼 |
|---|---|---|
| 아무것도 모름 (승객 평균) | 38.2% | |
| + 성별 (여성) | 68.8% | **+30.6** |
| + 등급 (1등석) | 87.8% | **+19.0** |
| + 나머지 (나이 · 요금 · 가족) | 96.0% | +8.2 |

그런데 **순서**를 바꾸면 오른 만큼이 달라진다 (등급부터 알려 주면 등급 +13.1)

# 해결: 모든 순서의 평균 (섀플리 값)

$$\phi_j = \frac{1}{\text{순서의 수}} \sum_{\text{모든 순서}} \left(j \text{를 알려 줬을 때 오른 만큼}\right)$$

정보 3가지 $\rightarrow$ 순서 $3! = 6$ 가지  1등석 여성: **성별** $+34.0$**, 등급** $+22.6$**, 나머지** $+1.3$

평균 $38.2 + 34.0 + 22.6 + 1.3 =$ **96.0**  몫의 합 = **정확히** 모델의 답

게임 이론의 공정한 기여 나누기 (Shapley, 1953)  SHAP = SHapley Additive exPlanations (Lundberg & Lee, 2017)

# “모르는 정보”는 어떻게 처리하나

모델은 성별을 꼭 넣어야 답한다. 성별을 “모른다”는 건?

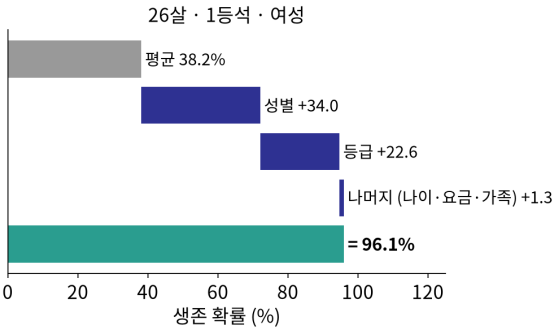
성별 자리에 **여러 승객의 실제 성별**을 넣어 보고 평균

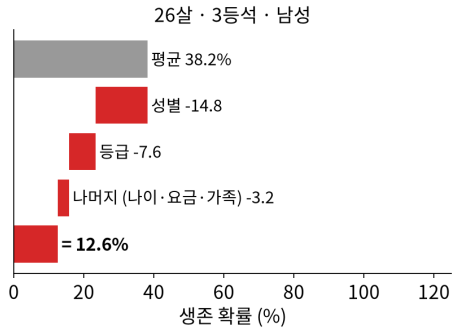
나무로 보면: 모르는 질문에서는 **양쪽 길을 다 가서** 비율대로 섞는다

1등석 여성: 다 알면 93%  성별을 모르면 남 64 · 여 36 비율로 섞어 **44%**

(깊이 2 짜리 설명용 나무 하나로 계산한 예)

# 두 승객의 몫

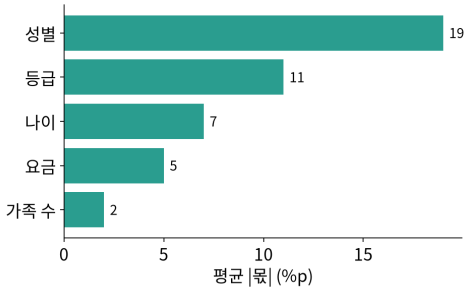


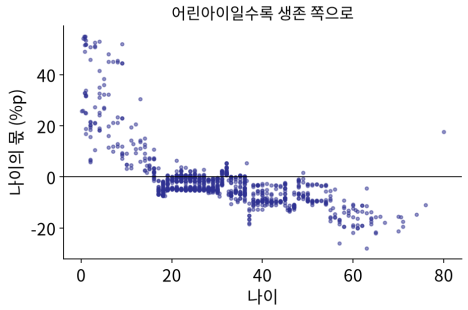




같은 26살, **성별** ($+34.0$ vs $-14.8$) 과 **등급** ($+22.6$ vs $-7.6$) 이 갈랐다

그날 밤 여성과 아이를 먼저 구명보트에 태웠다고 알려져 있다

# 모든 승객으로 모아 보면




평균 |몫| (%p): 성별 **19** 등급 11 나이 7 요금 5 가족 2

# SHAP 을 읽을 때 주의할 점

| | |
|---|---|
| **모델 설명이다** | 모델이 무엇을 보고 답했는지일 뿐, 원인을 증명하지 않는다 |
| **얽힌 특징** | 등급과 요금처럼 함께 움직이면 몫이 나뉘어 보인다 |
| **계산량** | 정보 $n$ 개면 순서 $n!$ 개 $\rightarrow$ 나무는 빠른 공식 (TreeSHAP) |

SHAP 은 나무뿐 아니라 신경망 (이미지 · 텍스트) 까지 **어떤 모델에도** 쓸 수 있다

# 문제풀이

1. 첫 나무가 모든 승객에게 0.4 를 예측했다. 실제 답이 1, 0, 1 인 세 승객의 남은 오차는? 학습률 0.5 인 두 번째 나무가 이 오차를 정확히 맞히면 새 예측은?
2. 정보 A, B 두 개. 아무것도 모를 때 50, A 만 알 때 70, B 만 알 때 60, 둘 다 알 때 90. A 와 B 의 섀플리 값은? 합은?
3. GBDT 의 학습률을 0.5 에서 0.05 로 줄였다. 나무 수는 어떻게 해야 하나?

# 실습

1. 부스팅 직접 구현: 깊이 1 나무로 남은 오차를 차례로 맞히기 → MSE 0.48 → 0.04
2. 타이타닉 GBDT: 학습률 · 나무 수 바꿔 보기, 조기 종료
3. SHAP: 두 승객의 몫 직접 계산 (6가지 순서) + `shap` 라이브러리로 확인

Titanic (OpenML; Vanderbilt titanic3)

▶ Colab에서 실습 노트북 열기

# 정리

**GBDT** 작은 나무를 차례로, 앞의 **남은 오차**를 맞히며 더한다 ($F \leftarrow F + \eta h$)

타이타닉 200그루 · 교차 검증 80.7% 나무가 많으면 과대적합 $\rightarrow$ 조기 종료

**SHAP** 정보를 알려 줄 때 오른 만큼을 **모든 순서로 평균** (섀플리 값)

몫의 합 = 모델의 답 26살 두 승객을 가른 것: 성별 · 등급