RNN 순환 신경망 (Recurrent Neural Network)

단어를 하나씩 읽으며 메모를 고쳐 쓴다

Machine Learning 1

한국과학영재학교 (KSA)

오늘의 질문

Dog bites man vs Man bites dog

단어 세 개는 **똑같다** 뜻은 **정반대**

지금까지의 신경망은 입력을 한꺼번에 받았다 **순서**는 어떻게 읽을까?

단어를 그냥 더하면

$$\mathbf{e}_{\text{dog}} + \mathbf{e}_{\text{bites}} + \mathbf{e}_{\text{man}} = \mathbf{e}_{\text{man}} + \mathbf{e}_{\text{bites}} + \mathbf{e}_{\text{dog}}$$

단어 벡터를 더하면 (bag of words) 두 문장은 **완전히 같은 숫자**

덧셈은 순서를 모른다 이어 붙이면 문장 길이가 다를 때 곤란

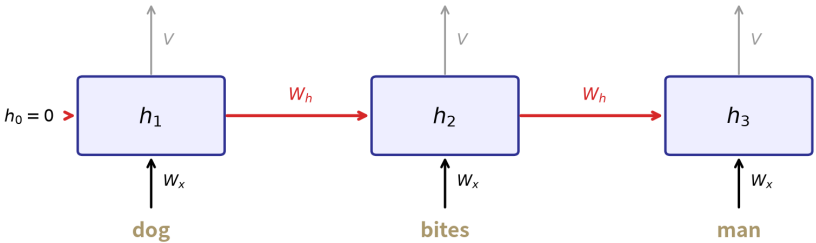
$\rightarrow$ 단어를 **하나씩, 차례로** 읽는 신경망이 필요하다

RNN: 메모를 고쳐 쓰며 읽는다

$$\mathbf{h}_t = \tanh\left(W_x\,\mathbf{x}_t + W_h\,\mathbf{h}_{t-1} + \mathbf{b}\right) \qquad \mathbf{y}_t = V\,\mathbf{h}_t$$

$\mathbf{x}_t$	t 번째 단어 (벡터)
$\mathbf{h}_t$	**은닉 상태** = 지금까지 읽은 내용의 메모 ($\mathbf{h}_0 = \mathbf{0}$)
$W_x, W_h, V, \mathbf{b}$	모든 단어에서 **같은 가중치**를 다시 쓴다 (순환)

시간으로 펼쳐 보면



메모가 W_h 를 타고 다음 단어로 넘어간다 마지막 메모 $\mathbf{h}_3$ 에 문장 전체가 담긴다

손으로 한 번: 메모가 한 칸인 RNN

$$h_t = \tanh(1 \cdot x_t + 0.5 \cdot h_{t-1}), \quad \text{입력 } x = 1, 0, 1$$

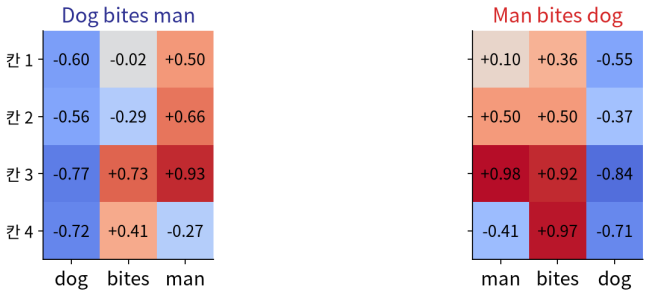
$$t = 1 \quad \tanh(1 + 0.5 \times 0) = 0.762$$

$$t = 2 \quad \tanh(0 + 0.5 \times 0.762) = \tanh(0.381) = 0.363$$

$$t = 3 \quad \tanh(1 + 0.5 \times 0.363) = \tanh(1.182) = \mathbf{0.828}$$

입력이 0 인 둘째 칸에서도 메모는 0 이 아니다 **앞의 1 을 기억**하고 있다

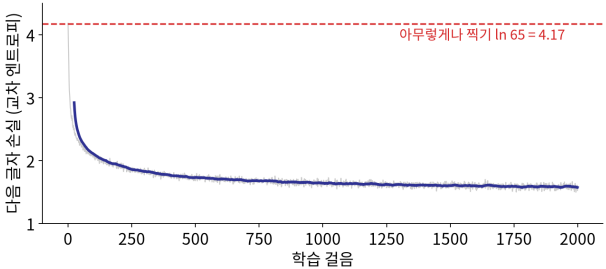
두 문장의 마지막 메모는 다르다



마지막 메모: $(+0.50, +0.66, +0.93, -0.27)$ vs $(-0.55, -0.37, -0.84, -0.71)$

같은 RNN (메모 4칸, 학습 전 무작위 가중치) 학습은 이 메모가 **뜻**을 담도록 고친다

RNN 언어 모델: 다음 글자 맞히기



셰익스피어 희곡 111만 글자, 매 칸에서 **다음 글자**를 맞히도록 학습 (교차 엔트로피)
손실: 처음 4.18 (찍기 수준) → 2,000걸음 뒤 **1.58**

학습한 RNN 이 쓴 글

200걸음

```
ROMEO: Why mome kish selled ouch me hand, in I to the My course his thee
reching thin bein so mane him stints, your well deatces is dinger not my
fits,
```

2,000걸음

```
ROMEO: Why make it with the death expenty in I the can you upon him thee
reshian of bloodel some shall stants, your way, and come are forrone; my
father we would for me I see they ches of the wife, sir.
```

다음 글자를 뽑아 다시 넣기를 반복 단어 · 띄어쓰기 · 구두점을 배웠다

뜻은 아직 엉망 은닉 128칸 RNN, 몇 분 학습 (Karpathy char-rnn 을 작게 재현)

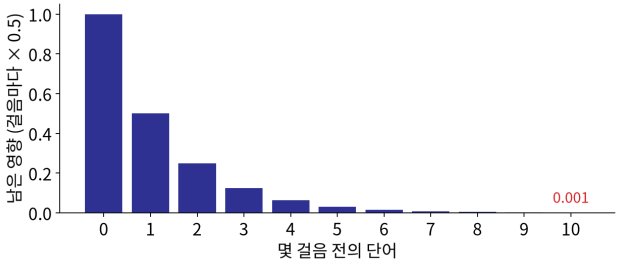
학습: 시간을 거슬러 역전파 (BPTT)

펼친 그림 (p.4) 에서 역전파 같은 가중치의 **기울기를 칸마다 더한다**

$$\frac{\partial L}{\partial \mathbf{h}_1} = \frac{\partial L}{\partial \mathbf{h}_T} \prod_{t=2}^{T} \frac{\partial \mathbf{h}_t}{\partial \mathbf{h}_{t-1}}$$

오래전 단어로 가는 기울기는 **여러 번 곱해진다** $\rightarrow$ **기울기 소실** (9주차)

약점: 오래된 기억이 흐려진다



한 걸음마다 영향이 절반으로 준다면 10걸음 뒤 $0.5^{10} \approx$ **0.001**

"The **cat**, which ate all the fish in the kitchen, **was** full": 멀리 떨어진 cat 과 was

RNN 이 쓰인 곳

여러 개 → 하나	문장 → 감정 (긍정 / 부정)	마지막 메모로 분류
여러 개 → 여러 개	다음 글자 · 단어 예측, 품사 붙이기	칸마다 출력
입력 → 다른 길이 출력	번역 (12주차 Seq2Seq)	읽는 RNN + 쓰는 RNN

2017년 트랜스포머 이전, 번역 · 음성 인식의 주력 지금도 작은 시계열 · 실시간 처리에 쓰인다

문제풀이

1. 손 계산 예 ($w_x = 1$, $w_h = 0.5$) 에 입력 $0, 1, 1$ 을 넣으면 h_1, h_2, h_3 는? ($\tanh 1 = 0.762$, $\tanh 1.381 = 0.881$)
2. 단어 벡터 100칸, 메모 200칸인 RNN 의 W_x, W_h, **b** 가중치 수는? 문장이 길어지면 가중치 수는?
3. 글자 65가지에서 아무렇게나 찍을 때의 교차 엔트로피는 왜 $\ln 65$ 인가?
4. 한 걸음마다 기억이 0.8 배가 된다면 20걸음 뒤에는? ($0.8^{10} \approx 0.107$)

실습

1. numpy 로 RNN 한 칸 구현 → 손 계산 0.762 · 0.363 · 0.828, 두 문장의 메모 비교
2. PyTorch `nn.RNN` 으로 글자 단위 언어 모델 (셰익스피어)
3. 학습 중간중간 글 써 보기, 온도 바꿔 보기

Tiny Shakespeare (Karpathy, char-rnn)

▶ Colab에서 실습 노트북 열기

정리

순서가 중요한 데이터: 단어를 더하면 순서를 잃는다

RNN $\mathbf{h}_t = \tanh(W_x\mathbf{x}_t + W_h\mathbf{h}_{t-1} + \mathbf{b})$ 모든 칸에서 같은 가중치

언어 모델: 다음 글자 맞히기, 손실 4.18 $\rightarrow$ 1.58, 영어 모양을 배운다

BPTT 에서 곱셈이 쌓여 **오래된 기억이 흐려진다** $\rightarrow$ 다음 시간 LSTM