트랜스포머 (Transformer)

모든 단어를 한 번에 보는 블록을 쌓는다

Machine Learning 1

한국과학영재학교 (KSA)

오늘의 질문: ChatGPT 의 T 는?

Chat Generative Pre-trained **T**ransformer

2017년 구글 논문 “**Attention Is All You Need**” (Vaswani 외 8명)

지금의 언어 모델 · 번역기 · 이미지 생성기 대부분이 이 구조 위에 있다

RNN 은 차례로, 트랜스포머는 한 번에

RNN: 하나씩 차례로 (5걸음)



트랜스포머: 모든 쌍을 한 번에 (1걸음)



	RNN	트랜스포머 (셀프 어텐션)
단어 n 개를 읽는 차례	n 걸음 (앞이 끝나야 뒤)	**1** 걸음 (모두 동시에, GPU)
첫 단어 $\leftrightarrow$ 끝 단어	$n-1$ 걸음 거쳐 전달	**바로** 연결
계산량	n 에 비례	모든 쌍: n^2 에 비례

셀프 어텐션, 여러 개의 머리로

단어 벡터 X ($n \times 512$) 에서 $Q = XW_Q,\ K = XW_K,\ V = XW_V$

$$\text{head} = \text{softmax}\left(\frac{QK^\top}{\sqrt{64}}\right)V$$

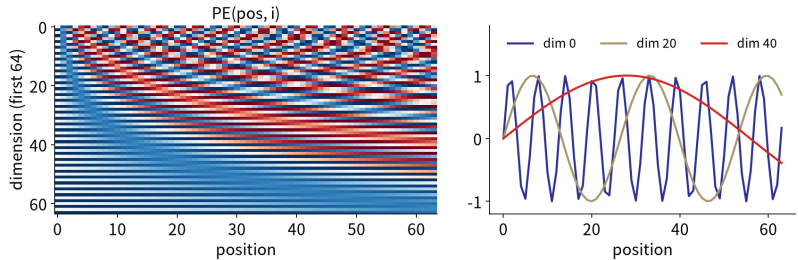
멀티헤드 512칸을 **8개 머리** × 64칸으로 나눠 따로 → 이어 붙여 W_O

왜 여러 개? 머리마다 다른 관계 (주어 ↔ 동사, “그것은” ↔ 동물)

지난 시간과 달리 Q, K, V 를 **학습하는 행렬**로: 무엇을 찾을지 · 내걸지 · 줄지를 배운다

순서는? 위치 정보를 더한다

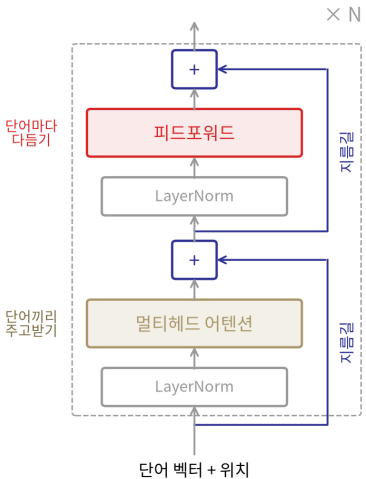
셀프 어텐션은 순서를 모른다: Dog bites man = Man bites dog (**같은 쌍**들)



입력 = 단어 벡터 + **위치 벡터** $\mathrm{PE}(pos, 2i) = \sin\left(pos/10000^{2i/d}\right)$, $2i+1$ 칸은 cos

칸마다 주기가 다른 물결 $\rightarrow$ 위치마다 다른 무늬 위치 벡터를 학습으로 정해도 비슷하다 (논문, GPT)

블록 하나: 주고받고, 다듬고



어텐션	단어끼리 정보를 **주고받는다**
피드포워드	단어마다 따로 **다듬는다**
	$512 \to 2048 \to 512$ (ReLU)
지름길	$x + f(x)$: ResNet (10주차)
LayerNorm	단어마다 평균 0 · 분산 1 로

이 블록을 **N 번** 쌓는다

그림은 GPT 등이 쓰는 순서 (정규화 먼저) 원 논문은 더한 뒤 정규화

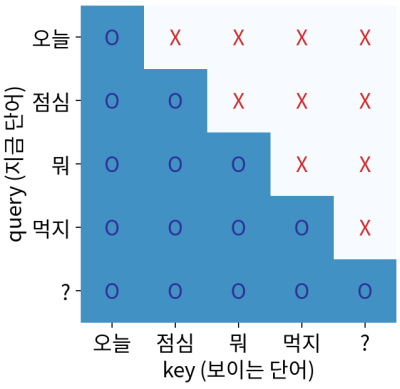
손으로 세기: 블록 하나의 가중치

어텐션	W_Q, W_K, W_V, W_O:	$d \times d$ 네 개	$4d^2$
피드포워드	$d \times 4d$,	$4d \times d$	$8d^2$
블록 하나			$12d^2$ (편향 · 정규화 빼고)

	d	층	가중치 $\approx 12d^2 \times$ 층
원 논문 (인코더 6층)	512	6	$3.1\text{M} \times 6 \approx 19\text{M}$
GPT-3 (2020)	12,288	96	$1.8\text{B} \times 96 \approx$ **174B**

GPT-3 의 1,750억 개가 거의 이 식 하나로 나온다

GPT: 앞 단어만 보고 다음 단어 맞히기



다음 단어를 맞히는데 뒤 단어를 보면 반칙
$\rightarrow$ 점수 행렬의 위쪽을 $-\infty$ 로 (softmax 후 0)

원 논문	인코더 6층 + 디코더 6층 (번역)
BERT (2018)	인코더만: 양쪽 다 본다
GPT (2018 $\sim$)	디코더만: **앞만** 본다

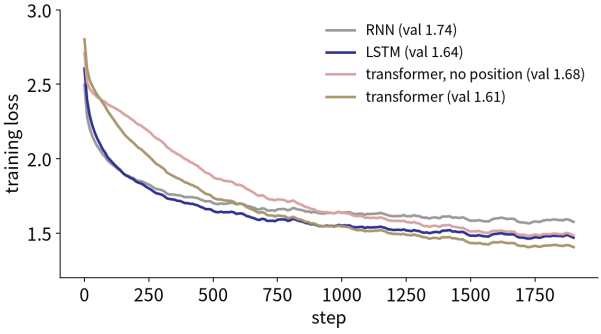
칸 하나의 앞만 보기로 길이 n 문장에서 n 개 문제를 한 번에 학습

논문 결과 (2017)

영어 → 독일어 (WMT'14)	BLEU **28.4**	기존 최고 +2 점 넘게
영어 → 프랑스어	BLEU **41.8**	GPU 8개로 3.5일 (훨씬 적은 계산)
base 모델		GPU 8개로 **12시간**

RNN 없이 어텐션만으로 더 잘, 더 빨리 → 제목: Attention Is All You Need

실험: 셰익스피어 글자 모델, 트랜스포머로



	검증 손실	가중치
RNN	1.74	5만
LSTM	1.64	15만
트랜스포머	**1.61**	82만
위치 정보 뺌	1.68	82만

폭 128 · 4층 · 머리 4 11주차와 같은 조건 (조각 64, 2,000걸음)

이 작은 CPU 실험에서는 한 걸음이 LSTM 의 약 3배 느렸다: 장점은 GPU · 긴 글 · 큰 모델에서 나온다

블록을 쌓아 온 길

2017	원 논문	인코더 6층 + 디코더 6층	번역
2018	BERT	인코더 24층 (large)	문장 이해 (14주차)
2020	GPT-3	디코더 **96층**, 1,750억 개	글 쓰기
2020	ViT	이미지 조각을 단어처럼	이미지 분류

블록은 거의 그대로, **층 · 폭 · 데이터**를 키웠다

문제풀이

1. $d = 768$, 12층 (GPT-2 small, BERT base) 의 블록 가중치는 대략 몇 개? ($12d^2 \times$ 층)
2. 단어 1,000개 문장에서 셀프 어텐션 점수는 몇 개 계산하나? 10,000개면 몇 배?
3. 앞만 보기 마스크에서 단어 5개 문장의 0 이 아닌 칸은 몇 개인가?
4. 위치 정보를 빼도 앞만 보는 모델은 손실 1.68 로 꽤 배웠다. 어떻게 위치를 짐작할 수 있었을까?

실습

1. 위치 정보 만들기 (사인 · 코사인), 앞만 보기 마스크
2. 트랜스포머 블록 직접 쌓기 $\rightarrow$ 가중치 수를 $12d^2$ 와 비교
3. 셰익스피어 작은 GPT 학습 $\rightarrow$ 글 써 보기

Tiny Shakespeare (Karpathy, char-rnn)

▶ Colab에서 실습 노트북 열기

정리

트랜스포머: RNN 없이 셀프 어텐션으로 모든 단어를 **한 번에** (2017)

입력 = 단어 + 위치 블록 = 멀티헤드 어텐션 $\rightarrow$ 피드포워드, 지름길 · LayerNorm

블록 하나 $\approx 12d^2$ GPT-3: $12 \times 12288^2 \times 96 \approx 1{,}750$억

GPT = 앞만 보는 디코더 셰익스피어 검증 손실 1.64 (LSTM) $\rightarrow$ 1.61