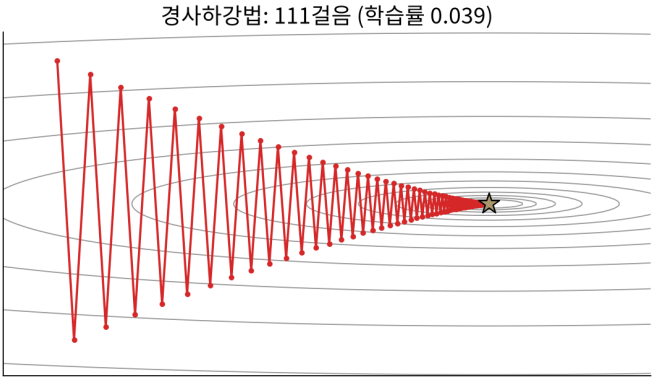
모멘텀과 Adam

골짜기 바닥까지 몇 걸음?

Machine Learning and Deep Learning

한국과학영재학교 (KSA)

오늘의 질문: 길쭉한 골짜기의 바닥까지



$f(x, y) = \frac{1}{2}(x^2 + 50y^2)$ 경사하강법: **지그재그로 111걸음** 더 빨리 갈 수 없을까?

왜 지그재그가 될까

$$\nabla f = (x,\ 50y)$$

y 방향 (가파름) 기울기가 50배 학습률이 $\frac{2}{50} = 0.04$ 를 넘으면 **튕겨 나간다**

x 방향 (완만함) 기울기가 작다 학습률 0.04 로는 한 걸음에 **4%** 만 간다

학습률 하나로 두 방향을 다 맞출 수 없다 가파른 쪽에 맞추면 완만한 쪽이 **찔끔찔끔**

모멘텀: 지난 속도를 기억한다

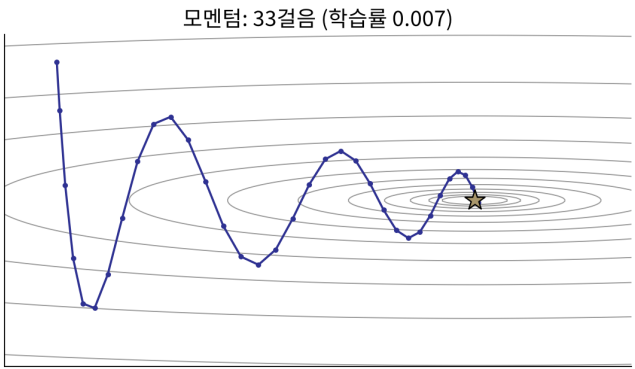
$$\mathbf{v} \leftarrow \beta\,\mathbf{v} + \nabla f \qquad \mathbf{w} \leftarrow \mathbf{w} - \eta\,\mathbf{v}$$

굴러가는 공처럼: 같은 방향이면 **빨라지고**, 방향이 바뀌면 **상쇄된다**

기울기가 계속 1 이면 ($\beta = 0.9$): $v = 1 \to 1.9 \to 2.71 \to 3.44 \to \cdots \to$ **10**

지그재그 방향 (위 · 아래) 은 서로 상쇄 바닥 쪽 방향 (옆) 은 쌓여서 최대 $\frac{1}{1-\beta} = 10$ 배

모멘텀: 33걸음



111걸음 → **33걸음** 출렁이지만 바닥 쪽으로 빠르게 (Sutskever 외, 2013)

Adam: 방향마다 보폭을 맞춘다

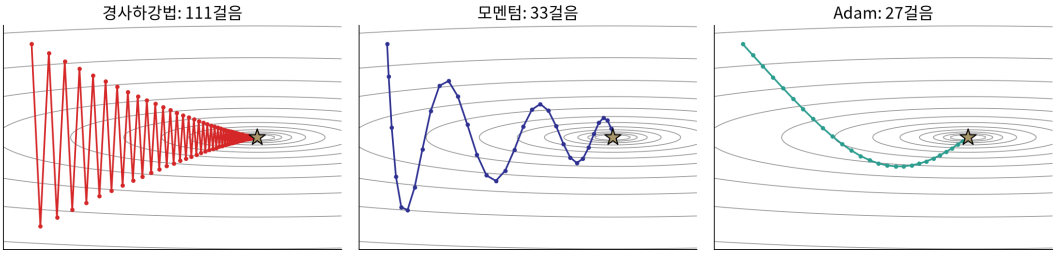
$$\mathbf{m} \leftarrow \beta_1 \mathbf{m} + (1 - \beta_1)\,\mathbf{g} \qquad \mathbf{s} \leftarrow \beta_2 \mathbf{s} + (1 - \beta_2)\,\mathbf{g}^2$$

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \frac{\hat{\mathbf{m}}}{\sqrt{\hat{\mathbf{s}}} + \epsilon}$$

- $\mathbf{m}$ 기울기의 평균 = 모멘텀 (방향)
- $\mathbf{s}$ 기울기 **제곱**의 평균 = 그 방향이 얼마나 가파른지
- $\hat{\mathbf{m}}, \hat{\mathbf{s}}$ 처음엔 0 에서 시작하니 크기 보정 ($\div(1 - \beta^t)$)

가파른 방향은 $\sqrt{s}$ 가 커서 **작게**, 완만한 방향은 **크게** 보폭이 대략 η 로 맞춰진다

Adam: 27걸음



경사하강법 111 모멘텀 33 Adam **27** (학습률 0.039 · 0.007 · 0.18)

Adam 의 기본값

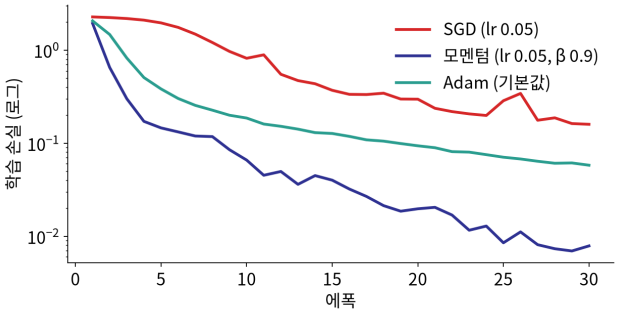
학습률 $\eta = 0.001$ $\beta_1 = 0.9$ $\beta_2 = 0.999$ $\epsilon = 10^{-8}$

기본값 그대로도 대부분 잘 된다 $\rightarrow$ 학습률 고르는 수고가 적다

PyTorch: `torch.optim.Adam(model.parameters(), lr=1e-3)`

Kingma & Ba (2014) AdamW: L2 정규화를 바르게 넣은 변형, 요즘 LLM 의 기본

실제 신경망에서는



손글씨 숫자, 10 에폭 뒤 학습 손실: SGD 0.817 모멘텀 **0.066** Adam 0.186

둘 다 SGD 보다 훨씬 빠르다. 모멘텀 · Adam 사이의 순서는 문제와 학습률에 따라 바뀐다

무엇을 쓸까

Adam / AdamW	처음 시도할 때, 트랜스포머 · 언어 모델
SGD + 모멘텀	이미지 CNN 을 오래 학습할 때 일반화가 조금 낫다는 보고
공통	학습률이 가장 중요, 학습률을 줄이는 스케줄과 함께

모두 SGD (미니배치) 위에서 걷는다: SGD 가 바탕, 모멘텀 · Adam 은 **걷는 방식**을 바꾼 것

문제풀이

1. $\beta = 0.5$ 인 모멘텀에서 기울기가 계속 2 이면 v 는 $2 \to ? \to ? \to \cdots$, 결국 몇에 가까워지나?
2. 기울기가 1, -1, 1, -1 로 번갈아 나온다. $\beta = 0.9$ 모멘텀의 v 는 처음 네 번에 각각 얼마인가?
3. $f = \frac{1}{2}(x^2 + 100y^2)$ 에서 경사하강법의 학습률은 대략 얼마보다 작아야 튕겨 나가지 않나?
4. Adam 에서 기울기가 한 방향은 늘 100, 다른 방향은 늘 0.01 이다. 두 방향의 보폭은 어떻게 되나?

실습

1. 경사하강법 · 모멘텀 · Adam 직접 구현 → 골짜기에서 111 · 33 · 27걸음 재현
2. 학습률을 바꿔 가며 걸음 수 비교 (각자 가장 좋은 학습률 찾기)
3. 실제 신경망: 손글씨 숫자에서 `torch.optim` SGD · 모멘텀 · Adam

Optical Recognition of Handwritten Digits (UCI; scikit-learn `load_digits`)

▶ Colab에서 실습 노트북 열기

정리

길쭉한 골짜기: 학습률 하나로는 가파른 쪽 · 완만한 쪽을 다 못 맞춘다 (111걸음)

모멘텀 $\mathbf{v} \leftarrow \beta\mathbf{v} + \nabla f$ 지그재그는 상쇄, 바닥 쪽은 가속 (33걸음)

Adam 모멘텀 + 방향별 보폭 $\hat{m}/\sqrt{\hat{s}}$ (27걸음) 기본값 0.001 · 0.9 · 0.999

실제로는 Adam 으로 시작, 학습률이 가장 중요