

CNN 기초와 응용

합성곱 · 출력크기 · FLOPs · 풀링 · 수용장 · ResNet · 탐지 · 분할 · 전이학습

Machine Learning 1 · 10주차

한국과학영재학교 (KSA)

Chapter 10

이번 주차 개요

이 챕터를 마치면

- 합성곱 출력 크기를 패딩·스트라이드와 함께 손으로 계산하고, 파라미터 수·FLOPs로 “왜 합성곱이 효율적인가”를 숫자로 설명
- 합성곱·풀링이 “좁아지고 깊어지는” 구조를 만드는 역할을 설명하고, LeNet→ResNet까지 스킵 연결이 왜 깊은망을 가능하게 하는지 서술
- 탐지·분할 헤드(R-CNN, IoU/NMS, 1×1 합성곱, U-Net)와 전이학습(특징 추출 vs 미세조정)이 언제·왜 유리한지 판단

- **10.1 합성곱, 출력 크기, 파라미터 수와 FLOPs** — MLP의 한계에서 출발해 파라미터 공유로 이어지는 “한 연산”을 계산한다
- **10.2 풀링과 전형적인 CNN 구조** — 그 연산을 “구조”로 쌓고, 깊이의 한계에 부딪혀 스킵 연결(ResNet)을 만난다
- **10.3 분류를 넘어서: 탐지, 분할, 전이학습** — 그 구조를 “새 문제”에 다시 쓴다

이 장을 관통하는 하나의 실: “재사용” — 새로 배울 것을 최소화하고, 이미 배운 것을 어디든 다시 쓰자.

10.1 합성곱, 출력 크기, 파라미터 수와 FLOPs

MLP로 이미지를 다루면 안 되는 이유

Chapter 9의 다층 퍼셉트론(MLP)에 이미지를 넣으려면 가로세로 픽셀을 **펼쳐서** 긴 벡터로 만들어야 한다.

- 200×200 흑백 이미지만 **4만 개의 입력**
- 첫 은닉층 뉴런 1000개면 그것만으로 **4천만 개**의 가중치
- “고양이가 왼쪽 위에 있든 오른쪽 아래에 있든 같은 고양이”라는 사실을 **전혀 활용 못 함**
- 픽셀 하나 위치만 옮겨도 **완전히 다른 입력**으로 취급

이미지의 공간 구조(위치 불변성)를 활용하려면?

합성곱: 작은 필터를 온 이미지에 재사용

핵심 아이디어는 허블·비셀(Hubel & Wiesel, 1962)의 시각피질 실험과 같다: 뉴런은 화면 전체가 아니라 **좁은 수용장**의 특정 방향 선분에만 반응한다.

- **합성곱**: $k \times k$ **필터(커널, kernel)**를 입력 위에서 **슬라이드**하며, 각 위치에서 겹치는 영역의 **원소별 곱의 합**을 계산
- 필터 값 자체가 **학습 대상 파라미터** — “모서리 탐지 필터”는 어느 위치에서든 모서리를 감지해야 하므로 위치마다 새로 배울 필요 없음

파라미터 공유 (parameter sharing)

이 재사용 덕분에 MLP보다 **훨씬 적은 파라미터**로 훨씬 큰 이미지를 다룰 수 있다.

conv2d 직접 구현해보기

```
def conv2d(image, kernel):
    img_h, img_w = len(image), len(image[0])
    k = len(kernel)
    out_h, out_w = img_h - k + 1, img_w - k + 1
    output = [[0.0] * out_w for _ in range(out_h)]
    for i in range(out_h):
        for j in range(out_w):
            total = 0.0
            for di in range(k):
                for dj in range(k):
                    total += image[i+di][j+dj] \
                        * kernel[di][dj]
            output[i][j] = total
    return output
```

- 입력 $n \times n \rightarrow$ 출력 $(n - k + 1) \times (n - k + 1)$
- 각 위치마다 필터와 **원소별 곱의 합**
- “합성곱층”이라는 용어는 후쿠시마의 네오코그니트론 (1980)에서 처음 사용

“합성곱”이라는 이름의 뜻: 뒤집기는 어디로?

신호처리의 정의로, 두 수열 f, k 의 합성곱은

$$(f * k)(i) = \sum_j k(j) f(i - j)$$

$i - j$ 에 주목: 커널이 **뒤집힌(flipped)** 모습으로 겹쳐진다. 그런데 우리 코드(`image[i+di][j+dj] * kernel[di][dj]`)는 뒤집기 없이 그대로 곱한다 — 신호처리 용어로 이것은 **상관(correlation)**이고 “합성곱”이 아니다.

그래도 아무도 신경 쓰지 않는 세 가지 이유:

- ① **필터 값은 학습 대상.** “정답 필터”가 따로 없으므로, 뒤집힌 버전이 다른 반응을 낸다면 가중치를 뒤집힌 것으로 학습시키면 그만 — 표현 가능한 함수 **집합**은 정확히 같다
- ② **고정 필터의 예외는 사실상 없음.** 뒤집기가 실질적 차이가 되는 경우는 “특정 주파수만 통과”하는 손설계 DSP 필터 정도
- ③ **이름의 기원.** LTI(선형 시불변) 시스템 이론의 “출력 = 임펄스 응답의 뒤집힌 버전과 입력의 합성곱” 표현에서 왔고, 네오코그니트론(1980) 이래 관성이 이어져 왔다

실무 규칙

코드와 수식에서는 “각 위치의 원소별 곱의 합”을 그냥 **“합성곱”**이라고 쓰면 된다 — 이 분야

손으로 한 번: 3×3 필터가 5×5 를 스캔

5×5 흑백 이미지(열 2에 흰선, 밝기 1, 배경 0)에 중심 열만 1인 3×3 필터(“수직선 탐지기”의 가장 단순한 버전):

		0	1	2	3	4
입력 5×5	0	0	0	1	0	0
	1	0	0	1	0	0
	2	0	0	1	0	0
	3	0	0	1	0	0
	4	0	0	1	0	0
필터 3×3	0	1	0			
	0	1	0			
	0	1	0			

출력 = $5 - 3 + 1 = 3$ 이므로 3×3

	j=0	j=1	j=2
i=0	0	3	0
i=1	0	3	0
i=2	0	3	0

중심 위치 ($i=1, j=1$) 직접 계산 — 필터가 이미지의 중심 3×3 영역(행 1~3, 열 1~3)을 덮는다:

$$\begin{aligned} & 0 \cdot 0 + 1 \cdot 1 + 0 \cdot 0 \text{ (행 1)} \\ & + 0 \cdot 0 + 1 \cdot 1 + 0 \cdot 0 \text{ (행 2)} \\ & + 0 \cdot 0 + 1 \cdot 1 + 0 \cdot 0 \text{ (행 3)} \\ & = 0 + 1 + 0 + 0 + 1 + 0 + 0 + 1 + 0 = 3 \end{aligned}$$

나머지 8개 위치도 같은 방식으로 (실습 노트북 § 1에서 numpy로 9개 위치를 그대로 실행).

세 가지를 한꺼번에 보는 손계산

- ① 5×5 입력이 3×3 으로 “줄어든” 것은 $n_{\text{out}} = n - k + 1$ 의 **자연스러운 결과** (다음 절에서 정리)
- ② **어느 위치에서든** 같은 가중치가 같은 패턴에 반응 — 파라미터 공유의 구체적 모습
- ③ “수직선”이 **원본 스케일 그대로** 다음 층으로 전달 — 원본이 5칸짜리 선이든 500칸짜리 선이든, 출력 지도 위에서는 “ 3×3 지도의 중심 열이 밝다”로 **똑같이** 표현됨

“규모를 초월한” 특징의 기반

마지막 점이 합성곱이 스케일에 무관한 특징을 만드는 기반이며, 10.2~10.3에서 풀링·수용장이 이 아이디어를 확장한다.

출력 크기 공식: 미적분이 아니라 “세는 문제”

입력 $n \times n$, 필터 $k \times k$, 패딩 p (가장자리에 0을 두르는 픽셀 수), 스트라이드 s (필터가 한 번에 이동하는 칸 수)일 때:

$$n_{\text{out}} = \left\lfloor \frac{n + 2p - k}{s} \right\rfloor + 1$$

- 예: $n=28, k=3, p=0, s=1$ 이면 $28 - 3 + 1 = \mathbf{26}$
- 패딩 없이는 필터를 지날 때마다 이미지가 점점 작아진다
- $p = (k - 1)/2$ 로 하면(**same padding**) 출력 크기를 입력과 같게 유지

유도 — 필터가 다 들어가는 위치를 세자 (1D로 줄여):

- 필터는 입력 **안쪽**에 완전히 들어와야 하므로 시작 위치 최댓값은 $n - k$
- s 로 이동하면 시작 위치는 $0, s, 2s, \dots$ 중 $\leq n - k$ 인 것들 — 항의 개수 $\lfloor (n - k)/s \rfloor + 1$
- 패딩 p 는 입력을 $n \rightarrow n + 2p$ 로 만들어 준다 (좌·우 **두** 쪽에 p 씩 — 그래서 공식에는 $2p$)

“패딩은 왜 $2p$ 인가” — 이 공식에서 가장 많이 범하는 실수. 코드 `padding=1` 은 **한 번당 1픽셀**, 총 늘어나는 길이는 $2p$ 다.

패딩 · 스트라이드 바꾸며 직접 세어보기


8×8 입력, 3×3 필터 ($p = 0$), 스트라이드만

	s	시작 위치	개수
바꾸며:	1	0, 1, 2, 3, 4, 5	6
	2	0, 2, 4	3
	4	0, 4	2

직접 세는 것과 $\lfloor (8 - 3)/s \rfloor + 1$ 이 $s \neq 1$ 에서도 일치 — $s=4$: “5칸을 4칸씩 건너뛰면 0과 4 두 곳”. 수직·수평 방향은 **독립적** — 사각형 입력이면 출력도 사각형.

명명: padding="valid" = 패딩 없음 (필터가 다 들어가는 위치만), padding="same" = k 가 홀수일 때 $p = (k - 1)/2$ 로 $n_{out} = n$.

28×28 input, 3×3 filter: valid filter starting positions (red ticks) = output size n_{out}



같은 28×28, $k=3$ 을 1D로 줄여 (p, s) 조합 4가지 — 회색은 패딩, 각 틱(tick)은 유효한 필터 시작 위치 하나. **틱의 개수가 곧**

n_{out} : $p=0, s=1 \rightarrow 26 \cdot p=1, s=1 \rightarrow 28$ (same) ·

$p=0, s=2 \rightarrow 13 \cdot p=1, s=2 \rightarrow 14$. 네 숫자 모두

$\lfloor (28 + 2p - 3)/s \rfloor + 1$ 로 그대로 계산된다.

스트라이드 $s = 2$ 가 실제로 하는 일

- 1D에서 길이를 반으로, 2D에서는 **가로·세로 둘 다** 반으로
- $\Rightarrow$ 공간 **면적은 $1/4$** 로 줄어든다
- 예: 224×224 에 $k=3, p=1, s=2$ 이면 $n_{\text{out}} = \lfloor (224 + 2 - 3)/2 \rfloor + 1 = \mathbf{112}$

AlexNet(2012)의 첫 합성곱 층

정확히 이 설정($224 \rightarrow 112$)으로 다운샘플링한다.

10.2절에서 2×2 **풀링**도 면적을 $1/4$ 로 줄여주는 것을 보게 되는데, “둘 중 무엇을 쓰느냐”는 질문이 생긴다 — 이 절 FAQ에서 비교한다.

파라미터 수 계산

C_{in} 개 입력 채널, C_{out} 개 출력 채널(= 필터 개수), 필터 $k \times k$ 인 합성곱 층의 파라미터 수(bias 포함):

$$\text{params} = (k \times k \times C_{in} + 1) \times C_{out}$$

- 예: $32 \times 32 \times 3$ 이미지, 3×3 필터, 출력 채널 16: $(3 \times 3 \times 3 + 1) \times 16 = \mathbf{448}$ 개뿐
- 같은 입력을 **완전연결층**(출력 뉴런 $32 \times 32 \times 16$)에 연결하려면 **수백만 개**가 필요하다

FLOPs는 “파라미터 수”와는 다른 질문이다.

- 파라미터 수 = “얼마나 많은 숫자를 저장해야 하는가”
- FLOPs = “몇 번의 곱셈-덧셈을 하는가” (속도)

FLOPs 공식: n_{out}^2 이 곱해진다

출력의 한 위치·한 채널을 계산하려면 $k \times k \times C_{\text{in}}$ 번 곱셈이 필요하고, 이것을 **모든 출력 위치 × 모든 필터**로 반복:

$$\text{FLOPs} \approx n_{\text{out}}^2 \times C_{\text{out}} \times (k \times k \times C_{\text{in}})$$

- 파라미터 수 공식과 거의 똑같이 생겼지만, **파라미터 수엔 없던 n_{out}^2 이 곱해진다**
- 이유: 같은 필터(같은 파라미터)를 **출력 위치마다 재사용** 하니 파라미터는 적어도, 계산은 그 위치 수만큼 **반복**

예: 224×224 흑백 ($C_{\text{in}}=1$), 3×3 필터 1개, $p=0$, $s=1$: $n_{\text{out}} = 222$

$$\text{FLOPs} = 222^2 \times 1 \times 9 = 49,284 \times 9 = 443,556 \text{ (약 44만 MAC)}$$

필터를 64개 ($C_{\text{out}}=64$)로 늘리면 **정확히 64배** (약 2,839만 MAC) — **커널 개수를 늘리면 파라미터 수와 연산량이 똑같이 정비례**로 늘어난다.

손계산 표: 미니 LeNet 세 층의 비용

28×28 흑백을 세 합성곱 층 + 한 풀링으로 줄여가는 작은 네트워크:

층	연산	출력 크기	파라미터	FLOPs
입력	28×28×1	—	—	—
conv 1	k=3, $C_{out}=4$, p=0, s=1	26×26×4	40	24,336
conv 2	k=3, $C_{in}=4$, $C_{out}=8$, p=0, s=1	24×24×8	296	165,888
pool	2×2 max pooling (s=2)	12×12×8	0	(비교 연산 864회)
conv 3	k=3, $C_{in}=8$, $C_{out}=16$, p=0, s=1	10×10×16	1,168	115,200
합계		10×10×16	1,504	305,424

conv 2 FLOPs 직접: $n_{out} = 24$, $24^2 = 576$ 위치 × 8 필터 × 9 × 4 = 36 MAC = $576 \times 8 \times 36 = 165,888$. 실습 노트북 § 3에서 numpy로 그대로 재계산.

표를 읽는 법: “재고” vs “유량”, MLP 비교


- ① **파라미터는 뒤로 갈수록 커지지만**($40 \rightarrow 296 \rightarrow 1,168$) **FLOPs 최댓값은 conv 2**(165,888) — FLOPs는 n_{out}^2 에 비례하고 conv 2가 공간적으로 가장 크다(24×24). conv 3은 채널 2배지만 공간 $1/4$ (10×10)라 오히려 적다
- ② **풀링은 파라미터 0**, 비용도 곱셈-덧셈이 아니라 **비교**(4개 중 최댓값) — FLOPs 합계에서 무시할 만큼 작음

세 합성곱 층을 **같은 출력 체적**($10 \times 10 \times 16 = 1,600$)의 **완전연결층 하나**(784 입력 $\rightarrow$ 1,600 뉴런)로 대체하면: 파라미터 $784 \times 1,600 + 1,600 = 1,256,000$ (합성곱 스택의 **약 835배**), FLOPs 1,254,400 (**약 4.1배**).

“재고” vs “유량”

파라미터는 “재고”(층당 고정 저장), **FLOPs는 “유량”**(출력 위치마다 반복되는 계산) — “한 번에” 보는 대신 **작은 패치를 재사용**하는 합성곱이 **약 0.12%의 파라미터, 1/4의 연산**으로 같은 체적의 특징을 만든다 — 게다가 **위치 불변성**이라는 귀납적 편향까지 덤. 한쪽만 보고 설계하면 안 된다.

좁아지고 깊어지는 CNN



- 위 그림의 네트워크: $32 \times 32 \times 3 \rightarrow \text{Conv } 5 \times 5 \text{ (6ch)} \rightarrow \text{Pool } 2 \times 2 \rightarrow \text{Conv } 5 \times 5 \text{ (16ch)}$
- 10.2절 전체를 관통하는 “**좁아지고 깊어진다**” 경향의 원형

합성곱을 거칠 때마다 **공간 크기(가로×세로)는 줄고 채널 수(깊이)는 늘어나는 모습.**

자주 하는 실수: 공식이 걸리는 두 곳

실수 1: “패딩은 출력에 더해지는 거다”

- $n=28, k=3, p=1, s=1$ 의 출력을 “ $28 + 2 = 30$ ” 이라고 — 패딩 픽셀이 출력을 만든다고 오해
- **패딩은 출력 위치를 새로 만들지 않는다** — “벗어나갈 것 같았던 위치”(필터가 원본 경계를 넘는 위치)를 **유효하게 만들어 주는 것**뿐
- 출력 = “패딩된 입력 안에서 필터가 완전히 들어가는 위치 수”
 $= \lfloor (28 + 2 - 3)/1 \rfloor + 1 = 28$
- 패딩의 정당한 용도는 “**same padding으로 크기를 유지**”, “출력을 키우는 것”이 아니다

연산량을 비교할 때는 “파라미터 몇 배”가 아니라 공식으로 직접 계산. (1×1 합성곱은 공간 크기 그대로 두고 채널만 선형 결합 — “경량으로 채널을 섞는다”는 용도로 VGG·ResNet 중간층에서 실전에 많이 쓰인다. 10.2에서 다시 만난다.)

실수 2: “FLOPs = 파라미터 $\times$ 고정 계수”

- FC에서는 샘플당 FLOPs $\approx 2 \times$ 파라미터라, 이 습관을 합성곱에도 적용하기 쉬움
- 그러나 **합성곱의 FLOPs/파라미터 비율은 n_{out}^2 이며 층마다 다름**
- 같은 224×224 , 64 출력 채널: $3 \times 3 = 640$ params, $\approx 2,839$ 만 MAC vs $1 \times 1 = 128$ params, ≈ 321 만 MAC
- 파라미터 비율 **5배**인데 FLOPs 비율은 **약 8.8배**

실습: 세 공식을 코드 한 페이지로

```
def out_size(n, k, p=0, s=1):
    return (n + 2*p - k) // s + 1
    # 1D 한방향의 출력 크기

def conv_cost(n_in, k, c_in, c_out,
              p=0, s=1):
    n_out = out_size(n_in, k, p, s)
    params = (k*k*c_in + 1) * c_out
    flops = n_out**2 * c_out \
            * (k*k*c_in)
    return n_out, params, flops

print(conv_cost(28, 3, 1, 4))      # (26, 40, 24336)
print(conv_cost(26, 3, 4, 8))      # (24, 296, 165888)
print(conv_cost(12, 3, 8, 16))     # (10, 1168, 115200)
```

- 합계 **1,504** — 손계산 표의 파라미터 합계와 정확히 일치
- “수식 → 코드 → 표”가 하나의 계산을 **세 번** 확인
- 세 공식(n_{out} , params, FLOPs)은 **독립이 아니라** 같은 $(n, k, p, s, C_{in}, C_{out})$ 에서 나란히 계산되는 **하나의 패키지**

핵심 공식 한눈에

항목	공식	무엇을 재나
출력 크기	$n_{\text{out}} = \lfloor (n + 2p - k)/s \rfloor + 1$	합성곱 후 공간 크기 (가로/세로 각각)
파라미터	$(k^2 C_{\text{in}} + 1) C_{\text{out}}$	저장해야 할 가중치 수 (bias 포함)
FLOPs	$n_{\text{out}}^2 C_{\text{out}} k^2 C_{\text{in}}$	곱셈-덧셈 횟수 (출력 위치마다 반복)
관계	$\text{FLOPs} \approx (\text{bias} \text{ \textbf{빼} params}) \times n_{\text{out}}^2$	“재고”와 “유량”의 차이

세 공식은 하나의 패키지다 — “재사용”이 만드는 효율의 숫자.

FAQ 1·2: 필터 크기와 파라미터 수

Q. 필터 크기는 왜 보통 홀수(3×3 , 5×5)?

정확히 **중심 픽셀이 하나** 있어서 “어느 픽셀을 중심으로 보는가”가 자연스럽다. 짝수(2×2)는 중심이 픽셀 사이에 걸쳐서 대칭 해석이 어렵다. 실전에서는 **3×3 을 여러 겹** 쌓는 것이 더 널리 쓰인다 — 3×3 두 개는 5×5 하나와 **같은 수용장을 18 vs 25** 파라미터로 만든다.

Q. 파라미터가 적으면 항상 좋은 건가?

학습이 빠르고 과적합(Ch. 6) 위험은 줄지만 **표현력도 줄어든다** — Ch. 4.1의 편향-분산 트레이드오프가 그대로 적용. CNN이 이미지에서 유리한 이유는 “파라미터가 적어서”가 아니라, 그 적은 파라미터가 **위치 불변성**이라는 이미지의 실제 구조에 맞는 **귀납적 편향(inductive bias)**을 인코딩하고 있기 때문이다.

FAQ 3: 스트라이드 2 vs 2×2 풀링

둘 다 면적을 1/4로 줄이는데, **세 가지 차이**:

- ① **정보 처리**: max pooling은 4개 중 3개를 **버리고** 최댓값 하나만 남김(미분 불가, 정보가 돌이킬 수 없이 사라짐). stride-2 합성곱은 각 창 안 $k^2 C_{in}$ 개를 **가중치로 합성**(미분 가능, “다운샘플링 직전에 뭘 살릴지”가 학습 대상)
- ② **자유도**: 풀링은 창 크기(2×2)와 축소율(1/2)이 함께 묶여, stride 합성곱은 필터 크기와 스트라이드를 **독립적**으로 고를 수 있다($5 \times 5, s=2$)
- ③ **역사**: LeNet·AlexNet·VGG 시절에는 max pooling이 표준 다운샘플러, **ResNet 이후** 고해상도 네트워크에서는 **stride-2 합성곱**이 주류 — 다운샘플링 자체를 네트워크가 학습

현대 네트워크는 둘을 섞어 쓰는 경우가 많다.

FAQ 4·5: FLOPs의 bias, PyTorch 확인

Q. FLOPs 공식에 bias의 “+1”이 없는데?

bias는 출력 위치당 **한 번만** 더해지는 값 — 그 비용 $n_{\text{out}}^2 C_{\text{out}}$ 은 주항 대비 **1 차수 낮은 차수 항**(일반 3×3 층에서 약 10% 미만). 표준 FLOPs 관례는 곱셈-덧셈(MAC) 수로 세고 bias를 무시.

Q. PyTorch에서 28×28 입력의 3×3 conv 출력이 정말 26×26 인가?

맞다 — `nn.Conv2d(1, 4, 3)`(기본 padding=0, stride=1)의 출력은 26×26 , `nn.Conv2d(1, 4, 3, padding=1)` 는 28×28 . PyTorch의 padding 인자는 이 절 공식의 **한 번당 패딩 수** p 그대로(총 $2p$). $p = (k - 1)/2$ 의 same-padding 트릭도 똑같이 동작. (참고: 26×26 에 또 $p=0$ 의 3×3 을 쓰면 24×24 — 짝수/홀수가 층을 지나며 바뀌지만 “크기 장부” 문제일 뿐 오류가 아님.)

확인 문제 (10.1): 숫자 네 개

- ① **출력 크기.** $56 \times 56, k=3, p=1, s=2 \rightarrow \lfloor (56 + 2 - 3)/2 \rfloor + 1 = \mathbf{28}$. (224→112 다운샘플링의 2배 크기 버전.)
- ② **파라미터·FLOPs.** 28×28 ($C_{in}=16$), 5×5 , $C_{out}=32, p=0, s=1$: (a) $n_{out} = 24$, (b) $(25 \times 16 + 1) \times 32 = \mathbf{12,832}$, (c) $24^2 \times 32 \times (25 \times 16) = \mathbf{7,372,800}$
- ③ **MLP 비교.** 앞 네트워크(1,504 / 305,424)와 같은 체적 FC(784→1,600) — FLOPs 비율은 “4배 안팎”인데 **파라미터 비율은 훨씬 큰 이유**를 한 문장으로
- ④ **실수 찾기.** “ $28 \times 28, k=3, p=1, \mathbf{s=2} \rightarrow (28 - 3 + 1)/2 + 2 = 15$ ” — 정답은 **14**. 패딩은 스트라이드로 나누기 **전에** 입력에 더해져야 한다: $\lfloor (28 + 2 - 3)/2 \rfloor + 1 = 14$

10.2 풀링과 전형적인 CNN 구조

최대 풀링: 이동에 둔감한 특징

합성곱 다음에는 보통 **풀링** 층으로 공간 크기를 줄인다. **최대 풀링(max pooling)**은 2×2 영역마다 **최댓값 하나만** 남긴다.

- 위치가 한두 칸 미세하게 움직여도 같은 최댓값이 뽑힐 가능성 높음 $\rightarrow$ 작은 이동에 **둔감한** (translation-invariant) 특징
- 풀링은 **학습 파라미터가 없음** — 순수한 **다운샘플링** 연산

4×4 특징지도를 1픽셀 오른쪽으로 살짝 옮기면 **다음 합성곱 층은 전혀 다른 16개의 숫자**를 보게 된다. 그런데 2×2 최대풀링을 적용하면 **두 경우 모두** 같은 결과:

$$\text{maxpool} = \begin{bmatrix} 1 & 3 \\ 1 & 4 \end{bmatrix} \quad (\text{원본과 1픽셀 이동, 동일})$$

“약간 세로선”은 살아남고, “정확히 어느 픽셀”은 버려진다

네 영역 각각(좌상·우상·좌하·우하)에서 원본의 최대값 (1, 3, 1, 4) 과 이동 후의 최대값 (1, 3, 1, 4) 이 같다.

핵심

“여기에 (대략) 세로선 같은 패턴이 있다”는 정보는 **살아남고**, “정확히 어느 픽셀에”는 정보는 **버려진다**.

- 최대풀링이 이동 불변성을 “완벽히” 주진 않는다 (2픽셀 이상 움직이면 풀링 셀 경계를 건너며 달라질 수 있음)
- 하지만 **한두 픽셀의 미세한 위치 변동**에 대해 특징지도를 “부드럽게” 만들어주는 효과는 확실

평균 풀링과 전역 평균 풀링

평균 풀링(average pooling) — 같은 영역의 **평균**을 남긴다.

- 최대풀링이 “이 지역의 **최대 반응**이 얼마나 컸는가”를 묻는다면, 평균풀링은 “**평균 반응**”
- 질감(texture) 같은 **분포 정보**를 더 잘 유지
그러나 실전에서는 **최대풀링이 압도적으로** 널리 쓰인다 — 소수 강한 반응이 “이 특징이 있다”는 **증거**이므로.

전역 평균 풀링(global average pooling, GAP) — 극단: 채널 전체($h \times w$ 모든 위치)의 평균을 **하나만** 남겨 공간 차원을 **아예 없앴**.

- “ 16×16 특징지도를 펼쳐 256개 숫자”가 아니라 “이 채널의 **평균 반응 1개**”
- 마지막 **완전연결층의 파라미터를 대폭 줄이는** 용도 (아래 VGG16에서)

풀링의 효과: 해상도 대 계산 비용

10.1절의 FLOPs 공식을 떠올리면 합성곱 연산량은 n_{out}^2 에 비례했다. 2×2 풀링은 한 번에 n 을 $n/2$ 로 줄이므로:

- **뒤이어서 오는 모든 합성곱 층의 연산량을 1/4로** 만든다
- 특징지도를 **2회** 풀링 → 공간 크기 1/4 (연산량 1/16), **3회** → 1/8 (1/64)

왜 대형 CNN은 224×224 를 7×7 로 줄이는가

“이미지 전체의 맥락”을 판단하려면 공간 해상도가 그 정도면 충분하고, **남은 용량을 특징의 수(채널) 쪽에 쓰겠다**는 설계 선택이다.

실습: 4×4 특징지도를 최대풀링으로

10.1절의 conv2d 코드와 같은 스타일로 최대풀링 직접 구현:

```
def max_pool(feature_map, pool_size=2):
    h, w = len(feature_map), \
           len(feature_map[0])
    out_h, out_w = h // pool_size, \
                   w // pool_size
    output = [[0.0] * out_w for _
               in range(out_h)]
    for i in range(out_h):
        for j in range(out_w):
            block = [
                feature_map[
                    i*pool_size+di]
                [j*pool_size+dj]
                for di in range(pool_size)
                for dj in range(pool_size)]
            output[i][j] = max(block)
    return output
```

```
fm = [[1, 0, 2, 1],
       [1, 0, 3, 1],
       [1, 0, 4, 1],
       [1, 0, 2, 1]]
```

- “원본” 특징지도를 그대로 넣으면
 $\begin{bmatrix} 1 & 3 \\ 1 & 4 \end{bmatrix}$ — 앞 계산과 **정확히 일치**
- 1픽셀 이동 버전도 **같은 결과** —
둔감함이 코드로

자주 하는 실수: 풀링을 “특징 추출”로 오해

정리

풀링은 **학습 파라미터가 없는 순수 다운샘플링** 연산이다. “특징을 추출한다”는 표현은 **합성곱 층의 역할**, 풀링의 역할은 **이미 학습된** 특징지도를 (a) 공간 해상도를 줄이고, (b) 미세한 위치 변동에 둔감하게 만드는 것.

이 구분을 섞으면 두 가지 흔한 설계 실수:

- **풀링을 너무 일찍, 너무 많이**: 첫 합성곱 직후 2×2 풀링을 하면 아직 “선분”을 감지하는 단계인데 해상도를 $1/4$ 로 줄여 **세부 정보를 잃음**. 실무에서는 **첫 두~세 합성곱 층은 풀링 없이**(스트라이드 1) 쌓고, 채널이 충분히 늘어난 뒤 풀링
- **풀링을 “합성곱의 대안”으로**: 풀링은 **합성곱 이후**에 쓰는 연산이지, **대신**이 아니다. “ 3×3 합성곱이 비싸니까 2×2 풀링으로 대체”는 학습하는 가중치를 **아예 없애버리는 것** (스트라이드 2 합성곱은 **학습 가능한** 다운샘플링이라 혼용되기도 하지만, 근본적 차이가 “학습 여부”)

수용장: 뒤쪽 층이 “보게 되는” 원본 영역

풀링의 공간 축소를 다른 관점에서 보면 **수용장(receptive field)**의 **확대**. 합성곱 한 층은 입력의 $k \times k$ 영역만 직접 보지만, 출력을 **또** 합성곱·풀링하면 두 번째 층의 뉴런 하나가 “보게 되는” 원본 영역은 더 넓어진다.

각 층의 필터 크기 k_l , 스트라이드 s_l 일 때, l 번째 층 뉴런의 수용장 크기:

$$R_l = R_{l-1} + (k_l - 1) \cdot \prod_{j < l} s_j, \quad R_0 = 1$$

- 한 층의 뉴런은 직전 층의 뉴런 k_l 개를 “보는데”, 각 뉴런이 이미 원본의 R_{l-1} 픽셀을 대표
- 인접 k_l 개의 수용장을 합치면 겹치는 $(k_l - 1)$ 픽셀만 **새로** 보이고, 이 확장량이 이전 스트라이드 곱만큼 **스케일업**

수용장 손계산 + 풀링이 스케일업하는 기제

입력 32×32 예:

층	연산	k	s	R_l
0	입력	—	—	1
1	Conv	5	1	$1+4 \cdot 1 = 5$
2	MaxPool	2	2	$5+1 \cdot 1 = 6$
3	Conv	5	1	$6+4 \cdot 2 = 14$


단 세 층 만에, 마지막 합성곱 뉴런은 원본의 14×14 영역(32×32 의 약 19%)을 “본다”.

- $3 \times 3, s=1$ 만 계속 쌓으면 $R_l = 1 + 2l$ 으로 선형
- 풀링($s=2$)을 한 번만 끼워도 그 뒤의 모든 확장이 2배 스케일업
- 10층만 쌓아도 수십 픽셀, 풀링을 섞으면 이미지 전체가 한 뉴런의 수용장

짜을 이룬다

합성곱(패턴 감지)이 “무엇을 보는가”를 학습하고,
풀링(수용장 확대·해상도 축소)이 “얼마나 넓은 시야로 보게 하는가”를 결정.

16개 층을 쌓아도: 풀링이 시야를 2배로



16개 층을 쌓아도 풀링 없이 스트라이드 1 합성곱만 쌓으면 수용장이 33px(입력 32px과 비슷)에 그치는 반면, [Conv3, Conv3, Pool2] 블록 4개를 쌓으면 **76px** — 이미지의 2배. 스트라이드 2 풀링 한 번이 그 뒤의 모든 확장을 2배 스케일업.

- Ch. 4.2 MLP에서 “은닉층을 쌓을수록 결정경계가 더 복잡한 형태”라는 관측과 **같은 원리**
- **얕은 층**은 지역적 패턴(선, 모서리)을, **깊은 층**은 그 지역적 패턴을 **넓은 시야에서 조합**한 고수준 특징(눈, 바퀴)을 감지

CNN의 전형적인 구조

$\underbrace{[\text{합성곱} \rightarrow \text{ReLU} \rightarrow \text{풀링}]}_{\text{반복}} \quad \dots \quad \rightarrow \quad \text{완전연결층 1~2개} \rightarrow \text{분류}$

- 공간 크기는 **줄이고**, 채널(특징) 수는 **늘려** 가다가 마지막에 완전연결층을 붙여 분류
- **LeNet**(1998, LeCun 등)이 **손글씨 숫자 인식**에 처음 이 패턴을 성공적으로 적용한 이래 계층 구조 그대로 유지
- 얇은 층 = 선/모서리(저수준), 깊은 층 = 눈/코/바퀴 (고수준) — 허블·비셀의 **단순 세포** → **복합 세포** 계층 구조와 같은 원리

LeNet-5 (1998)를 10.1 공식으로 풀기

층	연산	출력 크기	채널	파라미터
—	입력	32×32	1	—
C1	5×5 Conv + sigmoid	28×28	6	$(25 \cdot 1 + 1) \cdot 6 = 156$
S2	2×2 MaxPool	14×14	6	0
C3	5×5 Conv + sigmoid	10×10	16	$(25 \cdot 6 + 1) \cdot 16 = 2,416$
S4	2×2 MaxPool	5×5	16	0
C5	5×5 Conv + sigmoid	1×1	120	$(25 \cdot 16 + 1) \cdot 120 = 48,120$
F6	완전연결 (tanh)	—	84	$(1 \cdot 120) \cdot 84 + 84 = 10,164$
OUT	완전연결 (softmax)	—	10	$84 \cdot 10 + 10 = 850$
합계				≈ 6.2만

각 행은 10.1의 합성곱 공식 $(k^2 C_{in} + 1) C_{out}$ 과 완전연결 공식 $C_{in} C_{out} + C_{out}$ 을 그대로 대입(합성곱은 bias 포함, 풀링은 0).

LeNet-5에서 중요한 관찰: “펼쳐서 FC에 넣기”

- 구조의 “형”보다 **완전연결층이 입력을 어떻게 받아들이는가**가 중요 — F6은 C5의 특징지도 ($1 \times 1 \times 120$, 즉 120개 숫자)를 **펼쳐서** 입력으로 씀
- LeNet-5는 C5에서 공간 크기를 이미 1×1 로 줄여냈기 때문에 F6 입력이 120으로 **작지만** —
- **풀링을 덜 하고 채널을 크게 늘린 네트워크**에서는 이 “펼쳐진 벡터”가 **수만~수십만 길이가** 되어 **완전연결층이 파라미터의 대부분**을 차지

이 “펼쳐서 FC에 넣기”가 비효율이라는 인식이 10.3절 **전이학습**(“앞쪽 합성곱은 그대로 쓰고 마지막 FC 헤드만 재학습”)과 **전역 평균 풀링**의 동기가 된다.

공간 $32 \times 32 \rightarrow 1 \times 1$, 채널 $1 \rightarrow 120$ — “좁아지고 깊어진다” 경향의 **원형**.

AlexNet (2012)과 VGGNet (2014)

- 1990년대 후반~2012년 ImageNet 경쟁까지 “좁아지고 깊어진다” 패턴 **거의 그대로**
- **AlexNet**(Krizhevsky, Sutskever, Hinton, 2012): ImageNet 우승으로 CNN 시대 개막 — 원형은 LeNet과 같은 [Conv → ReLU → Pool] 반복, 다만 **채널**(64, 128, 256, 512)과 **깊이**를 크게 늘림

VGGNet(Simonyan & Zisserman, 2014)의 강력한 관찰

5×5 필터 하나를 3×3 필터 두 개로 대체하면, 같은 수용장(5×5)을 더 적은 파라미터로, 더 비선형으로(ReLU가 두 번 들어감) 만들 수 있다. 3×3만 쌓은 16층(VGG16)으로 같은 대회 2위 (1위는 GoogLeNet, 2014) — “**깊이 자체가 곧 힘**” 을 널리 퍼뜨림.

그런데 여기서 문제가 생겼다.

깊이 열화: 더 깊게 쌓으면 나빠진다

2015년, Kaiming He 등(마이크로소프트)이 이상한 현상을 발견: CNN을 더 깊게 쌓을수록 성능이 좋아질 줄 알았는데, 어느 지점을 넘으면 **오히려 나빠졌다**.


- **과적합이 아니다** — 학습 데이터에 대한 성능조차 나빠졌다 (training·validation이 같이 떨어짐)
- 층을 더해도 **그래디언트가 온전히 전달되지 못해** 깊은 층이 사실상 “학습이 안 되는” 문제 — Ch. 9의 그래디언트 소실이 CNN에서 **재발**

이 현상을 **깊이 열화(degradation)** 라고 부른다: “20층 네트워크는 뒤 10층을 **항등 함수**로 초기화하면 앞 10층 네트워크와 **정확히 동일**”하므로, 이론상 최소한 10층과 같은 성능을 내야 하는데 실제로는 나빠진다. ⇒ 원인은 과적합이 아니라 **최소값 찾기 최적화 문제**.


깊이 열화 재현: 스킵이 100%와 50%를 가른다

Depth degradation: same architecture and data, only skip connections differed

Loss: without skips, stuck at ln 2



Accuracy: skip connections take 50% -> 100%



24개 합성곱 층(3×3 Conv-Conv 블록 12개)을 세로줄/가로줄 데이터로 25 에폭 학습. 왼쪽: cross-entropy loss — 스킵 없이는 ln 2 근처에서 거의 움직임 없음. 오른쪽: train 정확도 — 스킵이 있는 버전만 100%에 도달. 구조·데이터·초기화 시드 모두 같고 **스킵 연결만** 달랐다.

- **평범 24층**(스킵 없음): loss ≈ 0.693 (ln 2, 동전 던지기), train_acc **0.500으로 고정**
- **잔차 24층**(스킵 있음): 15 에폭에 loss 0.355, **25 에폭 내 100% 도달**
- 매우 단순한 분류라 “학습 못 한다”가 **극단적으로** 드러난 예 — ImageNet에서는 점진적으로, 메커니즘은 같음

스킵 연결: $y = F(x) + x$

스킵 연결(skip / residual connection)은
그래디언트 **곱셈 사슬에 지름길**을 낸다 — 한
블록의 출력을 $F(x)$ 로 두는 대신, **입력을 그대로**
더한 $y = F(x) + x$ 로 정의:

```
def residual_block(x, F):  
    # F: 합성곱층몇개로 이루어진  
    # 함수에 (: Conv-ReLU-Conv)  
    return [F(x)[i] + x[i]  
            for i in range(len(x))]  
    # F(x) + x
```

왜 그래디언트를 살리는가(직관):
 $y = F(x) + x$ 를 x 로 미분하면

$$\frac{\partial y}{\partial x} = \frac{\partial F}{\partial x} + 1$$

- Ch. 9의 $\prod_l \sigma'(z_l) \cdot W_l$ 곱셈 사슬에서
 $\partial F / \partial x$ 가 아무리 작아져도(소실), “+1”
항 덕분에 그래디언트가 **최소 1은 유지**된
채 전달될 길 남음
- 입력을 “건너뛰어” 뒤쪽 층으로 **그대로**
흘려보내는 지름길

이 아이디어 덕분에 **100층이 넘는 CNN도 안정적으로** 학습할 수 있게 됐고, Ch. 12의
Transformer에도 (다른 형태로) 그대로 쓰인다.

“최소한 1”이 정말 성립하는가 — 수식과 수치

L 개의 잔차 블록을 쌓았을 때, 마지막 출력 x_L 에 대한 첫 입력 x_0 의 그래디언트는 연쇄법칙으로:

$$\frac{\partial x_L}{\partial x_0} = \prod_{l=1}^L \left(\frac{\partial F_l}{\partial x_{l-1}} + 1 \right)$$

이 곱을 전개하면(각 인자에서 “1”을 고르거나 “ $\partial F_l / \partial x_{l-1}$ ”을 고르는 모든 조합의 합) 정확히 **한** 항이 “모든 인자에서 1만 고른” = 1:

$$\frac{\partial x_L}{\partial x_0} = 1 + (\text{나머지 항들의 합})$$

스킵이 없으면 0에 수렴했을 경로에 항상 **“1”이라는 바닥**이 깔려 있다. 수치로도 확인: 무작위 초기화(표준편차 0.1)의 20층 FC에서 출력에 대한 입력의 그래디언트 노름:

- 스킵 **없는** 20층: $|dz/dx| \approx 2.5 \times 10^{-14}$ (사실상 0 — 그래디언트 소실)
- 스킵 **있는** 20층: $|dz/dx| \approx 8.2$ (신호 유지)

같은 가중치·구조, 스킵 연결만으로 **약 330조 배** ($8.2 / 2.5 \times 10^{-14} \approx 3 \times 10^{14}$) 차이.

$F(x) + x$ 의 차원 매칭 + 항등 블록의 시작점

실무: 차원 매칭

더하려면 $F(x)$ 와 x 의 차원(채널 $\times$ 공간)이 **정확히 일치**해야 한다. “채널은 늘고 공간은 줄어든다” 패턴을 따르면 F 가 $64 \rightarrow 128$ 채널, $28 \times 28 \rightarrow 14 \times 14$ 변환할 때 x 는 그대로 — **1×1 합성곱**(공간 유지, 채널만 바꿈)으로 x 의 차원을 맞춰준 뒤 더한다 (필요하면 2×2 스트라이드 1×1 합성곱으로 공간도 동시 축소).

“항등 블록”이 왜 좋은 시작점인가

F 를 **정규화된(0 근처) 작은 값**으로 초기화하면 학습 **시작** 시점에 $F(x) \approx 0$ 이라 $y \approx x$ — **항등 함수로 시작**. “깊은 네트워크가 최적의 시작점을 알은 네트워크의 항등 함수로 가질 수 있다” $\Rightarrow$ 학습이 “0에서 $F(x)$ 를 만들어야 한다”가 아니라 “이미 잘 동작하는 항등 함수 위에서 **잔차만** 미세 조정”. ResNet이 “깊은 망이 왜 어려운가”를 **표현력** 문제가 아니라 **최적화(초기화) 문제**로 재정의한 것.

배치 정규화: 스킵 연결의 “공범”

ResNet 논문은 스킵 연결과 함께 **배치 정규화(batch normalization)**(Ioffe & Szegedy, 2015)를 결합해 깊은 CNN의 학습 안정성을 크게 높였다. 합성곱 층 **사이에** 넣는 층으로, 각 **미니배치의 활성화값 분포**를 평균 0·분산 1로 표준화한 뒤, 학습 가능한 γ (스케일)· β (오프셋)로 다시 곱해/더해 “표준화가 너무 강하지 않게” 조절:

$$\hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad y = \gamma \hat{x} + \beta$$

- μ_B, σ_B^2 = 해당 **미니배치 전체** 활성화값의 평균·분산, $\epsilon = 0$ 나눗셈 방지 (예: 10^{-5})
- Ch. 9.2의 **초기화 문제를 층마다** 해결: 100층을 쌓아도 활성화값 분산이 층마다 달라지는 (폭발/소실) 것을 **학습 중에도 0·1로 되돌려, 초기화 값에 덜 민감하게** 깊게 쌓을 수 있게

“깊게 쌓기”에 필요한 두 조건 — 그래디언트가 살아서 전달되고(스킵), 활성화값이 적정 스케일로 유지되고(BN) — 를 **각각 독립적으로** 해결. (10.3에서 BN 통계 처리가 전이학습의 실전 함정이 되는 것 — μ_B, σ_B 가 **학습 시** 미니배치 기준이라 추론 시에는 **러닝된** 통계로 대체해야 함.)

실습: PyTorch SmallCNN + 파라미터 장부

세로줄 vs 가로줄(16×16 , 잡음 섞임)을 구분하는 아주 작은 CNN:

```
import torch, torch.nn as nn

class SmallCNN(nn.Module):
    def __init__(self):
        super().__init__()
        self.conv1 = nn.Conv2d(1, 8, 3,
                                padding=1)
        self.conv2 = nn.Conv2d(8, 16, 3,
                                padding=1)
        self.pool = nn.MaxPool2d(2)
        self.fc = nn.Linear(16*4*4, 2)
    def forward(self, x):
        x = self.pool(
            torch.relu(self.conv1(x)))
        x = self.pool(
            torch.relu(self.conv2(x)))
        x = x.view(x.size(0), -1)
        return self.fc(x)
```

층	연산	출력	II
—	입력 16×16	$16 \times 16 \times 1$	
Conv1	3×3 + ReLU (same)	$16 \times 16 \times 8$	
Pool1	2×2 MaxPool	$8 \times 8 \times 8$	
Conv2	3×3 + ReLU (same)	$8 \times 8 \times 16$	
Pool2	2×2 MaxPool	$4 \times 4 \times 16$	
FC	완전연결	2	

합계

Adam(lr=0.01) + CrossEntropyLoss. 초기
52%(동전 던지기) → 30 에폭 후 train/val **100%**.

10.3절에서 재사용할 **같은 모델**. 실습 노트북에서는 스킵 연결 있는/없는 두 버전으로 “깊이 열화” 실험을 직접 재현.

FAQ (10.2)

- **왜 풀링 다음에도 계속 합성곱을 쌓나?** 풀링 하나는 공간 크기만 절반으로 줄일 뿐, **패턴의 복잡도는 높이지 못함**. [합성곱 → 풀링] 을 반복해야 뒤쪽 뉴런 하나가 점점 **넓은 수용장**을 보며, 그 위에서 더 복잡한 패턴(눈, 바퀴)을 조합.
- **ResNet의 “+1”이 그래디언트 폭발을 일으키나?** 아니 — 스킵이 매 블록마다 **곱이 아니라 덧셈**으로 기여하므로, Ch. 9.2의 “곱이 지수적으로 커지는” 폭발 메커니즘과 **다름**. 그래디언트가 **여러 경로의 합**으로 전달돼 오히려 신호를 **더 고르게** 유지.
- **최대풀링의 “최댓값 위치” 정보는?** 최댓값 **그 자체**만 남기고 **어느 픽셀**이었던 정보는 **버림** — 이게 “미세 이동에 둔감”한 원리. **정확한 위치**가 필요한 문제(탐지)에서는 풀링을 거의 쓰지 않고 **스트라이드 2 합성곱**으로 다운샘플링, 또는 마지막에서 공간 **복원**(10.3 분할). “위치 보존”과 “이동 불변성”은 **트레이드오프**.
- **평균풀링을 쓰는 경우?** **전역** 평균풀링은 VGG16·현대 CNN의 마지막 분류층 **앞**에서 FC 파라미터를 크게 줄이는 용도로. **지역** 평균풀링(2×2 평균)도 “질감 분포” 요약에 쓰이지만 최대풀링보다 널리 쓰이지 않음.
- **“깊이 열화”가 과적합이 아닌 근거?** ResNet 논문의 결정적 실험: **더 깊은** 망의 **training** 정확도가 **더 얇은** 망의 training 정확도보다 **나쁨** — 과적합은 training이 오르고 validation만 떨어짐. “모델이 표현할 수 없어서”가 아니라 **최적화가 깊게 내려가지 못해서**.

확인 문제 (10.2)

- ① **수용장 손 계산.** $k=3, s=1$ 합성곱 3개 $\rightarrow 2 \times 2$ maxpool($s=2$) $\rightarrow k=3, s=1$ 합성곱 2개. 마지막 합성곱 뉴런의 수용장: $1 \rightarrow 3 \rightarrow 5 \rightarrow 8 \rightarrow 14 \rightarrow \mathbf{20}$. (풀링 한 번이 모든 **이후** 확장을 2배 스케일업.)
- ② **잔차 그래디언트 항.** $L = 3$ 블록에서 $(A_1 + 1)(A_2 + 1)(A_3 + 1)$ 을 분배법칙으로 완전히 전개하고, **모든 인자에서 “1”을 고른 항**(= 정확히 1)을 지목. 이 항이 스킵 없는 $\prod_l A_l$ 에 존재하지 않는 “바닥”임을 한 문장으로.
- ③ **구조 비교.** LeNet-5(≈ 6.2 만, FC 11,014)와 SmallCNN(1,762)의 파라미터 분포(합성곱 vs FC 비율)를 비교하고, 10.3의 전이학습이 “앞쪽 합성곱은 고정, 마지막 분류층만 재학습”하는 설계가 **왜 자연스러운지** LeNet-5 구조(C5가 공간 1×1 · 채널 120)를 들어 한 문단으로.

10.3 분류를 넘어서: 탐지, 분할, 전이학습

분류를 넘어서: 두 가지 새 문제

지금까지의 CNN은 “이미지 **전체**가 어떤 클래스인가”(분류)만 답했다. 실전 문제는 더 세밀한 답을 요구한다:

객체 탐지(Object Detection)

- “이미지 안에 사물이 **어디에**, 무엇이 있는가”
- 각 사물의 **위치**를 사각형 (bounding box, 4개 좌표)으로, 그 안의 **클래스**를 함께 예측


의미론적 분할(Semantic Segmentation)

- “**각 픽셀**이 어떤 클래스에 속하는가”
- 입력과 **동일한 크기**의 출력을 내며 각 픽셀에 클래스 라벨을 붙임
- 자율주행: “이 픽셀은 도로/보행자/차량”

탐지는 “위치까지 붙은 분류”다 — 분류는 벡터 1개를 내지만, 탐지는 사물 마다 (클래스, x , y , w , h)를 내야 하고 사물의 개수조차 모름. 어려운 부분은 “무엇을 보는가”(10.2가 이미 잘한다)가 아니라 “여러 개, 각기 다른 위치”를 **한 번의 전진전파**로 다루는가.

R-CNN (2014): “후보 → 특징 → 판정” 3단계

R-CNN 파이프라인 (2014) — 분류 CNN 위에 후보 생성 + SVM 헤드 + NMS를 붙인 것



R-CNN 파이프라인 — (1) 선택티브 서치로 ~2,000개 후보 박스,
(2) 각 후보를 224×224 로 줄여 CNN을 통과시켜 4,096차원 특징,
(3) 클래스별 SVM + 박스 회귀로 판정, (4) IoU 기반 NMS로 중복
박스 제거.

- 1 **후보 지역: 선택티브 서치** (2012, 딥러닝이 아닌 기술)가 색·질감이 비슷한 인접 영역을 합치며 후보 박스 ~**2,000개**. 슬라이딩 윈도우(수백만 개) 대비 “미리 좁히기”가 통하는 이유: 사물은 실제로 그렇게 많지 않고 작지도 않은 경우가 대부분
- 2 **특징 추출**: 2,000개 후보를 각각 224×224 로 비율만 맞춰 리사이즈하고, **분류용 CNN의 마지막 분류층을 제외한 부분을 그대로 통과** — 각 후보마다 4,096차원 특징 벡터 1개. “**분류로 배운 특징 추출기**”를 새 문제에 재사용하는 순간
- 3 **판정**: (a) **클래스별 SVM 하나씩** (Ch. 5의 SVM — 20개 클래스면 SVM 20개)로 “무엇이”, (b) **회귀 모델**로 “정확한 사물

왜 3단계인가 + 대가: 속도, 그리고 후속 3세대

- “여기에 사물이 있을 법한가”(후보) / “여기에 무슨 패턴이 있는가”(CNN 특징) / “도대체 뭘까, 어디까지인가” (SVM+회귀) — **각 단계에 가장 잘 맞는 도구를 쓰는 분업**
- 대가는 **속도**: PASCAL VOC 2012 테스트(20,000장) 1 GPU 약 **463초** vs 슬라이딩 윈도우 약 **605초**(논문 수치, 약 1.3배)로 “**느리지만 정확했다**” — 2014년 ImageNet·PASCAL 탐지를 제패 (전 SOTA 대비 15%대 mAP 향상)

이후 연구 = “정확도를 유지한 채 **어떻게 빠르게 할 것인가**”:

모델	연도	속도화 전략
Fast R-CNN	2015	이미지 하나 를 한 번 통과시켜 특징맵을 만들고, 후보마다 해당 영역의 특징만 풀링으로 공유 재사용 — 2,000회 전진전파가 1회로 줄어 10배 이상 빠짐
Faster R-CNN	2015	후보 추출(선택티브 서치) 자체도 학습 가능한 합성곱 층(RPN , Region Proposal Network)으로 — “2012년 딥러닝 이전 기술”이 마지막 남은 고리
YOLO	2016	후보도 단계도 없애고, 특징맵의 격자 위치마다 (클래스, 박스 좌표)를 한 번의 전진전파로 직접 회귀 — 탐지를 “ 회귀 문제로 ” 재정의, 실시간 탐지의 표준

네 세대 모두 “합성곱 특징 추출기 + 문제마다 다른 출력 헤드” 골격은 그대로 — 각각 10.1의 **파라미터 공유**,

IoU: 박스의 겹침을 재는 법

탐지 모델은 같은 사물에 **겹치는 박스 여러 개**를 낸다. 그래서 학습이 **아닌** 고정 후처리 **NMS(Non-Maximum Suppression, 비최대 억제)**가 붙고, 여기서 “겹기”는 **IoU(Intersection over Union)**로 잰다:

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{\text{겹치는 면적}}{\text{합쳐진(겹침 한 번만) 면적}}$$

- $[0, 1]$ 에 있고 **1이면 완전 일치**
- Ch. 3의 **재카드 지수**(Jaccard index)가 **면적 버전**으로 “박스 두 개의 비슷함”을 재는 것

손으로: $A = [0, 0, 10, 10]$, $B = [1, 1, 11, 11]$ — 교집합 $[1, 1, 10, 10] \rightarrow$ 면적 $9 \times 9 = 81$, 합집합 $100 + 100 - 81 = 119$.

$$\text{IoU} = 81/119 \approx \mathbf{0.68}$$

왜 IoU인가 — “교집합/작은 박스”나 “박스 중심거리”가 안 되는 이유는 **스케일 불변성**: 중심거리는 박스가 크면 같은 겹기라도 “멀어” 보이고, 교집합/합집합 비율은 박스를 함께 키우면(스케일) **변하지 않음**. 탐지 **훈련 라벨링**에서도 쓰인다 — 예측 박스가 정답과 $\text{IoU} \geq 0.5$ 면 “탐지 성공”
정밀도 평가 규칙이 PASCAL VOC·COCO **표준**. 같은 함수가 학습·평가 양쪽에 들어가는 셈.

NMS를 한 번 따라가보자

1. 모든 (박스, 점수)를 **점수 내림차순** 정렬 2. 가장 점수 높은 박스를 **보관**하고, 그것과 겹기가 임계값(보통 0.5)을 넘는 모든 박스를 **제거** 3. 남은 박스에서 2를 반복


박스	좌표 $[x_0, y_0, x_1, y_1]$	점수
A	$[0, 0, 10, 10]$	0.90
B	$[1, 1, 11, 11]$	0.80
C	$[20, 0, 30, 10]$	0.75
D	$[21, 1, 31, 11]$	0.60

- **A(0.90)** 먼저 보관
- B와 IoU **0.68** > **0.5** → **제거**
- 남은 **C(0.75)** 보관, D와 IoU 0.68 → **제거**
- **결과: A와 C만 남음** — 4개 박스에서 사물 2개. A,B 쌍과 C,D 쌍의 IoU가 **같은 값 0.68**을 두 번 씬으로써 “제거 기준은 점수가 아닌 **겹기**”임을 보임

NMS (threshold 0.5): 4 candidate boxes → 2 objects (only A and C remain)

A-B pair: IoU ≈ 0.68

C-D pair: IoU ≈ 0.68



4개 박스 중 NMS(임계값 0.5)가 A와 C를 남기고 B, D를 제거
A와 B의 겹기(거짓)이 한지한의 0.68을 차지해 B가 억제되는

분할: “격자 위치마다 붙은 분류기”

10.2의 분류 네트워크를 끝까지 펼쳐보자 — VGG 계열처럼 224×224 입력이 2×2 최대풀링을 **5번** 거치면 공간 크기는 $224/2^5 = 7$ 로 줄고, 마지막 합성곱 층의 출력은 7×7 **격자**(채널 512개). **분류 헤드**란 그 격자를 **펼쳐서** 1,000개 클래스 점수 하나로 모으는 층일 뿐이다.

의미론적 분할 헤드

1개의 헤드 대신, **49개의 격자 위치마다 “클래스 1,000개” 출력을 공유 가중치로 붙인다** — 마지막 층을 “ $512 \rightarrow 1,000$ 선형층”이 아니라 **출력 채널 1,000개의 1×1 합성곱**으로 바꾸면, 격자 **각 위치**에서 512개 특징을 1,000개 클래스 점수로 변환하고 그 가중치는 49개 위치가 **공유**(1×1 합성곱이 “위치당 분류기” — 10.1 FAQ의 “채널만 선형 결합”). 파라미터는 $512 \times 1,000 + 1,000$ **하나분**만 추가되지만, 답의 형태가 “벡터 1개”에서 **7×7 클래스 지도**로 바뀐다.

“각 픽셀”이 아니라 7×7 격자점인 이유: 풀링이 공간 정보를 반으로 줄인 5번의 결과 — 실제 분할 모델은 풀링을 줄이고 U-Net처럼 해상도를 **되살리는** 구조를 쓴다.

왜 공유가 올바른 편향인가 + U-Net

- “이 픽셀이 도로인가”의 정답은 이미지 좌상단이었던 우하단이었던 **같은 법칙**으로 결정됨 — 10.1에서 “고양이가 어디에 있든 같은 고양이”라 **합성곱**이 위치마다 가중치를 공유한다면, 분할에서는 “도로인지 아닌지의 판단법이 어디에서든 같다”라 **헤드**가 위치를 공유하는 것 — 합성곱의 **재사용 원리가 파이프라인의 다른 위치에서 다시 등장**

해상도 복원: U-Net(Ronneberger 등, 2015) — “ 7×7 격자 예측을 224×224 원본으로 되돌린다”는 것은 공간 크기를 5번 **더블업**(업샘플링)하는 문제, **풀링의 역방향**. “줄여가는” **코더**(encoder) 끝에 업샘플링으로 “늘려가는” **디코더**(decoder)를 **대칭**으로 붙여 **U자** 형태.

- 디코더만으로는 **어디가** 도로인지(정확한 경계)를 되찾기 어려움 — 위치 정보는 풀링에 이미 **버려짐**
- 해결책은 10.2의 **스킵 연결** — 코더의 **초기 층**(위치 정보가 아직 살아 있는 층)의 특징맵을 디코더의 **해당 레벨에 그대로 건너뛰어 더함**

ResNet이 스킵 연결로 **깊이**를 쌓을 수 있게 했다면, U-Net은 스킵 연결로 **해상도**를 되찾은 셈. U-Net이 **의료 영상 분할**(병리 슬라이드, 초음파)의 표준인 이유: “**몇십 장의 라벨만으로도** 쓸만하게 학습된다” — 전이학습·소데이터 이야기와 정확히 겹치는 지점.

전이학습: 처음부터 다시 배우지 않는다

대규모 데이터(ImageNet, 수백만 장)로 **미리 학습된 CNN의 앞쪽 층**들은 선/모서리/질감 같은 **아주 범용적인** 패턴을 감지하도록 학습돼 있다 — “고양이를 구분하는 능력”이 아니라 **“이미지를 보는 능력”** 자체에 가깝다. **전이학습(Transfer Learning)**은 이 사전학습된 앞쪽 층을 **그대로 재사용**하고, 마지막 몇 층만 새 문제에 맞게 다시 학습시킨다:

특징 추출(feature extraction)

- 사전학습된 층의 가중치를 **전부 고정 (freeze)**, **마지막 분류층만** 새로 학습
- **데이터가 적을 때** 특히 유리 — 새로 학습할 파라미터가 훨씬 적기 때문

미세조정(fine-tuning)

- 사전학습된 가중치를 **학습의 시작점**으로만 쓰고, 전체(또는 뒤쪽 일부) 층을 **낮은 학습률**로 계속 학습
- **새 데이터가 어느 정도 있을 때** 특징 추출보다 더 좋은 성능

“앞쪽 층은 범용하다”는 말의 첫 증거

- 추측이 아니라 **보여준 것** — AlexNet 논문 (Krizhevsky 등, 2012)이 학습된 **첫 합성곱 층의 필터를 그림으로 인쇄**했고, 거기서는 방향/색 대비를 감지하는 **Gabor 같은 필터**들이 늘어섬
- 장 머리에서 허블·비셀이 고양이 시각피질에서 본 **단순 세포의 수용장과 동일한 종류**의 패턴
- ImageNet 1,000개 클래스를 구분하기 위해 학습된 네트워크의 첫 층이 “고양이 특화”가 아니라 **“모서리 감지”**에 쓰였다는 뜻

전이학습이 이용하는 비대칭

층이 깊어질수록 특징이 눈·바퀴·사물 부분으로 “사물화”되는 계층 구조(10.2) 때문에, **앞으로 갈수록 재사용 가치가 높다** — **앞쪽 = 범용, 뒤쪽 = 특화.**

같은 작업에서 세 팔(arm) 비교

10.2의 SmallCNN(세로줄/가로줄 분류) 위에서 — 동일 아키텍처·동일 데이터(300 학습/200 검증)·동일 30 에폭, **다만 어느 층이 갱신되는가만** 바꿈:

팔	갱신되는 층	갱신 파라미터 (전체 1,762 중)
A. 스크래치(scratch)	전체	1,762
B. 특징 추출(frozen)	마지막 분류층(fc)만	514
C. 미세조정(fine-tuning)	전체 (낮은 학습률 0.001)	1,762

- 이 장난감 작업은 데이터가 충분하고 패턴이 단순해서 **세 팔 모두 검증 100%**에 도달
- 포인트는 **어느 쪽이 더 좋은가가 아니라, B가 전체 파라미터의 29%(514/1,762)만 건드리고도 같은 결과**를 냈다는 점
- 실제 문제에서 **데이터가 적으면 차이는 극적으로** 벌어진다 — A는 300장에 1,762개를 배우려다 **과적합**(Ch. 6)으로 검증 정확도가 처지고, B는 “새로 배울 것도 514개뿐”이라 같은 300장으로 충분히 배운다
- SmallCNN의 **합성곱 층이 1,248개(71%)**라는 장부가 전이학습의 “혜택 크기”를 직접 재주는 셈

세 팔의 코드: 동결은 requires_grad로

```
model = SmallCNN()
for p in model.conv1.parameters():
    p.requires_grad = False
for p in model.conv2.parameters():
    p.requires_grad = False

# requires_grad=True인 파라미터만
# 옵티마이저에 전달 -- fc 층만 학습됨
opt = torch.optim.Adam(
    filter(lambda p: p.requires_grad,
           model.parameters()), lr=0.01)
```

- 전체 1,762개 중 실제로 **학습되는** 파라미터는 **514개**뿐
- **30 에폭 후 검증 정확도 90%** 도달
- 학습 전후로 conv1 가중치를 직접 비교하면 **완전히 동일** — requires_grad=False 로 고정된 층은 역전파 대상에서 **아예 제외**되어, .backward() 를 아무리 호출해도 가중치가 **단 한 번도** 갱신되지 않음

두 단계 전이: “다른” 작업에서 배운 특징

실전 전이학습은 **다른(보통 훨씬 큰) 작업**에서 배운 가중치를 가져온다: (1) **큰** 데이터셋(4,000장, period 3 줄무늬 — “ImageNet”의 위장)에서 SmallCNN 학습(100%) → (2) 합성곱 가중치를 copy_로 복사, 합성곱 **동결**하고 **작은** 데이터셋(300장, period 4 — “새 문제”)의 **헤드만** 20 에폭 학습 → **검증 정확도 100%**.

```
pre = SmallCNN() # 단계1: 큰데이터에서사전학습
# ... 15 에폭학습 ... # 학습정확도 100%

model = SmallCNN()
with torch.no_grad(): # 단계2: 가중치복사
    for d, s in zip(model.conv1.parameters(),
                    pre.conv1.parameters()):
        d.copy_(s)
    # ... 도conv2 동일하게 ...
    for p in model.conv1.parameters():
        p.requires_grad = False # 합성곱동결
    # ... 도conv2 ...
opt = torch.optim.Adam(
    filter(lambda p: p.requires_grad,
           model.parameters()), lr=0.01)
# ... 20 에폭 ... # 검증정확도 100%
```

 **중요한 디테일: 새 작업의 줄무늬 주파수가 변했다 (period 3 → 4).** 사전학습된 특징은 새

어떤 데이터를 언제 쓸 것인가 + 왜 이게 되는가

새 문제의 상황

데이터가 적다(수십~수백 장)
데이터가 어느 정도 있고, 사전학습 도메인과 비슷하다
데이터가 충분하고, 도메인이 크게 다르다

추천 방식

특징 추출 — 헤드만 학습, 나머지 동결
미세조정 — 낮은 학습률, **뒤에서부터 순차 동결 해제**
스크래치도 고려 — 사전학습의 **편향(bias)**이 오히려

- 세 번째 줄이 **초보자가 놓치는 경우** — X-ray(2차원 투영, 흑백)에 RGB 자연영상의 ImageNet 특징을 그대로 없으면, “색 대비”라는 ImageNet의 핵심 신호가 **잡음**. 전이학습은 **데이터가 없을 때의 보험**이지, 도메인이 아무리 달라도 무조건 이득인 마법이 아님
- 실전 트릭: 순차 동결 해제(unfreezing)** — “마지막 층부터 뒤로 **한 층씩**” 해제, “수렴하지 않으면 다음 층을 하나 더 푼다”. 앞뒤 비대칭의 **거울상**: 층이 깊을수록 특징이 범용이라(10.2) **덜** 바뀌어야 하고, 얇을수록 도메인 특화라 **더** 바뀌어도 안전
- 왜 이게 되는가(Ch. 6)**: 정규화가 “모델을 **덜 유연하게** 만들어 분산을 줄인다”면, 전이학습은 “**시작점을 좋게 해서**” 동일한 목표 달성 — Ch. 4.1의 **편향-분산 프레임워크**가 다시 등장

자주 하는 실수 (10.3)

실수 1: 사전학습 모델의 정규화 통계를 무시

사전학습된 모델은 보통 특정 정규화(예: ImageNet의 **채널별 평균·표준편차**로 입력 표준화)를 적용받은 데이터로 학습됐다. 새 데이터에 이 정규화를 **빼먹거나 다른 값**을 쓰면, 필터들이 “본 적 없는 스케일의 입력”을 받아 성능이 예상보다 훨씬 나빠진다. **모델이 학습될 때 가정했던 데이터 분포를 추론 시점에도 정확히 재현해야 한다** — 사전학습 모델을 쓸 때는 반드시 **학습 전처리 파이프라인(평균/표준편차, 이미지 크기)**을 문서에서 확인하고 그대로 맞추는 것이 첫 단계.

실수 2: 높은 학습률로 미세조정하며 사전학습 가중치를 망침

사전학습 가중치는 사전학습 손실 지형에서 **좋은 지역**에 놓인 점. 큰 학습률(예: 0.01)로 시작하면 그 좋은 지역 경계를 **한 발로 뛰어넘는** 셈 — 범용 특징이 파괴되어 “전이한 모델”이 “전이를 안 한 것”보다 **나빠짐**. 미세조정은 스크래치 대비 **10~100배 낮은** 학습률(예: 0.001 또는 0.0001)로, 가능하면 “순차 동결 해제” 순서로 — 학습률은 “그라디언트 한 걸음의 대담함”(Ch. 9)이고, 좋은 시작점 위에서는 **작은 걸음이 정답**.

한눈에 보기: 같은 특징 추출기, 다른 헤드

문제	출력 형태	특징 추출기 위에 붙는 헤드	다
분류	벡터 1개(K개 클래스 점수)	격자 펼치기 + 선형층 1개	V
객체 탐지	(클래스, 박스 좌표 4개) × N개 사물	후보 생성 + 박스별 분류기(SVM) + NMS	R
의미론적 분할	입력과 같은 크기의 클래스 지도	위치별 공유 1×1 합성곱 (출력 채널 = 클래스 수)	U
전이학습	(위 중 아무거나)	헤드만 재학습, 또는 낮은 학습률로 전체 미세조정	—

장 마무리

네 줄 전부 10.2의 “**합성곱 스택**”이라는 **같은 줄기에 다른 헤드**를 붙인 것 — 헤드의 차이에 따라 답의 **형태만** 바뀐다(벡터 → 박스 목록 → 픽셀 지도). CNN은 “**이미지의 국소적 패턴은 위치와 무관하게 재사용될 수 있다**”는 하나의 통찰을, **합성곱이라는 연산 하나로 구현한 것** — 전이학습·탐지·분할·ResNet은 서로 다른 문제를 풀지만 전부 그 재료를 “**어떻게 재사용·재조합·안정화할 것인가**”를 답하는 응용.

FAQ (10.3)

- **분할이 분류보다 더 어려운 이유?** 격자 위치 는 고정되어 NMS 문제가 없지만 (1) **라벨 비용**: 분류는 이미지 1장에 라벨 1개, 분할은 **픽셀마다** 라벨(의료 영상 1장에 수백만 개, 전문의가 직접 그려야 함). (2) **경계**: 7×7 격자(풀링 5번) 해상도로는 “도로의 가장자리”가 흐려진다 → U-Net이 스킵으로 해상도를 **되찾아야** 함. (3) **클래스 불균형** 극단: 자율주행 프레임에서 “보행자” 픽셀은 0.1% 미만 — 정확도 99% 모델이 보행자를 **전부** “도로”로 분류할 수도 있음(Ch. 2의 정확도 함정, 픽셀 스케일에서 재발).
- **미세조정 학습률이 낮은 이유?** (실수 2) — 사전학습 가중치는 좋은 손실 지역 위에 있고, 큰 학습률은 그 지역을 **벗어나** 범용 특징을 파괴. 작은 걸음($1/10 \sim 1/100$)은 “**좋은 점의 근처에서**” 새 작업에 적응하는 것이지, 처음부터 배우는 게 아님.
- **데이터 100장뿐인데 전이학습을 해도 되나?** 그것이 전이학습의 **주식 용례**. 전제는 새 도메인이 사전학습 도메인과 “너무 다르지 않다”(가정 풍경 → 주차장 풍경은 OK, RGB 자연영상 → X-ray는 큰 점프). 100장 수준에서는 **특징 추출**(헤드만 학습)이 가장 안정적.
- **구별할 클래스가 ImageNet에 없는데? 되 며, 그게 표준 경우**. 앞쪽 층은 “고양이를 구분하는 능력”이 아니라 “**모서리를 보는 능력**”이라, ImageNet 1,000개 클래스에 없던 사물도 그 사물의 **모서리·질감**으로 앞쪽 층이 특징을 뽑아냄. 바꿔야 할 것은 **마지막 헤드**(출력 1,000개 → K개)뿐.

확인 문제 (10.3): 숫자 네 개

- ① **격자 크기.** 224×224 입력이 2×2 최대풀링을 5번 $\rightarrow 224/2^5 = 7$, “위치별 분류기” **49개**
- ② **IoU.** 박스 $[2, 3, 8, 9]$ 와 $[4, 3, 10, 7]$: 교집합 $[4, 3, 8, 7]$ 면적 **16**, 각 박스 면적 **36**과 **24** $\rightarrow$ 합집합 **44** $\Rightarrow$ $\text{IoU} = 16/44 = 4/11 \approx \mathbf{0.36}$
- ③ **NMS.** 앞 표의 4개 박스(A 0.90, B 0.80, C 0.75, D 0.60)에 임계값 0.5 $\rightarrow$ **A와 C**가 남음 (A-B 쌍과 C-D 쌍의 IoU가 **둘 다** 0.68 — “점수가 높은 쪽이 살아남는다”는 규칙만으로는 답이 안 나옴)
- ④ **헤드 파라미터.** 2048차원 특징을 1,000개 클래스 로 미세조정: $2048 \times 1000 + 1000 = \mathbf{2,049,000}$ — VGG-16 전체 1억 3,800만 파라미터에서 $\approx 1.5\%$. (“전이학습이 왜 저렴한가”의 숫자적 답)

이번 주차 정리

- ① **합성곱 = 재사용의 연산** — $n_{\text{out}} = \lfloor (n + 2p - k)/s \rfloor + 1$, params $(k^2 C_{\text{in}} + 1)C_{\text{out}}$, FLOPs에 n_{out}^2 이 곱해진다. 미니 LeNet이 MLP 대비 **0.12%의 파라미터, 1/4의 연산**.
- ② **좁아지고 깊어진다** — 합성곱이 “무엇을”(패턴), 풀링이 “얼마나 넓은 시야로”(수용장)를 결정. 깊이 열화는 **최적화 문제**이고, 스킵 연결의 “+1”이 그래디언트 바닥을 깔아 **100층이 넘는 CNN**을 가능하게 함.
- ③ **같은 줄기, 다른 헤드** — 분류(벡터 1개) / 탐지(박스 + NMS) / 분할(위치별 공유 1×1 합성곱) / 전이학습(앞쪽 동결, 헤드만 재학습). “**앞쪽 = 범용, 뒤쪽 = 특화**” 비대칭이 전이학습의 핵심.

다음 주 — Chapter 11. 시퀀스 모델

CNN이 가중치를 **공간**(이미지 위 위치)에 걸쳐 재사용한다면, RNN은 같은 가중치를 **시간**(시퀀스의 시점)에 걸쳐 재사용한다. 공간과 시간, 두 축에서 “**작은 단위 패턴을 재사용해 큰 구조를 쌓는다**”는 동일한 원리를 본 셈이다 — 이번 주차의 “재사용”이 바로 그 연결고리.