

# 어텐션과 트랜스포머

Q·K·V와 어텐션의 역사 · 스케일드 닷-프로덕트 어텐션과 셀프-어텐션 · 멀티헤드와  
포지셔널 인코딩

Machine Learning 1 · 12주차

한국과학영재학교 (KSA)

Chapter 12

# 이번 주차 개요

- **12.1 어텐션 아이디어와 Query·Key·Value** — RNN 순차성과 “은닉 상태 하나로 원문 전체 압축” 병목, 2014년 기계번역에서 태어난 어텐션, 같은 입력에서  $Q \cdot K \cdot V$ 가 왜 세 벡터인지 손으로 확인.
- **12.2 스케일드 닷-프로덕트 어텐션과 셀프-어텐션** — 4단계( $QK^T \rightarrow$  스케일링  $\rightarrow$  softmax  $\rightarrow V$  가중합) 손계산,  $\sqrt{d_k}$  스케일링의 분산 정당화, 대명사 지시 실험.
- **12.3 멀티헤드 어텐션과 포지셔널 인코딩** — “관점의 수” 문제, 파라미터 그대로 관점  $h$ 배 설계, 시계(clock) PE의 회전 성질, causal mask, 트랜스포머 블록 조립.

## 이 챕터를 마치면

$Q \cdot K \cdot V$  세 역할,  $\text{softmax}(QK^T / \sqrt{d_k})V$  의 4단계, 멀티헤드( $d_k = d_{\text{model}}/h$ ), 포지셔널 인코딩까지 — 다음 챕터 LLM 기계의 돌아가는 방식을 이미 알게 된다.

**2017년 “Attention Is All You Need” — 제목의 “All”은 무엇이 전부였던가?**

---

## 12.1 어텐션 아이디어와 Query·Key·Value

---

## RNN의 근본 문제: 순차성과 압축 병목

Ch. 11에서 본 RNN은 **한 단어씩 순서대로** 처리해야 했다 — 100번째 단어를 보려면 1~99번째를 순서대로 거쳐야 한다.

- 문제 (1): GPU는 **병렬 연산**에 특화됐는데, **순차 구조는 병렬성을 활용하지 못해** 느리다.
- 문제 (2): 먼 과거의 정보가 여러 단계를 거치며 **흐려진다** (Ch. 11의 그래디언트 소실과 정확히 같은 문제).

### 덜 눈에 띄는 세 번째 한계: 압축 병목

RNN의  $t$ 번째 은닉 상태는 1 ~  $t$ 번 입력만 볼 수 있다 — **미래** 정보는 순전파 단계에서 현재에 아예 도달하지 못한다. 기계번역처럼 “원문을 전부 읽은 뒤 번역을 시작해야 하는” 작업에서는, 원문을 처음부터 끝까지 읽은 뒤 **마지막 은닉 상태 하나**에 원문 전체의 의미를 압축해 담을 수밖에 없다 (Sutskever et al., 2014 인코더-디코더 구조가 이 형태를 강제). 문장이 길수록 한 벡터에 더 많은 정보를 구겨 넣어야 해 그만큼 잘 안 된다 — BPTT 그래디언트 소실과 같은 “길이에 대한 취약성”의 또 다른 모습.

**2014년 Bahdanau · Cho · Bengio가 보여준 우회로: 생성의 각 단계에서 “원문의 각 단어를 다시 돌아가서 보고, 적절한 비율로 쓴다” — 그게 바로 어텐션(attention)이다.**

## 어텐션의 직관: 모든 단어를 한 번에

“지금 이 단어를 이해하려면, 문장의 **다른 모든 단어를 한 번에** 보고, 그중 관련 있는 단어에 더 집중(attend)한다.”

예: “**그 동물은 도로를 건너지 않았다. 왜냐하면 그것은 너무 지쳐 있었기 때문이다.**” — “그것은”이 “그 동물”인지 “도로”인지는 **문장 전체를 동시에 봐야** 판단할 수 있다.

### RNN과의 차원이 달라지는 수식

어텐션은 현재 단어의 새 표현을 만들 때  $n$ 개 단어 각각에 **가중치 하나씩**, 총  $n$ 개를 계산 — “단어 위의 분포”를 만든다. 이  $n$ 차원 벡터를 **어텐션 가중치**라 부른다. “그것은”의 가중치는 (0.56, 0.01, 0.01, 0.42) — “동물”에 56%, 자기 자신에 42% (숫자는 12.2절 실습).

RNN이 주던 것: “과거의 **압축 요약(한 벡터)**”. 어텐션이 주는 것: “**관련 단어들의 내용을 적절한 비율로 섞은 것**”.

**어텐션의 기원은 새로운 아키텍처가 아니라, RNN에 붙인 “패치”였다** — 3년 뒤 트랜스포머는 그 메커니즘 하나만 남기고 RNN 본체를 통째로 걷어냈다. 이 장은 Ch. 11 서사의 귀결이다.

## 역사: 어텐션의 3년

(Vaswani et al., 2017) “어텐션”이라는 용어는 트랜스포머보다 **3년 앞서 기계번역** 분야에서 등장했다.

---

연도    논문

---

2014    Bahdanau · Cho · Bengio, Neural Machine Translation by Jointly Learning to Align and Tran

2015    Luong et al.

2017    Vaswani et al., Attention Is All You Need

---

기억해둘 한 줄: **어텐션의 기원은 RNN의 패치였고, 트랜스포머는 그 논리의 귀결**이다 — 12.2/12.3의 각 구성요소가 왜 그 형태인지가 훨씬 빨리 이해된다.

## Query, Key, Value — 세 가지 역할

각 단어(임베딩 벡터  $x$ )는 세 가지 벡터로 변환된다:

- **Query (Q)**: “내가 지금 무엇을 찾고 있는가”
- **Key (K)**: “나는 어떤 정보를 갖고 있는가”
- **Value (V)**: “실제로 전달할 내용”

세 벡터 모두 같은 입력 임베딩  $x$ 에 **서로 다른** 학습 가능한 가중치 행렬을 곱해 얻는다:

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

2014년 Bahdanau 버전에서는  $Q \cdot K \cdot V$ 가 모두 RNN 은닉 상태에서 나왔다 (번역 쪽 이전 은닉 상태 = Q, 원문 쪽 은닉 상태 = K = V). Q/K/V 이름 체계는 2017년 트랜스포머가 행렬 곱  $XW_Q, XW_K, XW_V$ 로 일반화하면서 표준 정착했다. 구조는 같다 — “**찾는 쪽 (질문), 답변 쪽(색인), 내용 그 자체**”의 삼각 관계.


# 도서관 비유와 전체 흐름

## 도서관 비유

- **Query** = 내가 찾는 책의 **주제**(질문)
- **Key** = 각 책의 **색인 카드**에 적힌 요약
- **Value** = **실제 책의 내용**

Query를 모든 책의 Key와 비교 → 가장 관련 있는 책들을 찾는다.

그 관련도만큼 실제 내용(Value)을 섞어서 가져오는 것이 다음 절의 어텐션 연산이다.



같은 입력 임베딩  $x_1, x_2$ 에 서로 다른 세 행렬

$W_Q, W_K, W_V$ 를 곱해  $Q \cdot K \cdot V$ 를 만들고,  $QK^T$

전수  $\rightarrow \text{softmax} \rightarrow V$ 가중합으로 어텐션 출력을



## 손으로 한 번: 같은 입력, 서로 다른 $Q \cdot K \cdot V$

단어 2개, 임베딩  $x_1 = (1, 0)$ ,  $x_2 = (0, 1)$  (즉  $X = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ ). 서로 다른 세 변환 행렬:

$$W_Q = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}, \quad W_K = \begin{pmatrix} 0.5 & 0 \\ 0 & 0.5 \end{pmatrix}, \quad W_V = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

$Q = XW_Q$ ,  $K = XW_K$ ,  $V = XW_V$  를 계산하면:

$$Q = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}, \quad K = \begin{pmatrix} 0.5 & 0 \\ 0 & 0.5 \end{pmatrix}, \quad V = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

### 핵심 관찰

같은 입력  $X$  에서 출발했는데도  $Q, K, V$  가 **서로 완전히 다른 값**으로 나온다 — 세 행렬이 각각 **독립적인 학습 파라미터**를 갖고 있기 때문이다.

# 세 행렬의 “역할”은 학습이 만든다

2단어 예의 세 행렬이 각각 하는 일:

| 행렬    | 효과                             | 역할                           |
|-------|--------------------------------|------------------------------|
| $W_Q$ | 두 번째 차원을 2배로 확대                | “찾는 방향”을 세우다                 |
| $W_K$ | 모든 차원을 절반으로 축소                 | “색인”의 스케일을 줄이다               |
| $W_V$ | 두 차원을 서로 섞음 (비대각 원소 $\neq 0$ ) | 전달할 <b>내용</b> 을 다른 공간에서 구성하다 |

이렇게 서로 다른 “역할”을 하는 변환들은 **학습을 통해 만들어진**다 — 사람이 “이 행렬은 대명사 담당”이라고 설계하는 것이 아니다.

실습:  $\text{qkv}(X, W_Q, W_K, W_V)$  함수를 완성해 손계산한  $Q, K, V$  와 일치하는지 확인 — “같은 입력에서 세 가지 다른 결과”가 나옴이 이 절의 포인트.

## 왜 “관련성”은 내적으로 재는가

12.2절에서 관련성은 **내적(dot product)**으로 잰다고 배운다. 공식이 나오기 전에 “왜 내적이냐”의 직관:

- 두 벡터의 내적  $a \cdot b = \|a\| \|b\| \cos \theta$  — 두 벡터의 방향이 얼마나 맞느냐에 비례 (노름을 나눠낸  $\cos \theta$  가 곧 Ch. 14.2의 코사인 유사도).
- 직각이면 0, 반대 방향이면 음수.
- “찾는 정보의 방향” = Query, “가진 정보의 방향” = Key 이면,  $Q \cdot K$ 는 찾는 것과 가진 것의 방향이 일치할수록 큰 숫자 — “관련성”의 정의 그 자체.

어텐션이 “공간적 거리가 가까운가”(유클리드 거리)를 재는 게 아니라 내적을 쓰는 이유: “**얼마나 가까운가**”가 아니라 “**얼마나 잘 맞는가(matching)**”를 묻기 때문.

부수적 함의: 벡터 크기가 크면 내적이 자동으로 커진다 — 12.2절이  $\sqrt{d_k}$  로 스케일링하는 이유가 여기에도 있다.

## 전체 파이프라인 미리보기: 3단계

위 2단어 예 하나로 12.2절의 “어텐션 연산” 전체를 미리 본다.

- ① 모든 단어 쌍의 **원점수(raw score)**  $QK^T$  계산
- ② 각 행에 **softmax**를 적용해 분포(어텐션 가중치) 생성
- ③ 그 가중치로  $V$ 의 행을 **가중합** → 출력

원점수:

$$QK^T = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 0.5 & 0 \\ 0 & 0.5 \end{pmatrix} = \begin{pmatrix} 0.5 & 0 \\ 0 & 1 \end{pmatrix}$$

- 단어 1의 Query (1, 0): 단어 1의 Key (0.5, 0) 과 잘 맞고, 단어 2의 Key (0, 0.5)와는 직각(내적 0).
- 단어 2의 Query (0, 2): 자기 Key와 방향 일치 ( $2 \times 0.5 = 1$ ), 단어 1의 Key와는 0.

이 예에서는  $W_Q, W_K$ 를 각 단어가 서로를 교차하지 않는 방향으로 **직접 설계**했다 — 실전에서는 이 설계를 **학습**이 대체한다.

## 계산 이어가기: 스케일링 · softmax · 가중합

$\sqrt{d_k} = \sqrt{2}$ 로 나눈 뒤 각 행에 softmax:

- 행 1:  $\text{softmax}(0.354, 0) = (0.587, 0.413)$  ( $0.354 = 0.5/\sqrt{2}$ )
- 행 2:  $\text{softmax}(0, 0.707) = (0.330, 0.670)$  ( $0.707 = 1/\sqrt{2}$ )

최종 출력 ( $V_1 = (2, 1), V_2 = (1, 2)$ ):

- 단어 1:  $0.587 V_1 + 0.413 V_2 = (1.587, 1.413)$
- 단어 2:  $0.330 V_1 + 0.670 V_2 = (1.330, 1.670)$

### 두 가지 관찰

(1) 단어 1의 출력이  $V_1$  쪽에, 단어 2의 출력이  $V_2$  쪽에 기울어 있다 (0.59, 0.67) — “관련 단어의 내용을 관련도만큼 섞는다”가 숫자로 성립. (2) 출력이 순수한 복사 (정답이면  $(2,1) \cdot (1,2)$ )는 아니다 — 다른 단어의 내용이 조금 섞여 있다.

어텐션 출력은 “가장 관련 있는 단어 하나를 고르는 것”이 아니라 “모든 Value의 가중평균” — 이 체감이 있으면 12.2절의 softmax가 “왜 합이 1인 분포여야 하는 지”가 자동으로 이해된다.

점수 차이가 클수록 어텐션 가중치는 더 집중된다: 단어 2의 점수 간격(1 vs 0)이 단어 1(0.5 vs 0)보다 크므로 가중치도 더 기울어 있다 (0.67/0.33 vs 0.59/0.41). 어떤 Key의 점수가


## A/B 비교: 변환 없이 $Q=K=V=X$ 로 쓰면

같은 2단어 예에서 **변환 없이**  $Q = K = V = X$  ( $X = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ )로 어텐션을 돌려본다: 점수

$XX^T = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \rightarrow \sqrt{2}$  스케일링 후  $(0.707, 0) / (0, 0.707) \rightarrow \text{softmax}$  후 **(0.670, 0.330) / (0.330, 0.670)**  $\rightarrow$  출력: 단어 1 = (0.670, 0.330), 단어 2 = (0.330, 0.670).

| 경우                      | 어텐션 가중치 (단어 1 행) | 단어 1의 출력       |
|-------------------------|------------------|----------------|
| $Q = K = V = X$ (변환 없음) | (0.670, 0.330)   | (0.670, 0.330) |
| 학습된 $W_Q, W_K, W_V$     | (0.587, 0.413)   | (1.587, 1.413) |

A/B comparison of attention weights — both are diagonal-dominant, differing in the degree of 'skew'



## 변환이 없으면 두 가지가 깨진다

- ❶ **자신의 임베딩과만 비게 된다.** 이 예의 임베딩이 서로 직각인 단위 벡터이므로, 각 단어는 **자기 자신과만** 높은 점수를 얻을 수밖에 없다 — 출력이 “내 임베딩에 남의 것을 약간 섞은 것”으로 고정된다.
- ❷ **학습할 여지가 없다 (더 근본적).**  $W_Q, W_K, W_V$  는 모델이 “무엇을 찾고, 무엇으로 색인하고, 무엇을 전달할지”를 데이터로부터 배울 수 있는 **유일한** 자리다.

처음부터  $Q = K = V = X$  로 고정하면 데이터에 무엇을 더 넣어도 어텐션 구조는 변하지 않는다 — “데이터가 구조를 결정”할 틈이 없는 고정 템플릿과 같다.

### 핵심

기울기가 실제로 흘러  $W_Q, W_K, W_V$  가 갱신되는 부분이 곧 모델이 “어떤 관계를 보게 될지”를 결정하는 부분이다 — 이 세 행렬의 존재가 어텐션 메커니즘의 **핵심**.

# 자주 묻는 질문 1: 왜 세 가지로 나뉘나

## Q·K·V는 왜 같은 입력에서 서로 다른 세 가지로 나뉘나요? 입력 자체를 비교하면 안 되나요?

- $Q = K = V = X$  (변환 없이 원본 입력을 그대로 씀)라면 “이 단어가 자기 자신과 얼마나 비슷한가”만 재계 되어 **표현력이 크게 제한된다**.
- 서로 다른 학습 가능한 변환  $W_Q, W_K, W_V$  를 두면, “무엇을 찾을지”와 “무엇을 제공할지”를 모델이 **데이터로부터 독립적으로 학습**할 수 있다.
- 예: 대명사는 “나를 가리키는 명사를 찾는다” 방향으로  $W_Q$  가, 명사는 “대명사가 찾는 대상이 될 수 있다” 방향으로  $W_K$  가 학습된다.

보충: “내적(유사도)으로 관련을 재고, 학습된 변환을 거친 뒤 비교한다”는 패턴은 Ch. 5.3 커널 함수  $K(x, x')$  과 정신적으로 닮아 있다.



## 자주 묻는 질문 2: Q와 K가 중복되는 것 아닌가

Q, K가 같은 X에서 나오는데, 출력이 “X를 하나의 행렬로 변환한 것”과 같지는 않나요?

- **중복이 아니다.** 점수  $QK^T$  는 두 행렬의 곱으로 결정된다 — 같은 X 여도  $W_Q$  와  $W_K$  가 무엇이냐에 따라 “어떤 단어 쌍이 만나고 어떤 쌍이 안 만나는지”가 완전히 달라진다.
- 같은 X 를 “질문 카드·색인 카드·내용 카드” 세 장으로 찍어 내는 것과 같다 — 질문·색인 카드는 **비교 단계**에서만, 내용 카드는 **전달 단계**에서만 쓰인다.
- $Q = K$  로 고정하면  $QK^T$  가 **대칭**이 되어 “내가 너를 찾는 정도” = “너가 나를 찾는 정도”가 되어 **비대칭적 관계**를 표현할 수 없다.

예: “대명사는 명사를 찾지만, 명사는 대명사를 찾지 않는다” — 실제 모델에서 어텐션의 **방향성**(어떤 헤드는 뒤쪽, 어떤 헤드는 앞쪽 단어를 본다)은 바로 이 **비대칭성**에서 나온다.

**그렇다면 왜 편향(bias)이 아니라 행렬 곱인가?**

- 편향은 모든 단어에 **같은** 벡터를 더하는 것 — “단어 A는 대명사고 단어 B는 명사”를 구분할 수 없고, 단어 사이의 **상대적 기하학**(각도, 방향)이 그대로다.
- 내적 점수는 바로 그 상대적 기하학으로 결정된다 — 점수의 의미를 바꾸려면 방향 자체를 돌리거나 늘리거나 쉼 수 있어야 한다(선형 변환). 선형만으로는 공간을 “접을” 수 없다 (Ch. 9.2) — 어텐션에서는 그 “접는 역할”을 **점수 비교**가 대신 맡는다.

## 자주 묻는 질문 4: 실제 모델에서 얼마나 큰가

2017년 원논문(Vaswani et al.)의 스케일:

- 모델 차원  $d_{model} = 512 \Rightarrow W_Q, W_K, W_V$  는 각각 **512×512** 행렬 (각각 약 **26만개** 파라미터).
- 감각 비교: Ch. 6 당뇨 회귀 문제가 특징 10개인 것과 비교하면 스케일을 잡기 좋다.
- 12.3절 멀티헤드에서는 이 512차원을  $h = 8$  개 헤드에 나눠 쓰므로 각 헤드 행렬은 **64×64**가 된다.

세 행렬 모두 **학습으로 결정**된다 — 사람이 “이 행렬은 대명사 담당”이라고 설계하지 않는다.

12.3절에서 보듯, 헤드들이 각자 다른 역할로 **스스로 분화** 한다는 것을 숫자와 관측으로 확인한다.

## 자주 하는 실수: “검색” 단계를 건너뛰기

어텐션을 “가중평균”으로만 보고 관련도 계산(3단계의 중간)을 건너뛰는 것.

- 처음 접할 때 가장 흔한 오해: 3단계의 중간 — **관련도 계산** — 을 건너뛰고 “ $V$ 의 가중평균”만 기억해 두는 것.
- $V$ 의 어떤 행이 많이 섞이게 될지를 결정하는 것은 **점수**( $QK^T$ )이며,  $V$ 가 아니라  $W_Q, W_K$ 가 그 점수를 만든다.
- $V$  = “무엇을 **mix**할지”, 점수 = “얼마나 **mix**할지”. 점수가 엉뚱하면  $V$ 의 가중평균은 **무관한 단어들의 평균**이 된다.

구현하거나 학습된 모델의 어텐션을 디버깅할 때 첫 단계는 항상 **점수 행렬의 패턴**을 보는 것:


- 대각선이 압도적으로 큰가 (각 단어가 **자기 자신만** 보는 패턴)
- 특정 열이 압도적인가 (많은 단어가 하나의 단어를 보고 — “그것은”의 “동물”처럼 **중심어**가 끌어당기는 경우)
- 거의 균일한가 (**집중 실패** — 가중치 행렬이 역할을 찾지 못했거나, 임베딩이 서로 구별이 안 되는 상태)

---

## 12.2 스케일드 닷-프로덕트 어텐션과 셀프-어텐션

---

# 트랜스포머 원논문의 핵심 연산



## Scaled dot-product attention은

Transformer 원논문의 핵심 연산. 한 단어의 Query가 모든 단어의 Key와 얼마나 “관련 있는가”를 내적(dot product)으로 잰다 (Bahdanau et al., 2014; Luong et al., 2015):

$$\text{Attention}(Q, K, V) = \text{softmax} \left( \frac{QK^T}{\sqrt{d_k}} \right) V$$

$d_k$  = Key 벡터의 **차원** (12.2 말미 실수 섹션 참고).

## 4단계로 뜯어보기

- ①  $QK^T$  — 모든 단어 쌍의 Query-Key 내적을 **한 번에** 계산한 행렬. 각 행 = 한 단어가 다른 모든 단어와 얼마나 관련 있는지에 대한 **원점수**.
- ②  $\sqrt{d_k}$  **로 나누기** (Key 벡터 차원의 제곱근) — 내적값이 차원이 커질수록 커지는 경향이 있어, softmax가 극단적인 값(0 또는 1에 가까운)만 내뱉게 되는 것을 막는 **스케일 조정**.
- ③ **softmax** — 각 행을 **확률분포**(합이 1)로 바꿈. “이 단어가 다른 단어들에게 나눠 주는 주의의 비율”.
- ④ **V 가중합** — 그 확률로 V(각 단어가 실제로 전달할 내용)의 가중합을 냄. 결과 = “**관련 단어들의 내용을 관련도만큼 섞어 담은**” 새로운 벡터.

# 코드로 4단계

(실습)

```
import math

def softmax(row):
    m = max(row)
    exps = [math.exp(v - m) for v in row]
    total = sum(exps)
    return [e / total for e in exps]

def attention(Q, K, V, d_k):
    scores = [[sum(Q[i][t] * K[j][t] for t in range(d_k))
                / math.sqrt(d_k) for j in range(len(K))]
               for i in range(len(Q))] # QK^T / sqrt(d_k)
    weights = [softmax(row) for row in scores] # softmax
    output = [[sum(weights[i][j] * V[j][t] for j in range(len(V)))
               for t in range(len(V[0]))]
               for i in range(len(Q))] # V 가중합
    return output, weights
```

실전에서는 이 4단계를 numpy 행렬 곱으로 한 줄씩 줄인다 (실습 노트북 참고).

## 코드 읽기: 4단계가 그대로 번역

- $\text{scores}[i][j] = Q[i] \cdot K[j] / \sqrt{d_k} = QK^T$  의  $(i, j)$  성분. scores 전체가  $n \times n$  원점수 행렬 자체.
- $\text{weights}[i] = \text{scores}[i]$ 에 softmax를 적용한 결과 —  $i$ 번째 단어(행)가  $j$ 번째 단어(열)에 나눠준 주의의 비율, **합이 1**.
- $\text{output}[i] = \text{weights}[i]$ 라는 가중치로  $V$ 의  $n$ 개 행을 **가중합**한 값 — “ $i$ 번째 단어가 다른 단어들에게 요청한 정보( $V$ )들을 관련도만큼 섞은 결과”.

3중 중첩 리스트 컴프리헨션이 처음엔 눈에 거슬리겠지만, 각각  $QK^T \rightarrow \sqrt{d_k}$  스케일  $\rightarrow \text{softmax} \rightarrow V$  가중합의 4단계를 **그대로 번역**한 것일 뿐이다.



## softmax를 다시 볼 이유: 차이를 증폭

Ch. 2.3(로지스틱 회귀의 출력을 확률로), Ch. 3(합이 1인 분포)에서 만난 softmax가, 어텐션 맥락에서 더 예리하게 — **원점수 간 “차이”를 지수적으로 증폭한다.**

2개 단어의 가장 단순한 경우 ( $s_1 = 0, s_2 = g$ ):

$$p_2 = \frac{e^g}{1 + e^g} = \frac{1}{1 + e^{-g}} = \sigma(g)$$

어텐션 원점수 차이에 대한 softmax는 정확히 시그모이드  $\sigma(g)$  — 로지스틱 회귀의 결정 함수가 “원점수 차이”를 입력으로 받는 모습. 두 원점수 사이의 “차이” 크기가 가중치의 극단적 정도를

|                | 원점수 차이 $g$ | 가중치 $(p_1, p_2)$ | 해석        |
|----------------|------------|------------------|-----------|
| 사실상 단독으로 결정한다: | 0.5        | (0.378, 0.622)   | 아직 균형     |
|                | 2          | (0.119, 0.881)   | 한쪽 우세     |
|                | 8          | (0.0003, 0.9997) | 사실상 하드 선택 |

차이가 0.5에서 8로 **16배**가 되자 “62:38의 균형”이 “99.97:0.03의 독주”로. 원점수가 큰 차원의 내적(차원에 비례해 커짐)을 그대로 놓으면 거의 one-hot — “관련 단어 하나만 고르는” 하드 경로가 되어 (1) 선택된 단어의 가중치 미분이 0(학습 신호 끊김), (2) 원점수 미세 변화에 가중치가 급격히 뒤집혀 불안정.  $\sqrt{d_k}$  스케일링은 이 “softmax의 극단화”를 막는 안전장치.

## $\sqrt{d_k}$ 로 나누는 이유: 분산의 정수학

“내적값이 차원이 커질수록 커진다”는 정확히 무엇을 뜻하는가?

- $q = (q_1, \dots, q_{d_k}), k = (k_1, \dots, k_{d_k})$  가 서로 독립이고 각 성분이 **평균 0·분산 1**의 분포에서 나온 벡터라고 하자.
- 내적  $\sum_{t=1}^{d_k} q_t k_t$  는 독립한 **0평균 곱  $d_k$ 개의 합**.
- 각 항  $q_t k_t$  의 분산은 1 (독립 0평균·분산 1 변수 두 개의 곱)이고, 독립 변수의 합은 **분산이 더해진다**.

$$\mathbb{E}[q \cdot k] = 0, \quad \text{Var}[q \cdot k] = d_k \quad \Rightarrow \quad \text{표준편차} = \sqrt{d_k}$$

즉 스케일링하지 않은 내적은  $\sqrt{d_k}$  스케일로 “자라난다” — 차원 64이면 표준편차 약 8, 차원 512이면 약 23. 원점수가  $\pm 20 \sim 30$  스케일로 벌어지면, softmax는 one-hot에 붙어버린다.

# 실제로 재보기: 무작위 내적 200쌍

무작위 벡터(각 성분  $\mathcal{N}(0, 1)$ ) 두 개를 200쌍 만들어 내적 계산 ( $d = 64$ ):

관측 범위


스케일링 전  $-19.1 \sim +22.3$

$\sqrt{64} = 8$ 으로 후  $-2.4 \sim +2.8$

- 최대치  $22.3 \approx 2.8\sigma$  — 기대와 일치.
- 전의  $-19 \sim +22$ 면 softmax는 사실상 one-hot ( $\sigma(22) \approx 1 - 2.7 \times 10^{-10}$ ).
- $\sqrt{64} = 8$ 으로 나누면  $-2.4 \sim +2.8$  — “분화된 가중치”를 정상적으로 내는 범위.

$\sqrt{d_k}$ 는 “마법 숫자”가 아니라 **내적의 표준편차를 정확히 1로 되돌리는 상수** — “무작위 기준선”에서 얼마나 벗어났는지를 표준편차 단위로 재계 한다.

$\sqrt{d_k}$ 가 “차원을 모르는 마법 상수”가 아니라 **“내적의 표준편차를 1로 환원하는” 스케일**이라, 원점수가 의미 있는 차이를 가질 때 softmax가 어떤 차원이든 정상적으로 분화된다.



차원  $d_k$ 가 커질 때, 스케일링 없이  $d: 4 \rightarrow 256$ 이면 softmax **최대 가중치  $0.63 \rightarrow 0.96$**  (one-hot에 수렴);  $1/\sqrt{d_k}$  스케일링은  $d$ 와 무관하게  **$0.46 \rightarrow 0.04$** 로 낮게(분화되게) 유지 (500회 평균, 실습 실험 6).

## 온도(temperature) 관점

“ $\sqrt{d_k}$ 가 아니라  $d_k$ 로 나누면 안 되나?”

- $d_k$ 로 나누면 내적의 표준편차가  $1/\sqrt{d_k}$ 까지 **과도하게** 줄어든다 — 원점수가 모두 0에 붙어 softmax가 **균등분포**( $1/n$ )에 가까워지고, “어떤 단어가 관련 있는가” 구분하는 신호가 소실된다.
- 스케일링은 “**정확히** 정규화”의 문제 —  $\sqrt{d_k}$ 가 아니라  $d_k$ 나 1이면 softmax 출력이 극단(one-hot)이나 반대(균등)로 치우친다.
- 실습 노트북에서 세 가지 스케일 ( $1, \sqrt{d_k}, d_k$ )을 같은 원점수에 적용해 가중치 분포를 나란히 비교.

### 더 일반적인 형태: 온도 $t$

어텐션 원점수를 온도  $t$ 로 나눠  $\text{softmax}(s/t)$ 로 적용.  $t$  크면 가중치가 **균등에 가까워지고**,  $t$  작으면 **극단적**(한 단어 독주).  $\sqrt{d_k}$  스케일링은 초기 무작위 상태에서 원점수의 표준편차가  $\sqrt{d_k}$ 라는 사실을 이용해  $t = \sqrt{d_k}$ 라는 “**정규 온도**”를 선택한 것. 실전에서 이 온도 관점으로 어텐션을 의도적으로 “분산”/“집중”하게 조절하기도 한다.

## 실습: 원점수 2개만 있는 예로 흐름 추적

$n = 2, d_k = 2$  아주 작은 예.  $Q = K = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, V = \begin{pmatrix} 10 & 0 \\ 0 & 10 \end{pmatrix}$ .

① **Step 1** —  $QK^T$ : 항등행렬이므로  $QK^T = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ . (1,1) 성분 =  $1 \times 1 + 0 \times 0 = 1$ .

② **Step 2** —  $\sqrt{d_k} = \sqrt{2} \approx 1.414$  로 나누기:  $\frac{QK^T}{\sqrt{2}} = \begin{pmatrix} 0.707 & 0 \\ 0 & 0.707 \end{pmatrix}$ .

③ **Step 3** — 첫 행  $[0.707, 0]$  에 softmax:  $e^{0.707} \approx 2.028, e^0 = 1$ , 합 3.028.

$$p_1 = \frac{2.028}{3.028} \approx 0.670, \quad p_2 = \frac{1}{3.028} \approx 0.330$$

첫 단어는 자기 자신에 67%, 다른 단어에 33% —  $Q \cdot K$ 가 같은 벡터라 자기 비교가 항상 한 번 더 유리한 구조(아래 “자기 주입” 참고).

④ **Step 4** — 가중합:  $\text{out}_1 = 0.670 \times V_1 + 0.330 \times V_2 = (6.70, 3.30)$ .

출력 (6.70, 3.30) 을  $V$  의 원행들 (10, 0), (0, 10) 과 비교하면 첫 번째  $V$  에 67%의 “분량”이 더 섞여 있다는 것이 직접 보인다 — “관련도가 높은 단어의 Value가 더 많이 기여한다”는 어텐션의 핵심 행동이 숫자로 구현된 모습. (이 예는 12.3절 연습문제 3의 설정과 정확히 같다.)

## 어텐션 출력의 볼록성: 볼록 껍질 안에만 존재

마지막 단계(가중합)가 **가중치의 합이 1인 가중 평균**이라는 사실은 출력의 범위에 강한 제약을 준다:

- 각 출력  $o_i = \sum_j w_{ij} v_j$  ( $\sum_j w_{ij} = 1, w_{ij} \geq 0$ )은  $V$ 의 원행들의 볼록 결합  $\Rightarrow V$  원행들로 만드는 볼록 껍질 (convex hull) 안에 항상 존재.
- 네 단어 예 숫자로 확인: “동물”의 출력  $[2.898, 0.133, 0.010]$  —  $V$  원행(=  $E$ 의 원행)들의 범위가 각 차원 0~3인데, 각 성분은 모두 0~3 안에 있고 성분 합도 **3.041**로  $V$  원행의 성분 합 (= 3)과 거의 같다. “균등 어텐션”(모두 1/4)의 출력은 단순 평균  $[1.45, 0.825, 0.75]$ 로, 실제 출력과는 완전히 다른 벡터 — 가중치가 “분포”에 따라 출력은 볼록 껍질 안에서 아무 위치나 만들 수 있다.

### 실전에서 이어지는 두 가지

(1) 출력의 스케일이 입력 스케일의 범위 안에 갇혀 있다 —  $V$ 가 큰 값으로 학습되면 출력도 그 범위 안에서만 “미세 조정”(때로는 장점 — 안정성, 때로는 한계 — “ $V$ 가 표현할 수 없는 값”은 한 층으로 만들 수 없음). (2) 가중치가 극단(one-hot)이면 출력은  $V$ 의 어떤 원행에, 균등이면 평균에 가까워진다 — softmax는 “어떤 원행을 얼마나 섞을지”의 비율, 새로운 값이 아니라 섞임을 만드는 도구.

## Self-Attention: 문장이 자기 자신을 본다

Q, K, V가 모두 같은 문장에서 나오면 **self-attention** — 각 단어가 같은 문장 안의 다른 모든 단어(자기 자신 포함)와의 관련도를 계산. 이게 이번 장 도입부의 메커니즘: “그것은”의 Query가 문장 안 모든 단어의 Key와 내적했을 때 “그 동물”의 Key와 **가장 높은 점수**가 나오도록 학습된다.

### 구조를 한 줄로

각 단어의 “새로운 표현” = 같은 문장 안의 모든 단어(자기 자신 포함)의 Value 벡터를, “그 단어가 각각과 얼마나 관련 있는가”를 softmax로 나눠 **가중평균한 값**.

**각 단어의 출력이 서로 독립이 아니다** — 앞 네 단어 예에서 “동물”의 출력에 “그것은”의 Value가 41.2% 섞여 있는 동시에, “그것은”의 출력에도 “동물”의 Value가 56.1% 섞인다. 두 단어는 서로의 표현을 서로에게 공급하면서 **동시에 업데이트** — RNN의 순차적 은닉 상태 업데이트와 **가장 근본적으로 다른 점** (12.1절의 병렬성 문제 바로 그 차이).


또 하나: 어텐션 연산 자체에는 “단어의 위치”라는 정보가 전혀 없다.  $QK^T$  는 내적만 계산 — 단어를 재배열해도 각 쌍의 원점수는 그대로(**순서 불변**), “강아지가 고양이를 쫓는다”와 “고양이가 강아지를 쫓는다”가 같은 출력을 내는 것은 이 순서 불변성의 직접 결과. 해결책 **positional encoding** (12.3절) — 여기서는 “어텐션이 순서를 모른다는 사실 자체”를 기억해 두자.

# 실습: 대명사 지시 관계를 시각화

(self-attention) 네 단어 [동물, 도로, 건너지, 그것은] 에 직접 설계한 임베딩으로 self-attention:

```
words = [ "동물", "도로", "건너지", "그것은" ]
E = [[3,0,0], [0,3,0], [0,0,3], [2.8,0.3,0]]
# 그것은이 "" 동물과 "" 유사하게 설계됨
Q = K = V = E
output, weights = attention(Q, K, V, d_k=3)
for w, row in zip(words, weights):
    print(w, [round(x, 3) for x in row])
```

|     | 동물           | 도로    | 건너지   | 그것은   |
|-----|--------------|-------|-------|-------|
| 동물  | 0.582        | 0.003 | 0.003 | 0.412 |
| 도로  | 0.005        | 0.980 | 0.005 | 0.009 |
| 건너지 | 0.005        | 0.005 | 0.984 | 0.005 |
| 그것은 | <b>0.561</b> | 0.007 | 0.004 | 0.427 |





## 왜 softmax가 이렇게 극단적인가 — 원점수에서

“같은 계산을 원점수 단계에서 한 번 더 펼쳐보면” 왜 softmax가 이렇게 극단적인 가중치를 내는지 선명해진다:

- $QK^T/\sqrt{3}$ 의 “그것은” 행은  $[4.85, 0.52, 0.0, 4.578]$  — “동물”(4.85)과 자기 자신(4.578)이 다른 두 단어(0.52, 0.0)보다 크게 벌어져 있다.
- softmax가 이 **4.85 vs 0.52의 차이를 지수적으로 증폭** ( $\approx e^{4.33} \approx 75$ 배)해서 **56% vs 0.7%**의 가중치로 변환.

### 두 단계의 “스케일이 다르다”

softmax 이전: “동물”과 “도로”의 원점수 차이 **4.33**이라는 절대적 크기. softmax 이후: **56배의 가중치 비**라는 상대적 비율. — 이 스케일 차이가 “softmax가 차이를 증폭한다”는 관찰의 구체적 수치다.

## 이 예의 한계를 정확히 짚어두기

- 위 계산은 임베딩을 손으로 설계한 것 — “그것은이 동물과 관련 있다”는 설계가 결과에 그대로 담기는 “확인 실험”(confirmation experiment)에 가깝다. 실제 모델에서는 이 임베딩과  $W_Q, W_K, W_V$  가 데이터로부터 학습되어 “의미적으로 관련된 단어가 서로 높은 원점수를 낸다”는 패턴이 스스로 만들어진다.
- 이 예의  $d_k = 3$  은 너무 작아  $\sqrt{d_k}$  스케일링의 “극단화 방지” 효과가 실제로는 약하게 보인다 (원점수가 0~5 범위라 softmax가 이미 충분히 분화되어 있음).
- $d_k$  가 크면(예: 512) 원점수가  $\sqrt{d_k} \approx 23$  스케일로 벌어져 스케일링이 없으면 one-hot으로 붙는 것 — 앞 절의 “무작위 내적 분산” 논리의 본 장면.

## 자주 하는 실수: $QK^T$ 의 행/열 방향 혼동

$QK^T$  가  $n \times n$  행렬인 것은 알지만,  $(i, j)$  성분이 “ $i$ 번째 Query가  $j$ 번째 Key와 관련 있는 점수”인지 그 반대인지를 헷갈리는 것이 이 절의 가장 흔한 실수.

확인법은 단순:  $QK^T$  의  $(i, j)$  성분은  $Q$  의  $i$ 번째 행과  $K^T$  의  $j$ 번째 열, 즉  $Q$  의  $i$ 번째 행과  $K$  의  $j$ 번째 행의 내적.

### 읽는 법

**행** = “어떤 단어가 (Query로) 보고 있는가” (누가 주의를 주고 있나)

**열** = “어떤 단어가 (Key로) 보고받고 있는가” (누가 주의의 대상인가)

네 단어 예에서: “그것은”의 행(4번째,  $[0.561, 0.007, 0.004, 0.427]$ ) = “그것은이 각 단어에 주는 주의”. “동물”의 열(1번째,  $[0.582, 0.005, 0.005, 0.561]^T$ ) = “각 단어가 ‘동물’에 주는 주의”.

## 어텐션은 대칭적이지 않다

- “그것은 → 동물”의 가중치 **0.561**은 “동물 → 그것은”의 가중치 **0.412**와 같지 않다.
- 어텐션은 대칭적이지 않다.
- 이유:  $QK^T$  가  $KQ^T$  와 일반적으로 다르다 — 내적은 대칭이지만,  $Q$  와  $K$  가 서로 다른 변환  $W_Q, W_K$  를 거치므로 “내가 찾는 것”과 “내가 가진 것”이 서로 다를 수 있다.
- 12.1절 FAQ에서 “왜 Q, K, V를 나눴는가”의 정답이 바로 이 **비대칭**에서 온다.

실습에서는 어텐션 행렬을 시각화해서 확인: “행 = Query, 열 = Key”라 적힌 라벨을 보고, “그것은”의 행이 “동물” 열과 만나는 칸 (= 0.561)이 “그것은이 동물에 주는 주의”임을 직접 확인. 이 “어떤 칸을 읽고 있는지”를 직관적으로 잡는 것이, 12.3절 멀티헤드에서 “**각 헤드가 어떤 관계를 포착하는가**”를 읽는 기초가 된다.

## 자주 하는 실수: $d_k$ 를 “임베딩 차원”으로 오해

$\sqrt{d_k}$  의  $d_k$  가 “임베딩 차원”이라는 것은 아니다.

- $d_k$  는 **Key 벡터의 차원**, 즉  $W_K$  가 만들어낸 벡터의 길이.
- 12.1절에서  $K = XW_K$  로,  $W_K$  가 입력 임베딩 차원  $d_{model}$  에서  $d_k$  **차원으로 투영**하는 변환임을 보았다.
- $d_{model} = 512$  인데  $d_k = 64$  라면,  $K$  는 64차원 벡터이고 스케일 상수는  $\sqrt{64} = 8$ .

이 투영 자체가 **파라미터 수를 줄이는 효과**( $512 \times 512$  행렬 대신  $512 \times 64$ )를 주기도 하지만, 그것보다 중요한 역할은:

- “**비교에 쓸 차원**”( $d_k$ )과 “**전달할 내용의 차원**”( $d_v$ , **Value의 차원**)을 독립적으로 설계할 수 있게 해준다.

이 “**비교 차원 vs 내용 차원을 분리**하는 아이디어”가 12.3절의 **멀티헤드 설계**(각 헤드가 자신의 작은  $d_k, d_v$  를 가짐)의 직접적 전제 조건이 된다.

## 확인 문제 4개(요약)

- 1 (원점수 손계산)  $n = 3, d_k = 2$  로  $QK^T$  를 구하고, 3번째 행을  $\sqrt{2}$  스케일링 + softmax.  
힌트:  $Q$  의 3번째 행  $(1, 1)$  과  $K$  의 세 행  $(1, 0), (1, 1), (0, 1)$  의 내적 =  $1, 2, 1 \Rightarrow [0.707, 1.414, 0.707] \rightarrow \approx [0.248, 0.503, 0.248]$  — 가운데  $K$  에 가장 높은 가중치.
- 2 (스케일링의 효과) 네 단어 예( $d_k = 3$ )의 임베딩을 10배로 확대하면  $QK^T$  는 100배  $\Rightarrow \sqrt{d_k}$  스케일링은 그대로이므로 softmax가 극단적으로 one-hot. “스케일링 상수는 초기 분산 기준이라, 임베딩 스케일이 변하면 다시 조정”해야 한다.
- 3 (순서에 대한 대칭) 임베딩  $[x_1, x_2]$  와 순서 뒤집은  $[x_2, x_1]$  에 self-attention 적용 — 각 단어의 출력(대표)은 같지만,  $W$  행렬은 행/열 인덱스가 재배열된 **퍼뮤테이션-등변** 관계. “순서 정보의 결핍”이 12.3절 PE의 동기.
- 4 (블록성 검증 — 코드) 각 출력 벡터가  $V$  의 4개 원행 최소/최대 성분 범위 안에 있는지 필요 조건으로 확인. (“블록 겹질 안에 있으면 범위에 반드시 있지만, 범위에 있어도 블록 겹질 안에 있지 않다”)

# 자주 묻는 질문 1: 문법적으로 “옳은” 대상에 집중하나

## 어텐션 가중치가 항상 “문법적으로 옳은” 대상에 집중 하나요?

- **항상 그렇지 않다.** 학습된 모델의 어텐션 헤드를 실제로 들여다보면, 어떤 헤드는 정확히 대명사-선행사 관계에 집중하지만, 다른 헤드는 그냥 **바로 이웃한 단어나 문장부호**에 집중하는 등 사람이 보기에 “덜 해석 가능한” 패턴을 학습하기도 한다 (Michel et al., 2019).
- 12.3절의 **멀티헤드 구조**가 바로 이런 “서로 다른 역할을 가진 여러 헤드”를 병렬로 두는 이유.

## 자주 묻는 질문 2·3: 변환이 없으면?

**softmax 없이 내적값을 바로 가중치로 쓰면 안 되나요?** 내적값은 범위가 정해져 있지 않고(음수 가능), 단어마다 스케일이 달라져 “합이 1” 보장이 없으니 출력 스케일이 불안정. softmax는 Ch. 2.3 로지스틱회귀와 동일한 역할 — 임의의 실수를 “합이 1인, 항상 양수인 분포”로 바꿔 안정적인 보간(interpolation)으로.

**$V$  도 같은 임베딩에서 나오는데, 왜 서로 다른  $W_V$  가 필요한가?  $V = X$  로 못 하나?**

- 가능하지만 **표현력이 제한**:  $V = X$  라면 출력은 “입력 임베딩들의 가중합”이므로 **한 층의 출력이 항상 입력 임베딩 공간 안에 갇혀 있다**.
- $W_V$  를 두면 “**비교에 쓰는 표현(Q,K)**”과 “**전달하는 내용(V)**”을 서로 독립적으로 학습 — 예: “그것은”의 Key는 “나를 가리킬 명사”에 높은 점수를 줘야 하고(비교용), Value는 “지쳐 있음” 같은 내용을 담아야 — 두 역할을 같은 벡터로 동시에 충당하기 어렵다.

참고: “ $Q = K = V = X$ ”만으로도 어텐션 가중치 자체는 일단 계산된다 (앞 실습이 그 설정) — 가중치 패턴이 의미적으로 잘 나오는지는  $W_Q, W_K, W_V$  가 학습되었을 때의 문제.



## 자주 묻는 질문 4: softmax의 그래디언트

$p_i = e^{s_i} / \sum_j e^{s_j}$  의  $s_k$  에 대한 미분:

$$\frac{\partial p_i}{\partial s_k} = p_i(\delta_{ik} - p_k) \quad (\text{크로네커 델타 } \delta_{ik})$$

해석: “내 확률  $p_i$  가, 내 원점수  $s_k$  를 올리면  $p_i(1 - p_k)$  만큼 증가하고, 다른 원점수  $s_j$  ( $j \neq k$ ) 를 올리면  $p_i p_j$  만큼 감소.”

### 중요한 관찰

$p_i$  가 1에 가까우면(one-hot)  $1 - p_k \approx 1 - p_i \approx 0$  이 되어 그 방향의 그래디언트가 사실상 0 — “이미 한 단어를 독점하면, 그 선택을 바꿀 학습 신호가 거의 안 온다.” 이게 “softmax가 one-hot으로 붙으면 학습이 멈춘다”는 앞 절 관찰의 **정확한 미분적 근거**.

이 미분 공식 자체는 Ch. 3 다중 분류 교차엔트로피 그래디언트 ( $p - y$ ) 와 정확히 같은 구조 — “softmax + 교차엔트로피”의 그래디언트가 선형으로 단순해지는 이유를 Ch. 3에서 본 바로 그 사실.

## 자주 묻는 질문 5: “자기 주입”은 왜 대각선이 높나

Q와 K가 같은 임베딩이면,  $q_i \cdot k_i = \|q_i\|^2 \geq 0$  (자기 자신과의 내적 = 노름 제곱, 항상 0 이상).

**Cauchy-Schwarz** 부등식  $q_i \cdot q_j \leq \|q_i\| \|q_j\|$  에 따르면, 다른 단어와의 내적이 자기 자신과의 내적보다 클 수 있는 경우는  $q_j$  의 노름이  $q_i$  보다 크고 방향까지 비슷할 때뿐 — 임베딩 노름이 서로 비슷하면 **자기 자신과의 내적이 최대가 되는 구조**.

네 단어 예에서 “도로”가 자기 자신에 **98.0%**를 주는 것이 정확히 이 구조의 산출물 — “도로”와 다른 단어 (동물 (3, 0, 0), 건너지 (0, 0, 3))와의 내적이 0인 반면, “도로”와 자기 자신 (0, 3, 0) 과의 내적이  $3^2 = 9$  이어서 softmax에서 압도적.

이 “자기 주입”은 **단점이 아니다** — 각 단어의 표현에 자기 자신의 Value를 기본적으로 포함시켜 “이 단어의 기존 정보가 완전히 사라지지 않고” 다른 단어의 정보가 추가되는 형태”로 동작 → **학습 안정성에 긍정적**.

“자기 주입 + 잔차” 조합은 10.2절 ResNet(He et al., 2015)의  $y = F(x) + x$  와 정신적으로 닮아 있다 — “출력 = 입력의 일부 + 새로운 정보” 패턴.

---

## 12.3 멀티헤드 어텐션과 포지셔널 인코딩

---

# Multi-Head Attention: 관점을 병렬로

Q, K, V를 한 세트만 쓰는 대신, **여러 세트**(“헤드”, head)를 병렬로 두고 각각 **다른 관점**의 관련성을 학습하게 한다 (Vaswani et al., 2017):

- 한 헤드는 **문법적 관계**(주어-동사)에, 다른 헤드는 **의미적 관계**(동의어)에 집중하는 식으로 역할이 나뉘는 경향이 관찰된다.
- 여러 헤드의 결과를 **이어붙인(concatenate)** 뒤 다시 한 번 **선형변환**해서 최종 출력을 만든다.

## Ch. 7.2 랜덤 포레스트(Breiman, 2001)와 같은 직관

“서로 다른 트리 여러 개의 다수결”로 단일 트리보다 안정적인 예측을 얻었던 것과 비슷. 다만 RF의 트리들은 **무작위성**만으로 다양해지는 반면, 멀티헤드의 각 헤드는 **역전파**를 통해 “서로 다른 역할을 맡는 것이 전체 손실을 줄이는 데 유리하다”는 방향으로 **스스로 분화**한다는 차이가 있다.

## 왜 헤드 하나가 부족할까 — “관점”의 문제

### “크기”의 문제가 아니라 “관점”의 문제.

- 한 개의 어텐션 헤드는 단어 쌍마다 **점수(내적) 하나**를 만든다 — 그 하나의 숫자가 그 쌍의 모든 관계를 짚어줘야 한다.
- 실제 언어에서 “단어  $i$ 와  $j$ 가 얼마나 관련 있는가”는 **여러 독립적 요인의 합**: 문법(주어-동사, 대명사-선행사), 의미(동의어, 상위어), 위치(바로 앞의 단어), 문장부호 등.
- 두 요인이 **거의 반대 방향**으로 작용하는 쌍이 항상 존재: “그것은”은 문법적으로는 “동물”을 봐야 하지만 (선행사), “도로”와 문맥상 더 가깝게 쓰일 수도 있다 (의미).
- 한 개의 점수는 이 둘을 **타협**해야 하지만, 두 개의 헤드는 각자 하나의 요인에 전부 집중할 수 있다 — 헤드가 두 개라 **“타협 대신 전담”**이 가능.

## 기하학적으로: 볼록 결합에서 직합으로

12.2절의 볼록성 논리를 떠올리면:

- 한 헤드는 각 단어에 대해  $V$  원행들의 **볼록 결합 하나**(볼록 껍질 안의 점 하나)를 만든다.
- 한 개의 헤드로는 각 단어에 “**하나의 혼합 비율**”만 표현되지만,  $h$ 개의 헤드는 “ $V_1 \cdot V_2$ 를 이 비율로 섞은 것”과 “ $V_3 \cdot V_4$ 를 저 비율로 섞은 것”을 **서로 독립적으로** 표현할 수 있다.
- 표현 가능한 영역이 **단일 볼록 결합에서 여러 부분공간의 볼록 결합의 직합(direct sum)으로 넓어진다.**

### 랜덤 포레스트 비유를 다시

단일 트리가 “한 번의 투표”라면 포레스트는 여러 투표의 병합. 헤드들도 마찬가지로 “**한 관점의 투표를 여러 개 붙여 놓는**” 것이다.

# 멀티헤드 공식

모델 차원  $d_{model}$  을  $h$ 개의 헤드에 나눠,  $i$ 번째 헤드는  $d_k = d_{model}/h$  차원의 Q, K, V 위에서 12.2절의 어텐션을 계산:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W_O, \quad \text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

- $W_i^Q, W_i^K \in \mathbb{R}^{d_{model} \times d_k}, W_i^V \in \mathbb{R}^{d_{model} \times d_v}$ : **헤드별 투영 행렬** — 각 헤드가 “무엇과 무엇을 비교할지”(Q·K)와 “무엇을 전달할지”(V)를 각자 학습(12.1절의 Q/K/V 삼분 구조가 **헤드마다 하나씩**).
- $W_O \in \mathbb{R}^{hd_v \times d_{model}}$ : 이어붙인 결과를 다시  $d_{model}$  차원으로 — “각 헤드의 정보를 어떻게 섞어 다음 층에 줄지”를 결정하는 **최종 선형변환**.

## $d_{model}$ 을 $h$ 로 나눈 이유

헤드를 “크게” 만드는 것이 아니라 “다” 만드는 것.

- 헤드 수를 늘리되 헤드당 차원을 줄이지 않으면(각 헤드도  $d_{model}$  차원 그대로), QKV 파라미터가 **헤드 수만큼 배로** 늘어난다.
- $d_k = d_{model}/h$  로 나눠야 **파라미터 수가 단일 헤드와 (거의) 같다**:

$$\underbrace{h \times 3 \times d_{model} \times \frac{d_{model}}{h}}_{h \text{ 헤드의 QKV 합계}} = 3 d_{model}^2 = \underbrace{3 \times d_{model} \times d_{model}}_{\text{단일 헤드 QKV}}$$

$d_{model} = 512$ ,  $h = 8$  으로 대면:  $8 \times 3 \times 512 \times 64 = 786,432 = 3 \times 512 \times 512$  — **정확히 같다**.  
(여기에  $W_O(512 \times 512 = 262,144)$ 만 더해진다.)

### 설계의 요지

파라미터 비용을 거의 그대로 유지한 채 독립적 관점의 수를  $h$ 배로 사는 것 — 더 많은 파라미터가 아니라 같은 파라미터를 **재배분**하는 설계. (12.2절 “ $d_k$  는 임베딩 차원이 아니라 헤드당 Key 차원”이라는 사실의 설계적 귀결.)



## 손으로 한 번: 두 헤드(자기 / 이웃)

단어 2개(임베딩  $x_1 = (1, 0)$ ,  $x_2 = (0, 1)$ ) 예에서 두 헤드를 직접 설계:

- **헤드 A (자기):**  $W_Q = W_K = W_V = I$  — 12.2절의 “자기 주입” 헤드.
- **헤드 B (이웃):** 그것과  $W_K$  **하나만**  $\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$  (두 차원을 바꾸는 행렬)로 달라도,  
 $Q = K = V = X$  에서  $K$  만 이 행렬을 거치면 각 단어가 다른 단어의 Key와 더 잘 맞게 되어  
“이웃 우선” 헤드.

| 헤드     | $W_K$                                          | 어텐션 가중치 (행=Query)                 | 읽기                       |
|--------|------------------------------------------------|-----------------------------------|--------------------------|
| A (자기) | $I$                                            | $(0.670, 0.330) / (0.330, 0.670)$ | 각 단어가 <b>자기 자신</b> 에 67% |
| B (이웃) | $\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ | $(0.330, 0.670) / (0.670, 0.330)$ | 각 단어가 <b>다른 단어</b> 에 67% |

두 행렬은 **완전한 미러다** — A 헤드의 “자기 우위” 방향이 바로 B 헤드의 “이웃 우위” 방향.  $V$  가 같은데도 **출력이 다르다:**

- 헤드 A의 단어 1 출력 =  $[0.670, 0.330]$
- 헤드 B의 단어 1 출력 =  $[0.330, 0.670]$

가중치가 반대라 섞임 비율이 뒤집힌 것.

## 이어붙임: 하나의 벡터 안에 두 관점

$W_O = I_4$  (연결만 하고 더 이상 섞지 않는 가장 단순한 경우)로 이어붙이면, 단어 1의 4차원 출력은

$$[0.670, 0.330, 0.330, 0.670], \quad \text{단어 2: } [0.330, 0.670, 0.670, 0.330]$$

읽어보면: 앞 2차원(헤드 A) = “단어 1의 자기는  $V_1$ , 단어 2의 자기는  $V_2$ ” 라는 사실; 뒤 2차원(헤드 B) = “단어 1의 이웃은  $V_2$ , 단어 2의 이웃은  $V_1$ ” 라는 **다른** 사실. 단일 헤드의 2차원 출력은 이 두 사실 중 **하나만** 담을 수 있었는데, **멀티헤드는 두 사실을 같은 벡터 안의 서로 다른 부분공간에 나란히 넣었다.**

실제 학습에서는 “자기/이웃 헤드”를 누가 말할지 **사람이 설계하지 않는다** — 손실이 줄어드는 방향으로 역전파가 각 헤드의  $W_i^Q, W_i^K, W_i^V$  를 스스로 다른 역할로 벌려놓는다.

**그런데 왜 “합치기(평균/합산)”가 아니라 “이어붙이기”인가?** 합하면  $h$ 개 헤드의 정보가 다시 하나의 벡터로 **재혼합**되어 각 헤드의 독립적 관점이 **희석**된다 — 미리 예에서 숫자로 확인: 두 헤드 출력을 더하면


$$[0.670, 0.330] + [0.330, 0.670] = [1.0, 1.0] \quad (\text{단어 2도 } [1.0, 1.0])$$

**두 단어의 출력이 정확히 같아진다!** — 미리였던 두 관점이 합산되는 순간 “이 단어와 저 단어가 다르다”는 정보가 소거된다. 이어붙임은 각 헤드 출력을 **서로 다른 차원(부분공간)**에 두어 소거를

막고,  $W_O$  가 “출력 차원  $j$ 는  $i$  번째 헤드와 몇번째 성분을 얼마 신뢰할지”를 결정하게 한다 — 46 / 62

# 세 단어 [개, 고양이, 쫓는다]: 서로 다른 3개 헤드

- (a) 자기-우위 헤드:  $Q = K = V$  로 self-attention — 12.2절 “자기 주입” 효과 (자기 자신과의 내적  $\|q_i\|^2$  가 최대)로 **대각선 우세** (“개” 0.78, “고양이” 0.74, “쫓는다” 0.93).
- (b) 위치-유사 헤드: Key만 1위치 순환 이동 ( $K_i = E_{i+1}$ ) — 각 단어는 **다음 단어**의 Key와 가장 잘 맞아 (개→고양이 0.78, 고양이→쫓는다 0.74, 쫓는다→개 0.93) — 위상(순서) 정보가 가중치에 새겨진다.
- (c) 역할 없음: 모든 Key를 (1, 1) 으로 — 모든 가중치가 **0.333 균일**, “아직 아무 역할도 분화하지 못한” 헤드.



3단어에 대해 패턴이 서로 다른 3개 헤드. 학습된 모델에는 (a)(b) 같은 서로 다른 패턴의 헤드들이 실제로 공존한다.

# 역사: 헤드 역할 분화는 관측된 사실인가

네 — “인터프리테이빌리티” 연구로 실제로 확인:

- Clark · Khandelwal · Levy · Manning (“What does BERT look at?”, 2019)은 BERT(Devlin et al., 2018)의 헤드를 하나씩 분석:

- 1 바로 앞 단어만 보는 “위치 헤드”
- 2 같은 품사의 단어끼리 집중하는 헤드
- 3 문법적 통사(주어-구문)를 추적하는 헤드


가 분명히 존재함을 보였다.

- 부수적 결과: 헤드의 50~60%를 임의로 제거해도 성능 저하 매우 작다 — 역할 분화는 실제로 있으면서도 **여분(redundancy)**이 크다 (이 때문에 **헤드 프루닝** (Michel et al., 2019)이 추론 속도 기법으로 쓰임).

- 주의: 어떤 헤드가 어떤 역할을 맡는가는 학습 run마다 다르다.


Head 8-10

- Direct objects attend to their verbs
- 86.8% accuracy at the dobj relation



Head 8-11

- Noun modifiers (e.g., determiners) attend to their noun
- 94.3% accuracy at the det relation



Head 7-6

- Possessive pronouns and apostrophes attend to the head of the corresponding NP
- 80.5% accuracy at the poss relation



Head 4-10

- Passive auxiliary verbs attend to the verb they modify
- 82.5% accuracy at the auxpass relation



Head 9-6

- Prepositions attend to their objects
- 76.3% accuracy at the pobj relation



Head 5-4

- Coreferent mentions attend to their antecedents
- 65.1% accuracy at linking the head of a coreferent mention to the head of an antecedent



## Positional Encoding: 순서 정보는 어떻게 넣나

어텐션 연산 자체는 **순서를 전혀 구분하지 않는다** —  $QK^T$  는 순서를 뒤섞어도 각 쌍의 관련도 자체는 똑같이 계산(집합처럼 취급). 그런데 “강아지가 고양이를 쫓는다”에서는 **순서가 의미를 바꾼다**. 그래서 Transformer는 각 단어의 임베딩에 위치 정보를 담은 벡터(positional encoding, 사인/코사인 함수의 고정 패턴)를 **더해서** 넣는다 — 같은 단어라도 위치가 다르면 입력 벡터 자체가 달라지므로, 어텐션이 **간접적으로** 순서를 활용할 수 있다.

“어텐션은 순서를 구분 못 한다”는 단순한 직관이 아니라, **코드로 확인할 수 있는 정리**:

- 단어 3개 [개, 고양이, 쫓는다] (임베딩 (1, 0), (0, 1), (2, 0))와 앞 두 단어를 바꾼 [고양이, 개, 쫓는다] 에 PE 없이 self-attention( $Q = K = V$ ) 적용.
- 두 문장의 어텐션 가중치 행렬:

$$W_B = P W_A P^T$$

(완전히 같은 관계 —  $P$  는 1·2행을 바꾼 **퍼뮤테이션 행렬**).

- 각 단어의 출력도 **정확히 퍼뮤테이션**: 문장 A에서 “고양이”의 출력 [0.745, 0.503], 문장 B에서 “고양이”의 출력도 [0.745, 0.503] — 같은 단어의 표현이 위치에 무관하게 정확히 같다. “누가 누구를 쫓는지”는 **통째로 사라졌다**.

permutation-equivariant(퍼뮤테이션-등변)

Made by Sumin Han · [suminhan@ksa.hs.kr](mailto:suminhan@ksa.hs.kr)

## PE의 수식: 시계 쌍

위치  $t$  의  $d_{model}$  차원 벡터를, 짝수 차원에 사인·홀수 차원에 코사인을 두는 식:

$$PE_{(t, 2i)} = \sin\left(\frac{t}{10000^{2i/d_{model}}}\right), \quad PE_{(t, 2i+1)} = \cos\left(\frac{t}{10000^{2i/d_{model}}}\right)$$

- 차원 쌍  $(2i, 2i+1)$  하나하나가 “**시계(clock)**” 하나 — 주파수  $\omega_i = 1/10000^{2i/d_{model}}$  의 사인/코사인 파동이 위치  $t$  를 따라 tock-tock하는 것.
- 가장 작은  $d_{model} = 4$  로 값을 써보면:


| 위치 $t$ | $PE(t)$ ( $d=4$ )               |
|--------|---------------------------------|
| 0      | (0.000, 1.000, 0.000, 1.000)    |
| 1      | (0.841, 0.540, 0.010, 1.000)    |
| 2      | (0.909, -0.416, 0.020, 0.9998)  |
| 10     | (-0.544, -0.839, 0.0998, 0.995) |

1번 시계(앞 짝,  $\omega = 1$ )는 **빠르게**, 2번 시계 (뒤 짝,  $\omega = 0.01$ )는 **아주 천천히** 돈다 — 첫 행에서 뒤 짝이  $(0, 1) \rightarrow (0.01, 1) \rightarrow (0.02, 0.9998)$  로 거의 제자리인 것과 대조.  $d_{model} = 512$  이면 **시계 256개** — 가장 빠른 시계 주기 약  $2\pi \approx 6.3$ , 가장 느린 시계 주기 약 60,000.

확인 문제 3:  $d_{model} = 4$  의 1번 시계 ( $\omega = 1$ )에서  $PE(3)$  의 앞 2성분  $(\sin 3, \cos 3) \approx (0.141, -0.990)$  에

# 256개의 시계 = 거의 유일한 512차원 패턴

- 256개의 시계가 모두를 합치면, 수만 단어 범위 안의 서로 다른 위치마다 거의 유일한 512차원 패턴이 생긴다.
- 2017년 모델이 512 길이의 문장을 다룰 수 있었던 이유이기도 하다.
- 빠른 시계(주기  $\approx 6.3$ )는 이웃 위치를 구분, 느린 시계(주기  $\approx 60,000$ )는 문장 전체의 “대략 어디쯤”을 표시.



(a) d=512의 1번(가장 빠른) 시계 vs 256번 (가장 느린) 시계의 사인/코사인 곡선. (b) d=4의 4개 차원 (2개 시계)을 위치  $t = 0 \sim 30$ 에 따라 그린 값 — 서로 다른 주기의 파동이 겹쳐 각 위치마다 고유한 패턴.

## 사인/코사인의 수학: 회전 성질

한 시계 쌍을 보면, 위치  $t$  의 패턴은 각도  $t\omega$  에 있는 “시계 바늘”.

**핵심 성질:** 위치  $k$  만큼 앞서는 것은, 시계 바늘을 각도  $k\omega$  만큼 돌리는 것과 동일.

즉,  $\omega$  에만 의존하는 고정된  $2 \times 2$  회전행렬  $R(\omega)$  가 존재해

$$PE_{(t+k)} = R(\omega)^k PE_{(t)}$$

가 성립(중학 수학의 “각도  $k$  회전 = 사인/코사인 가산 정리의 행렬 버전”). 2시계로 묶어  $R = \text{blockdiag}(R(\omega_1), R(\omega_2))$  로 쓰면,  $k$ 개의 위치 이동은 입력 벡터에 선형 변환  $R^k$  를 적용한 것과 정확히 같다.

### 그것이 왜 좋은가 (원논문의 표현)

“각 위치  $t$  의 PE는 상대 위치  $k$  에 대한 **선형 함수**로 표현된다” ( $PE_{(t+k)}$  의 각 성분이  $PE_{(t)}$  의 성분들의 선형 결합, 결합 계수는  $k$  에만 의존). 즉 **어텐션의 선형 도구**(Q·K 내적,  $W_O$  선형변환)만으로 “그 단어가 나보다  $k$ 칸 뒤”라는 상대 관계를 읽을 수 있다 — “절대 위치 7”이 아니라 “그 단어와의 거리 3”이 학습 대상. **차분 성질**  $PE_{(t+k)} - PE_{(t)} = (R^k - I) PE_{(t)}$  는 절대 위치  $t$  에 무관하고  $k$  만 담는 패턴을 만듦 (실습 실험 5,  $t = 3, k = 2$  수치 확인).



## 왜 “더하기”인가 — 그리고 왜 고정된 함수인가

- ① 임베딩에 더하면 총 차원이  $d_{model}$  그대로라, 12.1절 이후의 모든 행렬 크기( $W_Q, W_K, W_V$ 의 크기)와 파라미터 예산이 변하지 않는다. (붙여 넣는 concatenate도 변형으로 가능하지만 차원이 두 배가 되는 비용이 있다.)
- ② 학습하지 않고 고정 함수를 쓰는 이유:
  - ▶ 학습된 위치 임베딩: “학습 때 본 최대 위치”가 정의의 경계.
  - ▶  $\sin(t/10000^i)$ : 아무  $t$  에도 정의된다.

원논문(Vaswani et al., 2017)은 학습된 위치 임베딩도 실제 시도해 봤고, 결과 차이는 거의 없었으나 “더 긴 문장 외삽(extrapolation) 가능성”을 이유로 사인/코사인 버전을 택했다고 명시.

## 자주 하는 실수: PE를 빼먹고 어텐션만 쓰기

12.2절 실습의 attention 함수를 그대로 문장 두 개 — “강아지가 고양이를 쫓는다”와 “고양이가 강아지를 쫓는다” — 에 적용하면, 같은 세 단어로 이루어져 있으므로 (PE 없이) 두 문장에 대해 **완전히 동일한 어텐션 가중치와 출력이 나온다** — “누가 누구를 쫓는지”가 **통째로 사라지는 것**. Ch. 11.1에서 지적한 “MLP/CNN에 단어를 벡터 집합으로 넣으면 순서 정보가 사라진다”의 **형태만 바뀐 재발**: RNN은 순차 처리 구조 자체가 순서를 암묵적으로 인코딩했지만, 어텐션은 **병렬 처리를 얻은 대신** 그 암묵적 순서 정보를 잃었다 — PE로 명시적으로 다시 넣어줘야 한다.

### 정량화

PE를 넣자 같은 문장에서 “쫓는다”의 가중치 행이 **(0.187, 0.045, 0.768) → (0.013, 0.008, 0.979)** 로 달라진다 — **같은 단어라도 위치에 따라 어텐션이 달라진다는 것**, 이것이 PE가 실제로 하는 일 (실습 노트북 실험 4).

## 보너스: Masked Attention — 디코더는 왜 “왼쪽만” 보는가

트랜스포머 전체 구성에 필요한 조각이 하나 더 — 어텐션 점수 행렬에 **마스크(mask)**를 하는 것:

- 디코더가  $t$ 번째 단어를 만드는 순간,  $(t + 1)$ 번째 이후(“미래”)의 정보를 보아서는 안 된다.
- 실제 생성(추론) 시점엔 **미래가 아직 존재하지 않으므로**, 학습 때만 미래를 보고 훈련하면 **학습과 추론이 불일치**한다 (Ch. 6.1 과적합 문제와 같은 종류).
- **해법**: softmax 이전의 원점수 행렬에서, **상삼각(“미래” 위치)에  $-\infty$**  (실제로는  $-10^9$ )를 더함  $-e^{-10^9} \approx 0$  이므로 softmax 후 해당 위치의 가중치가 **정확히 0**.

### causal(인과) 마스크의 효과

학습은 모든 위치를 병렬로 계산하되 각 위치가 왼쪽만 보는 것이 가능해진다 — “학습의 병렬성”과 “생성의 순차성”을 하나의 마스크가 통일. Ch. 17 LLM의 자기회귀(**autoregressive**) 생성은 정확히 이 메커니즘 위에 있다(디코더의 self-attention이 “masked/causal attention”이라 불리는 이유).

### 3단어 예: causal mask 전/후

| 위치      | 마스크 없는 가중치 행          | 마스크 있(causal) 가중치 행       |
|---------|-----------------------|---------------------------|
| 1 (개)   | (0.284, 0.140, 0.576) | <b>(1.000, 0, 0)</b>      |
| 2 (고양이) | (0.248, 0.503, 0.248) | (0.330, 0.670, <b>0</b> ) |
| 3 (쫓는다) | (0.187, 0.045, 0.768) | (0.187, 0.045, 0.768)     |

- 첫 번째 단어는 이제 자기 자신만 본다.
- 3번째 단어(마지막)는 미래를 볼 게 없으므로 전/후 가중치 행이 동일.
- 중간 위치 2에서: “(0.248, 0.503, 0.248)  $\rightarrow$  (0.330, 0.670, 0)” — 3번째 위치(미래)에 주려던 0.248이 사라지고, 남은 두 위치에 재분배.


#### train/test 일치

“softmax 이전에  $-\infty$  를 더하면  $t$ 번째 위치가  $\leq t$  위치만 본다” — 이 점이 “**학습 때의  $t$ 번째 출력**”과 “**실제 생성 때의  $t$ 번째 토큰**”이 동일한 정보에 의존하게 만들어 train/test 일치를 보장 (힌트: 학습 때 미래를 보게 하면, 추론 때 미래가 없는 상황이 분포적으로 달라져 모델이 학습 시 익숙하지 않은 상태에 처한다 — 과적합/분포 불일치 관점).

## 전체 트랜스포머 블록: 조각 조립

12.1~12.3의 조각(Q/K/V 투영, scaled dot-product, self/multi-head, PE, causal mask)을 조립하면 **트랜스포머 블록(transformer block)**이 완성:

- 1 **multi-head self-attention** (+ 잔차 연결, layer norm(Ba et al., 2016))
  - 2 **position-wise feed-forward network**: 각 위치의 벡터를 독립적으로 2층 MLP ( $d_{model} \rightarrow 4 d_{model} \rightarrow d_{model}$ )에 통과 (+ 잔차 연결, layer norm)
- **잔차 연결**  $y = x + F(x)$ 는 ResNet(He et al., 2015)의 “단축로”와 **같은 구조** — 6~12층을 쌓아 그래디언트 경로가 길어지는 상황에서 중요.
  - **layer norm**은 **batch norm**(Ioffe & Szegedy, 2015)과 비슷한 “층마다 스케일 정규화” 역할 (Ch. 6.2 정규화 논리 참조).



## 왜 attention 뒤에 FFN이 필요한가

- self-attention은 단어 사이의 정보를 섞는 연산이지만, 그 연산 자체는 **선형**이다 — 점수  $QK^T$ , 가중합  $AV$  모두 **선형** (Ch. 9.2 “**선형만으로는 접을 수 없다**” 기억하자).
- 섞은 결과에 **비선형 변환**을 적용하는 역할이 **FFN의 몫**.

### 분담

**attention** = “어떤 정보를, 어떤 단어끼리, 얼마나 섞을지”, 그 뒤의 **FFN** = “섞인 정보를 어떻게 처리할지” — 9장 이후 반복된 “**선형 + 비선형**” 논리의 또 다른 실체.

### 참고: 파라미터 스케일의 감각

base 모델( $d_{model} = 512$ , 6 블록)에서 한 블록의 파라미터 대부분은 attention(QKV+ $W_O$  합계 약 **39만**)보다 **FFN**이 차지 —  $512 \rightarrow 2048 \rightarrow 512 = 2 \times 512 \times 2048 \approx$  **210만**. “**트랜스포머의 지식이 어디에 있는지**”를 찾는 연구 (FFN을 “키-값 메모리”로 본 해석 — Geva et al., 2020)에서 사실상의 대부분이 FFN의 가중치에 담겨 있다는 관찰이 이 비율과 맞닿아 있다.

# RNN 대비 이점

Self-attention은 모든 단어 쌍을 한 번에 병렬로 계산 — 순차 처리가 없어 GPU 병렬성을 최대한 활용, “1번째와 100번째 단어의 관련성”도 중간 99단계를 거치지 않고 직접 계산(그래디언트 소실 문제 구조적으로 훨씬 덜함).

대신: 문장 길이의 **제공**에 비례하는 계산량 ( $QK^T$  가  $n \times n$  행렬)이라는 **새로운 비용** — 아주 긴 문서를 다룰 때의 실무적 한계.

| 관점                                                                        | RNN/LSTM (Ch.11)                                                          | Self-Attention (Ch.12)                                                                                             |
|---------------------------------------------------------------------------|---------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------|
| 1번째 → 100번째 단어<br>경로<br>병렬성<br>긴 거리 의존<br>계산 복잡도(길이 $n$ 에<br>대해)<br>순서 정보 | 99 단계(순차 언폴딩)<br><br>없음(순차 필수)<br>BPTT로 그래디언트 소실<br>$O(n \cdot d^2)$ (선형) | <b>1 단계</b> ( $Q \cdot K$ 직접)<br><br><b>모든 쌍 동시</b><br><b>구조적으로 없음</b> (경로 항상 1)<br>$O(n^2 \cdot d)$ ( <b>제공</b> ) |
|                                                                           | 암묵적(순차 구조 자체가)                                                            | 명시적 (PE를 입력에 추가)                                                                                                   |

## 마지막 행이 앞 네 행의 “대가(trade-off)”

- 병렬성과 경로 길이 이점을 사면, 그 대가로:
  - ① **제공 계산량** ( $O(n^2)$ ),
  - ② “순서를 스스로 인코딩해야 하는” PE라는 명시적 장치.
- RNN은 순서 정보를 계산 구조 안에 숨겼고(대가: 순차성 + 소실), 어텐션은 입력 안에 넣었다(대가:  $n^2$  + PE 설계).
- 두 구조는 같은 “순서” 정보를 다른 곳에 둔 것.

### 자주 묻는 질문 1: $O(n^2)$ 가 실전에서 얼마나

문장 1,000단어면  $1000^2 = 100$ 만 쌍, 10,000단어면 1억 쌍 — 길이가 10배 늘면 계산량은 100배.  
이 때문에 아주 긴 문서(책 한 권 분량)를 다루는 LLM은 이 제공 비용을 줄이는 다양한 근사 기법(희소 어텐션 — Child et al., 2019; 슬라이딩 윈도우 등)을 함께 쓴다.



## FAQ 3개: PE와 헤드, RNN 메모리

- **PE가 고정인데, 모델은 “위치”를 실제로 배우는 건가?** 학습되는 것은 PE의 형태가 아니라 PE를 활용할 방법. PE는 “지도에 좌표를 찍어 주는 고정 장치”이고, 모델이 학습하는 것은 “좌표가 이런(상대) 관계로 다를 때 어텐션 점수를 이렇게 준다”는 가중치( $W_Q, W_K, W_O$  안의 패턴). “PE는 고정, PE를 쓰는 가중치가 학습”이라는 구분이 핵심.
- **512로 학습한 모델이 1000 길이를 자동 처리? 아니다** — “정의된다”는 PE 벡터 자체가  $t > 512$  에서도 유효한(비 NaN) 숫자를 낸다는 뜻이지, 그 위치에서의 어텐션 동작이 학습되었다는 뜻은 아니다. 실제 “장문 컨텍스트” LLM(LLaMA-2 4K, GPT-4 128K 등)은 단순 PE 외삽이 아니라 추가 학습(위치 보간 — Chen et al., 2023; 컨텍스트 연장 미세조정 등)이 필요. “함수가 정의된다”와 “동작이 학습된다”는 서로 다른 두 문장.
- **어텐션이 대체한 것은 RNN의 “메모리”인가?** RNN 은닉 상태 = 순차 압축된 “과거 요약”. 어텐션 = 압축이 아닌 랜덤 접근: 모든 과거(과 미래, mask 없으면)에 직접 접근. “과거를 담아 두는 메모리”(RNN 은닉 상태)와 “과거에 임의로 접근하는 메커니즘”(어텐션)은 다른 두 장치 — 어텐션이 더 좋은 것: (1) GPU 병렬성, (2) 경로 길이(→ 소실).

## 12주차 정리

- ① **12.1 — 어텐션은 RNN의 패치에서 시작** 압축 병목을 우회해 “원문 전체를 다시 보고 적절한 비율로 쓴다”.  $Q \cdot K \cdot V$ 는 같은 입력에서 서로 다른 세 변환 —  $W_Q, W_K, W_V$  가 **학습으로 결정**되며, 이 세 행렬의 존재가 어텐션의 핵심.
- ② **12.2 — 4단계와  $\sqrt{d_k} QK^T \rightarrow \sqrt{d_k}$  스케일  $\rightarrow \text{softmax} \rightarrow V$  가중합.** softmax는 원점수 차이를 지수적으로 증폭하고,  $\sqrt{d_k}$ 는 무작위 내적의 표준편차 (차원  $d_k$ )를 1로 환원하는 상수 — one-hot으로 붙는 softmax를 막는 안전장치.
- ③ **12.3 — 관점  $h$ 배 + 순서 명시적 인코딩** 멀티헤드는 **파라미터를 재배분**해 독립 관점의 수를  $h$ 배로 산다. PE는 시계(사인/코사인)의 회전 성질로 상대 위치를 선형 도구로 읽게 해준다. causal mask가 **학습의 병렬성과 생성의 순차성**을 하나로 통일.

### 다음 주차 — Chapter 13. 그래프 표현학습

노드와 엣지로 표현되는 데이터를 벡터로: Node2Vec·PageRank. “어텐션이 단어 쌍의 관련성을 직접 계산”한다는 아이디어가 “그래프의 이웃 구조”로 이동한다.