

그래프 표현학습 (Graph Representation Learning)

무작위 걷기와 정상분포 · Node2Vec: 걷기에 skip-gram · PageRank: 정상분포를
중요도로 · 확장: 단백질 · 금융 · 교통

Machine Learning 1 · 13주차

한국과학영재학교 (KSA)

Chapter 13

이번 주차 개요

- **13.1 Random Walk 기초** — 그래프 위 **무작위 걷기**가 마르코프 체인임을 정의하고, 카라테 클럽에서 걷기 말뚝치를 만들고, 노드에 머무는 장기 비율이 도(degree)에 비례함을 유도한다.
- **13.2 Node2Vec** — 걷기 경로 = “문장”, 노드 = “단어”로 word2vec의 **skip-gram**을 그대로 학습. $p \cdot q$ 두 계수가 탐색 스타일(BFS형 vs DFS형)을 어떻게 바꾸는지 작은 실험으로 본다.
- **13.3 PageRank** — “영원히 돌아다닌 뒤 각 노드에 머무는 확률은?”이라는 다른 질문. 댐핑 팩터 + 순간이동, 거듭제곱법 손계산, 그리고 두 가지 혼한 실수.
- **13.4 그래프 학습의 확장** — 두 아이디어를 실제 문제로: 단백질(AlphaFold → DeepFRI), 금융(AML World), 교통(STGCN).

그래프로 표현된 데이터를, 신경망이나 통계 모델이 다룰 수 있는 벡터로 어떻게 바꾸는가?

13.1 Random Walk 기초

이 장은 무엇을 묻는가 — AlphaFold가 준 관점

2021년 딥마인드의 **AlphaFold**(Jumper et al., 2021)는 아미노산 서열만 보고 단백질의 3차원 구조를 원자 단위 정확도로 예측해, 50년 가까운 생물학 난제를 사실상 해결했다.

- 핵심 관점 중 하나: 단백질을 **그래프**로 본다.
- 각 아미노산(잔기, residue) = **노드**, 공간적으로 가까운 잔기 쌍 사이의 관계 = **엣지**.
- “어떤 잔기가 어떤 잔기와 가까운가”를 알면 3차원 구조가 따라 나온다.

이 장의 질문은 AlphaFold 구조 자체를 유도하는 게 아니라 더 근본적인 것 — **그래프로 표현된 데이터를, 벡터로 어떻게 바꾸는가?**

핵심 실: word2vec 스킵그램의 그래프 재사용

14.2절의 스킵그램 원리

“문맥 안에서 **함께 나타나는** 단어는 **비슷한 벡터**를 갖는다”

- 이 원리를 그래프에 **그대로** 재사용한다.
- “문장”의 역할은 그래프 위의 **무작위 걷기**(random walk).
- 이 장은 14장(표현학습, PCA·word2vec)과 순환 구조: 14장에서 “함께 자주 나타나는 것은 가까운 벡터로 모인다”의 **텍스트** 버전을 배울 예정이고, 이 장은 그 적용 대상을 **텍스트가 아닌 그래프로** 바꾼 것을 먼저 보여준다.

뒤로 보면: “그래프 위에서 값을 반복해서 갱신한다”는 감각은 15장(잠재변수 생성모델)의 확률 모델과 ML2의 벨만 방정식 (반복 대입으로 고정점 수렴)으로 이어진다.

그래프 위 무작위 걷기 = 마르코프 체인

정의

노드 집합 $\{0, \dots, N-1\}$ 의 그래프 위에서 “지금 서 있는 노드”를 **상태**로 보고, 매 단계에서 **지금 노드의 이웃 중 하나를 골라 이동**하는 확률과정 = **마르코프 체인**(Markov chain).

- 상태 i 에서 j 로 건너가는 **전이확률** (transition probability):

$$P(i \rightarrow j) = \frac{1}{\deg(i)} \quad ((i, j) \in \mathcal{E}), \quad P(i \rightarrow j) = 0 \quad (\text{그 외})$$

- 이웃을 “동등한 확률로 골라” 이동 = **일괄적**(uniform) 무작위 걷기.

같은 체인, 다른 파라미터 — 다음 두 절의 예고

- **13.2 Node2Vec**: 이 전이확률에 p, q 두 계수를 붙여 **편향**(bias)시키는 변형.
- **13.3 PageRank**: 이 전이확률에 “**순간이동**”을 섞은 변형.

한 줄 정리

“같은 마르코프 체인 위에 파라미터만 바꾸는 것” — **같은 무작위 걷기에 서로 다른 질문을 던진다.**

마르코프 체인의 핵심 성질: 무자기성

다음 상태를 결정하는 것은 “지금 어디에 있는지”뿐이다 — 그전에 어떤 경로를 거쳐 왔는지는 아니다.

$$P(x_{t+1} \mid x_t, x_{t-1}, \dots, x_0) = P(x_t \rightarrow x_{t+1})$$

- 이 한 줄이 무작위 걷기가 “단순한 반복”으로 분석될 수 있는 이유 — 그래서 **수십억 노드의 웹에도 거둬제공법 한 줄로** 돌릴 수 있다.
- 예: 카라테 클럽에서 node 16이 node 5를 거쳐 왔는지 node 6을 거쳐 왔는지 **기억하지 않고**, 오직 “지금 node 16에 서 있고 내 이웃은 5와 6이다”만 아는 것이 바로 이 성질.

상태 분포를 계속 곱하면 — 정상분포

- 전이확률 행렬 P 를 “각 노드에 서 있을 확률”인 상태 분포 π 에 계속 곱한다:

$$\pi_{t+1} = \pi_t P$$

- 분포는 결국 멈추는 **정상분포**(stationary distribution) π^* 에 도달한다:

$$\pi^* P = \pi^*$$

- “영원히 돌아다닌 뒤 각 노드에 머무는 비율”이 바로 이 π^* — 아래에서 도(degree)에 비례함을 직접 유도.

같은 무작위 걷기, 다른 질문

13.2 Node2Vec

- “이 걷기가 만들어내는 **노드의 순서(시퀀스)**는 어떤 구조를 담고 있는가?”
- 그 시퀀스를 “문장” 취급해 word2vec의 skip-gram을 학습 → **노드 임베딩**.

13.3 PageRank

- “이 걷기를 영원히 돌리면 각 **노드에 머무는 확률** π^* 는 얼마인가?”
- 그 정상분포 자체를 노드의 “**중요도**”로 읽는다.

한 줄

같은 재료(그래프, 무작위 걷기)에서 하나는 **시퀀스**를 뽑아내고, 하나는 **정상분포**를 뽑아낸다 — 벡터와 스칼라, 두 가지 다른 표현.

왜 “무작위 걷기”가 “문장”을 대신하는 자연스러운 선택인가

- word2vec에서 “문장”이 가진 본질: 어떤 것들이 어떤 순서로 함께 나타나는지를 담는 것.
- 그래프 노드의 “함께 나타남” = “엣지로 연결되어, 서로를 따라다니면 만나는 것”.
- 어떤 노드에서 출발해 이웃을 무작위로 골라 반복 이동하는 **무작위 걷기**가 바로 이 “함께 나타남의 순서”를 만들어내는 **최소 장치**.
- 걷기 안에서 **인접한 노드는 서로 엣지로 연결되어** 있고, 어떤 노드 주위에 자주 등장하는 노드 = 그 노드의 구조적 “이웃”.

머무는 비율은 도(degree)에 비례한다

핵심 성질

무방향 그래프에서 일괄적 무작위 걷기를 무한히 계속하면, 노드 i 에 머무는 장기 비율은 그 노드의 **도**(degree, 연결된 엣지 수)에 비례:

$$\pi(i) = \frac{\deg(i)}{2|\mathcal{E}|}$$

($|\mathcal{E}|$ = 엣지 수, $2|\mathcal{E}|$ = 모든 노드의 도의 합)

- 즉 허브 노드는 걷기 말뚝치에 더 자주 등장 → skip-gram 학습에서 더 많이 업데이트.

허브는 더 많이 “나타나는 단어”

- 14.2절의 “**빈도 높은 단어의 임베딩 벡터 노름이 크다**” 는 현상과 **정확히 같은 메커니즘**.
- 카라테 클럽에서: node 33(관장) 도 17, node 0(감독) 도 16 — 두 파벌 리더가 구조적으로 가장 많이 “나타나는” 단어.
- 임베딩 학습이 자동으로 **구조적으로 중요한 노드에 더 많은 “학습 예산”**을 배정해준다고 볼 수 있다.

주석 — 이 절 후반과 13.3의 연결

“영원히 돌아다닌 뒤 각 노드에 머무는 비율”이라는 질문은 댐핑을 빼면 곧바로 **PageRank** 그 자체. 이 절의 후반부가 바로 이 질문에 정교한 답을 붙인다.

Zachary's Karate Club — 표준 테스트 데이터셋

- 1977년 인류학자 **웨인 재커리**(Wayne Zachary)가 한 가라테 동호회 **34명**의 친분 관계를 기록.
- 마침 이 동호회가 **감독(node 0)**과 **관장(node 33)** 두 파벌로 **실제 분열**.
- 34개 노드, **78개**의 친분 관계(edge)뿐인 작은 그래프.
- 그래프 임베딩이 “제대로 동작하는지” 확인하는 **표준 벤치마크**로 지금까지도 사용.

성공의 기준

라벨(파벌 소속) 없이 순수하게 그래프 구조만 보고 임베딩했는데도 두 파벌이 벡터 공간에서 자연스럽게 갈라지면 성공.

코드: 카라테 클럽 엣지 목록

```
KARATE_EDGES = [  
    (0,1), (0,2), (0,3), (0,4), (0,5), (0,6), (0,7), (0,8), (0,10), (0,11),  
    (0,12), (0,13), (0,17), (0,19), (0,21), (0,31), (1,2), (1,3), (1,7), (1,13),  
    (1,17), (1,19), (1,21), (1,30), (2,3), (2,7), (2,8), (2,9), (2,13), (2,27),  
    (2,28), (2,32), (3,7), (3,12), (3,13), (4,6), (4,10), (5,6), (5,10), (5,16),  
    (6,16), (8,30), (8,32), (8,33), (9,33), (13,33), (14,32), (14,33), (15,32),  
    (15,33), (18,32), (18,33), (19,33), (20,32), (20,33), (22,32), (22,33),  
    (23,25), (23,27), (23,29), (23,32), (23,33), (24,25), (24,27), (24,31),  
    (25,31), (26,29), (26,33), (27,33), (28,31), (28,33), (29,32), (29,33),  
    (30,32), (30,33), (31,32), (31,33), (32,33),  
]
```

무방향 그래프: 친분 관계 78개. node 0 = 감독, node 33 = 관장.

코드: 일괄적 무작위 걷기로 말뚱치 만들기

```
def random_walk(neighbors, start, length):
    walk = [start]
    for _ in range(length - 1):
        cur = walk[-1]
        if not neighbors[cur]:
            break
        walk.append(random.choice(neighbors[cur]))
    return walk

def build_walks(edges, n_nodes, walks_per_node=10, walk_length=8):
    neighbors = {i: [] for i in range(n_nodes)}
    for a, b in edges:
        neighbors[a].append(b)
        neighbors[b].append(a)
    walks = []
    for node in range(n_nodes):
        for _ in range(walks_per_node):
            walks.append([str(n) for n in random_walk(neighbors, node,
                                                         walk_length)])
    return walks
```

random_choice = 이웃을 동등한 확률로 고르는 일괄적 걷기. 각 걷기 = “문장”, 각 노드 번호 = “단어”.


걷기 → 말뭉치 → skip-gram → 임베딩

- ① **걷기** — `build_walks` 로 34개 노드 × 노드당 10개 걷기(길이 8) 생성.
- ② **말뭉치** — 이어붙인다: `corpus = sum(walks, [])`.
- ③ **학습** — 14.2절의 `train_skipgram`에 그대로 넣으면 **34개 노드 각각의 임베딩 벡터**가 나온다.
- ④ **시각화** — 14.1절의 **PCA**로 2차원까지 압축해 그리면, 실제로 두 파벌이 공간적으로 갈라진다.

같은 아이디어의 두 얼굴

`word2vec`과 `Node2Vec`은 서로 다른 데이터(텍스트 vs. 그래프)에 적용됐을 뿐, “함께 자주 나타나는 것들은 비슷한 벡터를 갖도록 학습한다”는 같은 아이디어의 두 얼굴.

결과: 라벨 없이 본 임베딩이 분열 구조를 회복



$p=q=1$ (일괄적 걷기)의 걷기
 34×10 개(길이 8)로 Node2Vec
학습($d=8$ 차원)한 임베딩을 SVD로
2차원 투영. 파랑 = 감독파, 주황 =
관장파. 두 군집이 2차원 공간에서
상당히 선명하게 갈라진다.

해석: 리더는 “경계”가 아니라 군집 중심에

- 두 파벌이 한쪽/다른 쪽으로 갈라지고, 두 파벌 리더 (node 0, node 33)이 **각 군집의 중심 부근**에 있다.
- 두 리더의 임베딩이 자기 파벌 군집 중심에서 각각 **약 0.2, 0.3** 거리 — 나머지 멤버의 중앙값은 감독파 약 1.1, 관장파 약 0.4.
- “리더는 두 파벌의 **경계**에 있어야 할 것” 같은 직관과 달리, 실제로는 군집 **내부에 잘 박혀 있다**.
- 군집 경계 근처에 두 파벌을 잇는 “**다리**” 역할을 하는 멤버들이 섞여 있어도 **정상** — 그래프에서 실제로 두 클러스터 사이를 잇고 있다.

13.2 Node2Vec: 걷기에 skip-gram을 그대로

13.1을 한 줄로: 걷기 안의 인접 = “함께 나타남”

확립된 것

그래프 위의 **무작위 걷기**는 마르코프 체인이고, 그 걷기 안의 **인접** 노드들은 서로를 “함께 나타남”으로 잇는다.

- 이제 그 “함께 나타남의 순서”, 곧 **걷기 시퀀스**를 14.2절 word2vec의 **skip-gram** 학습에 그대로 넣으면 된다.

(Grover & Leskovec, 2016)

random walk로 생성한 경로들에 word2vec의 skip-gram을 그대로 학습시킨 것.

word2vec의 세 요소를 그래프 버전으로 치환

word2vec → Node2Vec

문장 → 한 노드에서 출발해 이웃을 무작위로 따라가며 만든 **걷기 경로**(노드 시퀀스)

단어 → 그 경로 위에 순서대로 나오는 **노드**

학습 → 14.2절의 train_skipgram을 **한 줄도 고치지 않고** 그대로 (토큰이 단어 대신 노드 번호일 뿐)

“비슷한 문맥에 나오는 단어는 비슷한 벡터를 갖는다” → “**비슷한 이웃 구조를 가진 노드는 비슷한 벡터를 갖게 된다**”는 문장으로 바뀐 것뿐.

학습이 끝나면: 은닉층 가중치 = 노드 임베딩

- 14.2절과 똑같이 은닉층 가중치 행이 각 노드의 임베딩 벡터.
- 14.2절에서 word2vec은 “작은 신경망을 학습시킨다”고 소개됐다 — one-hot 입력층 · 임베딩 차원 은닉층 · 어휘 크기 출력층, 이진 교차엔트로피 최소화.

핵심 재료가 신경망을 전제로 하지 않는다

“건기로 시퀀스를 만들고 그 위에서 함께-나타남을 학습한다”는 틀 자체는 **신경망 없이도 성립**. skip-gram을 쓰든, 더 단순한 “함께 나타난 횟수” 카운트 기반의 선형 분해 (14.2절의 LSI 같은)를 쓰든 — Node2Vec은 그 **더 일반적인 틀** 위에 14.2절의 skip-gram이라는 하나의 실용적 학습자를 골랐을 뿐.

Node2Vec의 진짜 기여: 두 계수 p 와 q

- 13.1절 코드의 일괄적 걷기 = 원본 논문의 **가장 단순한 특수한 경우** ($p=q=1$).
- 논문의 실제 기여: 걷기에 p (return)과 q (in-out) 두 계수를 붙여 “**이웃 탐색의 스타일**”을 조절.

걷기가 노드 x_t 에 도달했을 때(직전 x_{t-1}), 다음 노드 x_{t+1} 를 고르는 확률은 가중치 $w_{x_{t-1}}(x_{t+1})$ 에 비례:

- **돌아가기** — 방금 있던 노드로 복귀 ($x_{t+1} = x_{t-1}$): 가중치 $1/p$
- **인근 머물기** — x_{t-1} 의 이웃(이미 탐색한 로컬 영역 안): 가중치 $1/q$
- **새 영토로** — 나머지(아직 탐색 안 한 이웃): 가중치 1

계수를 움직이면 탐색 스타일이 기울어진다

- $p = q = 1$: 모든 가중치가 1 $\rightarrow$ 정확히 **일괄적 무작위 걷기**.
- $p < 1$ ($1/p > 1$): 직전 노드로의 **뒤로 감** (backtracking) 확률이 올라간다.
- $q < 1$ ($1/q > 1$): 방금 탐색한 **로컬 영역 안에 머물기** 확률이 올라간다.
- $q > 1$ ($1/q < 1$): 이미 본 영역을 다시 밟는 것이 **억제**되어 걷기가 **새 영토로 확장**하려 한다.

원본 논문의 두 표준 프리셋

설정	탐색 스타일	강조하는 구조
$(p=1, q=16)$ — “node2vec”	BFS형 (넓이 우선)	구조적 동치 (structural equivalence) — 역할의 유사성
$(p=16, q=1)$ — “deep walk”	DFS형 (깊이 우선)	동질성 (homophily) — 같은 커뮤니티 속한 것의 유사성

일괄적 무작위 걷기는 돌을 **섞어서** 담고, p, q 가 이 중 어느 쪽에 더 초점을 맞추게 하는 “**다이얼**” 인 셈.

동질성 vs 구조적 동치 — 서로 다른 두 유사도

동질성 (homophily)

- 같은 커뮤니티의 노드는 **동질**하다.
- 예: 카라테 클럽에서 **한 파벌의 멤버끼리** 서로 비슷.
- → DFS형 (16, 1) 가 강조.

구조적 동치 (structural equivalence)

- **서로 다른** 커뮤니티의 두 노드도 **역할이 같을** 수 있다.
- 예: 다른 부서 두 곳에서 각각 “외부와의 **유일한 연결고리**” 역할을 하는 두 멤버.
- → BFS형 (1, 16) 가 강조.

코드: 편향 무작위 걷기 (일괄적 걷기를 대체)

```
def biased_walk(nb, start, length, p, q, rng):
    """의Node2Vec 편향무작위걷기 . nb: 노드 -> 이웃목록 """
    walk = [start]
    prev = None
    for _ in range(length - 1):
        cur = walk[-1]
        weights = []
        for nxt in nb[cur]:
            if prev is None:
                weights.append(1.0)
            elif nxt == prev:
                weights.append(1.0 / p)      # 돌아가기
            elif nxt in nb[prev]:
                weights.append(1.0 / q)      # 로컬영역머무르기
            else:
                weights.append(1.0)          # 새영토로
        r = rng.random() * sum(weights)     # 가중치에비례해뽑기
        acc, chosen = 0.0, nb[cur][0]
        for nxt, w in zip(nb[cur], weights):
            acc += w
            if r <= acc:
                chosen = nxt
                break
        walk.append(chosen)
```

작은 실험: p 와 q 가 임베딩을 얼마나 바꾸는가

세 가지 설정으로 걷기를 **재생성**해서 동일하게 Node2Vec을 학습(시드 고정):

- **일괄적** (1, 1) — 일괄적 무작위 걷기
- **BFS형** (1, 10) — 새 영토 확장 강조
- **DFS형** (10, 1) — 로컬 영역 머물기 강조

공통 하이퍼파라미터: walks_per_node=10, walk_length=8, dim=8 (노트북).

결과

설정	코사인 실루엣*	node 2의 유사 노드 상위 3개
(1, 1) 일괄적	0.351	7 (0.73), 13 (0.72), 9 (0.72)
(1, 10) BFS형	0.342	9 (0.86), 28 (0.73), 7 (0.72)
(10, 1) DFS형	0.393	12 (0.83), 19 (0.70), 17 (0.65)

*실루엣


두 파벌 라벨을 “참 군집”으로 두고, 각 노드가 **자기 파벌 군집의 평균 임베딩**에 상대 파벌 군집의 평균보다 얼마나 가까운지 $-1 \sim +1$ 로 재는 군집 분리 품질 지수 (**1에 가까울수록 잘 분리**).

해석: 방향은 보인다, 크기는 작다

- 34개 노드라는 작은 스케일에서 세 설정의 차이는 **작고**, 원본 논문의 대규모 패턴까지 그대로 재현되지는 않는다 (데이터가 작아 노이즈가 큰 것은 자연스러움).
- 그래도 방향을 짚자: **DFS형** (10, 1)에서 node 2의 상위 3개 유사 노드(12, 19, 17)가 **모두 감독 파벌**에 속하는 **가장 깔끔한 파벌 분리**.
- 카라테 클럽에서 파벌 = 커뮤니티이므로, 여기서는 커뮤니티 분리 품질이 곧 “잘 됐다”의 지표.

세 설정을 한 그림에

Node2Vec embeddings by p and q (2D projection)



일괄적 (1, 1), BFS형 (1, 10), DFS형 (10, 1) 으로 각각 학습한 임베딩을 2차원 투영. 파랑 = 감독파, 주황 = 관장파. 세 설정 모두 두 파벌을 나누지만, **DFS형(실루엣 0.393)이 가장 선명하게** 갈라진다.

교훈은 이 실험이 아니라 다음 문장

p, q 는 “커뮤니티 구조를 원하느냐, 역할 구조를 원하느냐”에 맞게 바꾸고, 그 효과를 **downstream** 태스크(분류 · 링크 예측 등)로 **실제 검증**해야 한다.

- 이 실험 자체는 34개 노드의 작은 데모 — 큰 그래프에서 p, q 의 효과가 훨씬 크게 벌어진다(원본 논문).

자주 하는 실수: 무방향 엣지를 방향 그대로 넣고 돌리기

- 카라테 그래프는 **무방향**, PageRank는 **방향** 그래프 위에서 정의된다.
- 표준 기법: “친분 관계 1개”를 **양방향 링크 2개**로 바꿔주는 **대칭화** (13.3절의 `directed_edges` 줄).
- 이 대칭화를 **누락**하고 `KARATE_EDGES`를 그대로 넣으면, 결과는 **각 엣지가 어떤 방향으로 기록되었는가에 따라** — 즉 **임의적인 저장 순서에 따라** — 달라진다.

대칭화 누락의 결과: 감독이 “사라진다”

```
scores_dir = pagerank(KARATE_EDGES, 34) # 실수: 대칭화누락
# 상위개 5: 33 (0.0759), 32 (0.0280), 31 (0.0135),
#           16 (0.0125), 6 (0.0080)
```

- node 0(감독, 도 16의 진정한 허브)이 상위 5개에서 완전히 사라진다.
- 그래프 자체는 하나도 안 바뀌었는데, 기록 관례가 “중요도 순위”를 뒤틀어버린 것.

교훈: 도메인 지식과의 교차검증

발견하기 힘든 종류의 버그

대칭화는 **한 줄**이지만, 이 실수는 “**왜 감독이 순위에서 빠졌지?**”라는 도메인 지식의 교차검증이 없으면 발견하기 어렵다.

- 습관: 알고리즘 결과와 “알고 있는 사실”이 **충돌하면**, 먼저 **파이프라인의 편의 전제**(여기선 방향성 처리)부터 의심한다.

13.3 PageRank: 정상분포를 중요도로

같은 무작위 걷기, 다른 질문: PageRank

- 13.1: 걷기를 “노드가 이웃을 얼마나 자주 만나는지”를 담은 **말뭉치**로.
- 13.2: 그 말뭉치에 skip-gram을 학습 → **임베딩**.
- 이 절: 말뭉치가 아니라, 13.1의 마지막 주석 “영원히 돌아다닌 뒤 각 노드에 머무는 비율”에 정식으로 답 — 그 답, 즉 **무작위 걷기의 정상분포** 그 자체를 노드 하나당 스칼라 “중요도”로 쓰는 것이 **PageRank**.

같은 재료, 갈라진 결과물

같은 무작위 걷기를 13.2와 이 절이 모두 쓰지만, 묻는 질문이 달라서 나온 결과물이 임베딩 벡터와 스칼라 점수로 갈라진 것.

1998년: 래리 페이지와 세르게이 브린

- 1996-97년, 스탠퍼드 대학원생이던 **래리 페이지** (Larry Page)와 **세르게이 브린** (Sergey Brin).
- 당시 웹 검색엔진들은 “페이지에 **키워드가 있는가**”로만 순위를 매김 → 웹이 너무 커져 **쓸모없는 결과만 뒤섞여** 나온다는 문제를 직감.
- 그들의 답: **웹 자체를 데이터로 보는 것** — 수억 개 웹페이지 사이의 **링크 구조**는 그 자체로 **“웹의 투표 기록”**
- 다른 사이트의 주인들이 자발적으로 그 페이지를 링크한 것이 “이 페이지가 중요하다”는 **증거**.

PageRank의 핵심 아이디어와 정식화

- 이 그래프 위를 **무작위로 영원히 돌아다닌다면**, 각 노드에 머물러 있을 확률은 각각 얼마나 될까?
- 그 답 = 그 노드의 **“중요도”** (1998, Brin & Page).
- 많은 페이지가 링크하는 페이지일수록, 또 **중요한 페이지**가 링크하는 페이지일수록, **무작위 서퍼**(random surfer)가 더 자주 머문다.
- “누가 누구를 링크하는가”를 **무작위 서퍼의 이동 행렬**로 정식화 → 1998년 논문 “The Anatomy of a Large-Scale Hypertextual Web Search Engine”이 실용 알고리즘으로 완성.

(사명 “Google”은 10^{100} 을 뜻하는 “googol”에서 온 말장난 — 조직하려던 웹의 규모에 대한 선언.)

PageRank 방정식

노드 i 의 페이지랭크 $PR(i)$ 는 다음을 만족해야 한다 — 자신을 가리키는 모든 노드 j 로부터, 그 노드가 가진 점수를 그 노드의 바깥 링크 수만큼 나눠 받은 합:

$$PR(i) = \frac{1-d}{N} + d \sum_{j \rightarrow i} \frac{PR(j)}{\text{outdeg}(j)}$$

- N = 전체 노드 수.
- d (보통 **0.85**) = **댐핑 팩터**(damping factor): 확률 d 로 링크를 따라가고, 확률 $1 - d$ 로 **아무 노드로나 순간이동**(teleport).
- 순간이동 = **막다른 골목**에 갇히거나 **순환**에 갇히는 것을 막기 위한 장치.

재귀식이라 한 번에 못 풀고 — 거듭제곱법

- 이 식은 우변에 PR 자신이 다시 등장하는 재귀식이라 한 번에 풀 수 없다.
- 그래서 아무 값(모든 노드에 $1/N$)에서 시작해, 우변에 반복해서 대입하며 값이 더 이상 바뀌지 않을 때까지 되풀이하는 거듭제곱법(power iteration)으로 푼다.

형태가 수렴을 보장

“새 값 = teleport 항 + 옛 값들의 가중 평균”이라는 방정식의 형태 — 이 형태가 반복법의 수렴을 보장하는 구조이며, 바로 뒤에 온다.

코드: pagerank (거듭제곱법)

```
def pagerank(edges, n_nodes, d=0.85, iters=100):
    outgoing = {i: [] for i in range(n_nodes)} # directed: a -> b
    for a, b in edges:
        outgoing[a].append(b)
    outdeg = {i: max(1, len(outgoing[i])) for i in range(n_nodes)}
    incoming = {i: [] for i in range(n_nodes)} # who points to me?
    for a, b in edges:
        incoming[b].append(a)

    pr = {i: 1 / n_nodes for i in range(n_nodes)}
    for _ in range(iters):
        pr = {i: (1 - d) / n_nodes + d * sum(pr[j] / outdeg[j]
                                              for j in incoming[i])
              for i in range(n_nodes)}
    return pr
```

코드: 대칭화하고 카라테 클럽에 적용

```
# Karate 은 Club 무방향그래프이므로 ,
# 친분관계하나를 양방향 링크로 취급한다
directed_edges = KARATE_EDGES + [(b, a) for a, b in KARATE_EDGES]
scores = pagerank(directed_edges, 34)
print(sorted(scores.items(), key=lambda kv: -kv[1])[:3])
# node 33, node 10 가장 높다 -- 실제 두 허브 """ 노드 관장(, 감독)과
# 정확히 일치
```

(대칭화, $d=0.85$, 100회 반복)


결과: 두 파벌 리더가 정확히 상위 2개

순위	노드	역할	PageRank
1	33	관장	0.1009
2	0	감독	0.0970
3	32	감독 파벌의 연결고리	0.0717

- 전체 점수의 합은 **정확히 1**.
- 최소값: teleport 하한 $\frac{1-d}{34} \approx 0.0044$ 보다도 조금 높은 **0.0096**(node 11, 도 1) — 하한은 “아무도 가리키지 않는 노드”가 받는 **이론적** 최저치일 뿐, 실제 그래프에서는 모든 노드가 누군가에게(직·간접으로) “가시게” 되니 그 위로 받쳐진다.
- 라벨을 하나도 안 본 “중요도 순위”가 **역사적 사실** (누가 어떤 파벌이었는지)과 거의 정확히 겹친다.

왜 node 33이 node 0보다 앞서는가

- node 33(도 17)이 node 0(도 16)보다 앞섬.
- “무작위 걷기가 더 자주 방문한다”는 도의 우위가 점수에 거의 그대로 드러난 모습.
- 상위권(33, 0, 32)은 모두 두 허브 노드와 그 연결고리.



34개 노드의 PageRank($d=0.85$, 대칭화)를 점수 높은 순으로 막대로. 파랑 = 감독파, 주황 = 관장파.
아래로 갈수록 점수가 teleport 하한에 수렴.

손으로 한 번: 노드 4개, 순환 하나, 외딴 끝 하나

$d = 0.5$ 인 방향 그래프로 최소 예제:

- $A \rightarrow B, B \rightarrow C, C \rightarrow A$ — **3-노드 순환**
- $D \rightarrow A$ — D는 A만 가리킨다 (들어오는 링크는 **없음**)

teleport 항

$$\frac{1-d}{N} = \frac{0.5}{4} = \mathbf{0.125}$$

1단계 — D는 들어오는 링크가 없다

- D를 가리키는 노드가 없으니 합 $\sum_{j \rightarrow D}$ 는 비어 있다:

$$PR(D) = \frac{1 - d}{N} = 0.125$$

읽기

D는 반복을 아무리 돌려도 0.125에 머문다 — “나를 가리키는 이가 없으니 **teleport**분밖에 받을 수 없다”는 뜻.

2단계 — 순환 속 3개 노드에 방정식

$$PR(A) = 0.125 + 0.5 \left(\frac{PR(C)}{1} + \frac{PR(D)}{1} \right)$$

$$PR(B) = 0.125 + 0.5 PR(A), \quad PR(C) = 0.125 + 0.5 PR(B)$$

(각 노드의 outdeg가 1이라 나누기는 일을 하지 않는다.)

3단계 — 대입으로 풀다

$PR(B), PR(C)$ 를 $PR(A)$ 식에 대입:

$$PR(A) = 0.125 + 0.5 \left(\underbrace{0.125 + 0.5(0.125 + 0.5 PR(A))}_{PR(C)} + \underbrace{0.125}_{PR(D)} \right) = 0.28125 + 0.125 PR(A)$$

$$PR(A) = \frac{0.28125}{0.875} = \frac{9}{28} \approx 0.321$$

```
PR(B) = 0.125 + 0.5 * 0.321 # ≈ 0.286  
PR(C) = 0.125 + 0.5 * 0.286 # ≈ 0.268  
# 계산: 0.321 + 0.286 + 0.268 + 0.125 = 1.000
```

이 작은 예제에서 읽어둘 것 두 가지

- 첫째. $A \cdot B \cdot C$ 는 모두 도 2(들어오는 1, 나가는 1)로 “겉모습은 똑같은”데, 점수는 **균등하지 않다** ($0.321 > 0.286 > 0.268$).
- “ $D \rightarrow A \rightarrow B \rightarrow C$ ” 흐름을 받는 A가 **D의 점수를 직접 받아 가장 크고, 순환을 돌수록 우위가 조금씩 소진된다.**

핵심


PageRank는 “엣지가 몇 개인가”가 아니라 “누가, 얼마나 중요한 위치에서 나를 가리키는가”의 문제.

거듭제곱법이 왜 수렴하는가 — 바나흐 고정점 정리

- 이 거듭제곱법의 수렴 논리는, **ML2 Chapter 4**에서 벨만 최적방정식의 해가 유일하게 존재함을 보일 때 쓸 **바나흐 고정점 정리**(Banach fixed point theorem)와 **정확히 같은 논리**.
- “어떤 변환을 값이 안 바뀔 때까지 반복해서 적용하면 결국 고정점(fixed point)에 도달한다”는 같은 수학:
- 여기서 = “그래프 위 확률분포”, 강화학습에서는 = “상태의 가치함수”.

수렴이 얼마나 빠른가 — 지수적으로

- 매 반복의 변화량(전체 노드 중 최대 $|\Delta PR|$)은 **지수적으로** 줄어든다.
- 카라테 클럽: $d=0.85$ 일 때 대략 **45회**로 10^{-9} 이내 수렴. $d=0.5$ 이면 **19회**.
- d 가 클수록 서퍼가 더 “장기 기억”을 하려 하므로 수렴이 **느려진다**.
- 작 중형 그래프: “**100회 반복**”이면 충분.
- 수십억 페이지 규모의 웹: 구글이 **분산 계산 · 희소화** 같은 별도 공학이 필요했던 이유.



매 반복의 최대 변화량 $\max |\Delta PR|$ 을 로그 스케어로. $d=0.85$ (파랑)가 $d=0.5$ (주황)보다 더 오래 걸리며, 두 곡선 모두 직선(= 지수적 감소)을 따라 10^{-9} 아래로.

실무 1: “수렴했는지” 확인 없이 반복 횟수만 고정하기

위의 코드는 단순화를 위해 `iters=100`을 고정했다 — 실제 사용에서는 변화량이 기준 ϵ 아래로 떨어질 때까지 돌리는 것이 정석:

```
def pagerank_converged(edges, n_nodes, d=0.85, tol=1e-9,
                      max_iters=1000):
    # ... 위( 와 pagerank 동일, 단 반복조건이 다름 )
    pr = {i: 1 / n_nodes for i in range(n_nodes)}
    for _ in range(max_iters):
        new = {i: (1 - d) / n_nodes + d * sum(pr[j] / outdeg[j]
                                              for j in incoming[i]) for i in range(n_nodes)}
        delta = max(abs(new[i] - pr[i]) for i in range(n_nodes))
        pr = new
        if delta < tol:
            break
    return pr
```

실무 2: dangling node (나가는 링크가 0인 노드)

- $\max(1, \cdot)$ 가 막는 것은 출도가 0인 전달자가 분모 0으로 만들지 않는 것이지, 그 노드 자신이 받는 teleport분 $\frac{1-d}{N}$ 을 없애는 것이 아니다.
- 그래서 “dangling 노드가 있으면 전체 PR의 합이 1이 안 된다”는 주장은 **잘못**. (2-노드 예제 $A \rightarrow B$ 만 있는 그래프에서도 B가 dangling이건 말건 합은 정확히 1.)
- 다만 출도가 0인 노드의 점수가 우변의 합에서 **어디로도 전달되지 않는다는 사실은 변함없다**.
- 카라테 그래프에는 그런 노드가 없어 합 = 1이 정확히 나왔지만, 웹처럼 “링크가 하나도 없는 죽은 페이지”가 흔한 그래프에서는 dangling 노드의 점수를 **모든 노드에 균등하게 재분배**해 주는 보정이 **표준**.

댐핑 팩터와 같은 계열의 공학 — “확률이 새는 구멍을 하나하나 막아주는” 장치들.

자주 하는 실수: “PageRank = 도(degree)”로 읽기

- “가리키는/가리켜지는 링크가 많을수록 점수가 크다”는 설명 때문에 PageRank를 “**도 순위**”로 단순화하는 경우가 많다.
- 무방향 그래프의 **대칭화**된 PageRank에서는 둘의 순위가 **매우 강하게** 상관난다(카라테 그래프에서도 상위권이 거의 도 순서와 일치).
- 그러나 이 둘은 **같은 것이 아니다** — $\sum_{j \rightarrow i} \frac{PR(j)}{\text{outdeg}(j)}$ 는 어떤 노드가 나를 가리키느냐를 가중.

본래 설계 목적

방향 그래프에서는 차가 확 벌어진다: “중요하지 않은 페이지 10개가 링크”보다 “**가장 중요한 페이지 1개가 링크**”가 더 높은 PageRank를 만드는 것. **인기(도)**와 **권위**(가리켜지는 쪽의 중요도)는 다른 개념이며, PageRank가 측정하는 쪽은 **후자**.

지금 어디에 쓰이는가

- 본업: 웹 검색 랭킹. 그러나 “방향 그래프 위 무작위 걷기의 정상분포 = 중요도”라는 틀 자체는 범용 도구.
- 학술 인용 네트워크(논문 · 저널 랭킹), 소셜 네트워크 영향력 분석.
- **개인화 PageRank**(Personalized PageRank): 무작위 걷기를 주어진 노드에서 다시 시작하는 변형 — 추천 시스템과 커뮤니티 감지에 사용.
- Node2Vec 쪽: 원본 논문에서 **100만 노드** 규모의 그래프 분류 · 링크 예측 · 시각화 시연. 이후 “그래프 → 노드 벡터 → 일반 ML 모델로 전달” 파이프라인의 첫 단계로 **약물 상호작용 예측, 단백질 기능 예측, NER** 등 다양한 그래프 문제에.

하나의 수학적 패턴

공유되는 패턴

PCA · word2vec · Node2Vec · PageRank는 얼핏 서로 다른 문제처럼 보이지만, 전부 “무언가를 어떤 변환에 반복해서 통과시키면 특별한 지점(고유벡터, 임베딩, 정상분포)에 수렴한다” 는 하나의 수학적 패턴을 공유한다.

지도 vs 비지도

지도학습이 “정답을 맞추는 법”을 배운다면, 비지도학습은 “데이터가 스스로 어떤 모양을 하고 있는지”를 배운다 — 둘은 서로 다른 질문에 답한다.

확인 문제: 2-노드 그래프

2-노드 방향 그래프 $A \leftrightarrow B$ ($A \rightarrow B, B \rightarrow A$)에 $d = 0.5, N = 2$ 로 PageRank를 손으로 계산.

- ① **단계 1** — 방정식 두 개: $PR(A) = 0.25 + 0.5 PR(B), PR(B) = 0.25 + 0.5 PR(A)$
- ② **단계 2** — 대칭성: $PR(A) = PR(B)$ 로 놓으면 $PR(A) = 0.25 + 0.5 PR(A)$, 즉 $PR(A) = PR(B) = 0.5 - d$ 의 값과 무관하게 각 0.5. (코드로 확인)
- ③ **단계 3 (핵심)** — $B \rightarrow A$ 엣지를 지우면 (B는 **dangling node**가 됨): $PR(A) = 0.25, PR(B) = 0.25 + 0.5 \times 0.25 = 0.375$ — 합이 $0.25 + 0.375 = \mathbf{0.625}$ 로, **1이 아니다. 왜 그런지, 그리고 본문의 어떤 공학 보정을 추가하면 합이 1로 돌아올지 이름으로 답하라.** (힌트: “자주 하는 실수” 섹션의 두 번째 세부 사항)

자주 묻는 질문 (1/2)

- **Q. PageRank도 임베딩인가요?** — 아니요. Node2Vec은 각 노드를 **벡터 공간의 한 점**(임베딩)으로, PageRank는 각 노드에 **스칼라 값**(중요도 점수) 하나만. “구조적으로 얼마나 비슷한가”(Node2Vec) vs “전체에서 얼마나 중요한가”(PageRank).
- **Q. 댐핑 팩터 d 가 없으면?** — $d=1$ 이면 순간이동이 전혀 없어 막다른 골목에서 서퍼가 **영원히 갇히거나**, 그래프가 여러 조각으로 나뉘어 있으면 **시작 조각에 따라 결과가 달라짐**. $d<1$ 의 순간이동 확률은 확률분포가 조각 사이를 계속 넘나들게 만들어 **유일한 해로 수렴**을 보장.
- **Q. 걷기 개수·길이는?** — 엄격한 공식은 없지만 원본 논문의 **노드당 10개 걷기, 길이 40, 차원 128**을 출발점으로 데이터 규모에 맞춰 줄인다(34개 노드에서는 10개 $\times$ 길이 8 $\cdot$ 차원 8이면 충분). 너무 짧으면 “문맥”이 바로 옆 이웃에 갇히고, 너무 길면 “출발 지점”을 잊어 문맥이 노이즈가 된다.

자주 묻는 질문 (2/2)

- Q. 무방향 그래프에 써도 되나요? — 된다. 표준 기법은 무방향 엣지 1개를 **방향 링크 2개**로 바꿔주는 것. 이렇게 하면 “도 순서에 가깝되, 누가 나를 가리키느냐를 가중한” 순서가 되며, 일반적으로 도 순위와 동일하지는 않다.
- Q. p, q 는 그래프마다 튜닝해야 하나요? — 보편적 최적값은 없다. 두 프리셋 $(1, 16), (16, 1)$ 도 “역할 구조 vs 커뮤니티 구조”에 맞춘 **출발점**에 불과 — 몇 가지 설정을 돌려보고 **downstream 태스크** 성능이나 시각화에서 기대된 구조가 보이므로 검증한다.

13.4 그래프 학습의 확장

두 아이디어 → 세 실전 방향

- 이장에서 배운 두 아이디어: **무작위 걷기 기반 그래프 임베딩**(Node2Vec)과 **정상분포**(PageRank).
- 오프너의 AlphaFold 이상으로 **훨씬 넓은 문제**에 적용된다.

세 가지 실전 방향 (지도식 수업)

- ① **(a) 단백질**: 구조를 알면, 그 구조로 기능을 분류
- ② **(b) 금융**: 거래 그래프에서 자금세탁 탐지 (IBM AML World)
- ③ **(c) 교통**: 도로망 + 시계열의 스페이오템포럴 그래프 교통 예측(STGCN)

(a) 단백질: 구조를 알면, 그 구조로 기능을 분류한다

- 오픈너의 **AlphaFold**는 잔기 쌍 사이의 **거리 · 각도 관계**를 그래프로 표현해 3차원 구조를 예측.
- 구조를 알고 나면 자연스러운 다음 질문: “이 구조는 어떤 기능을 하는가?”
- **DeepFRI**는 단백질 3차원 구조에서 얻은 **잔기 접촉 그래프**(contact graph)를 **그래프 신경망**(GCN)에 넣어, 그 단백질이 어떤 **생물학적 기능**을 갖는지 분류.

자연스러운 파이프라인

구조 예측(AlphaFold) → 구조 기반 기능 분류(DeepFRI)

이 장의 도구가 어디에 쓰이는가

- 구조를 3차원 좌표로 돌려받는 순간, “공간적으로 가까운 잔기 쌍”을 엣지로 묶으면 **접촉 그래프**가 만들어진다.
- 카라테 클럽의 친분 엣지를 “친하다”로 바꾼 것 같은 — **도메인 지식이 만든 그래프**.
- 그래프 신경망 계열은 이 그래프에 13장 전체를 관통한 “**이웃과 값을 합치면서 반복한다**”는 연산 — **그래프 컨볼루션**(graph convolution) — 을 적용.
- 각 잔기(노드)의 벡터를 **이웃 잔기의 정보와 섞어 몇 라운드 갱신**하면, “이 잔기는 구조적으로 어떤 위치에 있는가”가 인접성만큼 벡터에 스며든다.
- DeepFRI는 이렇게 쌓인 노드 표현을 받아 **수십만 개의 기능 라벨**(GO term) 중 해당 단백질을 설명하는 것을 골라내는 **분류 문제**로 만든다.

왜 서열을 바로 분류하지 않고 구조 그래프를 거치는가

“왜?”를 한 번

동일한 기능을 가진 단백질은 **서열이 많이 달라도 3차원 형태(구조)는 비슷하게 유지되는 경우가 흔하다.**

- 구조 그래프는 “**서열과 무관한 기능의 공통 요인**”을 더 직접적으로 담는 표현.
- 같은 구조에 다른 서열의 단백질(**유사 동종단백질**) 기능을 추론할 때 **서열 기반 모델보다 유리.**
- AlphaFold의 구조 예측이 생물학 난제를 풀기만 한 게 아니라, **그래프 기반 추론의 입력을 대량으로 공급하는 인프라**가 된 이유.

노트북 Part 1: 파이프라인의 뼈대

- 작은 합성 접촉 그래프(20개 노드)를 만들고.
- “접촉 수(도)를 특징으로 한” 매우 간단한 분류기를 돌린다.

주의: 이것은 DeepFRI의 GCN을 직접 학습하는 것이 아니다

“그래프 구조 특징 → 기능 분류” 파이프라인의 뼈대를 느끼는 데모.

(b) 금융: 거래 그래프에서 자금세탁 탐지

- **IBM AML World**: 계좌를 노드, 거래를 엣지로 하는 대규모 합성 거래 그래프 데이터셋.
- 자금세탁은 흔히 “여러 계좌를 거쳐 돈의 출처를 세탁”하는 패턴(**레이어링**)으로 나타나는데 —
- 개별 거래 하나만 보서는 안 보이고, 그래프 구조 전체(누가 누구와 얼마나 자주, 어떤 패턴으로 거래하는가)를 봐야 드러난다.
- Node2Vec 같은 그래프 임베딩이나 그래프 신경망으로 “의심스러운 부분그래프”를 탐지하는 방향의 대표적 실전 응용.

왜 합성 데이터셋인가 + 레이어링의 특징

합성인 것의 의미

“**답이 알려진 거래 그래프**”를 만들어서 탐지 모델의 성능을 **측정**할 수 있게 하는 것 — 실제 금융 데이터는 **프라이버시** 때문에 쉽게 공개될 수 없으니, **구조와 노이즈 수준만 조절**해서 “탐지 가능한 패턴”을 심어놓은 합성 데이터셋이 연구용으로 나온 것.

- 레이어링 패턴의 특징: 불법 자금의 흐름이 **1-2홉이 아니라 3-4홉 이상**으로 뻗어 있다.
- “계좌 A가 B로, B가 C로, C가 해외로” 이동하는 동안 **각 구간은 정상 거래와 구분하기 어렵다.**

이 장의 두 도구를 거래 그래프에

노드 임베딩 (Node2Vec 계열)

- 계좌를 “거래 네트워크에서 **어떤 위치에 있는가**”로 벡터화.
- 동일한 패턴으로 세탁에 쓰인 계좌들이 임베딩 공간에서 **같은 군집**에 모이면, 그 군집 자체가 “의심 패턴”의 **시그니처**.

중요도 점수 (PageRank 계열)

- “다른 계좌들이 **가장 많이** 거쳐가는 **통로**”에 높은 점수.
- 자금세탁의 **중계 계좌**(여러 출처를 여러 목적지로 합치고 흩어주는 허브) = 정확히 그런 **구조적 허브**.

두 신호를 결합하면

“무슨 특징인지 아직 이름이 붙지 않았지만” **구조적으로 수상한 계좌**를 선별 — 규칙 기반 탐지(“거래액 > 1억이면 신고”)가 놓치는 **패턴 전체가 정상인 개별 구간**까지 커버.

노트북 Part 2: 합성 거래 그래프

- 작은 합성 거래 그래프(20개 계좌, 정상 클러스터 + 의도적으로 심은 레이어링 경로)를 만들고.
- PageRank로 “중계 허브”를 찾아보며.
- 1홉 특징만으로는 왜 발견 못 하는지 보여준다.

(c) 교통: 도로망 위의 시계열 — spatio-temporal 그래프

- 지금까지: 그래프 구조 자체가 고정 (카라테 클럽의 친분 관계는 안 바뀜).
- 교통 예측처럼 그래프 위에 시계열이 얹히는 문제도 있다:
- 도로망(그래프)은 고정이지만, 각 도로 구간의 교통량은 시간에 따라 변한다.
- **STGCN**(Spatio-Temporal Graph Convolutional Network): 그래프 컨볼루션(공간 방향: “이웃 도로의 정보를 합친다”)와 시계열 모델(시간 방향: “과거 몇 스텝을 본다”)을 결합.

주의

비슷한 계열의 **DCRNN**도 있는데, 그 논문의 “**diffusion convolution**”은 15장 생성모델의 diffusion과는 다른 개념 — 여기서는 그래프 위의 확산 과정(무작위 걷기와 비슷한 발상)을 가리킨다.

왜 두 방향이 모두 필요한가

공간 방향만 — “이웃의 교통량을 합친다”

- **시간에 따른 변화**를 담을 수 없다: 출근 · 퇴근 시간대의 **파도**, 신호에 따른 **국소 정체**.

도로망은 그 **자신이 그래프**다 — 교차로가 노드이고 도로가 엣지.

시간 방향만 — “이 도로의 과거 교통량만 본다”

- **다른 도로의 영향**을 놓친다: 인접 구간의 정체가 이 구간으로 **전파**.

STGCN: 공간 $\times$ 시간을 순환적으로 결합

- ① 한 단계에서 (1) **공간 방향**으로 이웃 도로의 정보를 합치고,
- ② (2) **시간 방향**으로 과거 몇 단계의 **자기 자신**을 본다.
- 이것을 반복하면 “**인접 도로의 과거 흐름이 이 도로의 미래 흐름에 어떤 영향을 미치는가**”를 학습.
- 이 “**공간 $\times$ 시간 순환**” 구조는 13장 전체의 “**반복해서 값을 갱신한다**”는 패턴의 자연스러운 확장 (**노드 반복 $\rightarrow$ 노드 + 시간 반복**).

노트북 Part 3: 합성 도로망

- 작은 **합성 도로망**(4×4 격자, 교차로 = 노드)에서 인공적인 “**출근 파도**” 시계열을 만들고.
- 두 모델을 비교:
- (a) **1홉 이웃 평균만 보는 모델**
- (b) **3홉 이웃 평균 + 과거 3단계 자기 평균을 보는 모델**
- **결과: 이웃 범위를 넓히고 과거를 함께 보면 오차가 줄어든다.**

세 사례를 한 장으로

사례	그래프(자료)	이 장의 도구	질문
(a) 단백질	잔기 접촉 그래프	그래프 컨볼루션(GNN)	“이 구조는 어떤 기능을 하는가?”
(b) 금융	거래 그래프	노드 임베딩 + 중요도 점수	“어떤 계좌가 구조적으로 수상한가?”
(c) 교통	도로망 + 시계열	공간 × 시간 반복 갱신	“앞으로 N분 후의 교통량은?”

재료가 그대로 실전에 옮겨진다

- 세 케이스 모두, 이 강의 “재료”인 **그래프 자체**가 **도메인 지식에서 직접 만들어지는 형태** (접촉 그래프, 거래 그래프, 도로망).
- 이 강의 “연산”인 **반복해서 이웃과 값을 합친다**는 것이 각 도구의 **핵심**에 들어 있다.

그래프 학습에서 “모델링”이 “프로그래밍”보다 중요한 이유

도메인이 달라질수록 그래프를 어떻게 만드는가 (어떤 것을 노드로, 어떤 것을 엣지로 하는가)의 선택이 **모델의 성능을 결정한다**.

다음으로 가는 길: ML2 강화학습으로

- (c)의 “시계열을 그래프 위에 얹는다”는 생각은 **ML2의 강화학습**으로 자연스럽게 이어진다.
- **MDP**는 “상태를 노드로, 행동을 전환으로 놓은 그래프”와 같은 구조를 갖고.
- Q-함수 / 가치함수는 그 위에서 “반복해서 값을 갱신한다”는 연산을 수행 (ML2 Chapter 4의 **벨만 방정식**).

13.4 → ML2

13장의 “그래프 위에서 값을 갱신하는 감각”이, ML2의 “상태-행동 그래프 위에서 가치를 갱신하는 감각”으로 이어진다.

이번 주차 정리

- ① **13.1 무작위 걷기 = 마르코프 체인** — 전이확률 $P(i \rightarrow j) = 1/\text{deg}(i)$, 무자기성, 정상분포 π^* 가 **도에 비례**. 걷기 말뚝치 $\rightarrow$ skip-gram $\rightarrow$ 카라테 두 파벌이 공간적으로 갈라짐.
- ② **13.2 Node2Vec** — 걷기 경로 = 문장, 노드 = 단어로 skip-gram을 그대로. p, q = BFS형(역할) vs DFS형(커뮤니티) 다이얼. 실수: **무방향 대칭화 누락**.
- ③ **13.3 PageRank** — **같은 걷기에 다른 질문** (머무는 확률 = 중요도). 댐핑 + teleport, 거듭제곱법 (바나흐 고정점으로 수렴), 4-노드 손계산. $\neq$ **도**.
- ④ **13.4 확장** — 단백질(AlphaFold $\rightarrow$ DeepFRI) · 금융(AML World) · 교통(STGCN). “반복해서 이웃과 값을 합친다”가 실전 도구의 핵심.

다음 주 — Chapter 14. 표현학습

“함께 자주 나타나는 것은 가까운 벡터로 모인다”의 **텍스트 버전** — **PCA**와 **word2vec**. 이번 장이 그래프 버전을 먼저 보여줬고, 14장에서 그 원형을 본문에서 배운다. (“반복해서 값을 갱신한다”는 감각은 ML2의 벨만 방정식으로 이어진다.)