

잠재변수 생성모델: VAE에서 GAN, Diffusion까지

VAE: ELBO와 실습 · GAN, Diffusion, 그리고 세 원리 비교

Machine Learning 1 · 15주차

한국과학영재학교 (KSA)

Chapter 15

이번 주차 개요

- **15.1 VAE: ELBO와 실습** — 계산 불가능한 E-step을 신경망 인코더로 대체한 VAE. 엔센 부등식 한 번으로 ELBO를 유도하고, 두 봉우리 실습에서 **복원 항 vs KL 항**의 줄다리기를 학습 곡선으로 읽고, 표준정규분포에서 z 를 뽑아 디코더만 통과시키는 **생성 모드**까지 확인한다 (리파라미터화 트릭, β -VAE, “흐릿함”의 원인 포함).
- **15.2 GAN, Diffusion, 그리고 세 원리 비교** — 우도 기반과 다른 두 패러다임. GAN은 생성자·판별자의 **min-max 게임** (내쉬 균형, 1차원 장난감 손계산, 모드 붕괴, WGAN·CycleGAN·StyleGAN), Diffusion은 노이즈를 **한 단계씩 제거하는 MSE 회귀** (DDPM/DDIM, VAE 잠재 공간을 쓰는 Stable Diffusion, 자율주행 시뮬레이션 SceneDiffuser).

이 챕터를 마치면

ELBO를 **복원 항 + KL 정규화 항**으로 분해하고 학습 곡선에서 두 항의 **균형점**을 읽을 수 있고, GAN의 **내쉬 균형** (판별자 정확도 50%가 목표)과 **모드 붕괴**의 원인(다양성 항의 부재)을 설명할 수 있고, 세 원리를 **잠재변수 · 학습 방법 · 안정성 · 생성 속도**로 비교할 수 있다.

15.1 VAE: ELBO와 실습

EM에서 VAE로: 연속적으로, 신경망으로

- 4.4절 **GMM**: 잠재변수 z (어느 클러스터인가)가 **유한하고 이산적인** 가장 단순한 경우
- **VAE**(Variational Autoencoder, Kingma & Welling, 2013): **정확히 같은 질문** — “관측되지 않은 잠재변수가 데이터를 어떻게 만들어내는가”
- 차이: z 를 유한한 클러스터 번호가 아니라 **연속적인 벡터**로
- E-step/M-step의 명시적 반복 계산을 **신경망**으로 근사

한 문장 요약


“**EM의 E-step을 신경망이 맡는다**” — EM/GMM에서 VAE로의 전환을 가장 짧게 요약하는 문장.

“variational”이라는 이름의 기원

- 2013년 논문(Auto-Encoding Variational Bayes)의 주된 공헌은 새 생성모델이 아니라 **변분 베이즈**를 심층 신경망과 연결한 것
- 정확한 사후 $p(z|x)$ 를 계산하는 대신 **함수족 안에서 최적의 근사 $q(z|x)$ 를 “변분(변화시켜 보며)” 구하는 것**
- 맥스 웰링은 이 기법으로 텍스트 생성에 VAE를 적용한 논문 (ADAЕ, 2014)도 — 여기서 이미 표준 구조(인코더가 분포를 내놓는 구조)가 등장
- “생성형 신경망”은 2013~14년 한 번에 나온 것이 아니라 **변분 베이즈(오래된 통계 기법) × 심층학습**의 교차 지점에서 태동

방향적 그래프 모델 (원 논문 Fig. 1)

데이터 $\mathbf{x}$, 잠재 $\mathbf{z}$, 파라미터 θ . 생성 모델 $p_{\theta}(z)$, $p_{\theta}(x|z)$ 와 인식 모델 $q_{\phi}(z|x)$ 의 구조.



두 전통의 합류: 오토인코더 × 베이지안

오토인코더

- 1980년대, Geoffrey Hinton 그룹의 문자·음성 복원 연구에서 발전
- 입력을 낮은 차원의 “코드”로 **압축**하고 다시 **복원**하는 순환 구조

베이지안(잠재변수) 모델

- x 는 보이지 않는 원인 z 가 만들어낸 관측값이라는 **생성과정**의 관점
- 15.1절 GMM이 따랐던 전통

VAE = ?

“오토인코더의 **압축·복원 구조**”에 “잠재변수 모델의 **확률적 의미**”를 입힌 것.

왜 분포를 내놓는가: 빈 공간 문제

- 일반 오토인코더의 잠재 공간은 “그럴듯한 데이터로 복원되는 값”에 대한 **보장이 없음** — 학습점이 여기저기 흩어져 있고, 빈 공간에서 무작위 값을 뽑으면 무엇이 나올지 모름
- **VAE의 해법**: 인코더가 점 z 대신 **확률분포** (보통 정규분포의 평균·분산)를 내놓도록 강제
- 그 분포가 **표준정규분포**(평균 0, 분산 1)에 가깝도록 추가 제약
- $\Rightarrow$ 잠재 공간 전체가 **매끄럽고 빈틈없이** 채워져, 임의의 지점에서 샘플링해도 그럴듯한 데이터가 나올 가능성 상승

구조

인코더 $q_{\phi}(z|x)$ 가 x 로부터 z 의 분포(평균·분산)를 내놓고, 그 분포에서 z 를 샘플링한 뒤 디코더 $p_{\theta}(x|z)$ 가 x 를 복원(생성).

구조도: 학습 모드 vs 생성 모드

학습 모드 (실선)

- x 가 주어지면 인코더가 (μ, σ^2) 를 내놓고, 샘플링한 z 로 디코더가 x 를 복원
- 인코더 분포는 하단의 사전분포 $p(z)$ 에 가깝도록 KL 항이 “끌어당김”

생성 모드 (점선)

- 학습 후 **인코더는 완전히 버려짐**
- 사전분포 $p(z)$ 에서 z 를 무작위 추출 → 디코더에만 통과시켜 새 샘플



점선 = 생성 시 흐름(인코더 미사용), 실선 = 학습 시 흐름

“매끄럽게 펼쳐놓았다”의 실체

학습의 **전부** = 디코더가 “표준정규분포의 z ”라는 입력만으로 그럴듯한 x 를 만들어내도록 만드는 것.

우도 기반 접근과 “적분” 문제

- VAE는 생성형 모델 방식 중 첫 번째 — **우도 기반** (likelihood-based): 모델이 학습 데이터를 만들어낼 확률 $P(x)$ 를 (근사치로라도) **최대화**
- 문제:

$$p_{\theta}(x) = \int p_{\theta}(x|z) p(z) dz$$

가능한 모든 z 에 대한 **적분**이라 일반적으로 계산 불가능(intractable)

GMM과의 대조 (1)

- GMM: $p(x) = \sum_k \pi_k \mathcal{N}(x; \mu_k, \sigma_k^2)$
- z 가 **유한** → 유한 합, 각 항이 정규 밀도로 **닫힘** → 우도 정확히 계산 가능
- VAE: z 가 **연속** → 적분으로 바뀜, 디코더가 신경망 이라 닫힌 형태 없음

GMM과의 대조 (2)

- GMM: 이산이라 사후확률(책임값) 계산 가능 → **EM** 성립
- VAE: 이 적분의 “역방향” $p(z|x)$ 도 계산 불가능 → **E-step 수행 불가**
- 그래서 E-step을 신경망 $q_{\phi}(z|x)$ 로 **대체**(근사)

ELBO: 계산 가능한 하한으로 우회

직접 계산할 수 없는 $\log p_\theta(x)$ 대신, 다음이 성립함을 보일 수 있다:

$$\log p_\theta(x) \geq \mathbb{E}_{z \sim q_\phi(z|x)}[\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x) \parallel p(z))$$

우변을 **ELBO**(Evidence Lower BOund)라 부른다. 두 항의 의미:

첫 항: 복원 항

$\mathbb{E}[\log p_\theta(x|z)]$ — 인코더가 만든 z 로 디코더가 원본 x 를 얼마나 잘 복원하는가 (일반 오토인코더의 복원 오차와 본질적으로 같음).

둘째 항: 정규화 항

$D_{KL}(q_\phi(z|x) \parallel p(z))$ — 인코더 분포가 목표 사전분포 $p(z)$ (보통 표준정규)에서 얼마나 벗어났는가 (KL divergence, Ch. 2.3 새년의 정보이론에서 소개). 이 항이 바로 잠재 공간을 매끄럽게 만드는 힘.

ELBO 유도: 엔센 부등식 한 번

“왜 $\log p(x)$ 는 ELBO보다 항상 큰가?”를 직접 확인. q 를 우리가 고르는 임의의 근사분포로 놓고 $p(x) = \int p(x, z) dz$ 에 $\frac{q(z)}{q(z)} (= 1)$ 을 끼워넣는다:

$$\log p(x) = \log \int q(z) \frac{p(x, z)}{q(z)} dz = \log \mathbb{E}_{z \sim q} \left[\frac{p(x, z)}{q(z)} \right]$$

$\log$ 가 오목함수이므로 엔센 부등식 ($\log \mathbb{E}[X] \geq \mathbb{E}[\log X]$, Ch. 2.3 교차 엔트로피 부등식과 같은 근원)을 적용:

$$\log p(x) \geq \mathbb{E}_q \left[\log \frac{p(x, z)}{q(z)} \right] = \underbrace{\mathbb{E}_q[\log p(x|z)]}_{\text{복원 항}} - \underbrace{D_{KL}(q||p)}_{\text{정규화 항}}$$

마지막 등호에서 $\mathbb{E}_q[\log p(z)] - \mathbb{E}_q[\log q(z)] = -D_{KL}(q||p)$ 를 썼다. 엔센 부등식 한 번이 전부다.

갭의 정체: ELBO 최대화 = 변분 베이지

- 부등식의 “갭” $p(x) - \text{ELBO}$ 는 사실 $D_{KL}(q||p(z|x))$ — 근사분포가 **진짜 사후분포**와 얼마나 다른가
- $\Rightarrow$ ELBO를 최대화하는 것은 **사후분포 근사 q 를 정확히 만드는 것**과 동치
- “ELBO 최대화 = **변분 베이지**”라는 말이 정확히 이 뜻
- 등호가 성립하는 조건: $p(x, z)/q(z)$ 가 z 에 대해 상수, 즉 $q(z) = p(z|x)$ 일 때 (15.1절 연습문제 5 풀백 버전의 바로 그 조건)

학습에서의 의미

$\log p_{\theta}(x) \geq \text{ELBO}$ 이므로, **ELBO를 최대화하면 실제 우도의 하한도 함께 올라감** — 직접 계산 못하는 목표를 계산 가능한 **대리(surrogate)** 목표로 바꿔치기한 것.

손으로 한 번: 1차원 장난감에서 ELBO

15.1절 GMM과 같은 모양(1 근처·9 근처 두 봉우리)의 데이터. 1차원 z , 디코더 $p(x|z) = \mathcal{N}(x; z, 1)$, 사전 $p(z) = \mathcal{N}(0, 1)$. 근사분포를 **아무렇게나** $q(z) = \mathcal{N}(1, 1)$ 으로 고르고 $x = 1$ 에 대해 ELBO를 계산:

- **복원 항:** $\mathbb{E}_{z \sim \mathcal{N}(1, 1)}[\log \mathcal{N}(x; z, 1)]$
- z 가 평균 1·분산 1이면 $\mathbb{E}[(x - z)^2] = (x - 1)^2 + 1$ (분산 σ_z^2 항 — 아래 “자주 하는 실수” ① 참고)
- $\Rightarrow -\frac{1}{2}[(x - 1)^2 + 1 + \log 2\pi] \approx -\frac{1}{2}[0 + 1 + 1.838] = -\mathbf{1.419}$
- **정규화 항:** $D_{KL}(\mathcal{N}(1, 1) \parallel \mathcal{N}(0, 1))$ — 정규분포 사이 KL은 닫힌 형태:
 $\frac{1}{2}(\sigma_q^2 + \mu_q^2 - 1 - \log \sigma_q^2) = \frac{1}{2}(1 + 1 - 1 - 0) = \mathbf{0.5}$
- **ELBO** = $-1.419 - 0.5 = -\mathbf{1.919}$

진짜 $\log p(x)$ 와 비교: 부등식이 실제로 성립

- **진짜 $\log p(1)$:** $p(x) = \int \mathcal{N}(x|z, 1) \mathcal{N}(z; 0, 1) dz$ — “정규분포 두개의 합(적분)은 정규분포”
 $\rightarrow \mathcal{N}(x; 0, 2)$
- $\log p(1) = -\frac{1}{4} - \frac{1}{2} \log(4\pi) \approx -1.516$
- **부등식이 실제로 성립:** $-1.516 \geq -1.919$
- 갭 $-1.516 - (-1.919) = 0.403$ 은 정확히 $D_{KL}(q||p(z|x))$ — 진짜 사후 $p(z|x) = \mathcal{N}(0.5, 0.5)$
(Ch. 3 GDA 공식: 두 정규분포의 “합”이 사후)과 엉터리 근사 $\mathcal{N}(1, 1)$ 사이의 거리

$x = 9$ 로 다시 계산

복원 항 ≈ -33.419 , 정규화 항 $0.5 \rightarrow \text{ELBO} \approx -33.92$. 진짜 $\log p(9) = \log \mathcal{N}(9; 0, 2) \approx -21.52$
— **갭이 12.40으로 벌어짐.** $q = \mathcal{N}(1, 1)$ 은 $x = 1$ 근처에선 “그럭저럭” 근사(갭 0.4)지만 $x = 9$ 엔
완전히 부적합(갭 12.4).

숫자가 말하는 것: 입력별 분포가 필요한 이유

- “어느 쪽 붐우리에도 속하지 않는” $x = 5$ 의 우도도 낮음: $\log p(5) = \log \mathcal{N}(5; 0, 2) \approx -7.52$ ($x = 1$ 의 -1.52 보다 훨씬 낮음)
- $\Rightarrow$ 근사분포가 **데이터마다** 얼마나 잘 맞아야 하는지

ELBO를 최대화하는 것은 “근사분포를 잘 고르는 것”

실제 학습에서는 q 를 x 마다 다른 (인코더가 만들어내는) $q_\phi(\cdot|x)$ 로 놓아, 복원 향이 좋아질수록 정규화 향이 나빠지는(또는 그 반대) 균형이 학습이 끝난 지점에서 결정된다. 그 균형이 실제로 어디에 잡히는지 다음 실습에서 확인.

VAE 손실함수: ELBO의 코드

```
def vae_loss(x, x_reconstructed, mu, log_var):  
    # 복원손실여기서는 (로MSE 근사)  
    recon_loss = sum((x[i] - x_reconstructed[i]) ** 2 for i in range(len(x)))  
    # KL divergence: 정규분포 q(mu, sigma^2)와 표준정규 N(0,1)의 닫힌형태  
    kl_loss = -0.5 * sum(1 + log_var[i] - mu[i]**2 - math.exp(log_var[i]))  
                    for i in range(len(mu)))  
    return recon_loss + kl_loss # ELBO 최대화 = 음의 ELBO 최소화
```

정규분포 $\mathcal{N}(\mu, \sigma^2)$ 와 표준정규 $\mathcal{N}(0, 1)$ 사이의 KL은 닫힌 형태:

$$D_{KL}(\mathcal{N}(\mu, \sigma^2) \parallel \mathcal{N}(0, 1)) = \frac{1}{2} (\sigma^2 + \mu^2 - 1 - \log \sigma^2)$$

코드에서 이 값을 **음수**로 쓰는 이유: $-\frac{1}{2}(\sigma^2 + \mu^2 - 1 - \log \sigma^2)$ 는 ELBO 정규화 항에 마이너스가 붙은 형태($-D_{KL}$)이며, 복원 항과 더하면 ELBO 그 자체. 손실 = **음의 ELBO**를 최소화.

Reparameterization Trick

- z 를 확률분포에서 **직접 샘플링**하면 “샘플링” 연산은 **미분이 안 됨** → 역전파가 인코더까지 흘러가지 못함
- **Reparameterization Trick** (Rezende et al., 2014):

$$z = \mu + \sigma \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, 1)$$

- ϵ 은 무작위성을 밖으로 빼낸 상수 취급
- μ, σ 로 가는 경로가 전부 미분 가능한 연산(곱셈, 덧셈) → 역전파가 인코더 파라미터까지 정상적으로 흐름

왜 꼭 필요한가 (Ch.9 연결)

역전파는 연쇄법칙으로 미분 가능한 연산 사슬을 거슬러 올라가는 것 — “확률분포에서 무작위 추출” 연산은 미분이 정의되지 않는다. 이 트릭이 없으면 VAE의 인코더를 학습할 수 없다.

실습: 두 봉우리 데이터로 작은 VAE

15.1절 GMM 예제와 같은 모양(1 근처·9 근처 두 봉우리)의 1차원 데이터로 실제 VAE를 학습:

```
import torch, torch.nn as nn

class VAE(nn.Module):
    def __init__(self, latent_dim=2):
        super().__init__()
        self.enc = nn.Sequential(nn.Linear(1, 16), nn.ReLU())
        self.mu = nn.Linear(16, latent_dim)
        self.logvar = nn.Linear(16, latent_dim)
        self.dec = nn.Sequential(nn.Linear(latent_dim, 16), nn.ReLU(), nn.Linear(16, 1))
    def forward(self, x):
        h = self.enc(x)
        mu, logvar = self.mu(h), self.logvar(h)
        z = mu + torch.exp(0.5*logvar) * torch.randn_like(mu) # reparameterization trick
        return self.dec(z), mu, logvar
```

학습 곡선: 두 항의 줄다리기

500 에폭 학습 후 (스크래치패드 실행 검증):

에폭	loss (복원 손실, KL)
0	57.381 (54.392, 2.989)
100	3.051 (0.852, 2.199)
499	2.063 (0.482, 1.581)

- 손실이 57.4 $\rightarrow$ 2.06까지 꾸준히 감소 (무작위 초기화에 따라 수치 변동 — 시드 42 고정 시 epoch 0: 36.737, epoch 499: 1.667)
- 복원 손실이 에폭 99(0.428)보다 에폭 499(0.438)에서 **아주 약간 오르는** 구간 존재
- “총 손실 감소” $\neq$ “복원 손실만 감소” — KL 항이 크게 줄어드는 동안 복원 손실이 아주 약간 오르는 것이 두 항의 **균형이 다시 짜여지는** 과정 (epoch 199에서 복원 손실 0.461로 더 크게 올랐다가 다시 내려옴)

인코더가 두 봉우리에 배운 분포

학습이 끝난 뒤 인코더가 두 봉우리 각각에 어떤 분포를 배웠는지 확인 (시드 42 실행):

- 왼쪽 봉우리(≈ 1)의 점들: 평균 $(\mu_1, \mu_2) \approx (0.5, -0.88)$
- 오른쪽(≈ 9): $(-0.77, 1.42)$ 근처로 **분리**
- 분산은 아주 작음 ($\log \sigma^2 \approx -1.7$ 이하)

GMM과의 연결

인코더가 “왼쪽 점”과 “오른쪽 점”을 잠재 공간에서 **다른 위치에, 좁은 분포로** 배치 — GMM의 이산적 클러스터 할당에 해당하는 **연속적(soft) 버전**.

두 군집의 분산도 작게 수렴 — “여기”에 속한 점은 거의 결정적으로 배정되는, GMM의 책임값이 사실상 0/1에 가까워진 것과 같은 상태. 그 위치가 **원점(사전분포의 중심)을 사이에 두고** 대략 대칭 — KL 항이 두 군집을 원점 쪽으로 끌어당긴 흔적.

생성 모드: 원본을 전혀 보지 않고

학습이 끝난 뒤 **원본 데이터를 전혀 보지 않고**, 표준정규분포 $\mathcal{N}(0, 1)$ 에서 z 를 1000개 무작위 추출
→ **디코더에만** 통과:


생성된 샘플: 평균 4.83, 표준편차 3.84

1(왼쪽 봉우리) 근처 비율: 59.1%, 9(오른쪽 봉우리) 근처 비율: 40.9%

- 원본이 두 봉우리에 대략 절반씩인데, 디코더가 잠재 공간의 표준정규 z 만으로 그 두 봉우리를 **대략 6:4로 재현**
- 완벽하진 않지만 — “인코더가 데이터를 잠재 공간에 매끄럽게 펼쳐놓고, 어디서 샘플링해도 그럴듯한 데이터가 나온다”는 설계 목표가 실제로 작동하는 것을 확인
- (시드 42 실행: 평균 3.40 · 표준편차 2.82, 비율 74.9:25.1로 더 기울어짐 — 인코더가 두 봉우리를 정확히 **대칭적으로 배치하지 못해서**. 시드를 바꾸면 비율이 바뀌지만 큰 그림에는 영향 없음)

학습 과정 2×2 시각화

VAE 학습 과정 — 복원 항·KL 항의 균형과 두 붐우리의 재현 (시드 42)



(a) 손실 곡선 (log) (b) 인코더가 매긴 $\mu(z)$ (c) 원본
(d) 생성 샘플

- (a): KL 항이 2.2에서 1.2로 **큰 폭으로 떨어짐**, 복원 손실은 0.43 부근에서 **거의 제자리** — 두 항이 서로 “견제”하며 균형으로 수렴
- (b): GMM의 이산적 클러스터 할당의 **연속적(soft) 버전** — 각 점에 매긴 평균이 “왼쪽 $\approx (0.5, -0.9)$ ”, “오른쪽 $\approx (-0.8, 1.4)$ ” 근처의 **좁은 군집**으로 모임
- (c)(d): 생성 샘플(1000개)이 두 붐우리를 히스토그램으로 대략 재현

β -VAE: 두 항의 균형점을 “학습률처럼”

복원 항과 정규화 항의 계수를 1:1로 고정한 것은 하나의 선택일 뿐. β -VAE (H. Kingma, Salimans, Welling, 2016)는 정규화 항에 계수 β 를 붙여 $\mathcal{L} = \mathbb{E}[\log p(x|z)] - \beta D_{KL}$ 로 일반화:

β	복원 손실	KL	생성 샘플 표준편차
0	0.016	19.1	0.58
0.1	0.068	5.61	0.91
0.5	0.232	1.70	1.67
1.0 (기본)	0.378	1.22	2.05
2.0	0.546	0.90	2.42

- $\beta = 0$: 정규화 항 **완전히 끄** → 일반 오토인코더로 복귀. 복원 손실 0.016(아주 작음)이지만 KL 19.1(잠재 공간이 표준정규와 거의 무관), 생성 표준편차 0.58 — **데이터(표준편차 4.05)보다 훨씬 좁음**. 잠재 공간이 “여기저기 흩어져 있어 아무 데서 샘플링해도 안 된다”는 원래 문제 그대로.
- $\beta = 2$: 정규화 항 강화 → KL 0.90으로 작아지지만 복원 손실 0.55로 올라가고, 생성 표준편차 2.42 — **정보를 더 압축**하는 대가로 복원 품질이 약간 떨어짐.

β 는 “복원 품질 vs 잠재 공간의 매끄러움(정규성)”을 **학습률처럼 튜닝하는 하이퍼파라미터**. (“VAE가 왜 흐릿한지”의 답변도 결국 이 β 의 균형 문제에서 출발.)

자주 하는 실수 ①②: KL 항 계산

① 복원 항 기대값에 σ^2 항을 빼먹는 것

$\mathbb{E}[\log p(x|z)]$ 를 계산할 때 $(x - \mu)^2$ 만 쓰고 분산 σ_q^2 항을 빼먹으면 복원 항이 -0.919 로 **과소평가** (정답 -1.419). $z = \mu + \sigma\epsilon$ 일 때 $\mathbb{E}[(x - z)^2] = (x - \mu)^2 + \sigma^2$ — “평균으로 대체”한 것만으로 오차가 사라지지 않음. σ^2 가 큰(인코더가 불확실한) 입력에서 손실값이 실제보다 크게 나타나는(= ELBO 과소평가) 방향으로 오류를 만들어, “정규화 항을 줄이는데 왜 손실이 안 줄지”를 진단할 때 혼란의 원인.

② KL 항을 “분산만” 계산하는 것

인코더가 (μ, σ^2) 를 함께 내놓는데, KL 항에 μ^2 (위치) 항을 빼먹고 $\sigma^2 - 1 - \log \sigma^2$ 만 쓰면, μ 에 대한 **그래디언트가 0** — 인코더의 평균 출력 위치에 대해 정규화 항이 아무 작용도 하지 않아 “분산만 조절된다”는, 학습이 이상하게 멈추는 원인. $\frac{1}{2}(\sigma^2 + \mu^2 - 1 - \log \sigma^2)$ 의 μ^2 항이 **인코더의 위치(μ)를 원점 방향으로 끌어당기는 힘**임을 꼭 기억.

자주 하는 실수 ③④⑤

- ③ β 를 너무 크게 올려 “정규화만” 보는 학습 — β -VAE에서 β 를 극단적으로 올리면 KL이 0에 가까워지고 복원 손실은 커짐 — “인코더가 데이터를 전혀 담지 않고 표준정규분포를 그대로 뱉는” 방향으로 **치팅**할 유인이 강해짐. $\beta = 2$ 이미 복원 손실 0.55(기본 1.0 대비 1.45배). “KL을 많이 줄이면 잠재 공간이 더 매끄러우니 좋다”는 생각은 β -VAE의 **균형을 무너뜨리는 것**.
- ④ 생성 샘플을 “인코더”에 다시 넣는 것 — 생성 모드에서는 사전분포 $p(z)$ 에서 z 를 뽑아 **디코더에만** 통과. 인코더를 다시 거치면 “학습 데이터에 가까운 z ”만 만들어져 “새로운 샘플”이 안 나옴 (인코더는 생성 시 **사용하지 않는** 것이 VAE의 구조 — 구조도의 점선/실선 구분이 말해줌).
- ⑤ “ELBO가 높으면 진짜 우도도 반드시 높다”는 착각 — ELBO는 **하한**이지 근사가 아님. q 가 진짜 사후 $p(z|x)$ 와 크게 다르면 갭이 커짐 ($x = 9$ 예제: 갭 12.4, 진짜 -21.5 , ELBO -33.9). “ELBO 높음 $\rightarrow$ 우도 높음”은 **항상** 성립(하한이니까), “ELBO 낮음 $\rightarrow$ 우도 낮음”은 **반드시** 성립하지 않음 (q 가 나쁘면 갭이 큼).

확인 문제 (15.1)

- 1 **ELBO 부등식의 갭.** $\log p(x) - \text{ELBO} = D_{KL}(q||p(z|x))$ 임을 유도한 뒤, $q = p(z|x)$ 일 때만 갭이 0이 된다는 것을 한 문장으로 설명.
- 2 **정규분포 합 = 정규분포.** $\mathcal{N}(x; z, 1) \cdot \mathcal{N}(z; 0, 1)$ 에 대해 z 로 적분 하면 $\mathcal{N}(x; 0, 2)$ 가 된다는 것을, “두 독립 정규분포의 합은 정규분포”라는 사실로부터 한 문장으로 설명.
- 3 **손계산 재현.** $x = 9$ 예제에서 복원 항이 ≈ -33.4 가 되는 것을 직접 계산 (힌트: $(x - \mu)^2 = 64, \sigma_q^2 = 1, \log 2\pi \approx 1.838$ 대입).

핵심 요약

ELBO = 복원 항 - KL 정규화 항. ELBO 최대화 = 사후분포 근사 q 를 정확히 만드는 것 (변분 베이즈). μ^2 항은 위치를 원점 쪽으로 끌어당기는 힘, σ^2 항은 너비를 제어.

자주 묻는 질문: 두 항 중 하나만 최적화하면?

- **복원 항만**(KL 없이): 일반 오토인코더와 같아져 잠재 공간이 매끄럽지 않아 샘플링 품질이 나빠짐 — 실습에서 KL 항이 없었다면 생성 샘플이 두 봉우리를 재현하지 못했을 가능성 큼
- **KL 항만**(복원 없이): 인코더가 아무 정보도 담지 않고 그냥 표준정규분포를 그대로 뱉는 방향으로 “치팅” — 복원이 전혀 안 되는 무의미한 모델
- ⇒ **두 항의 균형이 VAE의 핵심**

자주 묻는 질문: 리파라미터화 · 흐릿함

Reparameterization trick이 왜 꼭 필요한가?

Ch. 9: 역전파는 연쇄법칙으로 미분 가능한 연산 사슬을 거슬러 올라가는 것. “확률분포에서 무작위 추출” 연산은 미분이 정의 안 됨. $z = \mu + \sigma \odot \epsilon$ 으로 다시 쓰면 무작위성은 ϵ (입력과 무관한 상수)에만, μ, σ 로 가는 경로는 전부 미분 가능(곱셈·덧셈) → 역전파가 인코더 파라미터까지 정상적으로 흐름.

KL 항이 “흐릿함”의 원인이라는 말은?

복원 항은 **기대값** $\mathbb{E}_{z \sim q}[\log p(x|z)]$ 를 최적화 — 인코더 분포의 **모든** z 로 복원했을 때의 **평균**이 좋아야 함. 분포가 넓을수록(σ^2 클수록) 복원된 x 후보가 넓게 퍼져 “모든 z 의 평균”이 흐려짐 → VAE 생성 이미지의 **흐릿함(blurry)** 근원. β 를 크게 하면 더 강해짐 (정보를 더 압축하니까). GAN이 “한 개 $z \rightarrow$ 한 개 x ”를 **결정적으로** 학습(흐릿하지 않은 선명함)하는 이유도 결국 “기대값 최적화 vs 결정적 복원”의 차이.

자주 묻는 질문: EM/GMM과의 관계 · 차원 선택

VAE와 15.1절 EM/GMM의 관계?

GMM: z 가 **이산**(클러스터 번호)이라 E-step(책임값)이 닫혀 계산 가능 → EM 성립. VAE: z 가 **연속**이라 E-step 자체가 계산 불가능 → **E-step을 신경망 $q_\phi(z|x)$ 로 대체**(근사), M-step을 **역전파**로 수행. “EM의 E-step을 신경망이 대신한다”. M-step도 “잠재변수별 파라미터 가중평균”이 아니라 “전체 파라미터를 ELBO의 그래디언트로 갱신”으로 바뀐다.

latent_dim = 2가 왜 2차원인가?

학습 대상이 아니라 하이퍼파라미터. 두 봉우리 데이터: “두 가지 원인”이 있어 1차원으로 충분, 2차원이면 두 봉우리가 원점 중심의 **대칭** 위치로 자연스럽게 배치. 이미지 데이터: 20~200 차원이 혼잡 — 너무 작으면 복원 품질 떨어짐, 너무 크면 “사용하지 않는 차원”으로 가득 차 KL이 커짐.

15.2 GAN, Diffusion, 그리고 세 원리 비교

15.1의 다음: 우도 기반과 확연히 다른 두 방식


- 15.1절 **VAE** = 4.4절 GMM/EM이 던진 질문을 신경망으로 근사 — 풀리지 않는 E-step을 인코더로 대체, 우도의 하한(ELBO)을 역전파로 최대화하는 **우도 기반**의 마지막 방식
- 이번 절: 우도 기반과 **확연히 다른** 두 방식
- **GAN**: 두 신경망의 **경쟁 게임**으로 학습
- **Diffusion**: 노이즈를 **한 단계씩 되돌리는 회귀 문제**로 학습
- 세 방식(VAE·GAN·Diffusion)이 나란히 놓이면 Chapter 15 전체의 그림이 완성

GAN: 생성자와 판별자의 min-max 게임

- 2014년, 몬트리올 대학교 얀 르쿤·요슈아 벵기오 연구소 박사 과정 **이언 굿펠로우(Ian Goodfellow)**: “진짜 같은 가짜를 만드는 모델 학습” 대신 **두 신경망이 서로 경쟁**하게 하면?
- **위조범**(생성자 G): 가짜를 만듦
- **감정사**(판별자 D): 진짜/가짜를 구별
- VAE가 “우도 최대화”라는 명확한 **단일** 목표함수가 있었던 것과 달리, GAN은 두 네트워크가 **서로 다른, 심지어 반대되는** 목표를 갖고 동시에 학습

역사적 일화

2015년 GAN 논문이 처음 ICLR 워크숍에 제출됐을 때 거절, 심사평 “**average quality**”. 2016년 ACM 튜링상 수상 연설에서 굿펠로우가 이 일화를 직접 소개 — “평균적”이라 거부당한 논문이 그해 딥러닝계를 가장 뜨겁게 달군 논문이 된 아이러니.



생성자·판별자와 목적함수

- **생성자**(Generator) G : 무작위 노이즈 $z \sim p(z)$ 를 입력받아 가짜 데이터 $G(z)$ 를 만듦
- **판별자**(Discriminator) D : 데이터를 입력받아, 그것이 **진짜일 확률** $D(x) \in [0, 1]$ 을 출력
(Ch.2 **로지스틱회귀**와 정확히 같은 형태)

목적함수 (min-max game):

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z \sim p(z)} [\log(1 - D(G(z)))]$$

판별자 손실	$-(\mathbb{E}[\log D(x)] + \mathbb{E}[\log(1 - D(G(z)))])$
생성자 손실	$-\mathbb{E}[\log D(G(z))]$ (D_fake를 1에 가깝게)

왜 “균형점”을 논해야 하는가

- 두 네트워크가 **서로 반대 목표**로 동시에 학습 → “학습이 끝났다”는 것이 무슨 의미인지 **다시 정의**해야 함
- 게임이론에서 이런 안정 상태 = **내쉬 균형**(Nash equilibrium) — **어느 쪽도 혼자서 전략을 바꿔서 더 나아질 수 없는 상태**
- 이론적으로 이 게임의 내쉬 균형은 $D(x) = 0.5$ (판별자가 진짜와 가짜를 전혀 구별하지 못함)이고, G 가 만드는 분포가 **실제 데이터 분포와 정확히 같아지는** 지점임이 증명되어 있음

실전 판독: 판별자 정확도 50%가 “목표 운영점”. 90%+로 치솟으면 G 가 이미 학습에서 이탈한 실패 신호.

1차원 장난감: 파라미터가 딱 1개인 GAN

“내쉬 균형”이 추상적으로 들리면, **파라미터가 딱 1개인** 장난감 GAN으로 균형을 직접 계산.

- 데이터 $x \sim \mathcal{N}(0, 1)$, 생성자 분포 $p_G = \mathcal{N}(0, s^2)$
- **표준편차 s 하나로** 가짜 분포의 “너비”만 바꿀 수 있는 생성자
- 평균은 0으로 고정 — 데이터와 가짜가 모두 0에 대칭이라 평균 0이 당연히 최고. 게임이 “너비 맞추기”라는 **한 가지 문제**로 깔끔하게 축소

판별자는 로지스틱회귀

D 는 x 위의 로지스틱회귀(Ch. 2.3). G 를 고정하고 D 를 **완전히** 최적화하면(미니배치가 아니라 전체 데이터에서 MLE로) 해는 **달린 형태**:

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_G(x)}$$

놀라운 닫힌 형태: JSD로 게임의 값

D^* 를 목적함수에 대입하면 게임의 값이 **닫힌 형태**로 나옴 (GAN 원논문 Theorem 7):

$$V(D^*, G) = 2 \text{JSD}(p_{\text{data}} \| p_G) - \log 4$$

JSD (Jensen-Shannon Divergence)

KL 발산의 “**양방향 평균**” 버전: $\text{JSD}(p \| q) = \frac{1}{2} D_{KL}(p \| m) + \frac{1}{2} D_{KL}(q \| m)$, $m = \frac{1}{2}(p + q)$. KL은 p, q 순서가 바뀌면 값이 달라지는 **비대칭** 발산인데, JSD는 두 방향의 평균이라 **대칭**.

- $\text{JSD} \geq 0$ 이고 두 분포가 **정확히 같을 때만** $0 \rightarrow V$ 의 최솟값은 $p_G = p_{\text{data}}$ 에서의 $-\log 4$
- $\text{JSD} \leq \log 2 \rightarrow$ 게임의 값은 항상 $[-\log 4, 0)$ 안에

“게임 값을 낮추라” = “JSD를 줄이라”

생성자 관점의 명령

“게임 값을 낮추라”는 것은 “가짜와 데이터 분포의 JSD를 줄이라”는 것과 정확히 같은 명령 — 두 분포를 일치시키는 것, 즉 내쉬 균형 $s^* = 1$ 으로 수렴.

“학습 루프”를 들여다보자 — 교대 반복 (좌표별 최적화):

- ① G 를 고정하고 D 를 최적화 (장난감에서는 닫힌 형태 D^* 라 바로 점프)
- ② D^* 를 고정하고 G 의 파라미터 s 를 그래디언트 스텝으로 한 스텝 갱신

4.4절 EM의 뼈대 (E-step: 파라미터 고정 → 잠재변수 채우기 / M-step: 잠재변수 고정 → 파라미터 갱신)과 같은 좌표별 최적화 구조가, “잠재변수”를 “한 네트워크”로 바뀐 형태로 그대로.

EM과의 결정적 차이

EM

- E-step이 **정확한** 사후확률을 채워 넣음
- “우도가 매 반복 절대 줄지 않는다”는 보장이 **증명 가능**

GAN 루프

- (1)이 일반적으로 **완전 최적화가 아닌 근사**
- 매 D 갱신마다 G 가 내려다보는 **경사면 자체가 바뀌고**
- 게임 값에 **단조 감소 보장이 없음**

이 장난감이 운 좋은 이유


게임 값이 s 의 매끄러운 함수로 **유일하게** 최소가 $s = 1$ 에 있어 **단조하게** 수렴. 실전 GAN의 “나쁜 소식들”(등락, 발산, 모드 붕괴)이 아직 안 보이는 이유 = 이 장난감에 **국소 균형이 딱 하나**뿐. 여러 개의 국소 균형이 존재하려면, 데이터 분포의 “여러 모드 중 일부만 덮는” 가짜 분포도 균형 후보가 되는 **고차원 세계**가 필요.

40스텝 교대 최적화 궤적

$s_0 = 2.0$, 학습률 $\eta = 0.15$ 로 40스텝 (수반 노트북 2절):

스텝	s	$V(D^*, G)$	$D^*(0)$
0	2.000	-1.201	0.667
10	1.664	-1.276	0.625
20	1.339	-1.346	0.572
30	1.113	-1.381	0.527
40	1.026	-1.386	0.507
∞	1.000	$-\log 4 \approx -1.386$	0.500

- (i) 균형점의 게임 값은 $-\log 4 \approx -1.386$ 인데 **0이 아님** — “생성자 손실이 0에 가까워지면 성공”은 틀린 읽기. 성공 신호 = V 가 더 이상 줄지 않고 $-\log 4$ 근방에서 **안정**
- (ii) $D^*(0)$ (판별자가 데이터 중심 $x = 0$ 을 “진짜”로 판정하는 확률)이 0.667에서 0.5로 **점점 구별력을 잃는** 궤적 — “내쉬 균형 = 판별자가 완전히 헛갈리는 점”의 실행



왼쪽: $V(D^*, G)$ 궤적, 오른쪽: $D^*(0)$ 수렴

장난감의 한계: 평균을 못 움직임

- 이 장난감의 생성자는 **평균을 못 움직임** → “데이터의 질량이 어디에 놓이는지”를 **선택할 자유가 없음** — 너비만 맞출 뿐
- 일반적인 GAN의 생성자는 **이 자유까지** 갖고 있음
- **모드 붕괴는 정확히 이 자유를 남용하는 실패 모드** (다음 섹션)

실전 학습: 교대 최적화의 함정

실제 GAN 학습 루프는 장난감과 같은 교대 구조 — 다만 닫힌 형태가 없어서 “최적 판별자로 점프” 대신 **그라디언트 스텝**을 걸음.

- (1) 판별자 갱신: G 고정, D 만 한 스텝
- (2) 생성자 갱신: D 고정, G 만 한 스텝 — G_{loss} 의 그라디언트가 D 를 “지나” G 의 파라미터로 흐름
- (두 번째 *fake*를 다시 계산하는 이유: 미분 그래프가 $D.\text{step}()$ 이후 **갱신된 D 를 거쳐야** 생성자 파라미터까지 흐름 — Ch. 9 “연산 그래프를 따라 거슬러 올라가는 것”)

EM과의 차이 (다시)

EM: E-step이 **정확한** 사후확률을 채워넣음 → “우도가 단조증가”가 **증명 가능**. GAN: (1)이 D 를 완전 최적화하지도, (2)가 G 를 완전 최적화하지도 못하는 **근사적** 게임 최적화 → 학습 곡선이 “꾸준히 하강하는 우도”처럼 보이지 않고, 오히려 **등락을 거듭**.

불안정성의 세 가지 양상

- **D 가 너무 강해지면 G 의 그래디언트가 무용화** — D 가 모든 가짜를 $D \approx 0$ 으로 확신하면, $\log(1 - D(G(z))) \approx 0$ 과 $\log D(G(z)) \rightarrow -\infty$ 사이에서 G 가 받는 신호는 “네가 만든 건 전부 가짜”라는 **방향 없는 신호** $\rightarrow$ Ch. 9 “**그래디언트 소실**”과 정확히 같은 구조
- **D 가 너무 약하면 G 는 “약한 판별자만” 속이는 법을 배움** — D 의 빈틈을 파고드는 가짜가 손실을 최소화하지만, 데이터 분포 자체를 잘 본 것은 아님. D 가 다음에 더 강해지면 다시 무너짐.
- **두 네트워크의 “학습 속도 밸런스”가 중요** — 한쪽이 너무 빨리 수렴하면 다른 쪽의 학습 신호가 사라짐. 실전 대응: D 에 **배터치 정규화**(Ch. 9)를 쓰거나, G 에 학습률을 작게 맞추거나, 그래디언트 페널티(WGAN-GP)를 붙이는 등

실수 1: D 정확도 50%를 “실패”로 읽기

거꾸다

이 게임에서 D 의 정확도 50%는 **가장 이상적인 운영점** (내쉬 균형).

- 학습 중 D 의 정확도가 **50% 부근**에서 머물면 “양쪽이 서로를 잘 따라가고 있다”는 **신호**
- 반대로 D 의 정확도가 **90%+**로 치솟으면 **G 가 이미 학습에서 이탈한 전형적 실패 신호** — “ D 가 잘 learned하고 있다”가 아니라 “ **G 가 D 를 못 따라가고 있다**”는 뜻

모드 붕괴: “성공”이 “실패”가 되는 지점

- 실전 GAN 학습이 자주 불안정 — 생성자가 판별자를 속이는 **몇 가지 패턴에만 몰려** 다양성을 잃는 현상 = **모드 붕괴(mode collapse)**
- VAE: 이론적으로 **안정적**이지만 생성 품질이 다소 **흐릿(blurry)** 경향
- GAN: **선명한** 결과이지만 **학습이 까다로움**

1차원 장난감이 이미 메커니즘을 보여줌

기본 GAN 목적함수에는 “**다양성을 유지하라는 항**”이 없음. 생성자 손실 $-\log D(G(z))$ 는 오직 “이 가짜가 D 를 얼마나 속였는가”에 의존. 데이터 분포가 세 개의 모드(예: 세 종류의 동물)를 갖고 있어도, **하나의** 모드만 집중적으로 만들어도 D 를 잘 속일 수 있다면 — 고차원 공간에서 D 가 “세 모드 모두를 동시에 감시”할 수 없는 한 — 그 하나에 집중하는 것이 손실을 줄이는 **가장 확실한 전략**.

VAE에는 이 항이 있다: 핵심 구조적 차이

VAE (15.1절)

- KL 항 $D_{KL}(q_\phi(z|x)||p(z))$ 이 “인코더 출력 분포가 표준정규분포에 가깝게 유지”를 **목적함수 안에 명시적으로** 요구
- 잠재 공간 **전체**가 쓰이는 구조적 압력
- “잠재 공간의 일부만 쓰는” 퇴화 = **ELBO**를 **직접적으로 낮추는 행위**

GAN

- 내쉬 균형 $p_G = p_{\text{data}}$ (모든 모드를 덮는 분포)가 “완전한 균형”
- 실제 학습이 풀고 있는 **근사적** 게임에서는 “일부 모드를 덮고 D 를 속이는” 분포도 **국소적으로 균형처럼** 작용
- 이 대응 **항이 없음**

이것이 VAE/GAN 비교에서 반복되는 핵심 구조적 차이.

2014년 이후 GAN 계열: “안정화”가 3년의 주제

기본 GAN의 불안정성을 고치려는 시도가 GAN 연구의 줄기를 이룸 (각 방법의 정확한 수학은 넘기고, “무엇을 고치려 했는지”만):

- **WGAN / WGAN-GP (2017, Arjovsky et al. / Gulrajani et al.)** — “ D 가 G 를 완전히 이기면 G 의 그래디언트가 사라진다”는 문제를 정조준. 게임의 값을 두 분포의 **워터스톤 거리**(Wasserstein-1, 두 분포를 “이동시켜 일치시키는 최소 비용” — 어스무버 거리)로 바꾼 뒤, D 를 **1-Lipschitz**로 제한(처음엔 가중치 클리핑, WGAN-GP는 **그래디언트 페널티**) → 게임 값이 두 분포의 실제 거리와 일치해 G 가 **분포가 어디로 옮겨가야 하는지 방향 신호**를 계속 수신. 그래디언트가 “0”으로 안 죽음 → 학습이 훨씬 안정적, 모드 붕괴도 감소.
- **pix2pix (2016), CycleGAN (2017)** — “이미지 → 이미지” 변환으로 확장. CycleGAN은 **레이블된** 데이터 없이도 (말 사진만, 기린 사진만) 두 분포 사이의 대응을 학습해 “말 → 기린” 같은 스타일 변환 — GAN이 “비슷한 이미지 생성”을 넘어 **구조를 보존하며 변환**하는 도구로 확장.
- **StyleGAN (2018–2019)** — 초고해상도 합성 인간 얼굴. 잠재 벡터를 “스타일 수준별로” 나눠 조작 → “얼굴 표정만 바꾸고 얼굴 형태는 그대로” 같은 **제어된** 생성 (16장 팀 프로젝트에서 다시 만남).
- **BigGAN (2019)** — ImageNet 전체에 걸친 대규모 **조건부** 생성 — “이 클래스의 이미지를 만들어라”를 1024×1024 해상도로.

Diffusion: 정방향/역방향 과정

정방향 과정 (forward process)

진짜 이미지 x_0 에 **아주 작은 노이즈**를 T 번 반복해서 추가해, 결국 x_T 가 **순수한 무작위 노이즈**가 됨.
이 과정은 **고정된 절차**이지 학습 대상이 아님.

역방향 과정 (reverse process)

신경망이 “**한 단계 전 노이즈가 어땠는지**”를 예측하도록 학습. 학습 후, 순수 노이즈 x_T 에서 시작해 이 역방향 단계를 T 번 반복 → **새로운 이미지**.

- GAN이 “**한 번에**” 노이즈를 이미지로 바꾸려 하는 것과 달리, Diffusion은 그 어려운 문제를 **아주 작은 단계 T 개로 잘게 쪼갬** — 각 단계는 “노이즈를 아주 조금만 제거”하는 훨씬 쉬운 문제 → **전체적으로 훨씬 안정적**
- **대가**: 이미지 하나 생성에 T 번 반복 필요 → GAN보다 **생성 속도 느림**
- 지금 가장 널리 쓰이는 이미지 생성 모델(Stable Diffusion 등)이 이 원리 사용

정방향은 왜 “학습 대상”이 아닌가

- 정방향 과정은 **고정된, 알려진** 절차:

$$x_t = \sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, I)$$

- 각 단계에 “얼마나 큰 노이즈를 추가하는지”가 미리 정해진 β_t **스케줄**에 따라 기계적 진행
- 노이즈를 **추가하는** 것은 역산이 됨 — 정확한 노이즈 값을 알면 x_{t-1} 을 바로 구함
- “어려운” 부분은 **노이즈 값을 관측하지 못한** 상태에서 “이 상태 x_t 에서 한 단계 전은 어땠을까”를 추측하는 **역방향** 쪽

학습 대상은 하나뿐

역방향 모델 $p_\theta(x_{t-1} \mid x_t)$.

“노이즈 예측” 회귀 문제 (DDPM)

실전(DDPM)에서는 역방향 분포를 직접 매개변수화하지 않고, 대신 신경망 $\epsilon_\theta(x_t, t)$ 가 x_t 에 추가된 노이즈 ϵ_t 를 예측하도록 학습:

$$\mathcal{L}(\theta) = \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$$

이 식이 **MSE 회귀 손실**이라는 점에 주목

이 장에서 본 모든 방식(EM의 M-step, VAE의 ELBO 역전파)과 달리, GAN의 min-max 게임도 아니고, 우도의 적분 근사도 아닌, **가장 보통의 단일 회귀 최적화**. “안정적으로 학습된다”의 정체가 바로 이것.

수학적으로 이 ϵ 예측은 $\nabla_x \log p_t(x)$, 즉 데이터 분포의 **스코어 함수**를 추정하는 것과 동치 (Song & Ermon, 2019) — “노이즈를 잘 예측” = “데이터가 어디에 뿔뿔한지 그 기울기를 안다”.

역방향 단계(DDPM)와 “다시 노이즈 추가”

역방향 단계는 한 줄:

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z, \quad z \sim \mathcal{N}(0, I)$$

- “ ϵ_θ 만큼 빼고(조금 깨끗해지고), $\sigma_t z$ 만큼 다시 더한다(다시 노이즈를 조금)”
- **역방향에도 노이즈를 다시 추가**하는 이 마지막 항이 처음엔 의외로 보일 수 있음
- 이유: $x_{t-1} | x_t$ 가 “하나의 점”이 아니라 **가우시안 분포**(불확실성이 있는)이기 때문
- “한 단계 전”도 **관측되지 않았으므로**, 그 분포에서 샘플링하는 것이 **절차의 일부**

자주 하는 실수 3

“denoise = 계속 깨끗해지는 과정”이라는 직관과 달리, DDPM의 역방향 단계에는 $+\sigma_t z$ (**다시 노이즈 추가**)가 있음. 이 항을 빼면 역방향 과정이 더 이상 $p(x_{t-1} | x_t)$ 가 아니라 “**점 추정**”으로 바뀌고, 생성 품질이 크게 떨어짐. $x_{t-1} | x_t$ 가 **분포**라는 점을 잊지 말 것.

역사: Sohl-Dickstein 2015 → DDPM 2020

- 2015년 **Sohl-Dickstein** 외 “Deep Unsupervised Learning using Nonequilibrium Thermodynamics” — 정방향/역방향 아이디어 **처음 딥러닝에 제안**. 하지만 **학습이 너무 느려** 실용화 못 함
- 2020년 **DDPM** (Ho, Jain & Abbeel, “Denoising Diffusion Probabilistic Models”): (i) 노이즈 예측 매개변수화 ϵ_θ , (ii) 단순한 MSE 손실, (iii) 실용적 스케줄 → **실제로 쓸 만한** 알고리즘으로 만듦
- 같은 해 **DDIM** (Song et al.): 역방향 과정을 **거의 결정적으로** 만들어 T 를 **1000에서 약 50** 단계로 줄임
- 2022년 **Stable Diffusion** (Stability AI): 여기에 15.1절의 **VAE**를 조합 — 이미지를 VAE 인코더로 **$8\times$ 압축한 잠재 공간**에서 Diffusion을 돌림, 계산량 $1/8^2$ 로 감소
- 15.1에서 “VAE의 매끄러운 잠재 공간”이 왜 중요한지 — 그것이 곧 Diffusion을 **안정 있게** 학습·추론할 수 있게 하는 **전제 조건**
- 같은 해 DALL·E 2, Midjourney, 2024년 Sora(영상)까지 — 이미지 생성의 **주류가 Diffusion으로 이동**

세 원리가 각자 독립적으로 끝나는 것이 아니라 서로 연결되어 실전 시스템으로 합쳐진다는 점 — 이번 장을 “세 개를 나란히” 보는 이유.

GAN vs Diffusion: “학습할 것” 한 줄

	GAN	Diffusion
학습할 네트워크	2개 (G, D)	1개 (ϵ_θ)
학습 목표	게임의 균형 (단힌 형태 없음)	$\ \epsilon - \epsilon_\theta\ ^2$ (MSE)
샘플링 시 순전파	1회	T 회 (DDIM으로 ~ 50 회)

이미지 밖으로: Waymo SceneDiffuser

Diffusion의 “노이즈를 점진적으로 되돌린다”는 원리는 픽셀 공간에 머물지 않음.

- 2024년 **Waymo** 자율주행 개발 시뮬레이션 도구 **SceneDiffuser**: **자연어 지시**(“자신의 차가 저속 차량을 따라가는 장면” 같은)로부터 **3차원 교통 장면의 초기 배치**(차량·보행객의 위치, 진행 방향, 크기)를 생성 + 그 장면을 **앞으로 전개될 미래(롤아웃)**까지 시뮬레이션
- 핵심: “**장면 수준(scene-level)의 Diffusion 사전분포**” — 장면 전체 상태가 시간에 따라 어떻게 흘러갈지를 하나의 **스페이오-템포럴(spatio-temporal, 공간-시간)** Diffusion 모델로 예측
- roadgraph·교통 신호 같은 제약 조건으로 노이즈 제거를 유도하는 **조건부 생성** — Stable Diffusion의 “텍스트 → 이미지”와 **정확히 같은 패턴**
- Stable Diffusion이 **이미지 하나**의 잠재 공간에서 노이즈를 되돌렸다면, SceneDiffuser는 **시간을 축으로 한 장면 전체**에서 되돌림
- ⇒ 자율주행 시스템을 테스트할 **상상 속 시나리오**를 대량으로 생성 — “**생성 모델이 안전 검증 도구로 쓰인다**”는 점을 보여주는 대표 사례. 추론에 필요한 모델 호출 횟수도 **16배** 감소

세 원리 비교

	VAE (우도 기반)	GAN (적대적)	Diffusion (스코어 기반)
잠재변수 학습 방법	연속 벡터 ELBO 최대화 (역전파)	없음 (노이즈를 직접 변환) min-max 게임 의 균형	연속(노이즈 단계) 각 단계 노이즈 예측 최소화
학습 안정성 생성 속도	비교적 안정적 빠름 (한 번에)	불안정하기 쉬움 빠름 (한 번에)	안정적 느림 (반복 필요)

참고: 4.4절 GMM도 같은 질문의 **이산 잠재변수** 버전 — z 가 클러스터 번호라 E-step이 닫힌 형태로 **정확히** 계산되므로, “정밀하지만 이산”으로 여기 추가하지 않음.

잠재변수 행 다시 읽기

“관측 안 된 구조”가 세 방식에서 각각 무엇이었는지:

- **VAE**의 z = **연속 벡터** — 가능치가 무한해서 E-step을 신경망으로 **근사**해야 함 (15.1절)
- **GAN**의 z = **분포가 아니라 그냥 랜덤 입력** — “데이터를 설명하는 잠재변수”의 역할을 **하지 않고**, 생성자가 입력으로 받는 **다양성의 원천**일 뿐 (z 의 분포를 학습하지도, $z \mid x$ 를 추론하지도 않음)
- **Diffusion**의 “잠재변수” = **중간 상태** x_t — 연속적이지만 **단계 t 가 이산적으로 T 개인**, “점진적으로 오염된 데이터” 그 자체

학습 방법 행 다시 읽기: 안정성의 원인

- **VAE**: ELBO(단일 목적함수)를 역전파로 최대화하는 **보통의** 최적화 → **안정**
- **Diffusion**: MSE 회귀라 **가장 보통의** 최적화 → **안정**
- (대조: 4.4절 EM은 **달린 형태**의 좌표별 최적화라 **증명 가능하게** 안정)
- **GAN**: 두 개의 최적화 알고리즘이 서로의 목표함수를 바꾸어놓는 게임 — 단조증가도, 볼록성도, “수렴했다는 것” 자체의 정의도 — 안정성의 근거가 없음

생성 속도 행: “안정성의 대가”

- 가장 **안정한** Diffusion은 생성에 **T 회 반복** 필요 (DDIM으로 줄여도 수십 회)
- 가장 **빠른** GAN/VAE는 **한 번의** 순전파로 생성

장 전체를 관통하는 트레이드오프

“데이터를 설명할 수 있다(안정성, 평가 가능)” vs “빨리 만들 수 있다(속도)”

실전 시스템은 “하나씩 고르는 것”이 아니라 **조합**

Stable Diffusion = **VAE**(잠재 공간) $\times$ **Diffusion**(노이즈 제거). SceneDiffuser = **Diffusion**
원리를 **시간 축의 장면**으로 확장. $\Rightarrow$ “세 원리를 나란히 보고 나서야, “관측되지 않은 구조가 데이터를 만들어낸다”는 하나의 질문이 얼마나 다양한 방식으로 풀릴 수 있는지”가 보임.

자주 하는 실수 2·4: GAN/Diffusion 판독

실수 2 — “생성자의 loss가 계속 줄어야 정상”이라고 기대

GAN의 loss 곡선은 **등락** — D 가 갱신될 때마다 G 의 손실 함수 **자체**가 바뀌므로, “loss가 튀었다”가 반드시 실패를 뜻하지 않음. (반대로 EM의 우도처럼 **단조증가**하는 곡선을 기대하면 GAN의 “정상”을 “이상”으로 오독.) 실전에서는 **샘플 품질**을 직접 보고, D 의 정확도가 50% 부근에서 **균형**을 유지하는지를 대시보드로.

실수 4 — “ D 의 정확도 50%”를 “잘 안 하고 있다”로 읽기

반대다 — 50%는 이 게임의 **목표** operating point(내쉬 균형). **정확도가 90%+로 치솟는 쪽**이 진짜 문제 신호 (위 “실전 학습”의 실수 1 참고).

확인 문제 (15.2)

- ① **(손계산, Tier A)** 1차원 장난감 GAN에서 $\mu = 0.5$ 일 때 게임의 값 $V(D^*, G) = \log(1 + 1/\phi(0.5))$ 를 계산 ($\phi(0.5) = 0.3521$). 균형점 $\mu = 0$ 에서의 값 $V(D^*, G) = \log(1 + 1/\phi(0)) = \log(1 + 1/0.3989)$ 와 비교 — “ $\mu = 0.5$ 에서는 아직 균형이 아니며, 생성자는 μ 를 어떤 방향으로 움직일 유인이 있는가”를 한 문장으로 (힌트: $\mu = 0$ 에서의 값이 **더 작아야** $\mu = 0$ 이 G 의 최소 — 즉 G 의 관점의 내쉬 균형).
- ② **(개념 서술)** 1차원 장난감에서 생성자는 결국 $\mu = 0$ **하나의 점**을 만듦 — 게임 관점에서는 “판별자를 완전히 속였다”의 **성공**이지만, 생성 품질 관점에서는 “다양성 0”의 **실패**. VAE의 ELBO에는 이 문제를 막는 **명시적인 항**이 있는데, 그 항이 무엇이며 GAN의 목적함수에는 왜 대응하는 항이 없는지를 두세 문장.

자주 묻는 질문: 모드 붕괴 · VAE/GAN/Diffusion

모드 붕괴는 왜 생기나요?

생성자는 판별자를 속이기만 하면 손실이 줄어듦 — 어떤 **한 종류**의 가짜가 판별자를 아주 잘 속인다는 것을 발견하면, 굳이 다른 다양한 가짜를 만들 이유가 없음. 판별자가 그 “치팅”을 알아채고 대응하기 전까지, 생성자는 그 **좁은 영역에만 몰릴** 유인. 근본 원인: VAE의 ELBO처럼 “**다양성을 명시적으로 요구하는 항**”이 GAN 기본 목적함수에는 **없음**.

Diffusion이 주류인데 VAE·GAN은 이제 안 쓰나요?

이미지 생성 분야에서는 Diffusion이 최근 주류가 됐지만, **VAE의 핵심 아이디어**(잠재 공간을 매끄럽게 만든다)는 여러 최신 시스템에서 Diffusion과 **결합**되어 사용 (예: 픽셀 공간이 아니라 **VAE로 압축한 잠재 공간**에서 Diffusion을 돌리는 구조 — Stable Diffusion이 정확히 이 방식). GAN도 **실시간성**이 중요한(반복 없이 한 번에 생성해야 하는) 응용에서는 여전히 사용 — “하나가 다른 셋을 완전히 대체했다”기보다, **각자 강점이 있는 도구로 함께**.

자주 묻는 질문: Diffusion 단계 수 · GAN 평가

Diffusion은 정말 T 번의 단계를 다 돌리나요?

원래 DDPM은 $T = 1000$ 인데, **DDIM**(2020)이 역방향 과정을 거의 **결정적으로** 만들어 **약 50단계**로 줄이고, 이후 **증류**(distillation) 계열 기법(**LCM**, **progressive distillation** 등)으로 **10단계 이하** 가능. 대가 = “완전한 DDPM에 비하면 품질이 조금 떨어짐”. “GAN보다 느리다”는 GAN 기준에서 **상대적** — 50단계 $\times$ 0.1초 $\approx$ 5초의 이미지 생성은 실제 응용에 **충분히 빠름**. (영상 생성처럼 샘플 수백 장을 만들어야 하는 분야에서는 이 차이가 더 중요.)

GAN은 ELBO 같은 “높을수록 좋은 단일 숫자”가 없는데, 학습 품질을 어떻게 평가?

GAN 계열은 단일 “우도” 숫자가 없어서 **샘플 기반** 지표가 따로 발전 — 대표적으로 **FID**(Fréchet Inception Distance): 실제 이미지와 생성 이미지를 InceptionNet 같은 **특징 추출기**로 변환한 뒤, 두 특징 분포의 **평균·공분산**(가우시안 근사) 사이의 **거리**. FID가 **작을수록** 생성 분포가 실제 분포에 **가깝**. VAE/GMM 계열은 “ELBO를 높인다”는 단일 숫자가 있어 비교가 쉬웠는데, GAN은 FID처럼 **외부 지표**가 필요 — 이(하나의 요인)가 이후 연구가 “**평가 가능한**” Diffusion 쪽으로 이동하는 데 일조.

연습문제 (코딩)

- 1. `em_step`과 `kl_divergence_gaussian`(정규분포 $\mathcal{N}(\mu, \sigma^2)$ 와 표준정규분포 사이의 KL divergence) 완성. 핵심 줄: $D_{KL} = -0.5 \cdot (1 + \log_var - \mu^2 - \exp(\log_var))$.
- 2. `discriminator_loss`와 `generator_loss` 완성 (위 15.2 절의 코드를 참고).
- 3. (개념) GMM에서 각 클러스터의 분산을 아주 작은 값으로 **고정**하고 학습하지 않으면 왜 **k-means와 같아지는지** 설명하고, VAE(우도 기반)와 GAN(적대적)의 **생성 품질·학습 안정성 트레이드오프**를 두세 문장으로 비교.
- 4. (손유도, Tier B) 데이터 3개 $x_1 = 1, x_2 = 9, x_3 = 10$, 2개 클러스터, 현재 파라미터 $\mu_1 = 0, \sigma_1 = 1, \mu_2 = 9, \sigma_2 = 1, \pi_1 = \pi_2 = 0.5$. x_1 에 대한 **책임값** $\gamma_{1,1}$ 과 $\gamma_{1,2}$ 를 손으로 계산 (힌트: 정규 밀도를 $x_1 = 1$ 에 대해 두 클러스터 각각 계산 후 대입. $\pi_1 = \pi_2$ 이므로 실제로는 π 가 **약분**되어 사라짐).
- 5. (손유도, Tier C — 풀백 준비 대상) $\log p_\theta(x) = \log \int p_\theta(x, z) dz$ 에서 시작해 엔센 부등식($\log \mathbb{E}[X] \geq \mathbb{E}[\log X]$)을 이용해 15.1절의 ELBO 부등식을 유도.

연습문제 5: ELBO 유도 빈칸 풀백

자유 유도가 어려운 경우 — 빈칸을 채워라:

$$\begin{aligned}\text{Step 1: } \log p(x) &= \log \text{integral}[q(z|x) * (p(x,z) / q(z|x)) dz] \\ &= \log E_q[\text{-----}]\end{aligned}$$

$$\begin{aligned}\text{Step 2: } \text{엔센부등식 (가log 오목함수) 적용:} \\ \log E_q[p(x,z)/q(z|x)] &\geq E_q[\log(\text{-----})]\end{aligned}$$

$$\begin{aligned}\text{Step 3: } p(x,z) &= p(x|z) * p(z) \text{로 분해하면:} \\ &= E_q[\log p(x|z)] + E_q[\text{-----}]\end{aligned}$$

$$\text{Step 4: } E_q[\log p(z) - \log q(z|x)] = -D_{KL}(q(z|x) || p(z)) \text{결론}$$

$$: \log p(x) \geq E_q[\log p(x|z)] - D_{KL}(q(z|x) || p(z)) \quad [\text{ELBO}]$$

정확성 확인

Step 2에서 **부등호가 등호가 아니라 부등식**인 이유를 한 문장으로 — (엔센 부등식이 **언제 등식**이 되는지: X 가 **상수**일 때).

이번 주차 정리

- 1 **15.1 VAE** — “EM의 E-step을 신경망이 맡는다”. ELBO = 복원 항 - KL 정규화 항 (엔센 부등식 한 번으로 유도). 갭 = $D_{KL}(q||p(z|x))$ - ELBO 최대화 = 변분 베イズ. μ^2 항이 인코더 위치를 원점 쪽으로, σ^2 항이 너비를 제어. **생성 모드**는 인코더를 **버리고** 디코더만 통과. β -VAE가 “복원 품질 vs 잠재 공간 매끄러움”을 튜닝. “흐릿함”의 원인 = **기대값 최적화**.
- 2 **15.2 GAN** — min-max 게임의 **내쉬 균형** ($D(x) = 0.5, p_G = p_{\text{data}}$). 1차원 장난감에서 $V(D^*, G) = 2 \text{ JSD} - \log 4$ 로 **달린 형태**. 성공 신호 = V 가 $-\log 4$ 근방에서 **안정**, $D^*(0) \rightarrow 0.5$. **모드 붕괴**의 원인 = 목적함수에 **다양성 항이 없음** (VAE에는 KL 항이 대응). WGAN/CycleGAN/StyleGAN/BigGAN = “**안정화**”가 3년의 주제.
- 3 **15.2 Diffusion + 비교** — 노이즈를 T 단계로 **쪼갠 MSE 회귀**(가장 보통의 최적화 → **안정**). 역방향에도 $+\sigma_t z$ (**다시 노이즈 추가**)가 필요. Stable Diffusion = **VAE 잠재 공간** × Diffusion. 세 원리: **잠재변수 · 학습 방법 · 안정성 · 생성 속도**로 비교 — 실전 시스템은 **조합**.

다음 주 — Chapter 16. Block B 캡스톤: 팀 프로젝트와 ML1 총정리

이번장에서 배운 **세 원리(VAE · GAN · Diffusion)**가 팀 프로젝트의 **모델 선택** 도구 상자로 등장 — **안정성 · 생성 속도 · 품질**의 기준으로 선택하고 **정당화**.