

Block B 캡스톤: 팀 프로젝트와 ML1 총정리

팀 프로젝트의 구조와 발표 · Peer-Review · ML1 총정리와 ML2로 가는 길

Machine Learning 1 · 16주차

한국과학영재학교 (KSA)

Chapter 16

이번 주차 개요

- **16.1 팀 프로젝트: 구조와 발표** — 4주 파이프라인(M1 M4)으로 Ch09 15의 도구를 실제 데이터에 적용. 핵심은 **“이 데이터에 딥러닝이 필요한가”**: 무작위·GBDT라는 두 층의 베이스라인을 모두 넘고, 데이터 구조·규모라는 두 축과 GBDT 비교·학습 곡선이라는 두 숫자로 반박 가능한 주장을 세운다.
- **16.2 Peer-Review** — 이번엔 네가 심사위원이다. 8.2 체크리스트에 “왜 딥러닝인가” 5번째 항목이 더해지고, 아키텍처-데이터 매칭과 선택 편향 $\mathbb{E}[\max]$ 부풀림을 정량화해 “test 0.95 vs 0.94는 잡음 수준”이라는 3점 질문을 쓴다.
- **16.3 ML1 총정리와 ML2로 가는 길** — 새 개념 없이 결실. 채점 합산(발표 50%/보고서 30%/리뷰 20%)과 “리뷰 한 통이 숫자를 바꾼” 사례, Ch02 15를 **4단계 구조**와 개념지도 위에 올리고, 정답 $y \rightarrow$ 보상 r 인 ML2를 “같은 구조, 다른 질문”으로 대비한다.

이 장 전체의 통과 기준

8.1의 마지막 문장: “같은 절차를 세 가지 언어(코드, 보고서, 리뷰)로 말할 수 있어야 이 프로젝트가 끝난 것이다.”

16.1 팀 프로젝트: 구조와 발표

왜 Block B의 시작에 또 프로젝트를 하는가

- Ch8.1(Block A 캡스톤)이 검증한 것: “Ch02 07의 도구가 실제 데이터 앞에서도 **작동하는가**”
— 정형 데이터 고전 ML의 완결
- 이번(Ch09 15의 도구)이 검증할 것: “신경망과 그 이후의 도구가, 이 데이터에 **정말 필요한가**”
- 모양은 같지만 무게가 다르다 — 전자는 “도구가 맞는가”, 후자는 “**도구가 필요한가**”를 묻는다
- 후자는 “**아예 안 쓰는 것(GBDT, Ch07)**과 비교해서” 물어야 성립한다

실전과의 연결

산업 현장 팀은 이미지·텍스트를 처음 만나면 “신경망을 돌려보자”가 아니라 “이 문제를 정형 문제로 치환해서 GBDT로 풀 수 있는가”부터 묻는다 — 정형 데이터에서는 지금도 GBDT 계열이 신경망과 비등하거나 이긴다. **“딥러닝을 써야 한다”는 대명제로 시작하는 팀은 이미 감점 상태.**

전체 그림: 4주 파이프라인

- 한 장으로: 데이터 → 파이프라인 → 평가 → 발표 (8.1과 같은 4박스, 박스에 쓴 장이 Ch09 15로 변경)
- 붉은 점선(평가→파이프라인)이 핵심: test에서 **누수**(Ch06.3)를 발견하거나, train/val 곡선이 **과적합의 모양**이면(Ch09.3, 10.2) **돌아가서 다시**
- 구조적 차이: “정형(Ch07 GBDT)으로 풀 것인가, 비정형 (Ch09 15 신경망)으로 풀 것인가” **분기**가 Box①과 Box② 사이에 들어옴
- 분기의 결과는 뒤의 모든 선택을 결정 ⇒ **M1(문제 정의)에서 이미 정해야 한다**

“한 번 지나가면 돌아올 수 없는 것”은 **test 한 번의 측정**뿐 — 그 외 모든 단계는 되돌아갈 수 있다.



파이프라인 한 장 — M1(정형이면 GBDT? 분기 포함)
→ 3분할·전처리·신경망 → test 한 번·수식적 정당화
→ 발표·리뷰

일정과 마일스톤 M1 M4

주	해야 할 일	마일스톤(제출)
1	데이터 후보 2 3개 조사, 정형/비정형 판정 , 팀 회의, 문제 정의 문서 (행·라벨·지표·베이스라인·“왜 DL” 초안)	M1 문제 정의 + 데이터 선택 + “왜 DL” 1페이지
2	3분할(Ch06.3) 스캐폴드, train으로만 fit한 전처리 , 1개 신경망 엔드투엔드 확인 , GBDT 베이스라인	M2 중간코드 리뷰 (코드 + 베이스라인 숫자 각 1줄)
3	나머지 기법 적용, val/CV(Ch06.2)로 튜닝, test 최종 측정(한 번만) , 학습 곡선	M3 학습 곡선 1장 + 최종 test 숫자 + GBDT 비교
4	수식적 정당화, 보고서·슬라이드, 발표(5 7분, 마지막에 “왜 DL”) , peer-review 2팀	M4 보고서 + 발표 + 리뷰 2건

- 4주(각 주 = 수업 3회). M1·M2는 개인별 선정 → 회의에서 팀 전체가 확정
- M2가 **베이스라인 숫자 한 줄**을 요구: 봐야 “신경망을 만들었다”고 말할 수 있는지 판정 가능
- M3가 **학습 곡선 한 장**을 요구: 최종 숫자만으론 에포크를 어떻게 정했는지 검증 불가 — val 곡선이 실제로 쓰였는지 그림에서 드러남. Block B의 x축은 **에포크**(8.1의 $n_{estimators}$ 와 다름)

프로젝트 구조

- **데이터** — Kaggle, UCI 외에 **Hugging Face Datasets**도 후보 (Ch11 13 시퀀스/LLM 프로젝트는 텍스트를 몇 줄로 불러옴)
- **적용** — Ch09 15 중 **최소 하나의 딥러닝 기법** (CNN, RNN/Transformer, 프롬프팅 응용, 또는 EM/VAE 계열 생성모델) 을 실제 데이터에 적용
- **필수: 수식적 정당화 최소 1개** — (1) CNN 구조면 Ch10.1 파라미터 수/연산량 공식으로 설계 정당화, (2) 정규화(dropout 등)면 Ch9.3 효과 설명, (3) 생성모델이면 Ch15 ELBO나 min-max 목적함수를 실제 구현에 연결
- **GBDT 비교(필수)** — 같은 데이터에 Ch7.3 GBDT(또는 랜덤포레스트)를 **베이스라인**으로 돌려, 신경망이 이보다 나은지 확인. 발표 “왜 DL” 근거의 출발점
- train/validation/test 분리(Ch06.3)를 8.1과 동일하게 준수

데이터 고르기 실전 가이드 — 기준 (6)

- Ch8.1의 5개 기준(행의 물리적 단위, 레이아웃 함정, 시계열, 클래스 비율, 크기)은 그대로 적용
- Block B에서만 추가 — **(6) “원시 특징”이 이미 정형으로 추출되어 있는가?** (정형/비정형 판정의 실전판)

경우	예	판정
(1) 수치·범주 열로만 구성된 표	매출표, 센서 로그(UCI 대부분)	정형 — GBDT와 비교해야 한다
(2) 픽셀·음파·토큰인 원시 배열	32×32×3 이미지, 오디오, 문장	비정형 — “손으로” 특징 만들기 어려우니 신경망이 특징 추출기
(3) 애매한 경우	이미 워드임베딩으로 벡터화된 텍스트	“원시 토큰으로 직접 모델링”을 선택해 Ch13 도구 필요성을 스스로 만드는 것도 합법 — 이유를 M1에 적어야 한다

후보 데이터셋 한 장

데이터셋	크기	정형/비정형	문제 정의	주의할 함정
sklearn digits (실습용)	1,797×64 (8×8)	정형(64-dim flatten)	숫자 → 0 9 분류	작아 신경 망이 GBDT 못 이기는 것이 정상 — § “왜 DL”의 교육 포인트
CIFAR-10 (HF)	60,000×32×32×3	비정형(원시 픽셀)	10개 물체 분류	레이블 불균형 없음. 중강 (회전·뒤집기, Ch10) 없이는 격차 큼
CIFAR-100 (HF)	60,000×32×32×3	비정형	100개 물체 분류	클래스 100개 — macro-F1 또는 top-1 + 베이스라인(무작위 1%) 명시
IMDb (HF)	50,000 문장	비정형(텍스트)	긍정/부정 감지	문장 길이 불균형 — Ch11 패딩/마스킹. BERT vs 단순 토큰화 비교
Toxic Comments (Kaggle)	159,576×6(라벨)	비정형(텍스트)	6개 독성 다중 라벨 분류	시그모이드 출력 + 라벨별 F1, 불균형 → 라벨별 PR-AUC
EMNIST (HF)	112,800×28×28	비정형(원시 픽셀)	글자 분류(62클래스)	784-dim 규모에서 CNN이 “8×8 flatten GBDT”보다 확실히 앞섬

기본 코스: 2단계

sklearn digits → **EMNIST** — digits에서 “정형(64-dim)으로 로는 GBDT와 대등하거나 못 이긴다”를 스스로 눈으로 확인한 뒤, 같은 문제를 28×28(784-dim)으로 확대하면 CNN의 우위가 드러남. “왜 DL” 질문에 **숫자로** 답하는 가장 깔끔한 경로.

두 층의 베이스라인: “무작위”와 “GBDT”

- ① **1층: 무작위(또는 다수 클래스)** — 모델이 아무것도 배운 상태의 **하한**. 10클래스 균형 데이터면 무작위 정확도 10%
- ② **2층: GBDT (Ch07.3)** — 정형 도구의 **상한** 에 가까운 기준. “신경망이 정형 도구보다 나은가”를 묻는 기준선
- ③ **본인 모델(신경망)** — 위 두 층을 **둘 다** 넘어야 “이 데이터에 딥러닝이 필요했다”고 말할 수 있다

모델 (digits, 8:1:1 stratify: val test macro-F1 1,437/180/180)			
다수 클래스(숫자 ‘1’, train 146개)	0.100	0.100	—
GBDT (200트리, 학습률 0.1)	0.983	0.944	0.944
작은 CNN (35,914 파라미터)	—	0.939	—

CNN은 GBDT(0.944)에 **비등~소폭 열세** — 이 3층 숫자가 “모델을 만들었다”는 주장을 단계별로 검증한다.

“예상대로 졌다”는 예상된 결과

- digits 같은 작은 정형 데이터에서는 신경망이 GBDT를 (소폭) 이기지 못하는 것이 예상되는 결과
- Grinsztajn, Oyallon & Varoquaux (2022), “Why do tree-based models still outperform deep learning on typical tabular data?": 저차원 정형 데이터에서는 GBDT가 신경망을 이긴다
- 신경망의 우위는 세 조건 중 하나에서 온다 — (a) 차원이 높은 데이터(텍스트를 원시 토큰으로 보면 $10^4 \sim 10^5$ 차원), (b) 데이터가 아주 큰 경우, (c) 특징이 공유되는 국소 구조(이미지)

이 프로젝트의 태도

digits는 64차원(저차원) $\Rightarrow$ GBDT가 앞서는 쪽이 예상이고, 실험은 정확히 그렇게 나온다 (64차원에서 GBDT 0.944 $\succ$ CNN 0.939, 격차 0.006). “왜 DL”의 정직한 답: “신경망이 좋다”가 아니라 “언제(어떤 차원·구조에서) 신경망이 좋은지”를 실증한다.

변수 하나만 바꾼다: $8 \times 8 \rightarrow 28 \times 28$

- 같은 digits 이미지를 8×8 에서 **28×28 (784차원)**으로 확대해 다시 GBDT vs CNN
- 64차원: GBDT가 **0.006** 앞서던 것이 $\Rightarrow$ 784차원: **CNN 0.961이 GBDT 0.944를 0.017로 역전**
- 격차 **0.006 $\rightarrow$ -0.017** — 닫히고 심지어 뒤집힘 = **축 2(규모)**의 증거
- 왜? 8×8 은 “이미지”여도 64개 수치로 flattening되어 **정형**이고, 28×28 (784개 픽셀)은 **국소 구조를 공유하는 원시 픽셀**에 가까워지는 순간 CNN의 **공유·평행불변 편향**이 일을 시작

이 실험까지 세운 팀의 “왜 DL” 답변

“64차원 정형에서는 GBDT 0.944가 상한이고 내 CNN(0.939)은 이를 어깨너머로 확인했으며, 같은 데이터를 784차원으로 확대하자 CNN이 오히려 0.961로 GBDT를 역전시켰다 — 내 문제가 차원·규모가 크다면 (EMNIST, CIFAR) CNN의 우위는 이 추세의 연장선이라는 것을 **숫자로** 보여준다.”

“왜 고전 ML이 아니라 딥러닝인가” — 2축 + 2숫자

(축 1) 데이터의 구조 — 정형인가,
원시(비정형)인가

- 정형(수치/범주 열) $\Rightarrow$ 기본 전제: “GBDT와 비교하라”
- 비정형(픽셀/음파/토큰) $\Rightarrow$ “신경망이 특징 추출기”라는 주장이 성립할 가능성이 생김

(축 2) 데이터의 규모 — 특징이 공유되는가,
크기만큼 비용이 오르는가

- Ch10.1 파라미터 수 공식이 “왜 CNN”을 수학적으로 설명

(숫자 1) GBDT 베이스라인 — “신경망이 정형 상한을 넘는가”

(숫자 2) 학습 곡선의 train/val 격차 —
신경망이 데이터가 커질수록 val 곡선이 계속 상승한다면 (GBDT는 일찍 포화), “규모가 커지면 DL에 유리하다”는 **전망**까지 제시 가능

네 가지를 보고서와 발표에 담으면

“왜 딥러닝인가”는 막연한 의문이 아니라 **반박 가능한 주장**이 된다 — 16.2의 peer-review가 이 주장을 심사하는 기준이기도 하다.

역사적 일화로 축을 붙잡자: AlexNet

- 2011년까지 이미지 분류의 최선은 사람이 손으로 만든 특징(HOG, SIFT) + 선형 분류자/GBDT
- 2012년 **AlexNet**(Krizhevsky, Sutskever & Hinton, 2012): **ImageNet**(128만 이미지)에서 오차율을 기존보다 **절대 10%p 가까이 줄여** 경쟁을 사실상 종료

이 전회의 본질

“신경망이 마법”이 아니라 — ① 데이터(ImageNet)가 갑자기 충분히 커지고 ② GPU가 학습을 가능하게 한 순간. **축 2(규모)가 축 1(비정형)을 결정지운** 대표 사례.

- 반대로, “정형 표 데이터”에서는 2020년대에도 **GBDT가 최선에 가까움**(Grinsztajn et al., 2022)
- 두 사례를 나란히 두면, “왜 DL”의 답이 **데이터의 구조와 규모**에서 나와야 하는 이유가 직관적으로 보인다

손으로 한 번: CNN의 파라미터 수

실습 노트북의 구조(Ch10.1 공식으로 계산):

$$1 \times 8 \times 8 \xrightarrow{\text{Conv2d}(1, 32, 3, \text{pad}=1, \text{str}=2)} 32 \times 4 \times 4 \xrightarrow{\text{MaxPool2d}(2)} 32 \times 2 \times 2$$
$$\xrightarrow{\text{Flatten}} 128 \xrightarrow{\text{FC}} 256 \xrightarrow{\text{ReLU}} 256 \xrightarrow{\text{FC}} 10$$

층	공식	파라미터 수
Conv2d(1→32, 3×3)	$1 \times 3 \times 3 \times 32 + 32$	320
MaxPool2d(2)	(파라미터 없음)	0
FC 128→256	$128 \times 256 + 256$	33,024
FC 256→10	$256 \times 10 + 10$	2,570
합계		35,914

conv: $\text{in_ch} \times k \times k \times \text{out_ch} + \text{out_ch}$, FC: $\text{in} \times \text{out} + \text{out}$
(Ch10.1)

```
import torch
n = sum(p.numel()
        for p in model.parameters())
print(n)      # 35,914
```

PyTorch로 돌려 **정확히 일치(35,914)** 확인 —
“10.1 공식으로 설계 정당화” 요구사항의 뼈대가
라이브러리 없이도 성립하는 것.

이 숫자의 의미는 비교해야 보인다

- 같은 8×8 을 **flatten(64-dim)**해서 $64 \rightarrow 64 \rightarrow 10$ 단순 MLP면 파라미터 **4,810**개뿐 — conv 층(320)보다 작다
- 즉, 작은 데이터에서는 “깊게/넓게”가 아니라 **입력 차원(flatten)이 작으면 GBDT**(특수한 파라미터가 아예 없음)가 효율적이다
- “왜 CNN”의 진짜 이유 = **해상도 S 가 커질 때**

해상도 S	“flatten $\rightarrow$ 256” FC ($S^2 \times 256$)	3×3 conv($1 \rightarrow 32$)	비율
8	16,384	320	$51 \times$
32	262,144	320	$819 \times$
64	1,048,576	320	$3,277 \times$
224	12,845,056	320	$40,141 \times$

“상수 vs 제곱”

flatten은 해상도 **제곱**(S^2)으로 폭증하지만, conv는 해상도와 무관하게 **320으로 일정** — 이 차이가 “이미지가 커질수록 CNN(파라미터 공유, 평행불변)이 필수”를 **수학적으로** 말한다. 이 표 한 장이 발표용 **수식적 정당화**로 그대로 쓰인다.

발표: 마지막 1분을 “왜 DL”에 전념

- 형식은 8.1과 동일(문제 정의 → 방법론 → 결과와 정당화 → 한계 분석, 팀당 5 7분)
- **시간 배분을 고정:** 문제 정의(1분) → 데이터와 정형/비정형 판정(1분) → 적용한 기법과 구조(2분) → 결과 + GBDT 비교·수식적 정당화(2분) → **“왜 DL인가”(1분)**

그 1분에 채울 것

§ “왜 고전 ML이 아니라”의 **2축 + 2숫자**. “정형인데도 신경망”이라면 GBDT와의 **숫자 비교 필수**.

- 8.1처럼 “**잘 안 된 부분**”을 정직하게 말하는 습관 유지 — 학습이 안 된 부분을 **Ch09**(역전파/그래디언트)·**9.3**(정규화)·**10.2**(과적합)의 개념으로 진단하는 것이 “방법론을 실제로 이해했는가”의 증거
- 8.1이 “어떤 고전 ML 모델이 이 데이터에 **맞는가**”를 물었다면, 이번엔 “**애초에** 딥러닝이 필요한 문제인가” 부터 스스로 판단


학습 곡선: Block B에서 x축이 “에포크”인 이유

- 8.1: $x\text{축} = n_estimators$ — GBDT는 모델을 크게 만드는 파라미터가 트리 수이므로 x축이 곧 **용량**
- Block B: 신경망은 **구조(층 수·너비)로 용량을 고정**하고, **학습량(에포크)을 바꿔** train/val 곡선 을 그리는 것이 표준
- 구조를 바꾸면 모델 **자신이 달라지므로**(트리 수 만큼 “같은 모델의 크기”가 아님) **에포크를 x축** 으로

GBDT ($n_estimators$)	train	val
20	0.988	0.944
50	1.000	0.961
200	1.000	0.983

train은 50트리에서 **1.0 포화**.

val 꺾임이 에포크를 정한다 (6.3절)



왼쪽: GBDT 곡선 / 오른쪽: CNN 에포크 곡선 — val 손실은 꺾임
포인트 이후 상승

6.3절의 원칙이 그대로

“train은 배운 것을, val만 재는 것을 한다”.
에포크를 늘리면 train 손실은 0으로
가지만 val 손실은 어느 에포크 이후
오름(과적합, Ch09.3).

이 val **꺾임 포인트**가 에포크·학습률·정규화
강도를 정하는 근거. M3의 “학습 곡선 1장”은
이 꺾임을 보여야 한다.

보고서 구조 (M4) — 6절

8.1의 6절 구조를 그대로 쓰되, **2절과 5절이 Block B용으로 바뀜.**

- ① **문제 정의**(0.5p) — 행의 물리적 단위, 라벨, 주 지표, 두 층의 베이스라인(무작위·GBDT) + 정형/비정형 판정과 그 근거(축 1)
- ② **데이터와 전처리**(1p) — 원본 통계, **train**으로만 **fit**한 전처리 명시(이미지 0 1 스케일, 텍스트 토크나이저/패딩), 분할 비율 + stratify/패딩 여부
- ③ **모델 선택과 이유**(1 2p) — 적용한 딥러닝 기법 ≥ 1 개와 그 구조(층·크기)를 Ch10.1 공식으로 정당화 (§ “손으로 한 번”) + **왜 GBDT가 아니라** 이 기법인가(축 2)
- ④ **결과**(1p) — 최종 test 숫자(한 번), **에포크 학습 곡선 1장**, **GBDT·무작위와의 비교 표**
- ⑤ **수식적 정당화**(1p) — **필수 1개**(10.1 파라미터 / 9.3 정규화 / 15 ELBO) — § “손으로 한 번”의 표를 그대로
- ⑥ **잘 안 된 부분과 원인 진단**(0.5p) — **필수**. 학습이 안 된/과적합된 부분을 Ch09·09.3·10.2의 개념으로 진단 — 8.1의 “**모두 잘 됐다**” 경고가 그대로 적용

채점 기준 (rubric)

항목	비중	좋은 답
문제 정의와 데이터	15%	행·라벨·지표· 두 층 베이스라인 이 명확하고, 정형/비정형 판정이 데이터 특성에 근거함
방법론 적절성	25%	GBDT와 비교해서 “왜 이 딥러닝 기법”의 근거가 Ch07·Ch10의 개념(차원·구조·공유)으로 설명됨
검증의 정직성	25%	3분할·train-fit· test 한 번 · 베이스라인· 에포크 학습 곡선 ·val 튜닝이 보고서에서 추적 가능
수식적 정당화	20%	Ch09 15 공식(10.1 파라미터, 9.3 정규화, 15 ELBO 중 ≥ 1 개)으로 “왜”를 설명했고, 관측(숫자) 과 일치
결과의 정직성과 반성	15%	GBDT보다 못 한 부분·학습이 안 된 부분을 숨기지 않고 Ch09 15의 개념으로 진단

8.1과의 차이

“방법론 적절성”이 “이 데이터에 맞는 고전 ML 모델인가”에서 “**딥러닝이 필요한가, 그리고 그 중 왜 이 기법인가**”로 확장 — 성공의 기준이 “신경망을 돌렸는가”가 아니라 “필요했는지를 **GBDT와 비교해 판정했는가**”이므로 25%. 성능이 GBDT보다 0.5%p 낮아도 “64차원 정형이므로 GBDT가 상한 이고, EMNIST(784차원)로 확대해 검증했다”는 논리까지 세우면 높은 점수.

자주 하는 실수 (5가지)

- **GBDT 베이스라인 없이 “신경망 정확도 0.95” 발표** — 두 층의 2층이 빠짐 (Ch07.3 “정형이면 GBDT와 비교” 위반). 리뷰 질문: “같은 데이터에 GBDT를 돌리면 몇 %인가요? 0.95가 상대로 얼마나 좋은지?”
- **“신경망이 최신이라서”라는 이유** — 2축 + 2숫자가 **전부** 빠져 있음. “최신”은 근거가 아님 (2022 Grinsztajn et al.: 정형에서는 GBDT가 여전히 경쟁적)
- **에포크를 test로 정하기** — “test 정확도가 더 높아지는 에포크까지 돌렸다” = Ch06.3 test-한-번 원칙 위반. 에포크·학습률·구조는 **val 곡선만**으로
- **flatten해서 GBDT에 비등한 것을 “신경망이 졌다”로 결론** — digits(64-dim) 비등은 예상된 결과. “64차원 정형”과 “28×28 원시 픽셀”을 구분하지 않고 단순 결론내는 것 — **차원/구조의 효과를 분리해 논의**
- **증강 없이 “val 과적합”만 보고 dropout만 올리기** — 과적합이 데이터 부족(증강)인지 모델 과대 (dropout/L2)인지 먼저 구분 — Ch09.3의 **다른 처방**

실습: “왜 DL”의 숫자를 코드로 검증하기

실습 노트북(sklearn digits만으로, CPU에서도)에서 이 절의 핵심 주장 — “정형·저차원에서는 GBDT가 상한이고, CNN의 우위는 구조 (공유)와 규모에서 온다” — 를 한 흐름으로 검증:

- 1 문제 정의 — digits($1,797 \times 64$), 0-9 분류, 주 지표 정확도
- 2 3분할 — 1,437/180/180, stratify
- 3 두 층 베이스라인 — 다수 클래스(‘1’) val/test 0.100
- 4 GBDT 베이스라인 — 200트리: val 0.983 / test 0.944 / macro-F1 0.944
- 5 CNN 파라미터 공식 — § “손으로 한 번”의 표를 코드로 재계산, torch와 정확히 일치(35,914) 확인
- 6 GBDT vs CNN (64차원) — 작은 CNN test 0.939, GBDT(0.944)에 소폭 열세(0.006) — “예상된 결과” 확인
- 7 $8 \times 8 \rightarrow 28 \times 28$ 확대 — 같은 digits를 784차원으로: GBDT 0.944 vs CNN **0.961** — 0.006 열세가 **0.017로 역전**(축 2의 증거)
- 8 해상도 vs 파라미터 — flatten FC(S^2)와 conv(상수) 표 생성
- 9 학습 곡선 — GBDT $n_estimators$ 곡선(train 50트리 1.0 포화) + CNN 에포크 곡선(train $\rightarrow 0$, val은 그 뒤로 꺾임)
- 10 선택 편향 — “에포크·구조 후보를 test로 골랐다면”의 $\mathbb{E}[\max]$ 부풀림(8.1과 동일, Ch06.3)

이 흐름이 보고서 6절로, 다시 16.2의 체크리스트 (“왜 DL” 추가 항목 포함)로 매핑 — 세 가지 언어(코드, 보고서, 리뷰)로 같은 절차를 말할 수 있어야 끝.

확인 문제 1 2

1. CIFAR-10(60,000개 32×32) CNN으로 test 0.82를 내고 “신경망이 GBDT보다 좋다”고 결론낸 팀 — 이 결론이 성립하려면 **먼저 확인해야 할 숫자 하나**와 이유?

답

같은 **flatten($3 \times 32 \times 32 = 3,072$ -dim)** 데이터에 GBDT를 돌려 얻은 **test 정확도**. “좋다”는 것은 GBDT보다 상대적으로 좋은지를 보여줘야 성립(2층 베이스라인). CIFAR 32×32 를 flatten하면 3,072차원(64차원 digits보다 훨씬 고차원)이라 GBDT가 CNN에 육박할 수도 있음 — 그 비교 없이는 “신경망이 좋다”는 1층(무작위)만 이긴 것에 그칠 수 있다.

2. Ch10.1 공식으로, 입력 $3 \times 32 \times 32$ 에 Conv2d(3, 64, 3, padding=1) 한 층의 파라미터 수를 계산하고, “flatten FC와 달리 해상도와 무관하다”는 것을 $S=32$ 에서 flatten($\rightarrow 256$)과 비교해 보여라.

답

conv: $3 \times 3 \times 3 \times 64 + 64 = 1,792$ (해상도 32와 무관). flatten FC($3,072 \rightarrow 256$):
 $3,072 \times 256 + 256 = 786,688$ — conv의 **약 439배**. 해상도 64가 되면 FC는 $12,288 \times 256$ 으로 4배가 되는데 conv는 그대로 1,792 — **상수 vs 제곱**이 “커질수록 CNN”의 근거.

확인 문제 3 4

3. train 손실 0.01, val 손실 0.40인 에포크까지 “**test가 더 좋아질 때까지** 돌렸다”고 보고 — Ch09.3 과적합 과 Ch06.3 test-한-번 원칙을 들어 깨진 원칙 **두 가지**와 올바른 방법?

답

(1) train/val 격차 0.39 = **과적합**(Ch09.3) — train이 0으로 가는데 val이 오르는 구간. (2) “test가 좋아질 때까지” = **test를 튜닝에 쓰는 선택 편향**(Ch06.3) — test는 한 번만. 올바르게: **val 손실의 최솟값(또는 plateau) 에포크**를 정한 뒤, 그 에포크로 **test를 딱 한 번**.

4. “우리 팀은 정형 표 데이터(5,000행×12열)인데 LLM을 fine-tune했다” — 2축(구조·규모)과 Grinsztajn et al. 2022 결과를 근거로 **반박 가능한 질문 하나**.

답

축 1(구조)이 정형이고 축 2(규모)도 12열로 작아 GBDT가 **경쟁적/우위인 영역**(2022). 질문: “12열·5,000행 정형에서 LLM fine-tune의 test 성능이 같은 데이터의 GBDT(Ch07.3)와 비교해서 절대적으로 얼마나 더 좋나요? 그 차이가 “특징의 국소 공유” 같은 구조적 이득이 아니라 단순히 용량 때문이라면, 정형이므로 GBDT가 상한인데 왜 LLM을 선택했 나요?” — “최신이라서”로 답할 수 없는, Ch07(GBDT)를 근거로 둔 질문.

자주 묻는 질문

- **Q. 정형 데이터에 굳이 신경망을 써도 되나요?** 된다 — 다만 정형에서는 지금도 GBDT 계열이 경쟁적인 경우가 흔함. 선택했다면 “왜 GBDT보다 이 문제에 더 적합하다고 판단했는지” (복잡한 상호작용 자동 학습, 다른 DL 모듈과 결합 계획 등)를 발표에서 설명할 수 있어야 — “최신이라서”는 근거가 아님. GBDT 비교 숫자가 그 증거가 되어야 한다.
- **Q. Ch09 15 중 여러 기법을 동시에 써도 되나요?** 권장 — 예: CNN으로 이미지 특징 추출 → 어텐션으로 조합. “왜 이 조합인가”의 추가 설계 근거 기회. 단, **수식적 정당화 1개**는 그중 하나의 기법만 충족하면 됨.
- **Q. GPU가 없는데 CNN을 돌릴 수 있나요?** 되다 — 기본 코스(digits 8×8 , EMNIST 28×28 , CIFAR 32×32)는 Colab 무료 CPU/T4로도 4주 안에 충분. 작은 CNN(35,914)은 CPU에서 수 분 만에 수렴. 대규모 (ResNet, BERT full fine-tune)가 필요하면 HF **pretrained** 모델 transfer + 마지막 층만 학습 — 정당화는 “왜 이 pretrained 구조인가”(Ch13 사전학습)로 변경.
- **Q. “왜 DL” 질문에 GBDT가 이기면(신경망이 못 이기면) 점수가 떨어지나요?** 떨어지지 않음 — 오히려 **정직한 결과**. 64차원 정형에서 GBDT와 비등은 예상 이며, “그래서 내 문제는 차원이 더 큰(784-dim) EMNIST여야 CNN 우위를 검증할 수 있다”로 연결하면 **높은** 점수. 감점은 GBDT를 돌려놓고도 “신경망 0.94”만 보고 단순 결론내는 경우.

16.2 Peer-Review

왜 이번 주가 “역전”의 주인가

- 16.1에서 각 팀은 발표팀으로서 프로젝트를 5 7분에 설명. 이번엔 역할이 역전 — 이번에는 네가 심사위원이다
- 다른 두 팀의 발표를 듣고 Ch8.2 체크리스트로 리뷰 를 쓰고, 그 리뷰의 품질로 네가 채점받음
- “반박 가능한 질문이 좋은 리뷰인가”(Popper, Amgen, Begley & Ellis 2012)는 8.2 재독으로 충분 — 이번 절은 그 위에 두 가지 추가

추가 ① 심사 대상이 달라졌다

8.2: 고전 ML 발표 → 이번: CNN, RNN/Transformer, VAE 계열 딥러닝 발표. “모델 선택이 데이터에 맞는가” 를 판단하는 데 더 많은 개념이 필요 — 비정형인지, 그 비정형성에 맞는 아키텍처인지, “정형인데 왜 신경망인가”.

추가 ② “정확도의 함정”이 새로운 얼굴로

신경망은 더 많고 복잡한 하이퍼파라미터(Ch9.3 학습률 스케줄, 드롭아웃률, 배치크기) + 학습이 에폭이라는 시간 차원을 가짐. 그래서 “에폭 300인데 val 곡선은 언제 꺾였나” 같은 Block B 전용 질문이 쏟아진다 — 이번 절의 대부분.

이번 주 진행과 체크리스트 — 5개 항목

순서	내용	시간	항목	확인할 것
1	다른 두 팀 발표 청취(각 57분, 16.1 형식 — “왜 DL” 질문 포함)	50분 중 30분	문제 정의	무엇을 예측/분류하려 했는지 명확 한가
2	체크리스트 기반 작성 리뷰 두 통 — 팀당 5개 항목 + 반박 질문 1개 이상	발표 직후	방법론 적절성	데이터 특성(비정형·불균형·시퀀스)에 맞는 아키텍처 를 골랐는가
3	질의·토론: 질문을 발표팀이 그 자리에서 답변, 교수가 양쪽 리뷰 품질을 함께 채점	나머지 시간	수식적 정당화	16.1 요구사항(최소 1개)을 충족 하고 실제로 타당 한가
			결과의 정직성	잘 안 된 부분을 숨기지 않고 원인을 분석했는가
			“왜 DL인가”	16.1 필수 질문에 구체적 근거로 답했는가

8.2와 동일 + 1

4개 항목은 Ch8.2와 동일하되 **5번째(“왜 고전 ML이 아니라 딥러닝인가”의 타당성)**가 추가. 토론에서 발표팀이 “**좋은 지적입니다**”로 넘긴 질문 = 그 리뷰가 **2점에 머물렀다**는 증거(8.2 FAQ와 동일한 논리) — **구체적 근거**(비정형성, Ch07 GBDT 비교)로 답했는지 가 **좋은 리뷰의 출발점**.

“왜 딥러닝인가”를 어떻게 채점하는가

이 질문을 형식적으로만 채우는 것과 내용적으로 채우는 것의 차이 = 8.2의 “**1점 vs 3점**” 구별과 정확히 같은 구조.

형식(2점)

- “왜 고전 ML이 아니라 딥러닝인가”에 **답변이 있었는지** 확인만
- “팀이 ‘데이터가 이미지라서’라고 답했다”로 끝나는 리뷰


내용(3점)

- 그 답변이 **이 학기의 개념으로 반박 가능한 근거** 인가까지 따짐
- 예: “이미지 데이터에 CNN을 썼는데, CNN의 **국소 receptive field + 파라미터 공유**가 이 데이터의 어떤 구조(Ch10.1)에 맞는지 설명할 수 있나요?”
- 발표팀이 **Ch10.1 공식이나 자기 코드에 다시 들어가야** 답할 수 있는 질문

판별 기준은 8.2 그대로: 발표팀이 “네, 알겠습니다”로 넘길 수 있으면 2점, 새 계산·새 확인이 없으면 답할 수 없으면 3점.

채점 기준: “채웠는가”가 아니라 “구체적인가”

- 8.2의 3단계(감상평 / 일반 지적 / 반박 가능한 질문)가 그대로 적용
- Block A에서 3점 리뷰의 “근거가 되는 개념”은 Ch02 07 범위였는데, Block B에서는 **아키텍처-데이터 매칭**이 가장 높은 확률로 3점짜리 질문을 만들어내는 영역



“왜 DL인가” 판단 나무 — 비정형인가로 분기 → 구조-편향 일치 여부 → 3점 질문

- 읽는 법: “**방법론 적절성**”을 채울 때 **왼쪽에서 오른쪽으로 한 번만** 따라가면 됨
- 비정형?** 예 → **데이터 구조와 편향이 일치?**
 - 일치**(이미지→CNN, 시퀀스→Transformer) ⇒ 3점: “이 구조를 아키텍처의 어떤 부분이 이용하나?”
 - 불일치**(이미지인데 완전연결) ⇒ 3점: “Ch10.1 파라미터 공식으로 왜 이 설계?”
- 오(정형)** → GBDT·로지스틱회귀와 **val**에서 비교했는가? 아니오 ⇒ “GBDT를 val에서 돌려봤나요?”
- 예/아니오가 **정해지지 않는 발표** ⇒ **그 자체를 질문으로**

리뷰를 더 깊게: 데이터 구조 ↔ 편향

- Block A: “모델을 어떻게 고르셨나요?”는 “kNN의 k 를 5로 한 이유는?”에 머물렀지만, Block B에서는 같은 질문이 **아래처럼 깊어짐**

(1) 데이터 구조 ↔ 아키텍처의 귀납적 편향

CNN의 국소 **receptive field** + **파라미터 공유**는 “이미지의 인접 픽셀이 서로 **상관 있다**는 인과적 가정”을 코드 속에 심어 넣는 것 (Ch10.1).

- 이 가정이 데이터에 **맞아야** CNN은 GBDT보다 유리해지고(Ch07.3 비교), **안 맞으면** (예: “셀 하나 = 이미지 파일”인 경우) 그 가정은 **아무 가치**를 주지 못함
- **리뷰 질문 예**: “여러분의 이미지에서 위치가 실제로 정보인가요 — 이미지를 무작위로 **회전·이동** 시켰을 때 val 정확도가 얼마나 변하나요?” — 발표팀이 **새 실험**(증강 효과를 측정하는 run)을 해야 답할 수 있으므로 8.2 기준으로 **3점**

8.2의 질문 등급 기준은 그대로: “새 실험이 필요 한 질문” = 3점, “말 몇 마디로 넘길 질문” = 2점.

에폭과 교정: Block B의 두 시간 축

(2) 학습의 시간 차원 — 에폭

- 고전 ML은 `fit()` **한 번**으로 끝나지만, 신경망은 에폭을 돌리는 **과정**이 모델의 일부
- 8.1 M3(하이퍼파라미터는 **val 곡선**으로만)가 신경망에서는 **에폭 수를 정하는 것까지 포함**
- “에폭 300을 돌렸다”는 **전제**(val 곡선이 300 부근에서 포화)를 만족할 때만 성립
- **질문 예**: “에폭 300인데 val 곡선은 언제 정점? 정점 이후 100개 에폭이 val에서 무엇을 바꿨나요?” — 답하려면 **학습 곡선(M3)**을 다시 꺼내 봐야 함

(3) 확률의 신뢰도 — 교정(calibration)

- “정확도 95%”를 넘겨도 “**0.99 확률로** 예측한 건 중 **99%가 정말 맞았는가**”는 **별개의 질문**
- 교차엔트로피가 낮아도 확률 **스케일 전체가 왜곡**된 모델(0.99를 말해도 실제로 0.87)은 “**위험도 기반 결정**”(의료, 사기)에서 정확도 결정과 **완전히 다른 결정**
- Block A(로지스틱회귀)는 교정이 구조적으로 좋아 잘 안 나왔지만, **신경망+드롭아웃은 드롭아웃 ON 상태에서 확률을 뽑으면 교정이 악화**(Guo et al., 2017)
- “**드롭아웃 off로 확률을 뽑았나요?**” = 합리적인 3점 질문

자주 하는 실수: “정확도가 높으니 좋은 모델”

- 딥러닝에서 특히 잦은 부실한 리뷰: “**test 정확도 95%라 정말 잘 만들었다**” — 숫자 하나만으로 판단
- 그 정확도가 Ch06.3 원칙(train/val/test 분리, **누수 방지**)을 지키고 나온 숫자인지, 불균형이면 Ch2.3 **PR-AUC**를 함께 확인했는지를 먼저 따지는 것이 건설적
- 예: “**검증셋·테스트셋을 나눈 기준을 설명해 주시겠어요?**” — 다시 확인해봐야 답할 수 있는 질문

Block B에서 특히 위험한 이유

“좋은 정확도”가 **우연일 가능성**이 Block A보다 **훨씬 높음**. Ch6.3 선택 편향 — 후보 m 개 중 $\max$ 를 고르면 $\mathbb{E}[\max]$ 만큼 **부풀어 오름** — m 이 클수록 커진다.

후보 공간(Block B)

$\sigma = 0.02$ 일 때 부풀림(8.1 표)

모델 2 3개 $\times$ (에폭 $\times$ 드롭아웃 $\times$ 학습률) 10 30개 $\Rightarrow m =$ **0.045~0.052** 부근
30 ~ 90

“**test 정확도 0.95**”가 실제로 0.90대 초반일 수 있다 — 8.2의 “**0.1%p가 잡음 수준**” 논리가 그대로 적용되되, Block B에서는 그 잡음이 더 크고, 후보가 더 많다.

실습 노트북이 정량화하는 “잡음의 두 기원”

- 실습 노트북(§ 4)이 이 잡음의 두 기원을 동시에 정량화:
- ① **표본 잡음**: 같은 모델의 test 100건만 바뀌도 정확도 범위 약 0.06
- ② **선택 편향**: 후보 m 개 중 최고를 고르는 $\mathbb{E}[\max]$ 가 약 0.04~0.05

리뷰어의 한 줄 판정

모델 간 정확도 차이가 이 두 숫자보다 작다면, 그 차이는 모델이 아니라 표본·선택에서 나온 것이다.

- 이 프레임이 16.2 실습의 “3점 질문 감각”을 만든다 — 발표를 들으며 “이 숫자가 나오면 3점 질문을 쓸 수 있다”는 기준이 생김
- § “자주 하는 실수”의 $\mathbb{E}[\max]$ 계산($m \approx 30, \sigma = 0.02$)과 서로 일치 — 후보가 30 90개면 1%p 차이는 원리적으로 잡음 범위

손으로 한 번: 가상의 딥러닝 발표

8.2의 “가상 발표”와 동일한 구조로 Block B 발표 하나를 놓고 체크리스트를 적용.

발표 요약

“우리 팀은 breast_cancer 데이터(569건 × 30 특성, 악성 63% : 양성 37%)로 악성 여부 분류 모델을 만들었다. 30차원 특징을 **64개 히든 뉴런의 1층 신경망**에 입력하고, **dropout 0.5**를 넣어서 **50에폭** 학습했다. **test 정확도 0.95**가 나왔다 — 로지스틱회귀(0.94)와 GBDT(0.94)보다 높다. 이미지/텍스트는 아니지만, 신경망이 특징의 **복잡한 상호작용을 자동으로 학습**할 수 있어서 고른 것이다.”

- 체크리스트 5개 항목을 하나씩 적용한다 (다음 프레임)
- 이 발표의 함정: **정형 표 데이터**에 신경망, 비교 대상과 **1%p 차이**, 수식적 정당화 “숫자만”

체크리스트 적용: 5개 항목을 하나씩

항목	적용
문제 정의 방법론 적절성	명확 — 이진 분류, 행=환자, 라벨=악성/양성 여기가 핵심. breast_cancer는 정형 표 데이터. 발표팀의 답변(“복잡한 상호작용 자동 학습”)은 16.1 FAQ가 명시적으로 허용한 근거 중 하나 — 형식상 통과 하나, FAQ가 요구한 “ Ch07 GBDT와 비교했을 때 ”를 정량적으로 충족했는가? “GBDT 0.94 vs 신경망 0.95”는 정확도로 1%p 차이이고, 선택 편향 계산(m 이 크면 부풀림 ≈ 0.05)에 비하면 잡음보다 작은 차이 — “신경망이 GBDT보다 좋다”는 결론은 이 발표만으로 성립하지 않음
수식적 정당화	“64개 히든 뉴런”이라는 숫자만 있고, Ch09.1 파라미터 수 공식 ($30 \times 64 + 64 + 64 \times 2 + 2 = 2114$ 개) 또는 Ch10.1 CNN 설계 공식으로 왜 64인가를 설명한 흔적이 없음 — 형식상 “구조를 정의했다”는 것이지 “ 정당화 한 것”이 아님
결과의 정직성 “왜 딥러닝인가”	“잘 안 된 부분”이 발표에 없음 — 8.1 보고서 구조 § 6이 필수로 요구하는 절 답변은 있었으나(위 방법론 항목) 정량적 근거(GBDT와 val에서의 비교 표) 가 없음

같은 발표에서: 3점 vs 2점

반박 가능한 질문 예시 (3점, “방법론 적절성”)

“breast_cancer는 정형 데이터인데, Ch7.3에서 배운 GBDT와 같은 **val 분할**에서 **F1**로 비교한 표를 보여줄 수 있나요? 발표의 0.95 vs 0.94 차이는 Ch6.3의 **선택 편향** (후보 m 개 중 max를 고르는 부풀림)과 같은 크기인지 — 즉, 이 1%p 차이가 “신경망이 더 좋다”는 결론을 뒷받침할 만큼 큰 근거인지 — **정량적으로** 알려주세요.”

8.2의 3점 기준으로 **관찰**(정확도만 비교) + **개념**(Ch06.3 선택 편향, Ch07.3 GBDT) + **왜 문제인지**(1%p는 잡음 범위)가 모두 들어 있다.

같은 발표에서 2점짜리로 떨어지는 버전

“정형 데이터에 신경망을 쓴 이유가 잘 모르겠네요, GBDT랑 비교해 보셨으면 좋겠어요.” — **관찰은 있지만 개념**(어떤 장의 어떤 원리)**이 없고**, 발표팀이 “네, 알겠습니다”로 넘길 수 있다. 8.2의 3단 채점 기준표의 **2점에** 정확히 해당.

딥러닝 발표에서 자주 발견되는 3점 질문 6가지 (1/2)

실제 Block B에서 반복되는 6가지 패턴 — 각 패턴이 **어떤 개념에 뿌리**를 박는지 함께. 발표를 들으며 체크리스트에 적어 넣기 쉽게.

발표팀의 흔한 말	반박 가능한 질문(3점)	근거 개념
1. “test 정확도 95%를 달성했다”	“베이스라인(다수 클래스) 정확도는 얼마였나요? Ch02.3의 정확도 함정 기준으로, 이 95%가 “무조건 다수로 찍는” 모델과 얼마나 다른지 F1·PR-AUC 로 보여주세요.”	Ch02.3 정확도의 함정, Ch08.1 베이스라인
2. “에폭 300으로 학습했다”	“ val 곡선이 언제 정점 에 도달했나요? Ch08.1 M3의 “하이퍼파라미터(에폭 포함)는 val 곡선으로만 정한다” 기준으로, 정점 이후에 돌린 에폭이 val에서 무엇을 바꾸었나요 — 학습 곡선을 다시 보여주세요.”	Ch08.1 M3 학습 곡선, Ch09.3 과적합
3. “dropout 0.5를 넣었다”	“dropout를 0.0/0.3/0.5/0.7을 val로 스위치 한 결과가 있나요? Ch09.3의 정규화 효과 기준으로, 이 0.5가 val 곡선으로 정한 값인지, 아니면 그냥 0.5를 쓴 것인지?”	Ch09.3 정규화/드롭아웃

딥러닝 발표에서 자주 발견되는 3점 질문 6가지 (2/2)

발표팀의 흔한 말	반박 가능한 질문(3점)	근거 개념
4. “CNN을 썼다”(이미지)	“이 이미지에서 위치가 실제로 정보인가요 — 무작위 회전·이동 (데이터 증강) 을 하면 val 정확도가 얼마나 변하나요? Ch10.1의 국소 편향 이 이 데이터에서 실제로 작동하는 증거가 되나요?”	Ch10.1 CNN의 국소 구조
5. “정형 데이터인데 신경망을 썼다”	“Ch07.3의 GBDT를 같은 val 분할 에서 F1 로 비교했나요? Ch06.3의 선택 편향 기준으로, 두 모델의 차이는 잡음보다 큰 근거인가?”	Ch07.3 GBDT, Ch06.3
6. “RNN/Transformer로 시퀀스를 처리했다”	“시퀀스를 시간순으로 3분할(Ch06.3)했나요? 무작위 분할 이면 같은 시퀀스의 앞뒤가 train/test에 섞여 누수 가 됩니다 — 분할 방법을 코드로 보여주세요.”	Ch06.3 시계열/그룹 분할, Ch11 RNN

이 표의 쓰임

“Block A의 8.2 체크리스트에 **Block B의 개념**을 넣은 버전” — 8.2의 **사기 탐지 예**(Ch02.3)가 여기 **#1로 그대로** 살아 있고, **#2~#6이 Block B에서 새로 등장**하는 패턴. 리뷰를 쓸 때 이 표를 한 번 보고, 발표에서 실제로 나온 것에 해당하는 행의 “근거 개념” 칸을 리뷰 템플릿의 6번 빈칸에 옮기면 된다.

리뷰 템플릿 — 8.2 + “왜 DL”

팀이름

: _____ 리뷰어 : _____


1. 문제정의—무엇을예측분류하려 / 했는지한문장으로 . 명확한가?
2. 방법론적절성—데이터구조비정형 (? 정형? 시퀀스? 불균형?)에어떤아키텍처가맞았는가
? 그선택에동의하는가 , 근거와함께 .
3. 수식적정당화—의 16.1 최소” 개를1” 채웠는가? Ch09의~15 어떤개념을썼고실제로타당한가
?
4. 결과의정직성—잘안된부분과그원인을 Ch09의~15 개념으로분석했는가
?
5. 왜” 딥러닝인가” 답변의타당성—데이터가비정형인가 ?예→그비정형성의구조와
** 아키텍처의귀납적편향이일치하는가 ?아니오→
GBDT로지스틱회귀와/ 에서val 정량비교했는가 ?
6. 반박가능한질문필수 (, 개1 이상) —근거개념
: Chapter __ 절 __ 개념(: _____)질문
: _____ 발표팀이(답이* 나쁘면* 결과가흔들리는것이어야함)

6번의 “근거 개념”+“질문” 두 칸이 비어 있으면 1 2점에 머문다. 이번 주엔 **5번의 분기(비정형/정형)를 실제로 채우려**
가는 것 — “비정형인가”의 판단 자체를 리뷰어가 내리는 것.

실습: 가상 발표를 코드로 검증하기

8.2 실습(“99.8%” 검증)과 같은 구조로 가상 발표(“MLP로 0.95”)를 코드로 검증 — 노트북이 순서대로 보여줌:

- 1 세 모델 + 베이스라인을 같은 test 분할에서 정확도·F1·PR-AUC·AUC·log-loss로 비교 — “0.95 vs 0.94”가 실제로 얼마나 큰 차이인지
- 2 MLP 학습 곡선 — 에폭 단위로 그려 “에폭 50 이 적당한가”를 val 포화 지점으로 확인
- 3 표본 잡음 실험 — 같은 모델·가중치로 test 100건을 60번 하위샘플링, 모델 간 차이가 표본 선택에 의존하는지
- 4 교정 체크 — “0.90+ 확률로 예측한 건”이 실제로 얼마나 맞는지를 계수로 — 정확도 0.95가 신뢰할 수 있는 확률인지 분리



노트북의 핵심 숫자 세 가지를 미리 짚으면, “이 숫자가 나오면 3점 질문을 쓸 수 있다”는 감각이 생긴다. (다음 프레임)

val 정확도 25 30 부근 포화, 그 뒤 train 손실만
계속 하락

핵심 숫자 ①·②: 표본 잡음과 학습 곡선

① 정확도 차이는 표본 잡음보다 작다

- 세 모델 test: logreg **0.959**, MLP **0.953**, GBDT **0.942** — **max-min 0.018**
- 같은 모델·가중치로 test 100건을 60번 바꾸면 **0.930~0.990**(범위 **0.06**)
- 모델 간 차이(0.018)는 표본 흔들림(0.06)의 **1/3** — “MLP 1위”는 **표본 선택**에 의존

② 학습 곡선이 에폭 수를 정한다

- val은 에폭 **25~32 포화**, 그 뒤에도 **train 손실만** 하락 → 과적합 신호
- “에폭 50”이 **포화(≈ 30)** 근거라면 3점 통과, 시간 제약 숫자라면 “30에서 멈췄을 때 val이 다른가” 증명 — **8.1 M3의 이유**

핵심 숫자 ③: 교정은 정확도와 별개

③ 교정은 정확도와 별개

- “**0.90+ 확률**로 예측한 샘플” 100건의 실제 악성 비율 = **0.980** — 대략은 맞지만 **확률 스케일 전체**가 맞다는 증거는 아님
- **정확도 0.953**(분류)과 **0.98**(확률 신뢰도)는 **두 개의 다른 숫자** — “이 모델의 **확률**을 위험도 결정에 쓸 수 있는가”가 의미를 갖는 이유

이 실험이 § “손으로 한 번”의 비판을 검증

“**test 0.95 vs 0.94는 잡음 수준**”이라는 리뷰어의 말이 이 실험에서 **실제로 일어나는 일**이라 반박 가능 — 세 숫자(①·②·③)가 가상 발표 비판의 근거.

확인 문제 1 2

1. breast_cancer(569×30)에 MLP로 test 0.95, “로지스틱회귀(0.94)보다 높으니 MLP가 더 좋은 모델이다” — Ch06.3 선택 편향과 Ch07.3 GBDT 비교를 근거로 **반박 가능한 질문 하나**.

답

“GBDT(Ch07.3)를 **같은 val 분할**에서 **F1**로 비교했나요? 0.95 vs 0.94의 1%p 차이는 Ch06.3 선택 편향 부풀림(후보 m 개 중 max, $m \approx 30$ 일 때 ≈ 0.04) 보다 **작거나 같은 크기**일 수 있습니다 — 이 차이가 결론을 뒷받침할 만큼 큰 근거인지 val F1과 함께 **정량적으로** 보여주세요.”

2. “CNN을 100에폭 학습했다” — val 정확도가 **에폭 40에서 정점(0.93)**에 도달한 뒤 **0.92** 까지 내려옴.
“100에폭” 결론의 **한계와 질문?**

답

val 곡선이 에폭 40에서 **꺾였으므로**, 100에폭 중 60개 는 val을 떨어뜨린 과적합 구간(Ch09.3 신호). “100에폭” 주장이 성립하려면 “왜 val이 더 나빠졌는지”를 Ch09.3 개념(정규화·dropout 부족? 학습률?)으로 **설명**해야 함. 질문: “val 정점(40) 이후 60개 에폭이 val을 0.93→0.92로 내려보냈는데, 이 하락을 진단해줄 수 있나요? 에폭 40에서 멈췄다면 0.93이었을 텐데, 왜 0.92를 발표 수치로 쓰셨나요?”

확인 문제 3 4

3. “텍스트에 RNN” — 시퀀스를 무작위로 70/15/15 분할. Ch06.3의 어떤 원칙이 깨졌고, 왜 test가 낙관적인가?

답

“시계열/시퀀스는 시간순(또는 그룹 단위)으로 나뉘야 한다”. 무작위 분할이면 같은 시퀀스 앞뒤가 train/test에 섞여 RNN이 학습한 문맥의 잔해를 보고 “예측” — 그룹 단위 누수. test가 “새 시퀀스에 잘 일반화하는 가”가 아니라 “같은 시퀀스의 나머지를 얼마나 외웠는가”를 재게 되어 낙관적.

4. “데이터가 이미지라서 CNN을 썼다”가 형식 (2점)에 머무는 이유, 3점으로 바꾸는 법?

답

“이미지라서 CNN”은 Ch10.1의 왜를 설명하지 않음 — 국소 receptive field + 파라미터 공유가 어떤 구조적 특성(인접 픽셀 상관)에 맞는지 말해야 “구조-편향 매칭”이 성립. 3점: “위치가 실제로 정보인가요 — 무작위 회전·이동 시키면 val이 얼마나 변하나요?”

확인 문제 5

5. “dropout 0.5를 넣었더니 val F1 0.88→0.91” — 이 설명이 타당한 조건?

답

“정규화했으니까 올랐다”(나쁜 설명)로는 안 되고, **train/val 격차가 줄었는지**를 함께 보여줘야 — “train F1 0.99/val 0.88 → 0.5 넣자 0.95/0.91로 **격차가 줄었다**”고 말해야 Ch09.3 “정규화가 분산을 줄인다”가 관측과 일치. 격차가 안 줄고 val만 올랐다면 그 0.03은 **잡음 범위**일 수 있음을 스스로 인정.

자주 묻는 질문

- **Q. Ch8의 peer-review와 뭐가 다른가요?** 체크리스트 **빠대**(문제 정의, 방법론, 수식적 정당화, 결과의 정직성)는 동일. “방법론 적절성”을 판단하는 기준 이 **늘어난다** — Ch8은 “이 데이터에 맞는 고전 ML 모델을 골랐는가”만 물었는데, 이번엔 “고전 ML이 아니라 딥러닝이 정말 필요했는가”까지 함께 판단.
- **Q. 정형 데이터에 DL을 쓴 팀에게 “GBDT로 다시 돌려라”는 질문이 가혹하지 않나요? 가혹하지 않음** — 16.1 FAQ가 발표팀에게 “GBDT와 비교했을 때의 근거를 설명하라”고 요구했으므로, 리뷰어가 “그 비교가 실제로 있는지”를 묻는 것은 **16.1 요구사항을 집행하는 것**에 불과. 비교 결과가 GBDT가 이기더라도(정형에서는 흔함, Ch07.3) 발표가 “실패”하는 것은 아님 — “GBDT가 이기긴 했지만, 다른 DL 모듈(예: Ch12 어텐션)과 **결합** 할 계획이 있어 신경망을 고랐다”도 충분한 근거. 리뷰어가 판정할 것은 “**비교를 했는가, 근거가 개념에 뿌리를 박는가**”이지 “비교에서 신경망이 이겼는가”가 아님.
- **Q. 학습 곡선이 val도 계속 상승 중(정점 도달 전) 이면 어떻게 리뷰하나요?** “**에폭 N 이 정점이 아니다**”를 지적 — val이 N 에서 여전히 상승 중이면 “ N 이 최적”이 아니라 “ N 이 관찰된 범위 내 **최선**”일 뿐, “ $2N$ 까지 돌리면 더 좋아질 것”이 성립할 수 있음. 질문: “에폭 $2N$ 까지 돌린 val 곡선을 보여줄 수 있나요?” — **새 실험이 필요하므로 3점**.
- **Q. 이미지인데 GBDT만 쓴 팀(= DL을 안 쓴 팀)은 어떻게 채점하나요?** 16.1 “적용” 요구사항 (Ch09 15 중 **최소 하나의 DL 기법**)을 **미충족** — “왜 DL인가” 항목은 “**해당 없음(요구사항 미충족)**”으로 채점하고 사유를 리뷰에 명시. “왜 DL을 안 썼는가”를 리뷰어가 판단하는 것이 아니라, **요구사항 충족 여부**가 이 항목의 범위.
- **Q. Block B의 프로젝트는 Block A보다 규모가 크면 안 되나요 — 같은 수준이면 되나요? 같은 수준이면 된다** — 요구사항(DL 기법 최소 1개 + 수식적 정당화 최소 1개)이 Block A와 구조적으로 동일. 유일한 차이: “**딥러닝 특유의 하이퍼파라미터(에폭, dropout, 학습률 스케줄)를 val 곡선으로 정했는가**”를 추가로 확인(위 § (2)(3)).

16.3 ML1 총정리와 ML2로 가는 길

이번 주 전체 그림: 캡스톤, 50분으로

- Ch16은 Block B 캡스톤 — 세 수업 블록: 16.1 기말 발표 → 16.2 peer-review → 이번 16.3
- 이번 블록에서: (1) **프로젝트 채점의 결실**, (2) **peer-review 절차의 결실**, (3) **ML1 전체 총정리와 ML2로 가는 다리**
- 다른 두 블록과 성격이 **다름** — **새 개념이 하나도 없다**. ML1의 14개 장은 이미 손에 있고, 할 일은 “세 가지 언어(코드, 보고서, 리뷰)로 말할 수 있는가”를 확인하는 것 (8.1의 마지막 문장)

순서	내용	시간
1	프로젝트 채점 결실 — 발표·보고서·리뷰의 합산 과, “ 리뷰가 숫자를 바꾼 ” 실제 사례 하나	약 15분
2	Peer-Review 결실 — 3단 기준 (8.2)에 딥러닝 특화 모범 리뷰 2통 을 적용	약 15분
3	ML1 개념지도 — Ch02 15를 한 장의 그림 에 두고, 복습 문제 7개 점검	약 15분
4	ML2로 가는 길 — 같은 구조, 다른 질문	약 5분

ML1 총정리: 한 학기를 14장으로

선형/로지스틱회귀의 경사하강법에서 시작해, 생성적 분류(나이브 베이즈/GDA), 거리·마진 기반(kNN, SVM), 트리 앙상블(GBDT), 신경망(역전파, CNN), 시퀀스·어텐션·LLM, 비지도학습(PCA, 임베딩), 잠재변수 생성모델(EM/GMM, VAE, GAN, Diffusion)까지.

장	배운 것	핵심 질문
Ch02	선형·로지스틱회귀	연속값과 확률을 어떻게 예측하는가
Ch03	나이브베이즈/GDA	데이터가 어떻게 생성됐는지부터 거꾸로 분류할 수 있는가
Ch04	kNN/k-means/GMM·EM	“가깝다”만으로 예측·군집화, 그 한계는
Ch05	SVM	확률이 아니라 마진 으로 경계를 정할 수 있는가
Ch06	정규화/모델선택	과적합 을 손실함수로 어떻게 통제하는가
Ch07	트리/RF/GBDT/SHAP	잘 나누는 질문을 어떻게 고르고, 어떻게 설명 하는가
Ch09	신경망/역전파/학습기법	층을 어떻게 학습시키고, 깊은 망은 왜 어려운가
Ch10	CNN 기초와 응용	이미지의 국소 구조 를 어떻게 효율적으로 다루고 재사용하는가
Ch11	시퀀스 모델	순서 가 있는 데이터를 어떻게 기억·처리하는가
Ch12	어텐션/트랜스포머	순차 처리 없이 모든 단어의 관계를 한 번에 계산
Ch13	그래프 표현학습	Random Walk/Node2Vec/PageRank — 그래프를 어떻게 벡터 로 바꾸는가
Ch14	PCA/word2vec/임베딩	정답 없이 구조를 찾고, 벡터를 실전에 어떻게 쓰는가
Ch15	VAE/GAN/Diffusion	잠재변수 로부터 어떻게 새 데이터를 만드는가
Ch17(부록)	LLM: 사전학습/프롬프팅/정렬	다음 토큰 예측이 폭넓은 능력이 되고, 사람 뜻에 맞게 다듬기

공통 흐름: 4단계 구조

거의 모든 장에서 반복되는 구조

모델을 정의하고 → 틀린 정도를 손실함수로 수치화 하고 → 그 손실을 줄이는 방향으로 파라미터를 조정

- 이 반복은 “교재를 통일감 있게 보이게 하려는” 우 연이 아니다 — 16.1 발표의 마지막 필수 질문이 “무엇을 데이터로 갖고 있고, 무엇을 맞히고 싶은가”인 이유
- 모델은 선택이지만, 이 4단계 구조는 의무 — GDA든 100층 트랜스포머든 “모델 정의 → 틀린 정도 수치화 → 파라미터 조정”을 거치지 않는 모델은 없다

새 문제를 만났을 때

시작할 생각은 “어느 장의 도구를 쓸 것인가”가 아니라 **“이 문제는 4단계 중 어디에 걸리는가”** — 데이터가 표인가, 이미지인가, 토큰인가? 정답(y)이 있는가? 틀린 정도를 무엇으로 재는가?

Block A vs Block B — 4단계로 나란히

단계	Block A (Ch02 07)	Block B (Ch09 15)
① 모델을 정의	선형 $w^T x + b$, 결정 트리 (Ch02, 07)	겹친 층의 네트워크, GAN은 두 개의 네트워크 (Ch09, 15)
② 손실	MSE, 교차엔트로피, 힌지 (Ch02, 05)	ELBO, min-max (Ch15.2, 15.3)
③ θ 조정	경사하강·정규방정식 (Ch02), EM (Ch15.1)	역전파 (Ch09), 적대적 학습 (Ch15.3)
④ 과적합 통제	λ 정규화, 교차검증 (Ch06)	dropout, early stopping (Ch09.3)

특별히 짚을 행: GAN (Ch15.3)

②③이 “손실 하나, 방향 하나”가 아니라 **생성과 판별자가 동시에 최소화/최대화하는 게임**. ③을 “경사를 내리막”이 아니라 “**두 플레이어의 균형**(내쉬 균형, $D = 0.5$)”으로 바꿔둔 것이, ML2에서 **보상이 손실보다 더 큰 도약**인 이유의 선구(§ ML2의 로드맵).

프로젝트 채점: 세 산출물의 합산

기말 프로젝트 점수 = **발표**(16.1, 57분) + **보고서**(58페이지) + **peer 리뷰**(16.2, 2건).

구성	비중	보는 것
발표	50%	16.1 채점 기준 5항목 — 특히 “ 결과의 정직성과 반성 ”(마지막 1분)
보고서	30%	발표의 주장이 코드로 재현 가능한가 — 8.1 보고서 구조 6절
Peer 리뷰(2건)	20%	네가 쓴 질문의 품질 — 8.2의 3단 기준(감상평/일반 지적/반박 기 질문)

“남의 프로젝트 리뷰”가 왜 자기 점수에 들어가는가

8.2에서 이미 답을 봄 — **좋은 리뷰는 발표팀의 결과를 단단하게** 만들고, 그 행위는 **Amgen**(Begley & Ellis, 2012)이 스스로 논문 53편을 재현해 본 것과 같은 **과학적 행위**. “리뷰를 잘 쓴 사람” = 이 학기의 절차를 **가장 깊게 이해한** 사람 — 채점이 그것을 반영.

결실 사례: “숫자를 바꾼 리뷰”

발표

“흉부 X-광 CNN, test 정확도 **94%**. **증강 6가지 변형**을 시도해 **가장 좋은 것을 골랐다**.”

- 리뷰어의 **3점 질문**: “6개 변형 중 **test**로 고른 것은 Ch06.3 **선택 편향** — 후보 6개면 $\mathbb{E}[\max] \approx 0.025$ **부풀림**. val은 몇 %인가?”

팀이 다시 확인해 보면 — 다른 원인이 드러난다

같은 환자의 여러 X-광이 train과 test에 **동시에** 들어 있었다(그룹 누수, 6.3). 환자 단위로 다시 나누자 test 정확도 **94% → 88%로 떨어짐** — “94%” 발표가 리뷰 한 통으로 “**88%, 그 이유까지**”라는 더 좋은 발표로.

반대의 경고

리뷰 후 “다시 확인”할 때 사람은 원래 **결론을 더 쉽게 다시 찾게 된다**(자기에게 유리한 편향) ⇒ 보고서에 **리뷰 답변을 별책으로 첨부** — “무엇을 다시 확인했는지”가 기록이 되어 확인이 **정말로** 일어났는지(숫자가 실제로 바뀌었는지) 추적 가능.

Peer-Review 결실: 3단 기준을 마지막에

- 리뷰 2건의 체크리스트 = 8.2와 동일 + 16.2 추가 항목 (“왜 고전 ML이 아니라 딥러닝인가”).
3단 기준 (1점 감상평 / 2점 일반 지적 / 3점 반박 가능한 질문)도 그대로 — 바뀌는 것은 **재료**

예시 1 — 선택 편향 질문

발표: “흥부 X-광에 CNN, 폐렴 분류. 증강 **6가지 변형** 중 가장 좋은 것을 골랐고, test **94%**.”

단계	리뷰
1점(감상평)	“증강 학습을 활용하셨군요. 결과가 인상적으로 보입니다.”
2점(일반 지적)	“증강 6가지를 어떻게 고르셨는지 기준 이 부족해 보입니다.”
3점(반박 가능)	“6개 변형 중 test 성능으로 고른 것은 Ch06.3의 선택 편향 (개념) — 후보 6개이면 정확도가 $\mathbb{E}[\max] \approx 0.025$ 부풀려질 수 있음(왜). val과 test 격차를 보여주세요 — 격차가 0.025 미만이면 부풀림 크기보다 작아 “test로 고르지 않았다”는 근거가 됨(구체적 산출물).”

Peer-Review 결실: 예시 2와 3점의 형태

예시 2 — “왜 딥러닝인가” 질문 (16.2 추가 항목)

발표: “고객 이탈 예측(**정형 테이블 데이터**)에 **Transformer** 적용, test 81%. 최신 아키텍처라 기대가 컸다.”

단계	리뷰
1점(감상평)	“최신 모델을 적용하셨네요. 81%는 좋은 결과입니다.”
2점(일반 지적)	“정형 데이터에 Transformer를 쓴 근거가 약해 보입니다.”
3점(반박 가능)	“정형 데이터에서 GBDT(Ch07.3) 는 신경망과 동일하거나 높은 성능이 흔합니다 — 같은 데이터의 GBDT val F1은 얼마인가요 (관찰 요구)? Transformer가 여기서 주는 구체적 구조적 장점 (규모, 상호작용 패턴)이 무엇이고 , 그 장점이 숫자 어디에 보입니까(개념)? 새 계산 없이 답할 수 없다면 “딥러닝이 필요했다”는 결론이 성립하지 않습니다.”

두 예시의 3점 질문은 같은 형태

관찰(발표에서 본 것) + **개념**(장 번호) + **왜 문제인지** + **구체적 산출물 요구** — 네 칸이 모두 채워져야 “좋은 지적입니다”로 넘길 수 없는 질문(8.2 FAQ).

이 학기 동안: 발표자 2회(8.1, 16.1), 리뷰어 2회(8.2, 16.2). 8.2의 “**반증 가능성(falsifiability)**” 이 이제 낯선 단어가 아니라면 — **이 절차는 끝난 것이다**.

ML1 개념지도



Ch02 15 개념지도 — 4개 박스 + 색 두 줄

- 4개 박스: ① 데이터·문제 정의(행의 단위/정답 유무/형태) → ② 모델(10가지 도구) → ③ 학습(4단계 구조) → ④ 평가(3분할·train fit / val에서만 / test 딱 한 번)
- 붉은 점선: ④에서 ①로 돌아감 (과적합·누수면 다시) — “되돌아갈 수 없는 것은 **test 한 번**뿐”
- 금색 점선: ③에서 ML2로 나감 — 정답 y 가 보상 r 로, 데이터가 에이전트의 경험으로

쓰기는 단순: Ch02 15의 모델을 하나 골라 ①②③④에 놓아본다

GMM: ③에서 “EM이 관측 데이터의 **우도**를 최대화하는 방향으로 θ 조정”. **VAE:** ②에서 “**ELBO**가 우도의 **하한**”(exact MLE는 어려우므로). **GAN:** ③에서 “**min-max — 게임**” — 세 개를 **전부** 놓을 수 있으면, 이 학기는 정말 끝난 것이다.

복습 문제 1 2: 장을 넘나드는 연결

1. Ch03의 **GDA**와 Ch15의 **GMM**은 둘 다 “정규분포를 가정한 생성적 모델” — 가장 핵심적인 차이?

답

GDA는 클래스 라벨 y 가 **관측되는**(지도) 상황에서 각 클래스의 분포를 추정하지만, GMM은 클러스터 소속(z)이 **관측되지 않는**(비지도) 상황에서 **EM**으로 그 **잠재변수까지 함께** 추정해야 한다.

2. Ch07의 **트리**와 Ch10의 **CNN**은 둘 다 “국소적인 정보를 활용하는 귀납적 편향” — 각각 어떤 방식으로 구현?

답

트리는 한 번에 특징 하나씩만 보고 분기해서 **저차원적 규칙을 조합**하고, CNN은 작은 필터가 이미지의 **국소 영역만** 보고 그 필터를 전체 이미지에 **재사용**(파라미터 공유) — 형태는 다르지만 “**전체를 한 번에 보지 않고 지역적으로 나눠서 본다**” 는 방향은 같다.

복습 문제 3 4: 같은 해법의 재발견, 같은 연산

3. Ch09의 **그래디언트 소실**이 Ch11(**RNN**) 과 Ch10(**ResNet**)에서 각각 어떤 해법으로 재등장?

답

ResNet은 **스킵 연결**($y = F(x) + x$)로 그래디언트가 “+1” 항을 통해 그대로 전달될 경로를 만들고, **LSTM/GRU**(Ch11.3)도 **게이트**를 통해 정보가 **곱셈 대신 덧셈**으로 흐르는 경로를 만들 — 서로 다른 구조(이미지 vs 시퀀스)에서 **같은 해법**(곱 승 사슬에 덧셈 지름길을 낸다)이 독립적으로 재발견된 것.

4. Ch12의 **어텐션**과 Ch15의 **VAE**은 둘 다 “가중합”을 핵심으로 — 각각 무엇의 가중합?

답

어텐션은 **softmax**로 정규화된 **관련도**(가중치)로 각 단어의 **Value 벡터**들의 가중합 — “관련 있는 정보를 섞은” 새 벡터. VAE의 **ELBO**는 (가중합은 아니지만) “복원 항”과 “KL 정규화 항”이라는 서로 다른 두 목표의 균형을 하나의 손실로 합친다는 점에서, “여러 신호를 하나로 종합한다”는 더 넓은 패턴을 공유.

복습 문제 5 6: 절차 자체가 개념

5. “하이퍼파라미터 조합 8개를 시도해 가장 좋은 것을 보고했다. test F1 **0.97**.” Ch06.3 선택 편향 으로 **부풀림 크기**를 추정하고, 반박 가능한 질문 하나.

답

후보 8개는 8.1 표에서 5개(≈ 0.023)와 50개(≈ 0.045) 사이의 ≈ 0.03 부풀림 — “0.97”이 실제로는 **0.94** 부근일 수 있음. 질문: “8개 조합 중 **val F1**로 고른 것과 **test F1**로 고른 것의 차이는 얼마인가요? val-test 격차가 0.02 미만 이면 그 격차는 선택 편향 크기보다 **작아** — test로 고르지 않았다는 근거가 없습니다.”

6. 실습 § 8에서 “**누수된 test**”의 정확도 **1.000**, 실제 test **0.947**(차이 **+0.053**) — 모델과 하이퍼파라미터를 **하나도 바꾸지 않고** 이 차이가 가능한가? 리뷰어는 무엇을 물어보는가?

답

가능 — **분할 방식** 하나가 바뀌면 됨. train에 이미 있는 **같은 단위**(환자/행)를 test에 넣는 그룹 누수(Ch06.3). 리뷰 질문은 **판단이 아니라 기계적 점검**: “train과 test에 **같은 환자가 동시에** 들어갔나요? GroupKFold로 재분할하면 test F1이 어떻게 변하나요?” — **분할 코드 한 줄**을 보면 즉시 판정.

복습 문제 7: “최신이라서”의 등급

7. 16.1 필수 질문 “왜 고전 ML이 아니라 딥러닝인가” 에 “**딥러닝이 최신이라서**”라고 답하는 팀을 8.2의 **3단 기준**으로 평가하고, 그 답을 **3점 질문**으로 바꿀 수 있는 질문을 쓰자.

답

“최신이라서”는 관찰도 개념도 없는 추상적 평가어로서 1 2점에 머물.

3점 질문 예: “같은 데이터에 GBDT(Ch07.3)를 돌리면 **val F1은 얼마인가요?** 그 네트워크가 주는 구체적 구조적 장점이 숫자 어디에 보 입니까?” — 새 계산 없이 답할 수 없으므로 반박 가능.

이 3문항(5 7)이 묻는 것


위 4문항(개념끼리의 연결)과 달리, 아래 3문항은 “**프로젝트 절차 자체가 개념**”임을 묻는다 — 16.1의 발표와 16.2의 리뷰에서 **바로 쓰는 판단력**.

실습: 검증 절차를 한 흐름으로

기말 프로젝트의 **절차 전체**를 breast_cancer(569건 × 30 특성)로 한 흐름에 실행 —
채점·리뷰·총정리가 “감”이 아니라 **숫자**에 뿌리박는지 확인:

- 1 **문제 정의** — 행=환자, 라벨=악성(1)/양성(0), 주 지표 **F1**(양성 비율 62.7%라 정확도보다 F1)
- 2 **3분할** — 341/114/114(stratify, seed 0)
- 3 **5개 모델 후보**(Ch02/04/07.1/07.2/07.3)를 **val F1로만** 순위 — logreg 0.993 > kNN 0.979 > RF 0.957 > GBDT 0.950 > tree 0.944 (기말은 Ch09 15 DL 기법을 요구하지만 **절차는 모델 종류와 무관** — Block A 모델로 시연)
- 4 **베이스라인** — 다수 클래스(악성) val F1 **0.768**. 1위와 격차 **+0.225** = “모델을 만들었다”는 증거
- 5 **test 딱 한 번** — val 1위(logreg)로 test acc 0.974, **F1 0.979**
- 6 **선택 편향** — 50개 후보 중 test 최고를 고르면 $\mathbb{E}[\max] \approx 0.045$ 부풀림
- 7 **val 순위 vs test 순위** — 이 데이터에서는 **일치**. 그러나 그것은 **우연이지 보장이 아님**
- 8 **누수 시연** — (a) 스케일러를 **전체 데이터**로 fit해도, 잘 섞인 깨끗한 데이터에서는 val F1이 **동일**(0.979 = 0.979) — “**보이지 않는 누수**”. (b) train의 같은 행 50건을 “test”로 넣으면 정확도 0.947 → **1.000(+0.053)** — **모델·하이퍼파라미터 불변, 분할 방식만**

val F1 vs test F1 — 우연이지 보장이 아니다



이 데이터에서 val/test 격차는 **작다**. 하지만 “작다”는 것은 **보장이 아니라 이 데이터의 운** — § 6의 $\mathbb{E}[\max]$ 가 그 격차가 뒤집힐 수 있는 폭을 정한다.

5개 모델의 val F1(파랑, 순위에 사용)과 test F1(남, 딱 한 번) — 붉은 점선은 다수 클래스 베이스라인(0.768)

§ 8(a)가 이 절에서 가장 오래 남을 숫자

누수의 위험성은 “해로움”이 증명될 수 없어서가 아니라 **보이지 않아서** — 깨끗한 데이터에서 정규화 통계를 **전체**로 fit하면 **어떤 신호도 없음**(val F1 0.979 = 0.979). (b)처럼 **보일 때도**(+0.053), 그것 역시 “**알고 보러**” 갔을 때 만 보임 $\Rightarrow$ 복습 6번의 리뷰 질문이 “판단”이 아니라 **기계적 점검**(“같은 환자가 train과 test에 동시에 들어갔나요?”) — 깨끗한 데이터에서는 누수가 숫자에 드러나지 않으므로, **절차(불합 코드)가 유일한 방어선**

ML2로 가기 전에

- ML1 = “정답이 있는 데이터로부터 배운다” — 지도학습·비지도학습의 세계
- ML2는 완전히 다른 질문에서 출발 — 정답 대신 보상만 주어지고, 데이터가 미리 있는 게 아니라 에이전트가 스스로 행동하며 만들어지는 강화학습의 세계
- 무대는 텍스트나 이미지가 아니라, 물리 법칙이 지배하는 로봇 시뮬레이션 환경(Sutton & Barto, 2018)

“ML1을 안 듣고 ML2를 바로 들어도 되나요?”

무방 — ML2 1주차가 이번 학기에 필요한 신경 망 기초를 압축해서 다시 짚어줌. 다만 Ch09(역전 파)와 Ch06(정규화, 특히 교차검증)의 감각이 남아 있다면 ML2를 훨씬 수월하게 따라갈 수 있음.

ML2의 로드맵: 같은 구조, 다른 질문 (1/2)

- “강화학습”이라는 말 자체가 **1984년 Richard Sutton의 박사논문**(Temporal Credit Assignment in Reinforcement Learning)에서 **처음 사용** — 학문적 조상은 **B.F. Skinner의 조작적 조건화**(행동주의, 1950년대)
- “보상만 보고, 틀렸다는 신호 없이 배우는 문제”를 학문화한 것이 Sutton의 질문 $\Rightarrow$ ML2가 “ML1의 반대”가 아니라 **ML1의 질문에서 정답 y 를 빼면 남는 문제** — 그 명칭의 연원에서도 읽힘

ML2 장	내용	ML1에서의 대응
Ch01	코스 소개, 신경망 미니 리뷰, Gymnasium 세팅	Ch09(역전파)의 감각 확인
Ch02	멀티암 밴딧	“보상만”의 가장 간단한 문제 — 탐색/활용 트레이드오프
Ch03	MDP 정식화	“데이터가 어떻게 만들어지 는가”(Ch03) — 데이터는 에이전트가 스스로 만든다
Ch04 07	동적계획법, 몬테카를로, TD, 적격흔적	Ch15(EM)의 “ 추정 ” — 정답 없이 값 함수 를 반복적 으로 추정
Ch08	Block A 캡스톤	이 장과 동일한 구조 (발표 + 리뷰 + 총정리)

ML2의 로드맵: 같은 구조, 다른 질문 (2/2)

ML2 장	내용	ML1에서의 대응
Ch09 11 Ch12 Ch13 15 Ch16	함수근사, DQN , 정책기반, PPO 모방학습 , 인간 피드백(RLHF) 로봇 시뮬레이션 , MuJoCo/Isaac, 모델기반 RL Block B 캡스톤과 학기 총정리	Ch09(역전파) + Ch06(과적합 통제)를 제어 문제 에 Ch03의 생성적 모델, Ch13의 정렬 을 RL로 Ch10 11의 구조를 물리 무대 위로 이 장과 동일한 구조

ML1 (정답 y 가 있음)

데이터셋(미리 주어져 있음)
라벨 y (모든 행에)
손실(틀린 정도)
일반화 = **test set** 성능
과적합 = **train**만 잘 맞음 (Ch06)

train/val/test 분리 (Ch06.3)

ML2 (보상 r 만)

경험(에이전트 의 자기 궤적 — 배우는 동안 만들어짐)
보상 r (보상만, 그것도 늦게와서)
리턴(누적 보상)
일반화 = **다음 환경**(실제 로봇)에서 잘하는가
과적합 = **시뮬레이터**에만 잘 맞음 (Ch14 **시물-실재 격차**)
탐색/활용 트레이드 오프 (Ch02) — “데이터를 만들 권리”가 대상

같은 구조, 다른 질문 — 한 학기가 남기는 선물

4단계는 그대로 살아 있다

① 모델 정의 → ② 손실 → ③ θ 조정 → ④ 통제는 ML2에서도 그대로 — 바뀌는 것은 ①의 “모델”(정책 $\pi(a|s)$)과 ④의 “데이터”(에이전트의 경험)뿐.

같은 구조, 다른 질문 — 이번 학기가 ML2에 남기는 정확한 선물. 어떤 모델을 쓸지보다 먼저 “무엇을 데이터로 갖고, 무엇을 맞히고 싶은가.”

- Q. 기말고사 대비 — 어디서부터? 개념 연결 4문항 + 절차 3문항을 그 순서로. 6번(누수 질문)을 노트북 없이 답하면 준비 끝.
- Q. Ch02 15가 섞여 있는데 기말은 Block B 만? 복습 문제가 의도적으로 두 블록을 넘나 둠 — “연결을 아는가”가 “개별 장을 외우는 것”보다 시험·ML2에서 훨씬 많이 쓰임.
- Q. ML1의 수식 유도를 전부 외워야? 아니오 — 4단계 구조의 감각이 자동인 것이 목표. 유도($GDA \leftrightarrow$ 로지스틱, ELBO)는 필요할 때 장에서 찾아보는 것이 정상, “손실을 뭐로 나타내지?”가 자동 반사 여야.
- Q. ML2의 프로젝트는 뭐가 다른가요? 뼈 대(발표+리뷰+채점)는 동일. “결과의 정직성”의 초점만 바뀜 — RL에서 “학습이 안 된 부분”은 실패가 아니라 데이터 — 왜 안 됐는지 Ch09 15의 개념으로 진단하는 것이 좋은 보고서.

이번 주차 정리

- ① **16.1** — 두 층의 베이스라인(무작위·GBDT)을 둘 다 넘어야 “딥러닝이 필요했다”. 근거는 2축(구조·규모) + 2숫자(GBDT 비교, 학습 곡선). digits 64차원 GBDT 0.944 > CNN 0.939, 784차원에서 역전 0.961 = 축 2(규모)의 증거.
- ② **16.2** — 이번엔 너가 심사위원. 체크리스트 + “왜 DL인가” 5번째 항목. 아키텍처-데이터 매칭이 3점 질문의 최빈 영역. “test 0.95 vs 0.94는 잡음 수준”을 $\mathbb{E}[\max](\approx 0.05)$ + 표본 잡음(0.06)으로 정량화.
- ③ **16.3** — 채점 합산(발표 50/보고서 30/리뷰 20)과 “리뷰 한 통이 94%를 88%로 바꿨다”(그룹 누수). Ch02 15를 4단계 구조 (모델 정의 → 손실 → θ 조정 → 통제)와 개념 지도 위에.

다음 학기 — ML2: 강화학습·로봇

정답 y 가 있는 세계에서 벗어난다 — 정답 대신 보상 r 만 주어지고, 에이전트가 스스로 데이터를 만들어 가는 로봇 시뮬레이션의 세계. 4단계 구조는 그대로 — 바뀌는 것은 ①의 모델(정책 $\pi(a|s)$)과 ④의 데이터(에이전트의 경험)뿐. **같은 구조, 다른 질문.**