

Block A 캡스톤 팀 프로젝트 공고 (샘플)

Spring 2027

1. 프로젝트 개요

Chapter 2~7에서 배운 고전 머신러닝 기법(회귀, 생성모델 기반 분류, 거리 기반 모델, SVM, 정규화와 모델 선택, 트리 기반 모델)을 실제 정형(tabular) 데이터에 적용하는 4주짜리 팀 프로젝트이다. 목표는 “높은 성능” 자체가 아니라, 그 성능 숫자를 정직하게 얻는 절차를 실제로 수행하고 보고하는 것이다.

4주 파이프라인: 데이터 선정 → 구현 → 검증 → 발표.

2. 필수 요구사항

- 데이터: Kaggle 또는 UCI Machine Learning Repository의 정형(행/열) 데이터 하나 (이미지·텍스트 제외 — 표 형태가 Ch.2~7 모델 검증에 적합).
- 적용 알고리즘: Chapter 2~7 중 최소 두 가지 모델(예: 로지스틱회귀 + GBDT)을 같은 데이터에 적용해 비교한다.
- 수식적 정당화 최소 1개: 예 — 정규화를 적용했다면 편향-분산 관점에서 왜 성능이 바뀌었는지, GBDT를 썼다면 SHAP으로 예측 하나를 분해, 여러 모델을 비교했다면 PR-AUC로 불균형을 고려한 비교.
- 검증 원칙: train/validation/test 3분할을 준수하고, 테스트 성능은 딱 한 번만 확인한다. 전처리는 반드시 train으로만 fit한다.
- 학습 곡선 필수 제시: 최종 숫자만으로는 하이퍼파라미터를 어떻게 정했는지 검증할 수 없다 — validation 곡선이 실제로 선택에 쓰였는지가 그림에서 드러나야 한다.

3. 데이터 고르기 실전 가이드

1. 행의 물리적 단위를 한 문장으로 설명할 수 있는가 (환자? 거래? 주문?) — 설명이 안 되면 예측 대상 단위를 일반화할 수 있는지 물을 수 없다.
2. 레이어아웃의 함정이 있는가 — 같은 개체의 여러 행이 있으면 무작위 분할 시 데이터 누수가 발생할 수 있다(그룹 단위 분할 필요).
3. 시계열이면 시간순으로 분할해야 한다.
4. 클래스 비율을 먼저 보고 지표를 정한다 — 비율이 99:1처럼 극단적이면 정확도가 아니라 PR-AUC/재현율을 사용한다.
5. 크기 — 100행 미만이면 교차검증 폴드가 너무 작아 숫자가 심하게 흔들린다. 500~10,000행 정도가 다루기 편하다.

4. 일정 및 마일스톤 (M1~M4)

주 / 해야 할 일	마일스톤(제출)
1주: 데이터 후보 2~3개 조사(크기·결측치·클래스 비율), 팀 회의, 문제 정의 문서(행의 단위, 라벨, 주 지표, 베이스라인)	M1 문제 정의 + 데이터 선택 (1p)
2주: 3분할 코드 스캐폴드, train으로만 fit하는 전처리, 1개 모델 엔드투엔드 확인, 베이스라인 측정	M2 중간 코드 리뷰(코드 + 베이스라인 1줄)
3주: 나머지 모델 적용, validation/교차검증으로 튜닝, test 최종 측정(한 번만), 학습 곡선 도출	M3 학습 곡선 1장 + 최종 test 숫자
4주: 수식적 정당화 작성, 보고서·슬라이드 완성, 발표 (5~7분), 다른 팀 2개에 대한 peer-review 작성	M4 보고서 + 발표 + 리뷰 2건

M2가 베이스라인 숫자 한 줄을 요구하는 이유: 이 숫자를 봐야 “모델을 만들었다”고 말할 수 있는지 판정할 수 있다. M3가 학습 곡선 한 장을 요구하는 이유: 최종 숫자만 제출하면 하이퍼파라미터를 어떻게 정했는지 검증할 수 없다.

5. 보고서 구조

1. 문제 정의 (0.5p): 행의 단위, 라벨, 주 지표, 베이스라인, “왜 이 지표를 골랐는가” 한 문장.
2. 데이터와 전처리 (1p): 원본 통계(크기·결측치·이상치), train으로만 fit 한 전처리 명시, 3분할 비율과 stratify 여부.
3. 모델 선택과 이유 (1~2p): 후보 2개 이상, 왜 이 후보들인가(데이터 특성과 연결: 거리 기반이면 스케일링, 트리 기반이면 불필요), validation 비교표.
4. 결과 (1p): 최종 test 숫자(한 번), 학습 곡선 1장, validation 비교표.
5. 수식적 정당화 (1p): 편향-분산, 정규화, SHAP, PR-AUC 중 1개 이상으로 “왜 이 결과가 나왔는지”.
6. 잘 안 된 부분과 원인 진단 (0.5p, 필수): 안 된 부분이 없었다면 무엇을 시도했다가 안 됐는지를 쓴다.

6. 채점 기준 (Rubric)

항목	비중	좋은 답
문제 정의와 데이터	15%	행의 단위·라벨·지표·베이스라인이 명확하고, 지표 선택이 데이터 특성에 근거함
방법론 적절성	25%	데이터 특성(불균형·차원·시계열·그룹)에 맞는 모델·전처리·분할을 Ch.2~7 개념으로 근거
검증의 정직성	25%	3분할·train-fit·test 한 번·베이스라인·학습 곡선·validation 튜닝이 추적 가능할 정도로 명시
수식적 정당화	20%	배운 개념 1개 이상으로 “왜”를 설명했고, 그 설명이 실제 관측 숫자와 일치
결과의 정직성과 반성	15%	잘 안 된 부분을 숨기지 않고 Ch.2~7 개념으로 원인 진단

목적은 “높은 성능”이 아니라 “성능 숫자를 정직하게 얻는 절차”를 수행한 것을 증명하는 것이다. 성능이 낮아도 절차가 정직하면 높은 점수를, 성능이 좋아 보여도 test를 두 번 썼거나 베이스라인이 없으면 크게 감점받는다.

7. 발표와 Peer-Review

- 발표: 팀당 5~7분.
- Peer-Review: 발표를 들은 팀은 다른 두 팀에 대해 작성 리뷰를 각 1통씩 제출한다. 각 리뷰는 아래 4항목 체크리스트와, 근거를 대야만 답할 수 있는 반박 가능한 질문을 1개 이상 포함해야 한다.

Peer-Review 체크리스트 (4항목)

항목	확인할 것
문제 정의	무엇을 예측/분류하려 했는지 명확한가
방법론 적절성	데이터 특성(불균형, 차원 수 등)에 맞는 모델을 골랐는가
수식적 정당화	요구사항을 충족했고, 그 설명이 실제로 타당한가
결과의 정직성	잘 안 된 부분을 숨기지 않고 원인을 분석했는가

8. 팀 구성 및 제출 방식

- 팀 구성: 팀당 인원 및 팀 편성 방식은 추후 공지.
- 제출물: 보고서(PDF), 코드(저장소 링크 또는 압축 파일), 발표 슬라이드, peer-review 2건.
- 제출 방법 및 마감: 추후 공지 (LMS/과제 제출 시스템 및 마감 일시는 별도 안내 예정).