Machine Learning 1: 머신러닝 첫걸음 2027. X. XX (예정)

Block B 캡스톤 팀 프로젝트 공고 (샘플)

Spring 2027

1. 프로젝트 개요

Chapter 9∼15에서 배운 딥러닝 기법(신경망 기초·역전파, CNN, 시퀀스 모델, 어텐션·트랜스포머, 그래프 표현학습, 표현학습, 잠재변수 생성모델)을 실제 데이터에 적용하는 4주짜리 팀 프로젝트이다. Block A (8주차)의 절차를 **딥러닝 무대**에서 다시 수행하며, 이번에는 "왜 고전 머신러닝이 아니라 딥러닝인가"를 직접 증명해야 한다.

4주 파이프라인: **데이터 선정** → **구현** → **검증** → **발표**.

2. 필수 요구사항

- **데이터**: Kaggle, UCI, Hugging Face Datasets 중에서 선택 (이미지·텍스트·시퀀스 등 비정형 데이터도 가능).
- **적용 알고리즘**: Chapter 9∼15 중 **최소 하나의 딥러닝 기법**(CNN, RNN/Transformer, 프롬프팅 응용, 또는 EM/VAE 계열 생성모델)을 실제 데이터에 적용한다.
- **수식적 정당화 최소 1개**: (1) CNN 구조라면 파라미터 수/연산량 공식으로 설계를 정당화, (2) 정규화(dropout 등)를 썼다면 그 효과를 설명, (3) 생성모델이라면 ELBO나 min-max 목적함수를 실제 구현과 연결.
- **GBDT 비교 (필수)**: 같은 데이터에 GBDT(또는 랜덤 포레스트)를 **베이스라인**으로 돌려, 신경망이 이보다 나은지 확인한다. 이것이 발표에서 "왜 딥러닝인가"를 답하는 근거의 출발점이 된다.
- **검증 원칙**: train/validation/test 3분할을 Block A와 동일하게 준수하고, **테스트 성능은 딱 한 번**만 확인한다.

3. 정형/비정형 판정 가이드

Block A의 5개 데이터 선정 기준(행의 물리적 단위, 레이아웃 함정, 시계열, 클래스 비율, 크기)은 그대로 적용되며, Block B에서는 다음 기준이 추가된다: **"원시 특징"이 이미 정형으로 추출되어 있는가?**

경우	예	판정
수치·범주 열로만 구성된 표	매출표, 센서 로그	**정형** — GBDT와 비교해야 한다
픽셀·음파·토큰인 원시 배열	이미지, 오디오, 문장	**비정형** — 손으로 특징을 만들기 어려우니 신경망이 특징 추출기 역할을 한다
애매한 경우	이미 임베딩으로 벡터화된 텍스트	원시 토큰으로 직접 모델링하는 선택도 가능 — 그 이유를 M1에 적어야 한다

4. 일정 및 마일스톤 (M1∼M4)

주 / 해야 할 일	**마일스톤(제출)**
1주: 데이터 후보 2∼3개 조사, 정형/비정형 판정, 팀 회의, 문제 정의 문서(행·라벨·지표·베이스라인·"왜 딥러닝인가" 초안)	**M1** 문제 정의 + 데이터 선택 + "왜 딥러닝인가" 1페이지
2주: 3분할 스캐폴드, train으로만 fit한 전처리, 1개 신경망 엔드투엔드 확인, **GBDT 베이스라인** 측정	**M2** 중간 코드 리뷰(코드 + 베이스라인 숫자 각 1줄)
3주: 나머지 기법 적용, validation/교차검증으로 튜닝, **test 최종 측정(한 번만)**, 학습 곡선 도출	**M3** 학습 곡선 1장 + 최종 test 숫자 + GBDT 비교
4주: 수식적 정당화, 보고서·슬라이드 완성, 발표 (5∼7분, 마지막에 "왜 딥러닝인가"), 다른 팀 2개에 대한 peer-review 작성	**M4** 보고서 + 발표 + 리뷰 2건

M3의 학습 곡선은 **에포크** 단위(Block A의 트리 개수와는 다른 축)이다. 최종 숫자만으로는 에포크 수를 어떻게 정했는지 검증할 수 없다 — validation 곡선이 실제로 쓰였는지가 그림에서 드러나야 한다.

5. 보고서 구조

Block A의 6절 구조를 그대로 쓰되, 2절과 5절이 Block B용으로 바뀐다.

1. **문제 정의** (0.5p): 행의 단위, 라벨, 주 지표, **두 층의 베이스라인**(무작위·GBDT), **정형/비정형 판정과 그 근거**.
2. **데이터와 전처리** (1p): 원본 통계, train으로만 fit한 전처리 명시(이미지 스케일링, 텍스트 토크나이저/패딩 등), 분할 비율.
3. **모델 선택과 이유** (1∼2p): 적용한 딥러닝 기법 1개 이상과 그 구조(층·크기)를 파라미터 수 공식으로 정당화, 왜 GBDT가 아니라 이 기법인가.
4. **결과** (1p): 최종 test 숫자(한 번), 에포크 학습 곡선 1장, GBDT·무작위와의 비교표.
5. **수식적 정당화** (1p, **필수 1개**): 파라미터 수/정규화 효과/ELBO 중 하나.
6. **잘 안 된 부분과 원인 진단** (0.5p, **필수**): 학습이 안 된/과적합된 부분을 배운 개념으로 진단.

6. 채점 기준 (Rubric)

항목	비중	좋은 답
문제 정의와 데이터	15%	행·라벨·지표·**두 층 베이스라인**이 명확하고, **정형/비정형 판정**이 데이터 특성에 근거함
방법론 적절성	25%	**GBDT와 비교해서** 왜 이 딥러닝 기법인지의 근거가 차원·구조·가중치 공유 등의 개념으로 설명됨
검증의 정직성	**25%**	3분할·train-fit·test 한 번·베이스라인·**에포크 학습 곡선**·validation 튜닝이 보고서에서 추적 가능
수식적 정당화	20%	배운 공식(파라미터 수, 정규화, ELBO 중 1개 이상)으로 "왜"를 설명했고, 관측한 숫자와 일치
결과의 정직성과 반성	15%	GBDT보다 못한 부분·학습이 안 된 부분을 숨기지 않고 배운 개념으로 진단

7. 발표와 Peer-Review

- **발표**: 팀당 5∼7분. 마지막에 **"왜 고전 머신러닝이 아니라 딥러닝인가"**에 구체적 근거로 답해야 한다.
- **Peer-Review**: 발표를 들은 팀은 다른 두 팀에 대해 작성 리뷰를 각 1통씩 제출한다. 각 리뷰는 아래 5항목 체크리스트와, 반박 가능한 질문을 1개 이상 포함해야 한다.

Peer-Review 체크리스트 (5항목 — Block A의 4항목 + 1)

항목	확인할 것
문제 정의	무엇을 예측/분류하려 했는지 명확한가
방법론 적절성	데이터 특성(비정형·불균형·시퀀스)에 맞는 아키텍처를 골랐는가
수식적 정당화	요구사항(최소 1개)을 충족하고 실제로 타당한가
결과의 정직성	잘 안 된 부분을 숨기지 않고 원인을 분석했는가
"왜 딥러닝인가"	필수 질문에 구체적 근거로 답했는가

8. 팀 구성 및 제출 방식

- **팀 구성**: 팀당 인원 및 팀 편성 방식은 추후 공지.
- **제출물**: 보고서(PDF), 코드(저장소 링크 또는 압축 파일), 발표 슬라이드, peer-review 2건.
- **제출 방법 및 마감**: 추후 공지 (LMS/과제 제출 시스템 및 마감 일시는 별도 안내 예정).