

신경망 기초, 역전파, 학습 기법

퍼셉트론의 한계와 역전파 · 그래디언트 소실 · 폭발과 활성화함수 · 초기화 · 정규화와 학습률 스케줄링

Machine Learning 1 · 9주차

한국과학영재학교 (KSA)

Week 9

이번 주차 개요

이 주차를 마치면

- XOR이 직선 하나로 안 풀리는 이유를 설명하고, 은닉층이 어떻게 푸는지 보여준다
- 역전파를 연쇄법칙으로부터 유도하고, 구현을 수치 미분으로 검증한다
- 그래디언트 소실·폭발을 진단하고, 활성화 함수와 초기화를 고른다
- 정규화와 학습률 스케줄링을 과적합·불안정 학습 상황에 맞게 적용한다
- **9.1 퍼셉트론의 한계, 순전파, 역전파** — XOR의 벽, 오차 δ 의 역전파, 2-2-1 손계산, numpy로 XOR 풀기
- **9.2 그래디언트 소실·폭발, 활성화 함수, 초기화** — 연쇄법칙의 곱, ReLU 계열, Xavier/He 초기화, “세 라인 방어선”
- **9.3 정규화 기법과 학습률 스케줄링** — dropout, BatchNorm, 가중치 감쇠, StepLR/코사인/warmup

세 절은 한 사슬: 그래디언트는 “연쇄법칙의 곱”(9.1) → 깊어지면 0으로 사라지거나 불어나는(9.2) → 학습을 안정적으로 끝내는 도구(9.3). Block B(CNN → RNN → 트랜스포머 → LLM)의 서막이다.


9.1 퍼셉트론의 한계, 순전파, 역전파

퍼셉트론: “AI의 시작”이자 “AI의 실망”

- **1958, 로젠블라트(코넬): 퍼셉트론 발표** — “컴퓨터가 배운다”, “우주 탐사 1세대 로봇”
- Week 2의 로지스틱회귀와 거의 동일, 시그모이드 대신 **스텝함수**

$$\hat{y} = \text{sgn}(w^{\top}x + b)$$

- 실제로 (당시 기준) 조종사 얼굴 인식 실험까지 수행




sgn(파랑, $z = 0$ 에서 도약) vs 시그모이드(주황, 매끄러운 전이)

퍼셉트론 학습 규칙

1969, Perceptrons: XOR의 벽과 AI의 겨울

- 단층 퍼셉트론은 XOR을 절대 못 맞춘다



Frank Rosenblatt(왼쪽)와 Charles Wightman —
1958년 12월, 최초의 퍼셉트론이 된 장치를 조립



Marvin Minsky — 페퍼트와 함께 1969년
Perceptrons를 써 단층 퍼셉트론의 한계를
증명

퍼셉트론에서 다층 신경망(MLP)으로

- 해법: 직선 하나로 안 되면, **직선을 여러 개 겹쳐 새 공간을 만든 뒤 그 공간에서 다시 나누기**
- 로지스틱회귀 = 은닉층 없는 가장 단순한 “신경망” $a = \sigma(w^T x)$
- **MLP**: 그 사이에 **은닉층**을 하나 이상 끼워 넣음
- 은닉층 하나만 추가해도 **XOR**을 완벽히 풀 수 있다

x_1	x_2	XOR
0	0	0
0	1	1
1	0	1
1	1	0

라벨 1인 점 (0, 1), (1, 0)과 라벨 0인 점 (0, 0), (1, 1)이 **대각선으로 교차** 배치 — 어떤 직선을 그어도 서로 다른 라벨이 한쪽에 섞여 들어간다.

XOR의 부등식 모순 — 직접 세워보자

직선분리 가능하다는 말 = 어떤 (w_1, w_2, b) 가 다음을 **모두** 만족:

$$w_2 + b > 0 \quad (0, 1) \quad w_1 + b > 0 \quad (1, 0) \quad b \leq 0 \quad (0, 0) \quad w_1 + w_2 + b \leq 0 \quad (1, 1)$$

- ① 첫 두 식을 더하면 $w_1 + w_2 + 2b > 0$
- ② 셋째 식($b \leq 0$)과 결합 $\Rightarrow w_1 + w_2 + b > -b \geq 0$
- ③ 넷째 식은 $w_1 + w_2 + b \leq 0$ 이라 주장 — **모순**

결론

부등식 네 개는 어떤 (w_1, w_2, b) 로도 동시에 성립 불가. 퍼셉트론에 필요한 것은 **비선형 결정경계**.



은닉층이 실제로 하는 것: “새 공간” 만들기

은닉 유닛 2개를 $f_1 = \sigma(x_1 + x_2 - 1)$, $f_2 = \sigma(-x_1 - x_2 + 1)$ 로 정하면:

(x_1, x_2)	라벨	f_1	f_2
(0, 0)	0	≈ 0.27	≈ 0.73
(1, 1)	0	≈ 0.73	≈ 0.27
(0, 1)	1	0.5	0.5
(1, 0)	1	0.5	0.5

- 새 공간 (f_1, f_2) 에서: **라벨 1의 두 점은 한 점으로 모이고**, 라벨 0의 두 점은 좌표가 다름
- 이제 **직선 하나로 깔끔히 분리**

“새로운 공간”이 그림으로: 결정경계



- **입력 공간** (x_1, x_2): 네 점 사이를 **비선형 곡선**이 지나 — 직선 하나로 못 나눔
- **은닉 공간** (a_1, a_2): 같은 네 점이 **직선 하나로** 깔끔히 분리

은닉층의 역할

“새 공간을 만들어, 거기서 직선으로 나누는 것.”

(실제로 학습된 망, 은닉 유닛 2개 · 20,000 에폭)

순전파 (Forward Propagation)

2층 신경망(입력 $\rightarrow$ 은닉 $\rightarrow$ 출력, W_1, b_1 은닉층 / W_2, b_2 출력층):

$$z_1 = W_1 x + b_1, \quad a_1 = \sigma(z_1), \quad z_2 = W_2^\top a_1 + b_2, \quad a_2 = \sigma(z_2)$$

- z : **활성화 전**(pre-activation), a : **활성화 후** — 최종 예측값은 a_2

주의 — 컨벤션

$W_1 \in \mathbb{R}^{m \times d}$ (행=은닉 유닛, 열=입력)이면 $z_1 = W_1 x + b_1$ 이 자연스럽고,

PyTorch/TensorFlow의 Linear와 일치.

아래 손계산은 **전치 배치**(행=입력, 열=은닉)로 $z_1 = x^\top W_1 + b_1$ 를 쓴다 — “같은 값이 전치된 모습으로 쓰여 있는” 것이 수치 미분 검증·9.2절의 가장 흔한 혼동의 근원.

역전파: 연쇄법칙을 거꾸로

● 역전파: 오차를 연쇄법칙으로 거꾸로 흘려보냄

$z_1 \rightarrow a_1 \rightarrow z_2 \rightarrow a_2 \rightarrow L$ (이 긴 사슬을 출력에서 입력 방향으로 거꾸로 따라가며 미분을 곱)

① **출력층 오차:** $\delta_2 = \frac{\partial L}{\partial z_2} = (a_2 - y) \sigma'(z_2)$

② **은닉층 오차:** $\delta_1 = (W_2 \delta_2) \odot \sigma'(z_1)$ ($\odot$: 원소별 곱)

③ **그래디언트:** $\frac{\partial L}{\partial W_2} = \delta_2 a_1^\top, \quad \frac{\partial L}{\partial W_1} = \delta_1 x^\top$

왜 출력층 오차가 “ $a_2 - y \cdot \sigma'$ ”로 깔끔한가

MSE $L = \frac{1}{2}(a_2 - y)^2$ 일 때:

$$\delta_2 = (a_2 - y) \sigma'(z_2) = (a_2 - y) a_2(1 - a_2)$$

시그모이드 미분항이 **그대로** 곱된다.

교차 엔트로피 $L = -[y \ln a_2 + (1 - y) \ln(1 - a_2)]$ 일 때:

$$\frac{\partial L}{\partial a_2} = -\frac{y}{a_2} + \frac{1 - y}{1 - a_2}$$

$\sigma'(z_2) = a_2(1 - a_2)$ 와 곱하면 **정확히 약분**.

“교차 엔트로피 + 시그모이드 출력”이 표준인 계산적 이유

$\delta_2 = a_2 - y$ — 포화 항(최대 0.25)이 붙지 않아, 예측이 0이나 1에 포화돼도 그래디언트가 상대적으로 크게 유지.

“역전파”라는 이름의 의미: 오차 벡터의 재사용

- 오차 δ 는 **출력층**에서 계산되고, 은닉층 방향으로 **거꾸로 전파**되면서 각 층의 그래디언트를 만들


$$\delta_{1,i} = \delta_2 \cdot W_{2,i} \cdot \sigma'(z_{1,i}) \quad \Rightarrow \quad \delta_1 = (W_2 \delta_2) \odot \sigma'(z_1)$$

그래디언트 재사용 — 역전파는 동적 프로그래밍

각 층의 δ 를 **한 번** 계산해 두고 아래 층에 **다시 쓰는** — “같은 미분을 두 번 계산하지 않는” 알고리즘.

- 역전파: **순전파 1회 + 역전파 1회** $\approx O(W)$

순전파와 역전파의 흐름: 한 장의 그림



● 실선 = 순전파:

$z_1 \rightarrow a_1 \rightarrow z_2 \rightarrow a_2$ (입력 → 은닉 → 출력)

● 점선 = 역전파: $\delta_2 \rightarrow \delta_1$ (출력 → 은닉)

역전파는 이름뿐이 아니라, **오차 값이 실제로 층을 거슬러 흘러가는 것**. 각 층의 그래디언트 $\partial L / \partial W_2, \partial L / \partial W_1$ 이 여기서 만들어진다.



Geoffrey Hinton — 1986년, 역전파 대중화 논문의 공저자

손으로 한 번: 2-2-1 순전파 + 손실

$x = (1, 0), y = 1$ (XOR(1,0)=1), $W_1 = \begin{bmatrix} 0.5 & 0.3 \\ -0.5 & 0.8 \end{bmatrix}, b_1 = (0.1, -0.2), W_2 = (0.7, -0.6), b_2 = 0.1$:

- **순전파:** $z_1 = x^\top W_1 + b_1 = (0.6, 0.1), a_1 = \sigma(z_1) \approx (0.646, 0.525)$
- $z_2 \approx 0.646 \times 0.7 + 0.525 \times (-0.6) + 0.1 \approx 0.237, a_2 \approx 0.559$
- **손실:** $L = \frac{1}{2}(a_2 - y)^2 \approx 0.097$

$$\delta_2 \approx (-0.441) \times 0.559 \times 0.441 \approx -0.109$$

$$\delta_1 = W_2 \delta_2 \odot \sigma'(z_1) \approx (-0.076, 0.065) \odot (0.229, 0.249) \approx (-0.017, 0.016)$$

2-2-1 손계산: 그래디언트와 한 스텝 갱신

$$\frac{\partial L}{\partial W_2} \approx \delta_2 a_1 \approx (-0.070, -0.057), \quad \frac{\partial L}{\partial W_1} \approx \begin{bmatrix} -0.017 & 0.016 \\ 0 & 0 \end{bmatrix}$$

- 학습률 $\alpha = 0.5$ 로 **한 스텝** 갱신 $\Rightarrow$ 손실 $0.097 \rightarrow 0.087$
- **핵심**: 은닉층 가중치 W_1 까지 **정확히 한 번의 역전파**로 갱신됐다

왜 이 계산이 중요하나

PyTorch/TensorFlow는 `.backward()` 한 줄로 이 모든 미분을 자동 계산(자동 미분, 1986 이후의 표준). 하지만 내부에서 연쇄법칙이 정확히 무엇을 하는지 모르면, 9.2절의 소실 문제를 **원인 진단**할 수 없다.

수치 미분 검증: “역전파가 맞다”를 기계로

수치 미분(numerical gradient checking): 가중치를 아주 작게 ($\epsilon = 10^{-6}$) 흔들어서 손실 변화량으로 미분을 직접 재봄

$$\frac{\partial L}{\partial w} \approx \frac{L(w + \epsilon) - L(w - \epsilon)}{2\epsilon}$$

파라미터	역전파	수치 미분	차이
$\partial L / \partial b_2$	-0.1087	-0.1087	6.6×10^{-12}
$\partial L / \partial W_{2,1}$	-0.0702	-0.0702	1.5×10^{-11}
$\partial L / \partial b_{1,1}$	-0.0174	-0.0174	6.3×10^{-12}
$\partial L / \partial W_{1,11}$	-0.0174	-0.0174	6.3×10^{-12}

실습: numpy로 2층 신경망 + XOR

```
import math, random

def sigmoid(x):
    return 1 / (1 + math.exp(-x))

def sigmoid_prime(x):
    s = sigmoid(x)
    return s * (1 - s)

def two_layer_forward(x, W1, b1, W2, b2):
    z1 = [sum(W1[i][j] * x[j] for j in range(len(x))) + b1[i]
          for i in range(len(b1))]
    a1 = [sigmoid(v) for v in z1]
    z2 = sum(W2[i] * a1[i] for i in range(len(a1))) + b2
    return sigmoid(z2), (x, z1, a1, z2, sigmoid(z2))

def two_layer_backward(y_true, cache, W2):
    x, z1, a1, z2, a2 = cache
    delta2 = (a2 - y_true) * sigmoid_prime(z2)
    delta1 = [W2[i] * delta2 * sigmoid_prime(z1[i]) for i in range(len(z1))]
    grad_W2 = [delta2 * a1[i] for i in range(len(a1))]
    grad_W1 = [[delta1[i] * x[j] for j in range(len(x))]
                for i in range(len(delta1))]
    return grad_W1, delta1, grad_W2, delta2
```

은닉 유닛 4개 + 5,000 에폭, 무작위 초기화: 최종 예측 [0.016, 0.977, 0.976, 0.030] → 반올림 [0, 1, 1, 0] — 정답 XOR 패턴과 정확히 일치. 로지스틱회귀 혼자서는 영원히 못 풀던 문제를 **은닉층 하나 + 역전파**로 풀어냄.

같은 데이터, 다른 운명: 로지스틱회귀 vs 2층 신경망

모델	최종 예측	손실
로지스틱회귀 (은닉층 없음)	[0.500, 0.500, 0.500, 0.500]	0.125
2층 신경망 (은닉 4개)	[0.016, 0.977, 0.976, 0.030]	0.0003

- 로지스틱회귀: 0.125에서 멈춤
- 2층 신경망: 0.0003까지 내려 정확히 분리

구조의 차이가 운명을 정한다

“은닉층이 왜 필요한가”를 가장 극적으로 보여주는 최소 예시.

“XOR을 풀었다”는 말이 성립하려면: 초기화 + 학습률

XOR 학습 성공 = (1) **무작위 초기화**가 적절 + (2) **학습률**이 적절.

0-초기화 (대칭성 문제): 모든 은닉 유닛이 같은 입력
· 같은 업데이트를 받아 **영원히 같은 값** 유지

0-초기화: 예측 [0.5, 0.5, 0.5, 0.5], 손실 0.125
(멈춤)

출력층이 “같은 값 4개를 합산” = 사실상 1차원. XOR을
분리할 표현력이 **구조적으로 없음**. (9.2절 Xavier/He 해결)

학습률 (같은 구조, 무작위 초기화, 시드 고정):

$\alpha = 0.01$: 손실 0.124 (사실상 무학습)

$\alpha = 0.5$: 손실 0.0003 (성공)

$\alpha = 2.0$: 손실 0.0001 (성공, 약간 빠름)

0.01은 50,000 에폭이 돼야 겨우 수렴 — “느리다”가
아니라 “못 배운다”. 2.0은 이 예제에선 수렴하나, 데이터가
크면 발산.

자주 하는 실수 (9.1)

- ① 가중치 0 초기화는 대칭을 깨지 못함

자주 묻는 질문 (9.1)

- **Q. 은닉층이 하나로 충분한가? 보편근사정리**(hornik, 1991): 은닉층 **하나**(뉴런 수 충분히 많으면)로도 이론적으로 어떤 연속함수든 근사 가능. 하지만 “가능하다” $\neq$ “학습이 쉽다” — 실전은 더 깊은 쪽이 같은 표현력을 **훨씬 적은 뉴런 수**로 달성 (CNN·트랜스포머의 “깊이” 효율성).
- **Q. 역전파가 매번 같은 미분을 계산한다는 확신은? 수치 미분**으로 $-\frac{L(w + \epsilon) - L(w - \epsilon)}{2\epsilon}$ 가 역전파 값과 소수점 몇 자리 내면 일치.
- **Q. 연쇄법칙인데 왜 1986년에야?** 아이디어는 1974년 워브루브스키 박사논문까지 거슬림 — 1986 논문은 **대중화**: (a) 최우도 추정과 연결, (b) 문자 인식 실험, (c) “은닉층을 학습할 수 있다”의 메시지.
- **Q. 순전파 vs 역전파 계산량? 동급** — 둘 다 $O(\text{총가중치})$. 한 에폭 = 순전파 1회 + 역전파 1회 $\approx 2 \times$ 순전파.


확인 문제 (9.1)

- ① **XOR의 부등식 모순.** $w_2 + b > 0, w_1 + b > 0, b \leq 0, w_1 + w_2 + b \leq 0$ — 첫 두 식을 더해 셋째 식과 모순을 만들어, 이 네 식을 모두 만족하는 (w_1, w_2, b) 가 **존재하지 않음**을 보여라.
- ② **δ_1 의 재사용.** $\delta_1 = (W_2\delta_2) \odot \sigma'(z_1)$ 에서 δ_2 가 출력층에서 이미 계산돼 **재사용** 된다는 것이 역전파가 “동적 프로그래밍”인 이유. 10층 망에서 모든 δ_l 을 처음부터 다시 계산하면 몇 번의 미분이 필요한가, 재사용하면 몇 번인가?
- ③ **교차 엔트로피의 약분.** 시그모이드 + 교차 엔트로피면 $\delta_2 = a_2 - y$ 로 미분항이 약분. MSE 때의 δ_2 와 비교하고, 그 차이가 “포화된 예측에서도 그래디언트가 살아있는” 것과 어떻게 연결되는지 한 문장으로.

9.2 그래디언트 소실·폭발, 활성화함수, 초기화

시그모이드의 숨은 함정: 그래디언트 소실

● 깊을수록 오히려 못 배운다



AlexNet (2012, ImageNet 승리): 5 합성곱 + 3 완전연결 = 8층 — 그 “깊음” 자체가 뉴스였다.

원인: $\sigma'(z) = \sigma(z)(1 - \sigma(z))$ 의 **최댓값은 $z = 0$ 에서 0.25**. 역전파는 층을 거슬러 이 미분값을 **곱해서** 전달.

$$\underbrace{0.25 \times 0.25 \times \cdots}_{10 \text{ 개 층}} \approx 9.5 \times 10^{-7}$$

→ **그래디언트 소실(vanishing)**: 신호가 사실상 0. 반면 가중치 초기화가 잘못되면 층을 거칠수록 오히려 **지수적으로 커지는 그래디언트 폭발(exploding)**도 일어남.


왜 “곱”인가 — 할인율 비유

- L 이 W_1 에 영향을 미치는 경로

핵심

소실은 “느리다”가 아니라 “**지수적으로 0에 수렴한다**”.

소실과 폭발은 연쇄법칙 곱의 두 얼굴




L개 층의 곱 형태 + 손으로 체감

$$\frac{\partial L}{\partial W_1} \propto \prod_{l=2}^L \sigma'(z_l) \cdot W_l$$

- 각 $\sigma'(z_l) < 1$ (시그모이드) $\Rightarrow$ 지수적으로 0 $\rightarrow$ **소실** | 각 항이 > 1 (가중치 큼) $\Rightarrow$ 지수 증가 $\rightarrow$ **폭발**

상황	값	의미
$\sigma' = 0.2$ 3개 층	$0.2^3 = 0.008$	그라디언트의 0.8%만 1층에 도달
$\sigma' = 0.2$ 10개 층	$\approx 1.0 \times 10^{-7}$	사실상 0
$\sigma' = 0.2$ 20개 층	$\approx 1.05 \times 10^{-14}$	float32 이내 $\rightarrow$ 반올림 0
승수 평균 2, 20개 층	$2^{20} \approx 10^6$	백만 배 부풀림, 발산 (NaN 전조)

실습: 10층 시그모이드에서 실제로 사라지는 그래디언트




- 꼭 10 시그모이드 층 10개, $W \sim \mathcal{N}(0, 1)$
- 출력층 3.16 → 입력층 0.0057, **약 550배 감소**
- $0.25^{10} \approx 9.5 \times 10^{-7}$ 은 활성 미분만 곱한 극단 하한 — 가중치 곱($\|W\| \approx \sqrt{10}$)이 일부 보상해 550배로 관측
- 실제 평균 $\sigma'(z)$ 는 0.13~0.19 — z 가 $\pm 2 \sim 6$ 까지 벌어진 **포화** 뉴런이 많기 때문

시그모이드 미분이 “0.25 이하”인 것 자체보다, **실제 데이터 위에서 포화로 평균이 0.2를 훨씬 하회**하는 것이 더 치명적 — 입력 근처 층은 사실상 그래디언트를 못 받아 학습이 멈춘 것과 다름없음. 20층이면 float32 정밀도($\approx 10^{-8}$) 이내로 **그래디언트 자체가 0으로 반올림**된다.

활성함수가 왜 필요한가


- $a_2 = W_2(W_1x) = (W_2W_1)x$
- 활성화함수는 각 층 사이에 “곡선을 접어 넣는” **비선형성**을 제공, 층이 쌓일수록 표현 가능 공간이 **지수적으로** 넓어짐



기본 3종: Sigmoid / Tanh / ReLU

함수	정의	미분	특징
Sigmoid	$\frac{1}{1 + e^{-z}}$	최댓값 0.25 ($z = 0$)	출력 (0, 1), 확률 해석 유용하나 소실에 취약
Tanh	$\frac{e^z - e^{-z}}{e^z + e^{-z}}$	최댓값 1	출력 (-1, 1), sigmoid보다 낮지만 양 끝에서 포화
ReLU	$\max(0, z)$	$z > 0: 1, z < 0: 0$	양수 구간 미분 항상 1 — 층을 거쳐도 작아지지 않음

활성함수(실선)와 미분(점선) — 미분이 1 근처를 유지하는가?



여섯 가지 활성화함수(윗줄 sigmoid/tanh/ReLU, 아랫줄 Leaky ReLU/GELU/Swish)와 각 미분 — sigmoid 미분의 최댓값 0.25(점선)과 ReLU 미분의 0/1 양극화가 대비.

Sigmoid와 Tanh의 한계

Sigmoid — 두 가지 문제

- 1 **포화**: $|z| \gtrsim 3$ 이면 $\sigma'(z) < 0.05$ — 깊은 망에서 소실을 가속
- 2 **중심화 문제**: 출력이 항상 $(0, 1)$ 의 양의 값 $\Rightarrow$ 다음 층의 가중치가 **동일 방향**으로 움직이는 경향 $\Rightarrow$ 비대칭 골짜기, 학습 느려짐

Ch.2의 로지스틱회귀에서는 확률 해석 때문에 시그모이드가 **옳지만**, 은닉층에서는 확률 해석이 불필요한데도 두 불이익만 받음.

Tanh — 시그모이드를 -1 방향으로 중심화

$$\tanh(z) = 2\sigma(2z) - 1$$

- 출력 $(-1, 1) \Rightarrow$ 중심화 문제 **해소**
- 미분 최댓값 $1 = \text{시그모이드}(0.25)$ 의 **4배**
- 1990년대 은닉층의 **사실상 표준**
- 그러나 $|z| \gtrsim 3$ 에서 여전히 포화 ($0.985 \rightarrow \text{미분} \approx 0.03$) — **깊이**에는 부족

ReLU: 2012년 이후 은닉층의 사실상 표준



- $f(z) = \max(0, z)$ — 미분이 $z > 0$ 에서 정확히 1
- 음수 구간 출력이 정확히 0 $\Rightarrow$ 희소(sparsity)

자주 하는 실수: 로지스틱회귀의 습관으로 은닉층에 시그모이드를

확률 해석이 필요한 것은 **출력층**뿐. 은닉층의 기본값은 **ReLU 계열**, 출력층은 **문제 형태에 맞게**:
회귀 $\rightarrow$ 항등, 이진분류 $\rightarrow$ 시그모이드, 다중분류 $\rightarrow$ softmax.

Dying ReLU — ReLU의 아킬레스건

- $z < 0$ 일 때 미분 0 — 부활 불가



학습률 0.45: ReLU 97% vs Leaky 0%

ReLU 계열 변형 (2013년경부터)

죽는 뉴런을 숨을 쉰다로 만든 것

함수	정의	한 줄 설명
Leaky ReLU	$\max(0.01z, z)$	음수 미분 0.01 — 죽지 않고 “숨 쉰다”
ELU	$\min(0, \alpha(e^z - 1))$	음수 구간 $-\alpha$ 로 완만 — 미분 0이 아님
Softplus	$\log(1 + e^z)$	ReLU의 매끄러운 근사 — $\text{softplus}' = \sigma$
Swish (SiLU)	$z \cdot \sigma(z)$	$z < 0$ 에서 작은 음수 허용 — ReLU보다 부드럽고, 깊은 망에서 손실 더 낮음 (2017)
GELU	$z \cdot \Phi(z)$	“ z 가 얼마나 양수적인가”의 확률로 가중 — 트랜스포머(GPT/BERT)의 표준 은닉층 활성화함수 (Week 12)

가중치 초기화: 0이 왜 치명적인가

- 0 초기화 시 대칭이 영원히 안 깨짐

기준: 활성화값의 2차 모멘트 $\mathbb{E}[a^2]$ 를 층을 거치며 보존

$z_l = \sum_i w_{li} a_{l-1,i}$, w 가 $\mathbb{E}[w] = 0$, 분산 σ_w^2 이면:

$$\mathbb{E}[z_l^2] = n_{l-1} \sigma_w^2 \mathbb{E}[a_{l-1}^2] \quad (n_{l-1} = \text{fan-in})$$

이를 1로 $\Rightarrow \sigma_w = 1/\sqrt{n_{l-1}}$ = **Xavier (Glorot, 2010) 초기화**.

He 초기화: ReLU가 버리는 $\frac{1}{2}$ 을 2배로

- ReLU 2차 모멘트 절반
- He 초기화: 분산 2배

조합	승수	해석
ReLU + Xavier	0.499	매 층 정확히 $\frac{1}{2} \rightarrow 10$ 층 후 $0.5^{10} \approx 10^{-3}$ (소실)
ReLU + He	0.998	$\frac{1}{2} \times 2 = 1$, 보존 (안정)
tanh + Xavier	0.393	선형 근사(1)보다 작음 — 포화로 추가 압축

초기화 요약 + “표준편차를 감으로”의 대가

초기화	표준편차	잘 맞는 활성화함수	핵심 아이디어
Xavier (2010)	$1/\sqrt{\text{fan-in}}$	tanh, sigmoid, linear	$\mathbb{E}[a^2]$ 를 1:1 보존 (선형 가정)
He (2015)	$\sqrt{2/\text{fan-in}}$	ReLU 계열	ReLU가 버리는 ½을 2배로 보상


$\sigma = 1.0$: $1.002 \rightarrow 34 \rightarrow 1.6 \times 10^3 \rightarrow \dots \rightarrow 1.1 \times 10^{17}$ (폭발)

$\sigma = 0.01$: $1.002 \rightarrow 3.4 \times 10^{-3} \rightarrow \dots \rightarrow 1.1 \times 10^{-23}$ (소실)

He ($\sigma \approx 0.141$): $1.002 \rightarrow 0.688 \rightarrow 0.650 \rightarrow 0.759 \rightarrow \dots \rightarrow 1.114$ (안정)

세 가지 초기화의 “운명”이 그림으로

초기화 표준편차 → 활성화 분산의 운명 (폭 100 ReLU 10층, seed=0)



- $\sigma = 1.0$: 층마다 약 30배씩 부풀어 10^{17} (**폭발** → 그래디언트 폭발)
- $\sigma = 0.01$: 약 300배씩 줄어 10^{-23} (**소실** → 학습 멈춤)
- **He**: 0.65~1.5로 안정

주목할 세부: He도 정확히 1이 아니라 0.65~1.5 사이를 **방향** — “½ 보상”이 정규분포 가정 하의 근사이므로 완전하지 않다. 이 “마지막 여정”의 미세 스케일 드리프트를 학습 중에도 붙잡아 주는 것이 9.3 BatchNorm.

큰 그림: 그래디언트를 살리는 세 라인 방어선

- ① **활성함수**: 미분이 1 근처를 유지하는 것을 고른다 (ReLU 계열) → “할인율” 자체를 낮춤
- ② **초기화**: 각 층의 입출력 스케일(분산)을 보존 (Xavier/He) → 시작점부터 “할인율 × 레버”가 1 근처로 맞춤
- ③ **정규화**: 스케일 유지

연쇄법칙 곱 1 근처 유지

실험: “활성함수 + 초기화” 실패의 두 얼굴

구성	결과
tanh (Xavier)	ep 0: loss=0.3796 → ep 50: loss=NaN (폭발 — 발산)
ReLU (He)	ep 0: loss=0.4453 → ep 1500: loss=0.2500 (정체 — 0.5 상수 예측)

- tanh: 그래디언트 **폭발** → NaN — “무언가가 터졌다”는 **명확한** 신호
- ReLU: 0.2500 = “라벨 평균 $\bar{y} = 0.5$ 를 상수로 예측”의 MSE — **가중치가 하나도 학습되지 않은 상태와 정확히 같은 손실**
- “loss가 0.25로 수렴했다”고 보고하면 성공처럼 보임 — 전형적 **정체(stagnation)** 실패

확인 문제 (9.2)

- ① **계산.** 20층 시그모이드, 각 층 $\sigma'(z_l) \leq 0.25$ 이면 그래디언트는 $(1/4)^{20} = 2^{-40} \approx 9.1 \times 10^{-13}$ — 1조 분의 1의 1%도 안 됨. 왜 “실제” 감소는 이 값과 정확히 같지 않은가? (힌트: 곱에는 σ' 만이 아니라 W_l 도 — $\|W_l\| > 1$ 이면 보상, < 1 이면 추가 감소)
- ② **코딩.** `he_init_std` = $\sqrt{2/\text{fan-in}}$, `xavier_init_std` = $1/\sqrt{\text{fan-in}}$, `e2_out` 완성. 검증:
`e2_out(1, 100, he, relu)` ≈ 1.0 (보존), `e2_out(1, 100, xavier, relu)` ≈ 0.5 (소실),
`e2_out(1, 100, he, tanh)` ≈ 2.0 (선형 근사 매 층 2배).
- ③ **개념.** 폭 $100 \rightarrow 100 \rightarrow 100$ ReLU에 Xavier(0.1)로 초기화, 10층 반복 시 $\mathbb{E}[a^2]$ 는 $0.5^{10} \approx 0.001$ — 소실인가 폭발인가? 그리고 He가 “2”를 왜 곱하는지 ReLU의 어떤 성질에서 오는지 한 문장으로.

자주 묻는 질문 (9.2)

- **Q. ReLU 미분이 0/1인데 왜 “완전히” 안 되나?** 곱의 인자가 σ' 하나뿐이 아님: (1) W_l 크기가 나쁘면 ReLU여도 소실/폭발 — 초기화의 역할, (2) $z < 0$ 이면 미분 0이라 죽은 뉴런은 영구히 기여 0 — ReLU 변형이 보완, (3) 학습 도중 스케일이 다시 흐름 — BatchNorm의 역할. **“활성함수+초기화+정규화” 세 라인이 함께 작동해야 해결.**
- **Q. 프레임워크 기본값이면 초기화 신경 안 써도 되나?** 전형적 구조(완전연결 ReLU)에는 맞다 — PyTorch 기본값이 Xavier/He. 하지만 (a) 스킵 커넥션/레지듀얼, (b) 커스텀 층 (합성곱, LSTM 셀)에서는 “fan-in”이 명확히 정의되지 않아 기본값이 적용 안 됨. “학습이 안 된다/발산한다”를 디버깅할 때 **첫 질문은 항상 “각 층의 그래디언트·활성 노름을 재보라”**.
- **Q. 출력층 활성화함수는? 문제 형태가 결정:** 회귀 → 항등(MSE 짝), 이진분류 → 시그모이드(교차엔트로피 짝), 다중분류 → softmax(Week 17 언어모델에서 재회).
- **실습 노트북:** 10층 시그모이드 $553 \times$ 감소, 세 초기화의 분산 갈림, dying ReLU 97%, 활성화함수 6종 비교, 7층 XOR tanh+Xavier(NaN) vs ReLU+He(0.25) vs Adam(수렴).

9.3 정규화 기법과 학습률 스케줄링

과적합과 신경망 전용 정규화

- **과적합**: 학습 데이터는 완벽히 맞히는데 새 데이터에서 성능 저하

Dropout

- 학습 시 매 스텝마다 일부 뉴런을 확률 p 로 무작위로 꺼버림
- 뉴런 간 **공적응(co-adapt)**을 억제 — 특정 뉴런에만 의존하는 대신 **견고한(robust)** 특징 학습

Batch Normalization (BN)

- 각 층의 입력을 **미니배치** 단위로 평균 0, 분산 1로 정규화, 이후 학습 가능한 γ, β 를 다시 곱·추가
- **internal covariate shift** 감소 → 학습이 더 빠르고 안정적

Dropout 코드: masking + 스케일 보정

```
def dropout(activations, p, training):  
    if not training:  
        return activations  
    import random  
    return [0.0 if random.random() < p else a / (1 - p)  
            for a in activations]
```

왜 $/(1 - p)$ 로 스케일을 보정하는가


학습 때 평균적으로 뉴런의 $(1 - p)$ 만 살아있으므로, 추론 시 전체 뉴런을 다 쓰는 것과 기댓값을 맞추기 위함 (inverted dropout).

Dropout: 앙상블 관점 — 2^N 개의 서브네트워크


- 2^N 개의 서브네트워크 존재
- 파라미터 공유로 앙상블 이득

Dropout: 매 전파마다 다른 은닉 유닛을 끄 (파라미터는 공유)


전파 #1: 다른 서브네트워크



전파 #2: 다른 서브네트워크



전파 #3: 다른 서브네트워크



왜 이것이 “과적합 억제”인가

뉴런이 서로의 존재를 전제로 학습(co-adapt)하지 못하게 됨 — “나만 잘하면 돼”가 아니라 “**나를 꺼놔도 팀이 돌아가야 하니까**”

$1/(1-p)$ 보정이 정확히 보존하는 것

- **보정 시 학습 기댓값이 추론값과 같음**

Dropout: 그림 + 자주 하는 실수




Figure 1: Dropout Neural Net Model. **Left:** A standard neural net with 2 hidden layers. **Right:** An example of a thinned net produced by applying dropout to the network on the left. Crossed units have been dropped.

posterior probability given the training data. This can sometimes be approximated quite well for simple or small models (Xiong et al., 2011; Salakhutdinov and Mnih, 2008), but we would like to approach the performance of the Bayesian gold standard using considerably less computation. We propose to do this by approximating an equally weighted geometric mean of the predictions of an exponential number of learned models that share parameters

(a) 표준 신경망 vs (b) 드롭아웃 적용 “얇아진”
신경망 — 훈련 중 랜덤 제거되는 유닛 (원 논문
Figure 1).

자주 하는 실수: 추론 때도 `model.train()`을
켜둔 채

PyTorch는 `.train()` 모드에서만 masking을 켜고,
`.eval()`에서 끄고 $(1 - p)$ 스케일로 동작.
`model.eval()`을 잊으면 **매번 다른 예측 + 값이**
 $(1 - p)$ 배 축소된 “학습용” 분포 → 정답률에
미치고도 정확도가 이상하게 뚝. “테스트마다
결과가 달라지는” **정석 원인.**

검증/추론 루프는 항상 with `torch.no_grad(): model.eval();`
...로 감싼다.

Batch Normalization: 각 층 입력을 매 스텝 재조정

BatchNorm (Ioffe–Szegedy, 2015): 각 층의 **입력**을 미니배치 단위로 평균 0, 분산 1로 정규화한 뒤, **학습 가능한** 스케일·시프트를 다시 붙임:

$$\hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad \text{출력} = \gamma \hat{x} + \beta$$

- μ_B, σ_B^2 : 그 미니배치의 평균·분산, γ (스케일)· β (시프트): 학습되는 파라미터


BN이 학습을 빨리 하는 이유 — 그리고 한 발 더

- BN은 각 층 입력을 매 스텝 $(0, 1)$ 로 재설정

한 발 더 정직하게

원 논문은 속도의 주된 원인을 “internal covariate shift 감소”로 꼽았으나, 후속 분석(Santurkar 등, 2018)은 손실함수의 **조건 개선(landscape 매끄러워짐)**이 진짜 주효 요인이라고 보정. 둘 다 사실 — “분포 안정화”는 가장 쉬운 직관.

BN 그림 + 이중 모드(학습 vs 추론)



BatchNorm 유무에 따른 MNIST 학습 수렴 속도 (원 논문 Figure 1) — BN이 더 큰 학습률로 적은 스텝에 고 정확도 도달.

꼭 알아야 할 세부: 이중 모드

학습 때는 **현재 미니배치**의 μ_B, σ_B^2 사용. 추론 때는


- 1 배치가 없을 수 있음 (batch size = 1)
- 2 한 배치 통계는 그 배치만의 “요행/사고” 포함

⇒ 학습 중 **러닝 평균·분산**(지수 이동 평균)을 계속 기록해 두고, 추론 때는 그 누적된 통계를 사용.

“학습/추론 시 통계가 다르다”는 사실은 dropout의 `.train()/.eval()`과 **같은 범주의 함정** — BN을 직접 구현할 때 가장 많이 틀리는 부분.

BN의 한계: 작은 배치 — LayerNorm/InstanceNorm/GroupNorm

- **LayerNorm**: 배치가 아니라 **특징(feature) 축**을 정규화 — 시계열·NLP(트랜스포머, 작은 배치/변동 길이) 표준
- **InstanceNorm**: batch를 무시, 샘플·채널 단위 (생성 모델)
- **GroupNorm**: 채널을 그룹 단위로 묶어 정규화 — batch size에 의존하지 않음



“BN을 쓰면 무조건 좋은가?”

배치가 충분히 큰 분류/회귀 CNN에서는 대체로 Yes, 그렇지 않은 곳에서는 LayerNorm 계열.

가중치 감쇠: Week 6의 L2가 최적화기로 바뀐 얼굴

- **가중치를 0 방향으로 살짝 당김**

- 예: $wd = 0.001, \eta = 1 \Rightarrow$ 스텝마다 0.999배 $\Rightarrow$ 1000스텝 뒤 $0.999^{1000} \approx 0.368 \approx 1/e$ (실행 검증)

= Week 6의 λ 가 **최적화 규칙으로 재포장**된 것.

L2 페널티 vs “해결된(decoupled)” weight decay

L2 페널티

$$w \leftarrow w - \eta (\nabla L + \lambda w)$$

손실에 $\lambda \|w\|^2$ 를 붙여 그래디언트에 λw 를 포함.

- ∇L 이 w 의 **선형 함수**(이차 손실)이면 두 갱신이 **숫자적으로 일치** (이차 손실, $\eta = 0.1$, $wd = 0.01$ 한 스텝: 두 방식 모두 정확히 **0.99880000** — 실행 검증)

Adam에서는 L2와 weight decay가 다름


해결된 weight decay (AdamW 방식)

$$w \leftarrow w - \eta \nabla L \quad \text{이후} \quad w \leftarrow (1 - \eta wd) w$$

손실 그래디언트만 내린 뒤 **곱셈**으로 줄임.

도구 지도: 어떤 문제에 어떤 도구


신경망 정규화·학습률 스케줄링 도구 지도 — '과적합'과 '학습 불안정' 두 문제별, 어떤 도구가 어떤 축을 푸는가



- 실무 두 축: (a) **과적합** (train 높고 val/test 뒤흔침), (b) **학습 불안정** (손실 안 줄거나 초기화·배치·lr에 예민)
- **과적합 문제면:** dropout + weight decay + 근본 해법인 **더 많은 데이터·증강**
- **느리다/불안정하면:** Batch/LayerNorm(분포 안정 → 큰 lr 가능) + **학습률 스케줄링**
- **“모두 쓰면 될까요?”: 아니** — BN과 dropout은 **둘 다** 약한 정규화 효과를 내, 과용 시 **과정규화(train·val 함께 떨어짐)**. 실무: 하나 추가 → val 곡선 확인 → 다음 추가.

학습률 스케줄링: 큰 lr으로 시작, 작은 lr으로 끝

- 초반 큰 α 로 빠르게, 후반 작게 정교하게
- 흔한 방식: **StepLR** (에폭마다 일정 비율로 감소),
코사인 스케줄 (부드러운 감소,
Loshchilov-Hutter 2016 SGDR)



골짜기에서 직접 확인 + 왜 “한 번에 큰 lr”이 위험한가

1차원 포물선 $L(w) = (w - 3)^2 + 0.5$, 시작 $w = 0$, 300스텝:


전략	결과
작은 lr 고정 (0.0072)	300스텝 뒤 $ w - 3 \approx 0.039$ — 바닥에 못 도착 (예산 소진)
0.08 (200스텝) $\rightarrow$ 0.0072 (100스텝)	$ w - 3 \approx 2 \times 10^{-15}$ — 도착

진동 직접 보기: 같은 포물선에 $\alpha = 0.9$ (최적 0.5 초과)로 1스텝 반복:

$$w : 0.0 \rightarrow 5.4 \rightarrow 1.08 \rightarrow 4.54 \rightarrow 1.77 \rightarrow 3.98 \rightarrow 2.21 \rightarrow 3.63 \rightarrow 2.50 \rightarrow \dots$$

큰 lr은 바닥에 못 붙는다

StepLR / 코사인 / warmup — 모양을 기억하자



고정 lr(회색 수평선) / StepLR(파랑 계단) / 코사인(빨강,
300에폭 동안 0.01 $\rightarrow$ 0으로 부드럽게).

- **StepLR**: step_size 에폭마다 $\alpha \leftarrow \gamma \alpha$. 예:
 $\alpha_0 = 0.01, \gamma = 0.5, \text{step}=50 \Rightarrow$
 $0.01 \rightarrow 0.005 \rightarrow 0.0025 \rightarrow 0.00125$
- **코사인**: $\alpha_t = \alpha_{\min} + \frac{1}{2}(\alpha_{\max} - \alpha_{\min})(1 + \cos(\pi t / T_{\max}))$
— 계단 뚝뚝보다 “lr의 공백기” 없음, 후반 수렴 매끄러움
- **warmup**: 처음 몇 에폭은 **아주 작은 lr**으로 시작해 점차 늘린 뒤 decay

초기 학습률 α_0 고르는 실무 기준

손실이 안정적으로 감소하는 가장 큰 lr

α	0.001	0.01	0.1	0.2	0.5
train acc	0.770	0.837	0.860	0.857	0.860
val acc	0.771	0.832	0.852	0.850	0.846

- “안정적으로 감소하는 가장 큰 lr” = 0.1~0.2, 스케줄링으로 후반에 줄이면 최적

실습: PyTorch로 정규화·스케줄링 적용 MLP

```
import torch, torch.nn as nn

class RegMLP(nn.Module):
    def __init__(self):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(2, 64), nn.BatchNorm1d(64), nn.ReLU(),
            nn.Dropout(0.3),
            nn.Linear(64, 64), nn.BatchNorm1d(64), nn.ReLU(),
            nn.Dropout(0.3),
            nn.Linear(64, 64), nn.BatchNorm1d(64), nn.ReLU(),
            nn.Dropout(0.3),
            nn.Linear(64, 1))
    def forward(self, x):
        return self.net(x).squeeze(-1)

opt = torch.optim.SGD(model.parameters(), lr=0.1)
sched = torch.optim.lr_scheduler.StepLR(opt, step_size=100, gamma=0.3)
# 학습루프안에서 : opt.step() 다음에 sched.step() 호출
```


make_moons(선형분리 불가능) 데이터, 64-64-64 은닉층, 300 에폭. 순서: Linear → BatchNorm → ReLU → Dropout — dropout을 BN보다 먼저 하면 미니배치마다 꺼지는 뉴런이 달라 BN의 평균·분산 계산 자체가 불안정해짐.

결과: “train이 함께 오른 정규화”

모델	train acc	val acc
일반 MLP (정규화·스케줄링 없음)	0.847	0.846
정규화 MLP (dropout + BN + StepLR)	0.870	0.846

- 정규화 모델이 train 정확도까지 더 높음
- val이 “떨어지지 않았다”는 것: 이 조합은 과정규화에 빠지지 않는 안전한 지점

dropout이 gap을 좁힌다 (숫자로)



학습 데이터만 150개(작게)로 제한한 moons, 64-64 MLP, 400에폭:

	train	val
평범한 MLP	0.920	0.844
dropout 0.5	0.913	0.846

gap: **0.076** → **0.067** — train·val 간격이 좁혀지고 val이 **오름**. “gap이 벌어지는 것 = 과적합”이라는 Week 4.1 신호를 dropout이 직접 좁혀줌.

BatchNorm이 활성화값의 흔들림을 없앤다 (숫자로)

구성	ep 0	ep 20	ep 40	ep 60	ep 80
BN 없음	0.437	0.557	0.693	0.920	1.084
BN 있음	0.595	0.576	0.580	0.577	0.591

- BN **없음**: 2층이 보는 활성화값이 **0.44** → **1.08로 2.5배** 미끄러짐 = 뒤층이 매번 다시 맞춰야 하는 internal covariate shift
- BN **있음**: **0.58 부근으로 안정**

“층의 입력 분포를 매 스텝 재설정한다”가 숫자로

이 표가 바로 9.2의 “BN이 활성화값을 $\mathcal{O}(1)$ 로 묶어 그래디언트 소실·폭발이 어려워진다”를 실증하는 숫자.

확인 문제 + 자주 묻는 질문 (9.3)

- **확인 1 ($1/(1-p)$ 의 불변성):** $a = (1, -2, 3, 4)$, $p = 0.5$ — “보정이 없으면 학습 기댓값이 $(1-p)$ 배 줄어 추론값과 어긋난다”를 **수식으로** 보이고, 보정 후 $E[\text{학습}] = \text{추론}$ 임을 확인.
- **확인 2 (BN 이중 모드):** 추론 시 BN이 **러닝 평균/분산**을 쓰고 현재 배치 통계를 쓰지 않는 이유(배치 부재, 배치 통계 노이즈) — dropout의 `.train()/.eval()`과 같은 범주의 함정임을 한 문장으로.
- **확인 3 (L2 vs weight decay):** 어떤 손실에서는 같고, Adam에서는 왜 다르고, 그래서 AdamW가 등장하는지.
- **확인 4 (스케줄링의 기하):** 포물선 $(w-3)^2$ 의 overshoot(진동)으로 “왜 큰 lr로 시작해 작은 lr로 끝내는가” — “최솟값 근처 큰 스텝 = 바닥 건너뛰기”.

FAQ: Dropout+BN 순서는 Linear $\rightarrow$ BN $\rightarrow$ ReLU $\rightarrow$ Dropout 권장. λ (Ch.6)는 “얼마나 단순해야 하는가”(손실함수)를, 스케줄은 “얼마나 빠르게/정교하게 찾아갈 것인가”(최적화 속도)를 조절 — 서로 다른 축. BN은 약한 정규화 효과가 있어 과적합이 심한(데이터 적은) 문제에서는 dropout도 함께. LayerNorm은 batch 축을 특징 축으로 — batch 작거나 시계열/순서 표준. weight decay + dropout은 흔히 함께, 단 한꺼번에 강하게 쓰면 **과소적합** — val 곡선으로 하나씩 강도 올리기. 스케줄링 없이는 “초반 큰 lr의 속도 + 후반 작은 lr의 정교함”을 **한 값으로** 잡을 수 없음.

이번 주차 정리

- ① **9.1 — 은닉층이 XOR의 벽을 넘는다:** 부등식 모순으로 단층 퍼셉트론의 한계를 보이고, 은닉층이 “직선으로 갈리는 새 공간”을 만든다. 역전파 = 연쇄법칙의 **재사용** (동적 프로그래밍) — 수치 미분으로 구현을 검증한다.
- ② **9.2 — 그래디언트는 “할인율의 곱”:** 층마다 $\sigma' \times W$ 를 곱해 깊어지면 지수적으로 0(소실)이거나 불어나 (폭발). 세 라인 방어: **활성함수(ReLU 계열) + 초기화 (Xavier/He) + 정규화(BatchNorm)**.
- ③ **9.3 — 학습을 실제로 끝내는 도구:** dropout(공적응 억제) · BatchNorm(분포 안정, 큰 lr 가능) · 가중치 감쇠(AdamW) · 학습률 스케줄링(초반 크게, 후반 작게, warmup).

다음 주 — Week 10. 합성곱 신경망 (CNN)

이번 강의 “일반부”(역전파, 활성화함수, 초기화, 정규화) 위에, **이미지의 특성에 맞는 “특수부”** — 합성곱층 — 를 올린다. 이번 장에서 세운 역전파·활성함수·초기화·정규화·스케줄링은 그 뒤의 모든 장(CNN→RNN→트랜스포머→LLM)에서 다시 쓰이는 도구다.