

CNN 기초와 응용

합성곱 · 출력크기 · FLOPs · 풀링 · 수용장 · ResNet · 탐지 · 분할 · 전이학습

Machine Learning 1 · 10주차

한국과학영재학교 (KSA)

Week 10

이번 주차 개요

이 주차를 마치면

- 합성곱 출력 크기를 패딩·스트라이드와 함께 손으로 계산하고, 파라미터 수·FLOPs로 “왜 합성곱이 효율적인가”를 숫자로 설명
 - 합성곱·풀링이 “좁아지고 깊어지는” 구조를 만드는 역할을 설명하고, LeNet→ResNet까지 스킵 연결이 왜 깊은망을 가능하게 하는지 서술
 - 탐지·분할 헤드(R-CNN, IoU/NMS, 1×1 합성곱, U-Net)와 전이학습(특징 추출 vs 미세조정)이 언제·왜 유리한지 판단
-
- **10.1 합성곱, 출력 크기, 파라미터 수와 FLOPs** — MLP의 한계에서 출발해 파라미터 공유로 이어지는 “한 연산”을 계산한다
 - **10.2 풀링과 전형적인 CNN 구조** — 그 연산을 “구조”로 쌓고, 깊이의 한계에 부딪혀 스킵 연결(ResNet)을 만난다
 - **10.3 분류를 넘어서: 탐지, 분할, 전이학습** — 그 구조를 “새 문제”에 다시 쓴다

이 장을 관통하는 하나의 실: “재사용” — 새로 배울 것을 최소화하고, 이미 배운 것을 어디든 다시 쓰자.

10.1 합성곱, 출력 크기, 파라미터 수와 FLOPs


MLP로 이미지를 다루면 안 되는 이유

- 200×200 흑백 이미지만 **4만 개의 입력**
- 첫 은닉층 뉴런 1000개면 그것만으로 **4천만 개의 가중치**
- “고양이가 왼쪽 위에 있든 오른쪽 아래에 있든 같은 고양이”라는 사실을 **전혀 활용 못함**


이미지의 공간 구조(위치 불변성)를 활용하려면?

그림으로: 이미지를 벡터로 펼치면

원본 이미지 (4×4)



1칸 오른쪽으로 이동



길이 16 벡터

펼치기



펼치기



16개 중 8개 원소가 바뀜

같은 “세로선” 패턴이 1칸만 오른쪽으로 이동해도, 펼친 벡터 16개 원소 중 절반이 달라진다 — MLP는 이 둘을 전혀 다른 입력으로 본다.


합성곱: 작은 필터를 온 이미지에 재사용

- 합성곱: 필터 슬라이드 및 원소별 곱의 합
- 필터 값은 학습 대상 파라미터

파라미터 공유 (parameter sharing)

이 재사용 덕분에 MLP보다 훨씬 적은 파라미터로 훨씬 큰 이미지를 다룰 수 있다.

그림으로: 필터가 슬라이드하며 곱-합을 계산



파란 실선 = 현재 위치, 금색 점선 = 필터가 슬라이드할 다른 위치들

파란 테두리가 현재 필터 위치, 금색 점선은 필터가 이어서 슬라이드할 다른 위치들 — 같은 3×3 필터가 입력 위 **모든** 위치에서 곱셈-합을 반복한다.

conv2d 직접 구현해보기

```
def conv2d(image, kernel):
    img_h, img_w = len(image), len(image[0])
    k = len(kernel)
    out_h, out_w = img_h - k + 1, img_w - k + 1
    output = [[0.0] * out_w for _ in range(out_h)]
    for i in range(out_h):
        for j in range(out_w):
            total = 0.0
            for di in range(k):
                for dj in range(k):
                    total += image[i+di][j+dj] \
                        * kernel[di][dj]
            output[i][j] = total
    return output
```

- 입력 $n \times n \rightarrow$ 출력 $(n - k + 1) \times (n - k + 1)$
- 각 위치마다 필터와 원소별 곱의 합
- “합성곱층”이라는 용어는 후쿠시마의 네오코그니트론 (1980)에서 처음 사용

“합성곱”이라는 이름의 뜻: 뒤집기는 어디로?

$$(f * k)(i) = \sum_j k(j) f(i - j)$$

코드는 상관(correlation)이고 합성곱이 아님

- ① 학습 대상이므로 표현 가능한 함수 집합은 정확히 같다

실무 규칙

코드와 수식에서는 “각 위치의 원소별 곱의 합”을 그냥 “합성곱”이라고 쓰면 된다 — 이 분야 전체가 그렇게 쓰고 있다.

손으로 한 번: 3×3 필터가 5×5 를 스캔

5×5 흑백 이미지(열 2에 흰선, 밝기 1, 배경 0)에 중심 열만 1인 3×3 필터(“수직선 탐지기”의 가장 단순한 버전):

		0	1	2	3	4
입력 5×5	0	0	0	1	0	0
	1	0	0	1	0	0
	2	0	0	1	0	0
	3	0	0	1	0	0
	4	0	0	1	0	0
필터 3×3	0	1	0			
	0	1	0			
	0	1	0			

출력 = $5 - 3 + 1 = 3$ 0 |므로 3×3

	j=0	j=1	j=2
i=0	0	3	0
i=1	0	3	0
i=2	0	3	0

중심 위치 ($i=1, j=1$) 직접 계산 — 필터가 이미지의 중심 3×3 영역(행 1~3, 열 1~3)을 덮는다:

$$\begin{aligned} & 0 \cdot 0 + 1 \cdot 1 + 0 \cdot 0 \text{ (행 1)} \\ & + 0 \cdot 0 + 1 \cdot 1 + 0 \cdot 0 \text{ (행 2)} \\ & + 0 \cdot 0 + 1 \cdot 1 + 0 \cdot 0 \text{ (행 3)} \\ & = 0 + 1 + 0 + 0 + 1 + 0 + 0 + 1 + 0 = 3 \end{aligned}$$


세 가지를 한꺼번에 보는 손계산

- ① 어느 위치에서든 같은 가중치가 같은 패턴에 반응 — 파라미터 공유의 구체적 모습
- ② 수직선은 원본 스케일 그대로 전달

“규모를 초월한” 특징의 기반

마지막 점이 합성곱이 스케일에 무관한 특징을 만드는 기반이며, 10.2~10.3에서 풀링·수용장이 이 아이디어를 확장한다.

그림으로: 파라미터 공유의 실제 모습



세 위치(파랑·빨강·황토) 모두 같은 필터를 재사용 --- 위치마다 새로 배우지 않는다

입력의 세 위치(파랑·빨강·황토)에서 **같은** 3×3 필터가 재사용되어, 출력 3×3 의 대각선에 “세로선 반응” 값 3이 그대로 나타난다.

출력 크기 공식: 미적분이 아니라 “세는 문제”

입력 $n \times n$, 필터 $k \times k$, 패딩 p (가장자리에 0을 두르는 픽셀 수), 스트라이드 s (필터가 한 번에 이동하는 칸 수)일 때:

$$n_{\text{out}} = \left\lfloor \frac{n + 2p - k}{s} \right\rfloor + 1$$

- s 로 이동하면 시작 위치는 $0, s, 2s, \dots$ 중 $\leq n - k$ 인 것들 — 항의 개수 $\lfloor (n - k)/s \rfloor + 1$

패딩 · 스트라이드 바꾸며 직접 세어보기


8×8 입력, 3×3 필터 ($p = 0$), 스트라이드만

	s	시작 위치	개수
바꾸며:	1	0, 1, 2, 3, 4, 5	6
	2	0, 2, 4	3
	4	0, 4	2

직접 세는 것과 $\lfloor (8 - 3)/s \rfloor + 1$ 이 $s \neq 1$ 에서도 일치 — $s=4$: “5칸을 4칸씩 건너뛰면 0과 4 두 곳”. 수직·수평 방향은 독립적 — 사각형 입력이면 출력도 사각형.

명명: padding=”valid” = 패딩 없음 (필터가 다 들어가는 위치만), padding=”same” = k 가 홀수일 때 $p = (k - 1)/2$ 로 $n_{out} = n$.

28×28 input, 3×3 filter: valid filter starting positions (red ticks) = output size n_{out}



같은 28×28, $k=3$ 을 1D로 줄여 (p, s) 조합 4가지 — 회색은 패딩, 각 틱(tick)은 유효한 필터 시작 위치 하나. 틱의 개수가 곧

n_{out} : $p=0, s=1 \rightarrow 26 \cdot p=1, s=1 \rightarrow 28$ (same) ·

$p=0, s=2 \rightarrow 13 \cdot p=1, s=2 \rightarrow 14$. 네 숫자 모두

$\lfloor (28 + 2p - 3)/s \rfloor + 1$ 로 그대로 계산된다.

스트라이드 $s = 2$ 가 실제로 하는 일

- 1D에서 길이를 반으로, 2D에서는 가로·세로 둘 다 반으로
- $\Rightarrow$ 공간 면적은 **1/4**로 줄어든다
- 예: 224×224 에 $k=3, p=1, s=2$ 이면 $n_{\text{out}} = \lfloor (224 + 2 - 3)/2 \rfloor + 1 = \mathbf{112}$

AlexNet(2012)의 첫 합성곱 층

정확히 이 설정($224 \rightarrow 112$)으로 다운샘플링한다.

파라미터 수 계산

합성곱 층 파라미터 수 공식

$$\text{params} = (k \times k \times C_{\text{in}} + 1) \times C_{\text{out}}$$

FLOPs는 “파라미터 수”와는 다른 질문이다.

- 파라미터 수 = “얼마나 많은 숫자를 저장해야 하는가”
- FLOPs = “몇 번의 곱셈-덧셈을 하는가” (속도)

FLOPs 공식: n_{out}^2 이 곱해진다

$$\text{FLOPs} \approx n_{\text{out}}^2 \times C_{\text{out}} \times (k \times k \times C_{\text{in}})$$

- 파라미터 수 공식과 거의 똑같이 생겼지만, **파라미터 수엔 없던** n_{out}^2 이 곱해진다

$$\text{FLOPs} = 222^2 \times 1 \times 9 = 49,284 \times 9 = 443,556 \text{ (약 44만 MAC)}$$

손계산 표: 미니 LeNet 세 층의 비용

28×28 층	흑백을 세 연산	합성곱 층 + 한 풀링으로 줄여가는 작은 네트워크:	출력 크기	파라미터	FLOPs
입력	28×28×1	—	—	—	—
conv 1	k=3, $C_{out}=4$, p=0, s=1	26×26×4	40	24,336	
conv 2	k=3, $C_{in}=4$, $C_{out}=8$, p=0, s=1	24×24×8	296	165,888	
pool	2×2 max pooling (s=2)	12×12×8	0	(비교 연산 864회)	
conv 3	k=3, $C_{in}=8$, $C_{out}=16$, p=0, s=1	10×10×16	1,168	115,200	
합계		10×10×16	1,504	305,424	

conv 2 FLOPs 직접 계산

표를 읽는 법: “재고” vs “유량”, MLP 비교


① FLOPs는 n_{out}^2 에 비례, conv 2가 최대

완전연결 대체 시 파라미터 835배, FLOPs 4.1배

“재고” vs “유량”

파라미터는 “재고”(층당 고정 저장), FLOPs는 “유량”(출력 위치마다 반복되는 계산) — “한 번에” 보는 대신 작은 패치를 재사용하는 합성곱이 약 0.12%의 파라미터, 1/4의 연산으로 같은 체적의 특징을 만든다 — 게다가 위치 불변성이라는 귀납적 편향까지 덤. 한쪽만 보고 설계하면 안 된다.

좁아지고 깊어지는 CNN



- 위 그림의 네트워크: $32 \times 32 \times 3 \rightarrow$ Conv 5×5 (6ch) $\rightarrow$ Pool $2 \times 2 \rightarrow$ Conv 5×5 (16ch)
- 10.2절 전체를 관통하는 “**좁아지고 깊어진다**” 경향의 원형

합성곱을 거칠 때마다 공간 크기(가로 $\times$ 세로)는 줄고 채널 수(깊이)는 늘어나는 모습.

자주 하는 실수: 공식이 걸리는 두 곳

실수 1: “패딩은 출력에 더해지는 거다”

- $n=28, k=3, p=1, s=1$ 의 출력을 “ $28 + 2 = 30$ ” 이라고 — 패딩 픽셀이 출력을 만든다고 오해
- **패딩은 출력 위치를 새로 만들지 않는다** — “벗어나갈 것 같았던 위치”(필터가 원본 경계를 넘는 위치)를 **유효하게 만들어 주는 것**뿐
- 출력 = “패딩된 입력 안에서 필터가 완전히 들어가는 위치 수”
 $= \lfloor (28 + 2 - 3)/1 \rfloor + 1 = 28$
- 패딩의 정당한 용도는 “**same padding으로 크기를 유지**”, “출력을 키우는 것”이 아니다

연산량을 비교할 때는 “파라미터 몇 배”가 아니라 공식으로 직접 계산. (1×1 합성곱은 공간 크기 그대로 두고 채널만 선형 결합 — “경량으로 채널을 섞는다”는 용도로 VGG·ResNet 중간층에서 실전에 많이 쓰인다. 10.2에서 다시 만난다.)

실수 2: “FLOPs = 파라미터 $\times$ 고정 계수”

- FC에서는 샘플당 FLOPs $\approx 2 \times$ 파라미터라, 이 습관을 합성곱에도 적용하기 쉬움
- 그러나 **합성곱의 FLOPs/파라미터 비율은 n_{out}^2 이며 층마다 다름**
- 같은 224×224 , 64 출력 채널: $3 \times 3 = 640$ params, $\approx 2,839$ 만 MAC vs $1 \times 1 = 128$ params, ≈ 321 만 MAC
- 파라미터 비율 **5배**인데 FLOPs 비율은 **약 8.8배**

실습: 세 공식을 코드 한 페이지로

```
def out_size(n, k, p=0, s=1):  
    return (n + 2*p - k) // s + 1  
    # 1D 한방향의 출력 크기  
  
def conv_cost(n_in, k, c_in, c_out,  
              p=0, s=1):  
    n_out = out_size(n_in, k, p, s)  
    params = (k*k*c_in + 1) * c_out  
    flops = n_out**2 * c_out \  
            * (k*k*c_in)  
    return n_out, params, flops  
  
print(conv_cost(28, 3, 1, 4))      # (26, 40, 24336)  
print(conv_cost(26, 3, 4, 8))      # (24, 296, 165888)  
print(conv_cost(12, 3, 8, 16))     # (10, 1168, 115200)
```

- 합계 **1,504** — 손계산 표의 파라미터 합계와 정확히 일치
- “수식 → 코드 → 표”가 하나의 계산을 **세 번** 확인
- 세 공식(n_{out} , params, FLOPs)은 **독립이 아니라** 같은 $(n, k, p, s, C_{in}, C_{out})$ 에서 나란히 계산되는 **하나의 패키지**

핵심 공식 한눈에

항목	공식	무엇을 재나
출력 크기	$n_{\text{out}} = \lfloor (n + 2p - k)/s \rfloor + 1$	합성곱 후 공간 크기 (가로/세로 각각)
파라미터	$(k^2 C_{\text{in}} + 1) C_{\text{out}}$	저장해야 할 가중치 수 (bias 포함)
FLOPs	$n_{\text{out}}^2 C_{\text{out}} k^2 C_{\text{in}}$	곱셈-덧셈 횟수 (출력 위치마다 반복)
관계	$\text{FLOPs} \approx (\text{bias} \text{ \& params}) \times n_{\text{out}}^2$	“재고”와 “유량”의 차이

세 공식은 하나의 패키지다 — “재사용”이 만드는 효율의 숫자.

FAQ 1·2: 필터 크기와 파라미터 수

Q. 필터 크기는 왜 보통 홀수(3×3 , 5×5)?

정확히 **중심 픽셀이 하나** 있어서 “어느 픽셀을 중심으로 보는가”가 자연스럽다. 짝수(2×2)는 중심이 픽셀 사이에 걸쳐서 대칭 해석이 어렵다. 실전에서는 **3×3 을 여러 겹** 쌓는 것이 더 널리 쓰인다 — 3×3 두 개는 5×5 하나와 **같은 수용장을 18 vs 25** 파라미터로 만든다.

Q. 파라미터가 적으면 항상 좋은 건가?

학습이 빠르고 과적합(Week 6) 위험은 줄지만 **표현력도 줄어든다** — Week 4.1의 편향-분산 트레이드오프가 그대로 적용. CNN이 이미지에서 유리한 이유는 “파라미터가 적어서”가 아니라, 그 적은 파라미터가 **위치 불변성**이라는 이미지의 실제 구조에 맞는 **귀납적 편향(inductive bias)**을 인코딩하고 있기 때문이다.

FAQ 3: 스트라이드 2 vs 2×2 풀링

둘 다 면적을 $1/4$ 로 줄이는데, 세 가지 차이:

- ① max pooling vs stride-2 합성곱
- ② 풀링 vs stride 합성곱 자유도

FAQ 4·5: FLOPs의 bias, PyTorch 확인

Q. FLOPs 공식에 bias의 “+1”이 없는데?

bias는 출력 위치당 **한 번만** 더해지는 값 — 그 비용 $n_{\text{out}}^2 C_{\text{out}}$ 은 주항 대비 **1 차수 낮은 차수 항**(일반 3×3 층에서 약 10% 미만). 표준 FLOPs 관례는 곱셈-덧셈(MAC) 수로 세고 bias를 무시.

Q. PyTorch에서 28×28 입력의 3×3 conv 출력이 정말 26×26 인가?

맞다 — `nn.Conv2d(1, 4, 3)`(기본 `padding=0, stride=1`)의 출력은 26×26 , `nn.Conv2d(1, 4, 3, padding=1)` 는 28×28 . PyTorch의 `padding` 인자는 이 절 공식의 **한 번당 패딩 수 p** 그대로(총 $2p$). $p = (k - 1)/2$ 의 `same-padding` 트릭도 똑같이 동작. (참고: 26×26 에 또 $p=0$ 의 3×3 을 쓰면 24×24 — 짝수/홀수가 층을 지나며 바뀌지만 “크기 장부” 문제일 뿐 오류가 아님.)

확인 문제 (10.1): 숫자 네 개

- ① **출력 크기.** 56×56 , $k=3$, $p=1$, $s=2 \rightarrow \lfloor (56 + 2 - 3)/2 \rfloor + 1 = \mathbf{28}$. (224→112 다운샘플링의 2배 크기 버전.)
- ② **파라미터·FLOPs.** 28×28 ($C_{in}=16$), 5×5 , $C_{out}=32$, $p=0$, $s=1$: (a) $n_{out} = 24$, (b) $(25 \times 16 + 1) \times 32 = \mathbf{12,832}$, (c) $24^2 \times 32 \times (25 \times 16) = \mathbf{7,372,800}$
- ③ **MLP 비교.** 앞 네트워크(1,504 / 305,424)와 같은 체적 FC(784→1,600) — FLOPs 비율은 “4배 안팎”인데 **파라미터 비율은 훨씬 큰 이유**를 한 문장으로
- ④ **실수 찾기.** “ 28×28 , $k=3$, $p=1$, $s=2 \rightarrow (28 - 3 + 1)/2 + 2 = 15$ ” — 정답은 **14**. 패딩은 스트라이드로 나누기 전에 입력에 더해져야 한다: $\lfloor (28 + 2 - 3)/2 \rfloor + 1 = 14$

10.2 풀링과 전형적인 CNN 구조

최대 풀링: 이동에 둔감한 특징

최대 풀링은 2×2 영역마다 최댓값 하나만 남긴다

- 작은 이동에 둔감한 특징

$$\text{maxpool} = \begin{bmatrix} 1 & 3 \\ 1 & 4 \end{bmatrix} \quad (\text{원본과 1픽셀 이동, 동일})$$

“약간 세로선”은 살아남고, “정확히 어느 픽셀”은 버려진다

핵심

“여기에 (대략) 세로선 같은 패턴이 있다”는 정보는 **살아남고**, “정확히 어느 픽셀에”는 정보는 **버려진다**.

- 최대풀링이 이동 불변성을 “완벽히” 주진 않는다 (2픽셀 이상 움직이면 풀링 셀 경계를 건너며 달라질 수 있음)
- 하지만 **한두 픽셀의 미세한 위치 변동**에 대해 특징지도를 “부드럽게” 만들어주는 효과는 확실

그림으로: 최대폴링의 이동 불변성

2×2
최대폴링

2×2
최대폴링

원본 ("세로선" 열1)

1	0	2	1
1	0	3	1
1	0	4	1
1	0	2	1

1	3
1	4

1픽셀 오른쪽 이동 (열2)

1	1	0	2
1	1	0	3
1	1	0	4
1	1	0	2

1	3
1	4

동일

네 폴링 영역의 최댓값 (1, 3, 1, 4) --- 이동 전후 완전히 동일

교재 예시 그대로 — 세로선이 1픽셀 오른쪽으로 이동해도, 2×2 최대폴링 결과는 (1, 3, 1, 4) 로 **완전히 동일**하다.

평균 풀링과 전역 평균 풀링

평균 풀링(average pooling) — 같은 영역의 **평균**을 남긴다.

- 최대풀링이 “이 지역의 **최대 반응**이 얼마나 컸는가”를 묻는다면, 평균풀링은 “**평균 반응**”
- 질감(texture) 같은 **분포 정보**를 더 잘 유지
그러나 실전에서는 **최대풀링이 압도적으로** 널리 쓰인다 — 소수 강한 반응이 “이 특징이 있다”는 **증거**이므로.

전역 평균 풀링(global average pooling, GAP) — 극단: 채널 전체($h \times w$ 모든 위치)의 **평균**을 **하나만** 남겨 공간 차원을 **아예 없앴**.

- “ 16×16 특징지도를 펼쳐 256개 숫자”가 아니라 “이 채널의 **평균 반응 1개**”
- 마지막 **완전연결층의 파라미터를 대폭 줄이는** 용도 (아래 VGG16에서)


풀링의 효과: 해상도 대 계산 비용

- 뒤이어서 오는 모든 합성곱 층의 연산량을 $1/4$ 로 만든다
- 특징지도를 **2회** 풀링 $\rightarrow$ 공간 크기 $1/4$ (연산량 $1/16$), **3회** $\rightarrow 1/8$ ($1/64$)

왜 대형 CNN은 224×224 를 7×7 로 줄이는가

“이미지 전체의 맥락”을 판단하려면 공간 해상도가 그 정도면 충분하고, 남은 용량을 특징의 수(채널) 쪽에 쓰겠다는 설계 선택이다.

그림으로: 풀링 반복이 만드는 해상도-연산량 트레이드오프



풀링 2회면 공간 크기 1/4(연산량 1/16), 3회면 1/8(1/64) — 대형 CNN이 224를 7까지 줄이는 이유.

실습: 4×4 특징지도를 최대풀링으로

10.1절의 conv2d 코드와 같은 스타일로 최대풀링 직접 구현:

```
def max_pool(feature_map, pool_size=2):
    h, w = len(feature_map), \
        len(feature_map[0])
    out_h, out_w = h // pool_size, \
        w // pool_size
    output = [[0.0] * out_w for _
              in range(out_h)]
    for i in range(out_h):
        for j in range(out_w):
            block = [
                feature_map[
                    i*pool_size+di
                    [j*pool_size+dj]
                for di in range(pool_size)
                for dj in range(pool_size)]
            output[i][j] = max(block)
    return output

fm = [[1, 0, 2, 1],
      [1, 0, 3, 1],
      [1, 0, 4, 1],
      [1, 0, 2, 1]]
print(max_pool(fm, 2)) # [[1, 3], [1, 4]]
```

- “원본” 특징지도를 그대로 넣으면 $\begin{bmatrix} 1 & 3 \\ 1 & 4 \end{bmatrix}$
— 앞 계산과 정확히 일치
- 1픽셀 이동 버전도 같은 결과 — 둔감함이
코드로

자주 하는 실수: 풀링을 “특징 추출”로 오해

정리

풀링은 학습 파라미터가 없는 순수 다운샘플링 연산이다. “특징을 추출한다”는 표현은 **합성곱 층의 역할**, 풀링의 역할은 이미 학습된 특징지도를 (a) 공간 해상도를 줄이고, (b) 미세한 위치 변동에 둔감하게 만드는 것.

- 풀링을 너무 일찍, 너무 많이
- 풀링은 합성곱의 대안이 아니다

수용장: 뒤쪽 층이 “보게 되는” 원본 영역

각 층의 필터 크기 k_l , 스트라이드 s_l 일 때, l 번째 층 뉴런의 수용장 크기:

$$R_l = R_{l-1} + (k_l - 1) \cdot \prod_{j < l} s_j, \quad R_0 = 1$$

수용장 손계산 + 풀링이 스케일업하는 기제

입력 32×32 예:

층	연산	k	s	R_l
0	입력	—	—	1
1	Conv	5	1	$1+4 \cdot 1 = 5$
2	MaxPool	2	2	$5+1 \cdot 1 = 6$
3	Conv	5	1	$6+4 \cdot 2 = 14$


단 세 층 만에, 마지막 합성곱 뉴런은 원본의 14×14 영역(32×32 의 약 19%)을 “본다”.

- $3 \times 3, s=1$ 만 계속 쌓으면 $R_l = 1 + 2l$ 으로 선형
- 풀링($s=2$)을 한 번만 끼워도 그 뒤의 모든 확장이 2배 스케일업
- 10층만 쌓아도 수십 픽셀, 풀링을 섞으면 이미지 전체가 한 뉴런의 수용장

짜을 이룬다

합성곱(패턴 감지)이 “무엇을 보는가”를 학습하고,
풀링(수용장 확대·해상도 축소)이 “얼마나 넓은 시야로 보게 하는가”를 결정.

16개 층을 쌓아도: 풀링이 시야를 2배로



16개 층을 쌓아도 풀링 없이 스트라이드 1 합성곱만 쌓으면 수용장이 33px(입력 32px과 비슷)에 그치는 반면, [Conv3, Conv3, Pool2] 블록 4개를 쌓으면 **76px** — 이미지의 2배. 스트라이드 2 풀링 한 번이 그 뒤의 모든 확장을 2배 스케일업.

- Week 4.2 MLP에서 “은닉층을 쌓을수록 결정경계가 더 복잡한 형태”라는 관측과 **같은 원리**
- **얕은 층**은 지역적 패턴(선, 모서리)을, **깊은 층**은 그 지역적 패턴을 **넓은 시야에서 조합한** 고수준 특징(눈, 바퀴)을 감지

CNN의 전형적인 구조

$\underbrace{[\text{합성곱} \rightarrow \text{ReLU} \rightarrow \text{풀링}]}_{\text{반복}} \cdots \rightarrow \text{완전연결층 1~2개} \rightarrow \text{분류}$

- 공간 축소, 채널 증가 후 완전연결층
- 얇은 층은 저수준, 깊은 층은 고수준 특징

LeNet-5 (1998)를 10.1 공식으로 풀기

층	연산	출력 크기	채널	파라미터
—	입력	32×32	1	—
C1	5×5 Conv + sigmoid	28×28	6	$(25 \cdot 1 + 1) \cdot 6 = 156$
S2	2×2 MaxPool	14×14	6	0
C3	5×5 Conv + sigmoid	10×10	16	$(25 \cdot 6 + 1) \cdot 16 = 2,416$
S4	2×2 MaxPool	5×5	16	0
C5	5×5 Conv + sigmoid	1×1	120	$(25 \cdot 16 + 1) \cdot 120 = 48,120$
F6	완전연결 (tanh)	—	84	$(1 \cdot 120) \cdot 84 + 84 = 10,164$
OUT	완전연결 (softmax)	—	10	$84 \cdot 10 + 10 = 850$
합계				$\approx 6.2\text{만}$


각 행은 10.1의 합성곱 공식 $(k^2 C_{\text{in}} + 1) C_{\text{out}}$ 과 완전연결 공식 $C_{\text{in}} C_{\text{out}} + C_{\text{out}}$ 을 그대로 대입(합성곱은 bias 포함, 풀링은 0).

LeNet-5에서 중요한 관찰: “펼쳐서 FC에 넣기”

- F6은 C5 특징지도를 펼쳐서 입력으로 씀

공간 $32 \times 32 \rightarrow 1 \times 1$, 채널 $1 \rightarrow 120$ — “좁아지고 깊어진다” 경향의 원형.

그림으로: LeNet-5의 “펼쳐서 FC에 넣기”



채널을 크게 늘린 최신 네트워크는 이 벡터가 수만 ~ 수십만 길이가 되어 FC 층이 파라미터 대부분을 차지한다

LeNet-5는 C5에서 이미 공간을 1×1 로 줄여 F6 입력이 120으로 작다 — 풀링을 덜 하는 최신 네트워크는 이 벡터가 훨씬 길어진다.

AlexNet (2012)과 VGGNet (2014)

- AlexNet: CNN 시대 개막

VGGNet(Simonyan & Zisserman, 2014)의 강력한 관찰

5×5 필터 하나를 3×3 필터 두 개로 대체하면, 같은 수용장(5×5)을 더 적은 파라미터로, 더 비선형으로(ReLU가 두 번 들어감) 만들 수 있다. 3×3 만 쌓은 16층(VGG16)으로 같은 대회 2위 (1위는 GoogLeNet, 2014) — “깊이 자체가 곧 힘” 을 널리 퍼뜨림.

깊이 열화: 더 깊게 쌓으면 나빠진다

- **과적합이 아니다** — 학습 데이터에 대한 성능조차 나빠졌다 (training·validation이 같이 떨어짐)

깊이 열화: 최소값 찾기 최적화 문제




Kaiming He — ResNet 1저자
(당시 마이크로소프트 리서치, 2015)


깊이 열화 재현: 스킵이 100%와 50%를 가른다

Depth degradation: same architecture and data, only skip connections differed

Loss: without skips, stuck at ln 2



Accuracy: skip connections take 50% -> 100%



24개 합성곱 층(3×3 Conv-Conv 블록 12개)을 세로줄/가로줄 데이터로 25 에폭 학습. 왼쪽: cross-entropy loss — 스킵 없이는 ln 2 근처에서 거의 움직임 없음. 오른쪽: train 정확도 — 스킵이 있는 버전만 100%에 도달. 구조·데이터·초기화 시드 모두 같고 **스킵 연결만** 달랐다.

- **평범 24층(스킵 없음):** loss ≈ 0.693 (ln 2, 동전 던지기), train_acc **0.500**으로 고정
- **잔차 24층(스킵 있음):** 15 에폭에 loss 0.355, **25 에폭 내 100% 도달**
- 매우 단순한 분류라 “학습 못 한다”가 **극단적으로** 드러난 예 — ImageNet에서는 점진적으로, 메커니즘은 같음

스킵 연결: $y = F(x) + x$

스킵 연결(skip / residual connection)은
그래디언트 곱셈 사슬에 **지름길**을 낸다 — 한
블록의 출력을 $F(x)$ 로 두는 대신, **입력을 그대로**
더한 $y = F(x) + x$ 로 정의:

```
def residual_block(x, F):  
    # F: 합성곱층몇개로 이루어진  
    # 함수예      (: Conv-ReLU-Conv)  
    return [F(x)[i] + x[i]  
            for i in range(len(x))]  
    # F(x) + x
```

왜 그래디언트를 살리는가(직관):

$y = F(x) + x$ 를 x 로 미분하면

$$\frac{\partial y}{\partial x} = \frac{\partial F}{\partial x} + 1$$

- Week 9의 $\prod_l \sigma'(z_l) \cdot W_l$ 곱셈 사슬에서 $\partial F / \partial x$ 가 아무리 작아져도(소실), “+1” 항 덕분에 그래디언트가 **최소 1**은 유지된 채 전달될 길 남음
- 입력을 “건너뛰어” 뒤쪽 층으로 **그대로** 흘려보내는 **지름길**

“최소한 1”이 정말 성립하는가 — 수식과 수치

$$\frac{\partial x_L}{\partial x_0} = \prod_{l=1}^L \left(\frac{\partial F_l}{\partial x_{l-1}} + 1 \right)$$

$$\frac{\partial x_L}{\partial x_0} = 1 + (\text{나머지 항들의 합})$$

- 스킵 **없는** 20층: $|dz/dx| \approx 2.5 \times 10^{-14}$ (사실상 0 — 그래디언트 소실)
- 스킵 **있는** 20층: $|dz/dx| \approx 8.2$ (신호 유지)

같은 가중치·구조, 스킵 연결만으로 **약 330조 배** ($8.2/2.5 \times 10^{-14} \approx 3 \times 10^{14}$) 차이.

$F(x) + x$ 의 차원 매칭 + 항등 블록의 시작점

실무: 차원 매칭

더하려면 $F(x)$ 와 x 의 차원(채널 $\times$ 공간)이 **정확히 일치**해야 한다. “채널은 늘고 공간은 줄어든다” 패턴을 따르면 F 가 $64 \rightarrow 128$ 채널, $28 \times 28 \rightarrow 14 \times 14$ 변환할 때 x 는 그대로 — **1×1 합성곱**(공간 유지, 채널만 바꿈)으로 x 의 차원을 맞춰준 뒤 더한다 (필요하면 2×2 스트라이드 1×1 합성곱으로 공간도 동시 축소).

“항등 블록”이 왜 좋은 시작점인가

F 를 정규화된(0 근처) 작은 값으로 초기화하면 학습 시작 시점에 $F(x) \approx 0$ 이라 $y \approx x$ — **항등 함수로 시작**. “깊은 네트워크가 최적의 시작점을 얇은 네트워크의 항등 함수로 가질 수 있다” $\Rightarrow$ 학습이 “0에서 $F(x)$ 를 만들어야 한다”가 아니라 “이미 잘 동작하는 항등 함수 위에서 **잔차만** 미세 조정”. ResNet이 “깊은 망이 왜 어려운가”를 **표현력** 문제가 아니라 **최적화(초기화)** 문제로 재정의한 것.

배치 정규화: 스킵 연결의 “공범”

ResNet 논문은 스킵 연결과 함께 **배치 정규화(batch normalization)**(Ioffe & Szegedy, 2015)를 결합해 깊은 CNN의 학습 안정성을 크게 높였다. 합성곱 층 **사이에** 넣는 층으로, 각 **미니배치의 활성화값 분포**를 평균 0·분산 1로 표준화한 뒤, 학습 가능한 γ (스케일)· β (오프셋)로 다시 곱해/더해 “표준화가 너무 강하지 않게” 조절:

$$\hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad y = \gamma \hat{x} + \beta$$

- μ_B, σ_B^2 = 해당 **미니배치 전체** 활성화값의 평균·분산, $\epsilon = 0$ 나눗셈 방지 (예: 10^{-5})

실습: PyTorch SmallCNN + 파라미터 장부

세로줄 vs 가로줄(16×16 , 잡음 섞임)을 구분하는 아주 작은 CNN:

```
import torch, torch.nn as nn

class SmallCNN(nn.Module):
    def __init__(self):
        super().__init__()
        self.conv1 = nn.Conv2d(1, 8, 3,
                                padding=1)
        self.conv2 = nn.Conv2d(8, 16, 3,
                                padding=1)
        self.pool = nn.MaxPool2d(2)
        self.fc = nn.Linear(16*4*4, 2)
    def forward(self, x):
        x = self.pool(
            torch.relu(self.conv1(x)))
        x = self.pool(
            torch.relu(self.conv2(x)))
        x = x.view(x.size(0), -1)
        return self.fc(x)
```

층	연산	출력	II
—	입력 16×16	$16 \times 16 \times 1$	
Conv1	3×3 + ReLU (same)	$16 \times 16 \times 8$	
Pool1	2×2 MaxPool	$8 \times 8 \times 8$	
Conv2	3×3 + ReLU (same)	$8 \times 8 \times 16$	
Pool2	2×2 MaxPool	$4 \times 4 \times 16$	
FC	완전연결	2	

합계

Adam(lr=0.01) + CrossEntropyLoss. 초기
52%(동전 던지기) → 30 에폭 후 train/val **100%**.

10.3절에서 재사용할 **같은 모델**. 실습 노트북에서는 스킵 연결 있는/없는 두 버전으로 “깊이 열화” 실험을 직접 재현.

FAQ (10.2)

- 최댓값 위치 정보 버림 — 이동 불변성
- 깊이 열화는 최적화 문제

확인 문제 (10.2)

- ① **수용장 손 계산.** $k=3, s=1$ 합성곱 3개 $\rightarrow 2 \times 2$ maxpool($s=2$) $\rightarrow k=3, s=1$ 합성곱 2개.
마지막 합성곱 뉴런의 수용장: $1 \rightarrow 3 \rightarrow 5 \rightarrow 8 \rightarrow 14 \rightarrow 20$. (풀링 한 번이 모든 이후 확장을 2배 스케일업.)
- ② **잔차 그래디언트 항.** $L = 3$ 블록에서 $(A_1 + 1)(A_2 + 1)(A_3 + 1)$ 을 분배법칙으로 완전히 전개하고, 모든 인자에서 “1”을 고른 항(= 정확히 1)을 지목. 이 항이 스킵 없는 $\prod_l A_l$ 에 존재하지 않는 “바닥”임을 한 문장으로.
- ③ **구조 비교.** LeNet-5(≈ 6.2 만, FC 11,014)와 SmallCNN(1,762)의 파라미터 분포(합성곱 vs FC 비율)를 비교하고, 10.3의 전이학습이 “앞쪽 합성곱은 고정, 마지막 분류층만 재학습”하는 설계가 왜 자연스러운지 LeNet-5 구조(C5가 공간 1×1 · 채널 120)를 들어 한 문단으로.

10.3 분류를 넘어서: 탐지, 분할, 전이학습

분류를 넘어서: 두 가지 새 문제


객체 탐지(Object Detection)

- “이미지 안에 사물이 **어디에**, 무엇이 있는가”
- 각 사물의 **위치**를 사각형 (bounding box, 4개 좌표)으로, 그 안의 **클래스**를 함께 예측

탐지는 위치까지 붙은 분류

의미론적 분할(Semantic Segmentation)


- “**각 픽셀**이 어떤 클래스에 속하는가”
- 입력과 **동일한 크기**의 출력을 내며 각 픽셀에 클래스 라벨을 붙임
- 자율주행: “이 픽셀은 도로/보행자/차량”



OpenCV DNN + YOLOv3(COCO로 학습)의 실제 객체 탐지 결과 — 각 상자가 위치, 라벨이 클래스

R-CNN (2014): “후보 → 특징 → 판정” 3단계

R-CNN 파이프라인 (2014) — 분류 CNN 위에 후보 생성 + SVM 헤드 + NMS를 붙인 것



R-CNN 파이프라인 — (1) 선택티브 서치로 ~2,000개 후보 박스, (2) 각 후보를 224×224 로 줄여 CNN을 통과시켜 4,096차원 특징, (3) 클래스별 SVM + 박스 회귀로 판정, (4) IoU 기반 NMS로 중복 박스 제거.

- 1 **후보 지역: 선택티브 서치** (2012, 딥러닝이 아닌 기술)가 색·질감이 비슷한 인접 영역을 합치며 후보 박스 ~**2,000개**. 슬라이딩 윈도우(수백만 개) 대비 “미리 좁히기”가 통하는 이유: 사물은 실제로 그렇게 많지 않고 작지도 않은 경우가 대부분
- 2 **특징 추출**: 2,000개 후보를 각각 224×224 로 비율만 맞춰 리사이즈하고, **분류용 CNN의 마지막 분류층을 제외한 부분을 그대로 통과** — 각 후보마다 4,096차원 특징 벡터 1개. “분류로 배운 특징 추출기”를 새 문제에 재사용하는 순간
- 3 **판정**: (a) 클래스별 **SVM 하나씩** (Week 5의 SVM — 20개 클래스면 SVM 20개)로 “무엇이?”, (b) **회귀 모델**로 “정확한 사물 경계로 미세 조정”. 2,000 후보 $\times$ SVM 20개 = 40,000회 판정 — “한 특징 벡터는 1번만 계산해도 4만 번 재사용”되는 또 하나의 파라미터 재사용

왜 3단계인가 + 대가: 속도, 그리고 후속 3세대

● 3단계 분업: 후보, 특징, 분류

모델	연도	속도화 전략
Fast R-CNN	2015	이미지 하나 를 한 번 통과시켜 특징맵을 만들고, 후보마다 해당 영역의 특징만 풀링으로 공유 재사용 — 2,000회 전진전파가 1회로 줄어 10배 이상 빠짐
Faster R-CNN	2015	후보 추출(셀렉티브 서치) 자체도 학습 가능한 합성곱층(RPN , Region Proposal Network)으로 — “2012년 딥러닝 이전 기술”이 마지막 남은 고리
YOLO	2016	후보도 단계도 없애고, 특징맵의 격자 위치마다 (클래스, 박스 좌표)를 한 번의 전진전파로 직접 회귀 — 탐지를 “ 회귀 문제로 ” 재정의, 실시간 탐지의 표준

IoU: 박스의 겹침을 재는 법

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{\text{겹치는 면적}}{\text{합쳐진(겹침 한 번만) 면적}}$$

- $[0, 1]$ 에 있고 **10이면 완전 일치**

손으로: $A = [0, 0, 10, 10]$, $B = [1, 1, 11, 11]$ — 교집합 $[1, 1, 10, 10] \rightarrow$ 면적 $9 \times 9 = 81$,
합집합 $100 + 100 - 81 = 119$.

$$\text{IoU} = 81/119 \approx \mathbf{0.68}$$

NMS를 한 번 따라가보자

1. 모든 (박스, 점수)를 점수 내림차순 정렬 2. 가장 점수 높은 박스를 **보관**하고, 그것과 겹기가 임계값(보통 0.5)을 넘는

모든 박스를 **제거** 3. 남은 박스에서 2를 반복


박스	좌표 $[x_0, y_0, x_1, y_1]$	점수
A	$[0, 0, 10, 10]$	0.90
B	$[1, 1, 11, 11]$	0.80
C	$[20, 0, 30, 10]$	0.75
D	$[21, 1, 31, 11]$	0.60

- **A(0.90)** 먼저 보관
- B와 IoU **0.68** > **0.5** → **제거**
- 남은 **C(0.75)** 보관, D와 IoU 0.68 → **제거**
- **결과: A와 C만 남음** — 4개 박스에서 사물 2개. A,B 쌍과 C,D 쌍의 IoU가 **같은 값 0.68**을 두 번 씬으로써 “제거 기준은 점수가 아닌 **겹기**”임을 보임

NMS (threshold 0.5): 4 candidate boxes → 2 objects (only A and C remain)

A-B pair: IoU ≈ 0.68

C-D pair: IoU ≈ 0.68



$k = \text{intersection} / \text{union}$; $0.68 > 0.5$ threshold, so the lower-scoring box is removed. $k = \text{intersection} / \text{union}$; $0.68 > 0.5$ threshold, so the lower-scoring box is removed.

4개 박스 중 NMS(임계값 0.5)가 A와 C를 남기고 B, D를 제거 — A와 B의 교집합(검정)이 합집합의 0.68을 차지해 B가 억제되는 것.

분할: “격자 위치마다 붙은 분류기”


224x224 입력이 7x7 격자로 줄고, 분류 헤드는 이를 1,000개

의미론적 분할 헤드

1개의 헤드 대신, **49개의 격자 위치마다 “클래스 1,000개”** 출력을 공유 가중치로 붙인다 — 마지막 층을 “512→1,000 선형층”이 아니라 **출력 채널 1,000개**의 **1×1 합성곱**으로 바꾸면, 격자 **각 위치**에서 512개 특징을 1,000개 클래스 점수로 변환하고 그 가중치는 49개 위치가 **공유**(1×1 합성곱이 “위치당 분류기” — 10.1 FAQ의 “채널만 선형 결합”). 파라미터는 $512 \times 1,000 + 1,000$ **하나분**만 추가되지만, 답의 형태가 “벡터 1개”에서 **7×7 클래스 지도**로 바뀐다.

그림으로: 224×224 가 7×7 격자로

224×224 입력이 2×2 최대풀링 5회로 7×7 격자까지 줄어든다




2×2 최대풀링을 5번 거치면 $224/2^5 = 7$ — 분류 헤드는 이 $7 \times 7 \times 512$ 격자를 1,000개 클래스 점수로 압축한다.

왜 공유가 올바른 편향인가 + U-Net

U-Net: 코더-디코더 대칭 구조

- 스킵 연결로 위치 정보 복원

그림으로: U-Net — 스킵 연결로 해상도를 되찾는다



점선 화살표 = 스킵 연결 (같은 레벨의 위치 정보를 디코더로 직접 전달)

줄여가는 인코더 끝에 늘려가는 디코더를 대칭으로 붙이고, 같은 레벨의 인코더 특징을 스킵 연결로 그대로 건너뛰어 더한다 (Ronneberger, Fischer, Brox, 2015).

전이학습: 처음부터 다시 배우지 않는다

전이학습: 사전학습된 앞쪽 층 재사용

특징 추출(feature extraction)

- 사전학습된 층의 가중치를 **전부 고정 (freeze)**, **마지막 분류층만** 새로 학습
- **데이터가 적을 때** 특히 유리 — 새로 학습할 파라미터가 훨씬 적기 때문

미세조정(fine-tuning)

- 사전학습된 가중치를 **학습의 시작점으로만** 쓰고, 전체(또는 뒤쪽 일부) 층을 **낮은 학습률로** 계속 학습
- **새 데이터가 어느 정도 있을 때** 특징 추출보다 더 좋은 성능

“앞쪽 층은 범용하다”는 말의 첫 증거

- AlexNet 첫 합성곱 층 필터: 방향/색 대비 감지
- 첫 층은 모서리 감지에 사용됨

전이학습이 이용하는 비대칭

층이 깊어질수록 특징이 눈·바퀴·사물 부분으로 “사물화”되는 계층 구조(10.2) 때문에, **앞으로 갈수록 재사용 가치가 높다** — 앞쪽 = 범용, 뒤쪽 = 특화.



David Hubel (1992)
고양이 시각피질 수용장 연구
(Hubel & Wiesel, 1962)



AlexNet 첫 합성곱 층의 96개 $11 \times 11 \times 3$ 필터 (Krizhevsky et al.,
NeurIPS 2012, Fig. 3) — 방향 선분을 감지하는 Gabor 유사 패턴

같은 작업에서 세 팔(arm) 비교

팔	갱신되는 층	갱신 파라미터 (전체 1,762 중)
A. 스크래치(scratch)	전체	1,762
B. 특징 추출(frozen)	마지막 분류층(fc)만	514
C. 미세조정(fine-tuning)	전체 (낮은 학습률 0.001)	1,762

- B는 29%만 건드리고도 같은 결과

세 팔의 코드: 동결은 requires_grad로

```
model = SmallCNN()
for p in model.conv1.parameters():
    p.requires_grad = False
for p in model.conv2.parameters():
    p.requires_grad = False

# requires_grad=True인 파라미터만
# 옵티마이저에 전달 -- fc 층만 학습됨
opt = torch.optim.Adam(
    filter(lambda p: p.requires_grad,
           model.parameters()), lr=0.01)
```

- 전체 1,762개 중 실제로 학습되는 파라미터는 **514개**뿐
- **30 에폭 후 검증 정확도 90%** 도달
- 학습 전후로 conv1 가중치를 직접 비교하면 **완전히 동일** —
requires_grad=False 로 고정된 층은 역전파 대상에서 **아예 제외**되어, .backward() 를 아무리 호출해도 가중치가 **단 한 번도** 갱신되지 않음

두 단계 전이: “다른” 작업에서 배운 특징

큰 데이터셋 학습 후 가중치 복사 및 헤드 재학습

```
pre = SmallCNN() # 단계1: 큰데이터에서사전학습
# ... 15 에폭학습 ... # 학습정확도 100%

model = SmallCNN()
with torch.no_grad(): # 단계2: 가중치복사
    for d, s in zip(model.conv1.parameters(),
                    pre.conv1.parameters()):
        d.copy_(s)
    # ... 도conv2 동일하게 ...
for p in model.conv1.parameters():
    p.requires_grad = False # 합성곱동결
# ... 도conv2 ...
opt = torch.optim.Adam(
    filter(lambda p: p.requires_grad,
           model.parameters()), lr=0.01)
# ... 20 에폭 ... # 검증정확도 100%
```

어떤 데이터를 언제 쓸 것인가 + 왜 이게 되는가

새 문제의 상황	추천 방식
데이터가 적다(수십~수백 장)	특징 추출 — 헤드만 학습, 나머지 동결
데이터가 어느 정도 있고, 사전학습 도메인과 비슷하다	미세조정 — 낮은 학습률, 뒤에서부터 순차 동결 하
데이터가 충분하고, 도메인이 크게 다르다	스크래치도 고려 — 사전학습의 편향(bias) 이 오

- **왜 이게 되는가**(Week 6): 정규화가 “모델을 덜 유연하게 만들어 분산을 줄인다”면, 전이학습은 “**시작점을 좋게 해서**” 동일한 목표 달성 — Week 4.1의 **편향-분산 프레임워크**가 다시 등장

자주 하는 실수 (10.3)

실수 1: 사전학습 모델의 정규화 통계를 무시

사전학습된 모델은 보통 특정 정규화(예: ImageNet의 **채널별 평균·표준편차**로 입력 표준화)를 적용받은 데이터로 학습됐다. 새 데이터에 이 정규화를 **빼먹거나 다른 값**을 쓰면, 필터들이 “본 적 없는 스케일의 입력”을 받아 성능이 예상보다 훨씬 나빠진다. **모델이 학습될 때 가정했던 데이터 분포를 추론 시점에도 정확히 재현해야 한다** — 사전학습 모델을 쓸 때는 반드시 **학습 전처리 파이프라인(평균/표준편차, 이미지 크기)**을 문서에서 확인하고 그대로 맞추는 것이 첫 단계.

실수 2: 높은 학습률로 미세조정하며 사전학습 가중치를 망침

사전학습 가중치는 사전학습 손실 지형에서 **좋은 지역**에 놓인 점. 큰 학습률(예: 0.01)로 시작하면 그 좋은 지역 경계를 **한 발로 뛰어넘는** 셈 — 범용 특징이 파괴되어 “전이한 모델”이 “전이를 안 한 것”보다 **나빠짐**. 미세조정은 스크래치 대비 **10~100배 낮은** 학습률(예: 0.001 또는 0.0001)로, 가능하면 “순차 동결 해제” 순서로 — 학습률은 “그래디언트 한 걸음의 대담함”(Week 9)이고, 좋은 시작점 위에서는 **작은 걸음이 정답**.

한눈에 보기: 같은 특징 추출기, 다른 헤드

문제	출력 형태	특징 추출기 위에 붙는 헤드	
분류	벡터 1개(K개 클래스 점수)	격자 펼치기 + 선형층 1개	V
객체 탐지	(클래스, 박스 좌표 4개) × N개 사물	후보 생성 + 박스별 분류기(SVM) + NMS	R
의미론적 분할	입력과 같은 크기의 클래스 지도	위치별 공유 1×1 합성곱 (출력 채널 = 클래스 수)	U
전이학습	(위 중 아무거나)	헤드만 재학습, 또는 낮은 학습률로 전체 미세조정	—

장 마무리

네 줄 전부 10.2의 “합성곱 스택”이라는 **같은 줄기에 다른 헤드를 붙인 것** — 헤드의 차이에 따라 답의 **형태만** 바뀐다(벡터 → 박스 목록 → 픽셀 지도). CNN은 “**이미지의 국소적 패턴은 위치와 무관하게 재사용될 수 있다**”는 하나의 통찰을, **합성곱이라는 연산 하나로 구현한 것** — 전이학습·탐지·분할·ResNet은 서로 다른 문제를 풀지만 전부 그 재료를 “**어떻게 재사용·재조합·안정화할 것인가**”를 답하는 응용.

FAQ (10.3)

- 분할이 분류보다 어려운 이유

확인 문제 (10.3): 숫자 네 개

- ① **격자 크기.** 224×224 입력이 2×2 최대풀링을 5번 $\rightarrow 224/2^5 = 7$, “위치별 분류기” **49개**
- ② **IoU.** 박스 $[2, 3, 8, 9]$ 와 $[4, 3, 10, 7]$: 교집합 $[4, 3, 8, 7]$ 면적 **16**, 각 박스 면적 **36**과 **24** $\rightarrow$ 합집합 **44** $\Rightarrow \text{IoU} = 16/44 = 4/11 \approx \mathbf{0.36}$
- ③ **NMS.** 앞 표의 4개 박스(A 0.90, B 0.80, C 0.75, D 0.60)에 임계값 0.5 $\rightarrow$ **A와 C가 남음** (A-B 쌍과 C-D 쌍의 IoU가 **둘 다** 0.68 — “점수가 높은 쪽이 살아남는다”는 규칙만으로는 답이 안 나옴)
- ④ **헤드 파라미터.** 2048차원 특징을 1,000개 클래스 로 미세조정:
 $2048 \times 1000 + 1000 = \mathbf{2,049,000}$ — VGG-16 전체 1억 3,800만 파라미터에서 $\approx 1.5\%$.
(“전이학습이 왜 저렴한가”의 숫자적 답)

이번 주차 정리

- ① **합성곱 = 재사용의 연산** — $n_{\text{out}} = \lfloor (n + 2p - k)/s \rfloor + 1$, params $(k^2 C_{\text{in}} + 1)C_{\text{out}}$, FLOPs에 n_{out}^2 이 곱해진다. 미니 LeNet이 MLP 대비 **0.12%의 파라미터, 1/4의 연산**.
- ② **좁아지고 깊어진다** — 합성곱이 “무엇을”(패턴), 풀링이 “얼마나 넓은 시야로”(수용장)를 결정. 깊이 열화는 **최적화 문제**이고, 스킵 연결의 “+1”이 그래디언트 바닥을 깔아 **100층이 넘는 CNN**을 가능하게 함.
- ③ **같은 줄기, 다른 헤드** — 분류(벡터 1개) / 탐지(박스 + NMS) / 분할(위치별 공유 1×1 합성곱) / 전이학습(앞쪽 동결, 헤드만 재학습). “**앞쪽 = 범용, 뒤쪽 = 특화**” 비대칭이 전이학습의 핵심.

다음 주 — Week 11. 시퀀스 모델

CNN이 가중치를 **공간**(이미지 위 위치)에 걸쳐 재사용한다면, RNN은 같은 가중치를 **시간**(시퀀스의 시점)에 걸쳐 재사용한다. 공간과 시간, 두 축에서 “**작은 단위 패턴을 재사용해 큰 구조를 쌓는다**”는 동일한 원리를 본 셈이다 — 이번 주차의 “재사용”이 바로 그 연결고리.