

시퀀스 모델

RNN 은닉 상태와 순전파 · BPTT와 numpy RNN 언어모델 · 그래디언트 소실과 LSTM/GRU

Machine Learning 1 · 11주차

한국과학영재학교 (KSA)

Week 11

이번 주차 개요

이 주차를 마치면

- RNN의 순전파 수식(은닉 상태 갱신식)을 손으로 유도하고, 파라미터 수가 시퀀스 길이에 무관한 이유를 설명
- BPTT의 재귀 구조(본 시점 오차 + 다음 시점에서 흘러온 그래디언트의 합)를 유도하고, numpy로 문자 단위 RNN 언어모델을 학습시킨다
- 그래디언트 곱적이 W_{hh} 고유값 1을 기준으로 지수적으로 소실·폭발함을 숫자로 확인하고, LSTM/GRU가 “곱은 조절 스위치, 덧셈은 통로”의 ResNet 스킵 연결 시간 축 버전임을 원리 수준으로 서술
- 기본 RNN → GRU → LSTM → Attention 사이에서 언제 무엇을 고를지 판단하고, 게이트가 소실을 “완화”할 뿐 “해결”하지 않는 이유를 설명

- **11.1 RNN: 은닉 상태와 순전파** — “은닉 상태는 지금까지 읽은 것의 요약”이라는 핵심 아이디어를 순전파 수식으로, 스칼라 RNN의 3개 시점과 고정점 수렴을 손으로 계산
- **11.2 BPTT와 numpy RNN 언어모델 실습** — BPTT를 시점 재귀식으로 유도하고, “abcabc...”를 배우는 문자 모델로 LLM의 “다음 토큰 예측”을 가장 축소된 형태로 재현
- **11.3 그래디언트 소실의 재발과 LSTM/GRU** — 소실·폭발을 숫자로 확인하고, 게이트(덧셈

11.1 RNN: 은닉 상태와 순전파

왜 순서가 중요한가

“강아지가 고양이를 쫓는다”와 “고양이가 강아지를 쫓는다”는 **똑같은 단어 세 개**로 이루어져 있지만 완전히 다른 문장이다.

- MLP·CNN에 이 문장을 넣으려면 단어를 **벡터 하나로 뭉쳐야** 한다 → **순서 정보가 사라짐**
- 주가 시계열: 같은 100개 숫자라도 순서에 따라 “상승 후 조정”이든 “조정 후 상승”이든 다른 신호
- DNA·단백질: 같은 염기 네 개(A, C, G, T)의 **배열** 자체가 의미를 결정
- CNN(Week 10)은 공간적 인접성 + 위치 불변성을 활용
- 시퀀스의 “왼쪽→오른쪽”은 **시간의 방향성**: 앞 단어는 뒤 단어를 영향주지만 뒤 단어는 앞 단어를 알 수 없다

이 비대칭을 모델이 반영할 수 있어야 한다 — RNN의 출발 질문.

역사: Elman 네트워크와 “시간 속의 구조”

RNN의 원형은 1990년 인지과학자 제프리 엘먼(Jeffrey Elman)의 논문 “Finding Structure in Time”(Elman, 1990).

- 질문: 신경망이 단어 목록을 외우는 대신 **시간에 걸친 패턴**을 추출할 수 있을까?
- 구조: 은닉층을 **센트럴 유닛**(지금 입력 처리)과 **라테럴 유닛**(이전 상태의 복사본 저장)으로 나눔
- 라테럴 유닛의 출력을 **다음 시점의 입력으로** 다시 돌린다 — 지금의 RNN과 거의 똑같음
- 단순한 반복 연결을 “시간을 기억하는 장치”로 재해석한 것이 핵심

유명한 실험과 계보

같은 어미 “-pits”가 “pit(구덩이)”의 복수인지 “pitch(공)”의 복수인지를 문맥이 구분하는 듯이 행동한다는 관찰 (나중에 비판도 받았으나 “같은 토큰도 맥락에 따라 다른 내적 표현” 직관의 원형). 1997년 호흐하이터·슈미트허버가 제안한 **LSTM** 이 2010년대 음성인식·번역에서 비약적 성능을 보여주며 RNN이 비로소 주류가 됨 (11.3절에서 다시 만남).

은닉 상태: 순차적 압축으로 요약

RNN의 핵심 아이디어는 **은닉 상태(hidden state)**: 문장을 한 단어씩 읽어가면서 “지금까지 읽은 내용의 요약”을 하나의 벡터에 계속 갱신해 나간다.

- 두 번째 단어를 처리할 때 **두 번째 단어 자체**뿐 아니라 “첫 번째 단어를 읽고 남은 요약”도 함께 입력 $\Rightarrow$ 지금 시점의 출력이 **과거 전체의 맥락**에 영향을 받는다
- h_t 는 길이 T 인 문장 전체(단어 T 개의 임베딩을 이으면 Td 차원)를 h 차원 벡터로 **압축** — h 가 작을수록 압축률 높아지고 **정보 손실**이 커짐
- PCA(Week 3)가 “데이터를 저차원 공간에 **내리는 것**”이라면, RNN은 “**시간 축**을 따라 내리는데, 내리는 과정 자체가 **학습**된다”
- 압축은 **순간적**이 아니라 **순차적**: h_t 는 $x_1, \dots, x_t$ 를 **다시 읽을 수 없도록** 압축해야 한다
- 다음 단어 예측 같은 과제에서는 **미래 정보가 없는 것이 오히려 정확**

“한 번 읽고 잊되, 잊지 말아야 할 것은 벡터에 남기는” — 이 장치가 RNN의 전부다.

RNN의 순전파


시점 t 마다 입력 x_t 와 이전 은닉 상태 h_{t-1} 을 받아, 새 은닉 상태 h_t 와 (필요하면) 출력 y_t 를 낸다:

$$h_t = \tanh(W_{xh} x_t + W_{hh} h_{t-1} + b_h), \quad y_t = W_{hy} h_t + b_y$$

- **핵심:** W_{xh}, W_{hh}, W_{hy} 가 **모든 시점에서 동일한 가중치를 재사용** (파라미터 공유)
- Week 10의 CNN 필터 재사용과 같은 아이디어를 **시간 축**에 적용한 것
- CNN: 공간 축(이미지 각 위치)에서 같은 필터를 재사용
- RNN: 시간 축(시퀀스 각 시점)에서 같은 가중치를 재사용
- 10단어 문장인지 100단어 문장인지에 관계없이 **같은 세 행렬**만 쓴다 — 입력이 크든 길든 **파라미터 수는 일정**

시간을 펼쳐서(unroll) 그리기

RNN을 시간 축 3번(시점 $t=1,2,3$)만을 펼쳐(unroll) 그린 개념도 — 각 시점에서 “동일한” $W_{xh}, W_{hh}, b_{xh}, b_{hh}$ 가 재사용된다(매트릭스 공유). self-loop가 “기억”이다



h_t 의 self-loop = “기억”의 시각화. $h_0 = 0$ 에서 시작.

시퀀스 전체를 한눈에 보는 가장 좋은 방법:
시간을 펼쳐서(unroll) 그리는 것.

- 같은 네트워크가 시점마다 반복되어 있는 것이지, 각 시점에 **별개의 층**이 있는 것이 아님
- 출력 y_t 는 $x_1, x_2, \dots, x_t$ **전부**에서 온다 — y_3 는 h_3 를 통해 x_1, x_2 의 영향도 받음
- 반대로 y_1 은 x_1 에서만 온다

“과거만 보고 미래는 못 본다”는 시간의 비가역성이 이 도식 안에 정확히 들어 있다.

파라미터 수: 시퀀스 길이와 무관

문자 단위 언어모델(어휘 $V = 26 - a \sim z$, 은닉 크기 $H = 8$)의 파라미터를 세어보자:

매개변수	크기	개수
W_{xh} (입력 $\rightarrow$ 은닉)	$H \times V$	$8 \times 26 = 208$
W_{hh} (은닉 $\rightarrow$ 은닉)	$H \times H$	$8 \times 8 = 64$
W_{hy} (은닉 $\rightarrow$ 출력)	$V \times H$	$26 \times 8 = 208$
b_h	H	8
b_y	V	26
합계		514

- 10글자든 1000글자든 **514개** — 파라미터가 시퀀스 길이에 비례하지 않는 것이 파라미터 공유의 직접적 혜택
- 비교: 같은 문자열을 MLP에 넣으려면 “직전 5글자” 윈도우를 펼쳐 $5 \times 26 = 130$ 차원 입력으로 — 더 긴 맥락은 윈도우 확대로 입력 차원이 선형 증가
- 첫 은닉층만 8개 뉴런이어도 $130 \times 8 + 8 = 1048$ 개 — **파라미터 수만 이미 RNN 전체(514)의 두 배**

코드: 한 걸음(*rnn_step*)과 전체(*rnn_forward*)

```
def rnn_step(x_t, h_prev, Wxh, Whh, b_h):
    z = [sum(Wxh[i][j]*x_t[j] for j in range(len(x_t))) +
         sum(Whh[i][j]*h_prev[j] for j in range(len(h_prev))) + b_h[i]
         for i in range(len(h_prev))]
    return [tanh(v) for v in z]

def rnn_forward(inputs, h0, Wxh, Whh, b_h):
    h = h0
    hidden_states = []
    for x_t in inputs:
        h = rnn_step(x_t, h, Wxh, Whh, b_h)
        hidden_states.append(h)
    return hidden_states
```

- 한 줄로 요약: “같은 *rnn_step*을 T 번 순서대로 반복하는 것”
- 이 순차성($t = 1$ 이 끝나야 $t = 2$ 를 시작)이 RNN의 장점(파라미터 효율)이자 동시에 단점(병렬화 불가 — 11.3절)

“무엇을” 담느냐: 누적합 예제

“과거의 요약”은 추상적이다 — 아주 단순한 **누적합(running sum)**을 RNN 구조가 어떻게 수행하는지 스칼라 예제로 직접 추적. (11.2절에서 같은 구조를 **학습**시키는 모델이 등장한다.)

- 스칼라 RNN, $w_{xh} = 0.1$, $w_{hh} = 0.9$, $b_h = 0$, 입력 $[2, 3, 1, 4]$
- pre-activation z_t (tanh 전)를 따라가면:

$$z_1 = 0.200, \quad z_2 = 0.480, \quad z_3 = 0.532, \quad z_4 = 0.879$$

기억의 감쇠 구조

$z_t = 0.1 x_t + 0.9 z_{t-1}$ 에 z_{t-1} 을 재귀적으로 대입하면:

$$z_t = 0.1 x_t + 0.1 \cdot 0.9 x_{t-1} + 0.1 \cdot 0.9^2 x_{t-2} + \dots$$

- **주의: $\tanh$ 가 없어야 성립하는 근사.** 실제로는 $h_t = \tanh(z_t)$ 라 재귀는 비선형 — z 가 작은 ($\tanh z \approx z$) 구간에서만 좋은 근사
- 그래도 **감쇠의 구조**는 정확히 보인다: z_t 는 과거 입력들의 **기하급수적으로 감쇠된 가중합**
- $0.9^k = k$ 칸 전 입력의 “**기억 세기**”
- $k = 10$: $0.9^{10} \approx 0.35$ (10단어 전 정보의 35% 잔존), $k = 20$: ≈ 0.12
- w_{hh} 를 0.5로 바꾸면 $0.5^{10} \approx 0.001$ — **거의 잊는다**

“기억의 길이”는 w_{hh} 하나의 값으로 조절된다 — 11.3절 “그라디언트도 같은 W_{hh} 의 곱으로 소실된다”의 열쇠.

tanh를 거친 은닉 상태: 포화

실제로 tanh를 거치면 $h_t = \tanh(z_t) = [0.197, 0.444, 0.462, 0.673]$.

- 이 h_t 를 누적합 추정치로 ($\hat{s}_t = 10 \cdot h_t$): 누적합 $[2, 5, 6, 10]$ 의 추정 $\rightarrow [1.97, 4.44, 4.62, 6.73]$
- 초기에는 거의 정확하고, 입력이 클수록 tanh의 **포화**로 점점 아래로 벗어남 — 두 원인:
 - 1 tanh의 “요약 벡터는 $[-1, 1]$ 안에 갇힌다”는 한계
 - 2 큰 숫자의 누적합을 **저차원 벡터 하나**에 담으려 할 때의 왜곡
- 실전 RNN은 **여러 차원** 은닉 상태(11.2절 $H = 8$) + 11.3절의 **게이트** 구조로 이 문제를 다룬다
- 주의: 11.2절의 “abcbabc...” 모델은 이 누적합을 스스로 학습한 것이 아니라 단 3글자 주기라는 더 쉬운 요령을 배운다 — 같은 구조라도 데이터에 따라 “기억”의 내용이 바뀐다.**

손으로 한 번: 스칼라 RNN 세 스텝

은닉 상태가 **스칼라(숫자 하나)**인 가장 단순한 RNN. $w_{xh} = 0.5$, $w_{hh} = 0.8$, $b_h = 0$, 입력이 매 시점 $x_t = 1.0$ 으로 고정, $h_0 = 0$ 에서 시작:

$$h_1 = \tanh(0.5 \times 1.0 + 0.8 \times 0) = \tanh(0.5) \approx 0.462$$

$$h_2 = \tanh(0.5 \times 1.0 + 0.8 \times 0.462) = \tanh(0.870) \approx 0.701$$

$$h_3 = \tanh(0.5 \times 1.0 + 0.8 \times 0.701) = \tanh(1.061) \approx 0.786$$

- 같은 입력($x_t = 1.0$)이 반복되는데도 h_t 가 매 시점 다른 값으로 갱신 ($0.462 \rightarrow 0.701 \rightarrow 0.786$)
- 이유: “이전 은닉 상태”가 매번 입력에 **새로 더해지기** 때문
- 점점 커지다가 어떤 값 근처로 **수렴**해간다 — $\tanh$ 가 큰 입력에서 **포화(saturate)**되어 1에 가까워지기 때문

이 “포화” 현상이 11.3절의 그래디언트 소실과 정확히 같은 뿌리(미분이 0에 가까워짐)를 공유한다.

고정점과 그 “속도”

위 계산을 10단계까지 이어가면 ($w_{xh} = 0.5, w_{hh} = 0.8$):

t	1	2	3	4	5	6	8	10
$z_t = 0.5 + 0.8 h_{t-1}$	0.500	0.870	1.061	1.129	1.149	1.154	1.156	1.156
$h_t = \tanh(z_t)$	0.462	0.701	0.786	0.811	0.817	0.819	0.820	0.820


- h_t 는 **고정점(fixed point)** $h^* = \tanh(0.5 + 0.8 h^*)$ 으로 수렴 — 해는 $h^* \approx 0.8196, t = 10$ 에서 차이 $< 10^{-3}$
- “같은 입력이 계속 오면 은닉 상태가 결국 한 곳에 정지한다” — RNN의 **동적(dynamics)**을 이해하는 출발점
- 수렴 **속도**는 고정점 근처의 “**증폭 인자**”로 결정: $\frac{dh_t}{dh_{t-1}} = 0.8 \cdot \tanh'(z_t)$
- $h^* \approx 0.82$ 에서 $\tanh'(z^*) = 1 - (h^*)^2 \approx 0.325 \Rightarrow$ 증폭 인자 $0.8 \times 0.325 \approx 0.26$ — 각 단계마다 차이가 약 4분의 1로 줄어듦 (표에서 h_5 이후가 거의 움직이지 않는 이유)

핵심: 이 “증폭 인자”가 11.3절의 그래디언트 소실과 정확히 같은 수식

- **순전파:** h_{t-1} 의 작은 변화가 h_t 에 얼마나 전달되는지 재는 $\tanh'(z_t) \cdot w_{hh}$ 의 곱
- **역전파:** 손실의 그래디언트가 시점을 거슬러 올라갈 때 곱해지는 인자 $\tanh'(z_t) \cdot W_{hh}$ (11.2절)
- → **구조적으로 동일:** 순전파의 “기억이 빠르게 잊히는 속도”와 역전파의 “그래디언트가 빠르게 사라지는 속도”는 **같은 연쇄법칙 곱의 두 얼굴**
- 11.3절이 다룰 그래디언트 소실을 **11.1절의 순전파에서 미리 체감**하고 있는 셈 — $\tanh$ 의 포화는 수렴을 **부추기는** 동시에 그래디언트 소실을 **조성하는** 동일한 원인

w_{hh} 를 0.9로 키우면? — 그리고 발산

- 고정점은 $h^* \approx 0.853$ 으로 조금 높아짐
- 증폭 인자 $0.9 \times (1 - 0.853^2) \approx 0.245 - 0.8$ 경우(0.263)보다 오히려 약간 **작아짐**
- 둘 다 6단계 만에 고정점의 10^{-3} 이내로 **정착**
- “**발산**”은 여전히 하지 않는다: 증폭 인자가 1보다 작기 때문
- 스칼라 RNN은 tanh의 범위 $[-1, 1]$ 에 갇혀 있어 발산 자체가 **불가능**



$w_{hh} = 0.8$: 0.820으로, $w_{hh} = 0.9$: 0.853으로 수렴
— 약 6단계 만에 정착.

단, 은닉 크기가 큰($H > 1$) RNN에서는 W_{hh} 의 고유값이 1보다 크면 h_t 가 실제로 발산하거나 진동할 수 있다 — 11.2절 “자주 하는 실수”의 그래디언트 폭발과 같은 뿌리 (Pascanu et al., 2013).

자주 하는 실수 1: “ h_t 는 x_t 만 의존한다”

RNN을 처음 접할 때 가장 흔한 오해: 순전파 수식에서 $W_{hh} h_{t-1}$ 항을 “보조적인 정규화 항”쯤으로 여기는 것.

- h_t 는 **과거 전체** $(x_1, \dots, x_t)$ 의 함수이며, x_t 하나만 의존하지 않는다
- “은닉 상태가 과거를 기억한다”는 이 절의 모든 주장이 **이 한 항**에 달려 있다
- $W_{hh} = 0$ 으로 두면: $h_t = \tanh(W_{xh} x_t + b_h)$ 로 “**시점을 독립적으로 처리하는 MLP**”로 퇴화
- 결과: 10단어 문장의 10번째 단어를 예측할 때 **앞의 9단어를 완전히 잊는** 모델

$W_{hh} h_{t-1}$ 을 빼면 RNN은 RNN이 아니다.

자주 하는 실수 2: “시점마다 가중치가 달라진다”

전개도에서 각 시점에 하나의 “박스”가 그려져 있어서, “시점 1에는 $W_{xh}^{(1)}$, 시점 2에는 $W_{xh}^{(2)}$...” 같은 **별개의 가중치**가 있는 것으로 오해하기 쉽다.

- 아니다 — 세 행렬 W_{xh}, W_{hh}, W_{hy} 가 **시점 전체에서 공유**된다 (파라미터 공유)
- 이 공유 덕분에:
 - ① 시퀀스 길이에 관계없이 **파라미터 수가 일정**
 - ② “5번째 단어를 처리하는 능력”이 “150번째 단어를 처리하는 능력”에도 **자동으로 전이**
- 이 공유가 없다면: RNN은 “시퀀스 길이 = 층 수”로 고정된, 학습할 파라미터가 시퀀스 길이에 **비례하는 단순 MLP 스택**과 다를 바가 없다

실습: 숫자 하나씩 코드로

3단계 손계산 · 고정점 · 누적합 예제를 하나의 코드로:

```
import math

def rnn_step(x, h, wxh, whh, b=0.0):
    return math.tanh(wxh * x + whh * h + b)

# 단계3 손계산 (w_xh=0.5, w_hh=0.8, x=1, h0=0)
h = 0.0
for _ in range(3):
    h = rnn_step(1.0, h, 0.5, 0.8)
    print(f"h = {h:.4f}")          # 0.4621 / 0.7012 / 0.7860

# 고정점반복대입 : h = tanh(0.5 + 0.8h)
h = 0.0
for _ in range(100):
    h = rnn_step(1.0, h, 0.5, 0.8)
print(f"고정점 h* ~ {h:.4f}")    # 0.8196

# 누적합예제 (w_xh=0.1, w_hh=0.9), 입력 [2,3,1,4]
h = 0.0
for x in [2.0, 3.0, 1.0, 4.0]:
    h = rnn_step(x, h, 0.1, 0.9)
    print(f"h = {h:.4f}")        # 0.1974 / 0.4444 / 0.4621 / 0.6728
```

핵심 공식 한눈에

항목	공식	무엇을 말하나
순전파 (재귀) 출력	$h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-1} + b_h)$ $y_t = W_{hy}h_t + b_y$	시점마다 은닉 상태 갱신 시점별 예측 (선형, 활성화함수 없음)
파라미터 기억의 감쇠	$(HV + 1) + H^2 + (VH + 1)$ $z_t \approx \sum_k w_{hh}^{k-1} \cdot w_{xh} x_{t-k+1}$	시퀀스 길이 T와 무관 w_{hh} 가 “기억의 길이”를 결정

한 줄

RNN = **같은 세 행렬을 T 번 순서대로 돌리며**, 이전 요약을 tanh로 압축해 갱신하는 구조.

FAQ: 은닉 상태 크기와 인코더-디코더

Q. 은닉 상태의 크기는 어떻게 정하나요?

“지금까지의 맥락을 얼마나 **풍부하게 요약**할 수 있는가”를 결정하는 하이퍼파라미터 — Week 9의 은닉층 뉴런 수와 같은 종류의 선택.

- 너무 작으면 **긴 문맥을 다 담지 못**하고
- 너무 크면 파라미터 증가 → **과적합 · 계산비용** 문제

Q. 입력과 출력이 다른 경우(번역)는?

“입력을 끝까지 읽고 **마지막 은닉 상태 하나**로부터 새 시퀀스를 순차 생성”하는 **인코더-디코더(encoder-decoder)** 구조를 쓰면 가능 — 단, 긴 입력을 하나의 벡터로 압축하면 **정보 손실**이 생김. **Week 12의 Attention이 정확히 이 한계를 보완하기 위해 출발했다** (Bahdanau et al., 2014).

FAQ: 문장 전체를 펼쳐 MLP에 넣으면 안 되는가

세 가지 이유다:

- ① **파라미터** — 문장 길이 $T \times$ 임베딩 차원 d 개 입력을 100개 뉴런의 은닉층에 연결하면 $100 T d$ 개 가중치 — T 에 **비례해 팽창**. RNN은 T 와 무관하게 $HV + H^2 + VH$ 개만
- ② **길이 가변성** — 실제 문장은 길이 불균일: 5단어와 200단어 입력을 하나의 MLP로 처리하려면 **패딩**이나 **분리된 모델**이 필요. RNN은 같은 가중치로 어떤 길이든 처리
- ③ **위치 인코딩 불필요** — MLP에 “100번째 단어”를 넣으려면 “이건 100번째 위치의 단어”라는 정보(위치 인코딩, Week 12)를 **별도로** 줘야. RNN은 **순차적 처리 자체**가 위치 정보를 자동 반영

그럼에도 “RNN은 순차적이라 느리다”는 이유로 Transformer가 주류가 된 이유도 11.3절에서 본다.

FAQ: 왜 tanh인가, h_0 는 항상 0인가

Q. 왜 tanh인가? 시그모이드(0 ~ 1)도 되는데

- ① **중심화**: tanh 출력 범위 $[-1, 1]$ 은 0 중심 대칭. 시그모이드 $[0, 1]$ 은 항상 양수 → 여러 성분이 “동일 방향”으로 움직이는 경향, 학습이 느려짐 (9.2절의 시그모이드 “비대칭 골짜기”)
- ② **미분의 크기**: $\tanh'$ 최대값 1 = 시그모이드 미분 최대값 0.25의 **4배** — 같은 깊이에서 그래디언트가 4배 강하게 전달

반대로 **출력층** $y_t = W_{hy}h_t + b_y$ 는 활성화함수 없이 **선형**: “다음 문자의 확률 분포(softmax)”나 “실수값(회귀)”으로 해석되어야 하므로 $[-1, 1]$ 로 자르는 tanh가 오히려 방해 — 은닉층과 출력층은 **역할**이 다르다.

Q. h_0 는 항상 0이어야 하나요?

꼭 아니다 — “시퀀스를 읽기 **전에** 알고 있는 것”을 담을 수 있는 초기 조건: (a) 0으로 고정 (가장 흔함), (b) **학습 가능** 파라미터 벡터, (c) **이전 시퀀스의 최종 은닉 상태**를 이어받아 이어지는 시퀀스 처리 (음성인식: 전 문장의 마지막 상태를 다음 문장의 초기 상태로).

11.2 BPTT와 numpy RNN 언어모델 실습

BPTT: 시간을 펼쳐서 역전파하기

“요약을 계속 갱신한다”는 구조를 배우게 만들려면 순전파만으로는 부족하다.

- 손실을 줄려면 각 가중치에 대한 **그래디언트**를 구해야
- h_t 가 h_{t-1} 에, h_{t-1} 이 h_{t-2} 에 의존하는 **사슬**을 이룸 $\Rightarrow$ Week 9의 “출력층 $\rightarrow$ 입력층” 역전파를 **시간 축을 따라 펼쳐** 적용

BPTT(Backpropagation Through Time)

시퀀스 길이 T 만큼 신경망을 **펼쳐서(unroll)** 각 시점을 독립된 층처럼 취급한 뒤 Week 9의 역전파를 **그대로** 적용.

$$\frac{\partial h_T}{\partial h_1} = \prod_{t=2}^T \frac{\partial h_t}{\partial h_{t-1}} = \prod_{t=2}^T \text{diag}(\tanh'(z_t)) W_{hh}$$

$$z_t = W_{xh}x_t + W_{hh}h_{t-1} + b_h, \tanh'(z_t) = 1 - h_t^2.$$

곱적: 소실·폭발의 씨앗

이 식이 말해주는 것: **먼 시점과 가까운 시점 사이를 건너는 그래디언트는 W_{hh} 를 $T - 1$ 번 곱하는 곱적이 된다.**

W_{hh} 고유값 < 1

곱이 **지수적으로 0**으로 — “그래디언트 소실”

W_{hh} 고유값 > 1


곱이 **지수적으로 ∞** 로 발산 — “그래디언트 폭발”

11.3절에서 “그래디언트 소실·폭발”이라는 이름으로 다시 만나는 바로 그 문제 (Pascanu et al., 2013).

이번 절: 그 양보다 먼저, 이 곱적 구조를 정확히 따라가며 각 파라미터의 그래디언트가 어떻게 누적되는지 유도한다.

펼쳐진 계산 그래프: 시점이 곧 “층”

RNN을 시간 축(T) 방향으로 펼쳐서 보는 계산 그래프
같은 가중치(W_{xh}, W_{hh}, W_{hy})가 시점마다 재사용 $\rightarrow$ 각 시점의 그래디언트는 같은 가중치에 더해짐($++$)
역전파(BPTT)는 손실 L에서 시작해 왼쪽(먼 과거 h_{-1})으로 좌살표와 반대 방향으로 흐른다



역전파는 오른쪽(손실)에서 왼쪽(과거)으로.

중요한 것 세 가지:

- 1 **수직 화살표(W_{hh})**: 자기-루프 ($h_{t-1} \rightarrow h_t$).
역전파에서는 **위에서 아래로** — h_t 에서 h_{t-1} 으로 거슬러 올라감
- 2 **각 시점의 출력 화살표(W_{hy})**: $h_t \rightarrow y_t$.
손실이 **모든 시점**의 y_t 에서 나므로 역전파는 이 화살표들에서 시작
- 3 **같은 색 박스가 모든 시점에서 반복**: 시점 1과 시점 2의 W_{xh}, W_{hh}, W_{hy} 는 **동일한** 가중치 (파라미터 공유) $\Rightarrow$ 각 시점의 그래디언트는 **같은 가중치의 그래디언트에 더해짐**

이 “누적”이 BPTT에서 가장 실수하기 쉬운 지점.

BPTT 유도: 시점마다 “(A) + (B)”

손실을 **모든 시점**의 크로스엔트로피 합으로 놓는다:

$$L = - \sum_{t=1}^T \sum_k y_{t,k}^{\text{true}} \log p_{t,k}$$

$p_t = \text{softmax}(W_{hy}h_t + b_y)$ = 시점 t 의 다음-문자 분포, y_t^{true} = 원-핫 정답.

역전파는 **마지막 시점 T 에서 첫 시점 1로** 순차적으로 내려간다. 핵심 — 각 시점 t 의 은닉 상태 그래디언트는 **두 부분의 합**:

$$\underbrace{W_{hy}^{\top}(p_t - y_t^{\text{true}})}_{(A) \text{ 본 시점의 출력 오차}} + \underbrace{W_{hh}^{\top} \left[\frac{\partial L}{\partial h_{t+1}} \odot (1 - h_{t+1}^2) \right]}_{(B) \text{ 시점 } t+1 \text{에서 흘러온 그래디언트}}$$

Week 9의 2층 역전파와 같은 형태

- “다음 시점에서 온 그래디언트 + 그 시점 자체의 출력 오차”를 합친다는 점에서, 각 시점의 역전파는 **Week 9.1의 2층 신경망 역전파와 형태가 같다**
- 다만 “은닉층에서 입력층으로” 대신 “**시점 t 에서 시점 $t - 1$ 으로**” 거슬러 올라간다는 점이 다를 뿐
- 재귀 구조: (B) 항이 **다음 시점의** $(A) + (B)$ 를 다시 포함 — 사슬이 이렇게 한 시점씩 이어진다

핵심 문장

본 시점 오차 (A)에, **더 새로운 시점**에서 흘러온 그래디언트 (B)를 **더하고**, W_{hh} 가 공유되므로 그 기여는 **같은 텐서에 누적**(+ =)된다.

BPTT 코드: 핵심 루프

```
# 역전파: t = T-1, T-2, ..., 0 순으로 (0-indexed)
dh_next = np.zeros(H) # dL/dh_{t+1} 첫(루프: 0)
dWxh = dWhh = dWhy = 0; dbh = dby = 0
for t in reversed(range(T)):
    p = softmax(Why @ hs[t] + by)
    dp = p.copy(); dp[targets[t]] -= 1 # p_t - onehot
    dWhy += np.outer(dp, hs[t]); dby += dp # (A)
    dh = Why.T @ dp + dh_next # (A)+(B)의 합
    dz = dh * (1 - hs[t]**2) # * tanh'(z_t)
    dh_next = Whh.T @ dz # -> 이전시점으로 B 전달
    dWhh += np.outer(dz, hps[t]); dbh += dz
    dWxh += np.outer(dz, one_hot(inputs[t]))
```

- **첫째** $dh = Why.T @ dp + dh_next$: 본 시점 오차에 **더 새로운 시점**에서 흘러온 그래디언트를 더하는 $(A) + (B)$
- **둘째** $dWhh += \dots$ 는 +=가 아니라 += $- W_{hh}$ 가 **모든 시점에서 공유**되므로 각 시점의 기여를 같은 텐서에 계속 더해야 함

왜 p - onehot인가: softmax + CE

크로스엔트로피($-\log p_k$, k 가 정답)를 softmax 출력 p_j 로 미분하면 **경악할 정도로 깔끔한 결과**:

$$\frac{\partial L}{\partial z_j} = p_j - \mathbb{1}[j = k]$$

“softmax의 출력에서 **정답 클래스 자리에만 1을 빼고** 나머지는 그대로”.

- Week 9.1의 로지스틱 회귀 + 크로스엔트로피 그래디언트 “(예측 - 정답)”와 **정확히 같은 패턴**의 다항분류 버전
- 왜 단순해지는가: 연쇄법칙으로 펼치면 $\sum_k (-y_k/p_k) p_k (\delta_{kj} - p_j)$
$$= - \underbrace{\sum_k y_k \delta_{kj}}_{y_j} + p_j \underbrace{\sum_k y_k}_1 = p_j - y_j$$
- softmax의 p_k 가 크로스엔트로피의 $1/p_k$ 와 **상쇄**되기 때문
- 직관: **예측 p_j 가 정답 y_j 에 가까울수록 그래디언트가 작아진다** — “이미 잘 맞힌 클래스는 거의 건드리지 않는다”는 직관이 수식으로 확인되는 지점
- 정답 클래스: $p_k - 1 < 0 \Rightarrow$ 그 로짓을 **올리고**, 나머지는 $p_j > 0 \Rightarrow$ 로짓을 **내려** 확률 질량을 정답 쪽으로 이동

손으로 한 번: 2시점 RNN의 순전파

은닉 크기 $H = 2$, 어휘 $V = 3$ ($a \cdot b \cdot c$)의 아주 작은 RNN으로 시퀀스 “ab”($T = 2$)을 읽고 **다음 문자**를 예측 (목표: 1번째 $\rightarrow b$, 2번째 $\rightarrow c$).

$$W_{xh} = \begin{bmatrix} 0.3 & -0.2 & 0.0 \\ 0.5 & 0.1 & -0.3 \end{bmatrix}, \quad W_{hh} = \begin{bmatrix} 0.4 & 0.2 \\ -0.3 & 0.5 \end{bmatrix}, \quad W_{hy} = \begin{bmatrix} 0.6 & -0.4 \\ 0.1 & 0.5 \\ -0.2 & 0.3 \end{bmatrix}$$

편의상 전부 0.1 이하의 작은 값, bias 0.

- **시점 1** (입력 $a = e_a = [1, 0, 0]^T$):

$$h_1 = \tanh(W_{xh}e_a) = \tanh \begin{pmatrix} 0.3 \\ 0.5 \end{pmatrix} = \begin{pmatrix} 0.2913 \\ 0.4621 \end{pmatrix}$$

- **시점 2** (입력 $b = [0, 1, 0]^T$): $z_2 = W_{xh}e_b + W_{hh}h_1 = \begin{pmatrix} 0.0089 \\ 0.2437 \end{pmatrix}$, $h_2 = \tanh(z_2) = \begin{pmatrix} 0.0089 \\ 0.2390 \end{pmatrix}$

2시점 예제: 출력 분포와 손실

각 시점의 출력 분포 (softmax):

$$p_1 = \text{softmax}(W_{hy}h_1) = \begin{pmatrix} 0.2937 \\ 0.3848 \\ 0.3215 \end{pmatrix}, \quad p_2 = \text{softmax}(W_{hy}h_2) = \begin{pmatrix} 0.2934 \\ 0.3622 \\ 0.3444 \end{pmatrix}$$

손실 (다음-문자 크로스엔트로피; 시점 1 목표 b(인덱스 1), 시점 2 목표 c(인덱스 2)):

$$L = -\log p_1[b] - \log p_2[c] = -\log 0.3848 - \log 0.3444 = 0.9550 + 1.0660 = \boxed{2.0210}$$

역전파는 시점 2 $\rightarrow$ 1 순서로. 시점 2부터: $\delta_2^{(y)} = [0.2934, 0.3622, -0.6556]$ (목표 인덱스 2를 -1 감소) $\Rightarrow$
 $\frac{\partial L}{\partial W_{hy}} += \delta_2^{(y)} h_2^\top, \frac{\partial L}{\partial b_y} += \delta_2^{(y)}, \frac{\partial L}{\partial h_2} = W_{hy}^\top \delta_2^{(y)} + \underbrace{0}_{\text{시점 3 없음}}, \frac{\partial L}{\partial z_2} = \frac{\partial L}{\partial h_2} \odot (1 - h_2^2), \text{ 그리고 } \frac{\partial L}{\partial h_1} += W_{hh}^\top \frac{\partial L}{\partial z_2}.$

2시점 예제: 최종 그래디언트

시점 1에서도 같은 과정(단, $\frac{\partial L}{\partial h_1}$ 에 **시점 2에서 흘러온 기여가 더해진** 뒤 곱해짐)을 반복하면:

$$\frac{\partial L}{\partial W_{hy}} = \begin{bmatrix} 0.0882 & 0.2058 \\ -0.1760 & -0.1977 \\ 0.0878 & -0.0081 \end{bmatrix}, \quad \frac{\partial L}{\partial W_{hh}} = \begin{bmatrix} 0.1000 & 0.1587 \\ -0.0365 & -0.0579 \end{bmatrix}$$

$$\frac{\partial L}{\partial W_{xh}} = \begin{bmatrix} 0.2062 & 0.3434 & 0 \\ -0.2537 & -0.1254 & 0 \end{bmatrix}, \quad \frac{\partial L}{\partial b_h} = \begin{pmatrix} 0.5496 \\ -0.3791 \end{pmatrix}, \quad \frac{\partial L}{\partial b_y} = \begin{pmatrix} 0.5871 \\ -0.2530 \\ -0.3341 \end{pmatrix}$$

- 이 값들을 numpy 코드(위 스냅샷)가 자동미분 없이 그대로 재현하며, **수치 미분**(각 가중치를 $\pm 10^{-6}$ 흔들어서 $\frac{L(w+\epsilon) - L(w-\epsilon)}{2\epsilon}$)과 비교하면 전부 10^{-10} 수준으로 일치
- 눈여겨볼 것은 $\frac{\partial L}{\partial W_{hh}}$** : 시점 2에서 온 그래디언트가 h_1 을 통해 **시점 1의 W_{hh} 기여에 덧붙었다**는 사실이 이 작은 예제에 한 박스 안에 담겨 있다
- 11.1절 “자기-루프가 시간 축의 파라미터 공유다”가 **그래디언트도** 공유된다는 뜻을 숫자가 보여줌

곱적의 양: 소실 · 폭발이 여기서 시작된다

유도에서 $\frac{\partial L}{\partial h_t}$ 가 시점을 거슬러 내려올 때마다 매번 $W_{hh}^\top$ 과 $(1 - h^2)$ (즉 $\tanh'$)를 곱받는다.

- 이 곱이 T 번 반복 $\Rightarrow \prod_t \tanh'(z_t) W_{hh}$
- $\tanh' \in (0, 1]$ (최대 1, 대부분 그 이하)이고 W_{hh} 크기도 보통 1 근처 $\Rightarrow$ 시퀀스가 길어질수록 **지수적으로 0으로 수렴하거나 발산**
- 숫자로 ($\tanh' \approx 0.5$, W_{hh} 크기 0.9, $T = 20$): $(0.5 \times 0.9)^{20} \approx 4.5 \times 10^{-7}$ — **사실상 0**
(11.3절 “그래디언트 소실” 예습)
- 반대로 고유값이 1을 넘으면 **발산(폭발)**

BPTT의 산술적 구조 자체가, 시퀀스 길이에 따라 그래디언트가 지수적으로 줄어들거나 커지는 원천이다 — 다음 실습에서 “그래디언트 클리핑”을 왜 넣는지가 바로 이것.

실습: numpy로 문자 단위 RNN 언어모델

“abcbabcbabc”(12문자)를 **문자 단위**로 예측하는 아주 작은 RNN 언어모델을 numpy로 직접 학습.

- **설정**: 어휘 {a, b, c} ($V = 3$), 은닉 크기 8, 다음-문자 예측 대상 **11개** ($T = 11$)
- **초기화**: 시드 42, $\mathcal{N}(0, 0.1^2)$ scale 0.1, 학습률 0.5, 500 에폭, 그래디언트 클리핑 5
- 입력 = 각 시점의 문자, 목표 = “다음 문자는?”

실습 코드: 초기화와 forward

```
import numpy as np

chars = "abc"; vocab_size = 3
hidden_size = 8
rng = np.random.RandomState(42)
Wxh = rng.randn(hidden_size, vocab_size) * 0.1
Whh = rng.randn(hidden_size, hidden_size) * 0.1
Why = rng.randn(vocab_size, hidden_size) * 0.1
bh, by = np.zeros(hidden_size), np.zeros(vocab_size)

text = "abcabcabcabc"
inputs = [chars.index(c) for c in text[:-1]] # a b c ... a b 개(11)
targets = [chars.index(c) for c in text[1:]] # b c a ... b c 개(11)

def forward(inputs, h0):
    h = h0; hs, ps, hps = [], [], []
    for idx in inputs:
        x = one_hot(idx)
        hps.append(h) # h_{t-1} 저장 (에dWhh 필요)
        h = np.tanh(Wxh @ x + Whh @ h + bh)
        p = softmax(Why @ h + by)
        hs.append(h); ps.append(p)
    return hs, ps, hps
```

RPTT dWxh, dWhh, dWhy, dbh, dbh를 구해줘 (오프도코드 += 누적)

초기 손실 12.09의 의미: 기준선

- 학습 시작 전, 모델은 3개 문자를 거의 **균등하게** (랜덤 초기화라 softmax 출력 $\approx [1/3, 1/3, 1/3]$) 예측
- 균등 분포의 한 위치 크로스엔트로피: $-\log(1/3) = \log 3 \approx 1.099$
- 예측 대상 11곳 $\Rightarrow$ 기준선 $11 \times \log 3 \approx 12.08$

“아무것도 모를 때”의 최대 불확실성

엔트로피 $\log 3 \times$ 시점 수. 실측 초기 손실 **12.09** 가 이 기준선과 거의 같은 것은 초기 가중치가 0 근처라 모델이 **사실상 균등 분포**를 내고 있음을 뜻한다 — “모델이 지금 **무작위 추측**을 하고 있다”는 기준선(baseline).

학습이 “잘 되고 있는가”를 말할 때 반드시 이 기준선부터 건져야 한다.


학습 결과: 14,000배 감소

500 에폭 학습 시 손실:

에폭	손실
초기	12.09 ($\approx 11 \cdot \ln 3$)
10	0.045
100	0.0043
500 (최종)	0.00086

- 손실이 기준선 12.09에서 **약 14,000배** 감소
- 학습 후 “a”부터 시작해 다음 문자를 계속 예측:
“**abcabcabcabc**” — 원본 패턴을 정확히 재현
- 이 작은 예제가 하는 일 = Week 17 LLM이
“다음 토큰을 예측한다”고 말하는 것의 **가장**
축소된 형태

“다음 문자 맞추기”와 “언어모델”의 차이가 크기 뿐
원리는 같다는 것을 8차원 은닉으로 확인할 수 있다.



초기 12.09 → 10에폭 0.045 → 500에폭 0.0009 (로그
스케일).

손실 곡선이 보여주는 것: 한 번에 모든 시점

- BPTT가 “시점 11곳의 오차를 **전부 모아** 시간을 거슬러 전달”하기 때문에
- **한 번의 에폭마다 모든 시점의 예측이 동시에 개선**된다
- 시점마다 **독립적으로** 학습했다면 이렇게 가파르게 떨어지지 않았을 것

왜 시점마다 따로 학습하면 안 되나

각 시점의 예측이 그 이전 시점들에 어떻게 의존하는지(BPTT가 계산하는 바로 그 의존성)를 전혀 반영하지 못한다. “다음 문자를 맞히는 능력”은 결국 “이전 문자들을 **얼마나 잘 요약했는가**”에 달려 — 손실을 전체 시퀀스에 대해 계산하고 역전파도 시간을 거슬러 전체에 해야 **은닉 상태가 실제로 유용한 요약**을 배우게 된다.

자주 하는 실수: 그래디언트 클리핑을 빼먹는 것

학습 코드에 `np.clip(dP, -5, 5)`로 그래디언트를 일정 범위로 **잘라내는(clipping)** 단계가 있다 — 이걸 빼먹으면?

- 그래디언트는 시점을 거슬러 내려올 때마다 $W_{hh}^T \tanh'$ 를 계속 곱함
- 학습 초반 가중치가 아직 “좋지 않은” 상태일 때 이 곱적이 1보다 커질 수 있음 $\Rightarrow$ 그래디언트가 **지수적으로 커져** 손실이 갑자기 **튀거나 NaN**이 됨

이 예제의 정량적 실측

학습률 2.0, 클리핑 **끄고** 500 에폭: 세 가중치 행렬의 절대값 최댓값 합 $\approx$ **47만** (467,172).
같은 설정으로 클리핑(상한 5) **켜면**: $\approx$ **83** 에 멈춤 — **약 5,600배 차이**.

Week 2.1의 학습률 발산과 원인은 다르다(학습률이 아니라 **시퀀스 길이에 걸친 곱셈**이 원인) — 증상은 똑같다. 손실이 갑자기 NaN이 되면 **그래디언트 폭발부터 의심**하고, 클리핑이나 더 작은 학습률을 먼저 시도 — RNN 계열 디버깅의 첫 단계.

자주 하는 실수: +=을 =로 쓰는 것

- **더 흔한 실수:** BPTT 루프에서 $dW_{hh} += \dots$ 를 $dW_{hh} = \dots$ 로 쓰는 것
- W_{hh} 가 모든 시점에서 공유되므로 각 시점의 기여를 **더해야** 하는데, =로 쓰면 **가장 마지막(가장 과거) 시점 기여 하나만 남고 나머지가 덮어쓰임**
- 증상: “학습은 되는데 **느리고**, 긴 시퀀스일수록 더 못 배운다” — **손실을 한 시점만** 보고 있는 것과 같으니까

BPTT 코드를 읽을 때 **첫째로** 확인할 두 줄

- (1) **그래디언트 클리핑**이 있는가?
- (2) $dW_{hh} +=$ 가 $dW_{hh} =$ 가 아닌가?

실전: 잘라내기 BPTT (truncated BPTT)

실제로 긴 문장을 학습할 때 T 가 커지면:

- ① 그래디언트 곱적이 지수적으로 소실 $\Rightarrow$ 먼 과거가 거의 학습에 기여하지 못함
- ② 계산·메모리가 T 에 비례해 증가

$\Rightarrow$ 시퀀스를 여러 개의 짧은 창(window)으로 잘라 각 창별로 BPTT를 하고, 은닉 상태만 창 사이로 넘겨주는 잘라내기 BPTT.

- “창 길이”는 소실되는 신호와 계산량 사이의 하이퍼파라미터
- LSTM은(11.3절) 이 잘라내기에 크게 의존하지 않도록 그래디언트 경로 자체를 수정한 구조임을 대비해서 기억.

잘라내기가 “거의 같은” 이유

- 잘라내기가 “약한” 것이 아니라 “**거의 같은**” 이유: **곱적이 지수적으로 소실되기 때문**
- 초기(학습 전) 가중치에서: 전체 11시점 BPTT로 구한 W_{hh} 그래디언트 노름 $\gg$ 마지막 4시점만 BPTT로 구한 것 — 그러나 **그 차이가 생각만큼 크지 않음**
- 먼 과거(시점 1~7)의 기여는 W_{hh}^T 을 **여덟 번 곱한 곱적**이라 이미 많이 작아져, **4시점 창으로 잘라도 전체 그래디언트의 상당 부분이 재현**
- 300에폭 진행 시 **전체 BPTT든 창 길이 4든** “abcbabcbabcb”를 정확히 재현

의의

긴 시퀀스에서 “**먼 과거의 그래디언트**”는 본질적으로 **미미**하므로 잘라내기의 **비용은 생각보다 작다**.

FAQ: 에폭이 많은 이유, W_{hh} 미분

Q. 왜 이렇게 많은 에폭이 필요했나요?

일부러 아주 단순한 구조(은닉 8)와 **기본 경사하강법** (Adam이 아니라)으로 **손으로 따라가기 쉽게** 만들었기 때문 — 실전에서는 Adam(Week 9의 SGD를 개선한 옵티마이저) + 더 큰 은닉 크기로 훨씬 적은 반복에 수렴. **중요한 것은 몇 에폭이 걸렸는가가 아니라, 손실이 실제로 0에 가깝게(12.09 → 0.00086) 줄었고 생성 문자열이 정답과 일치했다는 사실 자체.**

Q. W_{hh} 가 공유되니까 BPTT에서 “한 번만” 미분하면 안 되나요?

아니다 — **미분은 각 시점에서 각각** 해야 하고, 그 결과를 같은 W_{hh} 의 그래디언트 텐서에 **더해야** 함 (+=).

- 공유된 파라미터의 그래디언트 = 계산 그래프에서 **그 파라미터가 몇 번 쓰였는지만큼**의 기여 합
- CNN의 필터(Week 10)도 같은 원리: 하나의 필터가 이미지 위에 n^2 번 쓰이면 그 필터의 그래디언트는 n^2 개 위치의 **기여 합**

확인 문제: 숫자 세 개

- ① **초기 손실** — 어휘 3문자의 이 언어모델에서, 무작위 초기화($\approx$ 균등 분포)의 초기 손실을 “시점 수 $\times \log V$ ”로 예상하라. 12문자 시퀀스(11개 예측)라면 **얼마인가?** ($11 \times \log 3$) 이 “기준선”을 아는 것이 왜 중요한지 한 문장으로.
- ② **그래디언트 누적** — 손계산 예제의 $\frac{\partial L}{\partial W_{hh}} = \begin{bmatrix} 0.1000 & 0.1587 \\ -0.0365 & -0.0579 \end{bmatrix}$ 이 값이 **두 시점의 기여** 합임을 유도 식 $(A) + (B)$ 로 설명. $dW_{hh} = \dots$ (대입)를 썼다면 어떤 값만 남았을지 추정.
- ③ **곱적의 양** — $\tanh'(z) \approx 0.5$, W_{hh} 크기 1.2일 때, $T = 20$ 이면 $\prod_{t=2}^{20} (0.5 \times 1.2)$ 는 **몇 배?** ($0.6^{20} \approx 3.7 \times 10^{-5}$) 소실인지 폭발인지, 왜 그런지 한 문장으로.

11.3 그래디언트 소실의 재발과 LSTM/GRU

그래디언트 소실이 시간 축에서 재발

Week 9.2에서 본 것과 **정확히 같은 패턴**:

- $\tanh'$ 의 최댓값은 1이지만 **대부분의 구간에서 1보다 작고**
- 여기에 W_{hh} 까지 T 번(시퀀스 길이만큼) 곱해진다
- 시퀀스가 길수록(T 가 클수록) 이 곱은
 - ▶ W_{hh} 고유값 < 1 : 지수적으로 0에 가까워짐 — **그래디언트 소실**
 - ▶ W_{hh} 고유값 > 1 : **발산** — **그래디언트 폭발**
- 결과: 기본 RNN은 **먼 과거의 정보를 거의 기억하지 못한다** — “10단어 전에 나온 주어”를 지금 활용해야 하는 문장에서 특히 취약

숫자로 ($\tanh' \approx 0.5$, W_{hh} 크기 0.9, $T = 20$):

$$(0.5 \times 0.9)^{20} = 0.45^{20} \approx 4.5 \times 10^{-7} \quad (\text{사실상 } 0)$$

20단어 전의 정보는 지금 시점의 학습에 거의 아무 영향도 주지 못한다.

“소실”이 지수함수라는 것: 표로

$\frac{\partial h_T}{\partial h_1} = \prod_{t=2}^T \tanh'(z_t) w_{hh}$ (스칼라 단순화)를 T 를 크게 올려가며 계산:


시퀀스 길이 T	$\tanh' = 0.5, w_{hh} = 0.9$ (승수 0.45)	$w_{hh} = 1.5, \text{포화 } \tanh' = 0.5$ (승수 0.75)	$w_{hh} = 1.5, \text{미포화 } \tanh' \approx$
5	$0.45^4 \approx 4.1 \times 10^{-2}$	$0.75^4 \approx 3.2 \times 10^{-1}$	$1.5^4 \approx 5.1$
10	$0.45^9 \approx 7.6 \times 10^{-4}$	$0.75^9 \approx 7.5 \times 10^{-2}$	$1.5^9 \approx 38$
20	$0.45^{19} \approx 2.6 \times 10^{-7}$	$0.75^{19} \approx 4.2 \times 10^{-3}$	$1.5^{19} \approx 2.2 \times 10^5$
50	$0.45^{49} \approx 1.0 \times 10^{-17}$	—	—
100	$0.45^{99} \approx 4.7 \times 10^{-35}$	—	—

세 열을 읽으면 RNN 학습의 “운명”

- **첫째 열 (승수 $0.45 < 1$):** 전형적 소실. $T = 50$ 이면 10^{-17} 으로, float32의 표현 하한 ($\sim 10^{-38}$) 근처까지 밀림 — “100단어 전의 주어”의 그래디언트는 수치적으로 0과 구별 불가능, 그 자리의 가중치는 영원히 갱신되지 못함
- **둘째 열 (승수 0.75):** 같은 소실이지만 **16,000배 느리다** — w_{hh} 를 0.9에서 1.5로 올리자 소실은 사라지지 않고 속도만 줄었다. “게이트 없이 소실을 극복하려 하면 소실 ↔ 폭발 사이 줄타기에 불과”하다는 뜻
- **셋째 열 (승수 $1.5 > 1$):** 폭발. $T = 20$ 에서 이미 2.2×10^3 , $T = 50$ 이 넘으면 10^{10} 대로 NaN — 11.2절의 np.clip 그래디언트 클리핑이 바로 이 열을 막기 위한 **급조된 처방** (Pascanu et al., 2013)

승수 1 하나를 “조금만” 넘기면(1에 가까이) 소실이 느려지고, 크게 넘기면 폭발이 된다. 어떤 초기화를 잡아도 지수함수 라는 형 자체는 바뀌지 않는다 — 이 형을 바꾸는 것이 곧 게이트의 임무.

소실/폭발 갈라지는 세 곡선



승수 0.45 / 0.75 / 1.5의 그래디언트 곱이 시퀀스 길이 T 에 대해 지수적으로 소실 · 느린 소실 · 폭발로 갈라지는 곡선.

핵심 통찰

“승수의 밑이 1보다 작으면 지수 소실, 크면 지수 폭발”.

- 초기화를 W_{hh} 고유값이 1 근처에 오도록 정교하게 맞춰야 한다는 11.2절의 “자주 하는 실수”가 여기서 그 **깊이**를 드러냄
- 그러나 어떤 초기화도 **지수**라는 형은 못 바꿈 $\Rightarrow$ **구조**를 바꿔야 함

왜 곱셈이 문제고 덧셈은 아닌가

“곱을 반복하면 지수”는 수학의 당연한 결과 (a^T). 그런데 같은 길이의 사슬이어도, **각 단계가 이전 값을 “곱으로” 이어가는지 “더함으로” 이어가는지에 따라** 그래디언트의 운명이 완전히 갈린다.

기본 RNN (11.2절): 이전 은닉 상태를 곱해서 전달

ResNet 스킵 연결 (Week 10.2): 더함

$$y = F(x) + x$$

$$h_t = \tanh(\dots + W_{hh} h_{t-1}) \quad \Rightarrow \quad \frac{\partial h_t}{\partial h_{t-1}} \propto W_{hh} \quad (\text{매 단계 곱}) \quad \frac{\partial y}{\partial x} = \frac{\partial F(x)}{\partial x} + 1$$

매 단계마다 그래디언트를 **할인율** < 1 로 곱함.

“+1”이 매 스킵마다 정확히 1의 그래디언트를 통과시킴 — 미분 경로가 1로 “단락”해 있다.

스킵 20개를 쌓아도 0.45^{20} 이 아니라 $(1 + 0.45)^{20} \approx 3.7 \times 10^2$ — **할인 없이 1 그대로** 한 가닥을 통과.

LSTM의 “고속도로”: ResNet 스킵의 시간 축 버전

- LSTM/GRU가 이끄는 “고속도로” = **ResNet 스킵 연결의 시간 축 버전**
- **LSTM의 셀 상태** C_t 는 매 시점 “전부 버리고 새로 계산”하는 것이 **아니라**:

$$C_t = \underbrace{f_t \odot C_{t-1}}_{\text{기억 유지 (덧셈·스킵)}} + \underbrace{i_t \odot \tilde{C}_t}_{\text{신규 정보 추가 (덧셈)}}$$

- 이전 셀 상태에 **더해져서** 전달된다
- **곱셈(게이트)**은 “얼마나 남길지”라는 **크기 조절 스위치**로만 사용
- 정보 **본체**가 지나가는 통로는 **덧셈**

이 한 문장이 곧 “왜 LSTM이 긴 시퀀스에 강한가”의 전부 — Week 10.2 스킵 연결과 Week 9.2 “미분이 1에 가까울수록 그래디언트가 산다”가 시간 축에서 합류한 지점.

게이트(gate): LSTM 3개, GRU 2개

“게이트”는 이름만큼 단순한 장치: $\sigma(\cdot)$ 시그모이드로 산출한 **0과 1 사이의 숫자**로, “이 정보를 얼마나 통과/유지/갱신할 것인가”를 데이터와 학습으로 결정하는 **연속 스위치** (0 = 완전 차단, 1 = 완전 개방).


모델	게이트	역할(한 줄)
LSTM	망각 게이트 f_t	“기억(셀 상태)에서 지금 버릴 부분은?” — 1이면 그대로 유지
LSTM	입력 게이트 i_t	“지금 새로 기억에 쓸어 넣을 정보는?”
LSTM	출력 게이트 o_t	“저장된 기억 중 지금 출력에 보여줄 부분은?”
GRU	갱신 게이트 z_t	망각+입력을 하나로 통합: “기억의 얼마나를 새 값으로 교체할지”
GRU	출력 게이트 r_t	LSTM 출력 게이트와 같은 역할

공통 분모

LSTM = 3개의 스위치, GRU = 2개의 스위치 — GRU는 LSTM의 망각·입력 게이트를 하나의 “갱신” 결정으로 **합쳐** 파라미터를 줄였다. RNN의 “은닉 상태 전체를 매번 새로 쓴다”를, 게이트는 “어떤 부분은 보존하고 어떤 부분만 바꾸라”고 학습된 판단을 내리게 만든다. 공통 원리: **곱**으로 조절하는 **스위치** + **덧**으로 전달하는 **통로**.

LSTM 셀: 곱은 스위치, 덧셈은 고속도로

LSTM 셀: 게이트(곱, 덧셈)는 조절 스위치, 셀 상태 C(덧셈, 초속)는 정보를 통제로 전달하는 고속도로



이전 셀 상태 C_{t-1} 이 **망각 게이트 f_t 와 곱해지고(조절)**, **입력 게이트 $i_t \cdot \tilde{C}_t$ 가 더해져서(통로) C_t 로 이어지는 구조.**

- **곱(게이트)** = “얼마나 남길지” 조절
- **덧셈** = 정보가 **통째로** 지나가는 고속도로

이 분리(조절/통로)가 기본 RNN의 “전체 갱신(곱만)”과 구별되는 전부.

셀 상태의 그래디언트가 왜 1 근처를 유지하는가

“셀 상태가 덧셈으로 전달된다”를 그래디언트 관점에서 정확히 전개. 게이트만 추상화하면:

$$C_t = \underbrace{f_t \cdot C_{t-1}}_{\text{기억 유지}} + \underbrace{i_t \cdot \tilde{C}_t}_{\text{신규 기록}} \quad (f_t, i_t \in (0, 1))$$

기억이 시점 1에서 T 까지 전해지는 그래디언트: 신규 기록 항 ($i_t \tilde{C}_t$)은 C_{t-1} 에 무관하므로 미분에서 **떨어져 나가고**,

$$\frac{\partial C_T}{\partial C_1} = \prod_{t=2}^T f_t$$

- RNN의 $\prod \tanh'(z_t) w_{hh}$ 에서 $\tanh'$ (고정 할인율, ≈ 0.45)의 자리에 학습된 망각 게이트 f_t 가 들어온 것

차이 두 가지: 1에 수렴 + 통로 오염 없음

- ① 곱해질 수 있는 게 0~1이 아니라 (학습으로) 1에 수렴할 수 있다 — 기본 RNN의 승수 0.45는 구조가 1 미만으로 고정이지만, “계속 기억해야 한다”는 패턴을 학습하면 망각 게이트가 1에 가깝게 수렴 (이상적 해답 $f_t = 1$)
- ② 덧셈 항이 “기억 통로”를 오염시키지 않는다 — $i_t \tilde{C}_t$ 는 그래디언트를 생성하지만 기존 C_{t-1} 이 통과하는 경로를 할인하지는 않는다

게이트가 $f_t \approx 0.99$ 로 학습되면 $T = 100$ 에서 $0.99^{99} \approx 0.37$ vs RNN $0.45^{99} \approx 4.7 \times 10^{-35}$ — 약 10^{33} 배가 잘 보존. 승수의 밀이 0.45에서 0.99로 이동한 것: 아직 지수이고 1은 아니지만, 학습이 그 밀을 문제의 필요에 맞게 밀어 올릴 수 있는 것.

단, 게이트가 있어서가 아니라 게이트가 1에 수렴할 때 기억이 사는 것 (아래 “기억 과제” 실험이 보여줌).

게이트의 비용: 파라미터가 얼마나 늘까

게이트는 **공짜가 아니다**. 기본 RNN은 시점마다 W_{xh}, W_{hh}, W_{hy} 세 개($\approx 2 d_{in} d_h + d_h^2$)인데, 게이트 모델은 **이 조합을 3~4개로 복제**.

입력 차원 $d_{in} = 512$, 은닉 크기 $d_h = 128$ 에서:

모델	시점당 가중치($\approx$)	기본 RNN 대비
기본 RNN	$512 \cdot 128 + 128^2 \approx 8.2 \times 10^4$	$1\times$
GRU (게이트 3)	$3(d_{in} + d_h) d_h \approx 2.5 \times 10^5$	$\approx 3\times$
LSTM (게이트 4)	$4(d_{in} + d_h) d_h \approx 3.3 \times 10^5$	$\approx 4\times$

- 게이트 하나마다 입력 $\rightarrow$ 은닉, 은닉 $\rightarrow$ 은닉 가중치 한 조($(d_{in} + d_h) d_h$) 추가
- LSTM $\approx$ 4배, GRU $\approx$ 3배의 **메모리·계산**
- **데이터가 적은 문제에서는 게이트 모델이 오히려 과적합하기 쉬움** — “파라미터를 더 사서 버는 능력”과 “더 사서 무너지는” 사이에 **Week 6의 편향-분산 트레이드오프**가 그대로 놓여 있다.
게이트가 **시퀀스가 충분히 길어 소실이 실제로 병이 될 때**에 비로소 3~4배의 비용이 **값**을 하는 것이다.

역사: 1997년에 이미 알고 있었지만 생태계는 20년 뒤에 왔다

이 문제는 **새롭지 않다** — 시그모이드/타인 망의 그래디언트 소실은 1990년대 초부터 알려져 있었고, 1997년 **셉 홍하이저**(Sepp Hochreiter)와 **유르겐 슈미트허버**(Jürgen Schmidhuber)의 **LSTM** 논문(Hochreiter & Schmidhuber, 1997)은 이미 “**곱 대신 덧셈으로 기억을 전달하자**”는 해결책을 냈다.

- 1999~2000년대 LSTM이 기본 RNN을 압도함이 확인됐는데도 **2010년대 중반까지 “지나치게 복잡한 비주류 기법”으로 방치**
- 방치의 이유 = Week 9.2의 **생태** 문제: GPU 메모리, 고효율 프레임워크, He/Xavier 초기화, Adam, Dropout 등이 **없었고** 게이트를 붙인 LSTM은 **훈련 자체가 어려웠다**
- **2013~2014년 GPU + 프레임워크 + 초기화/옵티마이저가 한데 모여야** LSTM이 비로소 “**표준**”이 됨(2014년 seq2seq 번역·음성에서 두각)

교훈 — Week 9 “깊은 망은 세 라인(활성함수·초기화·최적화)이 함께 풀려야 했다”와 동일

좋은 아이디어(LSTM)와 그것을 쓸 수 있는 생태계는 동시에 와야 한다.

실습: “기억 과제”로 게이트가 정말 기억을 살리는가

“덧셈이 소실을 늦춘다”를 공짜로 믿지 말고 **실제로 학습해서** 확증. 과제는 의도적으로 **순차 병렬화를 배제**하고 **장기 기억만을 고립**시킨다.

과제


길이 $T = 100$ 의 시퀀스를 만든다. **첫 번째 토큰 ($t = 1$)은 0~9의 숫자 하나**(10차원 one-hot)이고, **나머지 99개 토큰은 전부 0**. 모델은 **마지막 시점 ($t = 100$)의 은닉 상태에서 “첫 번째 토큰이 뭐였는지”**를 분류.

- **중간 토큰에 새 정보가 전혀 없음** — $t = 100$ 의 답은 $t = 1$ 의 정보를 **99단계에 걸쳐 그대로 운반**할 수 있는가에 달려
- 기본 RNN: 0.45^{99} 수준의 소실로 이 “운반”을 거의 못 함
- 게이트 모델: 셀/은닉 스킵으로 정보를 **통째로 옮겨야** 함
- 세 모델, **같은 은닉 크기 32, Adam, 300에폭, 3개 seed 평균**

기억 과제: 결과

모델	seed 0	seed 1	seed 2	평균
기본 RNN	0.87	0.91	0.89	0.89
GRU	1.00	1.00	0.98	0.99
LSTM	0.61	1.00	0.96	0.86

기억 과제 (T=100, 0~9 숫자 + 99개 0): 게이트가 장기 기억을 살린다



3개 모델 × 3 seed는 CPU에서 약 1~2분.
(수식·코드는 실습 노트북 “기억 과제” 셀에서 그대로 실행.)

기억 과제에서 읽어야 할 세 가지

- ① **게이트가 기억을 살린다** 기본 RNN(0.89)은 “100단어 전의 첫 단어를 맞혀라”에서 약 10%를 꾸준히 놓침. GRU(0.99)/LSTM(0.86)은 확실히 더 높음 — **곱을 덧셈 스킵으로 바꾼 것이 실측으로 확인.**
- ② **흥미로운 반전: GRU(0.99)가 LSTM(0.86)보다 높다** 게이트가 많을수록 좋은 것은 아님. 이 과제는 데이터가 적고(512문장) 구조가 단순해서, 파라미터가 더 많은 LSTM ($\approx 4\times$)이 오히려 **과적합** — **seed 간 변동이 큼**(0.61~1.00), GRU($\approx 3\times$)가 더 **안정적·정확** — 아래 FAQ “게이트가 더 적은 GRU가 더 나은 경우가 많다”의 **생생한 증거**, Week 6의 **편향-분산 트레이드오프**가 시퀀스 모델에도 그대로 작동.
- ③ **seed에 크게 흔들린다** LSTM의 seed 0(0.61)은 실패에 가까움. 장기 기억 같은 “좁은 관”을 통과해야 하는 학습은 **초기화에 민감** — **단일 실행의 숫자가 아니라 여러 seed의 평균**을 보고 우열을 판단.

LSTM/GRU: 게이트로 소실을 완화 — 원리 한 줄

LSTM(Long Short-Term Memory)과 **GRU**(Gated Recurrent Unit)는 “게이트” 장치를 추가해, 은닉 상태를 매 시점 **완전히 새로 계산**하는 대신 **선택적으로 유지하거나 갱신**한다.

핵심 트릭

정보가 지나가는 경로에 **곱셈 대신 덧셈**이 섞이도록 설계 — Week 10.2에서 본 **ResNet의 스킵 연결** ($y = F(x) + x$)과 정확히 같은 원리.

덧셈은 그래디언트를 **그대로 통과**시키므로(미분이 1), 곱셈만 반복될 때보다 **소실이 훨씬 덜**하다.

자세한 게이트 수식은 이번 학기에서는 다루지 않으나, “왜 LSTM/GRU가 기본 RNN보다 긴 시퀀스에 강한가”의 답은 항상 이 **원리**로 귀결된다.

RNN의 근본적 한계: 순차성

- 게이트를 추가해도 RNN은 여전히 **순차적으로 한 시점씩** 처리해야 한다 — 100번째 단어를 처리하려면 1번째부터 99번째까지 **순서대로 다 거쳐야** 함
- 이 **순차성** 때문에:
 - ▶ 병렬화가 어려움
 - ▶ 아주 긴 시퀀스에서는 **여전히** 먼 과거 정보가 흐려진다

다음 장으로

Week 12의 **Attention/Transformer**는 이 **순차성 자체를 없애는** 완전히 다른 접근이다 — “필요할 때마다 과거 전체를 직접 다시 들여다본다”.

RNN은 “순서가 있는 데이터를 다루려면 과거를 기억하는 상태가 필요하다”는 통찰의 가장 단순한 구현이다 — 다음 장은 이 구조의 한계를 극복하는 이야기다.

실무 노트: 모델 고르는 “사다리”

앞의 논리를 한 문장으로 실무 지침으로:

기본 RNN → (길이에 따라 정확도 갈리면) **GRU** → (여전히 부족하면) **LSTM** → (길이 극단적) **Attention**
(Week 12)

- **그래디언트 클리핑은 기본 세팅이다** — 게이트가 소실을 **완화**해도 **폭발**은 막아주지 않음(승수가 1을 넘는 경로는 여전히 존재) — 매 스텝 그래디언트 노름을 상수로 잘라내는 클리핑은 RNN/LSTM/GRU 훈련의 **의무**
- **망각 게이트의 “기억하는 쪽”으로의 편향** — 이상적 기억 과제에서 망각 게이트는 **1(전부 유지)에 수렴**해야 함. 게이트가 0.5 근처에서 떠돌면 “기억을 못 한다” 증상 — **게이트의 초기화 + 초기 망각 게이트 바이어스**로 조절 하는 것이 실전 LSTM의 잘 알려진 트릭 (Jozefowicz et al., 2016) — “게이트가 1 근처로 **초기화**되어 있어야 기억을 **살릴 기회**가 있다”는 직감만 기억할 것

실무 노트: 과적합 감시

- 3~4배의 파라미터는 작은 데이터에서 과적합으로 돌아온다
- **train** $\gg$ **val gap**가 시퀀스 길이에 비례해 벌어진다면:
 - ▶ 모델 크기를 줄이거나(GRU $\rightarrow$ RNN으로 한 칸)
 - ▶ **dropout / early stopping**을 더 쓰는 쪽이 게이트를 더 붙이는 것보다 먼저 시도해야 함

자주 하는 실수: “소실을 완화했다”고 긴 시퀀스를 무조건 RNN으로

게이트가 소실을 **느리게** 한다고 해서 **아무 길이든** LSTM/GRU가 “기억한다”고 믿는 것은 실수. 두 가지 함정:

- **아직도 지수다, 다만 밀이 1에 가까워졌을 뿐** — 수천 토큰 이상이면 **LSTM/GRU**도 먼 과거를 서서히 잃어감. “완화이지 **해결이 아니다**” — 길이가 극단적일 때는 **Attention**으로 가는 게 정답
- **과적합** — 수천 문장 이하의 작은 문제에서 “시퀀스가 짧아 소실이 안 생길 것 같은데” LSTM을 올리면, 소실은 안 생기고 **과적합만** 생김 — “소실 증상”(훈련 중에도 긴 시퀀스 정확도가 안 옴)과 “과적합 증상”(train $\gg$ val)을 구분할 줄 알아야 한다

FAQ: 완화인가, 해결인가, GRU는 못나나, 셀 vs 은닉

Q. LSTM/GRU를 쓰면 그래디언트 소실이 완전히 사라지나요?

아니다 — “완화”이지 “해결”이 아니다. 게이트가 곱셈 경로 옆에 덧셈 경로를 추가해서 소실 속도를 크게 늦추지만, 수천 토큰 이상이면 LSTM/GRU도 여전히 먼 과거 정보를 점점 잃어감. **Week 12 Attention이 “순차적으로 압축해서 기억한다”는 접근 자체를 버리고 “필요할 때마다 과거 전체를 직접 다시 들여다본다”로 전환하는 이유가 바로 이것.**

Q. GRU는 LSTM보다 항상 나쁜가요(게이트가 더 적으니까)?

아니다 — 파라미터가 적어(게이트 3개 대신 2개) **학습이 빠르고 데이터가 적을 때 과적합 위험도 낮음**. 성능은 문제에 따라 둘 중 어느 쪽이 나올지 갈림 — “게이트가 많을수록 무조건 좋다”는 직감は 성립하지 않음 (Week 6 편향-분산 트레이드오프. 위 “GRU 0.99 vs LSTM 0.86”이 직접 증거).

FAQ: 셀 상태 vs 은닉 상태 — LSTM의 구조적 핵심

Q. 게이트 모델의 “셀 상태”와 기본 RNN의 “은닉 상태”는 같은 것인가요?

아니다 — 이것이 LSTM의 **구조적 핵심**.

- **기본 RNN:** 하나의 벡터 h_t 가 “지금의 출력에도 쓰이고 다음 시점의 입력에도 쓰이는” **둘의 역할을 동시에 함 (출력 = 상태)**
- **LSTM:** 이 둘을 분리
 - ▶ **셀 상태 C_t :** 장기 기억, **덧셈으로만 전달**되어 사실상 소실되지 않는 “저장소”
 - ▶ **은닉 상태 h_t :** 지금 시점의 “출력용 요약”, **셀에 게이트를 씌운 것**
- “기억을 오래 보관한다(C_t)”와 “지금 말한다(h_t)”를 **역할분담**한 것이, 소실을 **구조적으로** 줄이는 진짜 이유
- **GRU**는 이 분리를 **덜** 해(셀·은닉을 하나의 벡터로 통합) **파라미터가 줄어든다**

11주차 정리

- ① **11.1 — 은닉 상태는 “감쇠하는 요약”** — 같은 세 행렬(W_{xh}, W_{hh}, W_{hy})을 T 번 순서대로 돌려 파라미터를 길이와 무관하게 일정하게 만들고, w_{hh} 가 “기억의 길이”를 조절 — **파라미터 공유 = CNN의 시간 축 버전.**
- ② **11.2 — BPTT는 (A)+(B)의 재귀** — 본 시점 오차 + 다음 시점에서 온 그래디언트를 더하고, 공유 파라미터는 +=로 누적 — “abcbabc...” 8차원 문자모델은 LLM “다음 토큰 예측”의 **가장 축소된 형태**(12.09 → 0.00086, 14,000배).
- ③ **11.3 — 곱은 지수, 덧셈은 통로** — 그래디언트 곱적 $\prod \tanh' w_{hh}$ 가 고유값 1을 기준으로 지수 소실·폭발; LSTM/GRU는 **곱(게이트)=조절, 덧셈(셀 스킵)=통로**로 소실을 **완화** — 단, **순차성이라는 근본 한계는 남고**, 이것이 Week 12 어텐션의 계기.

다음 주 — Week 12. 어텐션과 트랜스포머

RNN이 “과거를 순차적으로 압축해서 기억”했다면, Attention은 “**필요할 때마다 과거 전체를 직접 다시 들여다본다**” — 11.1의 인코더-디코더 한계(긴 입력을 하나의 벡터로 압축하면 정보 손실)를 보완하러 등장하며, 11.3의 “완화이지 해결이 아니다”에 대한 **구조적** 답이다.