

n-step 부트스트래핑, 적격흔적, 그리고 계획

n-step TD · 적격흔적($TD(\lambda)$) · 계획과 학습: Dyna-Q

Machine Learning 2 · 7주차

한국과학영재학교 (KSA)

Chapter 7

이번 주차 개요

- **7.1 n-step TD: MC와 TD(0) 사이의 다이얼** — n-step 리턴 $G_t^{(n)}$ 을 정의하고, 7-state random walk에서 $n \in \{1, 3, 5, 10, 50\}$ 으로 30 seed 반복해 U자 곡선을 그린다. $\tau = t - n + 1$ 의 갱신 시차와 할인 지수 오프바이윈 버그를 디버깅한다.
- **7.2 적격흔적과 파라미터 튜닝** — 흔적 $e(s)$ 로 하나의 TD 오차가 **모든 상태를 동시에** 갱신하는 TD(λ)를 배운다. “ λ 를 고르는 일”과 “ n 을 고르는 일”은 같은 U자의 두 모습. 단 하나의 실행은 믿지 않는다(20회 반복 평균).
- **7.3 계획과 학습: Dyna-Q** — 본 (s, a) 의 결과 (r, s') 를 모델로 저장하고 실제 스텝마다 가상 TD(0) 갱신을 끼워 넣는 “경험 → 학습 → 모델 저장 → 계획” 루프. 5×5 격자에서 수렴 에피소드 334 → 35(약 9.5배)의 가속과 한계 효과를 측정한다.

이전·다음과의 연결

n-step TD, TD(λ), Dyna-Q는 모두 “**부트스트래핑을 얼마나 할 것인가**”라는 하나의 질문에 대한 서로 다른 답. Ch. 8 캡스톤에서 Gymnasium의 표 기반 환경으로 세 개를 직접 구현·비교하고, n-step 리턴은 Ch. 9 DQN의 기본 옵션으로 다시 만난다.

7.1 n-step TD: MC와 TD(0) 사이의 다이얼

복습: 두 극단 — MC와 TD(0)

- MC의 목표값: 에피소드 **끝까지의** 실제 보상 합(실제 리턴) G_t — 추정치 없음.
- TD(0)의 목표값: $r + \gamma V(s')$ — 실제 보상 1개 + 나머지 추정치.
- 나란히 쓰면 **같은 구조의 다른 길이**: 차이는 “실제 보상을 몇 개 쓸 것인가”가 1개와 “끝까지 전부”인 것.

1과 “끝까지” 사이의 아무 정수 n 도 가능해야 하지 않나 — n 개의 실제 보상 + 나머지는 추정치, 라는 목표값을 쓰자. 이것이 n-step TD.

n-step 리턴의 정의

n-step 리턴 $G_t^{(n)}$

$$G_t^{(n)} = R_t + \gamma R_{t+1} + \cdots + \gamma^{n-1} R_{t+n-1} + \gamma^n V(s_{t+n})$$

- $n = 1$ 이면 **정확히 TD(0)**, $n \rightarrow \infty$ (끝까지)이면 **정확히 MC**.
- n 을 늘릴수록 실제 관찰 의존 $\uparrow \Rightarrow$ **편향은 줄고 분산은 커진다** (Ch. 6.1 표의 트레이드오프 연속선상).
- n : 그 사이 어딘가를 상황에 맞게 고르는 **하이퍼파라미터**.

세 방법 한눈에 — 그리고 “갭신 시차”

	n	실제 보상	추정치(부트스트래핑)	갭신
TD(0)	1	R_t 1개	$V(s_{t+1})$	매 스텝 즉시
n-step TD	n	$R_t, \dots, R_{t+n-1}$ n 개	$V(s_{t+n})$	첫 갭신 $n - 1$ 스텝 지연
MC	∞	끝까지 전부	없음	에피소드 종료 시

기다려야 하는 시간(학습의 시차)

$G_t^{(n)}$ 을 계산하려면 t 에서 $t + n - 1$ 까지의 보상이 **다 모여야** 하므로, t 번 상태의 **첫** 갭신은 최소 $n - 1$ 스텝 뒤에야 가능. n 이 클수록 시차 $\uparrow$.

이 시차가 갭신 **횟수**에는 영향을 주지 않는다(반직관적 — FAQ에서 확인, 실습에서 직접 세어보자).

환경: 7개 상태 random walk

- 상태 0과 6: **터미널**, 1 ~ 5: 이동 상태.
- 매 스텝 50:50 좌우 이동(무작위 정책).
- 왼쪽 끝 -1 , 오른쪽 끝 $+1$ 보상. $\gamma = 0.9$, 상태 3에서 시작.
- 학습 목표: 이 환경의 **참값** $V^\pi(s)$ 와 비교해 n 번 추정 품질을 측정.

상태	참값 V^π
0	0 (터미널)
1	-0.5643
2	-0.2539
3	0 (시작, 대칭 중심)
4	$+0.2539$
5	$+0.5643$
6	0 (터미널)

$V(3) = 0, V(2) = -V(4), V(1) = -V(5).$

참값의 모양

7-state random walk에서 $n = 3$ 으로 10 에피소드 ($\alpha = 0.1$, seed 고정) 학습하면, 참값의 모양을 대략 따라가며 **오른쪽 끝(+1 목표)에 가까울수록 가치가 매끄럽게 단조 증가**(상태 $1 \approx -0.48$ 에서 오른쪽으로, 상태 $5 \approx +0.37$ 까지).

에피소드가 10개뿐이라 참값까지 다 도달하진 않지만, **방향(오른쪽 > 왼쪽)은 이미 잡혀** 있는 상태.

n-step TD 코드 (1/2)

```
def n_step_td(env_step, n, n_episodes, alpha, gamma,
              n_states, start_state):
    V = [0.0] * n_states
    for _ in range(n_episodes):
        states, rewards = [start_state], []
        s, T, t = start_state, float('inf'), 0
        while True:
            if t < T:
                a = random.randrange(2)    # 데모용무작위정책
                ns, r, done = env_step(s, a)
                states.append(ns); rewards.append(r)
                if done:
                    T = t + 1
                s = ns
            tau = t - n + 1                # tau 상태를 지금 갱신
            # --- 핵심줄은 3 다음 슬라이드에서 뜯어봄 ---
            if tau >= 0:
                G = n_step_target(tau)    # 목표값 계산
                V[states[tau]] += alpha * (G - V[states[tau]])
            if tau == T - 1:
                break
        t = T
```


n-step TD 코드 (2/2): 핵심 3줄

```
if tau >= 0:
    G = sum(gamma ** (i - tau) * rewards[i]
            for i in range(tau, min(tau + n, len(rewards))))
    if tau + n < T:
        G += gamma ** n * V[states[tau + n]] # 추정치항
    V[states[tau]] += alpha * (G - V[states[tau]])
```

- $\tau \geq 0$: 실제 보상 n 개가 다 모인 시점이므로 $G_{\tau}^{(n)}$ 계산 가능.
- $\tau + n < T$: n 스텝 윈도우가 끝나기 **전에** 에피소드가 끝나지 않았다면 $\gamma^n V(s_{\tau+n})$ 을 추가. 끝나면 **추정치 항 생략**(절단 목표값).
- 이 절단 덕분에 n 이 에피소드 길이보다 길면 **자동으로 MC**가 됨 — $n = 50$ 이 사실상 MC로 동작하는 이유(이 환경 에피소드 길이는 보통 50보다 짧음).

왜 $\tau = t - n + 1$ 인가 — 갱신 시차

- τ (갱신 대상 시점)는 항상 현재 t 보다 $n - 1$ **만큼 뒤쳐짐** — n 스텝의 실제 보상이 다 모여야 목표값을 계산 가능.
- t 가 한 스텝씩 가면 갱신 차례인 τ 도 한 칸씩 앞으로 밀려남.
- 에피소드 종료(" $t \geq T$ ") 이후에도 이 밀림이 $\tau = T - 1$ 까지 계속됨 — 아직 n 스텝 목표값을 계산 못 한 상태가 남아 있어서(꼬리 갱신).

갱신 횟수는 변하지 않는다

에피소드가 T 이동 상태면 $n = 1$ 이든 $n = T + 1$ 이든 **모든 이동 상태마다 정확히 1번씩**(총 T 번) 갱신된다. n 이 바꾸는 것은 갱신 **횟수**가 아니라, 첫 갱신까지의 **시차**와 목표값의 **구성**(실제/추정 비율).

중요: 목표값의 할인 지수를 세어라

- $G_t^{(n)}$ 정의에서 R_{t+k} 의 지수는 k . τ 번 상태 갱신 시: rewards[tau] 지수 0, rewards[tau+1] 지수 1, ..., rewards[i]의 지수는 $i - \tau$.
- 여기서 **하나만** 틀리면:

```
G = sum(gamma ** (i - tau - 1) * rewards[i] for i in ...)
# 각보상이 gamma만큼^{-1} 덜”” 할인된 -> 편향된목표값
```

- 이렇게 쓰면 $n = 1$ 일 때조차 **TD(0)의 목표값이 아님**. 2000 에피소드 학습 후에도 $V(5) \approx 0.84$ 로 참값 +0.5643에서 크게 벗어나 **수렴하지 않음**.
- 지수 하나가 틀리면 “TD(0)를 쓰는 것”이 아니라 **“편향된 목표값을 끝없이 쓰는 것”**.

online 관점 vs forward 관점

online 관점 (online view)

- 학습이 **진행되면서** 목표를 만들어 갱신.
- “지금 t 스텝을 왔다” → 지금까지 **실제로 쌓인** $R_t, \dots, R_{t+n-1}$ 으로 $G_t^{(n)}$ 계산.
- 위 코드의 $\text{tau} = t - n + 1$ 과 $\text{tau} + n < T$ 분기가 바로 산물.
- 실제 알고리즘의 **실행 순서**(갱신 시차, 에피소드 끝 처리)를 정확히 반영.

forward 관점 (forward view)

- 같은 경험(trajjectory) 위에서 n 을 바꾸면 **서로 다른 목표값**이 생김.
- $n = 1$: $R_t + \gamma V(s_{t+1})$
- $n = 2$: $R_t + \gamma R_{t+1} + \gamma^2 V(s_{t+2})$
- “ n 이 커지면 MC에 가까워진다”는 직관(목표값 **정의 자체**에서 $n \rightarrow \infty$ 가 MC 리턴)을 가장 투명하게 보여줌.

두 관점은 **동일한 알고리즘**을 기술. 7.2의 적격흔적은 “모든 n 을 동시에” 쓰면서 이 연결의 핵심이 됨.

왜 n 이 커지면 편향은 줄고 분산은 커지는가

- V 가 참값 V^π 라면 $G_t^{(n)}$ 의 기대값은 **정확히** $V^\pi(s_t)$ — 실제 보상 합이 “앞으로 받을 할인 보상의 기댓값”의 단일 샘플(모든 n 에서 성립).
- 학습 초반 $V \neq V^\pi$: 목표값에 추정치가 **일부** 섞여 있는 것 = **편향(bias)**의 출처.

편향 ↓ n 이 커지면 목표에서 추정치 비중 ↓, 실제 보상 비중 ↑ $\Rightarrow V$ 가 부정확해도 목표값이 참값에 가까워짐.


분산 ↑ 실제 보상 합이 길어지면 각 스텝의 전이·보상 무작위성이 더 많이 누적됨. MC가 “분산 극대”인 이유와 정확히 같음.

ML1 Ch. 4.1의 **편향-분산 트레이드오프**가 여기서는 n 이라는 하나의 다이얼 위 숫자로 드러남.

U자 곡선: n별 RMS 오차 (30 seed 평균)

n	RMS 오차 (10 에피소드)
1 (TD(0))	0.4007
3	0.3061 ← 이 환경·예산에서 초
5	0.3493
10	0.3994
50 (사실상 MC)	0.4170

설정: $\alpha = 0.1$, $\gamma = 0.9$, 10 에피소드, 30 seed.
오차가 n 에 대해 **U자**.



(좌) 10 에피소드: 최저점 $n = 3$. (우) 500 에피소드: 최저점이 $n = 1$ 쪽으로 **이동** ($n = 1$: 0.268, $n = 3$: 0.336, $n = 50$: 0.457).

- $n = 1$: 추정치 의존(편향)이 10 에피소드로는 씻겨나감 부족. $n = 50$: 분산이 너무 커서 적은 에피소드로 불안정.
- 데이터가 쌓이면 “갱신이 잦고 분산 작은” TD(0)의 이점이 살아나 최저점이 $n = 1$ 쪽으로 이동. 큰 n 패널티는 예산이 커져도 크게 줄지 않음.

결론: 보편적인 최적 n 은 없다

핵심

최적 n 은 에피소드 예산 · 환경의 확률적 정도 · 할인율에 따라 움직이는 하이퍼파라미터다.

이것이 실전에서 n 을 검증으로 튜닝해야 하는 이유이며, 7.2의 적격흔적이 “ n 을 고르는 문제” 자체를 피하는(모든 n 을 흔적으로 가중합) 대안인 이유이기도 하다.

n 을 고르는 경험칙

- (i) 에피소드 **짧고** 경험 **많다**: $n = \infty$ (MC)나 작은 n (TD(0))이 안전 — 편향을 씻어낼 데이터가 있으므로.
- (ii) 에피소드 **길고** 경험 **적다**: 중간 n (3~10)이 편향을 줄이면서 분산을 관리.
- (iii) 에피소드 **끝이 없다**(continuing task): MC 자체가 불가능 $\Rightarrow$ 유한 n 또는 적격흔적(7.2).

실전 DQN(Mnih et al., 2015) 계열에서도 n -step 리턴은 기본 옵션, 보통 3~10 범위로 튜닝.

자주 하는 실수 (1/2)

- **할인 지수를 잘못 세기.** $i - \text{tau} - 1$ 로 쓰면 $n = 1$ 이어도 **편향된 목표값**. 2000 에피소드 후에도 참값 미도달. “왜 안 수렴하지?” → **먼저 지수를 확인.**
- $\text{tau} = t$ (지금 상태를 지금 갱신)로 쓰기. $G_t^{(n)}$ 은 $R_t, \dots, R_{t+n-1}$ 이 다 모인 시점 $(t + n - 1)$ 에야 계산됨. $\text{tau} = t$ 면 아직 모이지 않은 보상을 참조 → **인덱스 에러**, 또는 0으로 채워져 편향. **$\text{tau} = t - n + 1$ 이 정확.**

자주 하는 실수 (2/2)

- **보상 합 상한 확인 안 하기.** 끝 근처에서는 남은 보상이 n 개보다 적음(예: $n = 3$ 인데 2스텝 남음). $\min(\text{tau} + n, \text{len}(\text{rewards}))$ 로 안 걸면 인덱스 에러 또는 “없는 보상”을 0으로 처리. 추정치 항도 $\text{tau} + n < T$ 없으면 종료 후 V 더하기 / 없는 인덱스 참조.
- “ $n > \text{에피소드 길이}$ 면 갱신 안 된다”는 오해. 갱신은 모든 이동 상태마다 정확히 1번(꼬리 갱신으로 절단 목표값 처리). n 이 바꾸는 것은 횟수가 **아니라** 시차와 목표값 구성.

자주 하는 실수 (3/3) + 실습

- “이 환경에서 $n = 3$ 이 최적”을 일반화. U자 최저점은 예산·환경에 따라 움직임(10 에피소드 $\rightarrow n = 3$, 500 에피소드 $\rightarrow n = 1$). 실전 표준: **검증 데이터로 n 을 튜닝**.

실습: U자 곡선을 직접 만들어보기

- ① 같은 random walk에서 $n \in \{1, 3, 5, 10, 50\}$, 10 에피소드 ($\alpha = 0.1, \gamma = 0.9$, 30 seed 평균) $\rightarrow$ RMS 비교. 최저점 $n = 3$, RMS 0.3061 재현.
- ② **추가 과제:** 에피소드 10 $\rightarrow$ 500으로 늘려 다시 그리면 최저점 $n = 1$ 으로 이동. “실전에서 n 을 고를 때 어떤 상황을 고려해야 하는가”를 한 문장으로 설명. (힌트: 예산 적을 때/많을 때 최저점 **위치**가 어떻게 달라지는가? 왜?)

확인 문제 (1/2)

- ① $n = 1$ 이 정확히 TD(0)임을 코드로 확인. $n=1$ 로 실행하고 갱신에 쓰인 G 가 $R_\tau + \gamma V(s_{\tau+1})$ 과 같은지 한 스텝 추적. (힌트: $\tau + 1 < T$ 일 때만 추정치 항 추가. 마지막 스텝에서는 $G = R_\tau$ 만 됨 — “터미널 V 는 0”과 일치하는가?)
- ② $n \rightarrow \infty$ 가 MC임을 확인. 에피소드가 길이 T 에서 끝나면($V(s_T) = 0$), $n \geq T$ 일 때 목표값이 실제 리턴 $G_t = \sum_{k=0}^{T-t-1} \gamma^k R_{t+k}$ 과 같은지 보여라.

확인 문제 (2/2)

- ③ **보상 가중치 버그의 효과.** $\gamma^{**}(i - \tau)$ 를 $(i - \tau - 1)$ 로 바꾸고 $n = 1, 2000$ 에피소드 $\rightarrow$ 참값 미도달 확인. “목표값의 편향이 **수렴 고정점 자체를 바꾼다**는 점을 어떻게 보여주는지” 한 문장.
- ④ **갱신 횟수 세기.** 에피소드 길이 T 에서 $n = 1, n = 3, n = T + 1$ 각각이 **몇 번** 갱신되는지 코드 추적. (힌트: τ 의 범위와 break 시점. 세 경우가 **모두 같은가?** 같은 이유?)

자주 묻는 질문 (1/2)

- **n-step TD도 부트스트래핑인가?** — 그렇다. $n < \infty$ 하면 목표값에 추정치 $V(s_{t+n})$ 이 들어 있으므로. $n \rightarrow \infty$ (끝까지 실제 보상만)일 때만 순수 MC.
- **갱신 횟수는 TD(0)·MC와 어떻게 다른가?** — **같다.** T 이동 상태면 모두 T 번. n-step은 첫 $n - 1$ 상태가 “늦어지는” 뿐이지 사라지지 않음(꼬리 갱신까지). n 이 바꾸는 것은 시차와 목표 구성. MC는 갱신 **시점**이 끝난 뒤라는 점만 다름.

자주 묻는 질문 (2/2)

- **실전에서는 n 을 얼마로?** — 후보 4~10개를 **검증 성능**으로 비교. 이 절의 실습이 그 튜닝의 축소판. DQN 구현 중엔 버퍼에서 미니배치를 이어붙여 n -step 목표값을 만드는 변형도 (Ch. 9 실습에서 마주침).
- **“ n 이 크면 분산 큼”은 갱신당 변동이 크다는 뜻인가?** — 그렇다. n 스텝치 전이·보상 무작위성이 합쳐짐(보상 0의 스텝도 “어디로 갔는가”의 전이 무작위성은 누적). 같은 총 정보를 작은 덩어리(작은 갱신) vs 큰 덩어리(드문 큰 갱신)로 나누는 것 = ML1 Ch. 9의 **배치 크기 트레이드오프**와 같은 구조.
- **적격흔적(7.2)은 정말 같은 것을 계산하나?** — “같은 효과(모든 n 가중합)를 다른 순서로 만든다”가 정확.

7.2 적격흔적과 파라미터 튜닝 실습

7.2의 두 가지

- 첫째, “ n 을 몇으로 잡을지”는 **직감으로 고를 수 없다** — 데이터로 확인해야 하는 **하이퍼파라미터**. n (7.1의 다이얼)과 λ (아래 적격흔적의 다이얼)를 바꿔가며, **20회 반복 평균**으로 U자 꼭짓점을 찾는 튜닝 실습.
- 둘째, n 하나를 고르는 대신 **모든 n 을 동시에** 처리하는 **적격흔적(eligibility trace)**:
- “이 상태가 **얼마나 자주, 얼마나 최근에** 방문됐는가”를 기록한 흔적 $e(s)$ 로, TD 오차가 발생하면 **흔적 크기에 비례해 모든 상태를 동시에 갱신**.

이 절의 주제 하나

편향-분산 트레이드오프(ML1 Ch. 4.1)를 “구체적인 숫자”로 만나는 방법.

실습: n 을 바꿔가며 최적 지점 찾기

- 같은 7-state random walk 환경. 참고: 이 절의 설정에서는 **참값** $V(s) = s/6$ (예: $V(3) = 0.5$)이 정확히 알려져 있음.
- n_step_td로 10 에피소드 학습, n 별 RMS 오차, **20회 반복 평균**:

n	평균 RMS 오차
1	0.3410
3	0.1830
5	0.1687 ← 최적
10	0.1883
50	0.2178

- 다시 **U자** — 양 극단($n = 1, n = 50$)보다 중간 ($n = 5$)이 최저. (7.1의 30 seed 실험에선 $n = 3$ 이 최저였음 — 설정·시드 수에 따라 바닥 위치가 미세하게 움직임.)
- 이 표가 아래 그림의 **왼쪽 패널**을 그대로 그린 것.

적격흔적: 모든 n 을 동시에

TD(λ)의 두 갱신식

$$e(s) \leftarrow \gamma \lambda e(s) + \mathbb{I}[s = s_t], \quad V(s) \leftarrow V(s) + \alpha \delta_t e(s) \quad (\text{모든 } s \text{에 대해})$$

- $\lambda \in [0, 1]$ 이 **새로운 다이얼**: $\lambda = 0 \Rightarrow$ 흔적이 매 스텝마다 거의 사라져 **TD(0)**, $\lambda = 1 \Rightarrow$ 흔적이 안 줄어 **MC에 가까움**.
- 이름 TD(λ)가 바로 이 다이얼에서 왔음.
- n-step TD = “ n 하나 고정해서 **전방(forward)**으로 내다봄” / 적격흔적 = “과거 방문 이력에 흔적을 남기고 **후방(backward)**으로 갱신을 퍼뜨림” — 사실상 같은 효과(전방/후방 관점의 등가성; 증명은 이 학기 범위 밖).

기원: ADALINE의 “자격 있는 시냅스”

- 이름이 생소해 보이지만 기원은 **1980년대 초** — Barto, Sutton, Anderson (1983~89) 논문.
- ADALINE(최소제곱학습기)에 “그 시점에 학습에 **자격(eligibility)**이 있는 시냅스가 어디인가”를 기록하는 장치를 처음 도입.
- 즉, 강화학습 TD(λ)가 아니라 “**어떤 시냅스가 지금 보상을 받을 자격이 있는가**”를 묻던 **신경망의 부가장치**였던 셈.
- “어떤 **상태**가 지금 TD 오차에 기여할 자격이 있는가” 로 옮겨온 것이 지금의 적격흔적.

“자격을 남기고, 나중에 그 자격만큼 크레딧을 배분한다”.

손으로 추적: $3 \rightarrow 2 \rightarrow 3 \rightarrow 4$

- 같은 random walk. 한 에피소드에서 상태 $3 \rightarrow 2 \rightarrow 3 \rightarrow 4$ 순서 방문(중간 상태라 보상 전부 0).
- $\gamma = 1, \lambda = 0.5, \alpha = 0.1, V \cdot e$ 는 0에서 시작. 각 스텝의 TD 오차 δ_t 가 이미 계산됐다고 놓고, **e 가 어떻게 변하고 V 갱신에 어떻게 쓰이는가**만 추적.
- 갱신 순서(매 스텝): **(1) $\gamma\lambda$ 로 감쇠** $\rightarrow$ **(2) 현재 상태 $+1$** $\rightarrow$ **(3) 모든 s 에 $V(s) += \alpha \delta_t e(s)$.**

다음 3프레임에 표를 $t = 0, 2, t = 3$ 으로 나눠 보여주고, 각 행의 계산을 확인한다.

추적 표 (1/2): $t = 0 \sim 2$

스텝 t	현재 상태	δ_t	이번 스텝 V 갱신
0	3	+0.4	$e(3) = 1: V(3) += 0.1 \cdot 0.4 \cdot 1 = +0.040$
1	2	+0.3	$e(2) = 1, e(3) = 0.5: V(2) += +0.030, V(3) += 0.1 \cdot 0.3 \cdot 0.5 = +0.015$
2	3	+0.5	$e(2) = 0.5, e(3) = 1.25: V(2) += +0.025, V(3) += 0.1 \cdot 0.5 \cdot 1.25 = +0.0625$

- $t = 1$: $t = 0$ 의 $e(3) = 1$ 이 0.5로 감쇠, 현재 2에 +1.
- $t = 2$: $e(3) = 0.5 \cdot 0.5 = 0.25$ 로 감쇠한 뒤 재방문에 +1 $\Rightarrow e(3) = 1.25$ — 방문 빈도가 흔적에 누적.

추적 표 (2/2): $t = 3$ 에서 한 오차, 세 상태

스텝 t	현재 상태	δ_t	이번 스텝 V 갱신
3	4	+0.2	$e(2) = 0.25, e(3) = 0.625, e(4) = 1$; $V(2) += +0.005, V(3) += +0.0125, V(4) += 0.1 \cdot 0.2 \cdot 1$

- 하나의 TD 오차 $\delta_3 = 0.2$ 가 세 개 상태 (2, 3, 4)를 동시에 갱신:

- ▶ 현재 상태 4(흔적 1)가 가장 크게,
- ▶ 직전 상태 3(0.625)이 그다음,
- ▶ 한 번 더 지난 상태 2(0.25)가 가장 작게.

이것이 “후방으로 크레딧을 퍼뜨린다”는 뜻.

- $\lambda = 0.5$ 라 기억이 1~2 스텝 전까지만 유효 — $\lambda = 0.9$ 로 올리면 훨씬 길어짐.

λ 가 n 을 어떻게 “대체”하는가

- n -step TD의 목표값 $G_t^{(n)}$: **단 하나의** n -step 리턴(정확히 n 스텝만 보고 나머지는 추정치).
- 적격흔적: 흔적 감쇠율 $\gamma\lambda$ 덕분에 t 스텝 전에 방문한 상태의 흔적은 대략 $(\gamma\lambda)^t$ 로 감소.

TD(λ)의 목표 = 한 줄

TD(λ)의 목표 $\approx$ “모든 n -step 목표의 가중평균, n 에 대한 가중치 $\propto \lambda^{n-1}$ ”

- λ **작으면** 가중치가 빠르게 λ^{n-1} 로 죽어 실질적으로 짧은 n (TD(0) 쪽)만 사용.
- λ **크면** 긴 n 에도 충분한 가중치 $\Rightarrow$ MC 쪽으로 이동.

“하나를 고르는 문제”에서 “분포의 형태”로

- n -step이 “하나의 n 을 고르는” 문제였다면, $TD(\lambda)$ 는 “가중치 분포 λ^{n-1} 의 형태”를 λ 하나로 조절하는 문제.
- 같은 편향-분산 트레이드오프를, **하나를 고르는 문제에서 분포의 형태를 고르는 문제로 승화**시킨 것.

직접 확인해야 할 한 줄

λ 를 n 으로 환산하는 근사 대응: $TD(\lambda)$ 의 **유효 수명(effective horizon)** $\sim 1/(1 - \lambda)$ **스텝**.
 $\lambda = 0.8$ 이면 대략 $1/(1 - 0.8) = 5$ 스텝 전후 — 이번 실험에서 $n = 5$ 가 최적, $\lambda = 0.8$ 이 최적인 것과 **동일한 방향**. 정확한 1:1 변환은 아니지만, “ $\lambda = 0.8$ 이 5스텝 정도 내다보는 것과 비슷하다”는 직관은 잡아둬.

실습: λ 를 바꿔가며 최적 지점 찾기



- λ 도 하이퍼파라미터 $\Rightarrow n$ 과 똑같이 **데이터로 고름**.
- 같은 random walk, 10 에피소드, $\alpha = 0.2$, $\gamma = 1$, λ 0~1, **20회 반복 평균 RMS**:

λ	평균 RMS 오차
0.0 (TD(0)와 동일)	0.3172
0.2	0.2790
0.4	0.2329
0.6	0.1774
0.8	0.1377 $\leftarrow$ 최적
1.0 (사실상 MC)	0.2674

- 다시 **U자**. 좌측 $\lambda = 0$ 은 정확히 TD(0) ($n = 1$, $\alpha = 0.2$ 결과와 같은 0.3172)라 편향 씻어내지 못함. 우측 $\lambda = 1$ 은 MC에 가까워 분산 큼.
- “ $\lambda = 0.8$ 이 만능 정답”이 아니다 — 환경·에피소드 수(예: 1000)가 바뀌면 U자 바닥은 **완전히 다른 위치**로 이동. 에피소드가 충분히 많으면 편향이 씻겨 λ 를 1에 가깝게(MC 쪽) 가져가도 좋은 경우 많음.
- “**데이터로 고르는 것**” 자체가 방법 — 검증 데이터·반복 실험으로 **매번 재확인하는 습관이 실전의 본체**.

두 개의 U자 나란히

RMS variance (mean: 10 episodes, alpha = 0.2, 20 repeat mean)



(좌) n -step: 최저 $n = 5, 0.17$. (우) TD(λ): 최저 $\lambda = 0.8, 0.14$. 10 에피소드 · $\alpha = 0.2$ · 20회 반복 평균.

두 패널이 나란하니 메시지가
선명하다

n 을 고르는 일과 λ 를 고르는 일은 같은
편향-분산 트레이드오프의 두 모습. 둘
다 U자. “ $n = 5$ ”와 “ $\lambda = 0.8$ ”은 서로
다른 문제를 푸는 게 아니라, “같은
U자에서 지금 이 데이터양·이
문제에서 바닥이 어디인지”를 각각의
다이얼 위에서 재확인한 결과일 뿐.

단 한 번의 실행은 믿지 마라


- 위 실습 코드($\alpha = 0.2$, 10 에피소드)를 **단 한 번** (시드 0)만 돌려 마지막 V 를 참값 $V(s) = s/6$ 과 비교:

	$V(1 \sim 5)$ (RMS)					
$n = 1$	0.00	0.02	0.08	0.16	0.48	(0.370)
$n = 5$	0.05	0.07	0.30	0.44	0.67	(0.201)
$n = 50$	0.12	0.20	0.37	0.56	0.81	(0.099) ← 이번엔 이게 제일 좋다
참값	0.17	0.33	0.50	0.67	0.83	

- 단일 실행에선 $n = 50$ 이 **제일 정확** — 이 실행만 보고 튜닝했다면 $n = 50$ 을 골랐을 것.
- 그러나 20회 평균에선 $n = 50$ 은 0.2178로 **양 끝 중 나쁜 쪽**. “이번엔 운이 좋아 $n = 50$ 이 잘 된” **단일 시드가 전체 U자를 완전히 역전시킨 것**.

아래 그림은 이 단일 실행(시드 0)의 세 곡선을 참값과 함께 그린 것 — $n = 50$ (빨강)이 이번 실행에선 참값에 가장 가까움.

단일 시드 vs 20회 평균



단일 실행(시드 0, $\alpha = 0.2$, 10 에피소드)의 학습 $V(s)$ 와 참값 $V^* = s/6$. $n = 1$ (회색)은 거의 0에서 움직이지 못해 큰 편향, $n = 5$ (파랑)은 중간, $n = 50$ (빨강)은 이번 실행에선 참값에 가장 가까움.

함정의 본질

하이퍼파라미터를 가르면서 단일 실행(단일 시드, 단일 검증집합)에 의존하면, “U자를 찾겠다”는 전제가 완전히 무너진다.

최적 지점을 찾는 실험은 반드시 여러 시드/반복으로 평균내야 한다 — 이 절이 실제로 강조하는 튜닝의 전제 조건.

이 절의 하이퍼파라미터 지도

방법	목표값	하이퍼파라미터(다이얼)	이 절의 결과
TD(0)	$r + \gamma V(s')$	$-(n = 1)$	U의 좌측 극단
n-step TD	n 스텝 실제 + 나머지 추정	$\mathbf{n}$	U의 바닥 $n \approx 5$
TD(λ)	모든 n 의 가중평균	λ	U의 바닥 $\lambda \approx 0.8$
(참고) MC	실제 리턴 G_t	$-(n = \infty, \lambda = 1)$	U의 우측 극단

- 여기에 α (**학습률**)과 **에피소드 수**가 겹침.
- α 는 U자의 **깊이**를, 에피소드 수는 U자의 **바닥 위치**를 동시에 바꿈 — 에피소드가 늘면 편향이 씻겨 나와 바닥이 **우측(긴 부트스트래핑)**으로 이동.
- “ $n = 5, \lambda = 0.8$ ”은 **이 실험(10 에피소드, $\alpha = 0.2$)에서의 답**이지 보편 정수가 아님.

실정: “데이터양을 늘릴수록 다이얼을 어떻게 이동시킬지”를 예상하고 검증 데이터로 확인하는 것이 정석. (TD(λ) 심화: Stanford CS234)

자주 하는 실수 (1/2)

- 첫째, “ $\lambda = 1$ 이 편향이 없으니까 무조건 낫다”. 편향이 없는 것(MC)은 분산이 최대인 극단. 10 에피소드라는 적은 데이터에선 분산이 편향보다 더 먼저 손해를 냄 $\Rightarrow$ U자 우측으로 갈수록 오히려 나빠짐. “편향만 보고 고르는” 것은 반쪽짜리 판단. 항상 편향과 분산을 합친 총 오차(RMS)로 봐야 함 — 이 절의 모든 표가 RMS로 집계된 이유.

자주 하는 실수 (2/2)

- **둘째, 단일 실행(단일 시드)으로 최적 지점 정하기.** 위 “단 한 번의 실행은 믿지 마라”가 그대로 실수. 하이퍼파라미터 실험은 필연적으로 **여러 시드·반복으로 평균**내야 U자 바닥이 안정적으로 보임. 하나의 실행은 **운**.
- **셋째, 흔적 갱신 순서를 뒤집기.** 순서는 “ $\gamma\lambda$ 로 감쇠 $\rightarrow$ 현재 상태 $+1 \rightarrow$ 모든 s 에 $V += \alpha\delta e$ ”. “ $+1$ ”을 갱신 **이후**에 하면, 그 스텝 TD 오차가 현재 상태 자신에 적용될 때 흔적이 1이 아닌 **감쇠된 값**이 되어 $\lambda = 0$ 이 TD(0)와 정확히 같아지지 않음. **건성 체크(sanity check):** $\lambda=0$ 이 $n=1$ 과 RMS가 **완전히 일치** 하는지($\alpha = 0.2$ 단일 실행에서 $0.3696 = 0.3696$). 순서가 바르면 이 일치성이 깨짐.

확인 문제

- ① **왜 U자인가.** 좌측 극단(짧은 부트스트래핑) = **편향**의 문제, 우측 극단(긴 부트스트래핑) = **분산**의 문제. 그리고 “에피소드 1000으로 늘리면 U자 바닥이 어느 쪽으로 이동할지, 왜” 한 문장씩.
- ② **흔적의 두 역할.** $t = 3$ 행에서 상태 4/3/2의 갱신 크기가 각각 다른 이유를 **흔적 값(1, 0.625, 0.25)**을 들어 설명. 상태 3이 상태 2보다 **더 큰 누적 갱신**을 받은 **두 번째 이유**(감쇠와 무관한 이유) 짚기. (힌트: 재방문 $\Rightarrow e(3) = 1.25$.)
- ③ **코딩.** $\text{td_lambda}(\lambda = 0)$ 의 마지막 V 가 같은 설정 $\text{n_step_td}(n=1)$ 과 RMS가 일치하는지 ($< 10^{-9}$ 차이) `assert`로 확인. 이 검증이 “적격흔적 코드가 올바른가”를 어떻게 보장하는지 한 문장.

자주 묻는 질문 (1/2)

- **에피소드 수가 많으면 $\lambda = 1$ (MC) 쪽이 좋아지나요?** — MC의 단점은 **분산**이지 편향이 아님. 에피소드 10개면 각 갱신이 “그 에피소드의 운”에 크게 흔들리지만 1000개면 무작위성이 **평균에 의해 서로 상쇄**되어 MC의 분산이 거의 사라짐 $\Rightarrow$ 남는 건 편향뿐(MC는 0) $\Rightarrow \lambda = 1$ 이 가장 정확. 반대로 에피소드가 적으면 편향·분산 중 **어느 쪽이 더 큰 손해인가**가 U자 좌/우 기울기를 정함.

자주 묻는 질문 (2/2)

- **“모든 상태 동시 갱신”의 계산 비용은 터지나?** — 갱신 대상 = 방문한 상태 수(보통 5개). 매 스텝 5번 곱셈+덧셈 = TD(0)의 “매 스텝 1번” 대비 **상당히 가벼운 증가**. 상태 10만 개(고차원 격자) 수준에선 “모든 상태 순회”가 병목 $\Rightarrow$ 실전에서는 **흔적 0인 상태를 건너뛰는 희소(sparse) 구현**, 또는 DQN처럼 **신경망 + 적격흔적 조합**. 핵심 구조적 아이디어(후방 크레딧 배분)는 그대로, 계산 표현만 상황에 맞게 최적화.

이 절의 핵심 한 줄

적격흔적은 “ n 하나를 고르는 것”을 “모든 n 의 가중분포를 λ 하나로 조절하는 것”으로 승화시킨 기법. 분포의 형태(λ) + 학습률(α) + 데이터량(에피소드 수) 셋이 **함께** U자 바닥을 정하므로, 이 셋을 **데이터로 튜닝**하는 것이 실전의 전부.

7.3 계획과 학습: Dyna-Q

경험을 버리지 않는 법

- 지금까지의 모델-프리 방법(MC, TD, Q-learning)은 경험을 **한 번 쓰고 버림**.
 - 그런데 한 스텝 $(s, a) \rightarrow (r, s')$ 에는 두 가지가 담겨 있다:
 - ▶ (1) **Q를 갱신할 신호**(TD(0) 갱신)
 - ▶ (2) **환경에 대한 지식** — “ (s, a) 를 하면 대략 (r, s') 이 나온다”.
- 모델-프리는 (2)를 **버림**.
- (2)는 어디에 쓰이는가? — **아직 실제로 가보지 못한 상태의 가치를 추정**하는 데.

(Sutton, 1990 박사논문)

이 정보를 간단한 **모델**로 저장해뒀다가, 실제 상호작용 사이사이에 **가상의 추가 학습(계획, planning)**을 끼워 넣는다.

왜 모델을 저장하는가 — 상호작용이 비쌀 때

- 실제 환경 상호작용의 **비용이 비쌀수록**, “간접적으로 값을 아는 것”의 가치가 큼.
- 로봇 한 칸 이동에 몇 초, 실험실 화학 반응은 하루를 넘길 수 있음.
- 실제 스텝 1회당 Q 갱신 횟수를 10배로 늘려주는 것은 **학습에 소요되는 실세계 시간을 10분의 1로 줄여주는 것과 같음**.

Dyna-Q의 계산

learning rate를 높이는 대신, **같은 실제 경험**으로 더 많은 갱신을 만들어내는 것. 아주 단순한 구조로 해냄: “**본 (s, a) 의 마지막 (r, s') 를 기억하는 표**”.

Dyna-Q 코드: 경험 → 학습 → 모델 저장 → 계획

```
def dyna_q(env_step, n_states, n_actions, n_episodes,
           planning_steps, alpha, gamma, epsilon, start_state):
    Q = [[0.0] * n_actions for _ in range(n_states)]
    model = {} # (s, a) -> (r, s') 관찰한것을그대로저장
    for _ in range(n_episodes):
        s = start_state
        for _ in range(100):
            a = random.randrange(n_actions) if random.random() < epsilon \
                else max(range(n_actions), key=lambda x: Q[s][x])
            ns, r, done = env_step(s, a)
            Q[s][a] += alpha * (r + gamma * max(Q[ns]) - Q[s][a]) # 1) 실제학습
            model[(s, a)] = (r, ns) # 2) 모델갱신
            for _ in range(planning_steps): # 3) 계획
                (ps, pa), (pr, pns) = random.choice(list(model.items()))
                Q[ps][pa] += alpha * (pr + gamma * max(Q[pns]) - Q[ps][pa])
            s = ns
            if done:
                break
    return Q
```

결정론적 환경 가정(같은 (s, a) 은 항상 같은 (r, s') 을 냄). `planning_steps`가 클수록 실제 스텝 1회당 경험을 모델을 통해 “몇 번이고 복습”.

실제 숫자: 같은 환경, 계획이 있는가

- 같은 격자 환경에서, 목표 상태(state 3, 오른쪽으로 가는 행동)의 Q 값이 0.5를 넘어서기까지의 에피소드 수:

설정	0.5 초과까지 에피소드
planning_steps=0 (순수 Q-learning)	253
planning_steps=10	9 ← 매 실제 스텝마다 모델로 10번 추가 학습

핵심

같은 실제 경험으로, 계획이 있는 쪽이 훨씬 더 많은 것을 뽑아낸다.

역사적 맥락: 학습과 계획을 하나의 루프로

- “Dyna”라는 이름은 **1990년 Richard Sutton의 박사논문**에 등장.
- 당시는 **학습(샘플로)**과 **계획(모델로)**을 서로 다른 연구 분야로 봄.
- Sutton은 이 둘을 **하나의 루프** 안에 넣고:

Dyna의 구조

학습이 만든 모델이 계획을 하고, 계획이 학습을 가속한다.

- 이후 **모델 기반 강화학습(model-based RL)**의 거의 모든 변형은 이 Dyna의 골격(실제 경험 $\leftrightarrow$ 모델로 계획, 두 루프 병행) 위에서 변주.
- Ch. 15.2의 **AlphaGo/AlphaZero**(Silver et al., 2016/2018)의 “신경망 $\leftrightarrow$ MCTS 탐색이 서로를 개선”도, 동전이 하나 뒤집힌(신경망 = 모델, MCTS = 계획) **같은 구조**.

손으로 계획 한 스텝: 3상태 예제

- 상태 S (출발) $\rightarrow X \rightarrow T$ (목표, 종료), 각 상태마다 행동 하나, 전이는 **결정론적**.

$$S \xrightarrow{a} X \text{ (보상 0)}, \quad X \xrightarrow{a} T \text{ (보상 +1)}, \quad \gamma = 0.9, \alpha = 0.5$$

- 참값(벨만방정식 **거꾸로** 쓰기): $Q(T) = 0, Q(X) = 1 + \gamma \cdot 0 = 1, Q(S) = 0 + \gamma \cdot 1 = 0.9$.
- 이 “**거꾸로**” 방향이 핵심 — 아래에서 실제로 어떻게 일어나는지 추적.

추적 (1/3): 실제 경험만 있으면 $Q(S)$ 는 안 움직임

- 초기 $Q(S) = Q(X) = Q(T) = 0$.
- 에이전트가 **실제로** $S \rightarrow X$ (보상 0) 한 번 경험:

$$Q(S) \leftarrow 0 + 0.5 (0 + 0.9 \cdot Q(X) - 0) = 0$$

$Q(X)$ 가 아직 0이라 $Q(S)$ 는 **안 움직임**. 여기까지가 순수 Q-learning이 할 수 있는 전부.

- 이어서 **실제로** $X \rightarrow T$ (보상 +1) 경험:

$$Q(X) \leftarrow 0 + 0.5 (1 + 0.9 \cdot 0 - 0) = 0.5$$

모델에는 $(X, a) \rightarrow (1, T)$ 가 추가됨.

추적 (2/3): 계획 한 스텝이 $Q(S)$ 를 움직인다

- **계획 한 스텝** 등장: 모델에서 무작위 (s, a) 를 뽑았는데 (S, a) 가 뽑힘(모델엔 이미 $(S, a) \rightarrow (0, X)$ 존재).
- 모델이 예측한 (r, s') 을 그대로 TD(0) 갱신에 사용:

$$Q(S) \leftarrow 0 + 0.5 \left(0 + 0.9 \cdot \underbrace{Q(X)}_{0.5} - 0 \right) = 0.5 \times 0.45 = 0.225$$

Dyna-Q의 본질

에이전트는 S 에 다시 발을 디딤 없이, X 에서 막 배운 값(0.5)이 모델을 타고 S 로 “거꾸로” 퍼졌다. 실제 경험이 한 상태의 Q 를 바꾸면, 계획은 그 변화가 **모델로 연결된 다른 상태들의 Q 에까지 퍼지도록** 만든다.

추적 (3/3): 몇 번만 더 하면 참값에 수렴

- 계획을 몇 번만 더 하면 $Q(S) \rightarrow 0.9$, $Q(X) \rightarrow 1$. (실제로 (X, a) 가 뽑히면 $Q(X)$ 쪽이 1로, (S, a) 가 뽑히면 $Q(S)$ 쪽이 0.9로 각각 접근.)

핵심 직관

TD(0)은 “현재 상태에서 **앞으로** 한 스텝”을 보지만, 계획은 “모델이 기억하는 (s, a) 에서 **모델을 따라** 한 스텝”을 보므로, **실제 이동 없이도 상태 공간 전체에 걸쳐 값을 퍼뜨릴** 수 있다.

실제 경험 = 신뢰할 수 있는 신호, **계획** = 그 신호를 넓게 퍼뜨리는 역할.

세 가지 축을 한자리에

방법	목표값	특징
MC (Ch. 5)	실제 리턴 G_t	편향 없음, 분산 큼, 에피소드 종료 필요
TD(0) (Ch. 6)	$r + \gamma V(s')$	편향 있음, 분산 작음, 매 스텝 학습
n-step TD	n 스텝 실제 + 나머지 추정	둘 사이 절충, n 이 다이얼
TD(λ)	모든 n 을 흔적으로 가중평균	n 고정 불필요, λ 가 다이얼
Dyna-Q	TD(0) + 학습된 모델로 계획	모델-프리와 모델-기반 결합

Block A 전체의 그림

이번 학기 Block A 전체가 사실 **“부트스트래핑을 얼마나 할 것인가”**라는 하나의 질문에 대한 서로 다른 답. 이번 장(7.1~7.3)은 그 질문에 n , λ , 계획이라는 세 종류의 추가적인 다이얼/루프를 더했다.

실습: 5×5 격자의 환경과 참값

- **환경:** 5×5 격자. 출발 $(4, 0)$ (아래 왼쪽), 목표 $(0, 4)$ (위 오른쪽), 4방향 이동, 벽 부딪히면 자리에 남음. 매 이동 **보상** -1 , 목표 도착 시 0 으로 종료. $\gamma = 1$ (유한하고 반드시 끝나는 과업이라 할인 불필요 — 5.2절 블랙잭과 같은 이유), $\alpha = 0.1, \varepsilon = 0.1$.

참값은 손으로 나온다

맨해튼 거리 $|4 - 0| + |0 - 4| = 8$ 스텝. 8번 이동 중 7번이 -1 , 마지막(목표 도착)이 $0 \Rightarrow$ **최적 리턴 정확히** -7 , $V^*(\text{출발}) = -7$.

“**위 또는 오른쪽**, $Q^* = -7$ ” — 위·오른쪽이 최단 경로 첫 스텝. 아래/왼쪽으로 한 칸 빠지면 9스텝이 되어 $Q^* = -8$. 학습 결과가 이 값에 접근하는지로 “잘 학습했는가”를 **숫자로 바로 판정**.

실습 코드: 5×5 격자 Dyna-Q

```
ACTIONS = [(-1, 0), (1, 0), (0, -1), (0, 1)] # up, down, left, right
START, GOAL = (4, 0), (0, 4)
```

```
def step(s, a):
    r, c = s
    nr = min(max(r + ACTIONS[a][0], 0), 4)
    nc = min(max(c + ACTIONS[a][1], 0), 4)
    ns = (nr, nc)
    if ns == GOAL:
        return ns, 0.0, True
    return ns, -1.0, False
```

```
def dyna_q_grid(n_episodes, planning_steps,
                alpha=0.1, gamma=1.0, epsilon=0.1, seed=0):
    rng = random.Random(seed)
    Q, model, returns = {}, {}, []
    for _ in range(n_episodes):
        s, ret = START, 0.0
        for _ in range(100):
            a = rng.randrange(4) if rng.random() < epsilon \
                else max(range(4), key=lambda x: Q.get((s, x), 0.0))
            ns, r, done = step(s, a)
            Q[(s, a)] = Q.get((s, a), 0.0) + alpha * (
                r + gamma * max(Q.get((ns, x), 0.0) for x in range(4))
            )
            returns.append(r)
            if done:
                model[(s, a)] = ns
                s = ns
        returns.append(ret)
```



실험: planning_steps 0 → 30

- 400 에피소드 학습(시드 0, 시드 1~3으로 재현 확인).
- 지표: “**25에피소드 평균 리턴이 최적치(-7)에서 1.0 이내(> -8)로 처음 들어가는 에피소드**”.

planning_steps	수렴 에피소드 (시드 0)	시드 1~3	400 에피소드 후 max Q (start)	모델
0 (순수 Q-learning)	334	334~387	-6.61	
5	75	65~75	-7.00	
10	52	51~55	-7.00	
30	35	35~61	-7.00	

커버리지: 400 에피소드 후 100개 (s, a) 중 95~96개 모델에 저장.

그래프로 보는 세 가지 발견



(좌) 매 에피소드 $\max_a Q(\text{출발}, a)$ 학습 곡선(원본 + 25에피소드 이동평균). 4개 곡선이 참값 -7 에 접근. (우) “ -8 위로 처음 오르는 에피소드” 막대 그래프 — $334(0) \rightarrow 35(30)$, **약 9.5배** 빠름.

- 1 **가속은 극적.** $334/35 \approx 9.5$ 배. 실제 상호작용 **35회**로, 계획 없이는 334회 걸렸던 학습이 끝.
- 2 **한계 효과 감소.** $0 \rightarrow 10$: $334 \rightarrow 52$ (약 6배). $10 \rightarrow 30$: $52 \rightarrow 35$ (약 1.5배)로만.
- 3 **모델은 거의 포화.** 100개 (s, a) 중 95~96개 커버. 작은 격자라 거의 모든 (s, a) 가 1회 이상 방문 — 이 커버리지가 계획 품질의 상한선.

Dyna-Q 루프 구조도



Dyna-Q 루프: (1) 실제 경험으로 TD(0) 갱신, (2) $\text{model}[(s,a)] = (r,s')$ 저장, (3) 모델에서 `planning_steps`번 무작위 (s,a) 뽑아 가상 TD(0) 갱신. 실제/계획 갱신 **모두 하나의 Q 테이블**로 모이고, 그 Q에서 ϵ -greedy 행동을 뽑아 다시 환경으로.

왜 `planning_steps`이 하이퍼파라미터인지

7.2에서 n 을 “편향-분산 사이 어딘가”로 튜닝했듯이, 여기서는 `planning_steps`를 “**계산 비용 대 가속 효과**” 사이 어딘가로 튜닝.

이번 실험: **10~30이 좋은 구간**. 0(계획 없음)과 “무한히 크게”(아래 실수 3 참조)는 둘 다 극단.

자주 하는 실수 (1/3)

- **1. 모델에 없는 (s, a) 를 직접 조회 $\Rightarrow$ `KeyError`.** `model`은 **희소(sparse) 딕셔너리** — 아직 한 번도 경험하지 않은 (s, a) 는 딕셔너리에 **그냥 없음**. `model[(s,a)]`로 직접 인덱싱하면 처음 방문하지 않은 상태에서 바로 `KeyError`.
- **정답:** 계획은 반드시 `model.items()`에서 **이미 있는** (s, a) 를 무작위로 뽑아야 (`random.choice(list(model.items()))`).
- “모델이 아직 불완전하다”는 것은 버그가 아니라 **정상 상태** — 초반엔 모델이 거의 비어 계획이 거의 아무것도 안 하고, 경험이 쌓일수록 계획 품질도 함께 올라감.

자주 하는 실수 (2/3)

- 2. “실제”와 “계획”을 별도 Q 테이블 두 개로 갱신. Dyna-Q가 작동하는 전부의 이유가 두 갱신이 같은 Q 테이블을 공유하는 것.
- 계획만 Q_{plan} , 실제 행동만 Q_{real} 로 하면, 계획이 만든 값 향상은 **실제 행동에 한 번도 반영되지 않음** $\Rightarrow$ 계획을 아무리 많이 돌려도 실제 학습속도가 1도 안 좋아짐.
- 검증: 이 절 코드에서 Q 가 **하나**이고, 1번 줄(실제)과 3번 줄(계획)이 **모두 그 Q 를 갱신하는지** 확인.

자주 하는 실수 (3/3)

- **3. `planning_steps`를 아주 크게 잡기.** 계획 1회 비용 $\approx$ 실제 스텝 1회 비용.
- 그런데 **모델 오차도 함께 “복리”로 증식** — 모델이 부정확한 초반에 계획을 과도하게 반복하면 그 오차가 Q 값에 **강하게 반영되어 오히려 학습을 방해.**
- 단순 계산량으로도 `planning_steps`=1000이면 실제 스텝 1회당 계획 1000회 $\Rightarrow$ **수렴은 빨리 안 되면서 만성적으로 느려짐.**

실전

`planning_steps`도 α, ϵ 과 같은 하이퍼파라미터로, 검증 성능으로 튜닝.

확인 문제

- ① **공유 테이블.** dyna_q_grid에서 계획 갱신(3번 단계)을 Q_plan 별도 딕셔너리로 분리하면, planning_steps=30의 수렴 에피소드가 순수 Q-learning(334)과 어떻게 달라지는지 **숫자 없이** 한 문장. (힌트: 계획의 산출물이 어디로 가는가.)
- ② **모델 커버리지.** 400 에피소드 후에도 100개 (s, a) 중 4개(4%)가 모델에 안 들어감. 이 “없는 4개”가 계획에 미치는 영향을 `random.choice(list(model.items()))`의 관점에서 설명.
- ③ **참값 판정.** 학습 후 Q 에서 $\max(Q[(\text{START}, 0 \sim 3)]) = -7.00$ 이고 $\arg \max$ 가 “위”(action 0) 또는 “오른쪽”(action 3)이면, 이 정책이 **최적**인 근거가 손계산 참값(위/오른쪽 = -7, 아래/왼쪽 = -8)에 어떻게 대응하는지 설명.

자주 묻는 질문 (1/2)

- **Dyna-Q의 모델은 항상 정확한가?** — 학습 초반엔 **전혀 그렇지 않음**. 몇 번밖에 못 가본 (s, a) 쌍의 모델은 부정확하거나 아예 없을 수 있음. 그런데도 작동하는 이유: 모델이 부정확해도 **“그 부정확한 모델로 계획한 결과”가 “아무것도 안 하는 것”보다는 대체로 낫고**, 실제 경험이 쌓일수록 모델도 함께 정확해져 계획 품질도 좋아짐.
- **planning_steps를 무한히 늘리면 항상 좋아지나?** — 실제 스텝 1회당 계획에 쓰는 계산량이 커질 뿐, 계획 자체는 **이미 모은 경험 이상의 새 정보를 만들어내지 못함**. 모델이 부정확한 상태에서 계획만 과도하게 반복하면 그 부정확함이 Q 에 더 강하게 반영 $\Rightarrow$ 오히려 해로울 수 있음(모델 오차의 “복리 효과”). 실전: **검증 성능으로 튜닝**.

자주 묻는 질문 (2/2)

- **Dyna-Q는 on-policy인가, off-policy인가?** — **off-policy**. Q 갱신 방식은 6.3절 Q-learning과 **완전히 같음** — 목표값에 $\max_a Q(s', a)$ (탐욕). 계획이 모델에서 (s, a) 를 무작위로 뽑는 것은 “행동 정책”이 아니라 “어떤 (s, a) 의 Q 를 갱신할지”를 고르는 것. 갱신 본질엔 여전히 max가 들어감.
 - **DQN의 경험 재사용(experience replay, Ch. 9)과 무엇이 다른가?** — 공통: “과거 경험을 재사용해 실제 스텝당 갱신을 여러 번”. 차이: **재사용의 원천**.
 - ▶ **재생**: 실제 (s, a, r, s') 튜플을 버퍼에서 다시 뽑아 씀 $\Rightarrow$ **모델 오차 없음**. 단, 경험한 전이만 재사용할 뿐 새로운 전이는 못 만듦.
 - ▶ **Dyna-Q 계획**: 모델 예측 (r, s') 으로 갱신 $\Rightarrow$ **모델 오차 동반**. 단, 모델이 연결한 아직 경험하지 않은 상태의 전이까지 만들 수 있음.
- “안전하지만 새것을 못 만든다”(재생) vs “새것을 만들 수 있지만 오차가 동반된다”(계획) — 이 트레이드오프가 Ch. 9 이후 모델 기반 DQN 변형들의 줄거리.

언제 Dyna-Q가 특히 효과적인가

Dyna-Q가 좋은 상황

- 실제 상호작용이 **비싸고** (로봇, 물리 실험, 자연 큰 시스템)
- 환경이 충분히 **규칙적**해서 간단한 모델로 대략 잡아낼 수 있을 때.

모델-프리가 더 좋은 상황

- 상호작용이 **아주 싸고**(시뮬레이션, 게임)
- 모델 학습이 **어렵거나**(강한 난수성, 비마르코프성) 신뢰할 수 없을 때.

첫 번째 판단 기준

“모델을 만들 수 있는가, 만들어도 신뢰할 만한가” — Dyna-Q를 쓸지 말지의 첫 번째 기준.

이번 주차 정리

- **7.1 n-step TD** — $G_t^{(n)}$ 은 MC와 TD(0) 사이의 하나의 다이얼. $\tau = t - n + 1$ 의 갱신 시차, 할인 지수 하나만 틀리면 $n = 1$ 이어도 **편향된 고정점**. 7-state random walk에서 30 seed 평균 $\Rightarrow$ **U자**. 보편적 최적 n 은 없으므로 검증으로 튜닝.
- **7.2 적격흔적** — 흔적 $e(s)$ 로 하나의 TD 오차가 **모든 상태를 동시에** 후방 갱신. λ 는 “ n 하나 고르기”를 “가중치 분포 λ^{n-1} 의 형태 고르기”로 승화. **단일 실행은 믿지 말 것** (20회 반복 평균). $\lambda = 0 \Leftrightarrow \text{TD}(0)$, $\lambda = 1 \Leftrightarrow \text{MC}$ 건성 체크.
- **7.3 Dyna-Q** — 본 (s, a) 의 (r, s') 를 모델로 저장, 실제 스텝마다 모델에서 가상 TD(0) 갱신. **실제/계획이 같은 Q 테이블 공유**가 전부. 5×5 격자: $334 \rightarrow 35$ 에피소드(약 9.5배), 한계 효과 + 모델 커버리지가 상한.

다음 주 — Chapter 8. Block A 캡스톤

Gymnasium의 표 기반 환경에서 **n-step TD · TD(λ) · Dyna-Q**를 팀 프로젝트로 직접 **구현·비교**. 이번 주 세 다이얼이 **같은 질문**(“부트스트래핑을 얼마나 할 것인가”)의 서로 다른 답이라는 것만 기억하면, 비교 설계가 훨씬 수월해진다.