

Block B 캡스톤: 팀 프로젝트와 학기 총정리

16.1 팀 프로젝트: 발표 · 16.2 Peer-Review · 16.3 ML2 총정리와 학기를 넘어서

Machine Learning 2 · 16주차

한국과학영재학교 (KSA)

Chapter 16

이번 주차 개요

이 챕터를 마치면

- ① 연속제어 환경에서 4주 파이프라인(환경 고르기 → 구현 → 평가 → 발표)으로 팀 프로젝트를 설계·실행하고, “시드 ≥ 3 · 무작위 정책 베이스라인 · 학습/평가 분리” 프로토콜을 실제로 수행할 수 있다.
 - ② “학습 곡선이 올랐다”와 “배운 정책이 무작위보다 낫다”가 서로 다른 문장임을 구분하고, 학습 도중(탐험 포함) 성과와 학습 후 결정적($a = \mu$) 평가의 격차를 11.2절의 분산 원리로 해석할 수 있다.
 - ③ 5항목 체크리스트와 1점(감상평) → 3점(반박 가능한 질문) 기준으로 다른 팀의 발표를 심사하는 peer-review를 작성할 수 있다.
 - ④ 학기 전체를 “모델 정의 → 틀린 정도를 수치화 → 개선” 3단계로 정리하고, 학기 이후 방향(오프라인 RL · 범용 로봇 정책 · sim-to-real)을 자기 언어로 말할 수 있다.
- **16.1** 팀 프로젝트: 발표 — Pendulum 실습, 시드 3개, 결정적 평가, 4주 파이프라인
 - **16.2** Peer-Review — 이번엔 네가 심사위원. “우연히 좋은” 패턴 5가지
 - **16.3** ML2 총정리 — 하나의 MDP를 네 경로로, 20문항 자가진단, 최신 동향

Ch. 9-15로 새 도구(신경망·시뮬레이션·트리 탐색)를 다 갖췄다. 이 장부터는 배울 개념이 남지 않는다 — 도구를 로봇 시뮬레이션에 직접 적용해, 그 결과를 정직하게 보고하는 것으로 학기를 마무리한다.

16.1 팀 프로젝트: 발표

왜 지금 프로젝트를 하는가 — Chapter 8의 쌍(pair)

- 8.1 Block A 캡스톤: “코드가 동작한다” vs. “내가 문제를 설계하고 평가할 수 있다”의 차이에 대한 첫 답.
- Ch. 9–15가 두 번째 절반의 도구를 전부 줬다: 표 대신 **신경망(DQN)**, 정책을 직접 학습(REINFORCE·PPO), 시연·선호로부터 배우기(모방학습), 물리 시뮬레이션(MuJoCo·Isaac Sim), 트리 탐색(MCTS).
- 16.1 = Chapter 8과 쌍인 절** — 같은 절차(환경 고르기 → 구현 → 시드 프로토콜 → 수식적 정당화 → 정직한 발표)를 **완전히 다른 무대**(연속제어 + 신경망)에서 다시 집행.

	Block A (8.1)	Block B (이 절)
환경	표 기반(이산 상태·행동)	연속제어(연속 상태·행동)
알고리즘	2개 이상(Q-learning vs SARSA)	1개 이상(DQN/PPO/모방/MCTS)
평가 프로토콜	$\epsilon = 0$ (greedy) 에피소드	결정적 실행 $a = \mu$ 에피소드
1시드 예산	초~분 단위	Pendulum 12만 스텝 $\approx 20\sim 30$ 초 $\sim$ MuJoCo
시드 ≥ 3 · 베이스라인	동일	동일

왜 알고리즘은 “1개 이상”인가

- Block A: 두 번째 알고리즘은 갱신 규칙 한 줄의 차이(6.3) — Q-learning vs SARSA.
- Block B: 각 알고리즘이 **별개의 신경망 학습 파이프라인**.
 - ▶ DQN: 리플레이 버퍼 + 타깃 네트워크가 따라온다.
 - ▶ PPO: GAE + 클리핑이 따라온다.
 - ▶ 모방학습: 시연 데이터셋이 따라온다.
- 팀 단위 현실적 예산: “한 파이프라인을 제대로 돌리고, 여유가 있으면 비교”.

변하지 않는 것이 핵심

시드 $\geq 3 \cdot$ 베이스라인(무작위 정책) $\cdot$ 학습/평가 분리하는 알고리즘과 무관한 **강화학습 실험의 골격**이라 Block A와 동일하다.

역사: 왜 Pendulum인가

- OpenAI 생태계(baselines → stable-baselines) 시대부터 연속 제어의 “hello world” — 라이브러리 PPO 튜토리얼의 표준 예제.
- PPO 논문(Schulman et al., 2017)은 같은 계열의 MuJoCo 연속 제어 고전 과제(Swimmer, Hopper 등)에서 검증.
- Pendulum은 그중 **가장 작은** 구성원: 3차원 상태, 1차원 행동, 에피소드 종료도 목표 상태도 없음 — “매 스텝 균형을 해야 하는” 보상이 연속 제어의 본질적 어려움을 최소 분량에 담는다.

첫 과제로 고르는 이유는 “쉬워서”가 아니라, 그 보상 구조가 학습 곡선 위에서 “정책이 지금 무엇을 하고 있는지”를 가장 선명하게 보여주기 때문이다.

프로젝트 구조 — 환경 · 적용 · 필수 요구사항

- **환경:** PyBullet 또는 Gymnasium의 연속제어 환경 (Pendulum, MuJoCo 기반 로봇 등) 중 하나.
- **적용:** Chapter 9–15 중 **최소 하나의 방법**(DQN, PPO, 모방학습, MCTS)으로 정책을 학습.
- **필수 — 수식적 정당화 최소 1개, 예:**
 - ▶ PPO: Ch11.3의 클리핑이 학습 안정성에 미친 영향(있음/없음 비교)
 - ▶ 모방학습: Ch12.1의 복합 오차 관찰(전문가 데이터 분포 밖 성능 저하)
 - ▶ 도메인 무작위화: Ch13.1의 현실 격차 논의와 연결해 효과 설명
- **학습 곡선(에피소드별 누적 보상)은 반드시 제시** — 지도학습의 손실 곡선에 해당하는, “학습이 실제로 되고 있는가”의 기본 증거.

환경 고르는 실전 가이드 — 후보에 점수를 매기자

- ① **상태·행동 공간의 차원** — 차원이 높으면 학습 예산이 급격히 커짐(예: HumanoidStandup은 348×17).
- ② **보상 구조** — “항상 음수(0이 목표)”형(Pendulum)과 “희소(목표 도달 시에만)”형(13.1 Reacher)은 **좋은 정책의 모습** 자체가 달라 평가 지표의 의미가 달라진다.
- ③ **시뮬레이션 격차가 보일 만큼 물리적으로 풍부한가** — 13.1 도메인 무작위화를 제시하려면 Pendulum은 격차가 안 나와 MuJoCo 로봇이 적합.
- ④ **코드 재사용성** — Ch11.2의 PPO 코드가 거의 그대로 적용되는가.

왜 점수 매기기를 하는가

기준을 먼저 정해두면 **팀 회의가 쉬워진다**(8.1절의 방식 그대로). 환경은 “임의로 고르는” 것이 아니라 기준에 대해 점수를 받는 것.

환경 후보 비교 — Block B 대표 4종

환경	상태×행동	보상 구조	에피소드
Pendulum-v1	3×1 (연속)	$r = -\theta^2 - 0.1\dot{\theta}^2 - 0.001a^2$, 항상 음수(0=완벽)	200
CartPole-v1	4×2 (이산)	생존 시 스텝당 -1, 쓰러지면 종료	500
MountainCar-v0	2×3 (이산)	스텝당 -1 (희소)	200
HumanoidStandup-v5	348×17 (연속)	포텐셜 기반 shaping(Ch14)	1000

보상 구조의 “형”이 다르면 좋은 정책의 **모습** 자체가 달라 — 평가 지표의 의미가 바뀐다.

환경-알고리즘 “페어링” 논리

- “잘 어울리는” 열의 논리가 핵심 — 환경과 알고리즘은 “검증하고 싶은 개념이 돋보이는 무대”가 무엇인가를 기준으로 짝을 이루어 골라야 한다.
- 11.3의 클리핑(있음/없음)을 발표하고 싶으면 → 연속 행동 공간에서 클리핑이 실제로 발동하는 **Pendulum**.
- 13.1의 도메인 무작위화를 발표하고 싶으면 → 격차가 생길 만큼 물리적으로 풍부한 **MuJoCo** 환경.
- 12.1의 복합 오차를 발표하고 싶으면 → **전문가 시연 데이터셋**이 있는 모방학습 과제.

“PPO를 쓰고 싶은데 환경을 뭐로 하지?”는 순서가 틀린 질문.
“개념 X를 테스트하고 싶은데 무대는 어디인가?”가 올바른 질문이다.

베이스라인: 무작위 정책의 리턴을 먼저 재자

- M1 제출물의 핵심 숫자 — “배운 정책이 실제로 무작위보다 나은가”를 판정할 **제로점**이 없으면 “개선됐다”고 말할 수 없다.
- Pendulum-v1 매 스텝 무작위 토크 정책(100 에피소드)의 평균 리턴: -1274.1 (**sd 300.0**), 대략 $[-1800, -760]$ 구간에 분포.
- **읽기 1** — “0”과 “좋은”의 거리가 표 기반보다 훨씬 크다. CliffWalking은 무작위 $-5000 \rightarrow$ 학습 후 -13 (400배 격차)였는데, 여기서 “좋은”이 0이고 무작위가 이미 $-1274 - 0$ 까지의 **거리 자체가 지표**.
- **읽기 2** — 아무것도 하지 않는 정책이 생각보다 나쁘지 않다. 토크 0 고정(zero-torque)이 약 -1230 으로 무작위와 같은 등급.
- “학습 곡선이 -1200 부근에서 시작한다”는 사실은 **학습의 증거가 전혀 안 된다** — 이 두 숫자(무작위 -1274 , zero-torque -1230)를 먼저 재야 “PPO가 -673 (무작위의 절반)”이라는 판단이 성립한다.

비교 프로토콜: 연속제어 버전 3개 항목

8.1절 프로토콜(시드 ≥ 3 , 학습 중/학습 후 분리, 시드별 표)을 연속제어로 번역 — 1·3은 그대로, 두 번째가 번역된다.

- ① **학습 시드 ≥ 3 개** — 시드를 바꾸는 것은 “실험을 다시 하는” 것이 아니라 **“우연인지 재검사하는”** 것. PPO는 초기화·샘플링·데이터 분할의 무작위성이 겹쳐 같은 코드도 시드만 바뀌어도 곡선 모양이 달라짐 (11.2: 큰 그림은 시드마다 안정적이나 마지막 10에피소드 평균은 $\pm 100 \sim 200$ 흔들림).
- ② **학습 도중 성과 vs 학습 후 평가** — $\varepsilon = 0$ 의 “번역 문제” (다음 프레임).
- ③ **알고리즘/시드별 숫자를 표로 제시.**

표 기반 ε -greedy에는 깔끔한 핸들이 있었음: 평가 때 $\varepsilon = 0$ 으로 하면 “순수 탐욕적”. 연속 정책 $a \sim \mathcal{N}(\mu_\theta(s), \sigma_\theta^2)$ 에는 ε 이라는 핸들이 없다.

$\varepsilon = 0$ 의 대응물 — 왜 $a = \mu$ 인가

대응 원리

- 학습 도중(샘플) 평가: 학습 중과 같은 $a = \mu + \sigma z$ 로 실행 — 탐험 노이즈가 섞인 성과.
- 학습 후(결정적) 평가: $a = \mu_{\theta}(s)$ 만 내보내고 샘플링 안 함 — 연속제어의 “greedy 평가” 대응물.

왜 $a = \mu$ 가 $\varepsilon = 0$ 인가?

- ε -greedy에서 ε 의 역할 = “확률 ε 로 아무 행동이나”.
- 정규분포 정책에서 “아무 행동”에 해당하는 것은 샘플링 노이즈 z — 빼면 “정책의 최선 추측” μ 만 남는다.

σ 를 0으로 만들면 안 되는 이유

σ 는 학습된 파라미터 — 11.2의 엔트로피 보너스가 0으로 쪼그라들지 않게 브레이크 역할.

평가 때 $\sigma = 0$ 으로 “학습”하는 것이 아니라, 파라미터를 그대로 두고 샘플링만 하지 않는 것이 정직한 “탐험 제거”. (“ σ 를 0으로 설정해서 돌려라”는 오답 — 파라미터를 바꾼 다른 정책의 실행이 되기 때문.)

실측: 3시드 결과 표와 읽기 1·2

실습 노트북: Ch11.2의 PPO 그대로, $\gamma = 0.99$, $\lambda = 0.95$, $\epsilon_{\text{clip}} = 0.2$, $\text{lr}=3\text{e-}4$, 시드당 300반복 $\times$ 400스텝 = 12만 스텝, 시드 0/1/2, 평가 50 에피소드

시드	학습 도중 마지막10	학습 후 결정적 $a = \mu$	학습 후 샘플 $a \sim \mathcal{N}$
0	-673.5	-1357.9	-1287.6
1	-732.3	-1454.2	-1399.4
2	-668.3	-1398.2	-1367.0
(베이스라인)	—	—	무작위 -1274.1 (100 에피소드)

이 표는 세 번 읽어야 하고, 세 번째가 이 절의 핵심이다.



- **읽기 1 — 학습 도중 곡선은 정말 올랐다:** 마지막 10 (-673/ -732/ -668)이 첫 10 (-777/ -866/ -914) 대비 **15~27% 개선**, 무작위 -1274보다 대략 2배 낫다. 이 숫자만 보면 “학습 성공”.
- **읽기 2 — 시드 간 편차가 있지만 방향은 일관:** 마지막 10의 시드 간 격차 약 65 (-668 ~ -732)로 “같은 모양” 범위 -11.2의 “큰 그림은 시드마다 안정적”이 재현된다.

읽기 3 — 결정적 평가가 베이스라인 아래다

- 세 시드의 $a = \mu$ 평가 평균 ≈ -1403 으로 무작위 정책 (-1274) 아래.

“학습 곡선이 올랐다”와 “배운 정책이 무작위보다 낫다”는 서로 다른 두 문장이다.

- 왜? 학습 도중 리턴은 **탐험 노이즈 σ** 가 섞인 채 측정한 것 — σ 샘플링이 운 좋게 진자를 높이 스윙하게 한 에피소드가 평균에 들어감 (11.2 FAQ: “에피소드 리턴 자체의 분산은 줄일 수 없다”).
- 노이즈를 빼면 12만 스텝으로는 μ 가 상태별로 아직 정확하지 못해, 결정적 정책은 “대충 그럴듯한 범위로 스윙” 수준 (아무것도 안 함 ≈ -1230 과 같은 등급).



좌: 학습 곡선 (검정 점선 = 무작위 베이스라인 -1274 , 시드마다 모양이 다르면 정상). 우: 같은 세 정책을 네 가지 측정 방식으로 — 학습 도중(탐험 포함)이 베이스라인을 크게 상회해도 결정적 $a = \mu$ 는 그 아래일 수 있음.

하이퍼파라미터 선택의 주의

- “학습 곡선이 예뻐질 때까지 $\gamma/\lambda/\epsilon_{\text{clip}}$ 을 조한다” — 지도학습에서 “val 곡선이 예뻐질 때까지 조정”하는 것과 같은 역할 (ML1 Ch6.2). 그 자체로 **정당한 모델 선택**.
- 단, 두 조건:
 - ① 어떤 곡선(학습 도중 리턴의 이동평균)을 보고 고르기로 정했는지를 보고서에 **기록**할 것.
 - ② 최종 **결정적** 평가는 선택된 파라미터로 **한 번만** 돌려야 한다.
- “결정적 평가가 예뻐질 때까지” 조정하는 것은 **평가에 대한 과적합** — ML1 6.2의 “test는 한 번만” 원칙이 그대로.
- 선택 기준의 **사전 기록**이 “정당한 val 선택”과 “평가 과적합”의 구분선이다 (16.2 체크리스트 “실험 프로토콜의 정직성” 항목에서 바로 감점 대상).

전체 그림: 4주 파이프라인

- 8.1절 파이프라인과 대칭 — 환경 → 알고리즘·구현 → 평가·정당화 → 발표.
- 각 박스가 Block B 어느 절의 원칙을 집행하는지 함께 적음.
- 붉은 점선(평가 → 구현·실험)이 핵심: 시드 간 편차가 비정상적으로 크거나 프로토콜 결함이 발견되면 돌아가서 다시 돌려야 한다는 뜻.
- “한 번 지나가면 돌아올 수 없는” 것은 최종 발표뿐 — 그 외 모든 단계는 되돌아갈 수 있다.



1주: 환경 고르기·문제 정의·베이스라인 / 2~3주: 알고리즘 구현·시드 ≥ 3 ·하이퍼파라미터 / 3~4주: 시드 비교 표·학습 곡선·보고서 / 4주: 발표·peer-review.

일정과 마일스톤 — M1~M4가 제출물

주 / 해야 할 일

1주: 환경 후보 2~3개 조사, **문제 정의 문서**(MDP 5요소, 주 지표와 리턴의 이론적 범위), **베이스라인**(무작위) 리턴 측정

2주: Ch9~15 코드 재사용으로 알고리즘 ≥ 1 개 구현, **시드 1개에서 엔드투엔드 동작 확인**(Pendulum 12만 스텝 $\approx 20 \sim 30$ 초), **학습 예산 추정**

@마일스톤(제출)

@M1

문제
정의

+

환경
선택

+

베이스라인

숫자

(1p)

@M2

중간코드

리뷰(코드

+

베이스라인

+

e2e

숫자)

수식적 정당화: 좋은 예와 나쁜 예

설정: 어떤 팀이 Pendulum에 PPO를 적용해 “학습이 잘 됐다”고 발표. 11.2 스크래치패드로 실행 검증한 실제 결과:

처음

10 에피소드평균리턴 : -1551.7

10 에피소드평균리턴 : -1092.2

나쁜 설명: “학습 곡선이 올라갔다. PPO가 잘 작동했다.”

좋은 설명: “12만 스텝(300 iteration) 동안 평균 리턴이 $-1551.7 \rightarrow -1092.2$ 로 약 30% 개선 — **다만 완전히 수렴한 수준은 아니고** 여전히 개선 여지. 이 개선은 보상을 $1/8$ 스케일링하고 $\gamma = 0.95$, $\lambda = 0.9$ 로 조정된 뒤에야 나타남 — Ch11.3의 GAE λ (편향-분산 트레이드오프)가 “왜 그렇게 골랐는지”의 답. 처음 시도(스케일링 없음, $\gamma = 0.99$)는 오히려 나빠짐 — Ch11.1대로 어드밴티지 추정의 **분산이 너무 커서** 클리핑이 그 노이즈를 충분히 걸러내지 못했기 때문으로 추정.”

두 설명은 같은 방향(개선됨)을 말하지만, 좋은 설명만 (1) 정확한 수치, (2) “완전 수렴 아님”의 정직함, (3) 하이퍼파라미터의 이론적 근거를 담는다 — 이것이 “수식적 정당화”의 실제 의미.

보고서 구조 (M4) — 발표 슬라이드 = 보고서의 절 제목

- 1 문제 정의 (0.5p): MDP 5요소(Ch3.1), 상태·행동 차원과 범위, 전이·보상(이론적 리턴 범위 포함), 할인율, 주 지표 (학습 후 결정적 평가의 평균 리턴), **베이스라인**.
- 2 알고리즘 선택과 이유 (1p): 왜 이 환경을 이 알고리즘에 골랐는가(S 페어링의 “무대” 논리), 하이퍼파라미터 ($\gamma, \lambda, \epsilon_{\text{clip}}$, 보상 스케일)와 선택 근거(Ch10~13 개념).
- 3 실험 프로토콜 (1p): 시드 목록, 학습 예산, **평가 프로토콜(결정적 $a = \mu$, 에피소드 수, 모든 시드에 동일) 명시**, 하이퍼파라미터 선택 절차. **이 절이 없으면 16.2 체크리스트에서 바로 감점.**
- 4 결과 (1p): 시드 비교 표, 학습 곡선 1장(여러 시드를 얹은 선으로), “**같은 정책 여러 측정**” 패널(학습 도중/결정적/베이스라인).
- 5 수식적 정당화 (1p): Ch9~15 개념 ≥ 1 개로 “왜 이 결과가 나왔는지” — “좋은 예” 문체로.
- 6 잘 안 된 부분과 원인 진단 (0.5p): **필수** — 안 된 부분이 없었으면 “무엇을 시도했다가 안 됐는가”를 쓴다. “모두 잘 됐다”는 보고서는 이 절이 비어 있다는 뜻.

채점 기준 (rubric)

항목	비중	좋은 답
문제 정의와 환경	15%	MDP 5요소·차원·지표·베이스라인·리턴 이론 범위가 명확, 환경 선택이 “개념 X가 돋보이는 무대” 논리로 근거됨
방법론 적절성	20%	Ch9~15 알고리즘이 환경 특성(연속/이산, 보상 희소성)에 맞았고, 하이퍼파라미터 근거가 배운 개념으로 설명됨
실험 프로토콜의 정직성	25%	시드 ≥ 3 , 동일 평가 프로토콜(결정적, 동일 에피소드 수), 베이스라인, 예산과 선택 절차가 보고서에서 추적 가능
수식적 정당화	20%	배운 개념 ≥ 1 개로 “왜”를 설명했고, 그 설명이 실제로 관측한 숫자와 일치
결과의 정직성과 반성	20%	불안정했던 시드·구간, 베이스라인 이하의 평가치를 숨기지 않고 Ch9~15 개념으로 진단

정직성 항목이 합계 45%인 이유

이 프로젝트의 목적은 “좋은 정책을 만들 것”이 아니라 **그 성능 숫자를 정직하게 얻는 절차를 실제로 수행한 것을 증명**을 겨냥한 평가가 베이스라인을 못 넘겨도 프로토콜이 정직하며 높은 점수 반대로 숫자가 예뻐도

자주 하는 실수 5가지 — 16.2 리뷰의 “반박 가능한 질문”이 된다

- 1 **시드 1개 실험으로 결론** — 같은 PPO라도 시드만 바뀌어도 마지막 10 평균이 $\pm 100 \sim 200$ 흔들림(실습표: $-668 \sim -732$). 알고리즘 간 차이가 시드 간 sd보다 작으면 결론은 “유의미한 차이 관측 불가”. 리뷰 질문: “시드 간 sd가 방법 간 차이보다 커요?”
- 2 **학습 도중 리턴을 “최종 정책 성과”로 보고** — 학습 도중 마지막 10($-673 \sim -732$)은 σ 샘플링 노이즈가 섞인 “탐험 포함 성과”. “곡선이 올랐다”를 “잘 학습됐다”로 번역하는 순간 읽기 3의 격차(결정적 -1403 vs 베이스라인 -1274)가 사라진다.
- 3 **결정적 평가가 예뻐질 때까지 하이퍼파라미터 조정** — 학습 곡선으로 조정하는 것은 정당한 val 선택이지만, 최종 평가치를 보며 조정하면 평가에 과적합(ML1 6.2 “test는 한 번만”). 구분선 = 선택 기준의 사전 기록.
- 4 **베이스라인 없이 “잘 배웠다”** — 무작위 리턴(-1274)을 재지 않고 “ -1400 , 꽤 좋다”라고 발표 = 그 숫자가 무작위보다 나쁜지도 모름. zero-torque(≈ -1230)까지 함께 재면 기준선 두 개가 생긴다.
- 5 **“결정적 $\ll$ 샘플 평가는 버그”로 오해** — $a = \mu$ 가 $a \sim \mathcal{N}$ 보다 낮은 것은 정상. 격차의 크기는 “정책이 탐험 운에 얼마나 의존하는가”의 측정값 — **작을수록** 정책이 자기 μ 만으로 선다.

발표 — 5~7분, 마지막 1분이 가장 평가받는다

- 구성: 문제 정의(1분) → 알고리즘과 이유(2분) → 학습 곡선 + 수식적 정당화(2~3분) → **잘 안 됐던 부분과 원인 진단(1분)**.
- “최종 결정적 리턴이 얼마였는가”보다 **“왜 이 알고리즘을 이 환경에 골랐고, 왜 이 결과가 나왔는가”**에 더 높은 점수.
- 마지막 1분 = rubric의 **“결과의 정직성과 반성”** 항목이 정확히 보는 곳.

예(실습 숫자를 그대로 발표): “PPO를 시드 3개로 12만 스텝 학습. 학습 도중 마지막 10은 $-673 / -732 / -668$ 으로 무작위 (-1274)보다 2배 정도 낮다. **다만** 학습 후 결정적($a = \mu$) 평가는 $-1358 / -1454 / -1398$ 으로 베이스라인 아래였다 — 11.2 FAQ의 “에피소드 리턴 자체의 분산은 줄일 수 없다”대로, 학습 도중 숫자에는 σ 샘플링의 운이 섞여 있었고, 노이즈를 빼면 12만 스텝으로는 μ 가 아직 정확하지 않다는 진단. 13~14절의 수백만 스텝 원리로 **예산 10배 실행**을 계획하고 있다.”

“실패에 가까운 실험”까지 **배운 개념으로 해석한 발표**가 더 높은 점수를 받는다 — “모든 것이 잘 됐다”는 발표는 이 항목에서 **스스로 감점**을 받는 것.

실습: 캡스톤 프로토콜 6단계를 코드로

- ① **(M1) 문제 정의** — Pendulum-v1의 MDP: 관찰 3차원 $[\cos \theta, \sin \theta, \dot{\theta}]$, 행동 1차원 토크 $[-2, +2]$ Nm, 200스텝, 보상 $r = -\theta^2 - 0.1\dot{\theta}^2 - 0.001a^2$ (상한 0).
- ② **베이스라인** — 무작위 정책 100 에피소드 (-1274.1 , sd 300).
- ③ **(M2) 구현** — Ch11.2의 ActorCritic + GAE 코드를 **재사용**(8.1 FAQ “코드를 처음부터 써야 하나요?”의 답과 같은 이유).
- ④ **(M3) 시드 0/1/2** — 같은 파라미터($\gamma = 0.99$, $\lambda = 0.95$, $\epsilon_{\text{clip}} = 0.2$)로 12만 스텝씩 (시드당 20~30초), 학습 도중 리턴 비교.
- ⑤ **학습 후 평가** — 세 정책을 (a) 결정적 $a = \mu$, (b) 샘플 $a \sim \mathcal{N}(\mu, \sigma)$ 로 각각 50 에피소드 평가 후 베이스라인과 비교.
- ⑥ **발표 자료용 한 장** — 좌: 시드별 학습 곡선, 우: “같은 정책, 측정 방식 네 가지” 막대.

이 6단계의 의미

곧 § 보고서 구조의 6개 절, 다시 16.2절의 체크리스트로 매핑된다 — **같은 절차를 세 가지 언어(코드, 보고서, 리뷰)로 말할 수 있어야** 이 프로젝트가 끝난 것이다.

확인 문제 (1)-(2)

- 1. 시드 0의 학습 도중 마지막 10이 -673.5 (베이스라인 -1274 의 2배)인데, 결정적 평가는 -1357.9 (베이스라인 아래)다. 어느 쪽이 “배운 정책의 진짜 성능”이고, **주 지표**는 무엇이어야 하는가?
→ **결정적**($a = \mu$) **평가**가 탐험을 뺀 본래 실력(8.1의 $\varepsilon = 0$ greedy 평가에 해당). 학습 도중 리턴은 “탐험 포함 성과”. 주 지표는 **결정적 평가** — 평가의 목표가 “정책의 안정적인 성능”이지 “학습 과정이 잘 봤는가”가 아니기 때문. 학습 곡선은 “학습이 실제로 되고 있었는가”의 증거로, **역할을 구분해 함께 보고**.
- 2. “연속 정책에는 ε 이 없으니, 평가할 때 σ 파라미터를 0으로 설정해서 돌리면 되지 않나요?” — 왜 오답인가?
→ σ 는 **학습된 파라미터**(엔트로피 보너스와 함께 학습 대상) — $\sigma = 0$ 로 바꾸면 “원래 정책에서 탐험을 제거한 실행”이 아니라 **파라미터를 바꾼 다른 정책**의 실행. 정답: 파라미터를 그대로 두고 $a = \mu_\theta(s)$ (**평균**)만 **내보내는 것** — “같은 정책을 샘플링 없이 실행”하는 것이 $\varepsilon = 0$ 과 동일한 역할.

확인 문제 (3)-(4) + 자주 묻는 질문

- 3. “PPO 결정적 평가가 -900으로 30% 개선됐다”는 발표에 던질 **3점 질문 2개**: (a) 프로토콜의 정직성: “시드를 몇 개로 확인했어요? 시드별 숫자는요?” (b) 결과의 정직성: “결정적 평가는 몇 에피소드로 잰가요? 베이스라인은 몇 에피소드로?” — 50 에피소드 결정적 평가의 시드당 sd가 186~239로 커서 평가 에피소드 수가 적으면 측정 오차와 구별 불가. (추가: “학습 예산(스텝 수)은 같았나요?” — 12만 vs 100만 스텝 비교는 알고리즘이 아니라 **예산 비교**.)
- 4. 12만 스텝 $\approx$ 22초(1시드)일 때, 100만 스텝 (8.3배)을 시드 3개로 돌리면 $\approx$ **10분 내외**. **M2에서** 해야 하는 이유: M3의 “남은 시드 실행”이 **예산 계획 없이는 시작할 수 없기** 때문 — Humanoid(수백배)에 적용하면 수 시간이 되고, 그제서야 “새벽에 돌리자/시드를 줄이자”의 결정. “얼마나 걸리는가” 는 실험 **설계의 일부**이지 행정 절차가 아니다.

FAQ — 수렴하지 않았어도 발표하는가? **된다** — “완전 수렴 아님”을 정직하게 보고하고 원인 진단하는 것이 부풀린 성공보다 낫다. / 알고리즘 2개가 비슷한가? **비슷함 자체가 관찰** — 학습 도중/학습 후를 나눠 비교하면 다른 트레이드오프가 드러남. / 시드 몇 개가 정석인가? Pendulum은 1시드 20~30초라 **3~5개가 현실적 하한**, MuJoCo 대형은 3개 + GPU 배분 고려. / PPO가 12만 스텝으로 베이스라인 못 넘기면? **예외가 아니라 일반** — Pendulum은 완전 수렴에 100만 스텝 이상. 성공 기준 = 정직한 절차 + 정당화. / 라이브러리 (stable-baselines3)를 써도 되나? **된다** — 다만 “그대로 쓴 부분”(기본값)과 “팀이 바꾼 부분”(환경 인터페이스, 예산, γ/λ , 평가 프로토콜)을 **구분**해야 하고, (b)가 실질적 산출물.

16.2 Peer-Review

왜 이번 주가 “역전”의 주인가

- 16.1에서 각 팀은 **발표팀**으로서 자신의 프로젝트를 5~7분 안에 설명했다. 이번 블록(16.2)에서는 역할이 역전된다 — **이번에는 네가 심사위원이다.**
- 다른 두 팀의 발표를 듣고, 체크리스트를 적용해 **리뷰 두 통**을 작성하고, 그 리뷰의 질로 채점받는다.
- “왜 반박 가능한 질문이 좋은 리뷰인가”의 근거(Popper의 반증주의, Amgen 재현 실험: 53편 중 6편만 재현 성공, 2011)는 ML1 8.2 / ML2 8.2에서 다뤘다 — 여기서는 **신경망 강화학습**이라는 새 대상에 무엇을 추가하는가만 다룬다.

심사 대상이 8.2에서 달라진 두 가지

첫째 — 알고리즘이 신경망에 올랐다

- DQN(Ch09) · REINFORCE · Actor-Critic(Ch10) · PPO(Ch11) · 모방학습(Ch12) · 시뮬레이션(Ch13~14) · MCTS(Ch15).
- 8.2: “CliffWalking에 SARSA vs Q-learning이 맞는가” — **한 장의 개념**으로 판단 가능.
- 16.2: “Pendulum(연속 행동)에 DQN을 쓴 팀” — **왜** DQN이 부적합한지(행동 공간의 **이산성 전제**, Ch09)까지 짚어야 한다.

둘째 — 시드 질문이 “신경망 특유의 새 얼굴”로

- (a) **초기화** 자체가 매번 다르다(무작위 가중치).
 - (b) 학습이 **수만~수백만 스텝**이라 “12만 스텝이면 충분히 수렴했는가”를 판정하기 어렵다.
 - (c) 하이퍼파라미터(γ , λ , 클리핑 ϵ , 보상 스케일)가 결과에 **지대하게** 영향.
- ⇒ 같은 “반박 가능한 질문”이 **수치 민감성** 질문으로 번역된다: “시드 2개를 더 돌리면 이동평균의 편차가?”(Ch11.2), “보상을 1/8로 스케일링한 게 결과의 방향을 바꿨나요?”(Ch11.3).

이번 주는 어떻게 진행되는가

순서	내용	시간 배분
1	다른 두 팀의 발표 청취(팀당 5~7분, 16.1 형식) + 보고서·코드시트 열람	약 30분
2	작성 리뷰 2통 — 팀당 체크리스트 5항목 + 반박 가능한 질문 ≥ 1 개(개념의 장·절 명시)	발표 직후(각
3	질의·토론 — 리뷰어가 쓴 질문에 발표팀이 그 자리에서 답변	나머지 시간

핵심 = 2번의 작성 리뷰

3번 토론은 “발표팀이 그 질문에 실제로 답할 수 있는가”를 가르는 자리 — **새로운 계산·실험**(시드 재실행, 평가 프로토콜 변경, 베이스라인 실측, 하이퍼파라미터 민감성 실험)을 꺼내야 답하는 질문이 **3점**이고, “네, 알겠습니다”로 넘겨질 질문은 2점에 머문다. 16.1에서 “수식적 정당화”가 발표팀의 의무였다면, 이번 주 그 타당성을 리뷰어가 심사하는 것.

Peer-Review 체크리스트 — 5항목

항목	확인할 것
환경 설명	상태·행동·보상이 명확히 정의됐는가
알고리즘 선택	환경의 특성(이산/연속 행동, 보상의 희소성 등)에 알고리즘이 맞았는가
수식적 정당화	요구사항을 충족했고, 실제로 관찰한 결과와 일치하는가
결과의 정직성	수렴하지 않은 부분·학습이 불안정했던 구간을 숨기지 않고 원인을 분석했는가
탐험-활용 균형	Chapter 2에서 배운 딜레마가 실제 학습 곡선에서 어떻게 드러났는가

5항목은 16.1 채점 기준의 **축 그대로** — 리뷰어와 발표팀이 **같은 기준표**를 공유해야 “감점”과 “좋은 지적”이 **같은 언어**로 이야기될 수 있다.

5항목의 구체적 의미 (1) 환경 설명 · (2) 알고리즘 선택

- **(1) 환경 설명** — MDP 5요소(Ch03.1) 중 **상태·행동·보상**이 보고서에서 추적 가능한지.
“Pendulum을 썼다” 한 줄만 있고 주 지표가 무엇인지(학습 도중 리턴? 이동평균? 평가 리턴?), 리턴의 부호 규약(항상 음수, 0에 가까울수록 좋음)이 없으면 뒤의 모든 숫자가 “무엇의 평균”인지 모른다. 학습 곡선이 에피소드 단위인지 스텝 단위 평균인지도 여기서.
- **(2) 알고리즘 선택** — “PPO를 골랐다”가 아니라, **이 환경의 어떤 특성이** 그 선택을 정당화하는지.
 - ▶ **연속 vs 이산** 행동 공간이 **가장 먼저** 봐야 하는 분기: DQN(Ch09)은 이산 행동을 전제로 $Q(s, a)$ 를 표처럼 출력 — 연속(Pendulum, Reacher)에 그대로 쓰면 “행동을 어떻게 이산화했는가”의 추가 전제가 붙는다.
 - ▶ **희소 보상**(Ch15.2의 보너스 구조)도 근거: 희소 보상에 DQN은 Q값의 희소성 문제(대부분 스텝이 0이라 학습 신호 약함)를 겪는다.

5항목의 구체적 의미 (3)-(5) 정당화 · 정직성 · 탐험-활용

- **(3) 수식적 정당화** — “최소 1개”를 채웠는지는 형식 문제, 이 항목은 내용: 깊은 개념(예: Ch11.3 GAE λ)이 **실제로 관찰한 숫자와 일치**하는가. “ λ 가 편향-분산을 조절한다”는 문장만 있고 λ 를 바꿔 어드밴티지 분산이 어떻게 변했는지 실측이 없으면, 그 문장은 어디에나 붙을 설명일 뿐.
- **(4) 결과의 정직성** — 신경망 **초기화 시드**를 몇 개 돌렸는지, 시드별 이동평균이 사라지지 않고 보고에 들어갔는지, “완전 수렴 아님”을 숨기지 않는지. “결과가 좋았는가”가 아니라 “결과가 **정직한 절차**로 얻어졌는가”를 본다.
- **(5) 탐험-활용 균형** — Ch02 멀티암 밴딧의 딜레마가 **실제 학습 곡선**에서 어떻게 드러나는지. 신경망 RL에서는 탐험이 ϵ -greedy(DQN, Ch09.2)나 가우시안 정책의 σ (Ch10.2, Ch11.2)로 구현 — “탐험을 줄여가는데 줄이는 시점이 학습 곡선의 어떤 지점이었나? 일찍 줄이면 고착, 늦으면 노이즈”(Ch02 직관의 신경망 버전 검증).

채점 기준: “채웠는가”가 아니라 “구체적인가”

리뷰 품질	특징	예시 (Penc)
1점 — 감상평	구체적 지적 없음. 듣기만 하고 느낌만 적음	“학습 곡선(작동한 것 같
2점 — 일반 지적	문제를 제기하지만 근거(개념)가 약함. 발표팀이 “네”로 넘길 수 있음	“시드를 하나 더 돌려라” (2점)에는 관찰도 개념도 없지만, 3점 질문에는 관찰(시드 수) + 개념(Ch11.2 초기화 민감성) + 왜 문제인지(숫자 비교)가 모두 들어 있다.
3점 — 반박 가능한 질문	이 학기 개념(장·절)을 명시하고, 답이 나쁘면 결과가 흔들리는 질문	“시드 2개 표준편차가 차이가 그 편 우연일 가능

1점 → 3점의 공통 패턴 (ML1 8.2와 똑같다)

추상적 평가어(“잘됐다”, “확인해보라”)를 (a) 구체적 관찰 + (b) 이 학기 개념(Ch NN) + (c) 그것이 왜 문제인지(숫자)로 교체. “시드를 하나 더 돌려라”(2점)에는 관찰도 개념도 없지만, 3점 질문에는 관찰(시드 수) + 개념(Ch11.2 초기화 민감성) + 왜 문제인지(숫자 비교)가 모두 들어 있다.

손으로 한 번: 가상 발표 (팀 “진자돌림”)

실습 노트북과 동일한 설정 — 모든 숫자는 실제로 그렇게 실행하면 나오는 것. 문제인 곳은 숫자가 아니라 프로토콜.

발표 요약

“Pendulum-v1에 PPO. 300 반복 $\times$ 400 스텝(총 12만 스텝), $\gamma = 0.99$, $\lambda = 0.95$, 클리핑 $\epsilon = 0.2$, 보상 스케일링 없음, **시드 42** 하나로 학습. 처음 10 에피소드 평균 리턴 $-805.3 \rightarrow$ 마지막 10 에피소드 평균 -742.0 으로 개선. 학습 곡선이 완만하게 올라가서 PPO가 잘 작동했다. Chapter 11에서 배운 클리핑 덕분에 안정적인 학습이 됐다.”

체크리스트 5항목을 하나씩 적용해 본다 — 문제는 모두 **숫자가 아니라 보고의 구조**에 있다.

가상 발표를 체크리스트로 — (1)(2) 환경 · 알고리즘

- **환경 설명** — 환경 자체는 명확하다(Pendulum-v1, 연속 행동 1차원 토크, 항상 음수 리턴). 그러나 **주 지표가 모호하다** — “마지막 10 에피소드 평균”이 학습 도중 에피소드 리턴인지, 학습 후(탐험 없이) 재평가한 리턴인지 문장에 없다. 8.1/16.1의 “비교 프로토콜”이 둘을 **반드시 나눠서** 보고하게 한 이유가 바로 이 모호함.
- **알고리즘 선택** — PPO는 연속 행동 환경(Pendulum)에 맞는 선택(Ch10~11). **이 항목은 통과.**

가상 발표를 체크리스트로 — (3)(4)(5)

- **수식적 정당화** — Ch11을 인용했지만, 인용과 관측이 **연결되어 있지 않다**. “클리핑 덕분에 안정적”은 어디에나 붙을 설명 — 클리핑 ϵ 을 바꿔서 안정성(곡선 변동폭, 발산 여부)이 어떻게 변했는지 실측이 없으면, 그 문장은 이 실험에 붙은 정황이 아니라 책에서 읽은 문장일 뿐.
- **결과의 정직성** — 세 가지가 **사라져 있다**: (1) **시드 1개**(신경망 초기화가 무작위라 학습 과정의 우연), (2) **베이스라인 부재**(무작위 정책 리턴 = “잘 배웠다”의 기준점), (3) **완전 수렴 여부 미명시**(12만 스텝은 이 과제에 “절반도 안” 왔을 수 있음, 11.2).
- **탐험-활용 균형** — PPO의 탐험은 가우시안 σ (11.2) 인데, σ 가 학습 중 어떻게 변했는지(초기 ≈ 0.61 에서 어디로) **한 마디도 없음** — Ch02 딜레마가 학습 곡선에 어떻게 반영됐는지 확인 불가.

이 발표에 대한 3점 질문

반박 가능한 질문

“시드 42 하나로 “마지막 10에피소드 평균 -742.0 ”이라고 했는데, **시드 2개를 더 돌리면** 그 평균의 **표준편차**가 얼마나 되나요? 그리고 “잘 배웠다”의 기준점인 **무작위 정책의 평균 리턴**(약 -1239) 대비 얼마나 개선됐나요? 12만 스텝이면 11.2에서 본 대로 “절반도 안” 온 수 있는데, 더 오래(예: 24만 스텝) 돌리면 이동평균이 계속 올라가나요, 아니면 이미 **포화**인가요?”

이 질문이 3점인 이유: 발표팀이 답하려면 **새로운 실험**(시드 2개 추가 + 무작위 베이스라인 실측 + 학습 스텝 확장)을 돌려야만 하고, 그 실험을 돌리면 “PPO가 잘 작동했다”는 결론이 **흔들릴** 수도 있다 — 3점 조건(개념 명시 + 답이 나쁘면 결과가 흔들림)을 정확히 만족.

“우연히 좋은” 패턴 5가지 — 신경망 RL 버전

ML1 8.2의 “우연히 좋은 결과” 원천 = 테스트셋 유출 · 정확도의 함정 · 과적합. RL에는 검증/테스트셋 자체가 없음 — 대신 학습 과정의 무작위성이 같은 역할. 8.2의 5가지(표 기반)를 신경망 RL에 맞게 다시 쓴 것. 발표 슬라이드에서 이 패턴을 보면 그 행의 “반박 가능한 질문”을 바로 던져야 한다.

패턴	겉보기	실제로는 / 반박 가능한 질문
1. 시드 1개 학습 곡선	“곡선이 완만하게 올라가네”	신경망 초기화 의 우연 — 같은 코드로 시드 1개만 돌리면 학습 곡선. “시드 2개를 더 돌리면 이동 평균이 좀 더 매끄러워지고 알고리즘 간 차이가 그 편차보다 큰 것 같아 (초기화 민감성)”
2. 학습 도중 리턴으로 “수렴” 결론	“마지막 100이 -742.0까지 올랐네”	학습 도중 리턴은 탐험 ($\sigma \cdot \epsilon$ 포함) 때문. 12만 스텝은 완전 수렴이 아닐 수 있음. “학습 후 탐험 0으로 재평가한 값은 -742.0보다 높을 수도 있지 않아요? (11.2)”

“우연히 좋은” 패턴 3~5

패턴	겉보기	실제로는 / 반박 가능한 질문
3. 하이퍼파라미터 “적당히” 하나	“ $\gamma = 0.99, \lambda = 0.95$ 로 학습”	민감성 미검증 — Ch11.3 GAE λ 분산)· γ (장기 리턴 비중)·보상 1/8 : 자체가 결과 방향을 바꿀 수 있음. “ $\lambda =$ 어드밴티지 분산이? 스케일링이 결론의 바꿨나요?”(Ch11.3, 16.1 예시)
4. 이산용 알고리즘을 연속 환경에	“DQN으로 학습했다”	DQN(Ch09)은 이산 행동을 전제 — 연속 행동에 쓰려면 행동 이산화 추가 보고에 없으면 선택 부적합. “행동을 이산화했나요? 정밀도 손실(Ch09) 확인 연속 정책(Ch10~11)이 자연스러운 이산화?”
5. 베이스라인 없이 “잘 배웠다”	“-742.0가 나왔다”	기준점 없이 “나다”를 말할 수 없다 — Ch11.3 M2 무작위 평균(약 -1239)을 재야 판 “무작위 정책의 평균 리턴은 얼마? 그 측정하셨나요?”(16.1 M2)

패턴 3이 특히 신경망 특유인 이유: 8.2의 하이퍼파라미터 (α, ϵ)는 일치하는 스케일에서 결과를 바꾸지만, 신경망의 $\gamma \cdot \lambda$ ·보상스케일은 리턴의 규모 (≈1000 안팎)를 직접 바꿔 “좋아진 것”이 알고리즘의 공헌인지

실습: 가상 발표를 리뷰어의 눈으로 재실행

- 1 발표팀 재현 — Pendulum-v1, PPO(Ch11.2 코드), 시드 42, $\gamma = 0.99$, $\lambda = 0.95$, 300×400 (12만 스텝) → 처음 10: -805.3, 마지막 10: -742.0. 발표팀의 숫자 재현.
- 2 패턴 1 검증 — 시드 2개 추가 — 시드 123, 7로 재실행 → 시드별 마지막 10 이동평균 표. 편차를 보고 “알고리즘의 차이”인가 “시드의 우연”인가를 판정.
- 3 패턴 2 검증 — 학습 스텝 확장 — 12만 → 24만 스텝, 이동평균이 포화되는지 → “절반도 안 왔다”(11.2)를 숫자로 확인.
- 4 패턴 3 검증 — 보상 스케일링 민감성 — $1/8$ 스케일링 + $\gamma = 0.95$ 로 재실행 → 스케일링이 결론의 방향을 바꾸는지.
- 5 패턴 5 검증 — 베이스라인 실측 — 무작위 정책 300 에피소드 → 평균 약 -1239.
- 6 리뷰 작성 — 실습에서 나온 숫자를 근거로 3점 리뷰를 실제 템플릿(나중)으로 완성.

이 6단계 = “리뷰어는 발표팀의 실험을 **자기 손으로** 재실행할 수 있는 사람”이라는 이 절의 핵심 태도를 코드 레벨에서 보여줌. “이 학습 곡선, 시드를 바꿔도 같은 모양이 나올까요?” 라는 질문은 **리뷰어가 실제로 다시 돌려본 적이 있을 때** 가장 날카롭다.


실제로 확인해본 것 — 같은 정책, 다른 프로토콜

- 발표팀의 “마지막 10 평균 -742.0 ”은 **학습 도중** 에피소드 리턴의 이동평균. 같은 학습 결과를 **학습 후**에 재평가하면: 탐험($\sigma \approx 0.61$)이 섞인 채 20 에피소드 $\rightarrow -1413$, 탐험 0(결정론적 μ 만) $\rightarrow -1491$. -742.0 은 둘 다보다 훨씬 좋아 보인다.
- **왜?** 학습 도중 에피소드는 학습 초반의 에피소드(탐험이 크고 운 좋게 수직 근처를 스치는 것 포함)까지 10개 평균에 들어가는 반면, 재평가는 마지막 시점의 정책을 순수하게 재기 때문. **같은 정책을 다른 프로토콜로 잰 값** (-742 vs $-1413 / -1491$)이 8.2 패턴 2(평가 ε)의 **신경망 버전** — ε 대신 가우시안 σ 가 탐험의 차원이 됐다.
- **베이스라인까지:** 무작위 300 에피소드 평균 **약** -1239 — 발표팀 정책의 순수 재평가 ($-1413 / -1491$)는 **무작위보다 오히려 나쁘다**(12만 스텝의 PPO가 아직 무작위 수준, 11.2 “절반도 안 왔다”가 숫자로 확인).
- **시드:** 42/123/7의 마지막 10 평균 $-742 / -658 / -568$ — 시드 간 sd(약 **70**)가 주장한 “개선폭”($-805 \rightarrow -742$, 약 63)보다 **크다**. “개선됐다”의 **방향성조차** 시드의 우연과 구별 불가 — 이 숫자들이 3점 질문이 왜 3점인지를 보여준다(답하려면 실제 실험을 돌려야 하고, 돌리면 결론이 “아직 무작위 수준”으로 뒤집힌다).

리뷰 쓰는 과정 — 체크리스트 → 반박 가능한 질문

- (1) 다른 팀 발표 + 보고서 읽고 **주장 파악**
(알고리즘·하이퍼파라미터·숫자·결론)
- (2) **체크리스트 5항목 적용**
- (3) 각 항목에서 **질문 초안** — 답이 새 계산·실험이어야 함
- (4) **분기**: “Ch9~15 개념(장·절)을 근거로 들고, 답하려면 **새 실험**(시드 재실행·평가 프로토콜 변경·베이스라인 실측·스케일 비교)이 필요한가?”
 - ▶ 예 → **반박 가능한 질문 채택**(초록)
 - ▶ 아니오 → “곡선이 올라가네요” 같은 **감상평** (빨강)으로 떨어짐 — Ch09.2(ϵ -greedy)·Ch11.3 (GAE λ)·Ch12.1(복합 오차) 개념으로 **다시 쓰기**(점선으로 (3) 회귀)
- (5) 3단계 기준(1/2/3점)으로 **자기 채점**

16.2 Peer-Review — ‘반박 가능한’ 리뷰를 쓰는 과정 (신경망 RL 버전)



리뷰 템플릿 — ML1 8.2에서 5번을 두 칸으로

ML1 8.2 템플릿에서 5번을 두 칸으로 늘린 것 (“근거가 되는 개념” + “반박하려면 어떤 새 실험이 필요한지”)이 강화학습 버전의 특징 — 답이 새 실험이어야 질문이 3점이 되기 때문. 5번 두 칸이 모두 채워져야 3점 도달; 비어 있으면 반박 불가능한 리뷰.

팀이름

: _____ 리뷰어 : _____

1. 환경설명—상태행동 · 이산연속 (/) 보상·부호 (규약, 희소여부) · 주지표학습중
(리턴? 이동평균? 평가리턴 ?)가 추적가능한가 ? 베이스라인무작위
() 리턴은 명시됐는가 ?
2. 알고리즘선택—이환경의어떤특성행동 (이산연속/, 보상구조)이 알고리즘
(Ch9~15) 선택을 정당화하는가 ? 개념으로 설명되는가 ?
3. 수식적정당화— ”≥개1” (16.1)를 채웠는가? 깊은개념이 실제로 관측한 숫자와 일치하는가 단순
(인용이 아닌가)?
4. 결과의정직성—시드초기화 () 수, 시드별 이동평균 , ”완전 수렴이 아니다
”가 정직하게 보고됐는가 ? 불안정한 시드구간이 · 있는가?
5. 반박가능한질문필수 (, 개1 이상) — 근거가 되는 개념
: Chapter __ 절 __ 개념 (: _____) 발표팀이 답하려면 필요한 새 실험 계산
/: _____ 질문
: _____ 발표팀이
(이 질문에 답이 나쁘면 결과가 흔들리는 것이어야 한다)

자주 하는 실수: 학습 곡선 한 번만 보고 결론 내리기

- RL 프로젝트에서 특히 빈번한 부실한 리뷰: “학습 곡선이 잘 올라갔으니 성공”로만 판단 — 그 곡선이 무작위 시드 하나인지, 반복해서 일관된 경향인지, 완전 수렴인지 “개선됐지만 갈 길이 남은” 상태인지를 먼저 물어야 한다.
- 신경망 RL에서 구조적으로 더 위험한 이유: 곡선의 “오르다/안 오르다”가 학습의 진전과 분리될 수 있기 때문 — 11.2에서 PPO 곡선은 “완만한 상승”이었으나 개별 에피소드 리턴은 -1800 (쓰러짐) ~ 0 (수직)까지 넓게 퍼져 있음. 이동평균이 올라간다고 에피소드 리턴의 분산이 줄어드는 것은 아니다.

학습 곡선 3문 — 리뷰어가 던지는 질문

- ① **시드(초기화):** 시드 몇 개의 평균(또는 범위) 인가? 1개라면 “일관된 경향”을 말할 수 없다.
- ② **평가 프로토콜:** “학습 도중 리턴”(탐험 포함)인지 “학습 후 탐험 0 재평가 리턴”인지? 다른 대상의 측정값이다.
- ③ **수렴 여부:** 이 스텝 수(예: 12만)가 완전 수렴인가? 더 오래 돌리면 포화인가요, 계속 오르나요(11.2)?

우리 팀 발표를 리뷰하기 — 발표 전 셀프-리뷰

- ML1 8.2의 결론을 그대로: **네가 심사할 때 던질 수 있는 가장 날카로운 질문을, 네 발표 전에 스스로 던져보고 답을 준비해두는 것이** 최선의 전략.
- § 5가지 패턴의 5개 질문을 **자기 팀의 보고서에** 적용:
 - ① 시드 3개의 이동평균 표가 **보고서에** 있는가
 - ② 평가 프로토콜 문장(탐험 0? 에피소드 수? 모든 시드에 동일)이 있는가
 - ③ 무작위 정책의 리턴이 **실측 숫자**로 적혀 있는가
 - ④ λ -보상스케일 민감성을 한 줄이라도 검증했는가
 - ⑤ 불안정한 시드·구간이 “잘 안 된 부분” 절에 사라지지 않고 있는가
- 이 5가지에 답이 없다면, **발표 전에** 해결해두는 것이 발표 중에 3점 리뷰를 받는 것보다 **항상 낫다**.

확인 문제 (1)-(2)

- 1. “시드 3개 이동평균 $-742/ -658/ -568$ 이 나왔으므로 PPO는 안정적이다” — 이 세 숫자는 **무엇의** 편차이고, **무엇의** 편차가 아니인가?

→ **학습 과정의** 무작위성(초기화 시드)이 만든 **세 개의 서로 다른 정책**의 이동평균 — “어떤 정책이 학습됐는가”의 편차이지 “그 정책을 재는 측정 오차”가 아님. 윈도우를 키워도 시드 간 편차($sd \approx 70$)는 안 사라짐.

“안정적이다”라 말하려면 **두 층의 불확실성**을 구분해서 (“시드 간 ± 70 , 시드 내 에피소드 분산 $\pm \dots$ ”) 나눠 적어야. 참고: 시드 간 편차(약 70)는 한 시드의 개선폭(약 63)보다 크므로 방향성조차 우연과 구별 불가.

- 2. “학습된 정책으로 마지막 10 에피소드 평균 -742 ” 에는 어떤 **모순**이 숨어 있는가?

→ “학습된 정책”이 σ 가 포함된 정책이라면 “마지막 10 에피소드”는 **탐험이 섞인** 측정 — PPO는 σ 가 학습 중 변하므로(11.2), “마지막” 에피소드의 σ 가 얼마 였는지 명시해야 “정책의 성과”. 질문: “ σ 는 얼마?

$\sigma = 0$ (결정론적)으로 재평가하면? 더 오래(30만 스텝) 하면 포화되나요(11.2)?”

확인 문제 (3)-(5)

- 3. “GAE의 $\lambda = 0.95$ 가 편향-분산을 조절해서 학습이 안정됐다(Ch11.3)”로 끝난 정당화는 **2점에 가깝다** — 개념은 인용했지만 관측 숫자가 없음. 3점 전환: “ λ 를 0.8/1.0으로 바꿔 어드밴티지 추정치의 분산을 실측했습니다 — 실측 표가 보고에 있습니까?”(관찰+개념+ 숫자).
- 4. “왜 DQN이 아니라 PPO인가요?” — 이대로면 **2점**(“연속이라서” 한 줄이면 반박이 어려움). 3점 버전: “Pendulum의 행동은 연속인데 DQN(Ch09)은 이산 전제로 $Q(s, a)$ 를 출력 — 이산화의 정밀도 손실을 확인했나요? 아니면 연속 정책인 PPO(Ch10~11)가 자연스러운 이유가 무엇인가요?”(체크리스트 2번에 Ch09 vs Ch10 개념 연결).
- 5. “PPO가 항상 좋은가요? “잘 학습했다”가 무작위(약 -1239)보다 나은 걸 어떻게 아나요?” — **정직한 범위**: “이 환경·이 설정(γ, λ , 12만 스텝)에서 시드 3개 한도에서 학습 도중 이동평균이 무작위보다 높다”(단, 순수 재평가 -1413/ -1491로는 오히려 나쁨; 외부 일반화는 이 실험이 지지하지 않음). **말하면 안 될** 추론: “PPO가 더 좋은 알고리즘이다” — 이 비교는 이 환경·이 스텝 수의 답이지 **알고리즘 우열**의 답이 아니다.

자주 묻는 질문

- **하이퍼파라미터 선택 근거까지 물어봐야 하나? 그렇다** — “적당히” 고른 값($\gamma, \lambda, \epsilon$, 보상 스케일)이 결과에 얼마나 큰 영향을 주는지 확인 했는지가 **방법론 적절성** 평가의 핵심.
- **모방학습/MCTS 팀은 체크리스트를 어떻게?** “학습 곡선” 대신 다른 증거로 — 모방학습: Ch12.1 **복합 오차**(전문가 분포 밖 성능 저하) 관찰됐는가 / MCTS: Ch15.2처럼 **시뮬레이션 횟수 증가** 시 선택되는 수가 더 정확해지는가.
- **문제가 없는 팀에 3점 질문을 어디서?** “문제가 보이지 않는 것”과 “확인되지 않은 것”은 다르다 — 3점 질문은 항상 **확인되지 않은 영역**에서 나옴(시드 5개 확장, λ 민감성, 더 긴 학습 스텝, 다른 평가 프로토콜). “이 실험의 다음 단계로 무엇이 가장 정보가 많을까요?”가 3점이 될 수 있다 — 발표팀이 답할 수 있다면 발표는 **더 단단해** 짐(리뷰어가 목표 달성).
- **“더 오래 돌려보세요”를 쉽게 요구할 수 없는데?** 리뷰어가 직접 300만 스텝을 돌릴 필요는 **없다** — 3점 질문은 발표팀이 돌려야 할 실험을 지적하는 것. “12만 스텝으로 포화가 안 보이는데, 이 과제는 완전 수렴에 수십만 스텝이 필요하다고(11.2) 했죠? 그걸 인지하고 “아직 안 끝났다”고 보고했나요?” — “몰랐습니다”면 **수렴 여부 미인식** 자체가 “결과의 정직성” 감점 요인.

16.3 ML2 총정리와 학기를 넘어서

이 절은 새로운 개념이 하나도 없다 — 하는 일 네 가지

- ① 16.1 발표 · 16.2 Peer-Review가 수렴해 온 **채점 기준(rubric)** 을 확정.
- ② **같은 작은 MDP를 네 가지 경로로 풀어** “모두가 같은 방정식을 푸는 구조”를 **숫자**로 확인.
- ③ 준비도를 스스로 재는 **자가진단**(20문항).
- ④ 학기 이후로 이어지는 지도(§ 학기를 넘어서)를 그림.

복습의 원칙

이 절의 모든 문장은 **이번 학기 13개 장의 요약** — 한 문장이라도 막히면 **그 장·절 번호로 돌아가는** 것이 복습이 아니라 정확한 복습이다.

프로젝트 채점 기준 — Block B 3주가 수렴하는 곳

8.1 rubric이 그대로 이어져 오면서 “Ch4~7 개념”이 “Ch9~15 개념”으로 교체된 것이 전부:

항목	비중	좋은 답이란
문제 정의와 환경	15%	상태·행동·보상이 명확(물리적 단위까지, Ch13), 환경 선택이 Ch9~15의 개념 검증 목적에 근거
알고리즘 적절성	20%	환경 특성(이산/연속, 희소성, 모델 유무)에 알고리즘이 맞고, 근거가 Ch9~15 개념으로 설명
실험 프로토콜의 정직성	25%	시드 ≥ 3 , 학습 곡선과 최종 평가(탐험 끄기 분리, 베이스라인(무작위 또는 사람이 설계한 PD 제어 등), $\epsilon \cdot \gamma \cdot \lambda$ -클리핑 ϵ 감수성 실험이 보고서에서 추적 가능
수식적 정당화	20%	배운 개념 ≥ 1 개로 “왜”를 설명(11.3 클리핑, 12.1 복합 오차, 13.1 도메인 무작위화 ...)했고, 관측 숫자와 일치
결과의 정직성과 반성	20%	불안정했던 시드·구간을 숨기지 않고 원인을 Ch9~15 개념으로 진단(16.1 좋은/나쁜 예 기준)

손으로 한 번: Peer-Review rubric을 직접 써보기

- 관점을 한 단계 더 뒤집어 “너가 채점자라면 무엇을 봐야 하는지” rubric을 직접 쓰는 연습.
- 5개 항목을 그대로 두고, 각 항목에 대해 두 칸을 채운다: (1) 나쁠 때는 어떤 모습인가(구체적 나쁜 패턴), (2) 그걸 시험하는 질문은 무엇인가(16.2의 반박 가능한 질문).

나쁠 때 (구체적 패턴)

@시험하는
질문
(반박
가능)

보고서에 **최고 점수 시드 하나만** 실려 있음. 학습 곡선이 매끄럽고 불안정 구간 설명이 없는데, 학습 로그(코드 출력)를 보면 300 iteration 중 **150~200 구간에서 리턴이 갑자기 내려간** 기록이 있음

@“로그의
150~200
it-
er-
a-
tion
리턴
추락을
보고서의

학습

“달리거나 쉬거나” MDP — 숫자로 보는 학기 중간고사

같은 작은 MDP를 Chapter 4~6의 네 경로로 풀어, 네 경로가 “같은 답, 또는 설명 가능한 다른 답”에 도달하는 것을 확인. 실습 노트북이 네 경로의 학습 곡선을 코드로 재현.

MDP(8.3 템플릿 ②): 3-state, $\gamma = 0.9$

- **S**(시작): run — 0.7 확률로 G, 0.3 확률로 S로 **미끄러짐**, 보상 0. rest — S에 남음, 보상 -1.
- **G**(골): collect — T로 전이, 보상 +3.
- **T**: 터미널.

경로 ① — 동적계획법(Ch4): 벨만방정식을 손으로 푼다

+3을 받는 유일한 길은 G에서 collect $\Rightarrow V^*(G) = 3$. S에서 run이 최선(후보 추측)이면:

$$V^*(S) = 0.9(0.7 \times 3 + 0.3 V^*(S)) = 1.89 + 0.27 V^*(S) \Rightarrow V^*(S) = \frac{1.89}{0.73} \approx 2.589$$

검증(후보+검증 Step 3):

$$Q^*(S, \text{run}) = 2.589 > Q^*(S, \text{rest}) = -1 + 0.9 \times 2.589 = 1.330 \checkmark$$

경로 ② 몬테카를로(Ch5) · 경로 ③ SARSA(Ch6 on-policy)

- **경로 ② 몬테카를로** — greedy 정책(run@S, collect@G)으로 에피소드를 끝까지 roll-out하고, 실제 리턴 G_t 를 그대로 목표값으로 (첫방문 MC). 4000 에피소드로 $V(S) \approx 2.594$ — 참값과 **0.2% 차이**. MC는 **편향이 없다**(실제 실현된 리턴의 기댓값이 정확히 V^π) — “충분히 많이 돌리면” 약속이 이 예에선 정말로 지켜진다.
- **경로 ③ SARSA** — TD 오차로 갱신하되, 다음 행동 a' 도 **실제 행동 정책(ϵ -greedy)**이 고른 것을 쓴다.

이번 학기의 핵심 드라마

SARSA는 최적값이 아니라 “탐험하는 행동 정책의 값”을 배운다. $\epsilon = 0.3$ 고정 시 π 의 값 $V^\pi(S) \approx 2.29$ 로 수렴 — 해석적으로 정확히 2.292. 2.589가 아니라 2.29.

(참고: 이때 $Q(S, \text{run})$ 자체는 ≈ 2.53 — π 가 15% 확률로 rest를 실제로 고르기 때문에 $V^\pi(S) = 0.85 Q^\pi(S, \text{run}) + 0.15 Q^\pi(S, \text{rest})$ 가 실제 선택 분포까지 반영해 더 낮아짐.)

경로 ③ SARSA — 0.297의 간극은 버그가 아니라 기능

- **2.589 — 2.292 = 0.297**의 간극은 **버그가 아니라 기능** — “ ϵ -greedy가 30%의 시간을 미끄러지며 낭비한다”는 사실이 가치에 반영된 것 (6.3 CliffWalking 에서 “학습 도중 리턴이 오히려 나쁜” SARSA의 근원이 바로 여기).
- ϵ 을 **감쇠**시키면(매 에피소드 0.995배 스케줄) V^π 는 V^* 에 가까워진다 — $\epsilon \rightarrow 0$ 이면 행동정책이 greedy로 수렴하므로, 실습에서 ϵ 감쇠 **SARSA는 2.589로 끝난다**.

on/off-policy의 차이는 **취향이 아니라 “무엇을 묻느냐”**의 차이 — ③은 “지금 탐험하는 정책의 값”, ④는 “최적 값”.
(확인 문제 3의 “왜 PPO는 데이터를 재사용할 수 없는가”의 표 버전이다.)

경로 ④ Q-learning(Ch6 off-policy) — max 한 줄

- 갱신식에 max을 써서, 행동 정책이 실제로 무엇을 했든 “다음에서는 **최선을 고른다면**”을 목표값으로 삼는다.
- 그래서 행동 정책과 무관하게 **최적 Q에 직접 수렴** — 시뮬레이션(2000 에피소드, ϵ 을 0.05까지 감쇠)
결과 $Q(S, \text{run}) \approx 2.64$, $Q(S, \text{rest}) \approx 1.34$, $Q(G, \text{collect}) = 3.0$ — 참값(2.589, 1.330, 3.0)에 근접.

경로	장	무엇을 쓰는지	$V(S)$ 추정/수렴값	수렴 대상
① 동적계획법 (손계산)	Ch4	전이 모델 P	2.589	최적값 V^*
② 몬테카를로	Ch5	에피소드 전체 리턴	2.594 (4000 에피소드)	greedy
③ SARSA	Ch6	1스텝 TD 오차 (on-policy)	2.29 ($\epsilon = 0.3$ 고정)	행동 정책
④ Q-learning	Ch6	1스텝 TD 오차 (off-policy)	2.64 (2000 에피소드, $Q(S, \text{run})$)	최적값 Q^*

③과 ④의 갱신식은 **한 줄 차이**다 — 6.3에서 “SARSA vs Q-learning의 차이는 max 한 줄”이라 했지만, 그 한 줄이 **수렴하는 대상 자체를 바꾼다**:

한 줄 차이 — SARSA vs Q-learning

```
# SARSA (on-policy): 다음행동은 a_next ε-greedy 실제로고른것
Q[s, a] += alpha * (r + gamma * Q[ns, a_next] - Q[s, a])
# Q-learning (off-policy): 실제로무엇을했든최선을 ”” 목표로
Q[s, a] += alpha * (r + gamma * np.max(Q[ns]) - Q[s, a])
```

왜 1개 MDP를 네 번 푸는가가 가치 있는가

단일 장에서는 보이지 않는 세 가지가 숫자로 드러난다. **(1) 목표가 다르면 답이 다르다** — ③④는 갱신식이 한 줄 ($Q[ns, a']$ vs $\max Q[ns]$) 다른 구조인데 $V(S)$ 가 2.29와 2.589에 각각 수렴 — 간극이 정확히 $V^* - V^\pi = 0.297$, “탐험의 가격” 그 자체. **(2) 네 경로 모두 같은 방정식을 쓴다** — ①이 벨만방정식을 직접 풀고, ②는 미래 향을 실제 실현으로, ③④는 한 스텝 예측 + 자기 추정으로 대체한 것뿐. **(3) 탐험의 비용이 측정된다** — ③의 0.297 간극은 “ $\epsilon = 0.3$ 의 탐험이 리턴 기준으로 이만큼 값어치가 한다”는 숫자 — Ch2에서 직관으로 시작한 탐험-활용 딜레마가 여기서는 측정 대상.

ML2 개념 지도 — 13개 장

장	배운 것	핵심 질문
Ch02	멀티암 밴딧	상태 없이도 탐험-활용 딜레마를 어떻게 다루는가
Ch03	MDP	강화학습 문제를 어떻게 수학적으로 정식화하는가
Ch04	동적계획법	모델을 알 때 최적 정책을 어떻게 계산하는가
Ch05	몬테카를로	모델 없이, 에피소드 결과만으로 어떻게 배우는가
Ch06	시간차 학습	에피소드가 끝나길 기다리지 않고 어떻게 배우는가
Ch07	n-step/적격흔적/Dyna	MC와 TD 사이, 경험 재사용은 어떻게 하는가
Ch09	DQN	표 대신 신경망으로 어떻게 Q-함수를 근사하는가
Ch10	정책기반 RL	Q를 거치지 않고 정책을 직접, 연속공간에서 어떻게 학습하는가
Ch11	PPO	정책이 한 번에 너무 멀리 움직이지 않게 어떻게 제한하는가
Ch12	모방학습/RLHF	시행착오 대신 시연이나 선호로부터 어떻게 배우는가
Ch13	로봇 시뮬레이션	물리 법칙이 지배하는 연속 제어 문제를 어떻게 다루는가
Ch14	MuJoCo/Isaac Sim	시뮬레이션의 정밀도와 속도를 어떻게 절충하는가
Ch15	MCTS	완벽한 모델이 있을 때 미리 수를 어떻게 읽어보는가

두 과목을 관통하는 구조 — 3단계

- ① **모델을 정의한다**: 상태를 행동(또는 그 확률분포)으로 매핑하는 함수의 형태를 정한다 (Q-테이블, 신경망 Q-함수, 정책 신경망, 게임 트리, ...).
- ② **틀린 정도(또는 목표와의 격차)를 수치화한다**: TD 오차, 정책 그래디언트의 목적함수, PPO의 클리핑된 목적함수, MCTS의 승률 통계, ... — **형태는 매번 다르지만** “지금 얼마나 좋은가/나쁜가를 수치 하나로 요약한다”는 **역할은 항상 같다**.
- ③ **그 수치를 개선하는 방향으로 파라미터(또는 탐색 방향)를 조정한다**: 경사하강법, 또는 트리 탐색의 반복 — **이 학기 배운 모든 알고리즘의 마지막 단계는 결국 이것**.

“네 경로” 예가 3단계의 축소판

앞의 4경로 예는 이 3단계가 같은 방정식 위에서 어떻게 변주되는지, 이 지도는 그 변주들이 어떤 축을 따라 정렬되는지를 그려준다.

Block B 개념 지도 읽는 법 — 박스와 축의 교차점

지도의 읽기는 8.3 Block A 지도와 같은 두 기법:


● (1) 질문은 박스가 아니라 박스와 축의 교차점

— “DQN의 리플레이 버퍼가 왜 PPO에는 없는가” = DQN 박스와 on/off-policy 축이 만나는 **엇지**; “GAE의 λ 를 0.95로 올리면 어떻게 되나” = PPO 박스와 편향-분산 축의 **엇지**.

● (2) 엇지가 곧 “왜” — 박스 자체를 묻는 질문은 드물다. 발표·면접에서 반복적으로 나오는 것은:

- ▶ **신경망으로 바꾼 이유**(Ch9, 표가 불가능해진 상태공간)
- ▶ **클립을 하는 이유**(Ch11, 한 번의 업데이트가 정책을 망가뜨리는 방어)
- ▶ **모방학습이 나빠지는 이유**(Ch12, 분포 이동의 복합 오차)
- ▶ **sim-to-real이 필요한 이유**(Ch13, 현실

Block B(Ch9~15) 개념 지도 — 한 질문: “정답 없이, 내가 만든 경험만으로, 로봇 스캐일까지 배우는가?”



확인 문제: 장을 넘나드는 복습 4개 (1)-(2)

- 1. Ch2.2의 **UCB**와 Ch15.2의 **UCT**는 수식이 거의 똑같다. 무엇이 같고, 다른가?

→ 둘 다 “지금까지의 평균 성과 + 덜 시도해본 정도에 대한 불확실성 보너스”라는 같은 형태 ($\bar{X} + c\sqrt{\ln N/n}$).
다른 것은 적용 대상 — UCB는 **밴딧의 팔**(상태 없는 단일 선택) 하나하나에, UCT는 **게임 트리의 매 노드마다** 독립적으로 적용되어 “각 국면에서 다음 수를 고르는” 문제를 반복해서 푼다.

- 2. Ch6.1의 **TD 오차**와 Ch10.3의 **Actor-Critic**은 어떤 관계인가?

→ Actor-Critic의 **critic**이 학습하는 신호가 바로 **TD 오차** — REINFORCE(10.2)가 에피소드 전체 리턴으로 그래디언트 분산이 컸다면, AC는 그 리턴을 **TD 오차**(한 스텝만 보고 계산한 어드밴티지 추정치)로 대체해 **분산을 줄인다**. Ch11.3의 **GAE**는 이 TD 오차를 여러 스텝에 걸쳐 지수가중평균한 **일반화**.

확인 문제: 장을 넘나드는 복습 4개 (3)-(4)

- 3. DQN(off-policy)이 리플레이 버퍼의 오래된 경험을 재사용할 수 있는데, REINFORCE·PPO는 왜(PPO는 부분적으로만) 그럴 수 없는가?

→ DQN은 **Q-함수**(정답이 정해진 값)를 배우는 것이라 “누가 그 경험을 만들었는지”와 무관하게 벨만 방정식이 성립 — **off-policy**. REINFORCE는 정책 그래디언트가 “지금 정책이 그 행동을 선택할 확률”에 의존 — 정책이 바뀌면 그 확률도 바뀌어 **옛 데이터의 그래디언트가 더 이상 정확하지 않다(on-policy)**. PPO는 확률비 $r_t(\theta)$ 로 이 차이를 **보정**하고 클리핑으로 오차를 억제해서 몇 에폭 정도는 재사용 가능하지만, DQN처럼 완전히 오래된 경험까지는 재사용 못 함.

- 4. Ch12.1 **모방학습**(BC/DAGger)과 Ch15.2 **MCTS**는 둘 다 “에이전트가 직접 시행착오를 겪는 것의 대안”. 각각 무엇을 대신 활용하는가?

→ 모방학습은 **사람의 시연**(전문가가 실제로 어떻게 행동했는지)을 **정답** 삼아 지도학습으로 정책을 배움. MCTS는 **완벽한 모델(규칙)로 만든 가상의 시뮬레이션**을 반복해서, 실제로 행동하기 전에 결과를 미리 들여다봄. 둘 다 표준 RL보다 **안전하거나 효율적**이지만, 전자는 **사람의 시연 데이터**가, 후자는 **정확한 모델(규칙)**이 있어야 한다는 **전제**가 필요.

복습 자가진단 — 20문항

8.3의 20문항과 같은 형식 — 각 문항에 대해 10초 안에 한 문장으로 답을 말할 수 있으면 O, 막히면 ×. 18개 이상 = 준비 완료 / 15~17 = ×가 모인 장의 “자주 하는 실수”+확인 문제 다시 / 12~14 = § 네 경로의 수식(TD 오차, 클리핑된 목적함수)을 손으로 다시 유도 / 12 미만 = § 자주 하는 실수(총정리판)를 건너뛰지 않는다.

한 문장 질문 (장)

- 1 DQN의 타겟 네트워크는 왜 매 스텝 갱신하면 안 되는가 (Ch09)
- 2 리플레이 버퍼가 해결하는 문제와, DQN에서만 가능한 이유 (Ch09/06)
- 3 TD 오차를 Q 로 표기하시오 (Ch06/09)
- 4 REINFORCE와 TD 갱신의 차이를 한 문장으로 (Ch10)
- 5 baseline 차분이 왜 편향을 만들지 않는가 (Ch10)
- 6 PPO의 클리핑이 막는 “나쁜 일”은 무엇인가 (Ch11)
- 7 정책 그래디언트가 왜 on-policy여야 하는가 (Ch10/11)
- 8 GAE의 λ 가 0이면 / 1에 가까우면 각각 무엇이 되는가 (Ch11)
- 9 행동복제가 “복합 오차”로 나빠지는 메커니즘 (Ch12)
- 10 DAGger가 복합 오차를 피하는 방식 (Ch12)
- 11 RLHF에서 “정답”이 아니라 무엇으로 레이블을 얻는가 (Ch12)
- 12 로봇 정책을 시뮬레이션에서 학습하는 이유 두 가지 (Ch13)
- 13 현실 격차가 “잡음”이 아니라 “편이”라는 말의 뜻 (Ch13)
- 14 도메인 무작위화 범위가 넓은 것이 항상 좋은 것이 아닌 이유 (Ch13)
- 15 MuJoCo와 Isaac Sim의 트레이드오프를 한 문장으로 (Ch14)
- 16 AlphaZero가 정책망과 가치망을 둘 다 쓴 이유 (Ch15)
- 17 UCT의 탐색 항이 “시도 횟수”로 무엇을 쓰는지 (Ch15/02)
- 18 MCTS가 DP와 다른 점 — “모델”을 어떻게 쓰는지 (Ch15/04)
- 19 이번 학기 모든 알고리즘의 공통 3단계를 쓰시오 (저체)

자가진단 답 (한 줄) — 핵심 10문항

- ① 1 — 목표와 추정치가 서로를 따라다니며 발산하기 때문(9.2절 보스팅 불안정의 방치 버전).
- ② 3 — $\delta = r + \gamma Q(s', a') - Q(s, a)$ — 최적을 추구하면 a' 자리에 max.
- ③ 5 — baseline $b(s)$ 가 a 에 무관하므로 $\mathbb{E}_a[\nabla \log \pi(a|s) b(s)] = b(s) \nabla \sum_a \pi(a|s) = 0$ — **분산만 줄고 편향은 0.**
- ④ 6 — $r_t(\theta)$ 가 1에서 크게 벗어나 한 업데이트에 정책이 “멀리 점프”해 좋은 정책을 **망가뜨리는 것** — 클리핑은 점프 반경을 제한.
- ⑤ 8 — $\lambda = 0$ 이면 TD(0)(편향 있음, 분산 작음), $\lambda \rightarrow 1$ 이면 (유한 에피소드에서) MC 리턴(편향 없음, 분산 큼) — 7.2의 U자 스펙트럼.
- ⑥ 9 — 전문가 데이터 **분포 밖** 상태에 들면 그 행동이 신뢰 불가 → 다음 상태가 더 벗어난 분포로 → 오차가 **스텝마다 곱해짐**(covariate shift).
- ⑦ 11 — 사람의 **선호**(두 응답 중 어느 것이 나은지) — 선호 데이터로 **보상 모델**을 먼저 학습하고, 그 보상으로 PPO.
- ⑧ 13 — **systematic**한 차이이므로 시뮬레이션 데이터를 늘려도 **사라지지 않음** — ML1 Ch04 bias-variance에서 “편이는 데이터로 안 줄고”의 RL 버전.
- ⑨ 15 — MuJoCo: 접촉·마찰 **정밀도**, Isaac: GPU **병렬화**(수천 환경 동시) — 정밀도 대 규모.
- ⑩ 20 — ML1은 다른이(데이터 수집자)가 만든 데이터와 정답을 줘 맞게 하고, ML2는 에이전트가 행동해서 데이터를 스스로 만들고 정답 없이 보상만으로 배운다 — “**무엇을 데이터로 갖고, 무엇을 최적화하는가**”의 답이 바뀌는 것.

자주 하는 실수 — 총정리판

- “곡선이 올라갔다”로 “왜 올라갔는지”를 대체하기 — 16.1 좋은/나쁜 예의 학기 전체 버전. “PPO로 학습 했는데 리턴이 좋아졌다”는 문장은 Ch11의 어떤 개념도 사용 하지 않은 문장. “보상 스케일링 1/8로 어드밴티지 분산이 줄었고 (11.1), $\lambda = 0.9$ 로 편향-분산 트레이드오프를 조정한(11.3) 결과”까지가 한 문장이면, 그 팀은 이 학기를 **통과**한 것.
- “시뮬레이션에서 검증했다”로 “완료” 선언하기 — 시뮬레이션 점수는 **시뮬레이션 환경의 점수**일 뿐, 시뮬 상위권 정책이 **실물에서 꿀찌**로 뒤집힐 수 있음. 물리 파라미터(감쇠, 마찰)를 넣었다면 그 파라미터를 바꿔 “순위 유지”가 성립하는지 확인한/안 한 팀의 점수가 rubric “방법론 적절성”에서 갈림.
- “PPO가 더 좋았다”를 조건 없이 쓰기 — 알고리즘 비교 결론에 **환경(연속/이산, 보상 구조), 시드 수, 하이퍼파라미터**가 붙지 않으면 그 문장은 **무효**. 유효한 버전: “Pendulum, 시드 3개, 같은 총 스텝 수에서, PPO($\lambda = 0.9$)가 REINFORCE 대비 에피소드당 리턴이 평균 12% 높고 시드 간 표준편차는 40% 작았다”.
- “수렴했다”와 “좋다”를 혼동하기 — 탐험이 부족한 상태의 Q값은 틀린 값으로 정확히 수렴할 수 있고, 곡선의 “평탄화”는 수렴일 수도 **고착(stuck)**일 수도 있음. 16.1 Pendulum 예(−1092, 이론 최적과는 멀다) = “개선됐지만 수렴한 것은 아니다”의 정직한 보고 예.
- 자기 프로젝트의 실패를 복습 자료로 안 쓰기 — “이 실험의 이상한 결과를 원인으로 진단하라”형 질문(발표 질의응답, 면접)에 답할 자료는 **바로 16.1의 “잘 안 됐던 부분과 원인 진단” 절**. 자기 실험의 실패 한 것을 개념으로 해석한 능력은 어떤 참고서로도 대체 불가.

마지막 체크리스트 — 학기 이후에 가져갈 세 가지

공식 목록은 13개 장이지만, 졸업하고 몇 년 뒤에 실제로 남는 것은 세 가지:

- ① **“무엇을 데이터(경험)으로 갖고, 무엇을 최적화하고 싶은가”라는 질문의 습관.** 새로운 문제(운영 전략, A/B 테스트, 물리 설계, LLM 후학습)를 마주했을 때 “어떤 에이전트·어떤 보상·어떤 경험인가”로 **번역하는 연습**을 13번 한 것이 이 학기. 알고리즘 이름은 잊어져도 **이 번역은 남는다** — ML1의 “행의 단위, 정답의 유무”와 쌍을 이루는, 문제 정식화 기술의 절반이 완성된 것.
- ② **정직한 숫자에 대한 기준.** 시드 ≥ 3 · 학습/평가 분리 · 베이스라인 · “완전히 수렴하지 않았다”는 문장 — 8.1 에서 시작해 16.1에서 반복된 프로토콜의 정직성은, 강화학습만이 아니라 **모든 실험 과학**(ML1 val/test 정직성과 같은 뿌리)의 기본 문법.
- ③ **“같은 방정식, 다른 형태”의 지도.** 이 학기의 알고리즘 13개는 **3단계 구조의 13가지 변주**에 불과 — 그래서 새 알고리즘 논문을 만나도 “이것은 ②번(수치화)을 바꾼 변주구나” 에서부터 읽을 수 있다. 지도의 **엣지**를 말할 수 있는 한, 지도는 **확장 가능한 자산**이고, **박스만 외운** 한으로는 **재고**에 불과하다.

최신 동향 — 이 학기가 이어지는 세 방향

이번 학기에서 다루기엔 이르지만 지금 활발히 연구되는 방향 — “지금 배운 것이 이런 곳으로 이어질 수 있다”는 지도를 그리는 것이 목적.

- **오프라인 강화학습 (Offline RL)** — 환경과 직접 상호작용하지 않고, 이미 모아둔 방대한 로그 데이터만으로 정책을 학습. 실물 로봇으로 탐험하는 것 자체가 위험하거나 비싼 상황(자율주행, 의료)에서 특히 중요. Ch12 모방학습과 문제의 식이 비슷하지만, 시연이 아니라 (좋은 것과 나쁜 것이 섞인) 임의의 로그로부터 배운다는 점이 다름.
- **범용 로봇 정책 (Generalist Robot Policies)** — 하나의 작업에 특화된 정책 대신, 다양한 로봇·작업에 걸쳐 일반화되는 하나의 큰 정책(RT-2, OpenVLA 등) — ML1의 LLM 사전학습 아이디어를 로봇 제어에 적용한 것에 가까움: 방대한 로봇 시연·상호작용 데이터로 폭넓게 학습한 뒤 특정 작업에 맞게 다듬음.
- **Sim-to-Real의 발전** — Ch13.1 도메인 무작위화를 넘어, 시뮬레이션과 실제 환경의 차이 자체를 학습으로 메우려는 연구 — Ch14 GPU 가속 시뮬레이션(Isaac Sim 등)이 “훨씬 많은 다양한 시뮬레이션 조건을 빠르게 경험시킨다”는 방향으로 기여.

더 깊이 파고들고 싶다면: 각 장에서 “이 학기 범위를 넘는다”고 언급됐던 부분 — TRPO의 상세 수학, DAgger의 수렴 증명, 멀티에이전트 RL의 내쉬 균형, AlphaZero의 자기대국 학습 세부사항 등.

자주 묻는 질문 — 산출물·Block A/B 차이·다음 방향

- **16.3의 산출물? 두 개:** (1) § 손으로 한 번의 rubric 표 4행(“나쁠 때의 모습” + “시험하는 질문”), (2) 20문항 자가진단에서 본인이 $\times$ 를 표한 것 중 **3개**를 골라, 각각 “말했어야 할 한 줄”을 **자기 언어**로 쓰는 것. $\times$ 개수 자체는 점수가 **아니다** — $\times$ 를 자기 언어로 메운 문장이 점수화. 16.1 = “프로젝트를 정직하게 수행했는가”, 16.2 = “남의 프로젝트를 구체적으로 심사를 했는가”, 16.3 = “**학기 전체를 자기 것으로 만들었는가**”를 묻는 블록.
- **Block A vs Block B 복습은 어디에 시간을?** 요구사항의 **형태**가 바뀌었다 — Block A: “알고리즘 최소 2개 비교” + 개념 연결 / Block B: **알고리즘 1개 + 수식적 정당화 1개**. “어떤 알고리즘을 썼는가”보다 “**왜**” 그 하이퍼파라미터(보상 스케일, γ , λ , 클립 ϵ)를 그렇게 골랐는가가 점수의 대부분을 결정 — 복습의 무게중심도 “개념 나열”에서 “**개념 → 내 실험의 숫자**”를 잇는 연습으로 이동.
- **졸업 후 자연스러운 다음은?** § 최신 동향의 **세 방향**이 현재 주류 — 오프라인 RL(로그 데이터만 있는 실서비스), 범용 로봇 정책(LLM 사전학습이 로봇으로 건너간 지점), Sim-to-Real(13~14장의 정면 돌파). 공통 지름줄은 **하나**: 3단계 구조(모델 정의 → 수치화 → 개선)로 그 연구를 **자신만의 언어로 다시 정식화**할 수 있는가.

마지막 한 문장

ML1이 “정답이 있는 데이터로부터 배운다”는 세계였다면,
ML2는 “스스로 행동해서 얻은 경험만으로 배운다”는 완전히 다른 세계.

- **밴딧**의 탐험-활용 딜레마에서 시작해 **MDP** · **동적계획법** · **몬테카를로** · **시간차 학습**으로 이론을 다졌고, **신경망**과 결합해 그 이론을 **로봇 시뮬레이션**이라는 현실적인 무대까지 끌고 왔다.
- 이제 이 두 세계 모두에서, “**무엇을 데이터(또는 경험)로 갖고 있고, 무엇을 최적화하고 싶은가**”라는 **같은 질문**을 던질 수 있을 것이다.

이번 주차 정리

- **16.1 팀 프로젝트: 발표** — 환경은 “개념 X가 돋보이는 무대” 기준으로, 알고리즘과 **페어링**.
베이스라인(무작위 -1274, zero-torque -1230)을 먼저 재야 “개선”의 방향을 말할 수 있다. $\epsilon = 0$ 의 대응물 = $a = \mu$ **결정적 평가** (σ 는 학습된 파라미터라 0으로 바꾸지 않고, 샘플링만 안 함). 12만 스텝 Pendulum 실습: 학습 도중 마지막 10(-673/ -732/ -668)이 베이스라인 2배여도, **결정적 평가**(≈ -1403)가 베이스라인(-1274) 아래 — “곡선이 올랐다” $\neq$ “무작위보다 낫다”. M2에 **학습 예산 추정**(22초 기준선). **수식적 정당화** = 수치 + “완전 수렴 아님”의 정직함 + 하이퍼파라미터 근거. **채점** = 정직성 45% — 프로토콜 정직성이 정책의 질보다 중요.
- **16.2 Peer-Review** — **역전의 주**: 네가 심사위원. 5항목(환경/알고리즘 선택/정당화/정직성/탐험-활용) + **1점(감상평)** → **2점(일반 지적)** → **3점(반박 가능한 질문 = 개념 명시 + 답이 나쁘면 결과가 흔들림)**. 신경망 특유의 “우연히 좋은” 패턴 5가지: 시드 1개 학습 곡선, 학습 도중 리턴으로 수렴 결론, 하이퍼파라미터 “적당히”, 이산용(DQN)을 연속에, 베이스라인 없이 “잘 배웠다”. 실습: 가상 발표(시드 42, -742.0)를 재실행 — 같은 정책, 다른 프로토콜로 -742 vs -1413/ -1491(결정론적), 무작위 -1239 **아래로** 뒤집힘. 시드 간 sd(약 70) > 개선폭(약 63). **발표 전 셀프-리뷰**가 최선의 전략.
- **16.3 ML2 총정리** — **새로운 개념 없음**. 하나의 MDP(달리거나 쉬거나, $\gamma = 0.9$)를 네 경로로: ① DP $V^*(S) = 2.589$ (정확) / ② MC 2.594(편향 없음) / ③ SARSA **2.29**(행동 정책 V^π , 간극 0.297 = “탐험의 가격”) / ④ Q-learning 2.64(max 한 줄이 수렴 대상 자체를 변경). 두 과목을 관통하는 **3단계**: 모델 정의 → 틀린 정도 수치화 → 개선. 개념 지도 읽기: 질문은 박스와 축의 교차점(엣지), 엣지가 곧 “왜” 30분할 자기질문: “하기 이후에 가져갈 배가지?”/버려진 수과 정직함 수자의 기증