Machine Learning 2: 강화학습 2027. X. XX (예정)

Block A 캡스톤 팀 프로젝트 공고 (샘플)

Spring 2027

1. 프로젝트 개요

Chapter 4∼7에서 배운 표 기반(tabular) 강화학습 기법(동적계획법, 몬테카를로, 시간차 학습, n-step 부트스트래핑)을 실제 Gymnasium 환경에 적용하는 4주짜리 팀 프로젝트이다. 목표는 "좋은 정책을 만드는 것" 자체가 아니라, **그 성능 숫자를 정직하게 얻는 절차**를 실제로 수행하고 보고하는 것이다.

4주 파이프라인: **환경 고르기** → **구현** → **평가** → **발표**.

2. 필수 요구사항

- **환경**: Gymnasium의 표 기반(이산 상태 · 행동) 환경 하나 — `FrozenLake-v1`, `CliffWalking-v1`, `Taxi-v4` 등.
- **적용 알고리즘**: Chapter 4∼7 중 **최소 두 가지**(예: Q-learning vs SARSA, MC 제어 vs n-step TD)를 같은 환경에 적용해 학습 곡선과 최종 정책을 비교한다.
- **수식적 정당화 최소 1개**: 예 — Q-learning/SARSA 비교라면 on/off-policy 관점에서 정책이 왜 다르게 학습됐는지, ε/α 변경 실험이라면 수렴 조건과 연결, Dyna-Q라면 계획 스텝 수와 학습 속도의 관계를 직접 측정.
- **베이스라인 필수**: 무작위 정책의 평균 리턴을 먼저 측정해, "배운 정책이 실제로 무작위보다 나은가"를 판정할 기준점을 마련한다.
- **시드** ≥ 3, 모든 시드에 **동일한 평가 프로토콜**(greedy 평가 $\varepsilon = 0$, 동일 에피소드 수)을 적용한다.

3. 환경 후보 (예시)

환경	상태× 행동	보상 구조	잘 어울리는 비교
FrozenLake-v1	16×4 (미끄럼)	도착 +1, 그 외 0 (구멍 종료)	MC vs SARSA — 확률 전이에서 시드 안정성
CliffWalking-v1	48×4	스텝 −1, 절벽 −100, 도착 0	SARSA vs Q-learning — on/off-policy 클래식 비교
Taxi-v4	500×6	성공 +20, 불법 −10, 스텝 −1	n-step vs TD(0), Dyna-Q

환경 선택은 자유이지만, **Chapter 4∼7의 개념 검증 목적**에 근거해야 한다 (상태 수, 보상 구조, 확률 전이 중 무엇이 이 비교를 정당화하는지 설명할 수 있어야 한다).

4. 시드 프로토콜

"한 번의 실행"은 아무것도 말해주지 않는다 — ε-greedy 탐험의 무작위성, 환경 전이 자체의 무작위성, 정책 초기화 때문에 같은 코드·같은 파라미터를 그대로 돌려도 매번 다른 학습 곡선이 나온다.

1. **시드** ≥ 3으로 비교할 모든 알고리즘을 전부 돌린다.
2. 학습 도중 성과(탐험 포함)와 학습 후 **greedy 평가** 성과를 반드시 분리해서 보고한다.
3. 하이퍼파라미터는 학습 곡선(validation)으로만 튜닝하고, 최종 평가 수치를 보며 조정하지 않는다.

5. 일정 및 마일스톤 (M1∼M4)

주 / 해야 할 일	마일스톤(제출)
1주: 환경 후보 2∼3개 조사(상태 수·보상 구조·확률 전이 여부), 팀 회의, 문제 정의 문서(어떤 MDP인지, 어떤 지표를 쓸지, 베이스라인)	**M1** 문제 정의 + 환경 선택 (1p)
2주: 두 알고리즘 구현, 베이스라인 리턴 측정, 시드 3개 중 1개에서 엔드투엔드 동작 확인	**M2** 중간 코드 리뷰 (코드 + 베이스라인 숫자 1줄)
3주: 나머지 시드 실행, ε/α 튜닝(모두 동일 프로토콜), greedy 평가($\varepsilon = 0$), 시드 비교표 도출	**M3** 학습 곡선 1장 + 시드 비교표
4주: 수식적 정당화, 보고서·슬라이드 완성, 발표 (5∼7분), 다른 팀 2개에 대한 peer-review 작성	**M4** 보고서 + 발표 + 리뷰 2건

M1, M2는 팀 전체가 모여 함께 결정한다.

6. 보고서 구조

1. **문제 정의** (0.5p): MDP 5요소(상태·행동·전이·보상· 할인율), 주 지표(greedy 평가 평균 리턴), 베이스라인(무작위 정책 리턴).
2. **알고리즘 선택과 이유** (1p): 후보 2개 이상, 왜 이 알고리즘을 이 환경에 골랐는가(보상 구조·상태 수와 연결), 하이퍼파라미터($\alpha, \gamma, \varepsilon$ 스케줄)와 선택 근거.
3. **실험 프로토콜** (1p): 시드 목록, 학습 에피소드 수, 평가 프로토콜($\varepsilon = 0$, 에피소드 수, 모든 알고리즘 동일) 명시.
4. **결과** (1p): 시드 비교표, 학습 곡선 1장(여러 시드를 한 그림에 얇은 선으로), greedy 정책 경로 시각화.
5. **수식적 정당화** (1p): 배운 개념 1개 이상으로 "왜 이 결과".
6. **잘 안 된 부분과 원인 진단** (0.5p, **필수**): 안 된 부분이 없었다면 무엇을 시도했다가 안 됐는지를 쓴다.

7. 채점 기준 (Rubric)

항목	비중	좋은 답
문제 정의와 환경	15%	MDP 5요소·지표·베이스라인이 명확하고, 선택이 개념 검증 목적에 근거
방법론 적절성	20%	환경 특성에 맞는 알고리즘·파라미터 선택, 근거가 배운 개념으로 설명됨
실험 프로토콜의 정직성	**25%**	시드 ≥ 3, 동일 평가 프로토콜, 베이스라인, ε 스케줄이 보고서에서 추적 가능할 만큼 명시
수식적 정당화	20%	배운 개념 1개 이상으로 "왜"를 설명했고, 관측한 숫자와 일치
결과의 정직성과 반성	**20%**	불안정했던 시드·구간을 숨기지 않고 배운 개념으로 진단

"실험 프로토콜의 정직성"과 "결과의 정직성과 반성" 두 항목이 합쳐서 **45%**를 차지한다.

8. 발표와 Peer-Review

- **발표**: 팀당 5~7분.
- **Peer-Review**: 발표를 들은 팀은 다른 두 팀에 대해 작성 리뷰를 각 1통씩 제출한다. 각 리뷰는 아래 4항목 체크리스트와, 반박 가능한 질문을 1개 이상 포함해야 한다.

Peer-Review 체크리스트 (4항목)

항목	확인할 것
환경 설명	상태·행동·보상이 명확히 정의됐는가, 주 지표(학습중 리턴? greedy 평가?)가 분리되어 있는가
알고리즘 선택	환경 특성(상태 공간, 보상 구조, 확률 전이)이 그 비교를 정당화하는가
수식적 정당화	짚은 개념이 실측 숫자와 일치하는가
결과의 정직성	시드 ≥ 3, 불안정했던 시드·구간이 숨겨지지 않고 보고됐는가

9. 팀 구성 및 제출 방식

- **팀 구성**: 팀당 인원 및 팀 편성 방식은 추후 공지.
- **제출물**: 보고서(PDF), 코드(저장소 링크 또는 압축 파일), 발표 슬라이드, peer-review 2건.

- **제출 방법 및 마감**: 추후 공지 (LMS/과제 제출 시스템 및 마감 일시는 별도 안내 예정).