

Block B 캡스톤 팀 프로젝트 공고 (샘플)

Spring 20XX

1. 프로젝트 개요

Chapter 9~15에서 배운 심층강화학습 도구(함수근사와 DQN, 정책기반 강화학습, PPO, 모방학습과 RLHF, 로봇 시뮬레이션, MCTS)를 **연속제어 환경**에 직접 적용하는 4주짜리 팀 프로젝트이다. 목표는 “좋은 정책을 만드는 것” 자체가 아니라, 그 성능 숫자를 정직하게 얻는 절차를 실제로 수행하고 보고하는 것이다.

4주 파이프라인: 환경 고르기 → 구현 → 평가 → 발표. 이 과정에서 “시드 ≥ 3 · 무작위 정책 베이스라인 · 학습/평가 분리”라는 실험 프로토콜을 지켜야 한다.

2. 필수 요구사항

- **환경:** PyBullet 또는 Gymnasium의 연속제어(또는 이산제어) 환경 중 하나(아래 3절 후보 참고, 팀별로 다른 환경 선택 가능).
- **적용 알고리즘:** Chapter 9~15 중 **최소 1개**의 방법(DQN, PPO, 모방학습, MCTS 등)으로 정책을 학습한다.
- **수식적 정당화 최소 1개:** 배운 개념(예: PPO 클리핑의 안정성 효과, 모방학습의 복합 오차, 도메인 무작위화의 sim-to-real 격차 완화)으로 “왜 이 결과가 나왔는지”를 설명해야 한다.
- **학습 곡선 필수 제시:** 에피소드별 누적 보상 곡선은 “학습이 실제로 되고 있는가”를 보여주는 기본 증거이다.
- **베이스라인 필수:** 무작위 정책의 평균 리턴을 먼저 측정해, “배운 정책이 실제로 무작위보다 나은가”를 판정할 기준점을 마련한다.
- **시드 ≥ 3 , 모든 시드에 동일한 평가 프로토콜**(학습 후 결정적 정책 $a = \mu$, 동일 에피소드 수)을 적용한다.

3. 환경 후보 (예시)

환경	상태 × 행동	보상 구조	잘 어울리는 개념
Pendulum-v1	3×1 (연속)	항상 음수, 0이 완벽	PPO 클리핑 효과
CartPole-v1	4×2 (이산)	생존 시 -1, 쓰러지면 종료	DQN vs PPO 비교
MountainCar-v0	2×3 (이산)	스텝당 -1 (희소)	GAE λ 트레이드오프
HumanoidStandup-v5	348×17 (연속)	포텐셜 기반 shaping	도메인 무작위화, MuJoCo

환경은 임의로 고르지 않는다. “검증하고 싶은 개념이 돋보이는 무대가 무엇인가”를 기준으로 알고리즘과 환경을 짝짓는다 — 예를 들어 PPO 클리핑의 효과를 보이고 싶다면 연속 행동 공간인 Pendulum 이, 도메인 무작위화 효과를 보이고 싶다면 물리적으로 더 풍부한 MuJoCo 환경이 적합하다.

4. 일정 및 마일스톤 (M1~M4)

주 / 해야 할 일	마일스톤(제출)
1주: 환경 후보 2~3개 조사, 문제 정의 문서 (MDP 5요소, 주 지표와 리턴의 이론적 범위), 베이스라인(무작위 정책) 리턴 측정	M1 문제 정의 + 환경 선택 + 베이스라인 숫자 (1p)
2주: 알고리즘 1개 이상 구현(기존 챕터 코드 재사용 가능), 시드 1개로 엔드투엔드 동작 확인, 학습 예산(예산 소요 시간) 추정	M2 중간 코드 리뷰(코드 + 베이스라인 + e2e 숫자)
3주: 나머지 시드 실행, 하이퍼파라미터 조정 (모든 시드에 동일 프로토콜 적용), 학습 후 결정적 평가, 학습 곡선/시드 비교표 작성	M3 학습 곡선 1장 + 시드 비교표
4주: 수식적 정당화 정리, 보고서·발표자료 완성, 발표(5~7분), 다른 팀 2개에 대한 peer-review 작성	M4 보고서 + 발표 + 리뷰 2건

5. 보고서 구조

1. 문제 정의 (0.5p): MDP 5요소, 상태·행동 차원과 범위, 전이·보상(이론적 리턴 범위 포함), 할인율, 주 지표(학습 후 결정적 평가의 평균 리턴), 베이스라인.
2. 알고리즘 선택과 이유 (1p): 왜 이 환경에 이 알고리즘을 골랐는가, 하이퍼파라미터와 그 선택 근거.
3. 실험 프로토콜 (1p): 시드 목록, 학습 예산, 평가 프로토콜(결정적 $a = \mu$, 에피소드 수, 모든 시드 동일) 명시.
4. 결과 (1p): 시드 비교표, 학습 곡선 1장(여러 시드를 함께 표시), 같은 정책의 여러 측정치(학습 도중/결정적/베이스라인) 비교.
5. 수식적 정당화 (1p): 배운 개념 1개 이상으로 “왜 이 결과가 나왔는지” 설명.
6. 잘 안 된 부분과 원인 진단 (0.5p, 필수): 안 된 부분이 없었다면 무엇을 시도했다가 잘 안 됐는지를 쓴다.

6. 채점 기준 (Rubric)

항목	비중	좋은 답
문제 정의와 환경	15%	MDP 5요소·차원·지표·베이스라인·리턴 이론 범위가 명확, 환경 선택 근거가 뚜렷함
방법론 적절성	20%	알고리즘이 환경 특성(이산/연속, 보상 희소성)에 맞았고, 하이퍼파라미터 근거가 배운 개념으로 설명됨
실험 프로토콜의 정직성	25%	시드 ≥ 3 , 동일 평가 프로토콜, 베이스라인, 예산과 선택 절차가 보고서에서 추적 가능
수식적 정당화	20%	배운 개념 1개 이상으로 “왜”를 설명했고, 그 설명이 실제 관측 숫자와 일치
결과의 정직성과 반성	20%	불안정했던 시드·구간, 베이스라인 이하의 결과를 숨기지 않고 배운 개념으로 진단

“실험 프로토콜의 정직성”과 “결과의 정직성과 반성” 두 항목이 합쳐서 45%를 차지한다. 결정적 평가가 베이스라인을 넘지 못해도 프로토콜이 정직하면 높은 점수를 받을 수 있고, 반대로 결과가 좋아 보여도 시드가 1개뿐이었다면 크게 감점된다.

7. 발표와 Peer-Review

- **발표:** 팀당 5~7분. 문제 정의(1분) → 알고리즘과 이유(2분) → 학습 곡선과 수식적 정당화(2~3분) → 잘 안 됐던 부분과 원인 진단(1분) 순서를 권장한다.
- **Peer-Review:** 발표를 들은 팀은 다른 두 팀에 대해 작성 리뷰를 각 1통씩 제출한다. 각 리뷰는 아래 5항목 체크리스트와, 근거를 대야만 답할 수 있는 반박 가능한 질문을 1개 이상 포함해야 한다.

Peer-Review 체크리스트 (5항목)

항목	확인할 것
환경 설명	상태·행동·보상이 명확히 정의됐는가
알고리즘 선택	환경 특성(이산/연속, 보상 희소성)에 알고리즘이 맞았는가
수식적 정당화	요구사항을 충족했고, 실제 관찰 결과와 일치하는가
결과의 정직성	수렴하지 않은 부분·불안정한 구간을 숨기지 않고 분석했는가
탐험-활용 균형	탐험-활용 딜레마가 실제 학습 곡선에서 어떻게 드러났는가

8. 자주 하는 실수 (미리 확인할 것)

1. 시드 1개만 돌리고 결론을 내리는 것 (시드 간 편차가 방법 간 차이보다 클 수 있다).
2. 학습 도중의 리턴(탐험 포함)을 최종 정책 성능으로 보고하는 것.
3. 최종 평가 수치가 예뻐질 때까지 하이퍼파라미터를 계속 조정하는 것(평가에 대한 과적합).
4. 베이스라인 없이 “잘 배웠다”고 주장하는 것.
5. 결정적 평가가 샘플링 평가보다 낮게 나오는 것을 버그로 오해하는 것 (정상적인 현상일 수 있다).

9. 팀 구성 및 제출 방식

- **팀 구성:** 팀당 인원 및 팀 편성 방식은 추후 공지 (예: 팀당 3~4인, 자유 구성 또는 무작위 배정).
- **제출물:** 보고서(PDF), 코드(저장소 링크 또는 압축 파일), 발표 슬라이드, peer-review 2건.
- **제출 방법 및 마감:** 추후 공지 (LMS/과제 제출 시스템 및 마감 일시는 별도 안내 예정).