**Machine Learning 2: 강화학습** 2027. X. XX (예정)

# 중간 프로젝트 공고 (샘플)

*Fall 2027*

## 1. 프로젝트 개요

4∼7주차에서 배운 표 기반(tabular) 강화학습 기법(동적계획법, 몬테카를로, 시간차 학습, n-step 부트스트래핑)을 실제 Gymnasium 환경에 적용하는 학기 전반 8주에 걸쳐 진행하는 팀 프로젝트이다. 목표는 "좋은 정책을 만드는 것" 자체가 아니라, **그 성능 숫자를 정직하게 얻는 절차**를 실제로 수행하고 보고하는 것이다.

진행 순서: **환경 고르기** → **Abstract** → **구현** → **평가** → **보고서 제출** → **동료평가**.

## 2. 필수 요구사항

- **환경**: Gymnasium의 표 기반(이산 상태 · 행동) 환경 하나 — `FrozenLake-v1`, `CliffWalking-v1`, `Taxi-v4` 등.
- **적용 알고리즘**: 4∼7주차 중 **최소 두 가지**(예: Q-learning vs SARSA, MC 제어 vs n-step TD)를 같은 환경에 적용해 학습 곡선과 최종 정책을 비교한다.
- **수식적 정당화 최소 1개**: 예 — Q-learning/SARSA 비교라면 on/off-policy 관점에서 정책이 왜 다르게 학습됐는지, $\varepsilon/\alpha$ 변경 실험이라면 수렴 조건과 연결, Dyna-Q라면 계획 스텝 수와 학습 속도의 관계를 직접 측정.
- **베이스라인 필수**: 무작위 정책의 평균 리턴을 먼저 측정해, "배운 정책이 실제로 무작위보다 나은가"를 판정할 기준점을 마련한다.
- **시드** $\geq 3$, 모든 시드에 **동일한 평가 프로토콜**(greedy 평가 $\varepsilon = 0$, 동일 에피소드 수)을 적용한다.

## 3. 환경 후보 (예시)

| 환경 | 상태× 행동 | 보상 구조 | 잘 어울리는 비교 |
|---|---|---|---|
| FrozenLake-v1 | 16×4 (미끄럼) | 도착 +1, 그 외 0 (구멍 종료) | MC vs SARSA — 확률 전이에서 시드 안정성 |
| CliffWalking-v1 | 48×4 | 스텝 −1, 절벽 −100, 도착 0 | SARSA vs Q-learning — on/off-policy 클래식 비교 |
| Taxi-v4 | 500×6 | 성공 +20, 불법 −10, 스텝 −1 | n-step vs TD(0), Dyna-Q |

환경 선택은 자유이지만, **4∼7주차의 개념 검증 목적**에 근거해야 한다 (상태 수, 보상 구조, 확률 전이 중 무엇이 이 비교를 정당화하는지 설명할 수 있어야 한다).

## 4. 시드 프로토콜

"한 번의 실행"은 아무것도 말해주지 않는다 — $\varepsilon$-greedy 탐험의 무작위성, 환경 전이 자체의 무작위성, 정책 초기화 때문에 같은 코드·같은 파라미터를 그대로 돌려도 매번 다른 학습 곡선이 나온다.

1. **시드** $\geq 3$으로 비교할 모든 알고리즘을 전부 돌린다.
2. 학습 도중 성과(탐험 포함)와 학습 후 **greedy 평가** 성과를 반드시 분리해서 보고한다.
3. 하이퍼파라미터는 학습 곡선(validation)으로만 튜닝하고, 최종 평가 수치를 보며 조정하지 않는다.

# 5. 일정 (전반 8주)

| 시기 | 해야 할 일 | 제출 |
|---|---|---|
| **1∼2주** | 팀 구성, 환경 후보 2∼3개 조사 (상태 수·보상 구조·확률 전이 여부) | |
| **3주** | 문제 정의(MDP 5요소, 주 지표), 선택한 환경, 무작위 정책 베이스라인과 비교할 알고리즘 계획 | **Abstract** (1p) |
| **4∼5주** | 두 알고리즘 구현, 시드 3개 이상 실행, $\varepsilon/\alpha$ 튜닝(모두 동일 프로토콜), greedy 평가, 시드 비교표 | |
| **6주 (중간고사 기간)** | 보고서 완성 | **보고서 제출**: 보고서 PDF + 코드 + 학습 곡선 |
| **7주** | 제출된 다른 팀 보고서 읽기 | |
| **8주 (중간고사 기간)** | 다른 팀 2개에 대한 peer-review 작성 | **동료평가** 제출 (리뷰 2건) |

Abstract에 무작위 정책 베이스라인 계획을 넣는 이유: 이 숫자를 봐야 "배운 정책이 무작위보다 나은가"를 판정할 수 있다.

# 6. 보고서 구조

1. **문제 정의** (0.5p): MDP 5요소(상태 · 행동 · 전이 · 보상 · 할인율), 주 지표(greedy 평가 평균 리턴), 베이스라인(무작위 정책 리턴).
2. **알고리즘 선택과 이유** (1p): 후보 2개 이상, 왜 이 알고리즘을 이 환경에 골랐는가 (보상 구조 · 상태 수와 연결), 하이퍼파라미터($\alpha, \gamma, \varepsilon$ 스케줄)와 선택 근거.
3. **실험 프로토콜** (1p): 시드 목록, 학습 에피소드 수, 평가 프로토콜($\varepsilon = 0$, 에피소드 수, 모든 알고리즘 동일) 명시.
4. **결과** (1p): 시드 비교표, 학습 곡선 1장(여러 시드를 한 그림에 얇은 선으로), greedy 정책 경로 시각화.
5. **수식적 정당화** (1p): 배운 개념 1개 이상으로 "왜 이 결과".
6. **재현 방법** (0.5p): 환경 버전, 시드 목록, 에피소드 수, 하이퍼파라미터, 실행 명령. 다른 사람이 같은 곡선을 다시 얻을 수 있어야 한다.
7. **한계와 잘 안 된 부분** (0.5p, **필수**): 안 된 부분이 없었다면 무엇을 시도했다가 안 됐는지를 쓴다.

# 7. 채점 기준 (Rubric)

다섯 항목을 각 20%로 채점한다. 목적은 "좋은 정책"이 아니라 **주장을 정직하고 재현 가능하게 입증**하는 것이다.

| 항목 | 비중 | 좋은 답 |
|---|---|---|
| **1. 주장의 명확성** (clarity) | 20% | 무엇을 주장하는지 첫 문단에서 한 문장으로 알 수 있고, MDP 5요소·주 지표가 명확하며, 결과가 주장과 이어짐 |
| **2. 비교 대상** (baseline) | 20% | 무작위 정책의 평균 리턴과 알고리즘 두 가지 이상이 같은 시드·같은 평가 프로토콜로 비교됨. 비교 없는 숫자는 해석하지 않음 |
| **3. 확장성** (scalability) | 20% | 다른 시드 묶음이나 다른 환경(예: 다른 맵 크기) 하나에서도 결론이 유지되는지 확인하고, 안 통하는 조건을 적음 |
| **4. 재현성** (reproducibility) | 20% | 환경 버전·시드 목록·에피소드 수·평가 프로토콜·하이퍼파라미터·실행 방법이 적혀 있어 다른 사람이 같은 곡선을 다시 얻을 수 있음 |
| **5. 한계의 솔직함** (limitations) | 20% | 불안정했던 시드·구간, 약한 가정, 통하지 않을 환경 조건을 숨기지 않고 원인을 진단함. 성능이 낮아도 한계가 정직하면 높은 점수 |

시드 하나만 보여 주거나, 무작위 정책 비교가 없거나, 재현이 불가능하면 크게 감점받는다.

# 8. 동료평가 (Peer-Review)

- **Peer-Review**: 8주차에 다른 두 팀의 보고서에 대해 작성 리뷰를 각 1통씩 제출한다. 각 리뷰는 아래 5항목 체크리스트와, 반박 가능한 질문을 1개 이상 포함해야 한다.

**Peer-Review 체크리스트 (채점 기준과 같은 5항목)**

| 항목 | 확인할 것 |
|---|---|
| 주장의 명확성 (clarity) | 무엇을 주장하는지 분명하게 썼는가 |
| 비교 대상 (baseline) | 비교 대상이 있는가 (무작위 정책 포함) |
| 확장성 (scalability) | 다른 환경에도 적용 가능한가 |
| 재현성 (reproducibility) | 다른 사람이 다시 해 볼 수 있는가 |
| 한계 (limitations) | 한계를 솔직하게 적었는가 |

## 9. 팀 구성 및 제출 방식

- **팀 구성**: 팀당 인원 및 팀 편성 방식은 추후 공지.
- **제출물**: Abstract(3주), 보고서(PDF)와 코드(6주), peer-review 2건(8주).
- **제출 방법 및 마감**: 추후 공지 (LMS/과제 제출 시스템 및 마감 일시는 별도 안내 예정).