Machine Learning 2: 강화학습 2027. X. XX (예정)

중간 프로젝트 공고 (샘플)

Fall 2027

1. 프로젝트 개요

4∼7주차에서 배운 표 기반(tabular) 강화학습 기법(동적계획법, 몬테카를로, 시간차 학습, n-step 부트스트래핑)을 실제 Gymnasium 환경에 적용하는 학기 전반 8주에 걸쳐 진행하는 팀 프로젝트이다. 목표는 "좋은 정책을 만드는 것" 자체가 아니라 **비판적 사고력을 기르는 것**이다. 그 성능 숫자를 정직하게 얻는 절차를 실제로 수행하고, "이 숫자를 믿어도 되는가"를 스스로 따져 보며 보고한다.

진행 순서: **환경 고르기** → **Abstract** → **구현** → **평가** → **보고서 제출** → **동료평가**.

2. 필수 요구사항

- **환경**: Gymnasium의 표 기반(이산 상태 · 행동) 환경 하나 — `FrozenLake-v1`, `CliffWalking-v1`, `Taxi-v4` 등.
- **적용 알고리즘**: 4∼7주차 중 **최소 두 가지**(예: Q-learning vs SARSA, MC 제어 vs n-step TD)를 같은 환경에 적용해 학습 곡선과 최종 정책을 비교한다.
- **수식적 정당화 최소 1개**: 예 — Q-learning/SARSA 비교라면 on/off-policy 관점에서 정책이 왜 다르게 학습됐는지, ε/α 변경 실험이라면 수렴 조건과 연결, Dyna-Q라면 계획 스텝 수와 학습 속도의 관계를 직접 측정.
- **베이스라인 필수**: 무작위 정책의 평균 리턴을 먼저 측정해, "배운 정책이 실제로 무작위보다 나은가"를 판정할 기준점을 마련한다.
- **시드** ≥ 3, 모든 시드에 **동일한 평가 프로토콜**(greedy 평가 $\varepsilon = 0$, 동일 에피소드 수)을 적용한다.

3. 환경 후보 (예시)

환경	상태× 행동	보상 구조	잘 어울리는 비교
FrozenLake-v1	16×4 (미끄럼)	도착 +1, 그 외 0 (구멍 종료)	MC vs SARSA — 확률 전이에서 시드 안정성
CliffWalking-v1	48×4	스텝 −1, 절벽 −100, 도착 0	SARSA vs Q-learning — on/off-policy 클래식 비교
Taxi-v4	500×6	성공 +20, 불법 −10, 스텝 −1	n-step vs TD(0), Dyna-Q

환경 선택은 자유이지만, **4∼7주차의 개념 검증 목적**에 근거해야 한다 (상태 수, 보상 구조, 확률 전이 중 무엇이 이 비교를 정당화하는지 설명할 수 있어야 한다).

4. 시드 프로토콜

"한 번의 실행"은 아무것도 말해주지 않는다 — ε-greedy 탐험의 무작위성, 환경 전이 자체의 무작위성, 정책 초기화 때문에 같은 코드·같은 파라미터를 그대로 돌려도 매번 다른 학습 곡선이 나온다.

1. **시드** ≥ 3으로 비교할 모든 알고리즘을 전부 돌린다.
2. 학습 도중 성과(탐험 포함)와 학습 후 **greedy 평가** 성과를 반드시 분리해서 보고한다.
3. 하이퍼파라미터는 학습 곡선(validation)으로만 튜닝하고, 최종 평가 수치를 보며 조정하지 않는다.

5. 일정 (전반 8주)

시기	해야 할 일	제출
1∼2주	팀 구성, 환경 후보 2∼3개 조사 (상태 수·보상 구조·확률 전이 여부)	
3주	문제 정의(MDP 5요소, 주 지표), 선택한 환경, 무작위 정책 베이스라인과 비교할 알고리즘 계획	**Abstract** (1p)
4∼5주	두 알고리즘 구현, 시드 3개 이상 실행, ε/α 튜닝(모두 동일 프로토콜), greedy 평가, 시드 비교표	
6주 (중간고사 기간)	보고서 완성	**보고서 제출**: 보고서 PDF + 코드 + 학습 곡선
7주	제출된 다른 팀 보고서 읽기	
8주 (중간고사 기간)	다른 팀 2개에 대한 peer-review 작성	**동료평가** 제출 (리뷰 2건)

Abstract에 무작위 정책 베이스라인 계획을 넣는 이유: 이 숫자를 봐야 "배운 정책이 무작위보다 나은가"를 판정할 수 있다.

6. 보고서 구조

1. **문제 정의** (0.5p): MDP 5요소(상태 · 행동 · 전이 · 보상 · 할인율), 주 지표(greedy 평가 평균 리턴), 베이스라인(무작위 정책 리턴).
2. **알고리즘 선택과 이유** (1p): 후보 2개 이상, 왜 이 알고리즘을 이 환경에 골랐는가 (보상 구조 · 상태 수와 연결), 하이퍼파라미터($\alpha, \gamma, \varepsilon$ 스케줄)와 선택 근거.
3. **실험 프로토콜** (1p): 시드 목록, 학습 에피소드 수, 평가 프로토콜($\varepsilon = 0$, 에피소드 수, 모든 알고리즘 동일) 명시.
4. **결과** (1p): 시드 비교표, 학습 곡선 1장(여러 시드를 한 그림에 얇은 선으로), greedy 정책 경로 시각화.
5. **수식적 정당화** (1p): 배운 개념 1개 이상으로 "왜 이 결과".
6. **재현 방법** (0.5p): 환경 버전, 시드 목록, 에피소드 수, 하이퍼파라미터, 실행 명령. 다른 사람이 같은 곡선을 다시 얻을 수 있어야 한다.
7. **한계와 잘 안 된 부분** (0.5p, **필수**): 안 된 부분이 없었다면 무엇을 시도했다가 안 됐는지를 쓴다.

7. 채점 기준 (Rubric)

다섯 항목을 각 20%로 채점한다. 목적은 "좋은 정책"이 아니라 **주장을 정직하고 재현 가능하게 입증**하는 것이다.

항목	비중	좋은 답
1. 주장의 명확성 (clarity)	20%	무엇을 주장하는지 첫 문단에서 한 문장으로 알 수 있고, MDP 5요소·주 지표가 명확하며, 결과가 주장과 이어짐
2. 비교 대상 (baseline)	20%	무작위 정책의 평균 리턴과 알고리즘 두 가지 이상이 같은 시드·같은 평가 프로토콜로 비교됨. 비교 없는 숫자는 해석하지 않음
3. 확장성 (scalability)	20%	다른 시드 묶음이나 다른 환경(예: 다른 맵 크기) 하나에서도 결론이 유지되는지 확인하고, 안 통하는 조건을 적음
4. 재현성 (reproducibility)	20%	환경 버전·시드 목록·에피소드 수·평가 프로토콜·하이퍼파라미터·실행 방법이 적혀 있어 다른 사람이 같은 곡선을 다시 얻을 수 있음
5. 한계의 솔직함 (limitations)	20%	불안정했던 시드·구간, 약한 가정, 통하지 않을 환경 조건을 숨기지 않고 원인을 진단함. 성능이 낮아도 한계가 정직하면 높은 점수

시드 하나만 보여 주거나, 무작위 정책 비교가 없거나, 재현이 불가능하면 크게 감점받는다.

8. 동료평가 (Peer-Review)

- **Peer-Review**: 8주차에 다른 두 팀의 보고서에 대해 작성 리뷰를 각 1통씩 제출한다. 각 리뷰는 아래 5항목 체크리스트와, 반박 가능한 질문을 1개 이상 포함해야 한다.

Peer-Review 체크리스트 (채점 기준과 같은 5항목)

항목	확인할 것
주장의 명확성 (clarity)	무엇을 주장하는지 분명하게 썼는가
비교 대상 (baseline)	비교 대상이 있는가 (무작위 정책 포함)
확장성 (scalability)	다른 환경에도 적용 가능한가
재현성 (reproducibility)	다른 사람이 다시 해 볼 수 있는가
한계 (limitations)	한계를 솔직하게 적었는가

9. 팀 구성 및 제출 방식

- **팀 구성**: 팀당 인원 및 팀 편성 방식은 추후 공지.
- **제출물**: Abstract(3주), 보고서(PDF)와 코드(6주), peer-review 2건(8주).
- **제출 방법 및 마감**: 추후 공지 (LMS/과제 제출 시스템 및 마감 일시는 별도 안내 예정).